



# Analiza și Prognoza Seriilor de Timp

## Capitolul 1: Procese Stochastice și Staționaritate



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

## Obiective de Învățare


**La finalul acestui capitol, veți fi capabili să:**

1. **Definiți** procesele stochastice și să înțelegeți proprietățile acestora
2. **Distingeți** între staționaritatea strictă și slabă (covarianță)
3. **Identificați** procesele de zgomot alb și mers aleatoriu
4. **Calculați** și interpretați ACF și PACF
5. **Aplicați** operatorul lag și diferențierea
6. **Efectuați** teste de staționaritate (ADF, KPSS)
7. **Analizați** date financiare de tip serie de timp
8. **Distingeți** între procesele cu rădăcină unitate și cele staționare în trend

## Structura Capitolului

- Motivație
- Procese Stochastice
- Staționaritate
- Operatorul Lag și Diferențierea
- Zgomot Alb și Mers Aleatoriu
- Funcții de Autocorelație
- Testarea Staționarității
- Aplicație pe Date Financiare
- Studiu de Caz: Testarea Staționarității
- Rezumat
- Quiz

## Exemple: Serii Staționare vs. Nestaționare



- Prețurile (stânga) sunt nestaționare: trend, media se schimbă în timp
- Randamentele (dreapta) sunt staționare: medie  $\approx 0$ , varianță aprox. constantă
- Randamente log:  $r_t = \ln P_t - \ln P_{t-1}$  (mai întâi logaritmăm, apoi diferențiem): nestaționar  $\rightarrow$  staționar

## Proces Stochastic: Definiție

### Definiție 1 (Proces Stochastic)

Un **proces stochastic** este o colecție de variabile aleatoare indexate după timp:

$$\{X_t(\omega) : t \in \mathcal{T}, \omega \in \Omega\}$$

unde  $\Omega$  este spațiul eșantion al rezultatelor posibile.

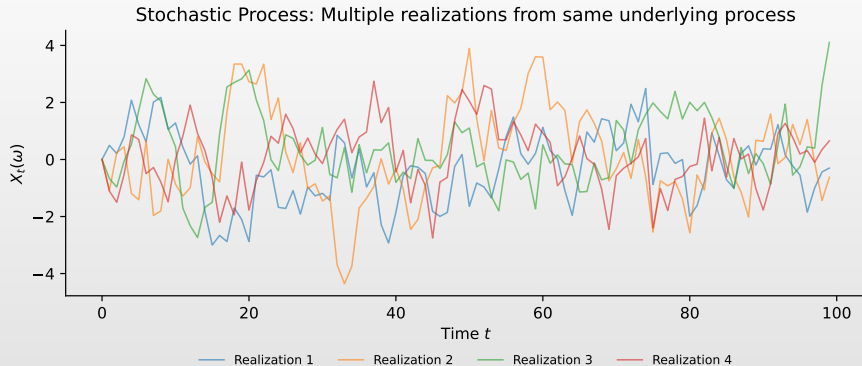
### Două Perspective

- $\omega$  **fixat**: O *realizare*  $\{X_t(\omega)\}_{t \in \mathcal{T}}$
- $t$  **fixat**: O *variabilă aleatoare*  $X_t$

### Observație Cheie

O serie de timp pe care o observăm este o **singură realizare** a procesului stochastic subiacent.

## Proces Stochastic: Ilustrare Vizuală



- Fiecare linie este o **realizare diferită** din același proces stochastic subiacent
- Observăm doar o **singură realizare**, dar vrem să înțelegem proprietățile procesului

## Momentele unui Proces Stochastic

### Primele Două Momente Caracterizează Procesul

- ▣ **Funcția de Medie:**  $\mu_t = \mathbb{E}[X_t]$
- ▣ **Autocovarianța (ACVF):**  $\gamma(t, s) = \text{Cov}(X_t, X_s) = \mathbb{E}[(X_t - \mu_t)(X_s - \mu_s)]$
- ▣ **Autocorelația (ACF):**  $\rho(t, s) = \gamma(t, s) / \sqrt{\text{Var}(X_t) \cdot \text{Var}(X_s)}$

### Proprietăți ACF

- ▣  $\rho(t, s) \in [-1, 1]$
- ▣  $\rho(t, t) = 1$  (corelație perfectă cu sine)

### Punct Cheie

- ▣  $\mu_t$  și  $\gamma(t, s)$  pot depinde de  $t$
- ▣ Staționaritatea elimină această dependență

## De ce Contează Staționaritatea

**Staționaritatea** este o ipoteză fundamentală pentru analiza seriilor de timp:

### Fără Staționaritate:

- Media, varianța se schimbă în timp
  - ▶ Estimările sunt inconsistente
- Trecutul poate să nu prezică viitorul
- Metodele standard eșuează
- Corelații false (spurioase)

### Cu Staționaritate:

- Proprietăți statistice constante
  - ▶ Ergodicitate justificată
- Putem estima dintr-o singură realizare
- Inferență validă posibilă
- Modelele sunt semnificative

### Principiu Cheie

Majoritatea modelelor de serii de timp (ARMA, ARIMA, etc.) necesită staționaritate. Seriile nestaționare trebuie transformate (de ex., diferențiere) înainte de modelare.



## Staționaritatea Strictă

### Definiție 2 (Staționaritate Strictă (Puternică))

Un proces  $\{X_t\}$  este **strict staționar** dacă pentru orice  $k$ , orice  $t_1, \dots, t_k$ , și orice  $h$ :

$$(X_{t_1}, X_{t_2}, \dots, X_{t_k}) \stackrel{d}{=} (X_{t_1+h}, X_{t_2+h}, \dots, X_{t_k+h})$$

**Notație:**  $X \stackrel{d}{=} Y$  înseamnă *egalitate în distribuție*:  $P(X \leq x) = P(Y \leq x)$  pentru toți  $x$ .

### Implicații


- ▣ Toate distribuțiile marginale  $F_{X_t}(x)$  identice
- ▣  $\mathbb{E}[X_t] = \mu$  (medie constantă, dacă există)
- ▣  $\text{Var}(X_t) = \sigma^2$  (varianță constantă, dacă există)
- ▣ Distribuțiile comune depind doar de lag

### Notă


Staționaritatea strictă este o condiție puternică, adesea imposibil de verificat în practică.

## Staționaritatea Strictă: Ilustrare Vizuală

Strictly Stationary: Joint distribution unchanged by time shift



Non-Stationary: Distribution changes with time



- Translația în timp nu schimbă distribuția comună a variabilelor
- Oricare două ferestre temporale au aceleași proprietăți statistice
- În practică: verificăm doar primele momente (staționaritate slabă)

## Staționaritatea Slabă (Covarianță)

### Definiție 3 (Staționaritate Slabă)

Un proces  $\{X_t\}$  este **slab staționar** (sau staționar în covarianță) dacă:

1.  $\mathbb{E}[X_t^2] < \infty$  pentru toți  $t$  (momente finite de ordin 2)
2.  $\mathbb{E}[X_t] = \mu$  pentru toți  $t$  (medie constantă)
3.  $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$  (covarianța depinde doar de lag-ul  $h$ , nu de  $t$ )

**Proprietate cheie:** Autocovarianța este o funcție doar de lag:


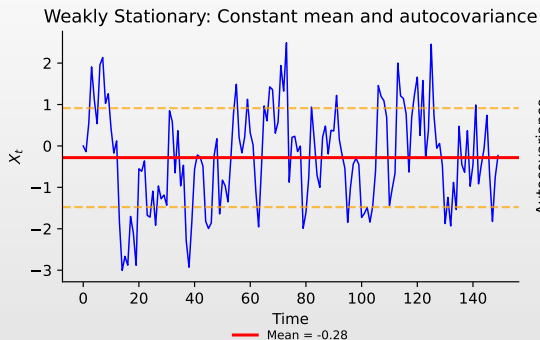
$$\gamma(h) = \text{Cov}(X_t, X_{t+h}) = \mathbb{E}[(X_t - \mu)(X_{t+h} - \mu)]$$

**Funcția de autocorelație:**

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)} = \frac{\text{Cov}(X_t, X_{t+h})}{\text{Var}(X_t)}$$

Notă:  $\rho(0) = 1$ ,  $|\rho(h)| \leq 1$  și  $\rho(h) = \rho(-h)$  (simetrie)

## Staționaritatea Slabă: Ilustrare Vizuală



- $\mathbb{E}[X_t] = \mu$  constantă — media nu depinde de timp
- $\text{Var}(X_t) = \sigma^2$  constantă — varianța nu depinde de timp
- $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$  — autocovarianța depinde doar de lag  $h$

## Relația între Staționaritate Strictă și Slabă

### Teoremă 1 (Implicație Fundamentală)

Dacă  $\{X_t\}$  este **strict staționar** și  $\mathbb{E}[X_t^2] < \infty$ , atunci  $\{X_t\}$  este și **slab staționar**.

### Demonstrație.

Fie  $t_1, t_2$  oarecare și  $h$  deplasare temporală arbitrară.

Din invarianța distribuției comune:  $(X_{t_1}, X_{t_2}) \stackrel{d}{=} (X_{t_1+h}, X_{t_2+h})$

(i)  $\mathbb{E}[X_{t_1}] = \mathbb{E}[X_{t_1+h}] = \mu$  (medie constantă)

(ii)  $\text{Cov}(X_{t_1}, X_{t_2}) = \text{Cov}(X_{t_1+h}, X_{t_2+h})$

Deci autocovarianța depinde doar de diferența  $t_2 - t_1 = h$ , nu de  $t_1$ .




**Atenție: Reciproca NU este adevărată!**

Există procese slab staționare dar **nu** strict staționare.

## Contraexemplu: Slab Staționar dar NU Strict Staționar

### Construcție

Fie  $\{X_t\}$  variabile aleatoare **independente** cu:  $t$  par:  $X_t \sim N(0, 1)$ ;  $t$  impar:  $X_t \sim \frac{\chi^2(5) - 5}{\sqrt{10}}$



**Slab staționar** ✓:  $\mathbb{E}[X_t] = 0$ ,  $\text{Var}(X_t) = 1$ ,  
 $\text{Cov}(X_t, X_{t+h}) = 0$  pentru orice  $t$

**NU strict staționar** ✗: Asimetria diferă ( $0$  vs  $> 0$ )  $\Rightarrow$   
 $X_1 \stackrel{d}{\neq} X_2$

## Proprietățile Funcției de Autocovarianță

### Propoziție 1

Pentru un proces slab staționar, ACVF  $\gamma(h)$  satisface:

1. **Simetrie:**  $\gamma(h) = \gamma(-h)$
2. **Maximum la zero:**  $|\gamma(h)| \leq \gamma(0) = \text{Var}(X_t)$
3. **Definit nenegativ:**  $\sum_{i,j} a_i a_j \gamma(i-j) \geq 0$  pentru orice  $a_1, \dots, a_n$

### Demonstrație (prop. 3)

$$\text{Var} \left( \sum_{i=1}^n a_i X_{t+i} \right) = \sum_{i,j} a_i a_j \gamma(i-j) \geq 0 \quad (\text{varianța} \geq 0)$$

**Implicație:** Nu orice funcție poate fi o funcție de autocovarianță validă.

## Ergodicitatea: Fundamentul Inferenței din Date

### Definiție 4 (Ergodicitate pentru Medie)

Un proces staționar  $\{X_t\}$  este **ergodic pentru medie** dacă:  $\bar{X}_T = \frac{1}{T} \sum_{t=1}^T X_t \xrightarrow{P} \mathbb{E}[X_t] = \mu$  când  $T \rightarrow \infty$

### De ce contează ergodicitatea?


- Avem doar **o singură realizare** a procesului stochastic
- Ergodicitatea permite estimarea lui  $\mu$  din media eșantionului  $\bar{X}_T$
- **Fără ergodicitate, inferența statistică nu este posibilă!**

### Teoremă 2 (Condiție Suficientă)

Dacă  $\sum_{h=0}^{\infty} |\gamma(h)| < \infty$  (autocovarianțe absolut sumabile), procesul este ergodic.



## Ergodicitatea: Ilustrare Vizuală



- Media temporală (o singură realizare) și media ansamblului (realizări multiple) converg ambele la  $\mu$
- Ergodicitatea garantează că putem estima  $\mu$  dintr-o singură serie temporală suficient de lungă

## Teorema de Descompunere Wold

### Teoremă 3 (Wold, 1938)

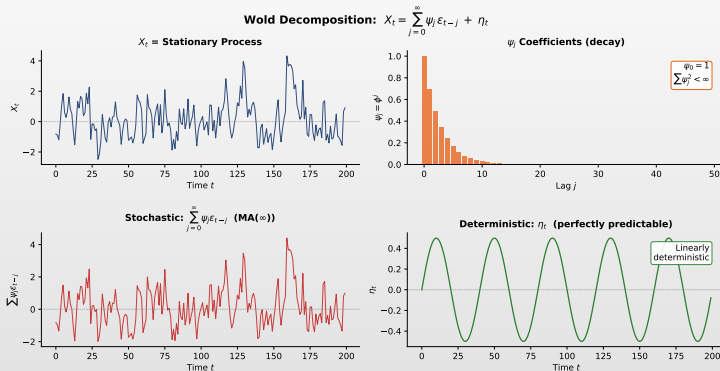
Orice proces **staționar în covarianță**  $\{X_t\}$  poate fi scris ca:  $X_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + \eta_t$

- ▣  $\varepsilon_t \sim WN(0, \sigma^2)$  — zgomot alb;  $\psi_0 = 1$ ,  $\sum \psi_j^2 < \infty$
- ▣  $\eta_t$  — componenta deterministă (perfect predictibilă)

### Semnificația Teoremei Wold

- ▣ Orice proces staționar = **medie mobilă infinită** + componentă deterministă
- ▣ Justifică teoretic modelele  $MA(q)$  și  $ARMA(p, q)$
- ▣ Coeficienții  $\psi_j$  măsoară impactul șocurilor trecute

## Teorema Wold: Ilustrare Vizuală



- $X_t$  se descompune în componentă **stochastică** (MA( $\infty$ )) și componentă **deterministă** ( $\eta_t$ )
- Coeficienții  $\psi_j$  descresc — șocurile recente au impact mai mare decât cele îndepărtate

## Operatorul Lag

### Definiție 5 (Operatorul Lag)

**Operatorul lag** (sau operatorul de întârziere)  $L$  este definit prin:

$$LX_t = X_{t-1}$$

### Proprietăți


- $L^k X_t = X_{t-k}$  (întârzie cu  $k$  perioade)
  - ▶ Notăție compactă pentru modele
- $L^0 = I$  (identitate)
- $(1 - \phi L)X_t = X_t - \phi X_{t-1}$

### Exemple

- $(1 - L)X_t = X_t - X_{t-1}$  (prima diferență)
- $(1 - L)^2 X_t = \Delta^2 X_t$  (a doua diferență)
- $(1 - L^{12})X_t$  (diferență sezonieră)

## Operatorul Lag: Ilustrare Vizuală

Lag Operator:  $LX_t = X_{t-1}$ , shifts series back by one period



- $LX_t = X_{t-1}$  — operatorul lag deplasează seria cu o perioadă în trecut
- $L^k X_t = X_{t-k}$  — deplasare cu  $k$  perioade;  $L^0 = I$  (identitate)
- **Operatorul diferență:**  $\Delta = (1 - L)$ , astfel  $\Delta X_t = X_t - X_{t-1}$

## Diferențierea

**Prima Diferență:**  $\Delta X_t = X_t - X_{t-1} = (1 - L)X_t$

**De ce Diferențiem?**

- Elimină trendul și rădăcina unitate
- Mers aleatoriu:  $\Delta X_t = \varepsilon_t$  (zgomot alb)

### Definiție 6 (Proces Integrat de Ordin $d$ )

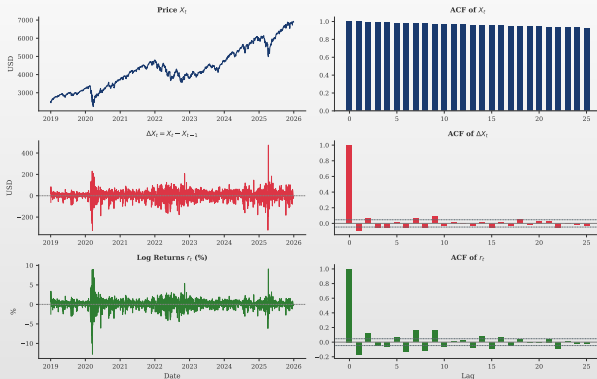
Un proces  $\{X_t\}$  este **integrat de ordin  $d$** , notat  $X_t \sim I(d)$ , dacă:

1.  $\Delta^d X_t = (1 - L)^d X_t$  este staționar ( $I(0)$  proces)
2.  $\Delta^{d-1} X_t$  **nu** este staționar

**Exemple:**

- $I(0)$ : Proces staționar (zgomot alb, AR staționar)
- $I(1)$ : Mers aleatoriu —  $\Delta X_t = \varepsilon_t$  este staționar
- $I(2)$ : Necesită două diferențieri pentru staționaritate

## Efectul Diferențierii: S&amp;P 500



- **Sus:** Prețuri S&P 500 — trend clar, nestaționar ( $I(1)$ )
- **Jos:** Randamente  $\log r_t = \ln P_t - \ln P_{t-1}$  — fluctuează în jurul mediei  $\approx 0$ , staționar

## Transformări pentru Stabilizarea Varianței

### Problema: Varianță Nestaționară

Multe serii economice au varianță care crește cu nivelul  $\Rightarrow$  **heteroscedasticitate**

#### Transformarea Logaritmică

$$Y_t = \log(X_t)$$

- ▣ Stabilizează varianța când  $\sigma_t \propto \mu_t$
- ▣ Interpretare: variații procentuale
- ▣ **Randamente log:**  $r_t = \log(P_t) - \log(P_{t-1})$

#### Transformarea Box-Cox

$$Y_t^{(\lambda)} = \begin{cases} \frac{X_t^\lambda - 1}{\lambda} & \lambda \neq 0 \\ \log(X_t) & \lambda = 0 \end{cases}$$

- ▣  $\lambda = 1$ : fără transformare
- ▣  $\lambda = 0.5$ : rădăcină pătrată
- ▣  $\lambda = 0$ : logaritm
- ▣  $\lambda$  se estimează din date



## Fluxul Complet: Log + Diferențiere

### Secvența Standard pentru Serii Financiare

1. **Date brute:** Prețuri  $P_t$  (nestaționare, varianță crescătoare)
2. **Logaritmare:**  $\log(P_t)$  (stabilizează varianța, încă nestaționară)
3. **Diferențiere:**  $\Delta \log(P_t) = \log(P_t) - \log(P_{t-1}) \approx r_t$  (staționară!)


### De ce funcționează?

- **Log:**  $\sigma \propto \mu \Rightarrow \sigma_{\log} \approx \text{const}$
- **Diferența:** elimină trendul
- **Combinația:** serie staționară

### Atenție la Ordine!

- **Corect:** Log  $\rightarrow$  Diferențiere
- Diferențierea fără log poate lăsa heteroscedasticitate
- Pentru date non-pozitive: Box-Cox cu shift

## Transformări: Ilustrare Vizuală



- $P_t \xrightarrow{\log} \log(P_t) \xrightarrow{\Delta} \text{Randamente } \log r_t$  — secvența standard de transformare
- Logaritmul stabilizează varianța; diferențierea elimină trendul  $\Rightarrow$  serie staționară

## Procesul de Zgomot Alb

### Definiție 7 (Zgomot Alb)

Un proces  $\{\varepsilon_t\}$  este **zgomot alb**, notat  $\varepsilon_t \sim WN(0, \sigma^2)$ , dacă:

1.  $\mathbb{E}[\varepsilon_t] = 0$  pentru orice  $t$
2.  $\text{Var}(\varepsilon_t) = \sigma^2$  pentru orice  $t$
3.  $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$  pentru  $t \neq s$

### ACF al Zgomotului Alb

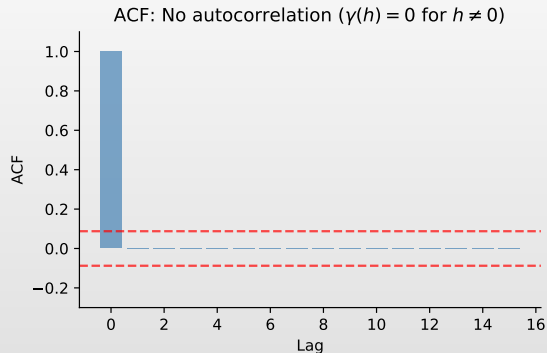

Din definiție:  $\gamma(0) = \sigma^2$  și  $\gamma(h) = \text{Cov}(\varepsilon_t, \varepsilon_{t+h}) = 0$  pentru  $h \neq 0$ . Deci:

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)} = \begin{cases} 1 & h = 0 \\ 0 & h \neq 0 \end{cases}$$

**Tipuri de zgomot alb** (în ordine crescătoare a restricțiilor):

1. **Slab (Weak WN)**: doar (1)–(3) de mai sus (necorelat, dar pot exista dependențe neliniare)
2. **Puternic (Strong WN)**:  $\varepsilon_t$  sunt *independente* și identic distribuite (i.i.d.)
3. **Gaussian WN**:  $\varepsilon_t \stackrel{iid}{\sim} N(0, \sigma^2)$  — necorelat  $\Rightarrow$  independent (distincția slab/puternic dispare)

## Zgomot Alb: Ilustrare Vizuală



## Procesul de Mers Aleatoriu

### Definiție 8 (Mers Aleatoriu)

$X_t = X_{t-1} + \varepsilon_t$  unde  $\varepsilon_t \sim WN(0, \sigma^2)$ ,  $X_0 = 0$     **Forma explicită:**  $X_t = \sum_{i=1}^t \varepsilon_i$

### Propoziție 2 (Proprietăți)

(i)  $\mathbb{E}[X_t] = 0$     (ii)  $\text{Var}(X_t) = t\sigma^2$     (iii)  $\text{Cov}(X_t, X_s) = \min(t, s) \cdot \sigma^2$

### Demonstrații.

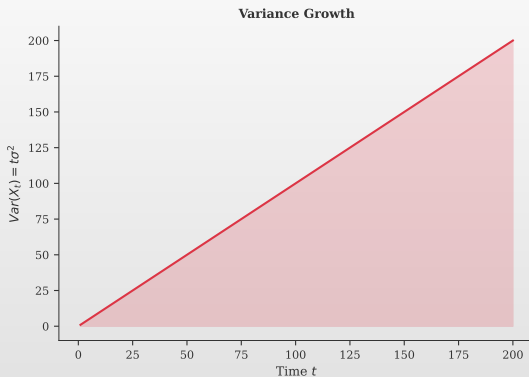

(i)  $\mathbb{E}[X_t] = \mathbb{E}[\sum_{i=1}^t \varepsilon_i] = \sum_{i=1}^t \mathbb{E}[\varepsilon_i] = 0$     (ii)  $\text{Var}(X_t) = \text{Var}(\sum_{i=1}^t \varepsilon_i) \stackrel{\text{indep.}}{=} \sum_{i=1}^t \text{Var}(\varepsilon_i) = t\sigma^2$

(iii) Fie  $s \leq t$ :  $\text{Cov}(X_t, X_s) = \text{Cov}(\sum_{i=1}^t \varepsilon_i, \sum_{j=1}^s \varepsilon_j) = \sum_{i=1}^s \sigma^2 = \min(t, s) \sigma^2$  □

### Nestaționar!

$\text{Var}(X_t) = t\sigma^2$  depinde de  $t \Rightarrow$  mersul aleatoriu **nu este staționar**

## Mers Aleatoriu: Vizualizare



- Fiecare șoc are **efect permanent**;  $\text{Var}(X_t) = t\sigma^2$  crește liniar cu timpul
- **Soluție:** Diferențierea transformă în zgomot alb:  $\Delta X_t = \varepsilon_t$

## Zgomot Alb vs Mers Aleatoriu: Comparație





## Zgomot Alb

- Staționar
- $\text{Var} = \sigma^2$  (const.)
- $\text{ACF} = 0, h \neq 0$
- Fără memorie

## Mers Aleatoriu




- Nestaționar
- $\text{Var} = t\sigma^2$  (crește)
- $\text{ACF} \approx 1$  (lent)
- Șocuri permanente

Legătură:  $\Delta X_t = \varepsilon_t$



— White Noise — Random Walk — 95% CI

## Comparație ACF: Staționar vs Mers Aleatoriu



- **Staționar:** ACF scade rapid (exponențial sau oscilant) spre zero
- **Mers aleatoriu:** ACF scade foarte lent, rămâne aproape de 1
- **Regulă practică:** ACF lent  $\Rightarrow$  suspectăm rădăcină unitate  $\Rightarrow$  test ADF



## Funcția de Autocorelație Eșantion

### ACF Eșantion la Lag-ul $h$

$$\hat{\rho}(h) = \frac{\sum_{t=1}^{T-h} (x_t - \bar{x})(x_{t+h} - \bar{x})}{\sum_{t=1}^T (x_t - \bar{x})^2} \quad \text{Proprietăți: } \hat{\rho}(0) = 1, |\hat{\rho}(h)| \leq 1$$

### Teoremă 4 (Bartlett, 1946)

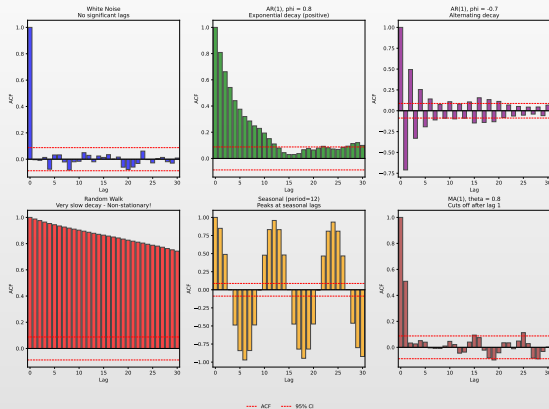
Sub  $H_0$ : zgomot alb, pentru  $T$  mare:  $\hat{\rho}(h) \approx N(0, 1/T)$

**Interval de încredere 95%:**  $\pm \frac{1.96}{\sqrt{T}}$  (benzile din graficele ACF)

### Atenție

Formula Bartlett validă **doar sub**  $H_0$ : **zgomot alb**. Pentru AR/MA, varianța asimptotică diferă.

## Tipare ACF pentru Diferite Procese



- **Zgomot alb:**  $ACF = 0$ ; **Staționar:** scade rapid; **Nestaționar:** scade lent
- **Sezonier:** Vârfuri la lag-uri sezonale (12, 24 pentru date lunare)

## Funcția de Autocorelație Parțială (PACF)

### Definiție 9 (Autocorelația Parțială)

**PACF** la lag-ul  $h$ , notat  $\phi_{hh}$ , este ultimul coeficient din regresia liniară:

$$X_t = \phi_{h1}X_{t-1} + \phi_{h2}X_{t-2} + \cdots + \phi_{hh}X_{t-h} + e_t$$

**Alternativ:**  $\phi_{hh} = \text{Corr}(X_t - \hat{X}_t^{(h-1)}, X_{t-h} - \hat{X}_{t-h}^{(h-1)})$

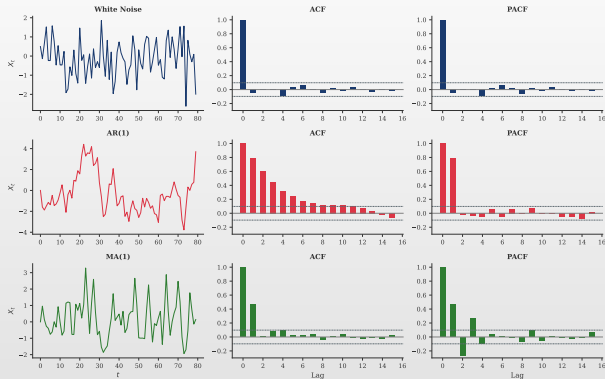
unde  $\hat{X}_t^{(h-1)}$  este predicția liniară bazată pe  $\{X_{t-1}, \dots, X_{t-h+1}\}$ .

**Interpretare:** Măsoară dependența *directă* la lag-ul  $h$ , eliminând efectul lag-urilor intermediare.

### Aplicație Cheie: Identificarea Ordinului Modelului

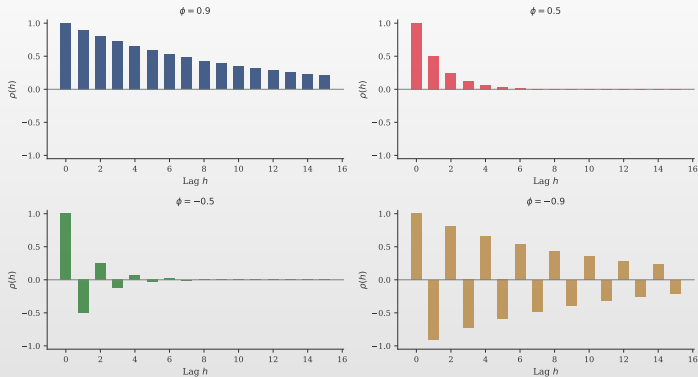
- Pentru  $\text{AR}(p)$ : PACF se **întrerupe** (devine zero) după lag-ul  $p$
- Pentru  $\text{MA}(q)$ : ACF se **întrerupe** după lag-ul  $q$

## Tipare ACF și PACF



- ▣ **AR( $p$ ):** ACF scade exponențial, PACF se întrerupe după lag  $p$
- ▣ **MA( $q$ ):** ACF se întrerupe după lag  $q$ , PACF scade exponențial
- ▣ **ARMA( $p, q$ ):** Ambele scad exponențial — identificarea necesită criterii informaționale

## Tipare de Scădere ACF



- ▣ **Scădere exponențială:** Dependență pozitivă persistentă (AR cu  $\phi > 0$ )
- ▣ **Scădere oscilantă:** Dependență alternantă (AR cu  $\phi < 0$ )
- ▣ Viteza de scădere indică puterea memoriei procesului

## Testul Augmented Dickey-Fuller (ADF)

**Modelul:**  $\Delta X_t = \alpha + \gamma X_{t-1} + \sum_{i=1}^p \delta_i \Delta X_{t-i} + \varepsilon_t$

**Notă:** Dacă modelul original este  $X_t = \rho X_{t-1} + \varepsilon_t$ , atunci  $\gamma = \rho - 1$ .

Astfel,  $H_0 : \gamma = 0$  este echivalent cu  $\rho = 1$  (rădăcină unitate).

### Ipoteze

- $H_0: \gamma = 0$  (rădăcină unitate)
- $H_1: \gamma < 0$  (staționar)

### Statistica de Test

$$\tau_{ADF} = \frac{\hat{\gamma}}{SE(\hat{\gamma})}$$

### Regula de Decizie

$\tau_{ADF} < \text{valoarea critică} \Rightarrow$  Respingem  $H_0 \Rightarrow$  Staționar

$\tau_{ADF} \geq \text{valoarea critică} \Rightarrow$  Nestaționar (rădăcină unitate)

**Important:** Valorile critice urmează distribuția Dickey-Fuller, **nu** distribuția normală sau  $t$ -Student.

## Testul KPSS

### Modelul

$$X_t = \xi t + r_t + \varepsilon_t \text{ unde } r_t = r_{t-1} + u_t$$

### Ipoteze (opus ADF)

- $H_0: \sigma_u^2 = 0$  (staționar)
- $H_1: \sigma_u^2 > 0$  (rădăcină unitate)

### Statistica de Test

$$LM = \frac{\sum_{t=1}^T S_t^2}{T^2 \hat{\sigma}^2}$$

$$\text{unde } S_t = \sum_{i=1}^t \hat{e}_i$$

### Regula de Decizie

$LM > \text{valoarea critică} \Rightarrow \text{Respingem } H_0 \Rightarrow \text{Nestaționar}$

$LM \leq \text{valoarea critică} \Rightarrow \text{Staționar}$

## Folosirea ADF și KPSS Împreună

### Testare Confirmatorie

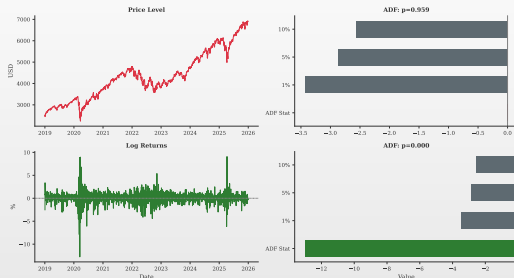
ADF	KPSS	Concluzie
Resp. $H_0$	Nu resp. $H_0$	Staționar
Nu resp. $H_0$	Resp. $H_0$	Rădăc. Unit.
Resp. $H_0$	Resp. $H_0$	Neconcludent
Nu resp. $H_0$	Nu resp. $H_0$	Neconcludent

### Flux de Lucru

1. Test ADF ( $H_0$ : rădăcină)
2. Test KPSS ( $H_0$ : staționar)
3. Rezultate concordante  $\Rightarrow$  OK
4. Altfel: teste PP, DF-GLS



## Testul ADF: Vizualizare cu S&amp;P 500

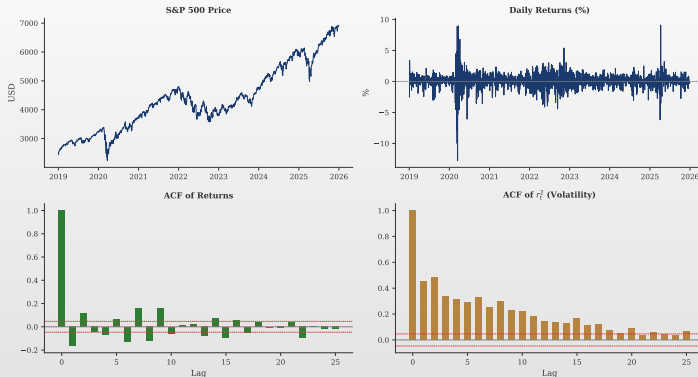


TSA\_ch1\_unit\_root\_tests

## Interpretarea Testului ADF


- $H_0$ : Rădăcină unitate; Valori critice:  $-3.43$  (1%),  $-2.86$  (5%),  $-2.57$  (10%)
- $\tau < \text{val. critică} \Rightarrow \text{respingem } H_0 \Rightarrow \text{serie staționară}$
- S&P 500: Prețuri nestaționare; Randamente staționare

## Analiza S&P 500: Prezentare Generală



- ▣ **Prețuri:** Trend ascendent, nestăionar; **Randamente:** Medie  $\approx 0$ , staționar
- ▣ **ACF randamente:**  $\approx 0$  (eficient); **ACF  $r_t^2$ :** Semnificativ (volatility clustering)

## Fapte Stilizate ale Randamentelor Financiare




### Proprietăți observate:

- ▣ Asimetrie negativă (coadă stângă)
- ▣ Kurtoză excesivă ( $\gg 3$ )
- ▣ Cozi groase (heavy tails)

### Implicații:


- ▣ Distribuția normală inadecvată
- ▣ Evenimente extreme mai probabile
- ▣ Necesită Student-t sau GED

## Volatility Clustering



- ▣ Randamente mari (în valoare absolută) urmate de randamente mari
- ▣ Perioade de calm urmate de perioade de calm
- ▣ **Volatilitate variabilă în timp**  $\Rightarrow$  modele ARCH/GARCH (Cap. 5)

## Studiu de Caz: PIB-ul Trimestrial al României



TSA\_ch1\_case\_gdp

### Analiza Inițială

- **Date:** PIB trimestrial România 2010–2023 (56 obs., INS/Eurostat)
- **Observații:** Trend ascendent, șoc COVID-19, posibil sezonier
- **Ipoteză:** Serie nestaționară — testăm cu ADF și KPSS

## Testarea Staționarității: ADF și KPSS

### Testul ADF

- $H_0$ : Rădăcină unitate
- Stat. ADF:  $-1.23$
- Val. critică:  $-2.89$
- Nu respingem  $H_0$

### Testul KPSS

- $H_0$ : Staționară
- Stat. KPSS:  $0.89$
- Val. critică:  $0.46$
- Respingem  $H_0$

### Concluzie: Ambele Teste Concordă

Seria PIB este **nestaționară** — necesită diferențiere

## Diferențierea: Transformare la Staționaritate

### După Diferențiere

- ▣ ADF:  $-4.56$  ( $p < 0.01$ )
- ▣ KPSS:  $0.21$  ( $p > 0.10$ )
- ▣ Ambele: staționară!

### Concluzie

- ▣ PIB nivel: nestaționar
- ▣  $\Delta$ PIB: staționar
- ▣ Folosim  $\Delta PIB_t$  pentru modelare

### Rezultat Final

PIB-ul necesită o diferențiere pentru a deveni staționar.

## Concluzii Principale

### Rezumat

1. **Proces stochastic** = colecție de variabile aleatoare indexate în timp
2. **Staționaritate slabă**: medie, varianță, autocovarianță constante
3. **Zgomot alb**:  $\varepsilon_t \sim WN(0, \sigma^2)$  — staționar,  $ACF = 0$
4. **Mers aleatoriu**:  $X_t = X_{t-1} + \varepsilon_t$  — nestaționar,  $Var(X_t) = t\sigma^2$
5. **ACF/PACF**: Instrumente cheie pentru identificarea structurii
6. **Diferențierea**: Transformă serii nestaționare în staționare
7. **Teste rădăcină unitate**: ADF ( $H_0$ : rădăcină unitate) vs KPSS ( $H_0$ : staționar)



## Formule Importante

### Staționaritate Slabă

- ▣  $\mathbb{E}[X_t] = \mu$  (medie constantă)
- ▣  $\text{Var}(X_t) = \sigma^2$  (varianță constantă)
- ▣  $\gamma(h) = \text{Cov}(X_t, X_{t+h})$
- ▣  $\rho(h) = \gamma(h)/\gamma(0)$

### Operatorul Lag

- ▣  $LX_t = X_{t-1}$
- ▣  $\Delta X_t = (1 - L)X_t$

### Zgomot Alb (WN)

- ▣  $\varepsilon_t \sim WN(0, \sigma^2)$
- ▣  $\rho(h) = 0$  pentru  $h \neq 0$

### Mers Aleatoriu (RW)

- ▣  $X_t = X_{t-1} + \varepsilon_t$
- ▣  $\text{Var}(X_t) = t\sigma^2$  (crește!)

## Previzualizare Capitolul Următor

### Capitolul 2: Modele ARMA

- ▣ Modele Autoregresive  $AR(p)$
- ▣ Modele Medie Mobilă  $MA(q)$
- ▣ Modele  $ARMA(p, q)$  combinate
- ▣ Identificare cu ACF/PACF

### Ce Vom Învăța

- ▣ Estimarea parametrilor
- ▣ Diagnosticarea modelului
- ▣ Prognoză și intervale de încredere
- ▣ Selecția modelului (AIC, BIC)



## Întrebarea 1

### Întrebare

Care sunt cele trei condiții pentru staționaritatea slabă (în covarianță)?

- (A) Media zero, varianța infinită, covarianță dependentă de timp
- (B) Media constantă, varianța constantă, autocovarianța depinde doar de lag
- (C) Distribuție normală, independență, varianță unitară
- (D) Trend liniar, sezonaliitate constantă, reziduuri albe

## Întrebarea 1: Răspuns



Răspuns: (B) —  $\mathbb{E}[X_t] = \mu$ ,  $\text{Var}(X_t) = \sigma^2$ ,  $\gamma(t, s) = \gamma(|t - s|)$

 TSA\_ch1\_stationarity

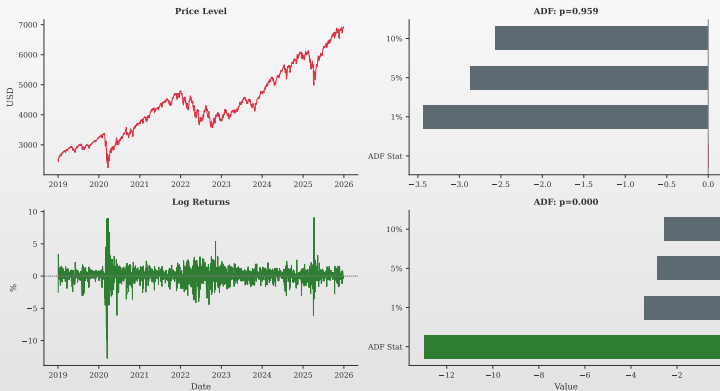
## Întrebarea 2

### Întrebare

Care este ipoteza nulă ( $H_0$ ) în testul ADF (Augmented Dickey-Fuller)?

- (A) Seria este staționară
- (B) Seria are rădăcină unitate (este nestaționară)
- (C) Seria nu are autocorelație
- (D) Seria are distribuție normală

## Întrebarea 2: Răspuns



**Răspuns: (B)** —  $H_0$ : rădăcină unitate;  $\tau < \text{val. critică} \Rightarrow$  staționară

 TSA\_ch1\_unit\_root\_tests


## Întrebarea 3

### Întrebare

Care este ipoteza nulă ( $H_0$ ) în testul KPSS?

- (A) Seria are rădăcină unitate (nestaționară)
- (B) Seria este staționară
- (C) Seria este un mers aleatoriu
- (D) Seria are trend determinist

## Întrebarea 3: Răspuns



**Răspuns: (B)** — KPSS:  $H_0$  staționară (opus ADF). Folosiți ambele teste!

 **TSA\_ch1\_stationarity**





## Întrebarea 4

### Întrebare

Care este proprietatea cheie a varianței unui mers aleatoriu  $X_t = X_{t-1} + \varepsilon_t$ ?

- (A) Varianța este constantă:  $\text{Var}(X_t) = \sigma^2$
- (B) Varianța crește liniar cu timpul:  $\text{Var}(X_t) = t\sigma^2$
- (C) Varianța scade cu timpul
- (D) Varianța este zero

## Întrebarea 4: Răspuns



**Răspuns: (B)** —  $\text{Var}(X_t) = t\sigma^2$  crește liniar  $\Rightarrow$  nestăionar

 TSA\_ch1\_random\_walk

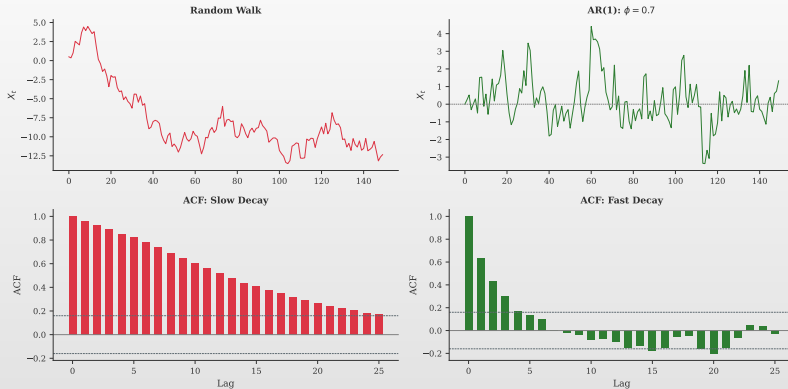
## Întrebarea 5

### Întrebare

Cum arată ACF-ul unui mers aleatoriu (serie nestaționară cu rădăcină unitate)?

- (A) Toate valorile sunt zero după lag 0
- (B) Scade exponențial rapid
- (C) Scade foarte lent (persistență înaltă)
- (D) Oscilează între pozitiv și negativ

## Întrebarea 5: Răspuns



**Răspuns: (C)** — ACF  $\approx 1$  pentru multe lag-uri, scădere lentă  $\Rightarrow$  test ADF

 TSA\_ch1\_random\_walk

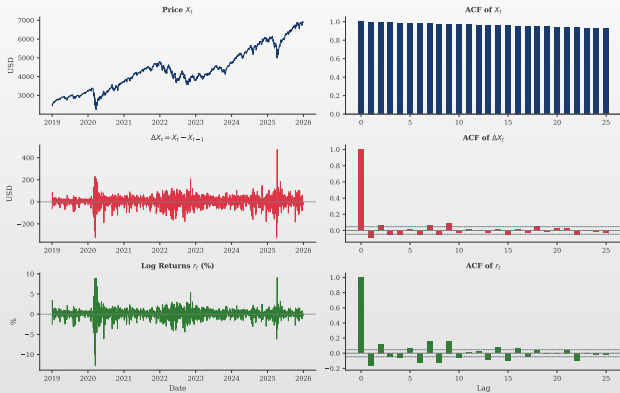
## Întrebarea 6

### Întrebare

Cum obținem randamente staționare dintr-o serie de prețuri financiare  $P_t$ ?

- (A) Diferențiere simplă:  $\Delta P_t = P_t - P_{t-1}$
- (B) Logaritmare apoi diferențiere:  $r_t = \ln P_t - \ln P_{t-1}$
- (C) Doar logaritmare:  $\ln P_t$
- (D) Standardizare:  $(P_t - \bar{P})/s_P$

## Întrebarea 6: Răspuns



**Răspuns: (B)** — Randamente log:  $r_t = \ln P_t - \ln P_{t-1}$ . Mai întâi  $\ln$  (stabilizează varianța), apoi  $\Delta$  (elimină trendul)  $\Rightarrow$  serie staționară.

 TSA\_ch1\_differencing

## Bibliografie

### Manuale Fundamentale

- ▣ Hyndman & Athanasopoulos (2021). *Forecasting*, OTexts
- ▣ Shumway & Stoffer (2017). *Time Series Analysis*, Springer
- ▣ Hamilton (1994). *Time Series Analysis*, Princeton

### Referințe Clasice

- ▣ Wold (1938). *Analysis of Stationary Time Series*
- ▣ Bartlett (1946). "Sampling Properties", *JRSS*

### Resurse Online

- ▣ **Quantlet**: <https://quantlet.com> — cod statistică
- ▣ **Quantinar**: <https://quantinar.com> — tutoriale
- ▣ **GitHub**: <https://github.com/QuantLet/TSA>

## Surse de Date și Software

### Date Utilizate

- ▣ **S&P 500:** Yahoo Finance
  - ▶ Prețuri, randamente
- ▣ **PIB România:** INS/Eurostat
  - ▶ Date trimestriale
- ▣ **Cursuri valutare:** BNR

### Software

- ▣ **Python:** statsmodels, pandas, matplotlib, scipy
- ▣ **R:** forecast, tseries, urca
- ▣ **Date:** Yahoo Finance, FRED, Eurostat



# Vă Mulțumim!

Întrebări?

*Graficele au fost generate folosind Python (statsmodels, matplotlib)*

Materialele cursului sunt disponibile la: <https://github.com/danpele/Time-Series-Analysis>