



Analiza și Prognoza Seriilor de Timp

Capitolul 1: Introducere în Serii de Timp

Fundamente și Concepte



La sfârșitul acestui capitol, veți fi capabili să:

1. **Înțelegeți** procesele stochastice și realizările lor
2. **Definiți** staționaritatea strictă și slabă (de covarianță)
3. **Distingeți** între zgomot alb și mers aleatoriu
4. **Calculați** și interpretați funcția de autocorelație (ACF)
5. **Aplicați** funcția de autocorelație parțială (PACF)
6. **Utilizați** operatorul lag și diferențierea
7. **Efectuați** testul ADF pentru rădăcină unitate
8. **Aplicați** testul KPSS și interpretați rezultatele combinate

Structura Capitolului

- 1 Procese Stochastice
- 2 Staționaritatea
- 3 Zgomot Alb și Mers Aleatoriu
- 4 Funcții de Autocorelație
- 5 Operatorul Lag și Diferențierea
- 6 Testarea Staționarității
- 7 Aplicație pe Date Financiare
- 8 Rezumat
- 9 Quiz
- 10 Studiu de Caz: PIB România
- 11 Referințe

Definiție 1 (Proces Stochastic)

Un **proces stochastic** este o colecție de variabile aleatoare indexate după timp:


$$\{X_t(\omega) : t \in \mathcal{T}, \omega \in \Omega\}$$

unde Ω este spațiul de selecție al rezultatelor posibile.

Două perspective:

- ω **fix**: O *realizare* sau *trajectorie de selecție* $\{X_t(\omega)\}_{t \in \mathcal{T}}$
- t **fix**: O *variabilă aleatoare* X_t cu distribuția $F_t(x)$

Observație cheie: O serie de timp pe care o observăm este o **realizare** a procesului stochastic subiacent. Folosim această singură realizare pentru a deduce proprietățile procesului.



Fiecare linie este o realizare diferită din același proces stochastic subiacent. Observăm doar o realizare dar vrem să înțelegem procesul.

Momentele unui Proces Stochastic

Primele două momente caracterizează proprietățile slabe:

Funcția de Medie: $\mu_t = \mathbb{E}[X_t]$

Funcția de Autocovarianță (ACVF):

$$\gamma(t, s) = \text{Cov}(X_t, X_s) = \mathbb{E}[(X_t - \mu_t)(X_s - \mu_s)]$$

Funcția de Autocorelație (ACF):

$$\rho(t, s) = \frac{\gamma(t, s)}{\sqrt{\text{Var}(X_t) \cdot \text{Var}(X_s)}}$$

Proprietăți: $\rho(t, s) \in [-1, 1]$ și $\rho(t, t) = 1$

De Ce Contează Staționaritatea

Staționaritatea este o ipoteză fundamentală pentru analiza seriilor de timp:

Fără Staționaritate:

- Media, varianța se schimbă în timp
- Trecutul poate să nu prezică viitorul
- Metodele standard eșuează
- Corelații false



Cu Staționaritate:

- Proprietăți statistice constante
- Putem estima din o singură realizare
- Inferență validă posibilă
- Modelele sunt semnificative

Principiu Cheie

Majoritatea modelelor de serii de timp (ARMA, ARIMA, etc.) necesită staționaritate. Seriile nestaționare trebuie transformate (de ex., diferențiere) înainte de modelare.

Staționar vs Nestaționar: Comparație Vizuală



- **Staționar:** Medie și varianță constante – fluctuează în jurul unui nivel fix
- **Nestaționar:** Media și/sau varianța se schimbă în timp
- Inspecția vizuală este primul pas; testele formale (ADF, KPSS) confirmă

Definiție 2 (Staționaritate Strictă (Puternică))

Un proces $\{X_t\}$ este **strict staționar** dacă pentru toți k , toți t_1, \dots, t_k și toți h :

$$(X_{t_1}, X_{t_2}, \dots, X_{t_k}) \stackrel{d}{=} (X_{t_1+h}, X_{t_2+h}, \dots, X_{t_k+h})$$


Interpretare: Distribuția comună a oricărei colecții de observații este **invariantă la deplasări temporale**.

Implicații:

- Toate distribuțiile marginale $F_{X_t}(x)$ sunt identice
- $\mathbb{E}[X_t] = \mu$ (medie constantă)
- $\text{Var}(X_t) = \sigma^2$ (varianță constantă)
- Distribuțiile comune depind doar de *diferențele* temporale

Notă: Staționaritatea strictă este o condiție puternică, adesea impractică de verificat.

Staționaritate Strictă: Ilustrație Vizuală



Staționar: oricare două ferestre au aceeași distribuție comună. Nestaționar: distribuția se schimbă în timp.

Staționaritate Slabă (de Covarianță)

Definiție 3 (Staționaritate Slabă)

Un proces $\{X_t\}$ este **slab staționar** (sau staționar de covarianță) dacă:

- ❶ $\mathbb{E}[X_t] = \mu$ (medie constantă)
- ❷ $\text{Var}(X_t) = \sigma^2 < \infty$ (varianță constantă, finită)
- ❸ $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$ (covarianța depinde doar de lag-ul h)

Proprietate cheie: Autocovarianța este o funcție doar de lag:

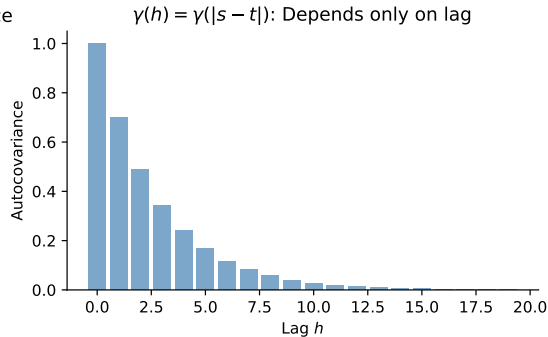

$$\gamma(h) = \text{Cov}(X_t, X_{t+h}) = \mathbb{E}[(X_t - \mu)(X_{t+h} - \mu)]$$

Funcția de autocorelație:

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)} = \frac{\text{Cov}(X_t, X_{t+h})}{\text{Var}(X_t)}$$

Notă: $\rho(0) = 1$ și $\rho(h) = \rho(-h)$ (simetrie)

Staționaritate Slabă: Ilustrație Vizuală



Stânga: medie și varianță constante. Dreapta: autocovarianța depinde doar de lag-ul h , nu de timpul t .

Proprietățile Funcției de Autocovarianță

Pentru un proces slab staționar, ACVF $\gamma(h)$ satisface:

- ❶ **Simetrie:** $\gamma(h) = \gamma(-h)$
- ❷ **Maxim la zero:** $|\gamma(h)| \leq \gamma(0)$
- ❸ **Definit nenegativ**

Implicație: Nu orice funcție poate fi o funcție de autocovarianță.

Definiție 4 (Zgomot Alb)

Un proces $\{\varepsilon_t\}$ este **zgomot alb**, notat $\varepsilon_t \sim WN(0, \sigma^2)$, dacă:

- ❶ $\mathbb{E}[\varepsilon_t] = 0$ pentru toți t
- ❷ $\text{Var}(\varepsilon_t) = \sigma^2$ pentru toți t
- ❸ $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$ pentru $t \neq s$


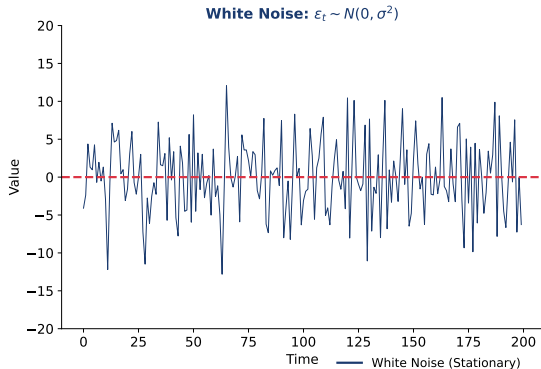
ACF al Zgomotului Alb:

$$\rho(h) = \begin{cases} 1 & \text{dacă } h = 0 \\ 0 & \text{dacă } h \neq 0 \end{cases}$$

Tipuri:



- **Zgomot alb slab:** Necorelat (condițiile de mai sus)
- **Zgomot alb puternic:** Independent și identic distribuit (i.i.d.)
- **Zgomot alb Gaussian:** $\varepsilon_t \stackrel{iid}{\sim} N(0, \sigma^2)$

Zgomot Alb vs Mers Aleatoriu: Comparație



- **Zgomot alb:** Fluctuează în jurul lui zero – staționar, varianță constantă
- **Mers aleatoriu:** Suma cumulativă a zgomotului alb – rătăcește, nestaționar
- Mersul aleatoriu este cel mai simplu proces nestaționar (rădăcină unitate)

Zgomot Alb: Ilustrație Vizuală



Stânga: zgomotul alb fluctuează în jurul lui zero cu varianță constantă. Dreapta: ACF arată nicio autocorelație (toate zero după lag 0).

Procesul de Mers Aleatoriu

Definiție: $X_t = X_{t-1} + \varepsilon_t$ unde $\varepsilon_t \sim WN(0, \sigma^2)$, $X_0 = 0$

Forma explicită: $X_t = \sum_{i=1}^t \varepsilon_i$

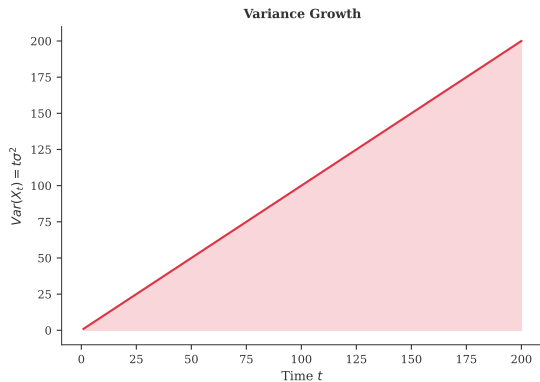

Proprietăți:

- $\mathbb{E}[X_t] = 0$ (medie constantă)
- $\text{Var}(X_t) = t\sigma^2$ (varianța crește în timp!)
- $\text{Cov}(X_t, X_s) = \min(t, s) \cdot \sigma^2$

Nestaționar!





Mersul aleatoriu **nu este staționar** deoarece varianța depinde de t .

Mers Aleatoriu: Vizualizare



Stânga: Traectorii multiple divergă în timp. **Dreapta:** Varianța crește liniar: $\text{Var}(X_t) = t\sigma^2$.

Staționar vs Nestaționar: Comparație



Diagnostic cheie: ACF al procesului staționar scade rapid; ACF al mersului aleatoriu scade foarte lent.

Funcția de Autocorelație din Eșantion

ACF din eșantion la lag-ul h :

$$\hat{\rho}(h) = \frac{\sum_{t=1}^{T-h} (x_t - \bar{x})(x_{t+h} - \bar{x})}{\sum_{t=1}^T (x_t - \bar{x})^2}$$

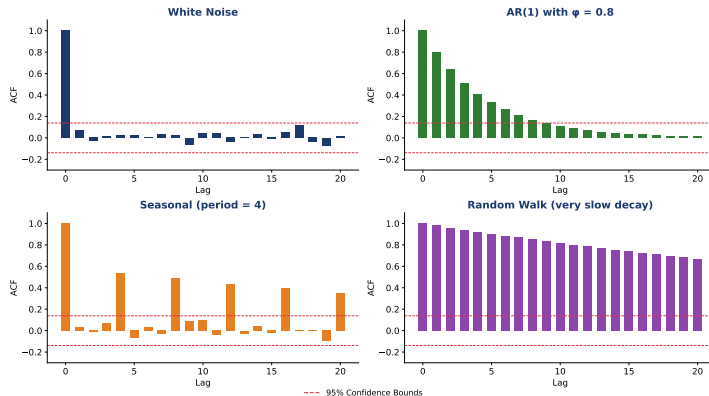
Proprietăți:

- $\hat{\rho}(0) = 1$ întotdeauna
- $|\hat{\rho}(h)| \leq 1$

Test de semnificație: Sub zgomot alb, $\hat{\rho}(h) \approx N(0, 1/T)$

Limite 95%: $\pm 1.96/\sqrt{T}$

Tipare ACF pentru Diferite Procese



- **Zgomot alb:** ACF scade la zero imediat (nicio dependență)
- **AR(1):** ACF scade exponențial – indică structură autoregresivă
- **Sezonier:** ACF arată vârfuri la lag-uri sezoniere (de ex., 12, 24 pentru lunar)
- **Mers aleatoriu:** ACF scade foarte lent – semn de nestăționaritate

Funcția de Autocorelație Parțială (PACF)

PACF ϕ_{hh} : Corelația dintre X_t și X_{t+h} după eliminarea efectului liniar al $X_{t+1}, \dots, X_{t+h-1}$.

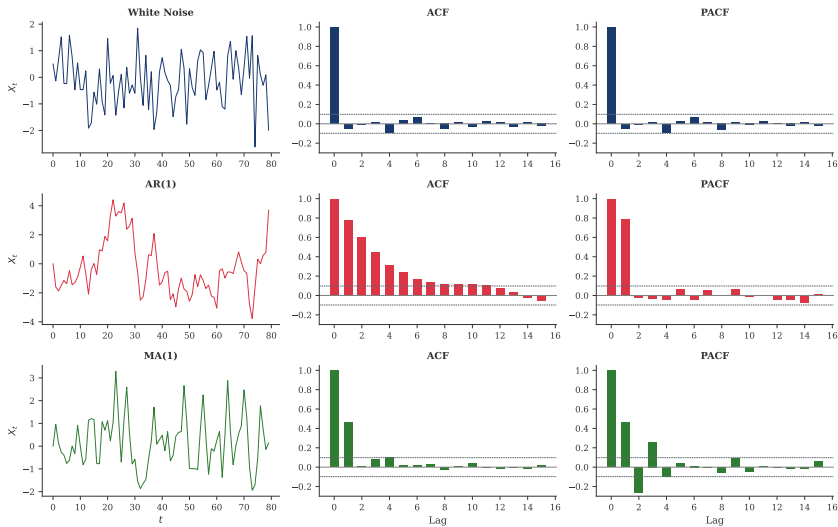
Interpretare:

- $\phi_{11} = \rho(1)$ (același ca ACF la lag 1)
- ϕ_{22} = corelația lui X_t, X_{t+2} controlând pentru X_{t+1}
- Măsoară dependența *directă* la lag-ul h

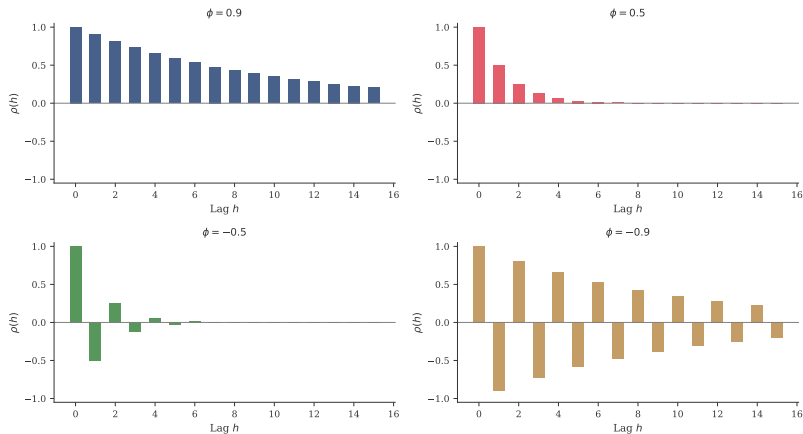
Aplicație cheie: Identificarea ordinului AR

- Pentru $AR(p)$: PACF **se întrerupe** după lag-ul p
- Pentru $MA(q)$: ACF **se întrerupe** după lag-ul q

Tipare ACF și PACF



ACF Teoretic pentru AR(1)



Pentru AR(1): $X_t = \phi X_{t-1} + \varepsilon_t$, ACF teoretic este $\rho(h) = \phi^h$.

Definiție 5 (Operatorul Lag)

Operatorul lag (sau operatorul de întârziere) L este definit prin:

$$LX_t = X_{t-1}$$

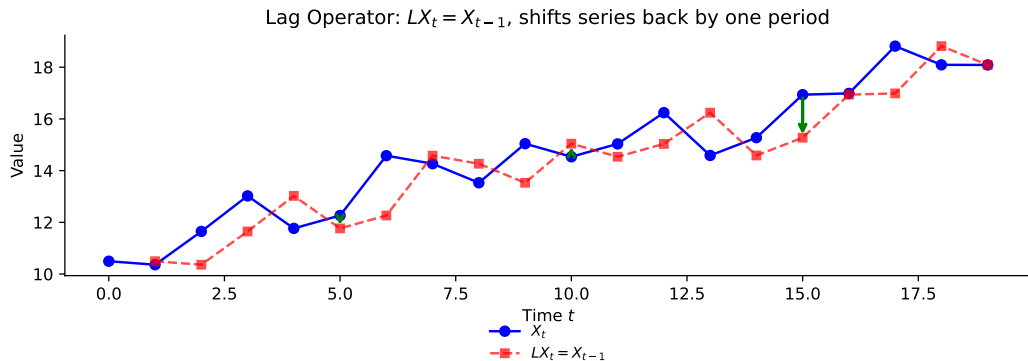
Proprietăți:

- $L^k X_t = X_{t-k}$ (întârziere cu k perioade)
- $L^0 = I$ (identitate)
- $(1 - \phi L)X_t = X_t - \phi X_{t-1}$

Exemple:

- AR(1): $(1 - \phi L)X_t = \varepsilon_t$
- MA(1): $X_t = (1 + \theta L)\varepsilon_t$
- AR(p): $(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p)X_t = \varepsilon_t$

Operatorul Lag: Ilustrație Vizuală



Operatorul lag L deplasează fiecare observație înapoi cu o perioadă de timp: $LX_t = X_{t-1}$.

Diferențierea

Prima diferență: $\Delta X_t = X_t - X_{t-1} = (1 - L)X_t$

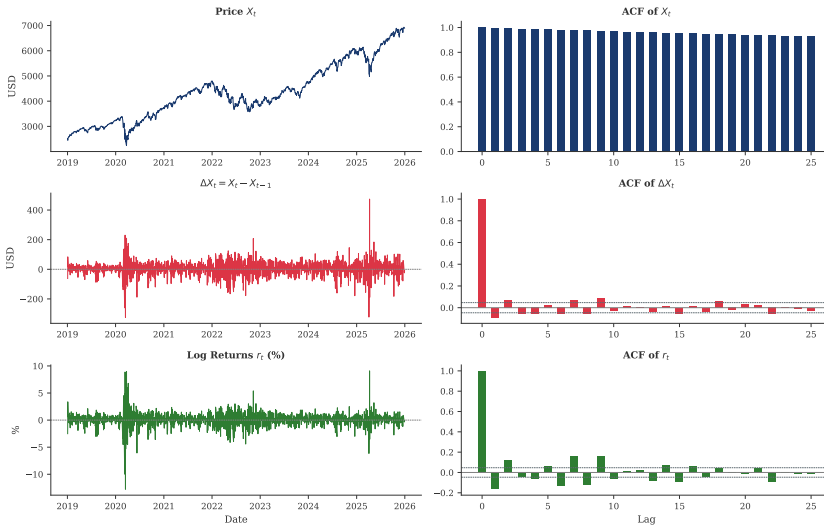
De ce diferențiem?

- Elimină trendul și rădăcina unitate
- Mers aleatoriu: $\Delta X_t = \varepsilon_t$ (zgomot alb)

Proces integrat: $X_t \sim I(d)$ dacă $\Delta^d X_t$ este staționar

- $I(0)$: Staționar (nu necesită diferențiere)
- $I(1)$: Necesită o diferențiere
- $I(2)$: Necesită două diferențieri

Efectul Diferențierii: S&P 500



Testul Augmented Dickey-Fuller (ADF)

Model: $\Delta X_t = \alpha + \gamma X_{t-1} + \sum_{i=1}^p \delta_i \Delta X_{t-i} + \varepsilon_t$

Ipoteze:

- $H_0: \gamma = 0$ (rădăcină unitate)
- $H_1: \gamma < 0$ (staționar)

Decizie:

- $\tau < \text{valoare critică} \Rightarrow \text{Respingem } H_0 \Rightarrow \text{Staționar}$
- $\tau \geq \text{valoare critică} \Rightarrow \text{Nestaționar}$

Statistica de test:

$$\tau = \frac{\hat{\gamma}}{SE(\hat{\gamma})}$$

Valori critice: distribuția Dickey-Fuller (nu normală)

Model: $X_t = \xi t + r_t + \varepsilon_t$ unde $r_t = r_{t-1} + u_t$

Ipoteze (opuse față de ADF):

- $H_0: \sigma_u^2 = 0$ (staționar)
- $H_1: \sigma_u^2 > 0$ (rădăcină unitate)

Statistica de test:

$$LM = \frac{\sum_{t=1}^T S_t^2}{T^2 \hat{\sigma}^2}$$

unde $S_t = \sum_{i=1}^t \hat{\varepsilon}_i$

Decizie:

- $LM > \text{valoare critică} \Rightarrow$ Respingem $H_0 \Rightarrow$ **Nestaționar**
- $LM \leq \text{valoare critică} \Rightarrow$ **Staționar**

Notă: KPSS completează ADF—folosiți ambele pentru concluzii robuste.




Testare confirmatorie pentru concluzii robuste:

ADF	KPSS	Concluzie
Respingem H_0	Nu respingem H_0	Staționar
Nu respingem H_0	Respingem H_0	Rădăcină Unitate
Respingem H_0	Respingem H_0	Neconcludent
Nu respingem H_0	Nu respingem H_0	Neconcludent





Flux de lucru recomandat:

- 1 Rulați testul ADF (nulă = rădăcină unitate)
- 2 Rulați testul KPSS (nulă = staționar)
- 3 Dacă rezultatele coincid, procedați cu încredere
- 4 Dacă neconcludent, considerați teste alternative (PP, DF-GLS)



Testul ADF: Vizualizare cu S&P 500



Analiza S&P 500: Prezentare Generală



Fapte Stilizate ale Randamentelor Financiare




Proprietăți observate:

- Asimetrie negativă (coadă stângă)
- Kurtoză excesivă ($\gg 3$)
- Cozi groase (heavy tails)

Implicații:

- Distribuția normală inadecvată
- Evenimente extreme mai probabile
- Necesită distribuție Student-t sau similară

Gruparea Volatilității



Fapt Stilizat

Randamentele mari (pozitive sau negative) tind să fie urmate de randamente mari. Această **grupare a volatilității** motivează modelele ARCH/GARCH (capitolele viitoare).

- ➊ **Proces stochastic** = colecție de variabile aleatoare indexate după timp
- ➋ **Realizare** = o traiectorie observată din procesul stochastic subiacent
- ➌ **Staționaritate slabă**: Medie constantă, varianță constantă, autocovarianță depinde doar de lag
- ➍ **Zgomot alb**: Proces necorelat cu medie zero și varianță constantă
- ➎ **Mers aleatoriu**: Suma cumulativă a zgomotului alb — nestăționar
- ➏ **ACF/PACF**: Instrumente esențiale pentru identificarea structurii de dependență
- ➐ **Operatorul lag**: $LX_t = X_{t-1}$; diferențiere: $\Delta X_t = X_t - X_{t-1}$
- ➑ **Testul ADF**: H_0 : rădăcină unitate (nestăționar)
- ➒ **Testul KPSS**: H_0 : staționar — folosiți împreună cu ADF pentru concluzii robuste

Staționaritate Slabă

$$\mathbb{E}[X_t] = \mu \text{ (constantă)}, \quad \text{Var}(X_t) = \sigma^2 \text{ (constantă)}, \quad \gamma(t, s) = \gamma(|t - s|)$$

Zgomot Alb

$$\mathbb{E}[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2, \quad \text{Cov}(\varepsilon_t, \varepsilon_s) = 0 \text{ pentru } t \neq s$$

Mers Aleatoriu

$$X_t = X_{t-1} + \varepsilon_t \quad \Rightarrow \quad \text{Var}(X_t) = t\sigma^2 \text{ (nestaționar)}$$

Autocovarianță și Autocorelație

$$\gamma(h) = \text{Cov}(X_t, X_{t+h}) \quad \rho(h) = \frac{\gamma(h)}{\gamma(0)}$$

Operatorul Lag

$$LX_t = X_{t-1}, \quad L^k X_t = X_{t-k}$$

Diferențiere

$$\Delta X_t = (1 - L)X_t = X_t - X_{t-1}$$

Testul ADF

$$\Delta X_t = \alpha + \beta t + \gamma X_{t-1} + \sum_{i=1}^p \delta_i \Delta X_{t-i} + \varepsilon_t$$

$H_0 : \gamma = 0$ (rădăcină unitate) vs $H_1 : \gamma < 0$ (staționar)

Testul KPSS

H_0 : Seria este staționară vs H_1 : Seria are rădăcină unitate

Capitolul 2: Modele ARMA

- Modele Autoregresive (AR)
- Modele de Medie Mobilă (MA)
- Modele ARMA combinate
- Identificarea modelului folosind ACF/PACF
- Estimarea parametrilor
- Diagnosticarea modelului
- Prognoza


Întrebarea Quiz 1

Întrebare

O serie de timp Y_t arată mișcare ascendentă de-a lungul anilor plus tipare repetitive în fiecare trimestru. Ce componente sunt prezente?

- ☐ A Doar trend
- ☐ B Doar sezonabilitate
- ☐ C Trend și Sezonabilitate
- ☐ D Doar zgomot aleatoriu

Întrebarea Quiz 1: Răspuns



Răspuns Corect: (C) Trend și Sezonalitate

Mișcare ascendentă = Trend; Tipare trimestriale = Sezonalitate ($s=4$)



Întrebarea Quiz 2

Întrebare

Care dintre următoarele este o caracteristică a unei serii de timp staționare?

- ☐ A Media se schimbă în timp
- ☐ B Varianța crește în timp
- ☐ C Medie și varianță constante în timp
- ☐ D Conține o componentă de trend

Întrebarea Quiz 2: Răspuns



Răspuns Corect: (C) Medie și varianță constante în timp


Staționaritatea necesită: medie constantă, varianță constantă și autocovarianța depinde doar de lag.

Întrebare

Pentru un proces de zgomot alb, cum arată ACF la lag-uri $k > 0$?

- ☐ A Descreștere exponențială
- ☐ B Toate valorile semnificative și pozitive
- ☐ C Toate valorile aproximativ zero (în interiorul benzilor de încredere)
- ☐ D Alternare pozitiv și negativ

Întrebarea Quiz 3: Răspuns



Răspuns Corect: (C) Aproximativ zero în interiorul benzilor de încredere



Zgomotul alb nu are autocorelație: $\rho_k = 0$ pentru toți $k \neq 0$.

Întrebare

Care este diferența cheie între zgomotul alb și mersul aleatoriu?

- ☐ A Zgomotul alb are trend, mersul aleatoriu nu
- ☐ B Mersul aleatoriu este suma cumulativă a zgomotului alb
- ☐ C Ambele sunt procese staționare
- ☐ D Zgomotul alb are varianță mai mare

Întrebarea Quiz 4: Răspuns



Răspuns Corect: (B) Mers aleatoriu = suma cumulativă a zgomotului alb



$$Y_t = Y_{t-1} + \varepsilon_t = \sum_{i=1}^t \varepsilon_i \text{ unde } \varepsilon_t \text{ este zgomot alb.}$$

Întrebare

Care metrică de eroare a prognozei este cea mai sensibilă la erori mari (valori aberante)?

- ☐ A MAE (Eroarea Medie Absolută)
- ☐ B RMSE (Rădăcina Erorii Medii Pătratice)
- ☐ C MAPE (Eroarea Medie Absolută Procentuală)
- ☐ D Toate sunt la fel de sensibile

Întrebarea Quiz 5: Răspuns



Răspuns Corect: (B) RMSE



RMSE ridică la pătrat erorile, deci erorile mari au impact disproporționat: $\sqrt{\frac{1}{n} \sum e_t^2}$

Întrebare

Când ar trebui să folosiți descompunerea multiplicativă în loc de cea aditivă?

- ☐ A Când seria nu are trend
- ☐ B Când amplitudinea sezonieră este constantă
- ☐ C Când amplitudinea sezonieră crește odată cu nivelul seriei
- ☐ D Când seria este staționară


Întrebarea Quiz 6: Răspuns



Răspuns Corect: (C) Amplitudinea sezonieră crește odată cu nivelul


Multiplicativă: $Y_t = T_t \times S_t \times \varepsilon_t$ — oscilațiile sezoniere proporționale cu trendul.

Studiu de Caz: PIB Trimestrial România



- **Date:** PIB trimestrial România, 2010–2023 (sursa: INS/Eurostat)
- **Observații:** Trend crescător, sezonabilitate trimestrială, șoc COVID-19 în 2020

Descompunerea Seriei PIB



Componente Identificate

- **Trend:** Creștere economică susținută
- **Sezonalitate:** Pattern trimestrial regulat ($Q4 > Q1$)
- **Reziduu:** Include șocul COVID-19 din 2020

Lecții Învățate

- Descompunerea ajută la înțelegerea structurii datelor
- Șocurile externe (COVID) apar în componenta reziduală
- Sezonalitatea trebuie modelată explicit

Următorii Pași

În capitolele următoare vom învăța să modelăm fiecare componentă: ARIMA pentru trend, SARIMA pentru sezonalitate.

Referințe



Hyndman, R.J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. 3rd ed., OTexts.



Hamilton, J.D. (1994). *Time Series Analysis*. Princeton University Press.



Box, G.E.P., Jenkins, G.M., Reinsel, G.C., & Ljung, G.M. (2015). *Time Series Analysis: Forecasting and Control*. 5th ed., Wiley.



Tsay, R.S. (2010). *Analysis of Financial Time Series*. 3rd ed., Wiley.



Cleveland, R.B., Cleveland, W.S., McRae, J.E., & Terpenning, I. (1990). STL: A Seasonal-Trend Decomposition. *Journal of Official Statistics*, 6(1), 3-73.

Date Reale Utilizate în Acest Capitol

- **Pasageri Aviație:** Set de date clasic Box-Jenkins, 1949–1960
- **S&P 500:** Yahoo Finance (SPY), date istorice
- **Pete Solare:** Set de date Statsmodels, observații lunare

Software și Instrumente

- **Python:** statsmodels, pandas, matplotlib, yfinance
- **R:** pachetele forecast, tseries
- **Surse de Date:** Yahoo Finance, FRED Economic Data

Vă Mulțumesc!

Întrebări?

Grafice generate folosind Python (statsmodels, matplotlib)

Materiale curs disponibile la: <https://github.com/danpele/Time-Series-Analysis>