



# Analiza și Prognoza Seriilor de Timp

## Capitolul 2: Modele ARMA



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

## Structura Cursului

Introducere și Operatorul Lag

Modele Autoregresive (AR)

Modele de Medie Mobilă (MA)

Modele ARMA

Identificarea Modelului

Eștimarea Parametrilor

Diagnosticarea Modelului

Proгноză cu ARMA


Implementare Practică

Studiu de Caz: Date Reale

Rezumat




## Exemplu Motivațional: Procese Staționare

Stock Returns: Approximately Stationary Series



- **Procese AR:** Valoarea curentă depinde de valorile trecute — comportament de revenire la medie
- **Procese MA:** Valoarea curentă depinde de șocurile trecute — memorie scurtă
- **ARMA:** Combină ambele mecanisme pentru modelare flexibilă

## Aplicații Practice ale ARMA




### Observație Cheie

Multe serii economice și financiare devin staționare după transformări simple (randamente, rate de creștere, abateri de la trend) — perfecte pentru modelarea ARMA!

## Identificarea Modelului prin Tipare ACF

Real Data: Different ACF Patterns Suggest Different Models



### ACF Dezvăluie Structura Modelului

Diferite modele ARMA produc tipare ACF distincte — putem identifica modelul examinând datele!

## Recapitulare: Staționaritatea

**Din Capitolul 1:** Un proces  $\{X_t\}$  este **slab staționar** dacă:

1.  $\mathbb{E}[X_t] = \mu$  (medie constantă)
2.  $\text{Var}(X_t) = \sigma^2 < \infty$  (varianță constantă, finită)
3.  $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$  (covarianța depinde doar de lag-ul  $h$ )

**De ce contează staționaritatea pentru ARMA:**

- ▣ Modelele ARMA presupun că procesul subiacent este staționar
- ▣ Datele nestaționare trebuie diferențiate mai întâi (ARIMA)
- ▣ Staționaritatea asigură parametri stabili ai modelului

**Astăzi:** Construim modele pentru serii de timp staționare folosind valori trecute și erori trecute.

## Operatorul Lag (Operatorul de Întârziere)

### Definiție 1 (Operatorul Lag)

**Operatorul lag**  $L$  (sau operatorul de întârziere  $B$ ) deplasează o serie de timp înapoi cu o perioadă:

$$LX_t = X_{t-1}$$


#### Proprietăți:

- ▣  $L^k X_t = X_{t-k}$  (deplasare înapoi cu  $k$  perioade)
- ▣  $L^0 X_t = X_t$  (identitate)
- ▣  $(1 - L)X_t = X_t - X_{t-1} = \Delta X_t$  (prima diferență)
- ▣  $(1 - L)^d X_t = \Delta^d X_t$  (diferența de ordin  $d$ )

#### Polinoame Lag:

$$\begin{aligned}\phi(L) &= 1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p \\ \theta(L) &= 1 + \theta_1 L + \theta_2 L^2 + \dots + \theta_q L^q\end{aligned}$$

## Operatorul Lag: Ilustrație Vizuală



**Observație cheie:** Operatorul lag este fundamentul notației modelelor ARMA



## Procesul de Zgomot Alb

### Definiție 2 (Zgomot Alb)

Un proces  $\{\varepsilon_t\}$  este **zgomot alb**, notat  $\varepsilon_t \sim WN(0, \sigma^2)$ , dacă:



1.  $\mathbb{E}[\varepsilon_t] = 0$  pentru toți  $t$
2.  $\text{Var}(\varepsilon_t) = \sigma^2$  pentru toți  $t$
3.  $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$  pentru toți  $t \neq s$

### Proprietăți:

- Zgomotul alb este “blocul de construcție” al modelelor ARMA
- ACF:  $\rho(0) = 1$ ,  $\rho(h) = 0$  pentru  $h \neq 0$
- PACF: același tipar
- **Zgomot alb Gaussian:** adițional  $\varepsilon_t \sim N(0, \sigma^2)$

**Notă:** Zgomotul alb *nu* este predictibil — este pur aleatoriu.

## Zgomot Alb: Ilustrare Vizuală



### Caracteristici Cheie

**Stânga:** Seria fluctuează aleatoriu în jurul mediei zero, fără tipare. **Dreapta:** ACF arată doar un vârf la lag 0; toate celelalte autocorelații sunt în intervalul de încredere — nicio structură de prezis.

## Modelul AR(1): Definiție

### Definiție 3 (Proces AR(1))

Un proces autoregresiv de ordin 1 este:

$$X_t = c + \phi X_{t-1} + \varepsilon_t$$

unde  $\varepsilon_t \sim WN(0, \sigma^2)$  și  $|\phi| < 1$  pentru staționaritate.

**Interpretare:**


- $c$ : constantă (interceptul)
- $\phi$ : coeficient autoregresiv — măsoară persistența
- $\varepsilon_t$ : inovație (șoc impredictibil)

**Folosind operatorul lag:**

$$(1 - \phi L)X_t = c + \varepsilon_t$$

$$\phi(L)X_t = c + \varepsilon_t \quad \text{unde } \phi(L) = 1 - \phi L$$

## AR(1): Ilustrație Vizuală



- $\phi$  **pozitiv (ex. 0.8)**: Fluctuații persistente, netede
  - ▶ Valorile tind să rămână pe aceeași parte a mediei
  - ▶ Revenire graduală la medie — aspect de “trend”
- $\phi$  **negativ (ex. -0.8)**: Comportament oscilant
  - ▶ Valorile alternează în jurul mediei
  - ▶ Schimbări rapide de semn — aspect “agitat”
- $|\phi|$  mai mare  $\Rightarrow$  revenire mai lentă la medie, persistență mai mare

## Condiția de Staționaritate AR(1)

Pentru ca AR(1) să fie staționar:  $|\phi| < 1$

Intuiție:

- ▣ Dacă  $|\phi| < 1$ : șocurile se diminuează în timp  $\rightarrow$  staționar
- ▣ Dacă  $|\phi| = 1$ : mers aleatoriu  $\rightarrow$  nestaționar (rădăcină unitate)
- ▣ Dacă  $|\phi| > 1$ : proces exploziv  $\rightarrow$  nestaționar

Ecuția caracteristică:

$$\phi(z) = 1 - \phi z = 0 \implies z = \frac{1}{\phi}$$

Staționaritatea necesită ca rădăcina  $z = 1/\phi$  să se afle **în afără cercului unitate**, adică  $|z| > 1$ , ceea ce înseamnă  $|\phi| < 1$ .

## Proprietățile AR(1)

Pentru un AR(1) staționar cu  $|\phi| < 1$ :

**Media:**

$$\mu = \mathbb{E}[X_t] = \frac{c}{1 - \phi}$$

**Varianța:**

$$\gamma(0) = \text{Var}(X_t) = \frac{\sigma^2}{1 - \phi^2}$$

**Autocovarianța:**

$$\gamma(h) = \phi^h \gamma(0) = \frac{\phi^h \sigma^2}{1 - \phi^2}$$

**Autocorelația (ACF):**

$$\rho(h) = \phi^h$$

**Observație cheie:** ACF scade exponențial la rata  $\phi$

## Demonstrație: Media AR(1)

**Afirmație:** Pentru AR(1):  $X_t = c + \phi X_{t-1} + \varepsilon_t$ , media este  $\mu = \frac{c}{1-\phi}$

**Demonstrație:** Luăm speranța ambelor părți:

$$\mathbb{E}[X_t] = \mathbb{E}[c + \phi X_{t-1} + \varepsilon_t] = c + \phi \mathbb{E}[X_{t-1}] + \mathbb{E}[\varepsilon_t]$$

Prin staționaritate,  $\mathbb{E}[X_t] = \mathbb{E}[X_{t-1}] = \mu$ , și  $\mathbb{E}[\varepsilon_t] = 0$ :

$$\mu = c + \phi \mu$$

Rezolvând pentru  $\mu$ :

$$\mu - \phi \mu = c \implies \mu(1 - \phi) = c \implies \boxed{\mu = \frac{c}{1 - \phi}}$$

### Cerință

Aceasta necesită  $\phi \neq 1$ . Dacă  $\phi = 1$  (rădăcină unitară), media este nedefinită.

## Demonstrație: Varianța AR(1)

**Afirmație:**  $\text{Var}(X_t) = \frac{\sigma^2}{1-\phi^2}$

**Demonstrație:** FSPG presupunem  $c = 0$  (proces centrat). Luăm varianța din  $X_t = \phi X_{t-1} + \varepsilon_t$ :

$$\text{Var}(X_t) = \text{Var}(\phi X_{t-1} + \varepsilon_t) = \phi^2 \text{Var}(X_{t-1}) + \text{Var}(\varepsilon_t) + 2\phi \text{Cov}(X_{t-1}, \varepsilon_t)$$

Deoarece  $\varepsilon_t$  este independent de  $X_{t-1}$ ,  $\text{Cov}(X_{t-1}, \varepsilon_t) = 0$ :

$$\gamma(0) = \phi^2 \gamma(0) + \sigma^2$$

Prin staționaritate,  $\text{Var}(X_t) = \text{Var}(X_{t-1}) = \gamma(0)$ :

$$\gamma(0) - \phi^2 \gamma(0) = \sigma^2 \implies \gamma(0)(1 - \phi^2) = \sigma^2 \implies \boxed{\gamma(0) = \frac{\sigma^2}{1 - \phi^2}}$$

### Notă

Necesită  $|\phi| < 1$  pentru varianță pozitivă. Când  $|\phi| \rightarrow 1$ , varianța  $\rightarrow \infty$ .



## Demonstrație: Funcția de Autocorelație AR(1)

**Afirmație:**  $\rho(h) = \phi^h$  pentru  $h \geq 0$

**Demonstrație:** Mai întâi, găsim autocovarianța  $\gamma(h) = \text{Cov}(X_t, X_{t-h})$ .

Înmulțim  $X_t = \phi X_{t-1} + \varepsilon_t$  cu  $X_{t-h}$  și luăm speranța:

$$\mathbb{E}[X_t X_{t-h}] = \phi \mathbb{E}[X_{t-1} X_{t-h}] + \mathbb{E}[\varepsilon_t X_{t-h}]$$

Pentru  $h \geq 1$ :  $\mathbb{E}[\varepsilon_t X_{t-h}] = 0$  (șocul viitor necorelat cu valorile trecute)


$$\gamma(h) = \phi \gamma(h-1)$$

Aceasta este o relație recursivă! Pornind de la  $\gamma(0)$ :

$$\gamma(1) = \phi \gamma(0), \quad \gamma(2) = \phi \gamma(1) = \phi^2 \gamma(0), \quad \dots \quad \boxed{\gamma(h) = \phi^h \gamma(0)}$$


ACF este:

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)} = \frac{\phi^h \gamma(0)}{\gamma(0)} = \boxed{\phi^h}$$

Varianța AR(1) ca Funcție de  $\phi$ 


**Observație cheie:** Pe măsură ce  $|\phi| \rightarrow 1$ , varianța explodează  $\rightarrow$  nestaționaritate

## Simulări AR(1): Efectul lui $\phi$





- Valori diferite ale lui  $\phi$  produc comportamente distincte:  $|\phi|$  mai mare înseamnă mai multă persistență
- $\phi$  pozitiv creează tipare netede, de trend;  $\phi$  negativ creează oscilații
- Pe măsură ce  $|\phi| \rightarrow 1$ , procesul devine mai persistent și se apropie de nestăționaritate

## ACF Teoretic AR(1)



**Tipar:**  $\rho(h) = \phi^h$  — descreștere exponențială (sau alternantă pentru  $\phi < 0$ )

## ACF și PACF AR(1): Teorie vs Eșantion



- **ACF:** Descreștere exponențială la rata  $\phi$  – formula teoretică:  $\rho(h) = \phi^h$
- **PACF:** Un singur vârf la lag 1, apoi se întrerupe – aceasta identifică AR(1)
- Eștimările din eșantion (bare) fluctuează în jurul valorilor teoretice; folosiți benzile de încredere

## Tipare ACF și PACF AR(1)

### ACF al AR(1):

- ▣ Scade exponențial:  $\rho(h) = \phi^h$
- ▣ Dacă  $\phi > 0$ : toate pozitive, descreștere graduală
- ▣ Dacă  $\phi < 0$ : semne alternante, descreștere în magnitudine

### PACF al AR(1):

- ▣ Se întrerupe după lag 1
- ▣  $\pi_1 = \phi$ ,  $\pi_k = 0$  pentru  $k > 1$

| ACF   |                          | PACF                  |
|-------|--------------------------|-----------------------|
| AR(1) | Descreștere exponențială | Se întrerupe la lag 1 |

**Acesta este tiparul cheie de identificare pentru AR(1)!**

## Modelul AR(p): Forma Generală

### Definiție 4 (Proces AR(p))

Un proces autoregresiv de ordin  $p$  este:

$$X_t = c + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t$$

Folosind operatorul lag:

$$\phi(L)X_t = c + \varepsilon_t$$

unde  $\phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p$



**Condiție de staționaritate:**

- ▣ Toate rădăcinile lui  $\phi(z) = 0$  trebuie să se afle **în afără** cercului unitate
- ▣ Echivalent: toate rădăcinile au modul  $> 1$

**Tiparul PACF:**

- ▣ PACF se întrerupe după lag  $p$
- ▣ ACF scade (exponențial sau cu oscilații amortizate)

## AR(p): Ilustrație Vizuală





## Caracteristici AR(2)

AR(2) poate prezenta comportament pseudo-ciclic când rădăcinile sunt complexe conjugate. ACF arată descreștere sinusoidală amortizată; PACF se întrerupe după lag 2 — tiparul cheie de identificare.




## Staționaritatea AR(2): Vizualizarea Cercului Unitate




**Regulă:** Toate rădăcinile lui  $\phi(z) = 0$  trebuie să se afle în afără cercului unitate umbrit

## Triunghiul de Staționaritate AR(2)



- Regiunea triunghiulară definește toate combinațiile de parametri AR(2) staționari
- Granițe:  $\phi_1 + \phi_2 < 1$ ,  $\phi_2 - \phi_1 < 1$  și  $|\phi_2| < 1$
- Punctele din afară acestei regiuni duc la procese nestaționare sau explozive

## Rădăcinile Polinomului Caracteristic



## Modelul AR(2)

### Definiție 5 (Proces AR(2))

$$X_t = c + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \varepsilon_t$$

#### Condiții de staționaritate pentru AR(2):

1.  $\phi_1 + \phi_2 < 1$
2.  $\phi_2 - \phi_1 < 1$
3.  $|\phi_2| < 1$

#### Comportamentul ACF depinde de rădăcini:

- ▣ **Rădăcini reale:** amestec de două descreșteri exponențiale
- ▣ **Rădăcini complexe:** tipar sinusoidal amortizat (pseudo-cicluri)

**PACF:** Se întrerupe după lag 2 ( $\pi_k = 0$  pentru  $k > 2$ )


## Quiz: Staționaritate AR

### Întrebare

Pentru ce valoare a lui  $\phi$  este procesul AR(1)  $X_t = c + \phi X_{t-1} + \varepsilon_t$  staționar?

- (A)  $\phi = 1.2$
- (B)  $\phi = 1.0$
- (C)  $\phi = -0.8$
- (D)  $\phi = -1.5$

## Quiz: Staționaritate AR – Răspuns

Răspuns Corect: (C)  $\phi = -0.8$ AR(1) este staționar dacă și numai dacă  $|\phi| < 1$ . Doar  $|-0.8| = 0.8 < 1$ .

## Modelul MA(1): Definiție

### Definiție 6 (Proces MA(1))

Un **proces de medie mobilă de ordin 1** este:

$$X_t = \mu + \varepsilon_t + \theta\varepsilon_{t-1}$$

unde  $\varepsilon_t \sim WN(0, \sigma^2)$ .

#### Interpretare:

- $\mu$ : media procesului
- $\theta$ : coeficient MA — măsoară impactul șocului trecut
- Valoarea curentă depinde de șocul curent și unul trecut


#### Folosind operatorul lag:

$$X_t = \mu + \theta(L)\varepsilon_t$$

unde  $\theta(L) = 1 + \theta L$

**Proprietate cheie:** Procesele MA sunt întotdeauna staționare pentru orice  $\theta$  finit

## MA(1): Ilustrație Vizuală



- **Panoul stâng:** Serie MA(1) — mai puțin persistentă decât AR(1), revenire rapidă la medie
- **Panoul drept:** ACF arată **întrerupere caracteristică după lag 1**
  - ▶ Doar  $\rho(1) \neq 0$ ; toate lagurile superioare sunt zero
  - ▶ Această întrerupere bruscă este indicatorul cheie pentru modele MA
- PACF descreștere exponențială (tipar opus față de AR)



## Proprietățile MA(1)

Pentru MA(1):  $X_t = \mu + \varepsilon_t + \theta\varepsilon_{t-1}$

**Media:**

$$\mathbb{E}[X_t] = \mu$$

**Varianța:**

$$\gamma(0) = \text{Var}(X_t) = \sigma^2(1 + \theta^2)$$

**Autocovarianța:**

$$\gamma(1) = \theta\sigma^2, \quad \gamma(h) = 0 \text{ pentru } h > 1$$

**Autocorelația (ACF):**

$$\rho(1) = \frac{\theta}{1 + \theta^2}, \quad \rho(h) = 0 \text{ pentru } h > 1$$

**Observație cheie:** ACF se întrerupe după lag 1

## Demonstrație: Varianța și Autocovarianța MA(1)

**Punct de plecare:**  $X_t = \varepsilon_t + \theta\varepsilon_{t-1}$  (presupunând  $\mu = 0$ )

**Varianța:**

$$\begin{aligned}\gamma(0) &= \text{Var}(X_t) = \text{Var}(\varepsilon_t + \theta\varepsilon_{t-1}) \\ &= \text{Var}(\varepsilon_t) + \theta^2\text{Var}(\varepsilon_{t-1}) + 2\theta\text{Cov}(\varepsilon_t, \varepsilon_{t-1}) \\ &= \sigma^2 + \theta^2\sigma^2 + 0 = \boxed{\sigma^2(1 + \theta^2)}\end{aligned}$$

**Autocovarianța la lag 1:**

$$\begin{aligned}\gamma(1) &= \text{Cov}(X_t, X_{t-1}) = \text{Cov}(\varepsilon_t + \theta\varepsilon_{t-1}, \varepsilon_{t-1} + \theta\varepsilon_{t-2}) \\ &= \text{Cov}(\varepsilon_t, \varepsilon_{t-1}) + \theta\text{Cov}(\varepsilon_t, \varepsilon_{t-2}) + \theta\text{Cov}(\varepsilon_{t-1}, \varepsilon_{t-1}) + \theta^2\text{Cov}(\varepsilon_{t-1}, \varepsilon_{t-2}) \\ &= 0 + 0 + \theta\sigma^2 + 0 = \boxed{\theta\sigma^2}\end{aligned}$$

**Autocovarianța la lag  $h \geq 2$ :** Niciun termen  $\varepsilon$  comun  $\Rightarrow \gamma(h) = 0$

## Demonstrație: Maximul ACF pentru MA(1)

**Afirmație:**  $|\rho(1)| \leq 0.5$  pentru orice valoare a lui  $\theta$

**Demonstrație:** ACF la lag 1 este:

$$\rho(1) = \frac{\gamma(1)}{\gamma(0)} = \frac{\theta\sigma^2}{\sigma^2(1 + \theta^2)} = \frac{\theta}{1 + \theta^2}$$

Pentru a găsi maximul, derivăm în raport cu  $\theta$  și egalăm cu zero:

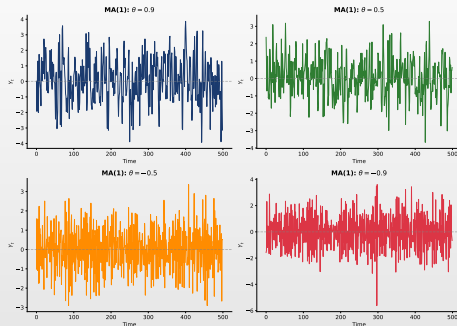
$$\frac{d\rho(1)}{d\theta} = \frac{(1 + \theta^2) - \theta(2\theta)}{(1 + \theta^2)^2} = \frac{1 - \theta^2}{(1 + \theta^2)^2} = 0$$

Soluție:  $\theta = \pm 1$ . La aceste valori:

$$\rho(1)|_{\theta=1} = \frac{1}{1+1} = \frac{1}{2}, \quad \rho(1)|_{\theta=-1} = \frac{-1}{1+1} = -\frac{1}{2}$$

### Implicație

Dacă estimați  $|\hat{\rho}(1)| > 0.5$  din date, procesul **nu** este MA(1).

Simulări MA(1): Efectul lui  $\theta$ 

- MA(1) este întotdeauna staționar indiferent de  $\theta$  – memorie finită de doar un lag
- $\theta$  pozitiv netezește seria;  $\theta$  negativ creează fluctuații mai rapide
- Spre deosebire de AR(1), șocurile MA(1) afectează procesul doar pentru o perioadă

## Tipare ACF și PACF MA(1)

### ACF al MA(1):

- ▣ Se întrerupe după lag 1
- ▣  $\rho(1) = \frac{\theta}{1+\theta^2}$ ,  $\rho(h) = 0$  pentru  $h > 1$
- ▣ Notă:  $|\rho(1)| \leq 0.5$  întotdeauna (maxim la  $\theta = \pm 1$ )



### PACF al MA(1):

- ▣ Scade exponențial (sau cu semne alternante)
- ▣ *Nu* se întrerupe

|       | ACF                   | PACF                     |
|-------|-----------------------|--------------------------|
| MA(1) | Se întrerupe la lag 1 | Descreștere exponențială |

**Acesta este tiparul opus față de AR(1)!**

## ACF și PACF MA(1): Comparăție Vizuală



- **ACF:** Un singur vârf la lag 1, apoi se întrerupe imediat – semnătura cheie MA(1)
- **PACF:** Descreștere exponențială – tipar opus față de AR(1)
- Această inversare a tiparelor ACF/PACF distinge procesele MA de cele AR

## Invertibilitatea Modelelor MA

### Definiție 7 (Invertibilitate)

Un proces MA este **invertibil** dacă poate fi scris ca un proces AR infinit:

$$X_t = \mu + \sum_{j=1}^{\infty} \pi_j (X_{t-j} - \mu) + \varepsilon_t$$

**Pentru MA(1):** Invertibil dacă  $|\theta| < 1$

**Pentru MA(q):** Toate rădăcinile lui  $\theta(z) = 0$  trebuie să se afle în afără cercului unitate


**De ce contează invertibilitatea:**

- ▣ Asigură reprezentare unică
- ▣ Necesară pentru prognoză și estimare
- ▣ Creează corespondență:  $AR(\infty) \leftrightarrow MA(q)$

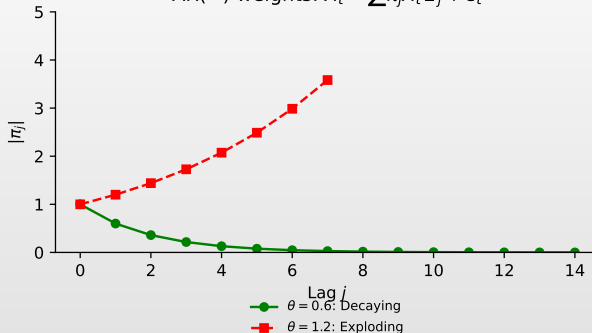
**Notă:** Staționaritatea este pentru AR, Invertibilitatea este pentru MA

## Invertibilitate: Ilustrație Vizuală

Invertibility: Root outside unit circle



AR( $\infty$ ) weights:  $X_t = \sum \pi_j X_{t-j} + \varepsilon_t$



Stânga: invertibilitatea necesită rădăcini în afară cercului unitate. Dreapta: ponderile AR( $\infty$ ) scad doar când  $|\theta| < 1$ .



## Modelul MA(q): Forma Generală

### Definiție 8 (Proces MA(q))

Un proces de medie mobilă de ordin  $q$  este:

$$X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

Folosind operatorul lag:



$$X_t = \mu + \theta(L)\varepsilon_t$$

unde  $\theta(L) = 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q$

**Proprietăți:**

- ▣ Întotdeauna staționar (varianță finită)
- ▣ ACF se întrerupe după lag  $q$ :  $\rho(h) = 0$  pentru  $h > q$
- ▣ PACF scade gradual
- ▣ Invertibil dacă toate rădăcinile lui  $\theta(z) = 0$  se află în afără cercului unitate

## MA(q): Ilustrație Vizuală



Proces MA(3). Semnătura cheie: ACF se întrerupe după lag  $q$  (aici, lag 3).

## Quiz: Recunoașterea Tiparelor ACF/PACF


### Întrebare

Observați: ACF are vârf la lag 1, apoi se întrerupe. PACF scade gradual. Ce model?

- (A) AR(1)
- (B) MA(1)
- (C) ARMA(1,1)
- (D) Zgomot alb

## Quiz: Recunoașterea Tiparelor ACF/PACF – Răspuns

Răspuns Corect: (B) MA(1)

ACF se întrerupe  $\rightarrow$  proces MA; PACF scade  $\rightarrow$  confirmă MA(1)

## Quiz: Invertibilitate MA

### Întrebare

Este MA(1)  $X_t = \varepsilon_t + 1.5\varepsilon_{t-1}$  invertibil?

- (A) Da, procesele MA sunt întotdeauna invertibile
- (B) Da, deoarece  $1.5 > 0$
- (C) Nu, deoarece  $|\theta| = 1.5 > 1$
- (D) Nu, procesele MA nu sunt niciodată invertibile

## Quiz: Invertibilitate MA

### Întrebare

Este MA(1)  $X_t = \varepsilon_t + 1.5\varepsilon_{t-1}$  invertibil?

- (A) Da, procesele MA sunt întotdeauna invertibile
- (B) Da, deoarece  $1.5 > 0$
- (C) Nu, deoarece  $|\theta| = 1.5 > 1$
- (D) Nu, procesele MA nu sunt niciodată invertibile

### Răspuns: (C)

Invertibilitatea necesită  $|\theta| < 1$ . Aici  $|\theta| = 1.5 > 1$ , deci nu este invertibil.

## Modelul ARMA(p,q): Definiție

### Definiție 9 (Proces ARMA(p,q))

Un **proces autoregresiv de medie mobilă** de ordin (p,q) este:

$$X_t = c + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

**Formă compactă folosind operatorii lag:**

$$\phi(L)(X_t - \mu) = \theta(L)\varepsilon_t$$


sau echivalent:

$$\phi(L)X_t = c + \theta(L)\varepsilon_t$$

unde  $\mu = \frac{c}{1 - \phi_1 - \cdots - \phi_p}$

**Idee cheie:** Combină componentele AR și MA pentru modelare mai flexibilă

## ARMA: Ilustrație Vizuală




- ▣ **ARMA(1,1) combină** persistența AR cu răspunsul la șocuri MA
- ▣ **Tipar ACF:** Descreștere după primul lag (nu întrerupere bruscă ca MA pur)
  - ▶ Primul lag influențat atât de  $\phi$  cât și de  $\theta$
  - ▶ Lagurile următoare descresc geometric ca AR
- ▣ **Tipar PACF:** De asemenea descreștere (nu întrerupere bruscă ca AR pur)
- ▣ Nici ACF nici PACF nu se întrerup — identificator cheie pentru modele mixte




## Structura Modelului ARMA

### ARMA(p,q) Model Structure



$$X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$



## Cum Funcționează Simularea ARMA



## Exemple ARMA



## Modelul ARMA(1,1)

## Definiție 10 (Proces ARMA(1,1))

$$X_t = c + \phi X_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$$

**Proprietăți (presupunând staționaritate și invertibilitate):**


- Media:  $\mu = \frac{c}{1-\phi}$
- Varianța:  $\gamma(0) = \frac{(1+2\phi\theta+\theta^2)\sigma^2}{1-\phi^2}$

**ACF:**

$$\rho(1) = \frac{(1 + \phi\theta)(\phi + \theta)}{1 + 2\phi\theta + \theta^2}$$
$$\rho(h) = \phi \cdot \rho(h-1) \quad \text{pentru } h \geq 2$$

**Tipar:** ACF scade exponențial după lag 1 (ca AR), dar punctul de pornire depinde atât de  $\phi$  cât și de  $\theta$

## Tipare ACF/PACF: AR vs MA vs ARMA



## Tipare ACF și PACF ARMA




| Model     | ACF                     | PACF                    |
|-----------|-------------------------|-------------------------|
| AR(p)     | Scade (exp./amortizat)  | Se întrerupe la lag $p$ |
| MA(q)     | Se întrerupe la lag $q$ | Scade (exp./amortizat)  |
| ARMA(p,q) | Scade după lag $q - p$  | Scade după lag $p - q$  |

## Regula cheie de identificare:

- ▣ **PACF se întrerupe** → proces AR (ordin = lag-ul de întrerupere)
- ▣ **ACF se întrerupe** → proces MA (ordin = lag-ul de întrerupere)
- ▣ **Ambele scad** → proces ARMA

**Atenție:** În practică, ACF/PACF din eșantion sunt zgomotoase; folosiți benzile de încredere

## Funcții de Răspuns la Impuls



**Interpretare:** Arată cum se propagă un șoc unitar prin sistem în timp

## Rezumat Staționaritate și Invertibilitate

Pentru ca ARMA(p,q) să fie bine comportat:

| Condiție        | Cerință  |
|-----------------|--|
| Staționaritate  | Rădăcinile lui $\phi(z) = 0$ în afără cercului unitate   |
| Invertibilitate | Rădăcinile lui $\theta(z) = 0$ în afără cercului unitate |


**Implicații:**

- **Staționaritate:** Se poate scrie ca MA( $\infty$ ):  $X_t = \mu + \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$
- **Invertibilitate:** Se poate scrie ca AR( $\infty$ ):  $X_t = \mu + \sum_{j=1}^{\infty} \pi_j (X_{t-j} - \mu) + \varepsilon_t$

**Reprezentare cauzală:**  $X_t$  depinde doar de șocurile *trecute* (nu viitoare)



## Teorema de Descompunere a lui Wold



Orice proces staționar poate fi scris ca  $MA(\infty)$ :  $X_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$

## Quiz: Reprezentarea ARMA

### Întrebare

Forma compactă  $\phi(L)X_t = \theta(L)\varepsilon_t$  reprezintă ce model?

- (A) Model AR pur
- (B) Model MA pur
- (C) Model ARMA
- (D) Niciunul de mai sus

## Quiz: Reprezentarea ARMA

### Întrebare

Forma compactă  $\phi(L)X_t = \theta(L)\varepsilon_t$  reprezintă ce model?

- (A) Model AR pur
- (B) Model MA pur
- (C) Model ARMA
- (D) Niciunul de mai sus

Răspuns: (C) Model ARMA

$\phi(L)$  este polinomul AR,  $\theta(L)$  este polinomul MA  $\rightarrow$  ARMA(p,q)

## Quiz: Operatorul Lag

## Întrebare

Ce este  $(1 - L)^2 X_t$ ?

- (A)  $X_t - X_{t-1}$
- (B)  $X_t - 2X_{t-1} + X_{t-2}$
- (C)  $X_t + X_{t-1} + X_{t-2}$
- (D)  $X_t - X_{t-2}$

## Quiz: Operatorul Lag

## Întrebare

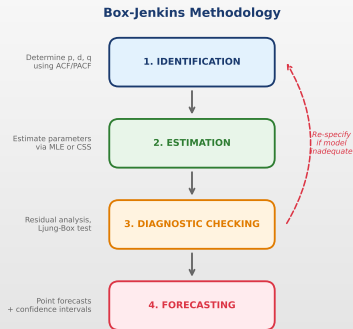
Ce este  $(1 - L)^2 X_t$ ?

- (A)  $X_t - X_{t-1}$
- (B)  $X_t - 2X_{t-1} + X_{t-2}$
- (C)  $X_t + X_{t-1} + X_{t-2}$
- (D)  $X_t - X_{t-2}$

## Răspuns: (B)

$(1 - L)^2 = 1 - 2L + L^2$ , deci  $(1 - L)^2 X_t = X_t - 2X_{t-1} + X_{t-2}$

# Metodologia Box-Jenkins



## Tabel Rezumat pentru Identificarea Modelului

model\_identificăți\_ion\_table.pdf

**Sfat practic:** Începeți simplu ( $p, q$  mici), creșteți dacă diagnosticele eșuează



TSA\_ch2\_acf\_pacf\_patterns


## Reguli de Identificare ACF/PACF

Tipare teoretice pentru procese staționare:

| Model     | Tipar ACF                         | Tipar PACF                        |
|-----------|-----------------------------------|-----------------------------------|
| AR(1)     | Descreștere exponențială          | Vârf la lag 1, apoi 0             |
| AR(2)     | Exponențială/sinusoidă amortizată | Vârfuri la lag-uri 1-2, apoi 0    |
| AR(p)     | Scade gradual                     | Se întrerupe după lag $p$         |
| MA(1)     | Vârf la lag 1, apoi 0             | Descreștere exponențială          |
| MA(2)     | Vârfuri la lag-uri 1-2, apoi 0    | Exponențială/sinusoidă amortizată |
| MA(q)     | Se întrerupe după lag $q$         | Scade gradual                     |
| ARMA(p,q) | Scade                             | Scade                             |



## Tipare ACF/PACF: Ghid Vizual



- **AR**: ACF scade, PACF se întrerupe – folosiți PACF pentru a identifica ordinul  $p$
- **MA**: ACF se întrerupe, PACF scade – folosiți ACF pentru a identifica ordinul  $q$
- **ARMA**: Ambele scad – necesită criterii informaționale pentru selecția modelului

## Criterii Informaționale

**Scop:** Echilibrează calitatea potrivirii față de complexitatea modelului

**Criteriul Informațional Akaike (AIC):**

$$AIC = -2 \ln(\hat{L}) + 2k$$

**Criteriul Informațional Bayesian (BIC/SBC):**


$$BIC = -2 \ln(\hat{L}) + k \ln(n)$$

unde  $\hat{L}$  = verosimilitate maximizată,  $k$  = număr de parametri,  $n$  = dimensiune eșantion

**Utilizare:**


- ▣ Valori mai mici sunt mai bune
- ▣ BIC penalizează complexitatea mai puternic decât AIC
- ▣ AIC tinde să aleagă modele mai mari; BIC mai simplu
- ▣ Comparăți modele potrivite pe *aceleași date*

## AIC vs BIC: Selecția Modelului



**Notă:** Pătratul alb marchează cel mai bun model; valorile mai mici (verde) sunt mai bune

## Principiul Parcimoniei: Compromisul Bias-Varianță



## Selecția Automată a Modelului

### Abordarea căutării pe grilă:

1. Potriviiți ARMA( $p, q$ ) pentru  $p = 0, 1, \dots, p_{max}$  și  $q = 0, 1, \dots, q_{max}$
2. Selectați modelul cu cel mai mic AIC sau BIC
3. Verificați cu teste de diagnostic

### În Python (statsmodels):

- ▣ `pm.auto_arima()` din pachetul `pmdarima`
- ▣ Testează automat staționaritatea, caută peste ordine
- ▣ Returnează cel mai bun model după AIC/BIC

### Atenție:

- ▣ Selecția automată este un punct de pornire, nu răspunsul final
- ▣ Verificați întotdeauna diagnosticele
- ▣ Considerați cunoștințele de domeniu

## Quiz: Criterii Informaționale

### Întrebare


Comparând ARMA(1,1) vs ARMA(2,1) folosind BIC, care este corect?

- (A) BIC mai mic înseamnă întotdeauna prognoze mai bune
- (B) BIC penalizează complexitatea mai puțin decât AIC
- (C) Modelul cu BIC mai mic este preferat
- (D) BIC poate compara doar modele cu același număr de parametri

## Quiz: Criterii Informaționale – Răspuns

Răspuns Corect: (C) Modelul cu BIC mai mic este preferat

BIC mai mic indică un compromis mai bun între potrivire și complexitate. BIC penalizează complexitatea *mai mult* decât AIC.



## Prezentare Generală a Metodelor de Eștimare

**Trei abordări principale:**

### **1. Metoda Momentelor / Yule-Walker (doar AR)**

- ▣ Potrivește autocorelațiile din eșantion la valorile teoretice
- ▣ Simplă, formă închisă pentru modele AR
- ▣ Nu este eficientă pentru componentele MA

### **2. Eștimarea prin Maximum de Verosimilitate (MLE)**

- ▣ Cea mai comună abordare
- ▣ Necesită ipoteză distribuțională (de obicei Gaussiană)
- ▣ Eficientă și consistentă

### **3. Cele Mai Mici Pătrate Condiționate**

- ▣ Minimizează suma pătratelor reziduurilor
- ▣ Condiționare pe observațiile inițiale
- ▣ Computațional mai simplă decât MLE exact




## Comparăția Metodelor de Eștimare



eștimation\_comparison.pdf

## Ecuțiile Yule-Walker pentru AR(p)



### Yule-Walker Equations

$$\rho(1) = \phi_1 + \phi_2 \rho(1)$$

$$\rho(2) = \phi_1 \rho(1) + \phi_2$$

$$\text{Matrix form: } R \cdot \phi = \rho$$

$R$  = autocorrelation matrix

$$\text{Solution: } \hat{\phi} = R^{-1}\rho$$

## Ecuțiile Yule-Walker: Forma Matriceală

Pentru AR(p):  $X_t = \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t$

**Ecuțiile Yule-Walker:**

$$\rho(k) = \phi_1 \rho(k-1) + \phi_2 \rho(k-2) + \cdots + \phi_p \rho(k-p)$$

pentru  $k = 1, 2, \dots, p$

**Forma matriceală:**

$$\begin{pmatrix} \rho(0) & \rho(1) & \cdots & \rho(p-1) \\ \rho(1) & \rho(0) & \cdots & \rho(p-2) \\ \vdots & \vdots & \ddots & \vdots \\ \rho(p-1) & \rho(p-2) & \cdots & \rho(0) \end{pmatrix} \begin{pmatrix} \phi_1 \\ \phi_2 \\ \vdots \\ \phi_p \end{pmatrix} = \begin{pmatrix} \rho(1) \\ \rho(2) \\ \vdots \\ \rho(p) \end{pmatrix}$$

**Eștimare:** Înlocuiți  $\rho(k)$  cu autocorelațiile din eșantion  $\hat{\rho}(k)$

## Demonstrație: Ecuațiile Yule-Walker

**Scop:** Derivarea relației  $\rho(k) = \phi_1\rho(k-1) + \dots + \phi_p\rho(k-p)$

**Demonstrație:** Pornim de la AR(p):  $X_t = \phi_1X_{t-1} + \dots + \phi_pX_{t-p} + \varepsilon_t$

Înmulțim ambele părți cu  $X_{t-k}$  și luăm speranța:

$$\mathbb{E}[X_t X_{t-k}] = \phi_1 \mathbb{E}[X_{t-1} X_{t-k}] + \dots + \phi_p \mathbb{E}[X_{t-p} X_{t-k}] + \mathbb{E}[\varepsilon_t X_{t-k}]$$

Pentru  $k \geq 1$ :  $\mathbb{E}[\varepsilon_t X_{t-k}] = 0$  (șocul viitor necorelat cu trecutul)

Folosind  $\gamma(k) = \mathbb{E}[X_t X_{t-k}]$  (presupunând medie zero):

$$\gamma(k) = \phi_1\gamma(k-1) + \phi_2\gamma(k-2) + \dots + \phi_p\gamma(k-p)$$

Împărțind la  $\gamma(0)$ :

$$\rho(k) = \phi_1\rho(k-1) + \phi_2\rho(k-2) + \dots + \phi_p\rho(k-p)$$

### Cazul Special AR(1)

$$\rho(k) = \phi_1\rho(k-1) = \phi_1^k \text{ (folosind } \rho(0) = 1)$$

## Eștimarea prin Maximum de Verosimilitate

**Presupunând erori Gaussiene:**  $\varepsilon_t \sim N(0, \sigma^2)$

**Log-verosimilitatea pentru ARMA(p,q):**

$$\ell(\phi, \theta, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{t=1}^n \varepsilon_t^2$$

unde  $\varepsilon_t$  sunt inovațiile calculate recursiv.

**Procedura de eștimare:**

1. Inițializare: folosiți metoda momentelor sau OLS pentru valori de pornire
2. Optimizare: metode numerice (de ex., BFGS, Newton-Raphson)
3. Iterare până la convergență

**În practică:** Folosiți `statsmodels.tsa.arima.model.ARIMA`

## Erori Standard și Inferență

**Distribuția asimptotică a MLE:**

$$\hat{\theta} \xrightarrow{d} N\left(\theta_0, \frac{1}{n}I(\theta_0)^{-1}\right)$$

unde  $I(\theta)$  este matricea informației Fisher.

**Erori standard:** Rădăcina pătrată a diagonalei lui  $\frac{1}{n}\hat{I}^{-1}$

**Testarea ipotezelor:**

- ▣  $H_0 : \phi_j = 0$  (sau  $\theta_j = 0$ )
- ▣ Statistică de test:  $z = \frac{\hat{\phi}_j}{SE(\hat{\phi}_j)} \sim N(0, 1)$  asimptotic
- ▣ Respingeți dacă  $|z| > 1.96$  la nivel de 5%

**Interval de încredere:**  $\hat{\phi}_j \pm 1.96 \cdot SE(\hat{\phi}_j)$

## Analiza Reziduurilor

**Dacă modelul este corect specificat, reziduurile ar trebui să fie zgomot alb:**

### 1. Reprezentați grafic reziduurile în timp

- ☐ Ar trebui să fluctueze în jurul lui zero
- ☐ Fără tipare sau trenduri evidente
- ☐ Varianță constantă (fără heteroscedasticitate)

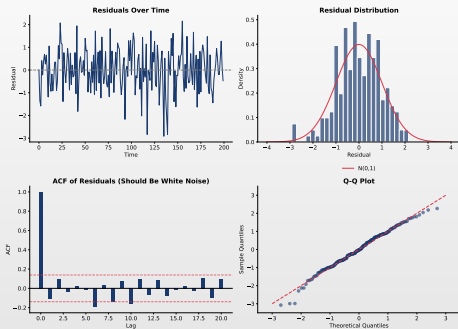
### 2. Verificați ACF reziduurilor

- ☐ Toate corelațiile ar trebui să fie în benzile de încredere
- ☐ Fără vârfuri semnificative → zgomot alb

### 3. Verificați histograma / graficul Q-Q

- ☐ Ar trebui să fie aproximativ normale (dacă presupunem Gaussian)
- ☐ Cozi groase sugerează erori non-normale

## Diagnosticarea Reziduurilor: Exemplu



- ▣ **Graficul reziduurilor:** Ar trebui să arate dispersie aleatorie în jurul lui zero cu varianță constantă
- ▣ **ACF reziduurilor:** Fără vârfuri semnificative indică zgomot alb (potrivire bună)
- ▣ **Graficul Q-Q:** Punctele pe linia diagonală indică reziduuri distribuite normal



## Testul Ljung-Box

### Definiție 11 (Testul Ljung-Box)

Testează dacă reziduurile sunt distribuite independent (fără autocorelație).

**Statistică de test:**

$$Q(m) = n(n+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{n-k}$$

**Ipoteze:**

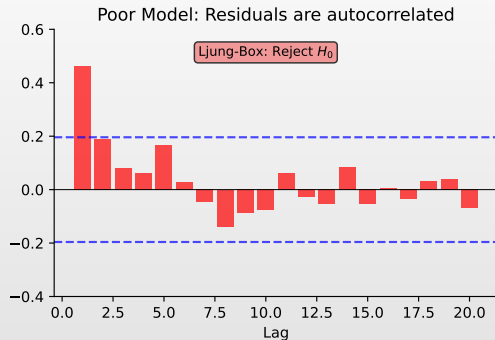

- $H_0$ : Reziduurile sunt zgomot alb (fără autocorelație până la lag  $m$ )
- $H_1$ : Reziduurile sunt autocorelate

**Distribuție:** Sub  $H_0$ ,  $Q(m) \sim \chi^2(m-p-q)$  aproximativ

**Decizie:**

- $p\text{-value} > 0.05 \rightarrow$  nu respingem  $H_0 \rightarrow$  reziduurile arată ca zgomot alb (bine!)
- $p\text{-value} < 0.05 \rightarrow$  autocorelație semnificativă rămâne  $\rightarrow$  model inadecvat

## Testul Ljung-Box: Ilustrație Vizuală



Stânga: Model bun – reziduurile sunt zgomot alb (fără ACF semnificativ). Dreapta: Model slab – reziduurile arată autocorelație.

## Lista de Verificare Diagnostic

**Un model ARMA bun ar trebui să satisfacă:**

1. **Staționaritate:** Rădăcinile AR în afără cercului unitate  
✓ Verificați cu `arroots`
2. **Invertibilitate:** Rădăcinile MA în afără cercului unitate  
✓ Verificați cu `maroots`
3. **Reziduuri zgomot alb:** Fără ACF semnificativ  
✓ Grafic ACF, testul Ljung-Box
4. **Reziduuri normale:** (dacă presupunem)  
✓ Grafic Q-Q, testul Jarque-Bera
5. **Fără heteroscedasticitate:** Varianță constantă  
✓ Reprezentăți reziduurile, testul ARCH
6. **Simplu:** Cel mai mic AIC/BIC dintre modelele adecvate

**Dacă diagnosticele eșuează:** Reveniți la identificare, încercați ordine diferite

## Quiz: Testul Ljung-Box

### Întrebare


După potrivirea unui model ARMA, rulați testul Ljung-Box pe reziduuri și obțineți  $p\text{-value} = 0.03$ . Ce înseamnă asta?

- (A) Modelul este adecvat, reziduurile sunt zgomot alb
- (B) Modelul este inadecvat, reziduurile au autocorelație
- (C) Trebuie să creșteți dimensiunea eșantionului
- (D) Testul este neconcludent

## Quiz: Testul Ljung-Box – Răspuns

Răspuns Corect: (B) Modelul este inadecvat

p-value < 0.05 respinge  $H_0$  (zgomot alb), indicând autocorelație reziduală rămasă.



## Proгноze Punctuale

**Prognoză optimă:** Speranța condiționată minimizează MSE

$$\hat{X}_{n+h|n} = \mathbb{E}[X_{n+h}|X_n, X_{n-1}, \dots]$$

**Pentru AR(1):**  $X_t = c + \phi X_{t-1} + \varepsilon_t$

$$\hat{X}_{n+1|n} = c + \phi X_n$$

$$\hat{X}_{n+2|n} = c + \phi \hat{X}_{n+1|n} = c(1 + \phi) + \phi^2 X_n$$

$$\hat{X}_{n+h|n} = \mu + \phi^h (X_n - \mu)$$

**Proprietate cheie:** Prognosele converg la media  $\mu$  când  $h \rightarrow \infty$

**Pentru MA(1):**  $X_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}$

$$\hat{X}_{n+1|n} = \mu + \theta \varepsilon_n$$

$$\hat{X}_{n+h|n} = \mu \quad \text{pentru } h > 1$$

## Incertitudinea Prognozei

**Eroarea de prognoză:**

$$e_{n+h|n} = X_{n+h} - \hat{X}_{n+h|n}$$

**Eroarea medie pătratică de prognoză (MSFE):**

$$\text{MSFE}(h) = \mathbb{E}[e_{n+h|n}^2] = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$$


unde  $\psi_j$  sunt coeficienții  $\text{MA}(\infty)$ .

**Pentru AR(1):**  $\psi_j = \phi^j$

$$\text{MSFE}(h) = \sigma^2 \frac{1 - \phi^{2h}}{1 - \phi^2} \rightarrow \frac{\sigma^2}{1 - \phi^2} = \text{Var}(X_t)$$


**Observație cheie:** Incertitudinea prognozei crește cu orizontul, ajungând eventual la varianța necondiționată

## Prognoză ARMA cu Intervale de Încredere







## Prognoză AR(1): Revenirea la Medie



- Prognozele converg la media necondiționată  $\mu$  pe măsură ce orizontul crește
- Rata de convergență depinde de  $|\phi|$ : valori mai mari înseamnă revenire mai lentă
- Intervalele de încredere se lărgesc cu orizontul, ajungând eventual la varianța necondiționată

## Varianța Erorii de Prognoză în Funcție de Orizont



## Intervale de Încredere pentru Prognoze

**Presupunând erori Gaussiene:**

$$X_{n+h}|X_n, \dots \sim N\left(\hat{X}_{n+h|n}, \text{MSFE}(h)\right)$$

**Interval de încredere  $(1 - \alpha)$ :**

$$\hat{X}_{n+h|n} \pm z_{\alpha/2} \cdot \sqrt{\text{MSFE}(h)}$$

unde  $z_{\alpha/2} = 1.96$  pentru IC 95%.

**Proprietăți:**

- Intervalele se largesc pe măsură ce orizontul crește
- În cele din urmă converg la intervalul necondiționat:  $\mu \pm z_{\alpha/2}\sigma_X$
- Lățimea depinde de parametrii modelului (coeficienți AR, etc.)

**În Python:** `model.get_forecast(h).conf_int()`

## Evaluarea Prognozei

### Testare în afără eșantionului:

1. Împărțiți datele: set de antrenare (potriviiți modelul) și set de test (evaluați)
2. Generați prognoze pentru perioadă de test
3. Comparăți prognozele cu valorile reale


### Metriци (din Capitolul 1):

- $MAE = \frac{1}{n} \sum |e_t|$
- $RMSE = \sqrt{\frac{1}{n} \sum e_t^2}$
- $MAPE = \frac{100}{n} \sum \left| \frac{e_t}{X_t} \right|$

### Fereastră mobilă/în expansiune:

- Re-estimăți modelul pe măsură ce sosesc date noi
- Evaluare mai realistă a performanței prognozei



## Exemplu de Prognoză Train/Validare/Test



### Bună Practică

Evaluati întotdeauna prognozele pe date nevăzute. Folosiți setul de antrenare pentru estimare, setul de validare pentru selecția modelului și setul de test pentru evaluarea finală.



## Prognoză cu Fereastră Mobilă (Rolling Forecast)



### Metodologia Rolling Forecast

- **Fereastră fixă:** Re-estimare model folosind cele mai recente  $w$  observații
- **Fereastră expansivă:** Folosește toate datele disponibile până la origine
- Generează prognoză 1-pas înainte, mută fereastra, repetă


## Rolling vs Proгноză Multi-Pas



### Diferențe Cheie

- **Rolling 1-pas:** Mai precis, necesită re-estimare frecventă
- **Multi-pas direct:** Estimare model separat pentru fiecare orizont  $h$
- **Multi-pas recursiv:** Iterează prognoze 1-pas (acumulare erori)

## Aplicație cu Date Reale: Comparăție Prognose



### Considerații Practice

- Datele reale prezintă adesea nestăționaritate, rupturi structurale
- Comparăți mai multe modele: ARMA, netezire exponențială, naive
- Folosiți validare încrucișată sau evaluare rolling pentru robustețe



## Quiz: Proprietățile Prognozei

### Întrebare


Pentru un model AR(1) staționar, ce se întâmplă cu prognozele când orizontul  $h \rightarrow \infty$ ?

- (A) Prognozele cresc nelimitat
- (B) Prognozele oscilează la nesfârșit
- (C) Prognozele converg la media necondiționată  $\mu$
- (D) Prognozele devin mai precise

## Quiz: Proprietățile Prognozei – Răspuns

Răspuns Corect: (C) Prognozele converg la  $\mu$

$\hat{X}_{n+h|n} = \mu + \phi^h(X_n - \mu) \rightarrow \mu$  când  $h \rightarrow \infty$  (deoarece  $|\phi| < 1$ )



## Implementare Python: Potrivirea ARMA

### Folosind statsmodels:

```
from statsmodels.tsa.arima.model import ARIMA

# Potrivire ARMA(2,1) -- notă: ARIMA(p,d,q) cu d=0
model = ARIMA(data, order=(2, 0, 1))
results = model.fit()

# Rezumat
print(results.summary())

# Prognoză
forecast = results.get_forecast(steps=10)
print(forecast.predicted_mean)
print(forecast.conf_int())
```

**Notă:** ARIMA cu  $d = 0$  este echivalent cu ARMA

## Python: Selecția Modelului cu pmdarima

### Selecție automată ARIMA:

```
import pmdarima as pm

# Auto ARIMA cu criteriul AIC
model = pm.auto_arima(data,
                      start_p=0, max_p=5,
                      start_q=0, max_q=5,
                      d=0, # Fără diferențiere pentru date staționare
                      seasonal=False,
                      information_criterion='aic',
                      trace=True)

print(model.summary())
```

**Rezultat:** Cel mai bun ordin al modelului și parametrii potriviți

## Rezumat Flux de Lucru

### 1. Pregătirea datelor

- ▶ Verificați valori lipsă, valori aberante
- ▶ Transformați dacă este necesar (log, diferențiere)

### 2. Verificarea staționarității

- ▶ Inspecție vizuală: grafic temporal, ACF
- ▶ Teste formale: ADF, KPSS
- ▶ Diferențiați dacă este nestaționar

### 3. Identificarea modelului

- ▶ Tipare ACF/PACF
- ▶ Căutare pe grilă cu criterii informaționale


### 4. Eștimare și diagnosticare

- ▶ Potriviiți modelul, verificați semnificația
- ▶ Analiză reziduală, testul Ljung-Box

### 5. Prognoză

- ▶ Prognoze punctuale cu intervale de încredere
- ▶ Validare în afără eșantionului


## Studiu de Caz: Petele Solare (Sunspots)



### Descrierea Datelor

**Numărul anual de pete solare (1700–2008):** Set de date clasic în analiza seriilor de timp. Serie staționară cu cicluri de aproximativ 11 ani. Vom aplica metodologia Box-Jenkins completă.


## Pasul 1: Analiza ACF/PACF



### Identificare

- ☐ **ACF:** Descreștere lentă, sinusoidală — sugerează AR
- ☐ **PACF:** Vârfuri semnificative la lag-urile 1, 2, 9 — sugerează AR(9) sau AR(2)
- ☐ Seria pare staționară (nu necesită diferențiere,  $d = 0$ )

## Pasul 2: Compararea Modelelor

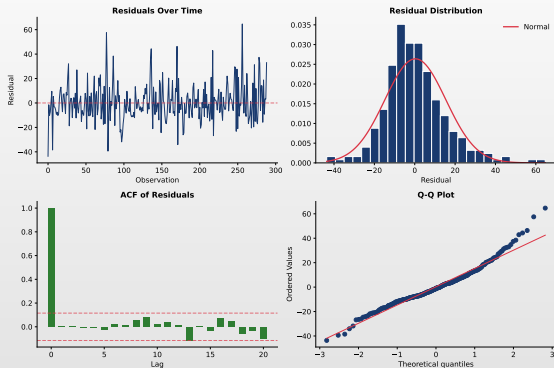


### Selecția Modelului

Comparăm mai multe modele candidate folosind criteriul AIC. Modelul **AR(9)** are cel mai mic AIC, capturând ciclul solar de 11 ani.




## Pasul 3: Verificarea Diagnostică



### Diagnostic AR(9)

Reziduurile seamănă cu zgomot alb: medie zero, varianță constantă, ACF fără structură semnificativă, distribuție aproximativ normală.

## Pasul 4: Prognoză



### Rezultate

- Modelul AR(9) captează natura ciclică a petelor solare
- Intervalele de încredere de 95% acoperă majoritatea valorilor reale
- RMSE pe setul de test: aproximativ 30 (rezonabil pentru această serie volatilă)

## Concluzii Cheie

1. **Modele AR( $p$ ):** Valoarea curentă depinde de  $p$  valori trecute
  - ▶ Staționaritate: rădăcinile lui  $\phi(z)$  în afără cercului unitate
  - ▶ PACF se întrerupe la lag  $p$
2. **Modele MA( $q$ ):** Valoarea curentă depinde de  $q$  șocuri trecute
  - ▶ Întotdeauna staționar; invertibilitate: rădăcinile lui  $\theta(z)$  în afără cercului unitate
  - ▶ ACF se întrerupe la lag  $q$
3. **ARMA( $p,q$ ):** Combină AR și MA pentru modelare flexibilă
  - ▶ Atât ACF cât și PACF scad
4. **Box-Jenkins:** Identificare  $\rightarrow$  Eștimare  $\rightarrow$  Diagnosticare  $\rightarrow$  Prognoză
5. **Diagnosticare:** Reziduurile trebuie să fie zgomot alb
6. **Prognoze:** Converge la medie; incertitudinea crește cu orizontul

## Previzualizare Capitolul Următor

### Capitolul 3: ARIMA și Modele Sezoniere

- ▣ ARIMA(p,d,q): Modele integrate pentru date nestaționare
- ▣ ARIMA Sezonier: SARIMA(p,d,q)(P,D,Q)<sub>s</sub>
- ▣ Diferențiere sezonieră
- ▣ Aplicații practice cu tipare sezoniere

### Lectură:

- ▣ Hyndman & Athanasopoulos, *Forecasting: Principles and Practice*, Cap. 9
- ▣ Box, Jenkins, Reinsel & Ljung, *Time Series Analysis*, Cap. 3-4

## Referințe



Box, G.E.P., Jenkins, G.M., Reinsel, G.C., & Ljung, G.M. (2015). *Time Series Analysis: Forecasting and Control*. 5th ed., Wiley.



Hamilton, J.D. (1994). *Time Series Analysis*. Princeton University Press.



Hyndman, R.J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. 3rd ed., OTexts.  
<https://otexts.com/fpp3/>



Brockwell, P.J., & Davis, R.A. (2016). *Introduction to Time Series and Forecasting*. 3rd ed., Springer.



Shumway, R.H., & Stoffer, D.S. (2017). *Time Series Analysis and Its Applications*. 4th ed., Springer.

## Surse de Date și Software

### Pachete Software:

- ▣ statsmodels – Modele statistice pentru Python, inclusiv ARIMA
- ▣ pmdarima – Selecție automată ARIMA pentru Python
- ▣ scipy – Optimizare și funcții statistice
- ▣ numpy, pandas – Manipulare date
- ▣ matplotlib – Vizualizare

### Date și Exemple:

- ▣ Serii de timp simulate pentru ilustrații
- ▣ Exemple bazate pe Hyndman & Athanasopoulos (2021)