



Analiza și Prognoza Seriilor de Timp

Capitolul 2: Modele ARMA



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

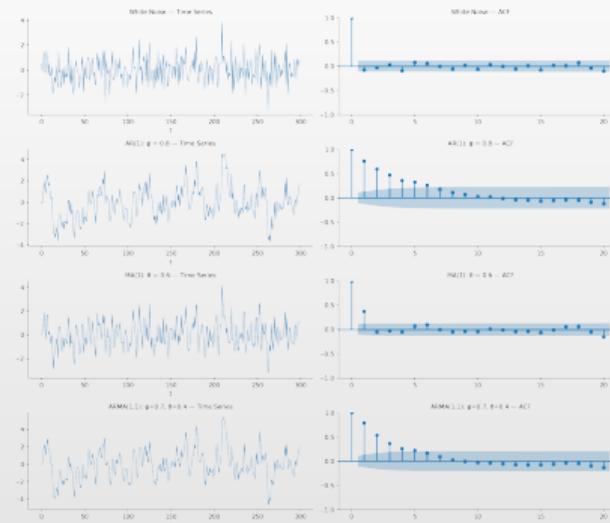
MSCA Digital Finance

Structura Cursului

- Motivație
- Introducere și Operatorul Lag
- Modele Autoregresive (AR)
- Modele de Medie Mobilă (MA)
- Modele ARMA
- Identificarea Modelului
- Estimarea Parametrilor
- Diagnosticarea Modelului
- Prognoză cu ARMA
- Implementare Practică
- Studiu de Caz: Date Reale
- Rezumat



Exemplu Motivațional: Procese Staționare

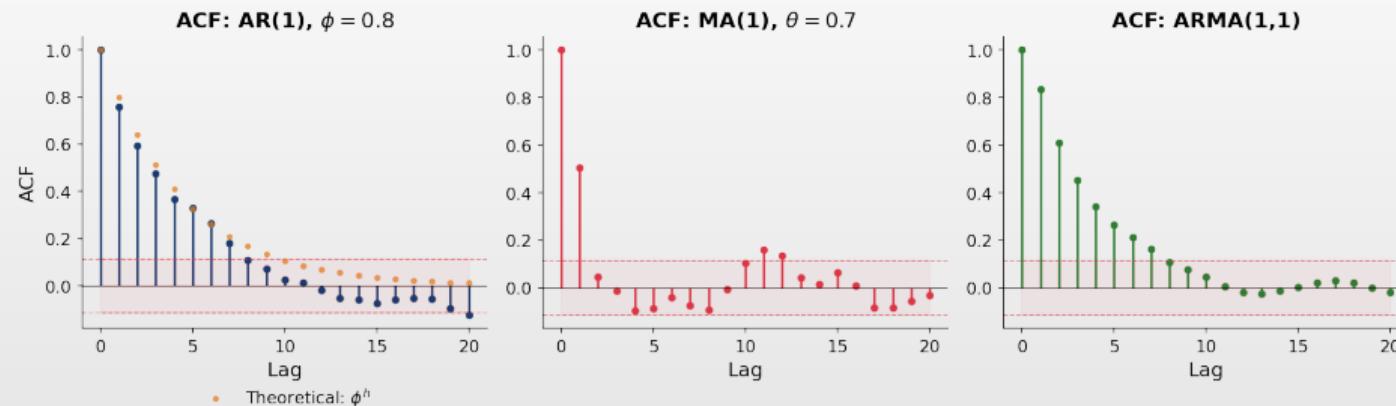


- **Procese AR:** Valoarea curentă depinde de valorile trecute — comportament de revenire la medie
- **Procese MA:** Valoarea curentă depinde de řourile trecute — memorie scurtă
- **ARMA:** Combină ambele mecanisme pentru modelare flexibilă



Identificarea Modelului prin Tipare ACF

Distinct ACF patterns for different models



ACF Dezvăluie Structura Modelului

- Diferite modele ARMA produc tipare ACF distincte
- Putem identifica modelul examinând datele!



Recapitulare: Staționaritatea

Din Capitolul 1: Un proces $\{X_t\}$ este **slab staționar** dacă:

1. $\mathbb{E}[X_t] = \mu$ (medie constantă)
2. $\text{Var}(X_t) = \sigma^2 < \infty$ (variantă constantă, finită)
3. $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$ (covarianța depinde doar de lag-ul h)

De ce contează staționaritatea pentru ARMA:

- Modelele ARMA presupun că procesul subiacent este staționar
- Datele nestaționare trebuie diferențiate mai întâi (ARIMA)
- Staționaritatea asigură parametri stabili ai modelului

Astăzi: Construim modele pentru serii de timp staționare folosind valori trecute și erori trecute.



Operatorul Lag (Operatorul de Întârziere)

Definiție 1 (Operatorul Lag)

Operatorul lag L (sau operatorul de întârziere B) deplasează o serie de timp înapoi cu o perioadă:

$$LX_t = X_{t-1}$$

Proprietăți:

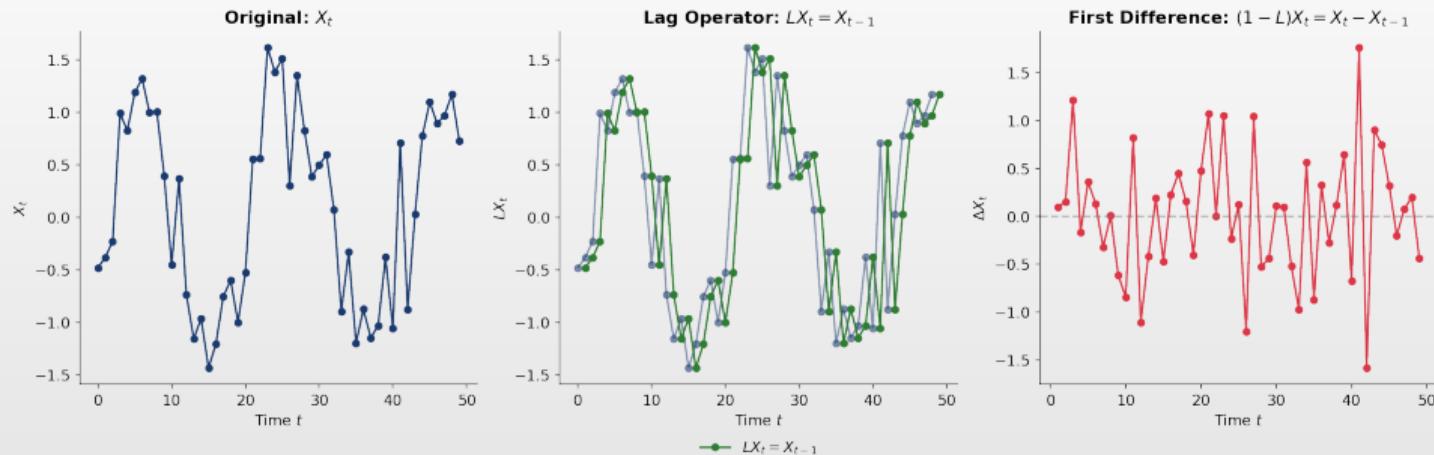
- $L^k X_t = X_{t-k}$ (deplasare înapoi cu k perioade)
- $L^0 X_t = X_t$ (identitate)
- $(1 - L)X_t = X_t - X_{t-1} = \Delta X_t$ (prima diferență)
- $(1 - L)^d X_t = \Delta^d X_t$ (diferență de ordin d)

Polinoame Lag:

$$\phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p$$

$$\theta(L) = 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q$$

Operatorul Lag: Ilustrație Vizuală



Observație cheie: Operatorul lag este fundamental notației modelelor ARMA



Procesul de Zgomot Alb

Definiție 2 (Zgomot Alb)

Un proces $\{\varepsilon_t\}$ este **zgomot alb**, notat $\varepsilon_t \sim WN(0, \sigma^2)$, dacă:

1. $\mathbb{E}[\varepsilon_t] = 0$ pentru toți t
2. $\text{Var}(\varepsilon_t) = \sigma^2$ pentru toți t
3. $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$ pentru toți $t \neq s$

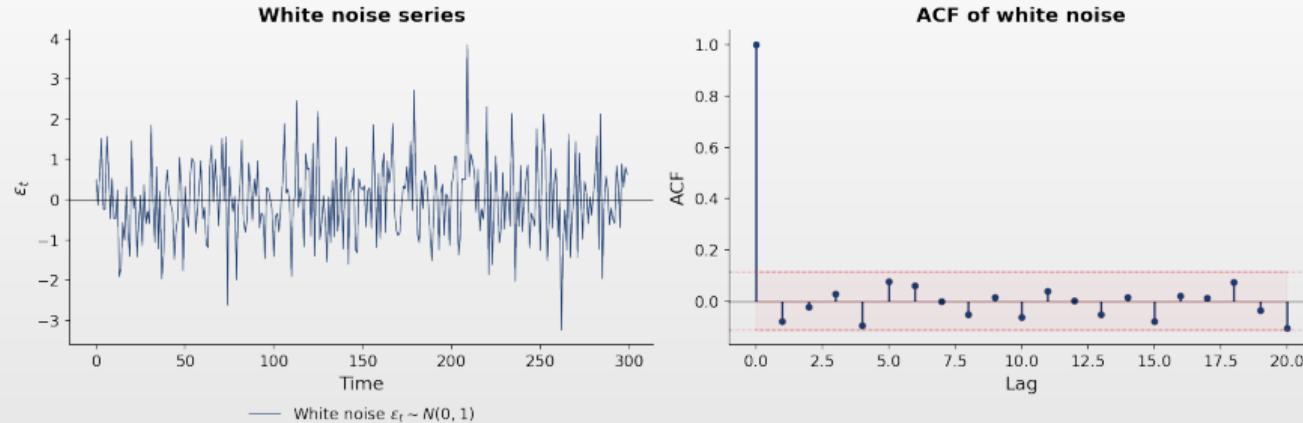
Proprietăți:

- Zgomotul alb este “blocul de construcție” al modelelor ARMA
- ACF: $\rho(0) = 1$, $\rho(h) = 0$ pentru $h \neq 0$
- PACF: același tipar
- Zgomot alb Gaussian:** adițional $\varepsilon_t \sim N(0, \sigma^2)$

Notă: Zgomotul alb *nu* este predictibil — este pur aleatoriu.



Zgomot Alb: Ilustrare Vizuală



Caracteristici Cheie

- Stânga:** Seria fluctuează aleatoriu în jurul mediei zero, fără tipare
- Dreapta:** ACF arată doar un vârf la lag 0; toate celelalte în intervalul de încredere



Modelul AR(1): Definiție

Definiție 3 (Proces AR(1))

Un proces autoregresiv de ordin 1 este:

$$X_t = c + \phi X_{t-1} + \varepsilon_t$$

unde $\varepsilon_t \sim WN(0, \sigma^2)$ și $|\phi| < 1$ pentru staționaritate.

Interpretare:

- c : constantă (interceptul)
- ϕ : coeficient autoregresiv — măsoară persistența
- ε_t : inovație (șoc impredictibil)

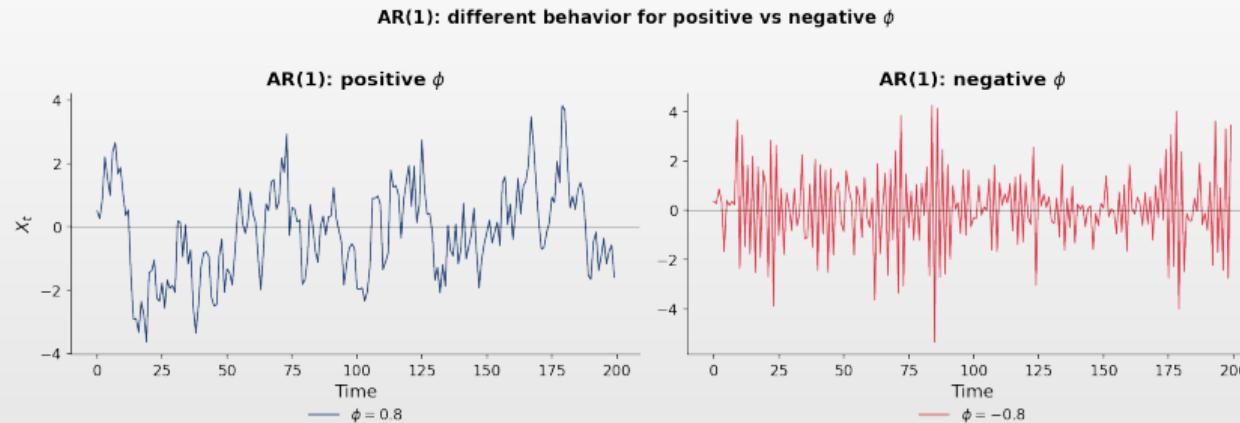
Folosind operatorul lag:

$$(1 - \phi L)X_t = c + \varepsilon_t$$

$$\phi(L)X_t = c + \varepsilon_t \quad \text{unde } \phi(L) = 1 - \phi L$$



AR(1): Ilustrație Vizuală



- ϕ pozitiv: Fluctuații persistente, revenire graduală la medie
- ϕ negativ: Comportament oscilant, alternând în jurul mediei
- $|\phi|$ mai mare \Rightarrow persistență mai mare, revenire mai lentă



Condiția de Staționaritate AR(1)

Pentru ca AR(1) să fie staționar: $|\phi| < 1$

Intuiție:

- Dacă $|\phi| < 1$: șocurile se diminuează în timp \succ staționar
- Dacă $|\phi| = 1$: mers aleatoriu \succ nestaționar (rădăcină unitară)
- Dacă $|\phi| > 1$: proces exploziv \succ nestaționar

Ecuația caracteristică:

$$\phi(z) = 1 - \phi z = 0 \implies z = \frac{1}{\phi}$$

Staționaritatea necesită ca rădăcina $z = 1/\phi$ să se afle **în afără cercului unitate**, adică $|z| > 1$, ceea ce înseamnă $|\phi| < 1$.



Proprietățile AR(1)

Pentru un AR(1) staționar cu $|\phi| < 1$:

Media:

$$\mu = \mathbb{E}[X_t] = \frac{c}{1 - \phi}$$

Varianța:

$$\gamma(0) = \text{Var}(X_t) = \frac{\sigma^2}{1 - \phi^2}$$

Autocovarianța:

$$\gamma(h) = \phi^h \gamma(0) = \frac{\phi^h \sigma^2}{1 - \phi^2}$$

Autocorelația (ACF):

$$\rho(h) = \phi^h$$

Observație cheie: ACF scade exponențial la rata ϕ



Demonstrație: Media AR(1)

Afirmătie: Pentru AR(1): $X_t = c + \phi X_{t-1} + \varepsilon_t$, media este $\mu = \frac{c}{1-\phi}$

Demonstrație: Luăm speranța ambelor părți:

$$\mathbb{E}[X_t] = \mathbb{E}[c + \phi X_{t-1} + \varepsilon_t] = c + \phi \mathbb{E}[X_{t-1}] + \mathbb{E}[\varepsilon_t]$$

Prin staționaritate, $\mathbb{E}[X_t] = \mathbb{E}[X_{t-1}] = \mu$, și $\mathbb{E}[\varepsilon_t] = 0$:

$$\mu = c + \phi\mu$$

Rezolvând pentru μ :

$$\mu - \phi\mu = c \implies \mu(1 - \phi) = c \implies \boxed{\mu = \frac{c}{1 - \phi}}$$

Cerință

- Aceasta necesită $\phi \neq 1$
- Dacă $\phi = 1$ (rădăcină unitară), media este nedefinită



Demonstrație: Varianța AR(1)

Afirmăție: $\text{Var}(X_t) = \frac{\sigma^2}{1-\phi^2}$

Demonstrație: FSPG presupunem $c = 0$ (proces centrat). Luăm varianța din $X_t = \phi X_{t-1} + \varepsilon_t$:

$$\text{Var}(X_t) = \text{Var}(\phi X_{t-1} + \varepsilon_t) = \phi^2 \text{Var}(X_{t-1}) + \text{Var}(\varepsilon_t) + 2\phi \text{Cov}(X_{t-1}, \varepsilon_t)$$

Deoarece ε_t este independent de X_{t-1} , $\text{Cov}(X_{t-1}, \varepsilon_t) = 0$:

$$\gamma(0) = \phi^2 \gamma(0) + \sigma^2$$

Prin staționaritate, $\text{Var}(X_t) = \text{Var}(X_{t-1}) = \gamma(0)$:

$$\gamma(0) - \phi^2 \gamma(0) = \sigma^2 \implies \gamma(0)(1 - \phi^2) = \sigma^2 \implies \boxed{\gamma(0) = \frac{\sigma^2}{1 - \phi^2}}$$

Notă

- Necesită $|\phi| < 1$ pentru varianță pozitivă
- Când $|\phi| \rightarrow 1$, varianță $\rightarrow \infty$

Demonstrație: Funcția de Autocorelație AR(1)

Afirmătie: $\rho(h) = \phi^h$ pentru $h \geq 0$

Demonstrație: Mai întâi, găsim autocovarianța $\gamma(h) = \text{Cov}(X_t, X_{t-h})$. Înmulțim $X_t = \phi X_{t-1} + \varepsilon_t$ cu X_{t-h} și luăm speranța:

$$\mathbb{E}[X_t X_{t-h}] = \phi \mathbb{E}[X_{t-1} X_{t-h}] + \mathbb{E}[\varepsilon_t X_{t-h}]$$

Pentru $h \geq 1$: $\mathbb{E}[\varepsilon_t X_{t-h}] = 0$ (șocul viitor necorelat cu valorile trecute)

$$\gamma(h) = \phi \gamma(h-1)$$

Aceasta este o relație recursivă! Pornind de la $\gamma(0)$:

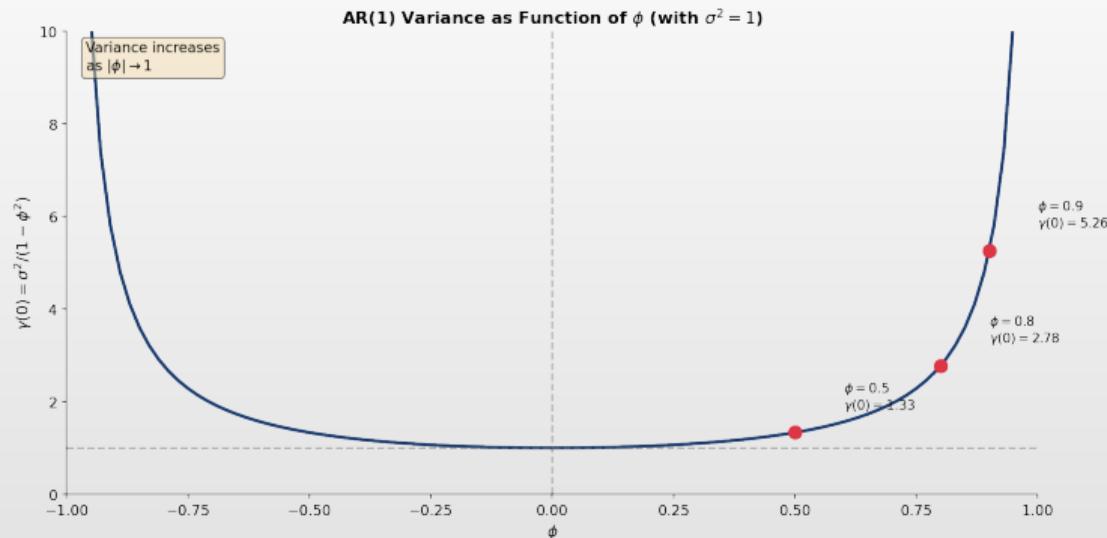
$$\gamma(1) = \phi \gamma(0), \quad \gamma(2) = \phi \gamma(1) = \phi^2 \gamma(0), \quad \dots \quad \boxed{\gamma(h) = \phi^h \gamma(0)}$$

ACF este:

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)} = \frac{\phi^h \gamma(0)}{\gamma(0)} = \boxed{\phi^h}$$



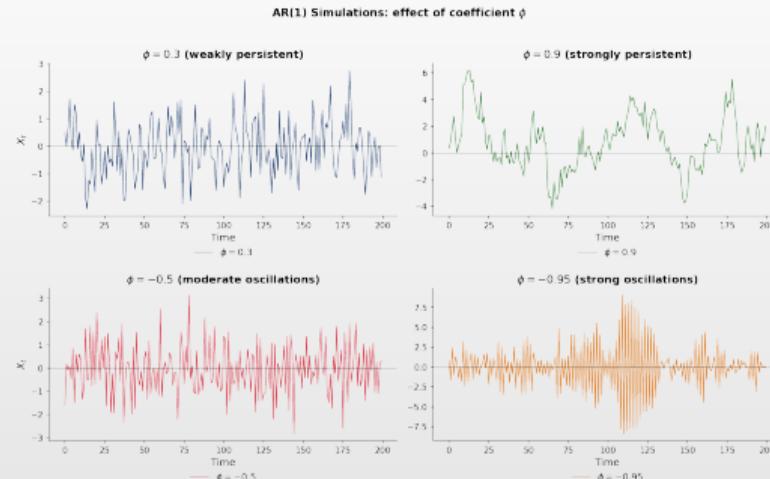
Varianța AR(1) ca Funcție de ϕ



Observație cheie: Pe măsură ce $|\phi| \rightarrow 1$, varianța explodează \rightarrow nestaționaritate



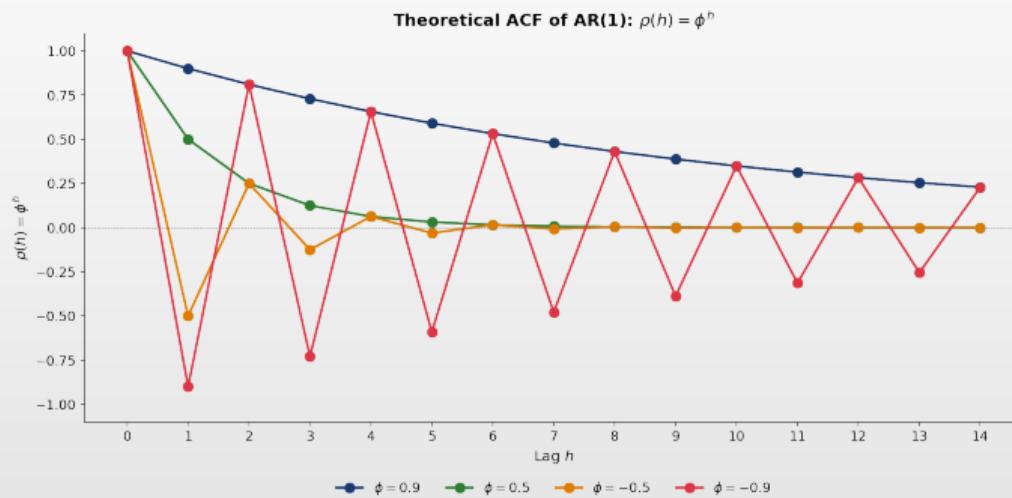
Simulări AR(1): Efectul lui ϕ



- Valori diferite ale lui ϕ produc comportamente distincte: $|\phi|$ mai mare înseamnă mai multă persistență
- ϕ pozitiv creează tipare netede, de trend; ϕ negativ creează oscilații
- Pe măsură ce $|\phi| \rightarrow 1$, procesul devine mai persistent și se apropie de nestaționaritate



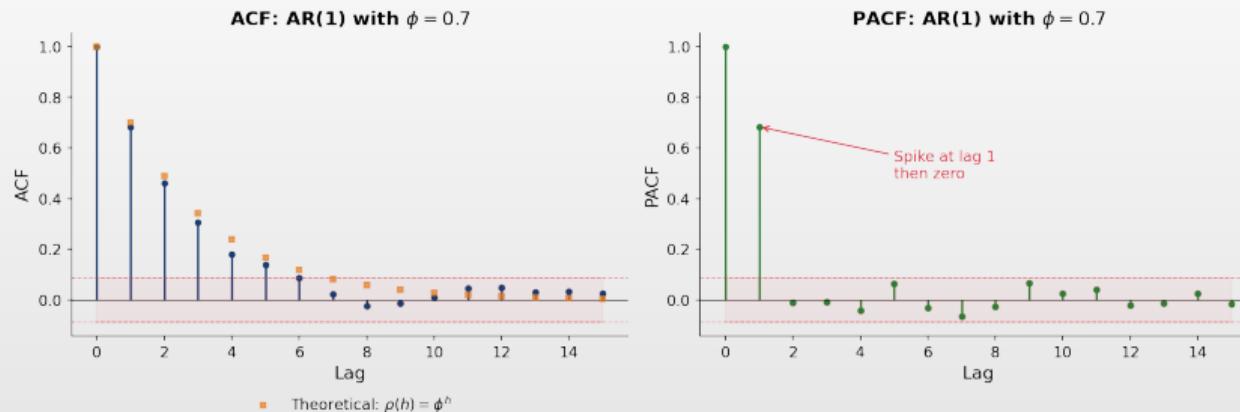
ACF Teoretic AR(1)



Tipar: $\rho(h) = \phi^h$ — descreștere exponențială (sau alternanță pentru $\phi < 0$)

ACF și PACF AR(1): Teorie vs Eșantion

ACF and PACF for AR(1): theory vs sample



- **ACF:** Descreștere exponențială la rata ϕ – formula teoretică: $\rho(h) = \phi^h$
- **PACF:** Un singur vârf la lag 1, apoi se anulează – aceasta identifică AR(1)
- Eștimările din eșantion (bare) fluctuează în jurul valorilor teoretice; folosiți benzile de încredere

Tipare ACF și PACF AR(1)

ACF al AR(1):

- Scade exponențial: $\rho(h) = \phi^h$
- Dacă $\phi > 0$: toate pozitive, descreștere graduală
- Dacă $\phi < 0$: semne alternante, descreștere în magnitudine

PACF al AR(1):

- Se anulează după lag 1
- $\pi_1 = \phi$, $\pi_k = 0$ pentru $k > 1$

	ACF	PACF
AR(1)	Descreștere exponențială	Se anulează la lag 1

Acesta este tiparul cheie de identificare pentru AR(1)!



Modelul AR(p): Forma Generală

Definiție 4 (Proces AR(p))

Un proces autoregresiv de ordin p este:

$$X_t = c + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t$$

Folosind operatorul lag:

$$\phi(L)X_t = c + \varepsilon_t$$

unde $\phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p$

Condiție de staționaritate:

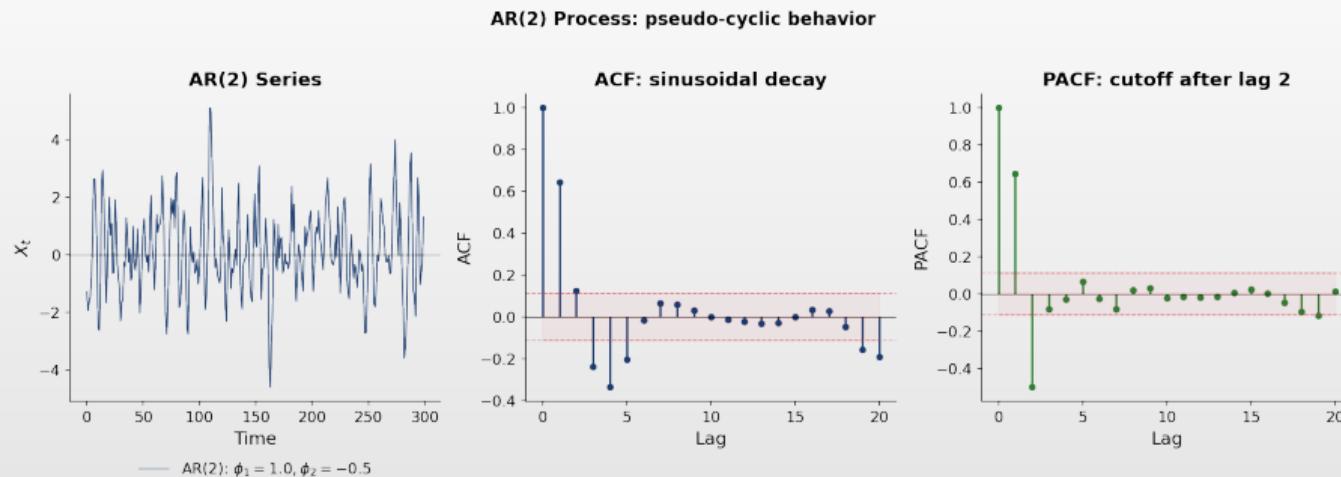
- Toate rădăcinile lui $\phi(z) = 0$ trebuie să se afle **în afără** cercului unitate
- Echivalent: toate rădăcinile au modul > 1

Tiparul PACF:

- PACF se anulează după lag p
- ACF scade (exponențial sau cu oscilații amortizate)



AR(p): Ilustrație Vizuală

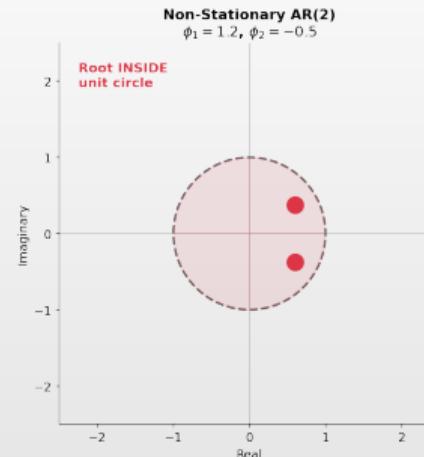
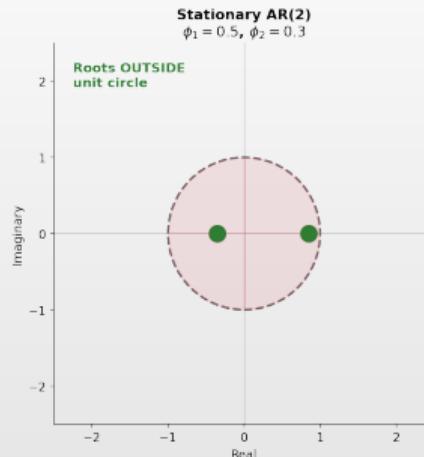


Caracteristici AR(2)

- AR(2) poate prezenta comportament pseudo-ciclic (rădăcini complexe); ACF sinusoidală amortizată
- PACF se anulează după lag 2 — tiparul cheie de identificare



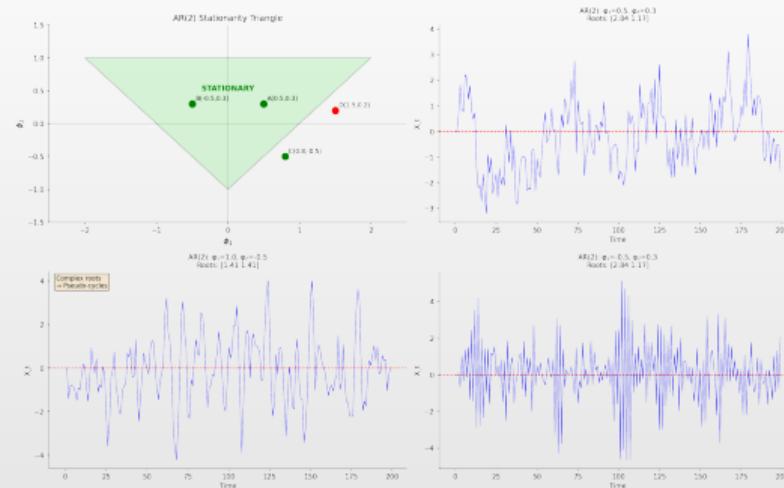
Staționaritatea AR(2): Vizualizarea Cercului Unitate



Regulă: Toate rădăcinile lui $\phi(z) = 0$ trebuie să se afle **în afără** cercului unitate umbrit



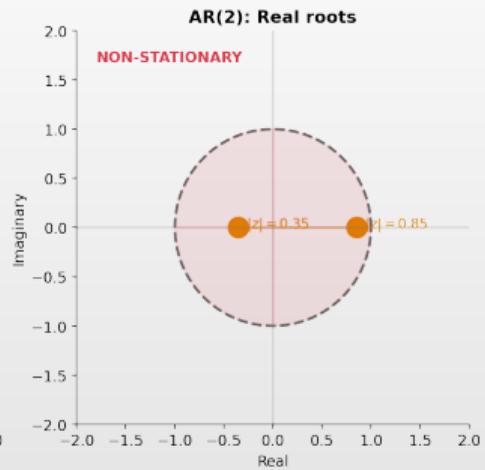
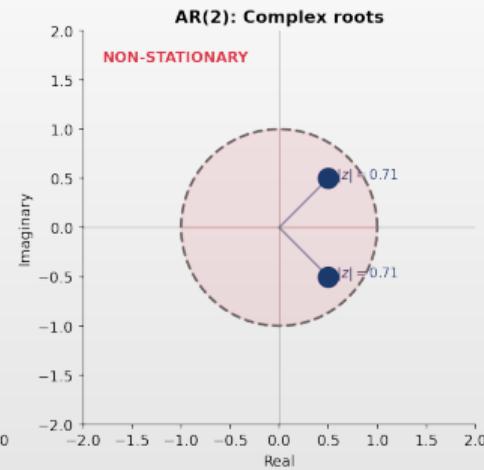
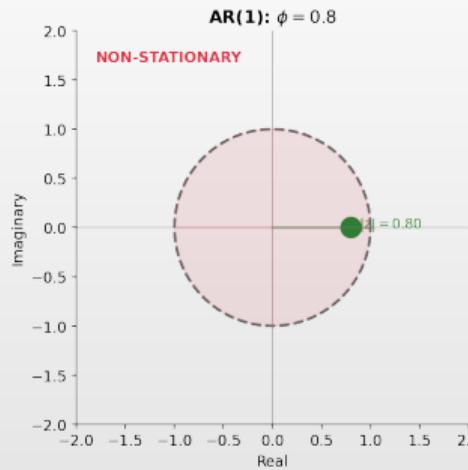
Triunghiul de Staționaritate AR(2)



- Regiunea triunghiulară definește toate combinațiile de parametri AR(2) staționari
- Granițe: $\phi_1 + \phi_2 < 1$, $\phi_2 - \phi_1 < 1$ și $|\phi_2| < 1$
- Punctele din afară acestei regiuni duc la procese nestaționare sau explosive



Rădăcinile Polinomului Caracteristic



Modelul AR(2)

Definiție 5 (Proces AR(2))

$$X_t = c + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \varepsilon_t$$

Condiții de staționaritate pentru AR(2):

1. $\phi_1 + \phi_2 < 1$
2. $\phi_2 - \phi_1 < 1$
3. $|\phi_2| < 1$

Comportamentul ACF depinde de rădăcini:

- Rădăcini reale:** amestec de două descreșteri exponențiale
- Rădăcini complexe:** tipar sinusoidal amortizat (pseudo-cicluri)

PACF: Se anulează după lag 2 ($\pi_k = 0$ pentru $k > 2$)



Quiz: Staționaritate AR

Întrebare

Pentru ce valoare a lui ϕ este procesul AR(1) $X_t = c + \phi X_{t-1} + \varepsilon_t$ staționar?

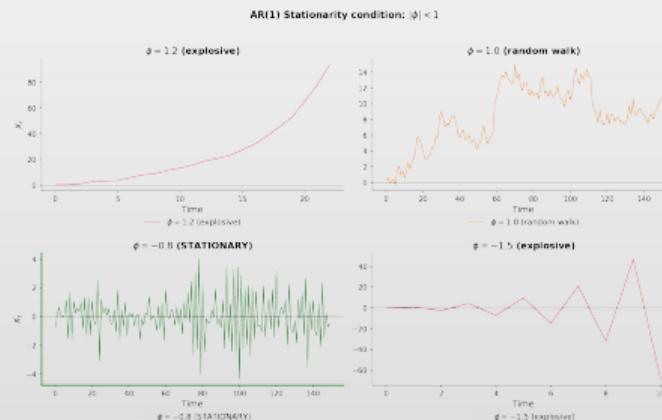
- (A) $\phi = 1.2$
- (B) $\phi = 1.0$
- (C) $\phi = -0.8$
- (D) $\phi = -1.5$



Quiz: Staționaritate AR – Răspuns

Răspuns Corect: (C) $\phi = -0.8$

- AR(1) este staționar dacă și numai dacă $|\phi| < 1$
- Doar $|-0.8| = 0.8 < 1$



Modelul MA(1): Definiție

Definiție 6 (Proces MA(1))

Un proces de medie mobilă de ordin 1 este:

$$X_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}$$

unde $\varepsilon_t \sim WN(0, \sigma^2)$.

Interpretare:

- μ : media procesului
- θ : coeficient MA — măsoară impactul șocului trecut
- Valoarea curentă depinde de șocul curent și unul trecut

Folosind operatorul lag:

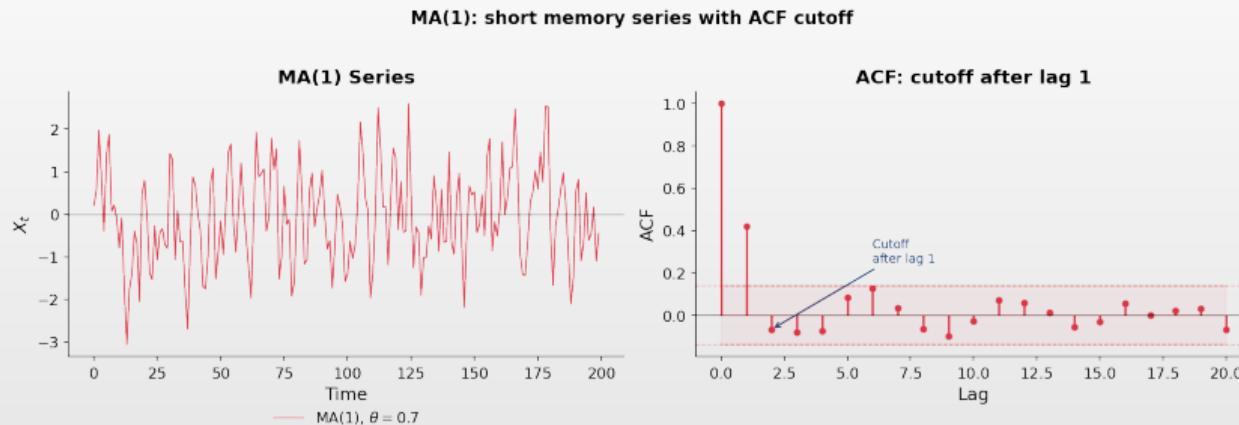
$$X_t = \mu + \theta(L)\varepsilon_t$$

unde $\theta(L) = 1 + \theta L$

Proprietate cheie: Procesele MA sunt **întotdeauna staționare** pentru orice θ finit



MA(1): Ilustrație Vizuală



- **Panoul stâng:** Serie MA(1) — mai puțin persistentă decât AR(1), revenire rapidă la medie
- **Panoul drept:** ACF arată **anulare caracteristică după lag 1**
 - ▶ Doar $\rho(1) \neq 0$; toate lagurile superioare sunt zero
 - ▶ Această anulare bruscă este identificatorul cheie pentru modele MA
- PACF descreștere exponențială (tipar opus față de AR)



Proprietățile MA(1)

Pentru MA(1): $X_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}$

Media:

$$\mathbb{E}[X_t] = \mu$$

Varianța:

$$\gamma(0) = \text{Var}(X_t) = \sigma^2(1 + \theta^2)$$

Autocovarianța:

$$\gamma(1) = \theta\sigma^2, \quad \gamma(h) = 0 \text{ pentru } h > 1$$

Autocorelația (ACF):

$$\rho(1) = \frac{\theta}{1 + \theta^2}, \quad \rho(h) = 0 \text{ pentru } h > 1$$

Observație cheie: ACF se anulează după lag 1

Demonstrație: Varianța și Autocovarianța MA(1)

Punct de plecare: $X_t = \varepsilon_t + \theta\varepsilon_{t-1}$ (presupunând $\mu = 0$)

Varianța:

$$\begin{aligned}\gamma(0) &= \text{Var}(X_t) = \text{Var}(\varepsilon_t + \theta\varepsilon_{t-1}) \\ &= \text{Var}(\varepsilon_t) + \theta^2\text{Var}(\varepsilon_{t-1}) + 2\theta\text{Cov}(\varepsilon_t, \varepsilon_{t-1}) \\ &= \sigma^2 + \theta^2\sigma^2 + 0 = \boxed{\sigma^2(1 + \theta^2)}\end{aligned}$$

Autocovarianța la lag 1:

$$\begin{aligned}\gamma(1) &= \text{Cov}(X_t, X_{t-1}) = \text{Cov}(\varepsilon_t + \theta\varepsilon_{t-1}, \varepsilon_{t-1} + \theta\varepsilon_{t-2}) \\ &= \text{Cov}(\varepsilon_t, \varepsilon_{t-1}) + \theta\text{Cov}(\varepsilon_t, \varepsilon_{t-2}) + \theta\text{Cov}(\varepsilon_{t-1}, \varepsilon_{t-1}) + \theta^2\text{Cov}(\varepsilon_{t-1}, \varepsilon_{t-2}) \\ &= 0 + 0 + \theta\sigma^2 + 0 = \boxed{\theta\sigma^2}\end{aligned}$$

Autocovarianța la lag $h \geq 2$: Niciun termen ε comun $\Rightarrow \gamma(h) = 0$



Demonstrație: Maximul ACF pentru MA(1)

Afirmatie: $|\rho(1)| \leq 0.5$ pentru orice valoare a lui θ

Demonstrație: ACF la lag 1 este:

$$\rho(1) = \frac{\gamma(1)}{\gamma(0)} = \frac{\theta\sigma^2}{\sigma^2(1+\theta^2)} = \frac{\theta}{1+\theta^2}$$

Pentru a găsi maximul, derivăm în raport cu θ și egalăm cu zero:

$$\frac{d\rho(1)}{d\theta} = \frac{(1+\theta^2) - \theta(2\theta)}{(1+\theta^2)^2} = \frac{1-\theta^2}{(1+\theta^2)^2} = 0$$

Soluție: $\theta = \pm 1$. La aceste valori:

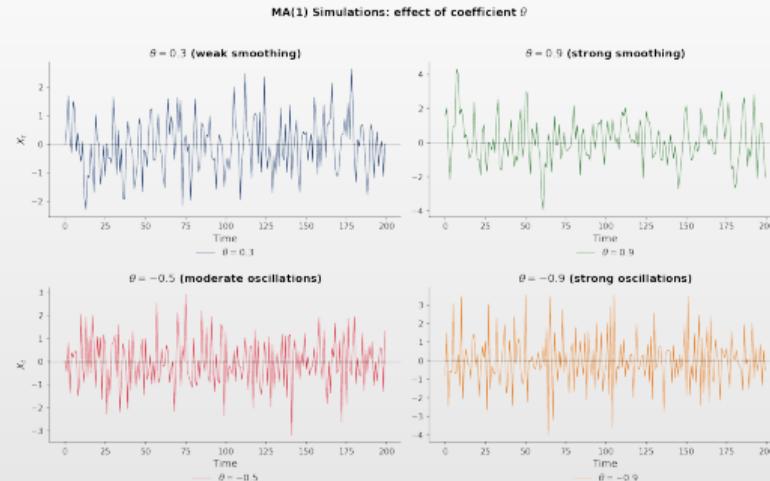
$$\rho(1)|_{\theta=1} = \frac{1}{1+1} = \frac{1}{2}, \quad \rho(1)|_{\theta=-1} = \frac{-1}{1+1} = -\frac{1}{2}$$

Implicație

- Dacă estimați $|\hat{\rho}(1)| > 0.5$ din date, procesul **nu** este MA(1)



Simulări MA(1): Efectul lui θ



- MA(1) este întotdeauna staționar indiferent de θ – memorie finită de doar un lag
- θ pozitiv netezește seria; θ negativ creează fluctuații mai rapide
- Spre deosebire de AR(1), șocurile MA(1) afectează procesul doar pentru o perioadă

Tipare ACF și PACF MA(1)

ACF al MA(1):

- Se anulează după lag 1
- $\rho(1) = \frac{\theta}{1+\theta^2}$, $\rho(h) = 0$ pentru $h > 1$
- Notă: $|\rho(1)| \leq 0.5$ întotdeauna (maxim la $\theta = \pm 1$)

PACF al MA(1):

- Scade exponențial (sau cu semne alternante)
- Nu se anulează

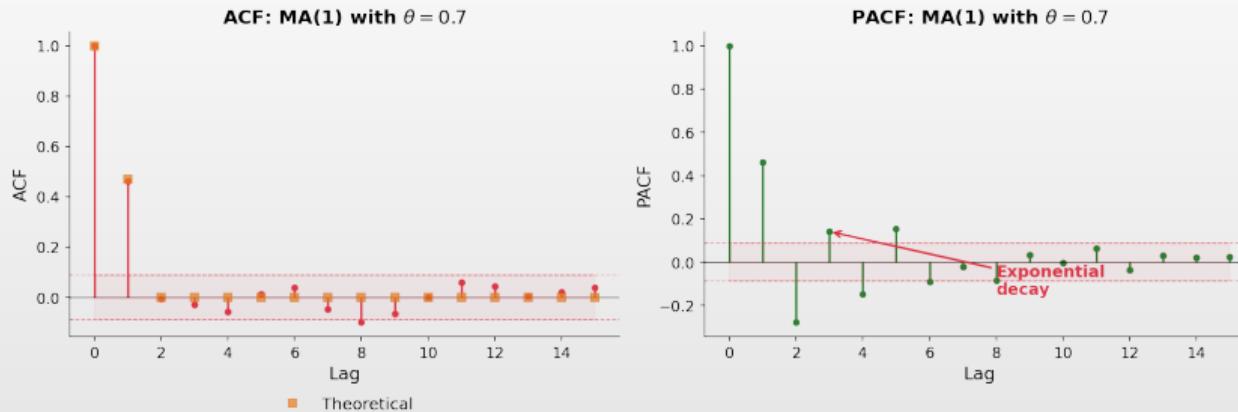
ACF	PACF
MA(1) Se anulează la lag 1	Descreștere exponențială

Acesta este tiparul opus față de AR(1)!



ACF și PACF MA(1): Comparație Vizuală

ACF and PACF for MA(1): opposite pattern to AR(1)



- **ACF:** Un singur vârf la lag 1, apoi se anulează imediat – semnătura cheie MA(1)
- **PACF:** Descreștere exponentiațională – tipar opus față de AR(1)
- Această inversare a tiparelor ACF/PACF distinge procesele MA de cele AR



Invertibilitatea Modelelor MA

Definiție 7 (Invertibilitate)

Un proces MA este **invertibil** dacă poate fi scris ca un proces AR infinit:

$$X_t = \mu + \sum_{j=1}^{\infty} \pi_j (X_{t-j} - \mu) + \varepsilon_t$$

Pentru MA(1): Invertibil dacă $|\theta| < 1$

Pentru MA(q): Toate rădăcinile lui $\theta(z) = 0$ trebuie să se afle în afără cercului unitate

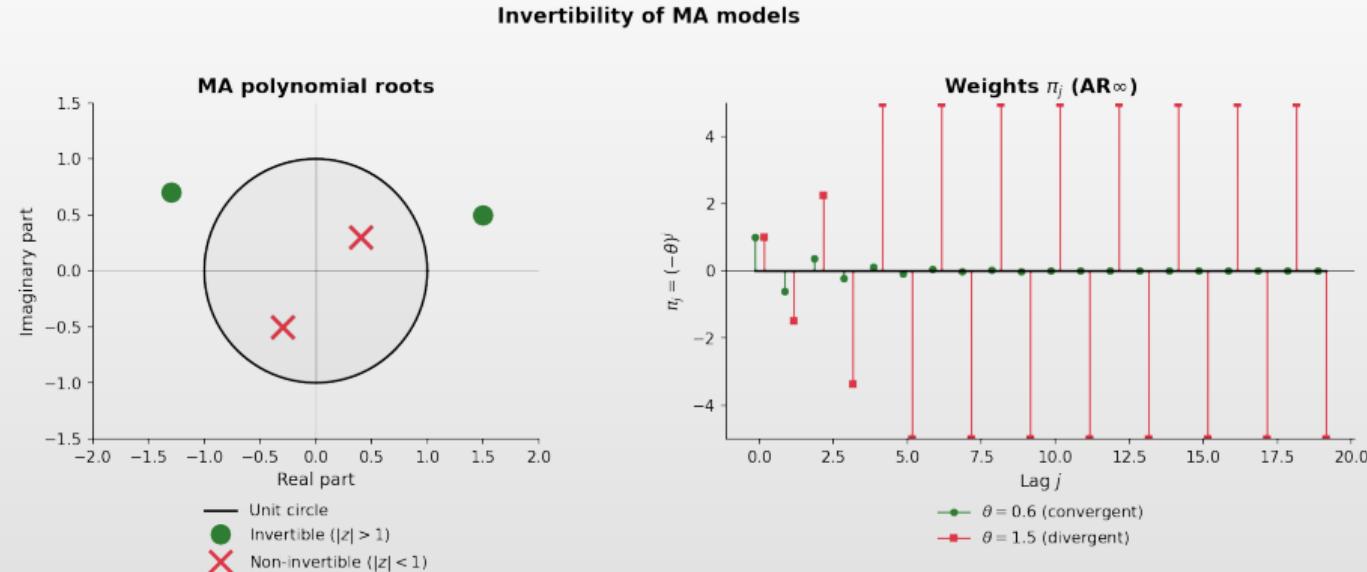
De ce contează invertibilitatea:

- Asigură reprezentare unică
- Necesară pentru prognoză și estimare
- Creează corespondență: $AR(\infty) \leftrightarrow MA(q)$

Notă: Staționaritatea este pentru AR, Invertibilitatea este pentru MA



Invertibilitate: Ilustrație Vizuală



Stânga: invertibilitatea necesită rădăcini în afara cercului unitate. Dreapta: ponderile $AR(\infty)$ scad doar când $|\theta| < 1$.



Modelul MA(q): Forma Generală

Definiție 8 (Proces MA(q))

Un proces de medie mobilă de ordin q este:

$$X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

Folosind operatorul lag:

$$X_t = \mu + \theta(L)\varepsilon_t$$

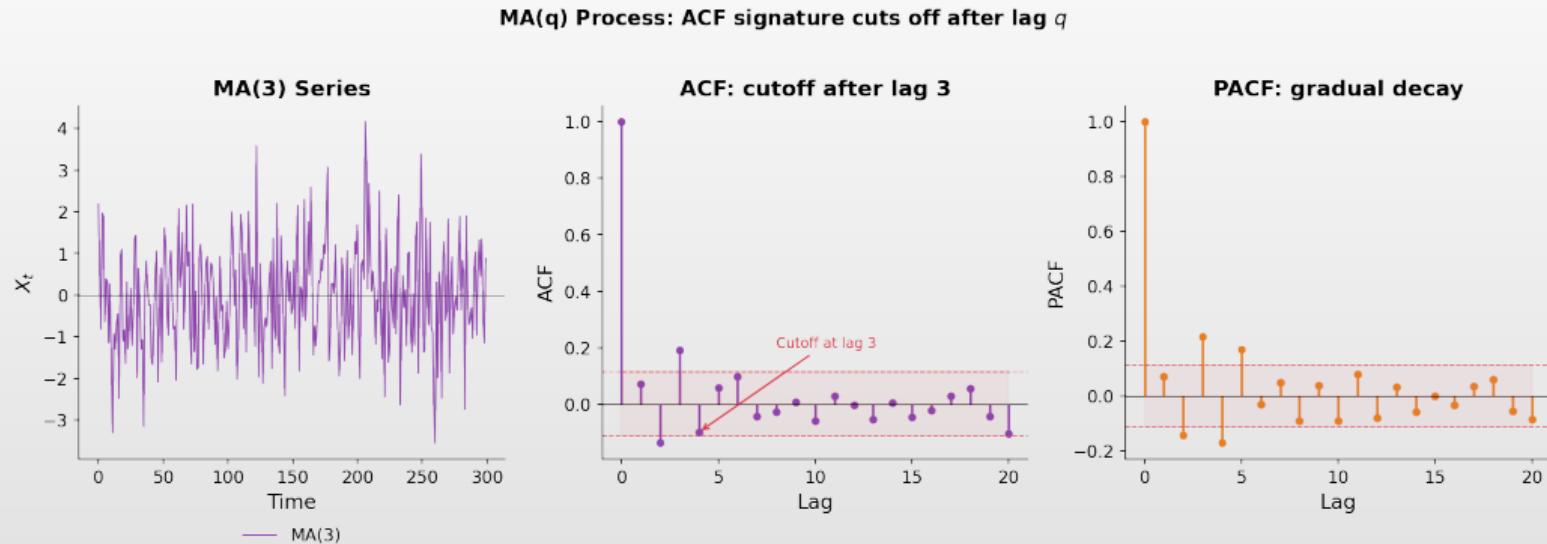
$$\text{unde } \theta(L) = 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q$$

Proprietăți:

- Întotdeauna staționar (varianță finită)
- ACF se anulează după lag q : $\rho(h) = 0$ pentru $h > q$
- PACF scade gradual
- Invertibil dacă toate rădăcinile lui $\theta(z) = 0$ se află în afără cercului unitate



MA(q): Ilustrație Vizuală



Proces MA(3). Semnătura cheie: ACF se anulează după lag q (aici, lag 3).



Quiz: Recunoașterea Tiparelor ACF/PACF

Întrebare

Observații: ACF are vârf la lag 1, apoi se anulează. PACF scade gradual. Ce model?

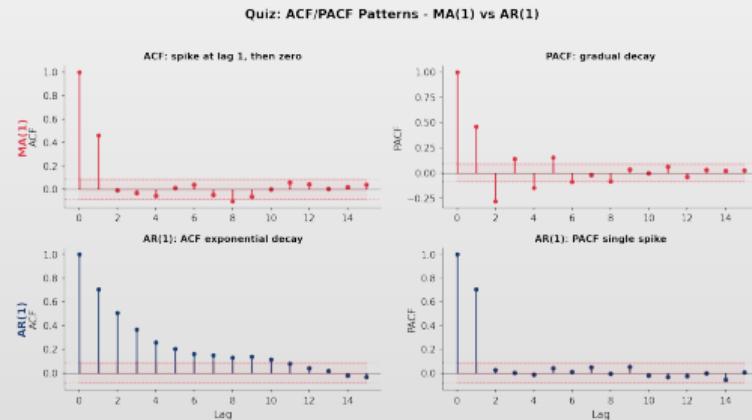
- (A) AR(1)
- (B) MA(1)
- (C) ARMA(1,1)
- (D) Zgomot alb



Quiz: Recunoașterea Tiparelor ACF/PACF – Răspuns

Răspuns Corect: (B) MA(1)

- ACF se anulează \succ proces MA
- PACF scade \succ confirmă MA(1)



Quiz: Invertibilitate MA

Întrebare

Este MA(1) $X_t = \varepsilon_t + 1.5\varepsilon_{t-1}$ invertibil?

- (A) Da, procesele MA sunt întotdeauna invertibile
- (B) Da, deoarece $1.5 > 0$
- (C) Nu, deoarece $|\theta| = 1.5 > 1$
- (D) Nu, procesele MA nu sunt niciodată invertibile



Quiz: Invertibilitate MA

Întrebare

Este MA(1) $X_t = \varepsilon_t + 1.5\varepsilon_{t-1}$ invertibil?

- (A) Da, procesele MA sunt întotdeauna invertibile
- (B) Da, deoarece $1.5 > 0$
- (C) Nu, deoarece $|\theta| = 1.5 > 1$
- (D) Nu, procesele MA nu sunt niciodată invertibile

Răspuns: (C)

- Invertibilitatea necesită $|\theta| < 1$
- Aici $|\theta| = 1.5 > 1$, deci nu este invertibil



Modelul ARMA(p,q): Definiție

Definiție 9 (Proces ARMA(p,q))

Un proces autoregresiv de medie mobilă de ordin (p,q) este:

$$X_t = c + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

Formă compactă folosind operatorii lag:

$$\phi(L)(X_t - \mu) = \theta(L)\varepsilon_t$$

sau echivalent:

$$\phi(L)X_t = c + \theta(L)\varepsilon_t$$

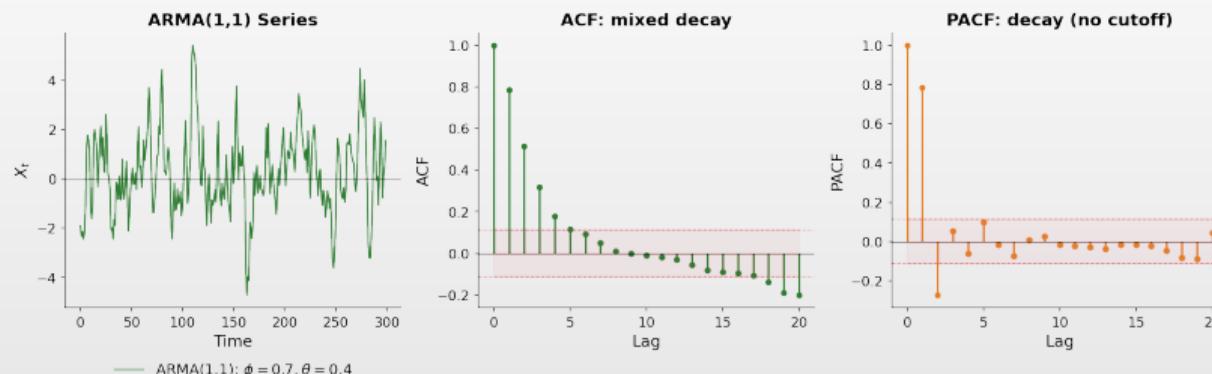
$$\text{unde } \mu = \frac{c}{1-\phi_1-\cdots-\phi_p}$$

Idee cheie: Combină componente AR și MA pentru modelare mai flexibilă



ARMA: Ilustrație Vizuală

ARMA(1,1): neither ACF nor PACF cut off



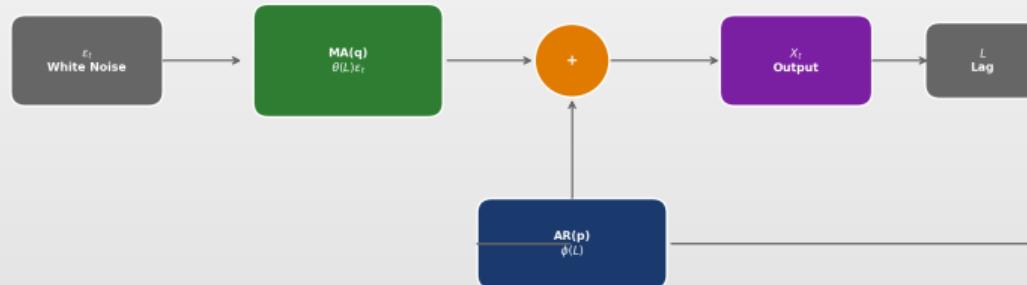
- **ARMA(1,1) combină persistența AR cu răspunsul la șocuri MA**
- **Tipar ACF:** Descreștere după primul lag (nu anulare bruscă ca MA pur)
 - ▶ Primul lag influențat atât de ϕ cât și de θ
 - ▶ Lagurile următoare descresc geometric ca AR
- **Tipar PACF:** De asemenea descreștere (nu anulare bruscă ca AR pur)
- Nici ACF nici PACF nu se întrerup — identificator cheie pentru modele mixte



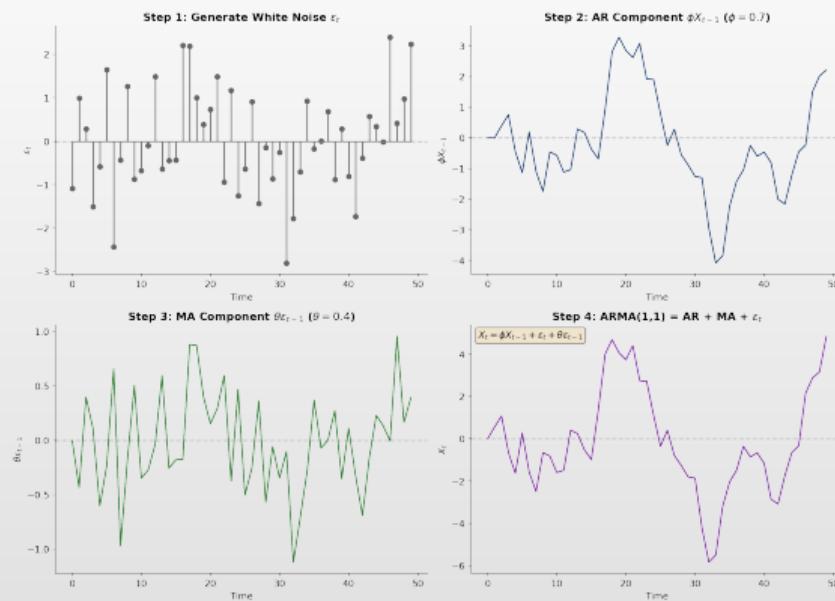
Structura Modelului ARMA

ARMA(p,q) Model Structure

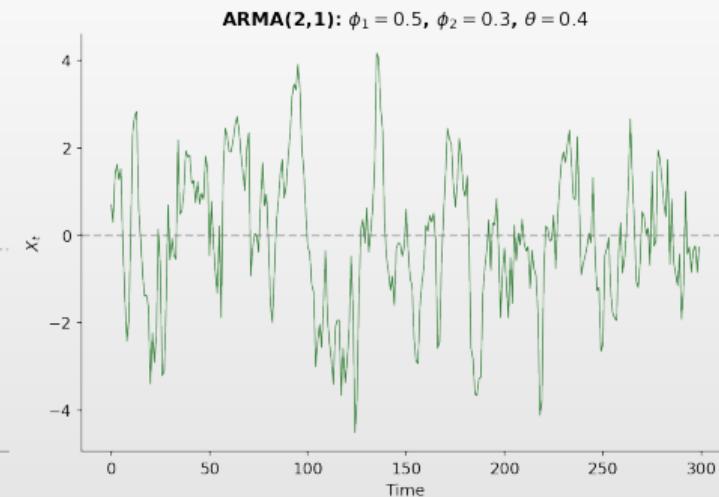
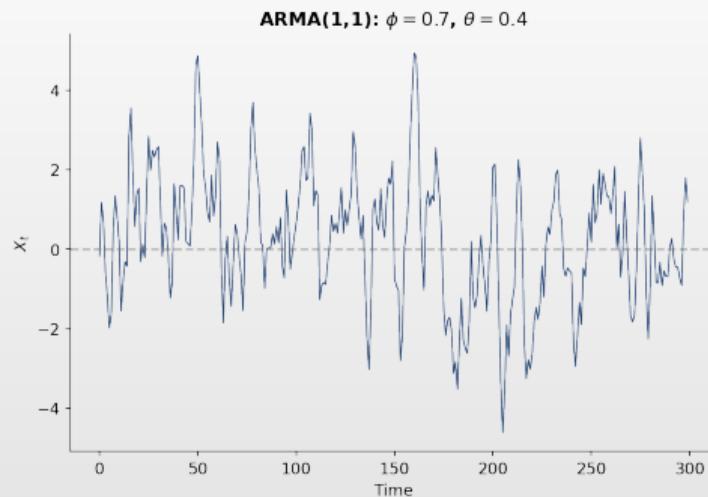
$$X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$



Cum Funcționează Simularea ARMA



Exemple ARMA



Modelul ARMA(1,1)

Definiție 10 (Proces ARMA(1,1))

$$X_t = c + \phi X_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$$

Proprietăți (presupunând staționaritate și invertibilitate):

- Media: $\mu = \frac{c}{1-\phi}$
- Varianța: $\gamma(0) = \frac{(1+2\phi\theta+\theta^2)\sigma^2}{1-\phi^2}$

ACF:

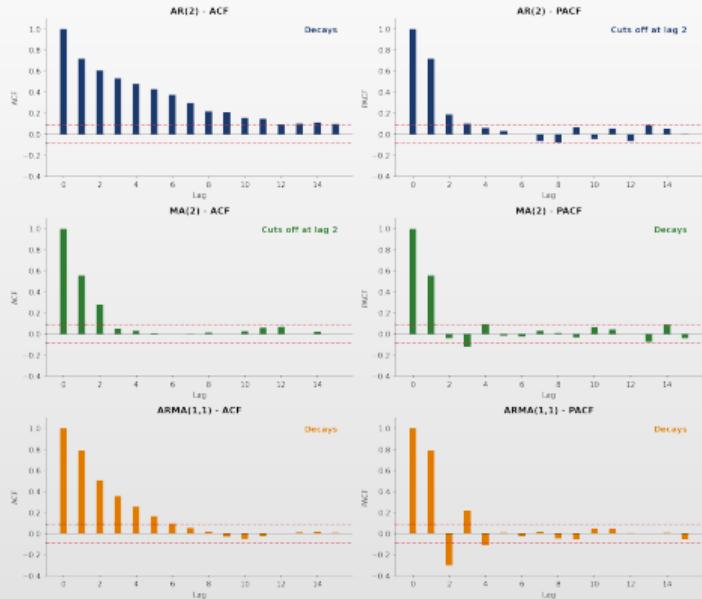
$$\rho(1) = \frac{(1 + \phi\theta)(\phi + \theta)}{1 + 2\phi\theta + \theta^2}$$

$$\rho(h) = \phi \cdot \rho(h-1) \quad \text{pentru } h \geq 2$$

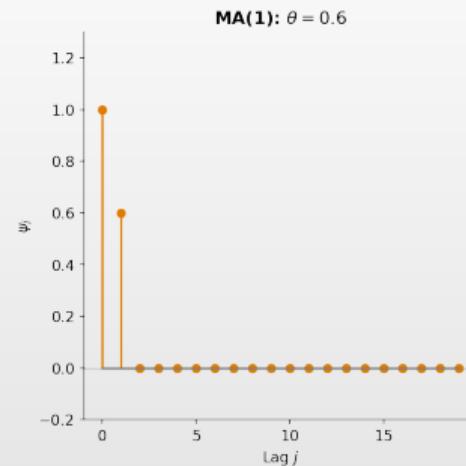
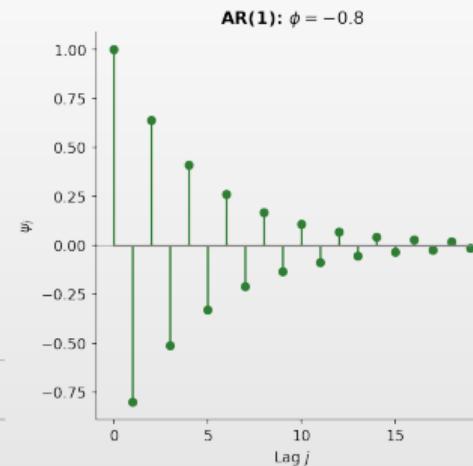
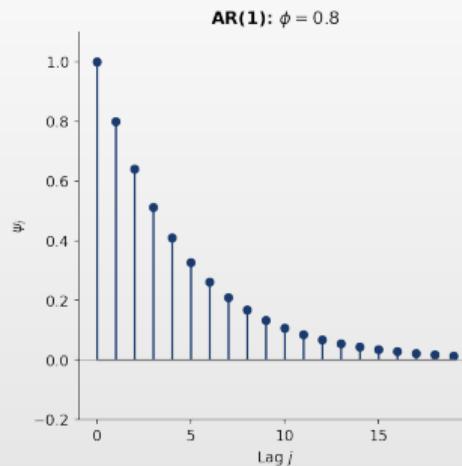
Tipar: ACF scade exponențial după lag 1 (ca AR), dar punctul de pornire depinde atât de ϕ cât și de θ



Tipare ACF/PACF: AR vs MA vs ARMA



Funcții de Răspuns la Impuls



Interpretare: Arată cum se propagă un soc unitar prin sistem în timp

Rezumat Staționaritate și Invertibilitate

Pentru ca ARMA(p,q) să fie bine comportat:

Condiție	Cerință
Staționaritate	Rădăcinile lui $\phi(z) = 0$ în afără cercului unitate
Invertibilitate	Rădăcinile lui $\theta(z) = 0$ în afără cercului unitate

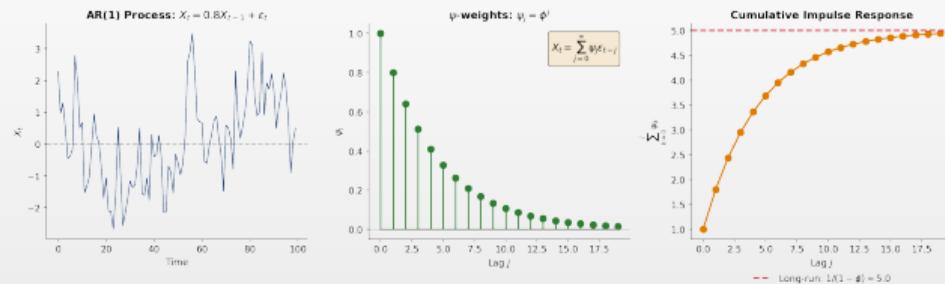
Implicații:

- Staționaritate:** Se poate scrie ca MA(∞): $X_t = \mu + \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$
- Invertibilitate:** Se poate scrie ca AR(∞): $X_t = \mu + \sum_{j=1}^{\infty} \pi_j (X_{t-j} - \mu) + \varepsilon_t$

Reprezentare cauzală: X_t depinde doar de șocurile *trecute* (nu viitoare)



Teorema de Descompunere a lui Wold



Orice proces staționar poate fi scris ca MA(∞): $X_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$

Quiz: Reprezentarea ARMA

Întrebare

Forma compactă $\phi(L)X_t = \theta(L)\varepsilon_t$ reprezintă ce model?

- (A) Model AR pur
- (B) Model MA pur
- (C) Model ARMA
- (D) Niciunul de mai sus



Quiz: Reprezentarea ARMA

Întrebare

Forma compactă $\phi(L)X_t = \theta(L)\varepsilon_t$ reprezintă ce model?

- (A) Model AR pur
- (B) Model MA pur
- (C) Model ARMA
- (D) Niciunul de mai sus

Răspuns: (C) Model ARMA

- $\phi(L)$ este polinomul AR, $\theta(L)$ este polinomul MA \succsim ARMA(p,q)

Quiz: Operatorul Lag

Întrebare

Ce este $(1 - L)^2 X_t$?

- (A) $X_t - X_{t-1}$
- (B) $X_t - 2X_{t-1} + X_{t-2}$
- (C) $X_t + X_{t-1} + X_{t-2}$
- (D) $X_t - X_{t-2}$



Quiz: Operatorul Lag

Întrebare

Ce este $(1 - L)^2 X_t$?

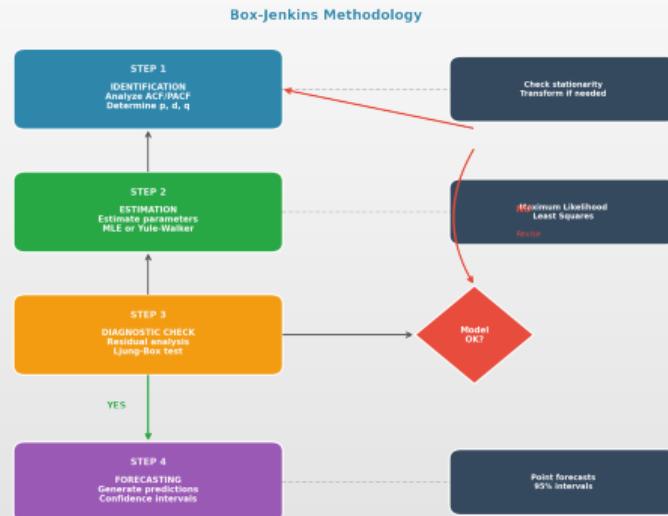
- (A) $X_t - X_{t-1}$
- (B) $X_t - 2X_{t-1} + X_{t-2}$
- (C) $X_t + X_{t-1} + X_{t-2}$
- (D) $X_t - X_{t-2}$

Răspuns: (B)

- $(1 - L)^2 = 1 - 2L + L^2$
- $(1 - L)^2 X_t = X_t - 2X_{t-1} + X_{t-2}$



Metodologia Box-Jenkins



Tabel Rezumat pentru Identificarea Modelului

Model Identification: ACF/PACF Patterns

Model	ACF Pattern	PACF Pattern
AR(p)	Exponential decay or damped oscillation	Cuts off after lag p
MA(q)	Cuts off after lag q	Exponential decay or damped oscillation
ARMA(p,q)	Exponential decay after lag q-p	Exponential decay after lag p-q

Sfat practic: Începeți simplu (p, q mici), creșteți dacă diagnosticele eșuează



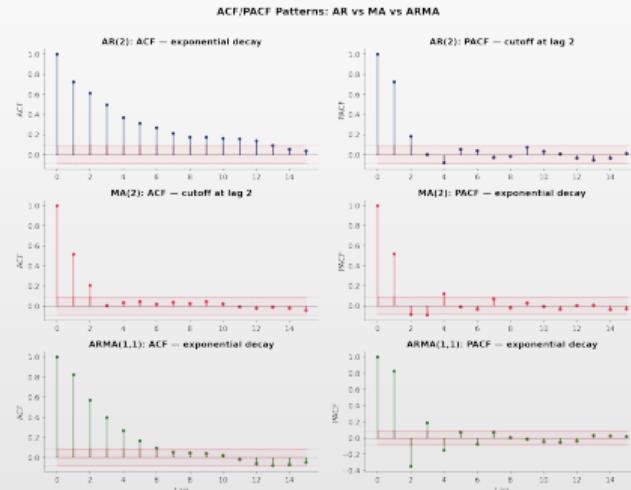
Reguli de Identificare ACF/PACF

Tipare teoretice pentru procese staționare:

Model	Tipar ACF	Tipar PACF
AR(1)	Descreștere exponențială	Vârf la lag 1, apoi 0
AR(2)	Exponențială/sinusoidă amortizată	Vârfuri la lag-uri 1-2, apoi 0
AR(p)	Scade gradual	Se anulează după lag p
MA(1)	Vârf la lag 1, apoi 0	Descreștere exponențială
MA(2)	Vârfuri la lag-uri 1-2, apoi 0	Exponențială/sinusoidă amortizată
MA(q)	Se anulează după lag q	Scade gradual
ARMA(p,q)	Scade	Scade



Tipare ACF/PACF: Ghid Vizual



- **AR**: ACF scade, PACF se anulează – folosiți PACF pentru a identifica ordinul p
- **MA**: ACF se anulează, PACF scade – folosiți ACF pentru a identifica ordinul q
- **ARMA**: Ambele scad – necesită criterii informaționale pentru selecția modelului



Criterii Informaționale

Scop: Echilibrează calitatea potrivirii față de complexitatea modelului

Criteriul Informațional Akaike (AIC):

$$AIC = -2 \ln(\hat{L}) + 2k$$

Criteriul Informațional Bayesian (BIC/SBC):

$$BIC = -2 \ln(\hat{L}) + k \ln(n)$$

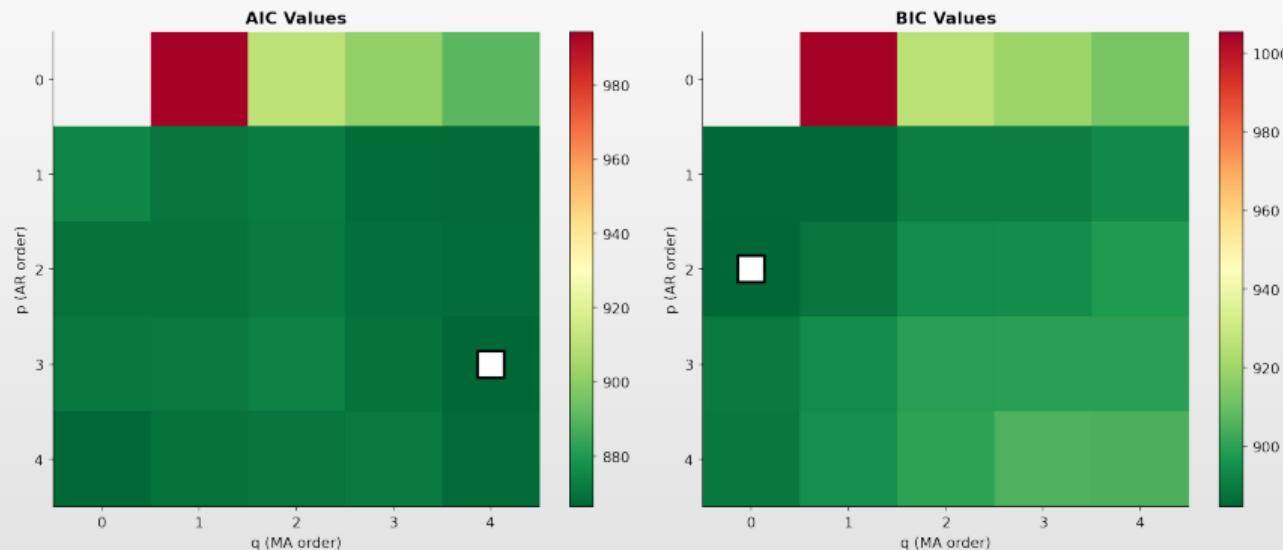
unde \hat{L} = verosimilitate maximizată, k = număr de parametri, n = dimensiune eșantion

Utilizare:

- Valori mai mici sunt mai bune
- BIC penalizează complexitatea mai puternic decât AIC
- AIC tinde să aleagă modele mai mari; BIC mai simplu
- Comparați modele potrivite pe *aceleasi date*



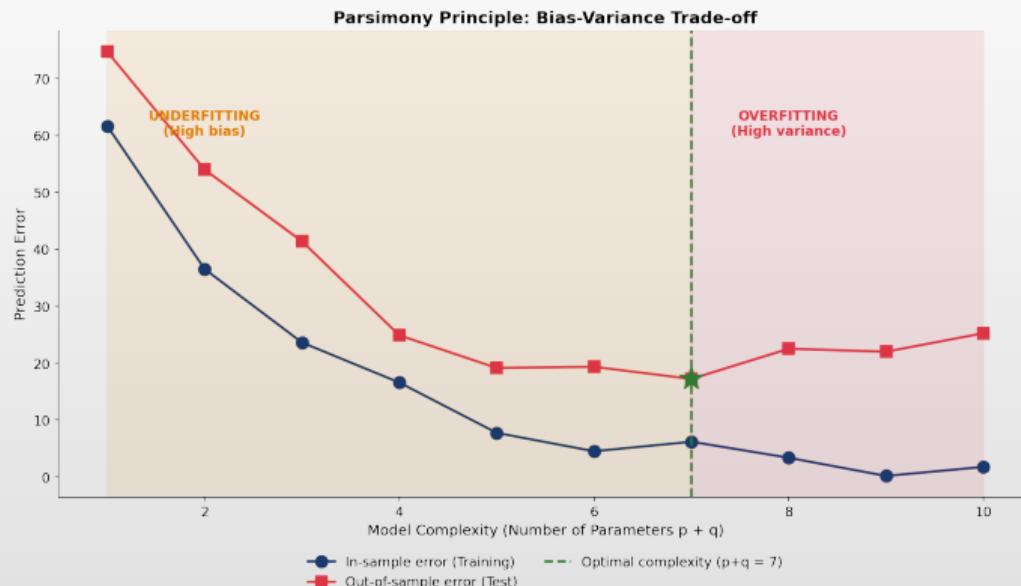
AIC vs BIC: Selecția Modelului



Notă: Pătratul alb marchează cel mai bun model; valorile mai mici (verde) sunt mai bune



Principiul Parcimoniei: Compromisul Bias-Varianță



Selectia Automata a Modelului

Abordarea cautarii pe grila:

1. Potriviti ARMA(p,q) pentru $p = 0, 1, \dots, p_{max}$ si $q = 0, 1, \dots, q_{max}$
2. Selectati modelul cu cel mai mic AIC sau BIC
3. Verificați cu teste de diagnostic

In Python (statsmodels):

- pm.auto_arima() din pachetul pmdarima
- Testeaza automat stationaritatea, cauta peste ordine
- Returneaza cel mai bun model dupa AIC/BIC

Atentie:

- Selectia automata este un punct de pornire, nu raspunsul final
- Verificați întotdeauna diagnosticele
- Considerați cunoștințele de domeniu



Quiz: Criterii Informaționale

Întrebare

Comparând ARMA(1,1) vs ARMA(2,1) folosind BIC, care este corect?

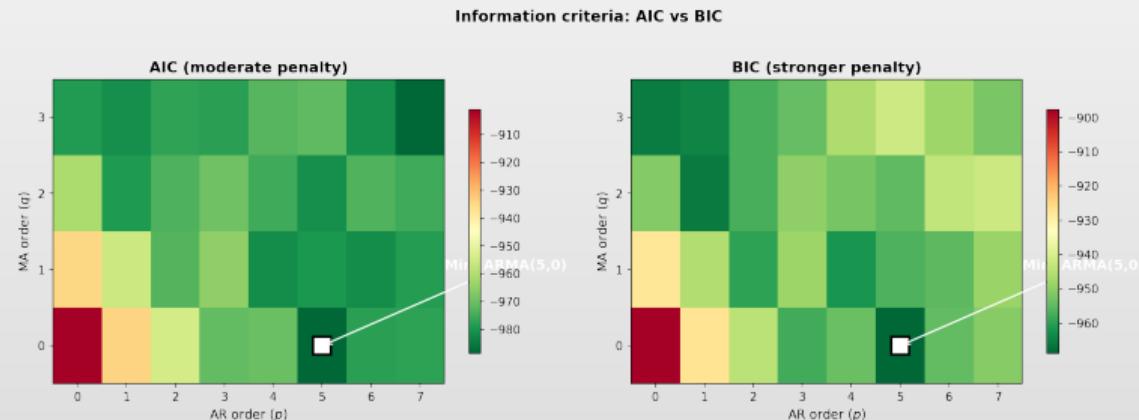
- (A) BIC mai mic înseamnă întotdeauna prognoze mai bune
- (B) BIC penalizează complexitatea mai puțin decât AIC
- (C) Modelul cu BIC mai mic este preferat
- (D) BIC poate compara doar modele cu același număr de parametri



Quiz: Criterii Informaționale – Răspuns

Răspuns Corect: (C) Modelul cu BIC mai mic este preferat

- BIC mai mic indică un compromis mai bun între estimare și complexitate
- BIC penalizează complexitatea *mai mult* decât AIC



Prezentare Generală a Metodelor de Estimare

Trei abordări principale:

1. Metoda Momentelor / Yule-Walker (doar AR)

- Potrivește autocorelațiile din eșantion la valorile teoretice
- Simplă, formă închisă pentru modele AR
- Nu este eficientă pentru componente MA

2. Estimarea prin Maximum de Verosimilitate (MLE)

- Cea mai comună abordare
- Necesită ipoteză distribuțională (de obicei Gaussiană)
- Eficientă și consistentă

3. Cele Mai Mici Pătrate Condiționate

- Minimizează suma pătratelor reziduurilor
- Condiționare pe observațiile inițiale
- Computațional mai simplă decât MLE exact



Comparația Metodelor de Estimare

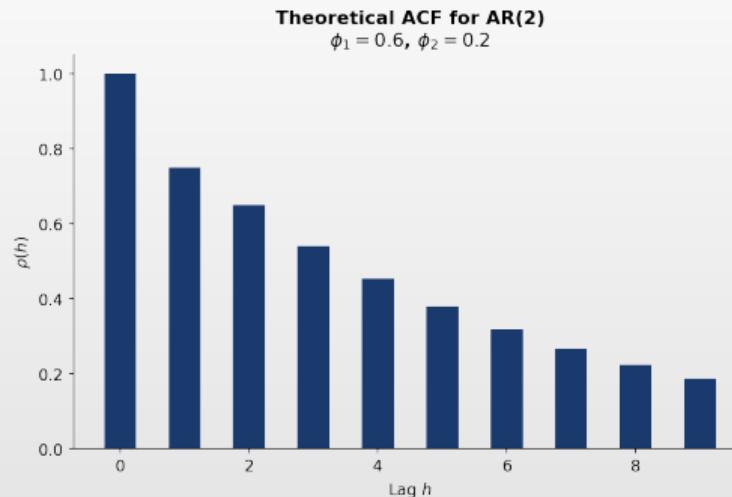
ARMA Parameter Estimation Methods

Yule-Walker	Maximum Likelihood	Conditional LS
Pros: <ul style="list-style-type: none">+ Simple computation+ Closed-form solution Cons: <ul style="list-style-type: none">- AR only- Less efficient	Pros: <ul style="list-style-type: none">+ Most efficient+ Works for ARMA Cons: <ul style="list-style-type: none">- Iterative- Local optima risk	Pros: <ul style="list-style-type: none">+ Simple to implement+ Fast computation Cons: <ul style="list-style-type: none">- Based for small n- Ignores initial values

Recommendation: Use MLE for final estimation,
Yule-Walker for initial values



Ecuatiile Yule-Walker pentru AR(p)



Yule-Walker Equations

$$\rho(1) = \phi_1 + \phi_2 \rho(1)$$

$$\rho(2) = \phi_1 \rho(1) + \phi_2$$

Matrix form: $R \cdot \phi = \rho$

R = autocorrelation matrix

Solution: $\hat{\phi} = R^{-1} \rho$

Ecuațiile Yule-Walker: Forma Matriceală

Pentru AR(p): $X_t = \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t$

Ecuațiile Yule-Walker:

$$\rho(k) = \phi_1 \rho(k-1) + \phi_2 \rho(k-2) + \cdots + \phi_p \rho(k-p)$$

pentru $k = 1, 2, \dots, p$

Forma matriceală:

$$\begin{pmatrix} \rho(0) & \rho(1) & \cdots & \rho(p-1) \\ \rho(1) & \rho(0) & \cdots & \rho(p-2) \\ \vdots & \vdots & \ddots & \vdots \\ \rho(p-1) & \rho(p-2) & \cdots & \rho(0) \end{pmatrix} \begin{pmatrix} \phi_1 \\ \phi_2 \\ \vdots \\ \phi_p \end{pmatrix} = \begin{pmatrix} \rho(1) \\ \rho(2) \\ \vdots \\ \rho(p) \end{pmatrix}$$

Estimare: Înlocuiți $\rho(k)$ cu autocorelațiile din eșantion $\hat{\rho}(k)$

Demonstrație: Ecuatiile Yule-Walker

Scop: Derivarea relației $\rho(k) = \phi_1\rho(k-1) + \cdots + \phi_p\rho(k-p)$

Demonstrație: Pornim de la AR(p): $X_t = \phi_1X_{t-1} + \cdots + \phi_pX_{t-p} + \varepsilon_t$
 Înmulțim ambele părți cu X_{t-k} și luăm speranța:

$$\mathbb{E}[X_t X_{t-k}] = \phi_1 \mathbb{E}[X_{t-1} X_{t-k}] + \cdots + \phi_p \mathbb{E}[X_{t-p} X_{t-k}] + \mathbb{E}[\varepsilon_t X_{t-k}]$$

Pentru $k \geq 1$: $\mathbb{E}[\varepsilon_t X_{t-k}] = 0$ (șocul viitor necorelat cu trecutul)

Folosind $\gamma(k) = \mathbb{E}[X_t X_{t-k}]$ (presupunând medie zero):

$$\gamma(k) = \phi_1\gamma(k-1) + \phi_2\gamma(k-2) + \cdots + \phi_p\gamma(k-p)$$

Împărțind la $\gamma(0)$:

$$\boxed{\rho(k) = \phi_1\rho(k-1) + \phi_2\rho(k-2) + \cdots + \phi_p\rho(k-p)}$$

Cazul Special AR(1)

- $\rho(k) = \phi_1\rho(k-1) = \phi_1^k$ (folosind $\rho(0) = 1$)



Estimarea prin Maximum de Verosimilitate

Presupunând erori Gaussiane: $\varepsilon_t \sim N(0, \sigma^2)$

Log-verosimilitatea pentru ARMA(p,q):

$$\ell(\phi, \theta, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{t=1}^n \varepsilon_t^2$$

unde ε_t sunt inovațiile calculate recursiv.

Procedura de estimare:

1. Inițializare: folosiți metoda momentelor sau OLS pentru valori de pornire
2. Optimizare: metode numerice (de ex., BFGS, Newton-Raphson)
3. Iterare până la convergență

În practică: Folosiți `statsmodels.tsa.arima.model.ARIMA`



Erori Standard și Inferență

Distribuția asimptotică a MLE:

$$\hat{\theta} \xrightarrow{d} N\left(\theta_0, \frac{1}{n} I(\theta_0)^{-1}\right)$$

unde $I(\theta)$ este matricea informației Fisher.

Erori standard: Rădăcina pătrată a diagonalei lui $\frac{1}{n} \hat{I}^{-1}$

Testarea ipotezelor:

- $H_0 : \phi_j = 0$ (sau $\theta_j = 0$)
- Statistică de test: $z = \frac{\hat{\phi}_j}{SE(\hat{\phi}_j)} \sim N(0, 1)$ asimptotic
- Respingeți dacă $|z| > 1.96$ la nivel de 5%

Interval de încredere: $\hat{\phi}_j \pm 1.96 \cdot SE(\hat{\phi}_j)$



Analiza Reziduurilor

Dacă modelul este corect specificat, reziduurile ar trebui să fie zgomot alb:

1. Reprezentăți grafic reziduurile în timp

- Ar trebui să fluctueze în jurul lui zero
- Fără tipare sau tenduri evidente
- Varianță constantă (fără heteroscedasticitate)

2. Verificați ACF reziduurilor

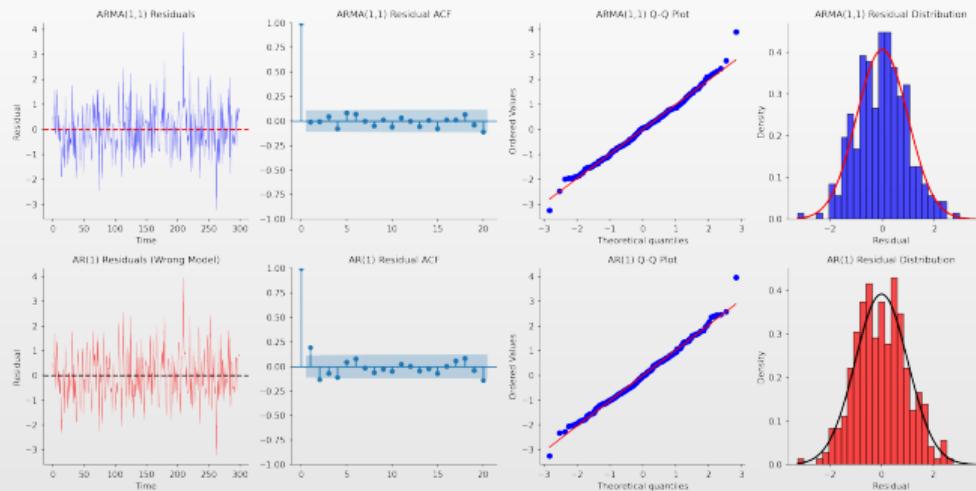
- Toate corelațiile ar trebui să fie în benzile de încredere
- Fără vârfuri semnificative \succ zgomot alb

3. Verificați histograma / graficul Q-Q

- Ar trebui să fie aproximativ normale (dacă presupunem Gaussian)
- Cozi groase sugerează erori non-normale



Diagnosticarea Reziduurilor: Exemplu



- **Graficul reziduurilor:** Ar trebui să arate dispersie aleatorie în jurul lui zero cu varianță constantă
- **ACF reziduurilor:** Fără vârfuri semnificative indică zgomot alb (ajustare bună)
- **Graficul Q-Q:** Punctele pe linia diagonală indică reziduuri distribuite normal



Testul Ljung-Box

Definiție 11 (Testul Ljung-Box)

Testează dacă reziduurile sunt distribuite independent (fără autocorelație).

Statistică de test:

$$Q(m) = n(n + 2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{n - k}$$

Ipoteze:

- H_0 : Reziduurile sunt zgomot alb (fără autocorelație până la lag m)
- H_1 : Reziduurile sunt autocorelate

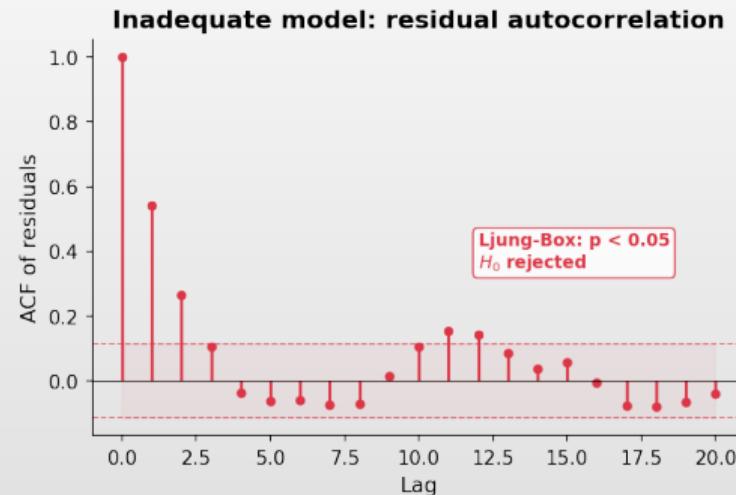
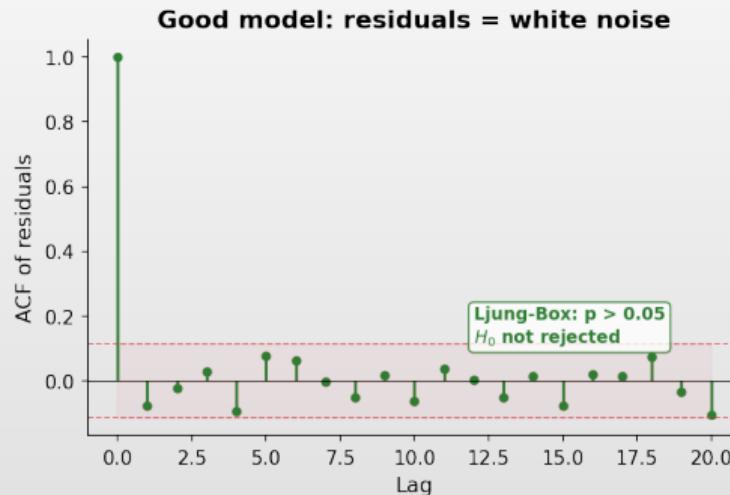
Distribuție: Sub H_0 , $Q(m) \sim \chi^2(m - p - q)$ aproximativ

Decizie:

- p-value > 0.05 \succ nu respingem H_0 \succ reziduurile arată ca zgomot alb (bine!)
- p-value < 0.05 \succ autocorelație semnificativă rămâne \succ model inadecvat

Testul Ljung-Box: Ilustrație Vizuală

Ljung-Box Test: good model vs inadequate model



Stânga: Model bun – reziduurile sunt zgomot alb (fără ACF semnificativ). Dreapta: Model slab – reziduurile arată autocorelație.



Listă de Verificare Diagnostic

Un model ARMA bun ar trebui să satisfacă:

1. **Staționaritate:** Rădăcinile AR în afără cercului unitate
✓ Verificați cu `arroots`
2. **Invertibilitate:** Rădăcinile MA în afără cercului unitate
✓ Verificați cu `maroots`
3. **Reziduuri zgomot alb:** Fără ACF semnificativ
✓ Grafic ACF, testul Ljung-Box
4. **Reziduuri normale:** (dacă presupunem)
✓ Grafic Q-Q, testul Jarque-Bera
5. **Fără heteroscedasticitate:** Varianță constantă
✓ Reprezentări reziduurile, testul ARCH
6. **Simplu:** Cel mai mic AIC/BIC dintre modelele adecvate

Dacă diagnosticele eşuează: Reveniți la identificare, încercați ordine diferite



Quiz: Testul Ljung-Box

Întrebare

După estimarea unui model ARMA, rulați testul Ljung-Box pe rezidiuuri și obțineți p-value = 0.03. Ce înseamnă asta?

- (A) Modelul este adecvat, rezidiuurile sunt zgomot alb
- (B) Modelul este inadecvat, rezidiuurile au autocorelație
- (C) Trebuie să creșteți dimensiunea eșantionului
- (D) Testul este neconcludent

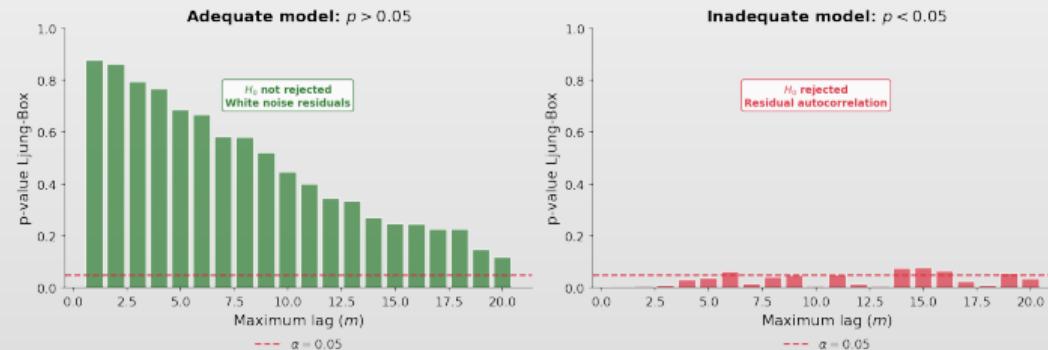


Quiz: Testul Ljung-Box – Răspuns

Răspuns Corect: (B) Modelul este inadecvat

- p-value < 0.05 respinge H_0 (zgomot alb)
- Indică autocorelație reziduală rămasă

Quiz: Interpreting the Ljung-Box test



Prognoze Punctuale

Prognoză optimă: Speranța condiționată minimizează MSE

$$\hat{X}_{n+h|n} = \mathbb{E}[X_{n+h}|X_n, X_{n-1}, \dots]$$

Pentru AR(1): $X_t = c + \phi X_{t-1} + \varepsilon_t$

$$\hat{X}_{n+1|n} = c + \phi X_n$$

$$\hat{X}_{n+2|n} = c + \phi \hat{X}_{n+1|n} = c(1 + \phi) + \phi^2 X_n$$

$$\hat{X}_{n+h|n} = \mu + \phi^h (X_n - \mu)$$

Proprietate cheie: Prognozele converg la media μ când $h \rightarrow \infty$

Pentru MA(1): $X_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}$

$$\hat{X}_{n+1|n} = \mu + \theta \varepsilon_n$$

$$\hat{X}_{n+h|n} = \mu \quad \text{pentru } h > 1$$



Incertitudinea Prognozei

Eroarea de prognoză:

$$e_{n+h|n} = X_{n+h} - \hat{X}_{n+h|n}$$

Eroarea medie pătratică de prognoză (MSFE):

$$\text{MSFE}(h) = \mathbb{E}[e_{n+h|n}^2] = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$$

unde ψ_j sunt coeficienții MA(∞).

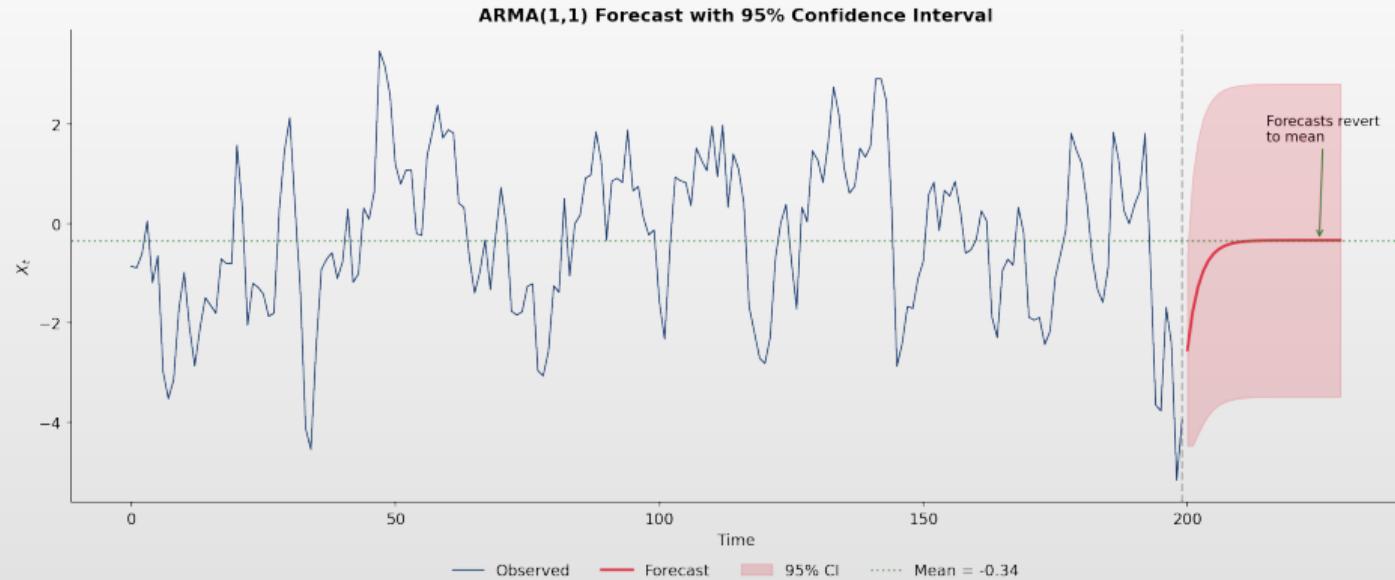
Pentru AR(1): $\psi_j = \phi^j$

$$\text{MSFE}(h) = \sigma^2 \frac{1 - \phi^{2h}}{1 - \phi^2} \rightarrow \frac{\sigma^2}{1 - \phi^2} = \text{Var}(X_t)$$

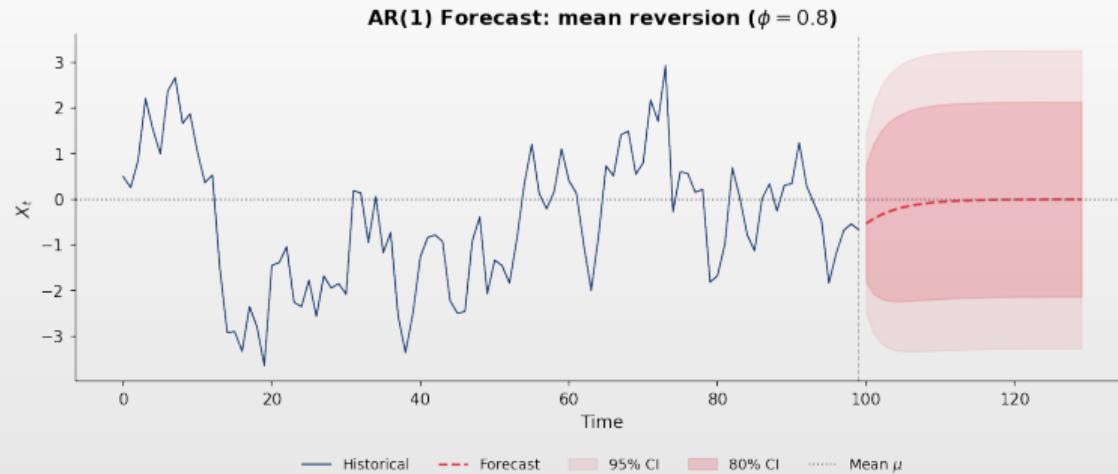
Observație cheie: Incertitudinea prognozei crește cu orizontul, ajungând eventual la varianța necondiționată



Prognosă ARMA cu Intervale de Încredere



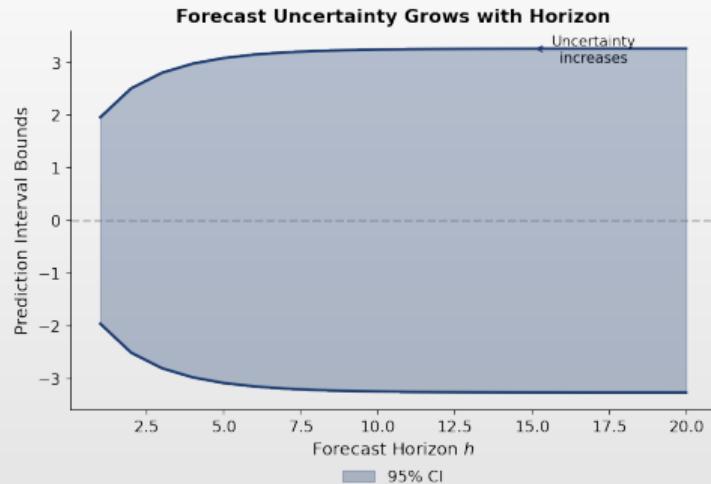
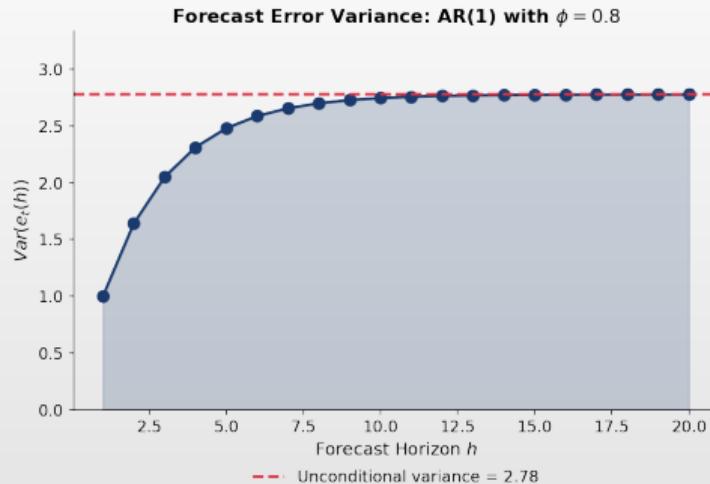
Prognosă AR(1): Revenirea la Medie



- Prognozele converg la media necondiționată μ pe măsură ce orizontul crește
- Rata de convergență depinde de $|\phi|$: valori mai mari înseamnă revenire mai lentă
- Intervalele de încredere se largesc cu orizontul, ajungând eventual la varianța necondiționată



Varianța Erorii de Prognoză în Funcție de Orizont



Intervale de Încredere pentru Prognoze

Presupunând erori Gaussiane:

$$X_{n+h}|X_n, \dots \sim N\left(\hat{X}_{n+h|n}, \text{MSFE}(h)\right)$$

Interval de încredere $(1 - \alpha)$:

$$\hat{X}_{n+h|n} \pm z_{\alpha/2} \cdot \sqrt{\text{MSFE}(h)}$$

unde $z_{\alpha/2} = 1.96$ pentru IC 95%.

Proprietăți:

- Intervalele se largesc pe măsură ce orizontul crește
- În cele din urmă converg la intervalul necondiționat: $\mu \pm z_{\alpha/2}\sigma_x$
- Lățimea depinde de parametrii modelului (coeficienți AR, etc.)

În Python: `model.get_forecast(h).conf_int()`



Evaluarea Prognozei

Testare în afără eșantionului:

1. Împărțiți datele: set de antrenare (potriviti modelul) și set de test (evaluați)
2. Generați prognoze pentru perioadă de test
3. Comparați prognozele cu valorile reale

Metrici (din Capitolul 1):

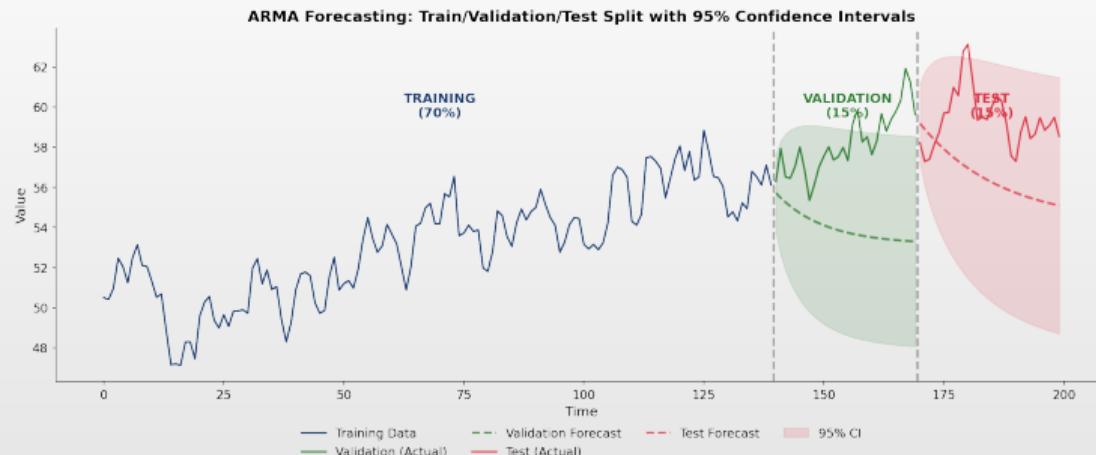
- MAE = $\frac{1}{n} \sum |e_t|$
- RMSE = $\sqrt{\frac{1}{n} \sum e_t^2}$
- MAPE = $\frac{100}{n} \sum \left| \frac{e_t}{X_t} \right|$

Fereastră mobilă/în expansiune:

- Re-estimați modelul pe măsură ce sosesc date noi
- Evaluare mai realistă a performanței proguozei



Exemplu de Prognoză Train/Validare/Test

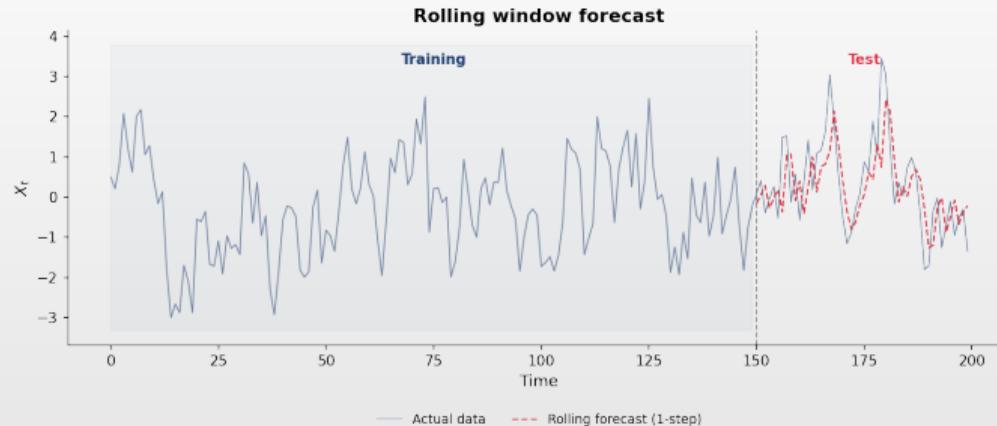


Bună Practică

- Evaluati întotdeauna prognozele pe date nevăzute (train/validation/test split)



Prognoză cu Fereastră Mobilă (Rolling Forecast)



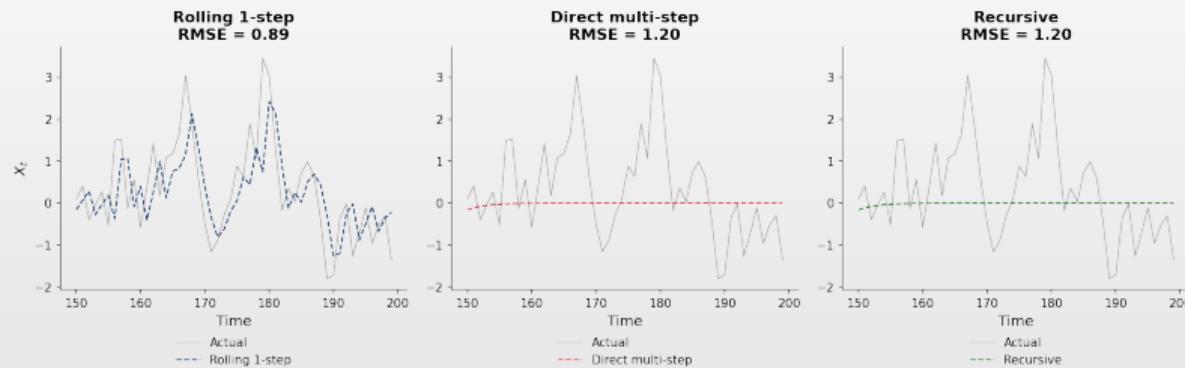
Metodologia Rolling Forecast

- ☐ **Fereastră fixă** (ultimele w obs.) vs **expansivă** (toate datele); generează prognoza 1-pas, repetă



Rolling vs Prognoză Multi-Pas

Comparison: Rolling vs Multi-step vs Recursive

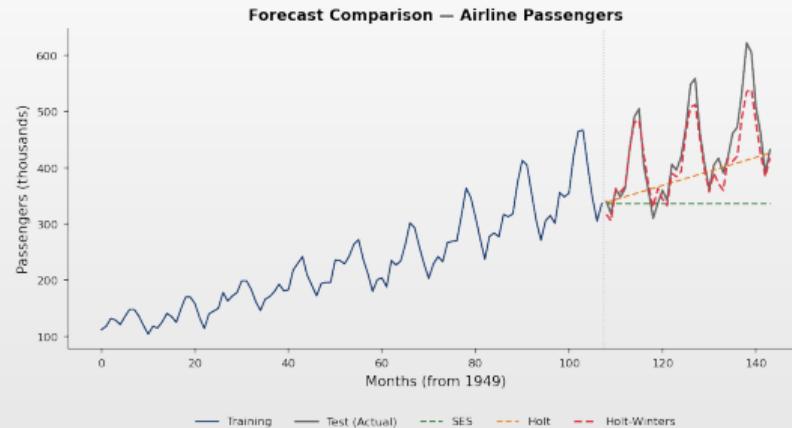


Diferențe Cheie

- Rolling 1-pas (precis); Multi-pas direct (model separat/orizont); Recursiv (acumulare erori)**



Aplicație cu Date Reale: Comparație Prognoze



Considerații Practice

- Date reale: nestaționaritate, rupturi; comparați modele; folosiți validare rolling



Quiz: Proprietățile Prognozei

Întrebare

Pentru un model AR(1) staționar, ce se întâmplă cu prognozele când orizontul $h \rightarrow \infty$?

- (A) Prognozele cresc nelimitat
- (B) Prognozele oscilează la nesfârșit
- (C) Prognozele converg la media necondiționată μ
- (D) Prognozele devin mai precise

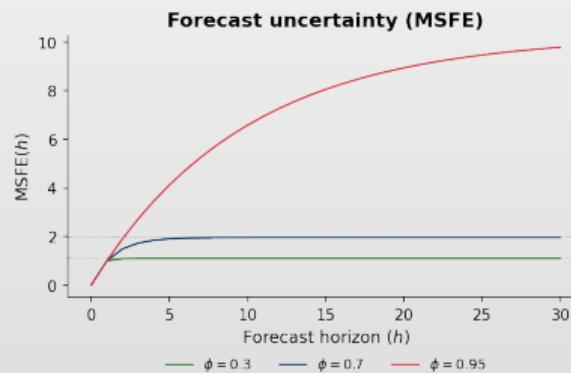
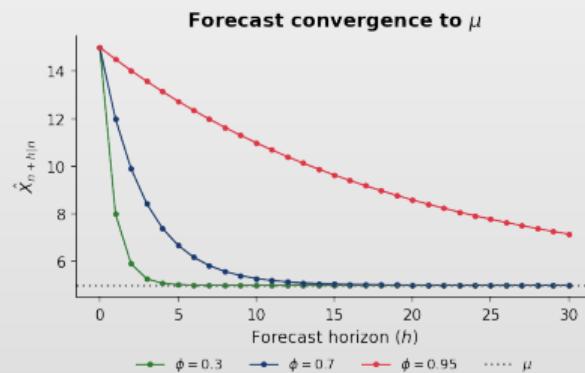


Quiz: Proprietățile Prognozei – Răspuns

Răspuns Corect: (C) Prognozele converg la μ

- $\hat{X}_{n+h|n} = \mu + \phi^h(X_n - \mu) \rightarrow \mu$ când $h \rightarrow \infty$ (deoarece $|\phi| < 1$)

Quiz: Forecast properties of stationary AR(1)



Implementare Python: Potrivirea ARMA

Folosind statsmodels:

```
from statsmodels.tsa.arima.model import ARIMA

# Potrivire ARMA(2,1) -- notă: ARIMA(p,d,q) cu d=0
model = ARIMA(data, order=(2, 0, 1))
results = model.fit()

# Rezumat
print(results.summary())

# Prognoză
forecast = results.get_forecast(steps=10)
print(forecast.predicted_mean)
print(forecast.conf_int())
```

Notă: ARIMA cu $d = 0$ este echivalent cu ARMA



Python: Selecția Modelului cu pmдарима

Selectie automată ARIMA:

```
import pmдарима as pm

# Auto ARIMA cu criteriul AIC
model = pm.auto_arima(data,
                       start_p=0, max_p=5,
                       start_q=0, max_q=5,
                       d=0, # Fără diferențiere pentru date staționare
                       seasonal=False,
                       information_criterion='aic',
                       trace=True)

print(model.summary())
```

Rezultat: Cel mai bun ordin al modelului și parametrii potriviti



Rezumat Flux de Lucru

1. Pregătirea datelor

- ▶ Verificați valori lipsă, valori aberante
- ▶ Transformați dacă este necesar (log, diferențiere)

2. Verificarea staționarității

- ▶ Inspecție vizuală: grafic temporal, ACF
- ▶ Teste formale: ADF, KPSS
- ▶ Diferențiați dacă este nestaționar

3. Identificarea modelului

- ▶ Tipare ACF/PACF
- ▶ Căutare pe grilă cu criterii informaționale

4. Estimare și diagnosticare

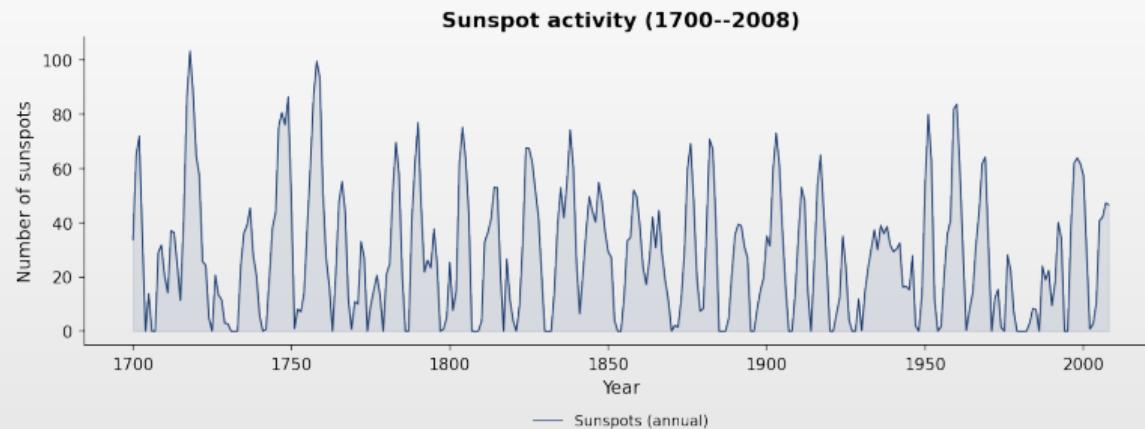
- ▶ Potriviți modelul, verificați semnificația
- ▶ Analiză reziduală, testul Ljung-Box

5. Prognoză

- ▶ Prognoze punctuale cu intervale de încredere
- ▶ Validare în afără eșantionului



Studiu de Caz: Petele Solare (Sunspots)

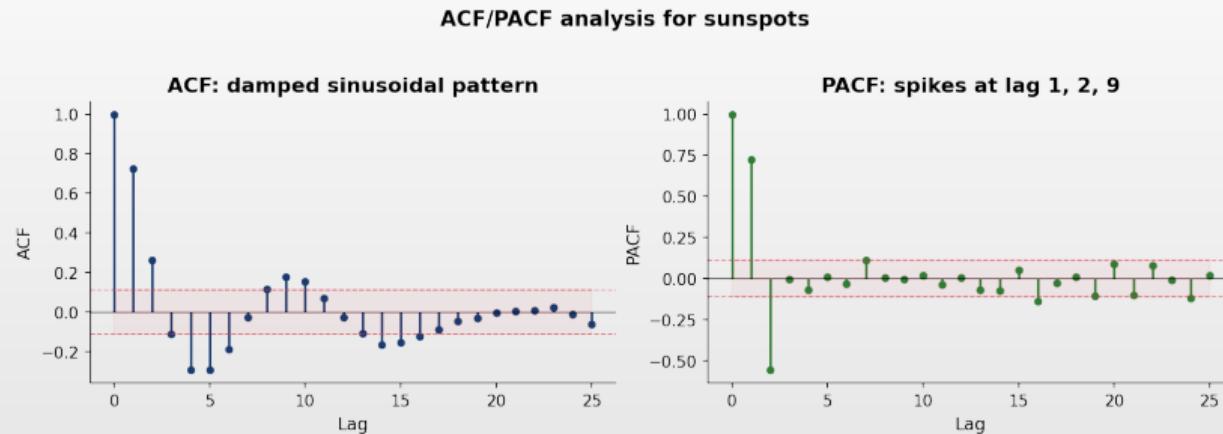


Descrierea Datelor

- Pete solare anuale (1700–2008): serie staționară cu cicluri de ~11 ani; metodologie Box-Jenkins



Pasul 1: Analiza ACF/PACF

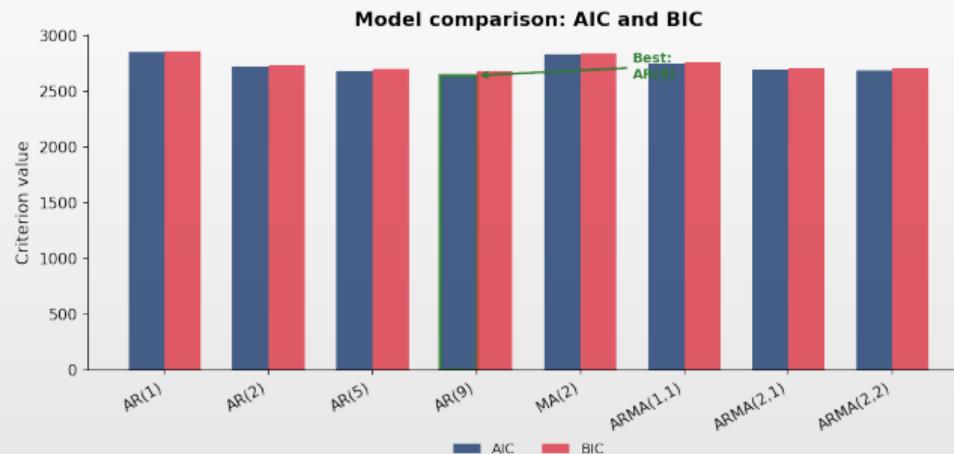


Identificare

- ACF sinusoidală (AR); PACF cu vârfuri la lag 1, 2, 9 \Rightarrow AR(2) sau AR(9); serie staționară ($d = 0$)



Pasul 2: Compararea Modelelor

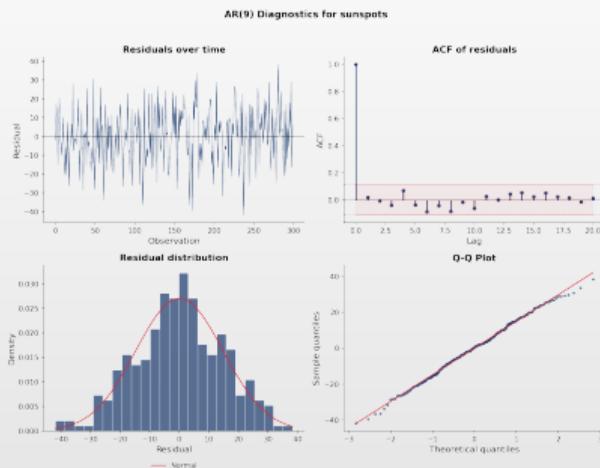


Selectia Modelului

- Comparăm mai multe modele candidate folosind criteriul AIC
- Modelul **AR(9)** are cel mai mic AIC, capturând ciclul solar de 11 ani



Pasul 3: Verificarea Diagnostică

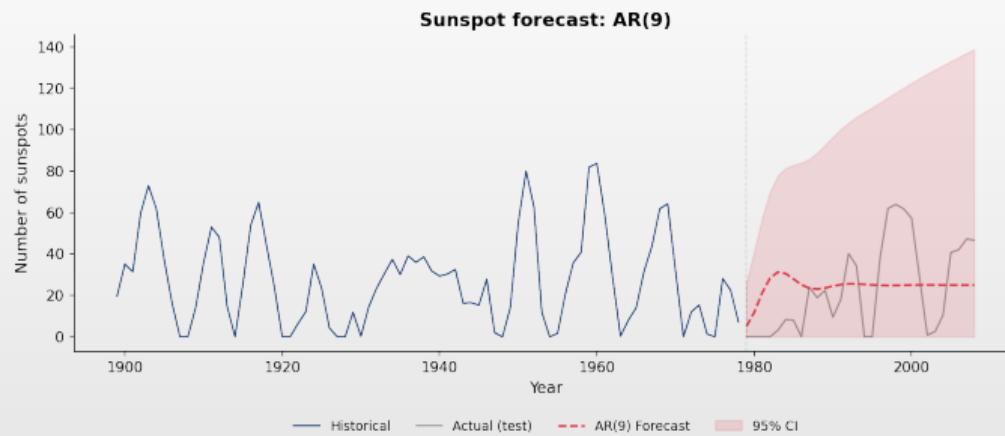


Diagnostică AR(9)

- Reziduuri: zgomot alb, medie zero, varianță constantă, ACF fără structură, \approx normal



Pasul 4: Prognoză



Rezultate

- AR(9) captează ciclicitatea; IC 95% acoperă valorile reale; RMSE ≈ 30



Concluzii Cheie

1. **AR(p):** Depinde de p valori trecute; staționaritate: rădăcini în afara cercului unitate; PACF se anulează la lag p
2. **MA(q):** Depinde de q șouri trecute; întotdeauna staționar; ACF se anulează la lag q
3. **ARMA(p,q):** Combină AR și MA; atât ACF cât și PACF scad
4. **Box-Jenkins:** Identificare → Estimare → Diagnosticare → Prognoză
5. **Diagnosticare:** Reziduurile trebuie să fie zgomot alb
6. **Prognoze:** Converg la medie; incertitudinea crește cu orizontul



Previzualizare Capitolul Următor

Capitolul 3: ARIMA și Modele Sezoniere

- ARIMA(p,d,q): Modele integrate pentru date nestaționare
- ARIMA Sezonier: SARIMA(p,d,q)(P,D,Q)_s
- Diferențiere sezonieră
- Aplicații practice cu tipare sezoniere

Lectură:

- Hyndman & Athanasopoulos, *Forecasting: Principles and Practice*, Cap. 9
- Box, Jenkins, Reinsel & Ljung, *Time Series Analysis*, Cap. 3-4

Referințe

-  Box, G.E.P., Jenkins, G.M., Reinsel, G.C., & Ljung, G.M. (2015). *Time Series Analysis: Forecasting and Control*. 5th ed., Wiley.
-  Hamilton, J.D. (1994). *Time Series Analysis*. Princeton University Press.
-  Hyndman, R.J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. 3rd ed., OTexts.
<https://otexts.com/fpp3/>
-  Brockwell, P.J., & Davis, R.A. (2016). *Introduction to Time Series and Forecasting*. 3rd ed., Springer.
-  Shumway, R.H., & Stoffer, D.S. (2017). *Time Series Analysis and Its Applications*. 4th ed., Springer.

Surse de Date și Software

Pachete Software:

- statsmodels – Modele statistice pentru Python, inclusiv ARIMA
- pmdarima – Selectie automată ARIMA pentru Python
- scipy – Optimizare și funcții statistice
- numpy, pandas – Manipulare date
- matplotlib – Vizualizare

Date și Exemple:

- Serii de timp simulate pentru ilustrații
- Exemple bazate pe Hyndman & Athanasopoulos (2021)

