



Analiza și Prognoza Seriilor de Timp

Capitolul 2: Modele ARMA

Seminar



Cuprins Seminar

- 1 Test Grilă
- 2 Întrebări Adevărat/Fals
- 3 Exerciții de Calcul
- 4 Exerciții Python
- 5 Analiză pe Date Reale
- 6 Întrebări de Discuție
- 7 Rezumat

Test 1: Operatorul Lag

Întrebare

Care este rezultatul aplicării $(1 - L)^2$ lui X_t ?

- A. $X_t - X_{t-1}$
- B. $X_t - 2X_{t-1} + X_{t-2}$
- C. $X_t + X_{t-1} + X_{t-2}$
- D. $X_t - X_{t-2}$

Răspunsul pe slide-ul următor...

Test 1: Soluție

Răspuns: $B - X_t - 2X_{t-1} + X_{t-2}$

Explicație:

$$\begin{aligned}(1 - L)^2 X_t &= (1 - 2L + L^2) X_t \\&= X_t - 2LX_t + L^2 X_t \\&= X_t - 2X_{t-1} + X_{t-2}\end{aligned}$$

Aceasta este diferența de ordinul doi a lui X_t .

Notă: $(1 - L)$ este operatorul de diferențiere de ordinul întâi, $(1 - L)^2$ este diferența de ordinul doi.

Test 2: Staționaritatea AR(1)

Întrebare

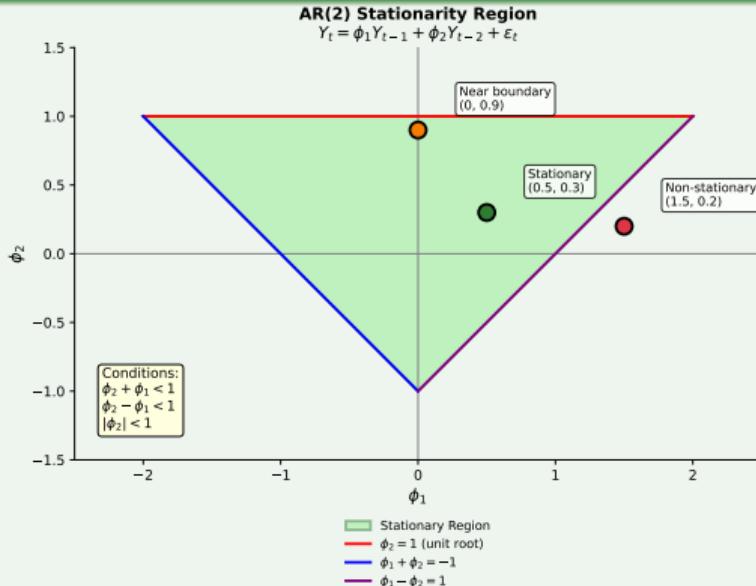
Pentru ce valoare a lui ϕ procesul AR(1) $X_t = 0.5 + \phi X_{t-1} + \varepsilon_t$ este staționar?

- A. $\phi = 1.2$
- B. $\phi = 1.0$
- C. $\phi = -0.8$
- D. $\phi = -1.5$

Răspunsul pe slide-ul următor...

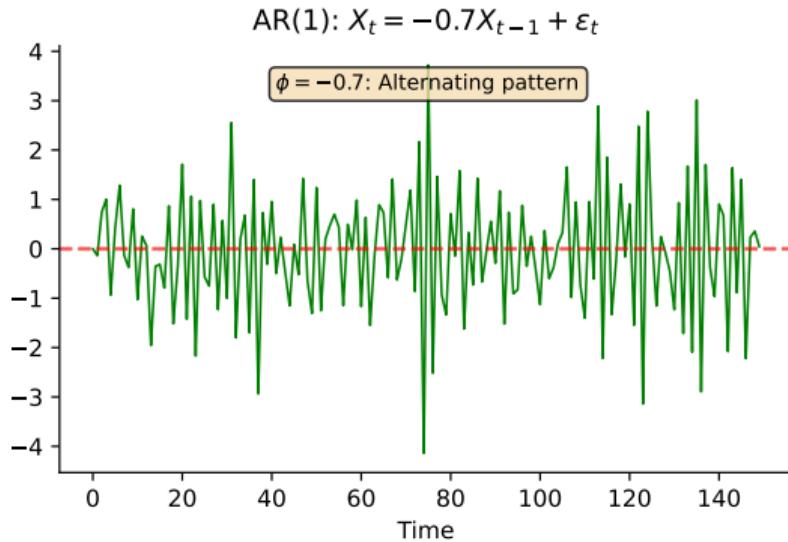
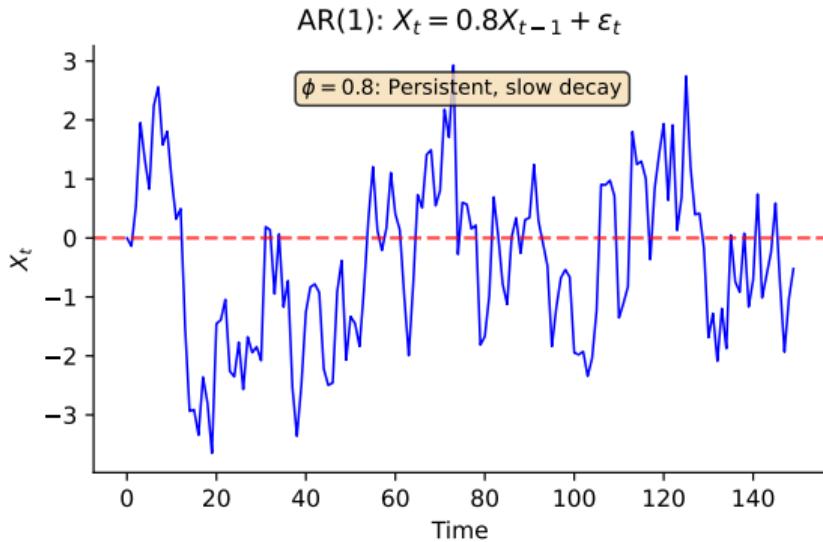
Test 2: Soluție

Răspuns: $C - \phi = -0.8$ (Staționar)



Staționaritate AR(1): $|\phi| < 1$ (rădăcina în afara cercului unitate). Doar C satisface: $|-0.8| = 0.8 < 1$

Vizual: Comportamentul Procesului AR(1)



ϕ pozitiv: modele persistente, netede. ϕ negativ: comportament oscilant în jurul mediei.

Întrebare

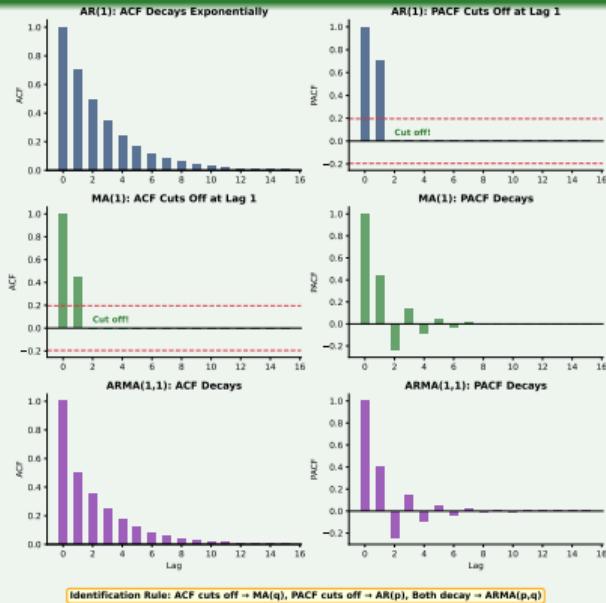
Observați următorul model ACF: vârf semnificativ la lag 1, apoi toate celelalte lag-uri sunt în interiorul benzilor de încredere. PACF arată descreștere graduală. Ce model este sugerat?

- A. AR(1)
- B. MA(1)
- C. ARMA(1,1)
- D. Zgomot alb

Răspunsul pe slide-ul următor...


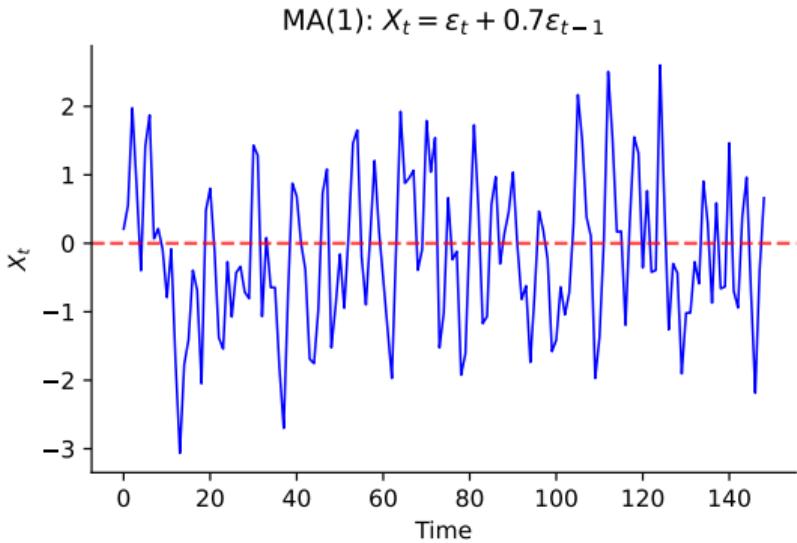
Test 3: Soluție

Răspuns: B – MA(1)



Model: ACF se întrerupe după lag 1 \Rightarrow MA(1); PACF descrește \Rightarrow confirmă structura MA (nu AR)

Vizual: Procesul MA(1) și ACF



Procesul MA(1) (stânga). Semnătura cheie: ACF se întrerupe brusc după lag 1 (dreapta).

Întrebare

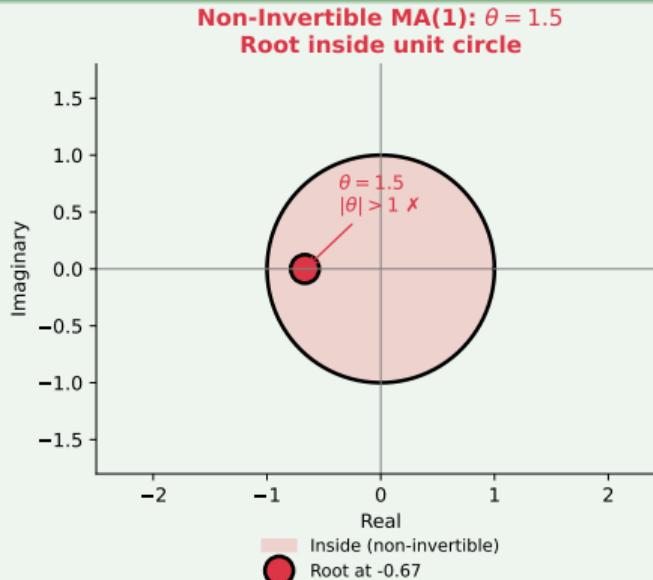
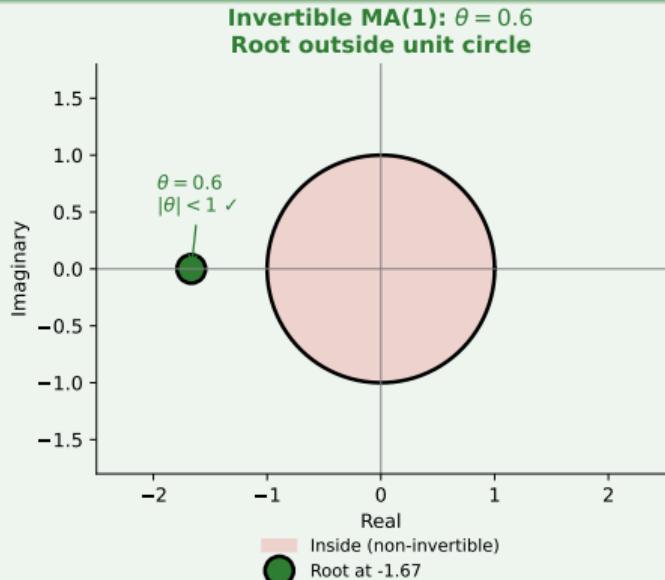
Pentru procesul MA(1) $X_t = \varepsilon_t + 1.5\varepsilon_{t-1}$, este procesul invertibil?

- A. Da, deoarece procesele MA sunt întotdeauna invertibile
- B. Da, deoarece $1.5 > 0$
- C. Nu, deoarece $|\theta| = 1.5 > 1$
- D. Nu, deoarece procesele MA nu sunt niciodată invertibile

Răspunsul pe slide-ul următor...

Test 4: Soluție


Răspuns: C – Nu este invertibil ($|\theta| = 1.5 > 1$)



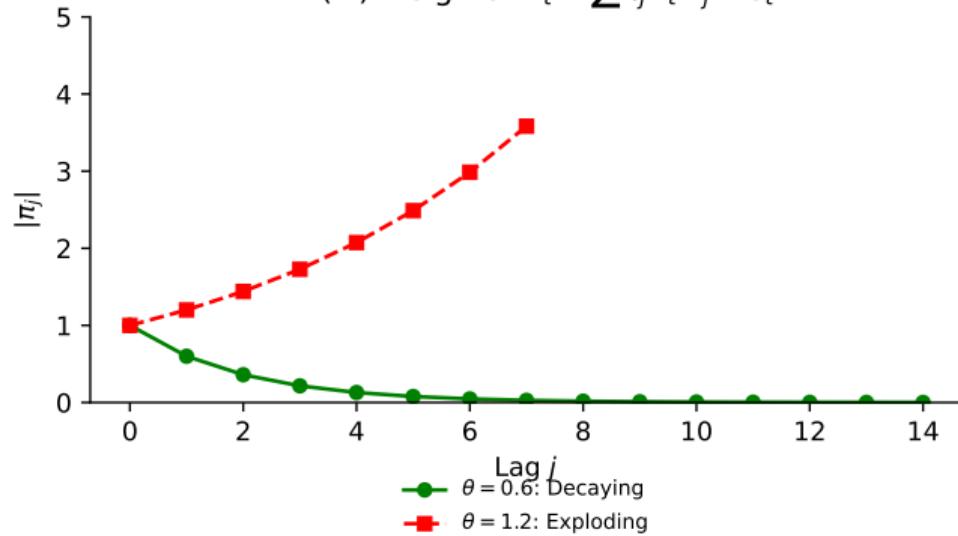
Invertibilitate MA: Rădăcina $z = -1/\theta$ trebuie să fie în afara cercului unitate $\Leftrightarrow |\theta| < 1$. Aici $z = -0.67$ este în interior!

Vizual: Conceptul de Invertibilitate

Invertibility: Root outside unit circle



AR(∞) weights: $X_t = \sum \pi_j X_{t-j} + \varepsilon_t$



Stânga: invertibilitatea necesită rădăcini în afara cercului unitate. Dreapta: ponderile AR(∞) descresc doar când $|\theta| < 1$.

Întrebare

Forma compactă $\phi(L)X_t = \theta(L)\varepsilon_t$ reprezintă ce model?

- A. Model AR pur
- B. Model MA pur
- C. Model ARMA
- D. Niciunul dintre cele de mai sus

Răspunsul pe slide-ul următor...

Test 5: Soluție

Răspuns: C – Model ARMA

- $\phi(L) = 1 - \phi_1L - \cdots - \phi_pL^p$ este polinomul AR
- $\theta(L) = 1 + \theta_1L + \cdots + \theta_qL^q$ este polinomul MA

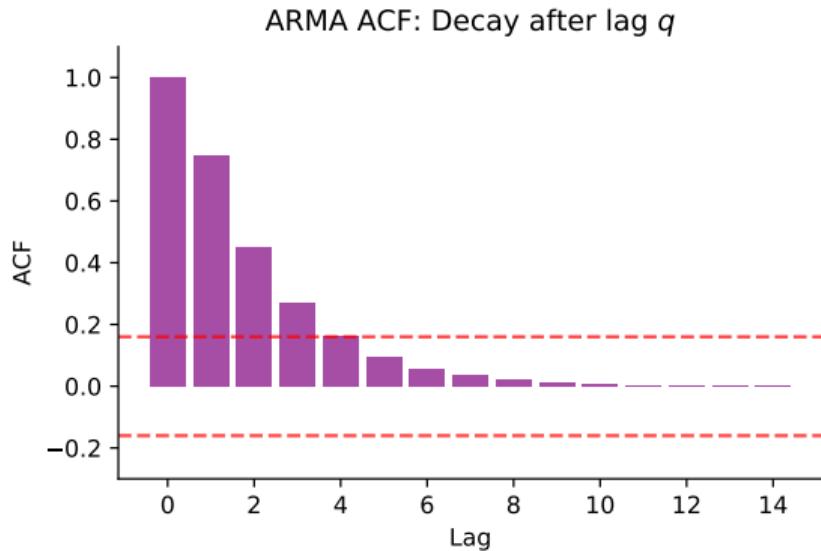
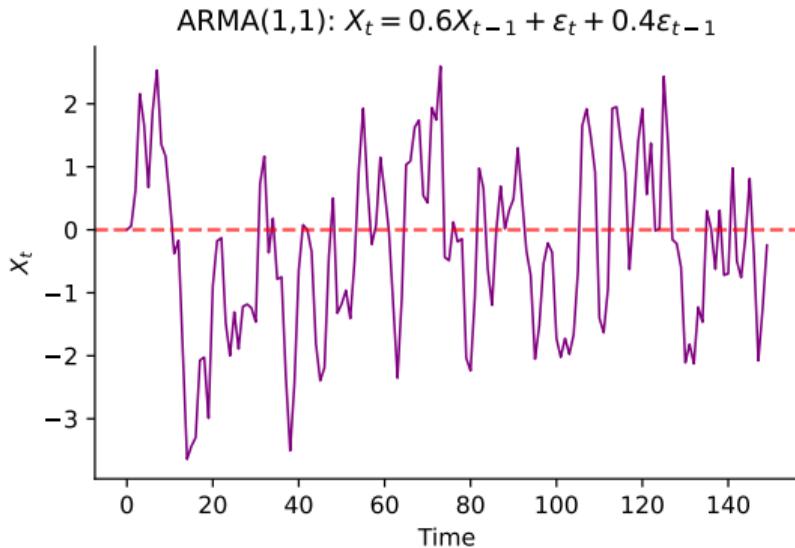
Ecuatia $\phi(L)X_t = \theta(L)\varepsilon_t$ se expandeaza la:

$$X_t - \phi_1X_{t-1} - \cdots - \phi_pX_{t-p} = \varepsilon_t + \theta_1\varepsilon_{t-1} + \cdots + \theta_q\varepsilon_{t-q}$$

Acesta este modelul general **ARMA(p,q)**.

Cazuri speciale: $\theta(L) = 1$ (fără MA): AR pur; $\phi(L) = 1$ (fără AR): MA pur

Vizual: Procesul ARMA



ARMA(1,1) combină componente AR și MA. ACF arată descreștere după lag-ul inițial.

Întrebare


Când comparăm ARMA(1,1) și ARMA(2,1) folosind BIC, care afirmație este corectă?

- A. BIC mai mic înseamnă întotdeauna prognoze mai bune
- B. BIC penalizează complexitatea mai puțin decât AIC
- C. Modelul cu BIC mai mic este preferat
- D. BIC poate compara doar modele cu același număr de parametri

Răspunsul pe slide-ul următor...

Test 6: Soluție

Răspuns: C – BIC mai mic este preferat



AIC: $-2 \ln(\hat{L}) + 2k$ **BIC:** $-2 \ln(\hat{L}) + k \ln(n)$ BIC penalizează complexitatea mai mult \Rightarrow modele mai simple

Întrebare

După ajustarea unui model ARMA(2,1), rulați testul Ljung-Box pe reziduuri și obțineți valoare-p = 0.02. Ce concluzie trageți?

- A. Modelul este adekvat
- B. Reziduurile sunt zgomot alb
- C. Există autocorelație semnificativă în reziduuri
- D. Modelul are prea mulți parametri

Răspunsul pe slide-ul următor...

Test 7: Soluție

Răspuns: C – Există autocorelație semnificativă în reziduuri

Testul Ljung-Box are:

- H_0 : Reziduurile sunt zgomot alb (fără autocorelație)
- H_1 : Reziduurile au autocorelație semnificativă

Cu valoare-p = 0.02 < 0.05:

- **Respingem H_0**
- Concluzie: reziduurile **nu** sunt zgomot alb
- Modelul este **inadecvat** — structură semnificativă rămâne

Pasul următor: Încercați un model diferit (de exemplu, creșteți p sau q)

Test 8: Prognoză

Întrebare

Pentru un model AR(1) cu $\phi = 0.6$ și medie $\mu = 10$, ce se întâmplă cu prognozele când orizontul $h \rightarrow \infty$?

- A. Prognozele cresc fără limită
- B. Prognozele converg la 0
- C. Prognozele converg la $\mu = 10$
- D. Prognozele oscilează pentru totdeauna

Răspunsul pe slide-ul următor...

Test 8: Soluție

Răspuns: C – Prognozele converg la $\mu = 10$

Pentru AR(1), prognoza la h pași înainte este:

$$\hat{X}_{n+h|n} = \mu + \phi^h(X_n - \mu)$$

Deoarece $|\phi| = 0.6 < 1$:

$$\lim_{h \rightarrow \infty} \phi^h = 0$$

Prin urmare:

$$\lim_{h \rightarrow \infty} \hat{X}_{n+h|n} = \mu + 0 \cdot (X_n - \mu) = \mu = 10$$

Observație cheie: Prognozele pe termen lung din modele ARMA staționare converg întotdeauna la media necondiționată.

Test 9: Rădăcinile AR(2)

Întrebare

Un proces AR(2) are rădăcinile caracteristice $z_1 = 0.8$ și $z_2 = -0.5$. Este staționar?

- A. Da, deoarece ambele rădăcini sunt în interiorul cercului unitate
- B. Nu, deoarece o rădăcină este negativă
- C. Nu, deoarece rădăcinile trebuie să fie în afara cercului unitate
- D. Nu se poate determina fără mai multe informații

Răspunsul pe slide-ul următor...

Test 9: Soluție

Răspuns: C – Rădăcinile trebuie să fie în afara cercului unitate

Pentru staționaritatea AR, rădăcinile lui $\phi(z) = 0$ trebuie să fie **în afara** cercului unitate, adică $|z| > 1$.

Aici: $|z_1| = 0.8 < 1$ și $|z_2| = 0.5 < 1$ – ambele **în interior** cercului unitate.

→ **Nestaționar** (de fapt exploziv)

Notă: Condiție echivalentă: coeficienții ϕ_1, ϕ_2 trebuie să satisfacă triunghiul de staționaritate.

Test 10: Proprietățile MA(q)

Întrebare

Pentru un proces MA(2), ACF-ul:

- A. Descrește exponențial
- B. Se întrerupe după lag 2
- C. Se întrerupe după lag 1
- D. Nu se întrerupe niciodată

Răspunsul pe slide-ul următor...

Test 10: Soluție

Răspuns: B – Se întrerupe după lag 2

Pentru $MA(q)$, ACF-ul este exact zero pentru lag-uri $> q$.

- $MA(1)$: ACF se întrerupe după lag 1
- $MA(2)$: ACF se întrerupe după lag 2
- $MA(q)$: ACF se întrerupe după lag q

Aceasta este caracteristica cheie de identificare: întreruperea ACF \Rightarrow ordinul MA.

Între timp, PACF-ul proceselor MA descrește (nu se întrerupe).

Întrebare

De ce ar putea fi preferat ARMA(1,1) față de AR(5) chiar dacă ambele se potrivesc la fel de bine?

- A. Modelele ARMA sunt întotdeauna mai bune
- B. Mai puțini parametri reduc riscul de supraajustare
- C. Modelele AR nu pot captura trenduri
- D. Componentele MA sunt mai stabile

Răspunsul pe slide-ul următor...

Test 11: Soluție

Răspuns: B – Mai puțini parametri reduc riscul de supraajustare

Principiul parsimoniei: preferați modele mai simple.

- ARMA(1,1): 2 parametri (ϕ_1, θ_1)
- AR(5): 5 parametri (ϕ_1, \dots, ϕ_5)

Mai puțini parametri înseamnă:

- Risc mai mic de supraajustare
- Prognoze mai bune în afara eșantionului
- Model mai interpretabil

BIC penalizează complexitatea mai mult decât AIC, selectând adesea modele mai simple.

Întrebare

După ajustarea unui model ARMA, ACF-ul reziduurilor arată un vârf semnificativ la lag 5. Aceasta sugerează:

- A. Modelul este adecvat
- B. Modelul ar putea avea nevoie de termeni de ordin mai mare
- C. Reziduurile sunt zgomot alb
- D. Datele sunt nestaționare

Răspunsul pe slide-ul următor...

Răspuns: B – Modelul ar putea avea nevoie de termeni de ordin mai mare

Reziduurile bune ar trebui să fie zgomot alb fără ACF semnificativ.

Un vârf semnificativ la lag 5 indică structură de autocorelație rămasă necaptată de model.

Acțiuni:

- Luați în considerare adăugarea termenilor AR sau MA
- Verificați dacă componenta AR(5) sau MA(5) ajută
- Rulați din nou testul Ljung-Box după modificare

Întrebare

Teorema descompunerii Wold afirmă că orice proces staționar poate fi scris ca:

- A. Un proces AR finit
- B. Un proces MA finit
- C. Un proces MA infinit plus o componentă deterministă
- D. Un proces ARIMA

Răspunsul pe slide-ul următor...

Test 13: Soluție

Răspuns: C – Un proces MA infinit plus o componentă deterministă

Teorema lui Wold: Orice proces staționar poate fi scris ca:

$$X_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + \eta_t$$

unde η_t este deterministic și $\sum \psi_j^2 < \infty$.

Implicatie: MA(∞) este reprezentarea cea mai generală. Modelele ARMA sunt aproximări eficiente ale acestui MA infinit.

Întrebare

Cum faceți un proces cu rădăcină unitară să devină staționar?

- A. Scădeți un trend liniar
- B. Luați diferențe de ordinul întâi
- C. Aplicați media mobilă
- D. Folosiți ajustare sezonieră

Răspunsul pe slide-ul următor...

Răspuns: B – Luați diferențe de ordinul întâi

- Rădăcină unitară (trend stochastic): Folosiți diferențierea
- Trend staționar (trend determinist): Folosiți regresia pentru eliminarea trendului

Pentru mersul aleatoriu $X_t = X_{t-1} + \varepsilon_t$:

$$\Delta X_t = X_t - X_{t-1} = \varepsilon_t$$

care este zgomot alb staționar.

Întrebare

Determinați dacă fiecare afirmație este Adevărată sau Falsă:

- ① Un proces AR(2) poate prezenta comportament pseudo-ciclic.
- ② Procesele MA necesită o condiție de staționaritate.
- ③ PACF-ul unui proces AR(p) se întrerupe după lag p .
- ④ Dacă AIC selectează ARMA(2,1) și BIC selectează ARMA(1,1), nu pot fi ambele corecte.
- ⑤ Intervalele de încredere ale prognozei se îngustează pe măsură ce orizontul de prognoză crește.
- ⑥ Ecuațiile Yule-Walker pot fi folosite pentru a estima parametrii MA.

Răspunsul pe slide-ul următor...

Răspunsuri

- ① **ADEVĂRAT**: AR(2) cu rădăcini complexe arată oscilații amortizate
- ② **FALS**: Procesele MA sunt întotdeauna staționare; au nevoie de condiția de *invertibilitate*
- ③ **ADEVĂRAT**: Aceasta este caracteristica cheie de identificare a AR(p)
- ④ **FALS**: Ambele pot fi „corecte” — optimizează criterii diferite (AIC favorizează potrivirea, BIC favorizează parsimonia)
- ⑤ **FALS**: Intervalele de încredere se *lărgesc* pe măsură ce orizontul crește (mai multă incertitudine)
- ⑥ **FALS**: Yule-Walker este doar pentru modele AR; MA folosește MLE

Exercițiu 1: Proprietățile AR(1)

Problemă: Considerați procesul AR(1):

$$X_t = 2 + 0.7X_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim WN(0, 9)$$

Calculați:

- ① Media μ
- ② Varianța $\gamma(0)$
- ③ Autocovarianța $\gamma(1)$ și $\gamma(2)$
- ④ Autocorelația $\rho(1)$ și $\rho(2)$

Exercițiu 1: Soluție

Dat: $c = 2$, $\phi = 0.7$, $\sigma^2 = 9$

1. Media:

$$\mu = \frac{c}{1 - \phi} = \frac{2}{1 - 0.7} = \frac{2}{0.3} = 6.67$$

2. Varianță:

$$\gamma(0) = \frac{\sigma^2}{1 - \phi^2} = \frac{9}{1 - 0.49} = \frac{9}{0.51} = 17.65$$

3. Autocovarianță:

$$\gamma(1) = \phi \cdot \gamma(0) = 0.7 \times 17.65 = 12.35$$

$$\gamma(2) = \phi^2 \cdot \gamma(0) = 0.49 \times 17.65 = 8.65$$

4. Autocorelația:

$$\rho(1) = \phi = 0.7, \quad \rho(2) = \phi^2 = 0.49$$

Exercițiu 2: Proprietățile MA(1)

Problemă: Considerați procesul MA(1):

$$X_t = 5 + \varepsilon_t - 0.4\varepsilon_{t-1}, \quad \varepsilon_t \sim WN(0, 4)$$

Calculați:

- ① Media μ
- ② Varianța $\gamma(0)$
- ③ Autocovarianța $\gamma(1)$
- ④ Autocorelația $\rho(1)$
- ⑤ Este acest proces invertibil?

Exercițiu 2: Soluție

Dat: $\mu = 5$, $\theta = -0.4$, $\sigma^2 = 4$

1. Media:

$$\mathbb{E}[X_t] = \mu = 5$$

2. Varianță:

$$\gamma(0) = \sigma^2(1 + \theta^2) = 4(1 + 0.16) = 4 \times 1.16 = 4.64$$

3. Autocovarianța la lag 1:

$$\gamma(1) = \theta\sigma^2 = -0.4 \times 4 = -1.6$$

4. Autocorelația:

$$\rho(1) = \frac{\gamma(1)}{\gamma(0)} = \frac{-1.6}{4.64} = -0.345$$

5. Invertibilitate: $|\theta| = 0.4 < 1 \rightarrow$ **Da, invertibil**

Exercițiu 3: Rădăcinile Caracteristice

Problemă: Considerați procesul AR(2):

$$X_t = 0.5X_{t-1} + 0.3X_{t-2} + \varepsilon_t$$

- ① Scrieți ecuația caracteristică
- ② Găsiți rădăcinile caracteristice
- ③ Este acest proces staționar?

Exercițiu 3: Soluție

1. Ecuatia caracteristică:

$$\phi(z) = 1 - \phi_1 z - \phi_2 z^2 = 1 - 0.5z - 0.3z^2 = 0$$

Sau: $0.3z^2 + 0.5z - 1 = 0$

2. Rădăcinile (folosind formula quadratică):

$$z = \frac{-0.5 \pm \sqrt{0.25 + 1.2}}{0.6} = \frac{-0.5 \pm 1.204}{0.6}$$

$$z_1 = \frac{0.704}{0.6} = 1.17, \quad z_2 = \frac{-1.704}{0.6} = -2.84$$

3. Verificarea staționarității:

Ambele rădăcini au $|z| > 1$: $|z_1| = 1.17 > 1$ și $|z_2| = 2.84 > 1$

→ **Staționar** (rădăcini în afara cercului unitate)

Exercițiu 4: Prognoză

Problemă: Ați ajustat un model AR(1):

$$X_t = 3 + 0.8X_{t-1} + \varepsilon_t, \quad \sigma^2 = 4$$

Dat $X_{100} = 20$, calculați:

- ① Prognoza la 1 pas înainte $\hat{X}_{101|100}$
- ② Prognoza la 2 pași înainte $\hat{X}_{102|100}$
- ③ Prognoza pe termen lung $\hat{X}_{100+h|100}$ când $h \rightarrow \infty$
- ④ Intervalul de încredere de 95% pentru $\hat{X}_{101|100}$

Exercițiu 4: Soluție

Dat: $c = 3$, $\phi = 0.8$, $\sigma^2 = 4$, $X_{100} = 20$

Media: $\mu = \frac{3}{1-0.8} = 15$

1. Prognoza la un pas:

$$\hat{X}_{101|100} = c + \phi X_{100} = 3 + 0.8 \times 20 = 19$$

2. Prognoza la doi pași:

$$\hat{X}_{102|100} = c + \phi \hat{X}_{101|100} = 3 + 0.8 \times 19 = 18.2$$

3. Prognoza pe termen lung:

$$\lim_{h \rightarrow \infty} \hat{X}_{100+h|100} = \mu = 15$$

4. IC 95% pentru 1 pas:

$$\text{MSFE}(1) = \sigma^2 = 4, \quad \sqrt{\text{MSFE}(1)} = 2$$

$$IC : 19 \pm 1.96 \times 2 = [15.08, 22.92]$$

Exercițiu Python 1: Simulare și Ajustare AR(1)

Sarcină:

- ① Simulați 500 de observații dintr-un AR(1) cu $\phi = 0.7$
- ② Reprezentați grafic seria și ACF/PACF
- ③ Ajustați un model AR(1) și verificați dacă $\hat{\phi} \approx 0.7$
- ④ Examinați diagnosticele reziduurilor

Cod indiciu:

```
np.random.seed(42)
n = 500
phi = 0.7
x = np.zeros(n)
for t in range(1, n):
    x[t] = phi * x[t-1] + np.random.randn()
```

Exercițiu Python 2: Selectarea Modelului

Sarcină:

- ① Încărcați o serie de timp reală (de exemplu, randamente de acțiuni)
- ② Verificați staționaritatea folosind testul ADF
- ③ Comparați AIC/BIC pentru ARMA(1,0), ARMA(0,1), ARMA(1,1), ARMA(2,1)
- ④ Selectați cel mai bun model
- ⑤ Generați prognoze cu intervale de încredere

Funcții cheie:

- `adfuller()` pentru testul de staționaritate
- `ARIMA(data, order=(p,0,q)).fit()` pentru ajustare
- `results.aic, results.bic` pentru criterii
- `results.get_forecast(h)` pentru predicții

Exercițiu Python 3: Verificarea Diagnosticelor

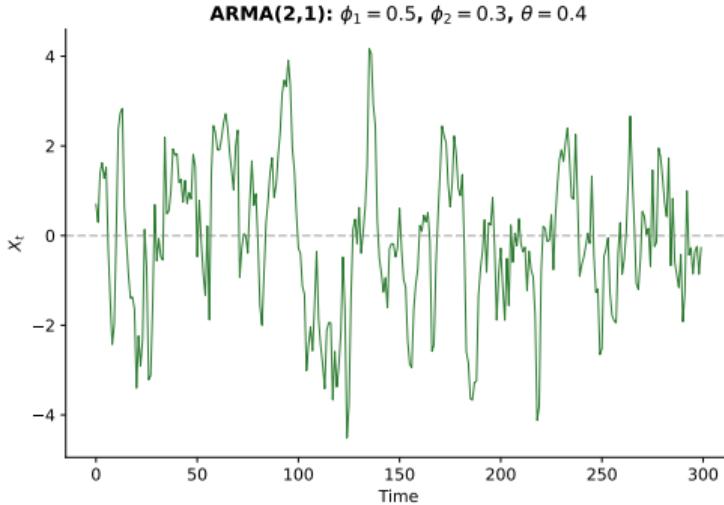
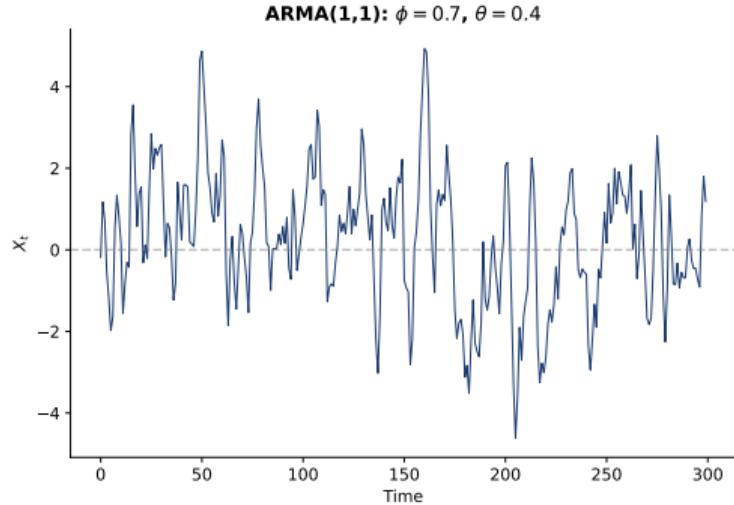
Sarcină: După ajustarea unui model, efectuați diagnostice complete:

- ① Reprezentați grafic reziduurile în timp
- ② Reprezentați grafic ACF-ul reziduurilor
- ③ Creați graficul Q-Q
- ④ Rulați testul Ljung-Box
- ⑤ Verificați dacă rădăcinile AR/MA sunt în afara cercului unitate

Funcții cheie:

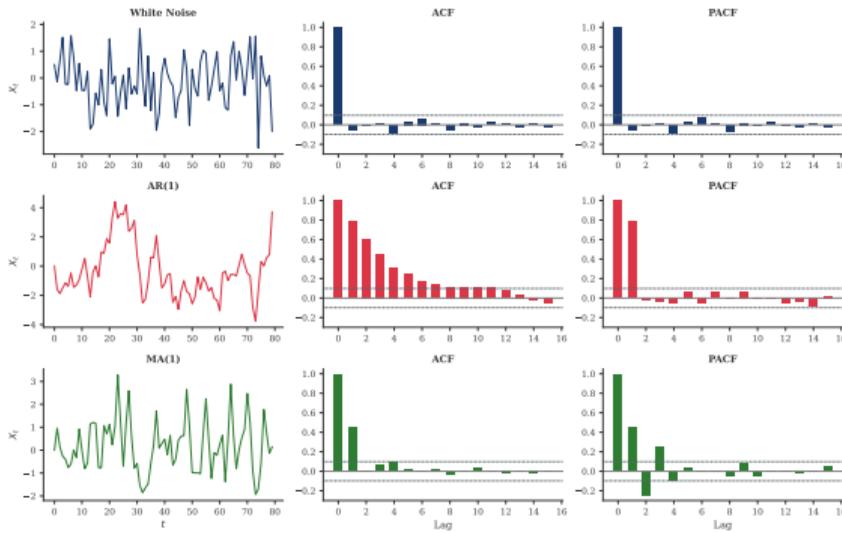
- `results.resid` pentru reziduuri
- `plot_acf(resid)` pentru graficul ACF
- `stats.probplot(resid)` pentru graficul Q-Q
- `acorr_ljungbox(resid)` pentru testul portmanteau
- `results.arroots, results.maroots` pentru rădăcini

Studiu de Caz: Indicele Producției Industriale



- Producția industrială SUA: date lunare, deja staționare (rate de creștere)
- Arată modele ARMA tipice: revenire la medie cu dependență pe termen scurt
- Gruparea volatilității vizibilă – ARMA captează media condiționată
- Potrivit pentru modelarea ARMA fără diferențiere

Recunoașterea Modelului ACF/PACF



- ACF arată descreștere graduală – sugerează componentă AR
- PACF se întrerupe după lag 2 – sugerează că AR(2) ar putea fi potrivit
- Unele lag-uri semnificative în ACF dincolo de lag 2 – termenii MA ar putea ajuta
- Model consistent cu ARMA(2,1) sau modele similare de ordin mic

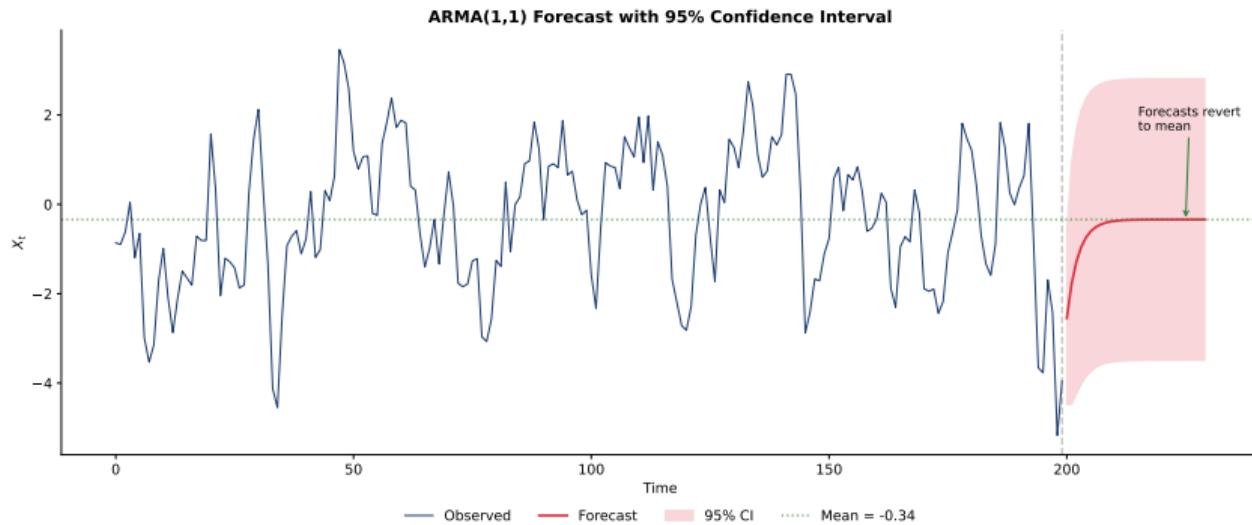
Model: ARMA(2,1) pentru Creșterea Producției Industriale

Parametru	Estimat	Eroare Std.	z-stat	valoare-p
c (const)	0.156	0.048	3.25	0.001
ϕ_1 (AR.L1)	0.423	0.089	4.75	< 0.001
ϕ_2 (AR.L2)	0.187	0.072	2.60	0.009
θ_1 (MA.L1)	-0.156	0.091	-1.71	0.087

Selecția Modelului

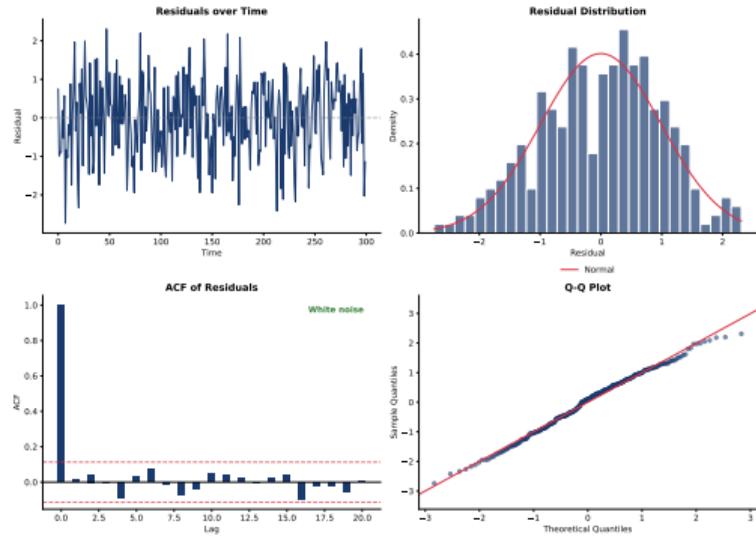
AIC: -412.5, BIC: -398.2. Modelul trece verificările de staționaritate și invertibilitate.

Performanța Prognozei



- Prognozele ARMA revin la media necondiționată
- Prognozele pe termen scurt captează dinamica recentă
- Intervalele de încredere se extind cu orizontul de prognoză
- Comparația cu prognoza naivă arată îmbunătățirea ARMA

Diagnosticile Modelului



- Reziduurile par aleatoare fără modele sistematice
- ACF-ul reziduurilor în limitele de încredere
- Graficul Q-Q arată normalitate aproximativă
- Testul Ljung-Box: $p > 0.05$ – fără autocorelație semnificativă în reziduuri

Discuție 1: Selecția Modelului

Scenariu: Modelați rate de inflație lunare. După verificarea staționarității (trecută), găsiți:

- ACF: semnificativ la lagurile 1, 2, 3, apoi descrește
- PACF: semnificativ la lagurile 1, 2, apoi se întrerupe
- AIC selectează ARMA(2,3)
- BIC selectează ARMA(2,0) = AR(2)

Întrebări:

- ① Ce sugerează modelul ACF/PACF?
- ② De ce nu sunt de acord AIC și BIC?
- ③ Ce model ați alege și de ce?
- ④ Ce verificări suplimentare ați efectua?

Discuție 2: Evaluarea Prognozei

Scenariu: Ajustați un model ARMA(1,1) pe randamente zilnice de acțiuni. Ajustarea în eșantion arată bine (valoare-p Ljung-Box = 0.45), dar RMSE în afara eșantionului este mai rău decât o prognoză simplă de mers aleatoriu.

Întrebări:

- ① Este aceasta surprinzător? De ce sau de ce nu?
- ② Ce ne spune aceasta despre predictibilitatea randamentelor de acțiuni?
- ③ Ar trebui să concluzionați că modelul ARMA este inutil?
- ④ Ce alternative ati putea considera?

Indiciu: Gândiți-vă la Ipoteza Pieței Eficiente și la ce captează ARMA vs ce nu captează (de exemplu, gruparea volatilității).

Discuție 3: Aplicație în Lumea Reală

Scenariu: Un economist de la banca centrală vă cere să prognozați creșterea trimestrială a PIB-ului pentru planificarea politicii.

Întrebări:

- ① Ce analiză preliminară ați face înainte de a ajusta ARMA?
- ② PIB-ul este adesea nestaționar — cum ați gestionat aceasta?
- ③ Ați folosit AIC sau BIC pentru selecția modelului? De ce?
- ④ Cum ați comunicat incertitudinea prognozei factorilor de decizie?
- ⑤ Ce limitări ale modelelor ARMA ar trebui să menționați?

Concluzii Cheie din Seminarul de Astăzi

1 Modele AR: Valoarea curentă depinde de valorile trecute

- Staționaritate: $|\phi| < 1$ pentru AR(1)
- PACF se întrerupe la lag p

2 Modele MA: Valoarea curentă depinde de șocurile trecute

- Întotdeauna staționare; invertibilitate: $|\theta| < 1$ pentru MA(1)
- ACF se întrerupe la lag q

3 Selectia modelului: Folosiți modelele ACF/PACF + criterii informaționale

4 Diagnostice: Reziduurile trebuie să fie zgomot alb (testul Ljung-Box)

5 Prognoză: Prognozele punctuale converg la medie; incertitudinea crește

Următorul Seminar: ARIMA și Modele Sezoniere

Referințe

-  Box, G.E.P., Jenkins, G.M., Reinsel, G.C., & Ljung, G.M. (2015). *Time Series Analysis: Forecasting and Control*. 5th ed., Wiley.
-  Hamilton, J.D. (1994). *Time Series Analysis*. Princeton University Press.
-  Hyndman, R.J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. 3rd ed., OTexts.
-  Brockwell, P.J., & Davis, R.A. (2016). *Introduction to Time Series and Forecasting*. 3rd ed., Springer.

Instrumente Software:

- statsmodels – Modele ARIMA pentru Python
- pmdarima – Selecție automată ARIMA
- pandas – Manipulare date serii de timp
- matplotlib – Vizualizare

Date și Exemple:

- Procese AR, MA și ARMA simulate
- Exemple bazate pe Hyndman & Athanasopoulos (2021)

Vă mulțumesc!

Întrebări?