



Analiza și Prognoză Seriilor de Timp

## Capitolul 4: Modele SARIMA


Serii de Timp Sezoniere



# Cuprins


- 1 Sezonalitatea în seriile de timp
- 2 Diferențierea sezonieră
- 3 Modelul SARIMA
- 4 Tipare ACF și PACF sezoniere
- 5 Estimare și diagnosticare
- 6 Prognoză cu SARIMA
- 7 Aplicație pe date reale: Pasageri companiilor aeriene
- 8 Studiu de caz: Pasageri aerieni
- 9 Sumar

## Exemplu motivational: Sezonalitatea este peste tot





- Vânzările cu amănuntul prezintă **tipare anuale clare**: vârfuri în decembrie, minime în ianuarie
- Modelele ARIMA standard nu pot captura aceste **cicluri sezoniere repetitive**
- Ignorarea sezonalității duce la erori sistematice de prognoză

# Înțelegerea componentelor sezoniere



- Serie de timp sezonieră = **Trend + Tipar sezonier + Reziduuri**
- Descompunerea ajută la vizualizarea separată a fiecărei componente
- Modelele SARIMA captează atât dinamică trendului, cât și comportamentul sezonier


## Understanding Seasonal Patterns



- Cererea de energie prezintă o **sezonalitate lunară puternică** (cycluri de încălzire/răcire)
- Tiparul se repetă previzibil în fiecare an cu mici variații
- Companiile de utilități folosesc prognozele SARIMA pentru planificarea capacitatii

# De ce avem nevoie de SARIMA?

## Why ARIMA Is Not Enough for Seasonal Data



- Stânga: ACF sezonieră prezintă vârfuri la lag-urile 12, 24, 36... (tipar anual)
- Dreapta: Reziduurile ARIMA încă prezintă autocorelație sezonieră — modelul este incomplet
- SARIMA adaugă termeni AR și MA sezonieri pentru a captura aceste tipare

# Ce vom învăța astăzi

## Concepțe

- Identificarea tiparelor sezoniere
- Operatorul de diferențiere sezonieră
- Notația SARIMA( $p, d, q$ )( $P, D, Q$ ) $_s$
- Celebrul "Model Airline"
- Selecția modelului pentru date sezoniere

## Abilități

- Diagnosticarea sezonalității din ACF/PACF
- Determinarea perioadei sezoniere  $s$
- Alegerea ordinelor sezoniere ( $P, D, Q$ )
- Implementarea SARIMA în Python/R
- Prognoză seriilor de timp sezoniere

## Ideeă cheie

SARIMA = ARIMA aplicată la **două frecvențe**: nivelul obișnuit (pe termen scurt) și cel sezonier (pe termen lung)

# Ce este sezonalitatea?


## Definitie 1 (Sezonalitate)

O serie de timp prezintă **sezonalitate** când arată fluctuații regulate, periodice care se repetă pe o perioadă fixă  $s$  (perioadă sezonieră).

## Perioade sezoniere comune

- Date lunare:  $s = 12$  (ciclu anual)
- Date trimestriale:  $s = 4$  (ciclu anual)
- Date săptămânaile:  $s = 52$  (anual) sau  $s = 7$  (tipar săptămânal)
- Date zilnice:  $s = 7$  (tipar săptămânal)

## Sezonalitatea: Ilustrare vizuala



### Perioade Sezoniere

Stânga: Date lunare cu  $s = 12$  (ciclul anual). Dreapta: Date trimestriale cu  $s = 4$ . Tiparul se repetă la fiecare  $s$  perioade — această regularitate este exploatață de modelele SARIMA.

## Exemple de date sezoniere

### Serii economice

- Vânzări cu amânuntul (vârfuri de sărbători)
- Turism (vara/iarna)
- Producție agricolă
- Consum de energie
- Ocuparea forței de muncă (cicluri de angajare)

### Alte domenii

- Vreme/temperatura
- Trafic pe site-uri web
- Admisiuni la spital
- Utilizarea transportului
- Cererea de electricitate

### De ce contează


Ignorarea sezonărilor duce la prognoze distorsionate și inferență invalidă!

## Exemplu: Datele privind pasagerii companiilor aeriene



- Pasageri internaționali lunari ai companiilor aeriene (1949–1960)
- **Trend ascendent** clar și **amplitudine sezonieră crescătoare**
- Vârfurile din vara reflectă tiparele călătoriilor de vacanță

## Vizualizarea tiparelor sezoniere



- Diagrama box plot relevă un tipar sezonier consistent de-a lungul anilor
- Iulie–August prezintă cele mai mari numere de pasageri (călătorii de vară)
- Noiembrie–Februarie prezintă cele mai mici numere (lunile de iarnă)

## Sezonalitate deterministă vs stochastică

### Sezonalitate deterministă

Tipar sezonier fix:  $Y_t = \sum_{j=1}^s \gamma_j D_{jt} + \varepsilon_t$  unde  $D_{jt}$  sunt variabile dummy sezoniere.

#### Proprietăți:

- Tiparul constant în timp
- Eliminat prin regresie

### Sezonalitate stochastică

Tipar sezonier în evoluție:  $\Delta_s Y_t = Y_t - Y_{t-s}$  prezintă structura de dependență.

#### Proprietăți:

- Tiparul evoluează în timp
- Necesită diferențiere sezonieră

# Detectarea sezonalității

## Metode vizuale

- Graficul seriei de timp – căutați tipare repetitive
- Graficul sub-seriilor sezoniere – comparați aceleași sezoane de-a lungul anilor
- Graficul ACF – vârfuri la lag-uri sezoniere ( $s, 2s, 3s, \dots$ )


## Teste statistice

- Teste de rădăcină unitară sezonieră (HEGY, CH, OCSB)
- Testul F pentru variabile dummy sezoniere
- Testul Kruskal-Wallis (neparametric)

## Semnatura ACF

Sezonalitate puternică: ACF prezintă vârfuri semnificative la lagurile  $s, 2s, 3s, \dots$

## ACF relevă structura sezonieră



- Descreștere lentă la toate lag-urile indică nestaționaritate (trend)
- Vârfuri la lag-urile 12, 24, 36 confirmă tiparul sezonier ( $s = 12$ )
- ACF la lag-urile sezoniere prezintă descreștere lentă  $\Rightarrow$  necesită diferențiere sezonieră

## Testul F pentru variabile dummy sezoniere: Intuiție

### Ce face acest test?

Testează dacă **valorile medii diferă semnificativ între sezoane**.

- Dacă media din ianuarie  $\neq$  media din februarie  $\neq \dots \neq$  media din decembrie  $\Rightarrow$  sezonitate
- Compară un model CU variabile dummy sezoniere vs. un model FARA

### Modelele comparate

**Restricționat:**  $Y_t = \alpha + \varepsilon_t$     **Nerestricționat:**  $Y_t = \alpha + \sum_{j=1}^{s-1} \gamma_j D_{jt} + \varepsilon_t$   
unde  $D_{jt} = 1$  dacă observația  $t$  este în sezonul  $j$ , 0 altfel.

### Ideea cheie

Dacă adăugarea variabilelor dummy sezoniere **reduce semnificativ** erorile de predicție, atunci sezonitatea este prezentă.

## Testul F pentru variabile dummy sezoniere: Formula și exemplu

### Formula statisticii F

$$F = \frac{(SSR_R - SSR_U)/(s - 1)}{SSR_U/(n - s)} \sim F_{s-1, n-s}$$

- $SSR_R$  = Suma pătratelor reziduurilor din modelul restricționat (fără dummy)
- $SSR_U$  = Suma pătratelor reziduurilor din modelul nerestricționat (cu dummy)
- $s - 1$  = numărul de restricții (lunar: 11, trimestrial: 3)

### Exemplu numeric (Date lunare, n=120)

$SSR_R = 15000$ ,  $SSR_U = 8500$ ,  $s = 12$

$$F = \frac{(15000 - 8500)/11}{8500/108} = \frac{590.9}{78.7} = 7.51$$

Valoarea critică  $F_{0.05, 11, 108} \approx 1.87$ . Deoarece  $7.51 > 1.87$ : **Respingem  $H_0$  ⇒ Sezonalitate prezentă!**

# Testul Kruskal-Wallis: Intuiție

## Ce face acest test?

Un test **neparametric** care verifică dacă observațiile din diferite sezoane provin din aceeași distribuție.

- Funcționează prin **ordonarea** tuturor observațiilor de la cea mai mică la cea mai mare
- Verifică dacă rangurile sunt distribuite uniform între sezoane
- Dacă un sezon are în mod constant ranguri mai mari/mici  $\Rightarrow$  sezonalitate

## De ce să-l folosim în locul testului F?

- **Fără ipoteza de normalitate** – funcționează cu orice distribuție
- **Robust la valori extreme** – valorile extreme nu distorsionează rezultatele

## Limitare

Mai puțin puternic decât testul F când datele SUNT distribuite normal.

# Testul Kruskal-Wallis: Formula și exemplu

## Statistică de test

$$H = \frac{12}{N(N+1)} \sum_{j=1}^s \frac{R_j^2}{n_j} - 3(N+1) \quad \text{unde } N = \text{total obs.}, n_j = \text{obs. în sezonul } j, R_j = \text{suma rangurilor.}$$

## Exemplu: Vânzări trimestriale (n=20, s=4)

Date ordonate 1-20. Sumele rangurilor: T1:  $R_1 = 15$ , T2:  $R_2 = 35$ , T3:  $R_3 = 70$ , T4:  $R_4 = 90$

$$H = \frac{12}{20 \times 21} \left( \frac{15^2}{5} + \frac{35^2}{5} + \frac{70^2}{5} + \frac{90^2}{5} \right) - 3(21) = 12.6$$

Valoarea critică  $\chi^2_{0.05, 3} = 7.81$ . Deoarece  $12.6 > 7.81$ : **Respingem  $H_0 \Rightarrow$  Sezonalitate!**

## In Python

```
scipy.stats.kruskal(q1, q2, q3, q4)
```

## Testul HEGY: Ce problemă rezolvă?

### Întrebarea cheie

Având o serie de timp sezonieră, trebuie să știm:

- ➊ Are nevoie de **diferențiere obișnuită** ( $1 - L$ )?  $\Rightarrow$  setam  $d = 1$
- ➋ Are nevoie de **diferențiere sezonieră** ( $1 - L^s$ )?  $\Rightarrow$  setam  $D = 1$

HEGY testează pentru **ambele** tipuri de rădăcini unitare simultan!

### De ce să nu folosim doar ADF?

ADF testează doar pentru o rădăcină unitară **obișnuită** la frecvența zero. Datele sezoniere pot avea rădăcini unitare la **frecvențe sezoniere** pe care ADF le omite!

### HEGY testează frecvențe multiple

Trimestrial: testează la  $0, \pi, \pm\pi/2$ . Lunar: testează la  $0, \pi, \pm\pi/6, \pm\pi/3, \pm\pi/2, \pm2\pi/3, \pm5\pi/6$ .

# Testul HEGY: Formula de regresie (Trimestrial)

## Regresia auxiliara HEGY

Pentru date trimestriale ( $s = 4$ ), estimam:

$$\Delta_4 y_t = \pi_1 z_{1,t-1} + \pi_2 z_{2,t-1} + \pi_3 z_{3,t-2} + \pi_4 z_{4,t-2} + \sum_{j=1}^k \phi_j \Delta_4 y_{t-j} + \varepsilon_t$$

## Variabile transformate

$$z_{1t} = (1 + L + L^2 + L^3)y_t = y_t + y_{t-1} + y_{t-2} + y_{t-3}$$

$$z_{2t} = -(1 - L + L^2 - L^3)y_t = -y_t + y_{t-1} - y_{t-2} + y_{t-3}$$

$$z_{3t} = -(1 - L^2)y_t = -y_t + y_{t-2} ; \quad z_{4t} = -(L - L^3)y_t = -y_{t-1} + y_{t-3}$$

## Ipoteze

$$H_0 : \pi_1 = 0 \text{ (freqv. 0)}, \quad H_0 : \pi_2 = 0 \text{ (freqv. } \pi\text{)}, \quad H_0 : \pi_3 = \pi_4 = 0 \text{ (freqv. } \pm\pi/2\text{)}$$

## Testul HEGY: Reguli de decizie cu exemple

### Valori critice HEGY (5%, n=100, cu constanta)

| Test                         | Statistică | Valoare critică | Dacă NU este respins... |
|------------------------------|------------|-----------------|-------------------------|
| $t_1 (\pi_1 = 0)$            | t-stat     | -2.88           | Necesită $d = 1$        |
| $t_2 (\pi_2 = 0)$            | t-stat     | -2.88           | Necesită $D = 1$        |
| $F_{34} (\pi_3 = \pi_4 = 0)$ | F-stat     | 6.57            | Necesită $D = 1$        |

### Exemplu: PIB trimestrial

Sa presupunem ca HEGY da:  $t_1 = -1.52$ ,  $t_2 = -4.21$ ,  $F_{34} = 2.15$

- $t_1 = -1.52 > -2.88$ : Nu putem respinge  $\Rightarrow$  necesită  $d = 1$
- $t_2 = -4.21 < -2.88$ : Respingem  $\Rightarrow$  fără rădăcină unitară la  $\pi$
- $F_{34} = 2.15 < 6.57$ : Nu putem respinge  $\Rightarrow$  necesită  $D = 1$

**Concluzie:** Folosim SARIMA cu  $d = 1, D = 1$

## Testul Canova-Hansen: Opusul testului HEGY

### HEGY vs Canova-Hansen: Ipoteze nule diferite!

|                 | HEGY                              | Canova-Hansen                     |
|-----------------|-----------------------------------|-----------------------------------|
| $H_0$           | Rădăcină unitară sezonieră        | Fără rădăcină unitară sezonieră   |
| $H_1$           | Fără rădăcină unitară sezonieră   | Rădăcină unitară sezonieră        |
| Respingem $H_0$ | Folosim variabile dummy sezoniere | Folosim diferențiere $(1 - L^s)$  |
| Nu respingem    | Folosim diferențiere $(1 - L^s)$  | Folosim variabile dummy sezoniere |

### De ce contează?

- HEGY: "Demonstrați ca NU există rădăcină unitară" (conservator fata de diferențiere)
- CH: "Demonstrați ca EXISTA rădăcină unitară" (conservator fata de variabile dummy)
- Folosiți **ambele** teste pentru concluzii robuste!

## Testul Canova-Hansen: Formula

### Procedura de testare

1. Regresam  $y_t$  pe variabile dummy sezoniere:  $y_t = \sum_{j=1}^s \gamma_j D_{jt} + u_t$
2. Calculam sumele partiale la frecvența sezonieră  $\lambda_i$ :  $S_{it}^{(c)} = \sum_{j=1}^t \hat{u}_j \cos(\lambda_i j)$ ,  $S_{it}^{(s)} = \sum_{j=1}^t \hat{u}_j \sin(\lambda_i j)$

### Statistică de test LM

$$LM_i = \frac{1}{T^2 \hat{\omega}_i} \left[ \sum_{t=1}^T (S_{it}^{(c)})^2 + \sum_{t=1}^T (S_{it}^{(s)})^2 \right]$$

unde  $\hat{\omega}_i$  = estimator consistent al densității spectrale la frecvența  $\lambda_i$ .

### Decizie

Respingem  $H_0$  (staționaritate) dacă  $LM >$  valoare critică  $\Rightarrow$  este necesară diferențierea sezonieră.

## Sumar: Alegerea testului de sezonalitate potrivit

| Test                     | $H_0$                                    | Dacă respingem                             | Cel mai bun pentru                          |
|--------------------------|--|--|---|
| Test F<br>Kruskal-Wallis | Fără sezonalitate<br>Fără dif. sezonieră | Sezonalitate există<br>Sezonalitate există | Date normale<br>Non-normale, valori extreme |
| HEGY                     | Rădăcină unitară există                  | Folosim dummy                              | Determinarea $d, D$                         |
| Canova-Hansen            | Fără rădăcină unitară                    | Folosim $(1 - L^s)$                        | Confirmarea stabilității                    |

### Ideea cheie

Test F/Kruskal-Wallis: "Există sezonalitate?"

HEGY/Canova-Hansen: "Ce tip?" (deterministă vs stochastică)

## Definitie 2 (Diferenta sezonieră)

**Operatorul de diferență sezonieră**  $\Delta_s$  este definit ca:



$$\Delta_s Y_t = (1 - L^s) Y_t = Y_t - Y_{t-s}$$

unde  $L^s Y_t = Y_{t-s}$  este operatorul de lag sezonier.

## Exemple

- Date lunare ( $s = 12$ ):  $\Delta_{12} Y_t = Y_t - Y_{t-12}$   
Compară fiecare lună cu aceeași lună din anul trecut
- Date trimestriale ( $s = 4$ ):  $\Delta_4 Y_t = Y_t - Y_{t-4}$   
Compară fiecare trimestru cu același trimestru din anul trecut

## Diferenta sezonieră: Ilustrare vizuala



### Efectul Diferențierii Sezoniere

Stânga: Seria originală cu tipar sezonier clar. Dreapta: După  $\Delta_{12} = (1 - L^{12})$ , tiparul sezonier este eliminat. Compararea an-la-an elimină efectele sezoniere.

## Demonstrație: Diferențierea Sezonieră Elimină Sezonalitatea Deterministă

**Afirmăție:** Dacă  $Y_t = \mu_t + \varepsilon_t$  unde  $\mu_t = \mu_{t-s}$  (medie periodică), atunci  $\Delta_s Y_t$  elimină media sezonieră.

**Demonstrație:** Fie  $Y_t = \mu_t + \varepsilon_t$  unde  $\mu_t$  are perioadă  $s$ . Aplicăm diferența sezonieră:

$$\begin{aligned}\Delta_s Y_t &= Y_t - Y_{t-s} = (\mu_t + \varepsilon_t) - (\mu_{t-s} + \varepsilon_{t-s}) \\ &= \mu_t - \mu_{t-s} + \varepsilon_t - \varepsilon_{t-s} \\ &= 0 + \varepsilon_t - \varepsilon_{t-s} \quad (\text{deoarece } \mu_t = \mu_{t-s})\end{aligned}$$

**Proprietățile lui**  $\Delta_s Y_t = \varepsilon_t - \varepsilon_{t-s}$ :

- $\mathbb{E}[\Delta_s Y_t] = 0$  (medie constantă)
- $\text{Var}(\Delta_s Y_t) = 2\sigma^2$  (varianță constantă)
- Autocovarianță:  $\gamma(s) = -\sigma^2$ ,  $\gamma(k) = 0$  pentru  $k \neq 0, s$

### Rezultat

Diferențierea sezonieră transformă tiparul sezonier periodic în MA(1) la lag-ul sezonier.

## Combinarea diferențierii obișnuite și sezoniere

### Diferențiere completa

Pentru serii cu atât trend cât și sezonalitate:

$$\Delta\Delta_s Y_t = (1 - L)(1 - L^s)Y_t$$

### Dezvoltare

$$(1 - L)(1 - L^s)Y_t = Y_t - Y_{t-1} - Y_{t-s} + Y_{t-s-1}$$


Pentru date lunare ( $s = 12$ ):

$$\Delta\Delta_{12} Y_t = Y_t - Y_{t-1} - Y_{t-12} + Y_{t-13}$$

### Ordinea diferențierii


- $d$ : numărul de diferențe obișnuite (eliminarea trendului)
- $D$ : numărul de diferențe sezoniere (eliminarea trendului sezonier)

## Efectul operațiilor de diferențiere



- Diferențierea obișnuită elimină trendul dar tiparul sezonier ramane
- Diferențierea sezonieră elimină sezonalitatea dar tiparul de trend ramane
- **Ambele diferențe sunt necesare pentru a atinge staționaritatea**

## ACF înainte și după diferențiere



- ACF originală: descreștere lentă indică nestaționaritate
- După  $\Delta$ : vârfuri sezoniere raman la lagurile 12, 24, 36
- După  $\Delta_{12}$ : descreșterea de trend ramane la lagurile initiale
- După  $\Delta\Delta_{12}$ : ACF se opreste brusc  $\Rightarrow$  staționară

## Definitie 3 (Proces integrat sezonier)

O serie  $Y_t$  este **integrata sezonier** de ordinul  $(d, D)_s$ , scrisa  $Y_t \sim I(d, D)_s$ , dacă:

$$(1 - L)^d (1 - L^s)^D Y_t$$

este staționară.

## Cazuri comune

- $I(1, 0)_{12}$ : Doar rădăcină unitară obișnuită (lunară)
- $I(0, 1)_{12}$ : Doar rădăcină unitară sezonieră
- $I(1, 1)_{12}$ : Atât rădăcină unitară obișnuită cât și sezonieră

# Definitia modelului SARIMA

Definitie 4 (SARIMA( $p, d, q$ )  $\times$  ( $P, D, Q$ ) $_s$ )


Modelul **Seasonal ARIMA** este:

$$\phi(L)\Phi(L^s)(1 - L)^d(1 - L^s)^D Y_t = c + \theta(L)\Theta(L^s)\varepsilon_t$$

## Componente

- $\phi(L) = 1 - \phi_1L - \dots - \phi_pL^p$ : AR non-sezonier
- $\Phi(L^s) = 1 - \Phi_1L^s - \dots - \Phi_PL^{Ps}$ : AR sezonier
- $\theta(L) = 1 + \theta_1L + \dots + \theta_qL^q$ : MA non-sezonier
- $\Theta(L^s) = 1 + \Theta_1L^s + \dots + \Theta_QL^{Qs}$ : MA sezonier
- $(1 - L)^d$ : Diferențiere obișnuită;  $(1 - L^s)^D$ : Diferențiere sezonieră

## SARIMA: Ilustrare vizuala



### Strategia de Diferențiere

Transformare progresivă: Originală → diferență obișnuită (elimină trendul) → diferență sezonieră (elimină sezonialitatea) → ambele. Aplicați diferențierea minimă necesară pentru a obține staționaritate.

## Demonstrație: Structura Multiplicativă Sezonieră

De ce multiplicativă? Considerăm SARIMA( $1, 0, 0$ )  $\times$  ( $1, 0, 0$ ) $_s$ :

$$(1 - \phi L)(1 - \Phi L^s) Y_t = \varepsilon_t$$

Dezvoltăm produsul:

$$\begin{aligned}(1 - \phi L)(1 - \Phi L^s) Y_t &= Y_t - \phi LY_t - \Phi L^s Y_t + \phi\Phi L^{s+1} Y_t \\ &= Y_t - \phi Y_{t-1} - \Phi Y_{t-s} + \phi\Phi Y_{t-s-1}\end{aligned}$$

Rezultat: Modelul include un **termen de interacțiune**  $\phi\Phi Y_{t-s-1}$

### Interpretare (Lunar, $s = 12$ )

$Y_t$  depinde de:

- $Y_{t-1}$ : Luna trecută (dinamică pe termen scurt)
- $Y_{t-12}$ : Aceeași lună anul trecut (efectul sezonier)
- $Y_{t-13}$ : Interacțiunea ambelor efecte

### Parsimonie

Forma multiplicativă: 2 parametri ( $\phi, \Phi$ ). Forma aditivă ar necesita 3+ parametri.

## Specificație completă

SARIMA( $p, d, q) \times (P, D, Q)_s$  are 7 parametri de specificat:

| Parametru | Semnificație                        |
|-----------|-------------------------------------|
| $p$       | Ordinul AR non-sezonier             |
| $d$       | Ordinul diferențierii non-sezoniere |
| $q$       | Ordinul MA non-sezonier             |
| $P$       | Ordinul AR sezonier                 |
| $D$       | Ordinul diferențierii sezoniere     |
| $Q$       | Ordinul MA sezonier                 |
| $s$       | Perioada sezonieră                  |

## Exemplu

SARIMA(1, 1, 1)  $\times$  (1, 1, 1)<sub>12</sub>: Date lunare cu AR(1), MA(1), AR sezonier(1), MA sezonier(1), și atât diferențiere obișnuită cât și sezonieră.

## Modele SARIMA comune

Modelul Airline:  $\text{SARIMA}(0, 1, 1) \times (0, 1, 1)_s$

$(1 - L)(1 - L^s)Y_t = (1 + \theta L)(1 + \Theta L^s)\varepsilon_t$  – Model clasic (Box & Jenkins, 1970)

SARIMA(1, 0, 0)  $\times$  (1, 0, 0)<sub>s</sub>

$(1 - \phi L)(1 - \Phi L^s)Y_t = \varepsilon_t$  – AR sezonier și non-sezonier pur

SARIMA(0, 1, 1)  $\times$  (0, 1, 0)<sub>s</sub>

$(1 - L)(1 - L^s)Y_t = (1 + \theta L)\varepsilon_t$  – Random walk + dif. sezonieră + MA(1)

## Structura multiplicativă

### De ce multiplicativă?

Părțile sezonieră și non-sezonieră se înmulțesc:

$$\phi(L)\Phi(L^s) \quad \text{și} \quad \theta(L)\Theta(L^s)$$

Exemplu: SARIMA(1, 0, 0)  $\times$  (1, 0, 0)<sub>12</sub>

$$(1 - \phi L)(1 - \Phi L^{12}) Y_t = \varepsilon_t$$

$$\text{Desvoltand: } Y_t - \phi Y_{t-1} - \Phi Y_{t-12} + \phi \Phi Y_{t-13} = \varepsilon_t$$

Termenul incrustat  $\phi \Phi Y_{t-13}$  captează interacțiunea!

### Interpretare

Structura multiplicativă permite modelarea parsimonioasă a tipelor sezoniere complexe cu puțini parametri.

## Ideea cheie

Modelele sezoniere prezintă tipare la ambele:

- Lag-uri non-sezoniere:  $1, 2, 3, \dots$
- Lag-uri sezoniere:  $s, 2s, 3s, \dots$

| Model      | ACF                            | PACF                           |
|------------|--------------------------------|--------------------------------|
| SAR( $P$ ) | Descreste la $s, 2s, \dots$    | Se opreste după $Ps$           |
| SMA( $Q$ ) | Se opreste după $Qs$           | Descreste la $s, 2s, \dots$    |
| SARMA      | Descreste la lag-uri sezoniere | Descreste la lag-uri sezoniere |

## Exemplu: ACF/PACF pentru modelul Airline

SARIMA(0, 1, 1)  $\times$  (0, 1, 1)<sub>12</sub>

După diferențiere  $W_t = (1 - L)(1 - L^{12})Y_t$ :

$$W_t = (1 + \theta L)(1 + \Theta L^{12})\varepsilon_t$$

### Tiparul ACF așteptat

- Vârf la lag-ul 1 (de la  $\theta$ )
- Vârf la lag-ul 12 (de la  $\Theta$ )
- Vârf la lag-ul 13 (de la interacțiunea  $\theta \cdot \Theta$ )
- Toate celelalte lag-uri aproape de zero

### Tiparul PACF așteptat

- Descreștere exponențială la lagurile 1, 2, 3, ...
- Descreștere exponențială la lagurile 12, 24, 36, ...

## Proces pas cu pas

- ① Examinați ACF pentru descreștere lentă la lag-uri sezoniere  $\Rightarrow$  diferențiere sezonieră
- ② După diferențiere, verificați tiparele ACF/PACF
- ③ Comportamentul non-sezonier la lagurile  $1, 2, \dots, s - 1$
- ④ Comportamentul sezonier la lagurile  $s, 2s, 3s, \dots$

## Sfaturi practice

- Începeți cu  $d \leq 1$  și  $D \leq 1$
- De obicei  $P, Q \leq 2$  este suficient
- Folosiți criterii informationale (AIC, BIC) pentru selecția finală
- Algoritmii Auto-SARIMA pot ajută

## Estimare prin verosimilitate maxima

Abordare standard pentru SARIMA:

- MLE condiționată (condiționată de valorile inițiale)
- MLE exactă (prin filtrul Kalman)

## Considerații computationale

- Mai mulți parametri decat ARIMA  $\Rightarrow$  mai multe date necesare
- Parametrii sezonieri estimați din lagurile  $s, 2s, \dots$
- Necesită suficiente cicluri sezoniere (cel puțin 3-4 ani de date lunare)

## Condiții de staționaritate

Atât polinoamele AR non-sezoniere cât și sezoniere trebuie să aibă rădăcini în afara cercului unitate:

- $\phi(z) = 0 \Rightarrow |z| > 1$
- $\Phi(z^s) = 0 \Rightarrow |z| > 1$

## Condiții de invertibilitate

Atât polinoamele MA non-sezoniere cât și sezoniere trebuie să aibă rădăcini în afara cercului unitate:

- $\theta(z) = 0 \Rightarrow |z| > 1$
- $\Theta(z^s) = 0 \Rightarrow |z| > 1$

## Analiza reziduurilor

După ajustarea SARIMA, verificați ca reziduurile sunt zgomot alb:

- ① Graficul reziduurilor în timp (fără tipare)
- ② ACF a reziduurilor (fără vârfuri semnificative)
- ③ Testul Ljung-Box la lag-uri multiple inclusiv sezoniere
- ④ Teste de normalitate (grafic Q-Q, Jarque-Bera)

## Important

Verificați ACF la **ambele** lag-uri non-sezoniere și sezoniere!

ACF semnificativă la lag-ul 12 sugerează modelare sezonieră inadecvată.

## Criterii informationale

Comparați modelele SARIMA concurente folosind:

- $AIC = -2 \ln(L) + 2k$
- $BIC = -2 \ln(L) + k \ln(n)$
- $AICc = AIC + \frac{2k(k+1)}{n-k-1}$  (corectat pentru esantioane mici)

unde  $k = p + q + P + Q + 1$  (plus 1 pentru varianța).

## Auto-SARIMA

`pmdarima.auto_arima()` din Python cu `seasonal=True` cauta automat  $(p, d, q) \times (P, D, Q)_s$  optim.

## Calculul prognozei

Prognozele SARIMA sunt calculate recursiv:

- Înlocuiți  $\varepsilon_{T+h}$  viitor cu 0
- Înlocuiți  $Y_{T+h}$  viitor cu prognozele  $\hat{Y}_{T+h|T}$
- Folosiți valorile trecute cunoscute  $Y_T, Y_{T-1}, \dots$

## Tiparul sezonier în prognoze

Prognozele SARIMA captează în mod natural sezonialitatea:

- Pe termen scurt: influențate de valorile recente
- Pe termen lung: revin la tiparul sezonier

# Intervale de prognoză

## Cuantificarea incertitudinii

Interval de predicție  $(1 - \alpha)\%$ :

$$\hat{Y}_{T+h|T} \pm z_{\alpha/2} \sqrt{\text{Var}(e_{T+h})}$$

Varianta calculată din reprezentarea MA( $\infty$ ).

## Proprietăți cheie

- Intervalele se largesc cu orizontul de prognoză
- Pentru serii  $I(1,1)_s$ : intervalele cresc nelimitat
- Tiparul sezonier vizibil în prognozele punctuale
- Incertitudinea captează atât variația de trend cât și cea sezonieră

## Comportamentul când $h \rightarrow \infty$

- Prognozele punctuale converg la tiparul sezonier determinist
- Dacă există deriva: trend linear + tipar sezonier
- Intervalele de prognoză continuă să se lărgească

## Implicație practică


- Pe termen scurt: SARIMA captează atât nivelul cât și sezonul
- Pe termen mediu: Prognoze sezoniere bune, incertitudine crescătoare
- Pe termen lung: Reflectă în principal tiparul sezonier, intervale largi

## Datele privind pasagerii companiilor aeriene




- Set de date clasic: Pasageri internaționali lunari ai companiilor aeriene (1949-1960)
- Trend ascendent clar și amplitudine sezonieră crescătoare

## Descompunerea sezonieră




- Trend: Crestere puternică ascendentă
- Sezonalitate: Vârfuri de vară (călătorii de vacanță)
- Rezidual: Variație aleatoare după eliminarea trendului și sezonului

## Analiza ACF/PACF




- După diferențierea  $\Delta\Delta_{12}$ : vârfuri la lag-urile 1 și 12
- Sugerează SARIMA(0, 1, 1)  $\times$  (0, 1, 1)<sub>12</sub> (Modelul Airline)

## Rezultatele prognozei SARIMA



- SARIMA captează atât trendul cât și tiparul sezonier
- Prognozele prezintă vârfuri și minime sezoniere corespunzătoare

# Diagnosticarea modelului



- Reziduurile par aleatorii; ACF în limite la toate lag-urile
- Modelul captează adecvat structura sezonieră


## Ajustarea SARIMA în Python

```
from statsmodels.tsa.statespace.sarimax import SARIMAX  
model = SARIMAX(y, order=(0,1,1), seasonal_order=(0,1,1,12))  
results = model.fit()  
forecast = results.get_forecast(steps=24)
```

## Nota


Exemple complete în Python cu comentarii sunt furnizate în caietele Jupyter.

## Studiu de caz: Date despre pasagerii aerieni




- Setul de date clasic Box-Jenkins: pasageri aerieni lunari (1949-1960)
- Trend ascendent clar și amplitudine sezonieră crescătoare
- Sezonalitatea multiplicativă sugerează transformarea logaritmică

## Pasul 1: Transformări




- Transformarea log stabilizează varianța (multiplicativ → aditiv)
- Prima diferență elimină trendul; diferența sezonieră elimină sezonialitatea
- Seria dublu diferențiată pare staționară

## Pasul 2: Analiza ACF/PACF




- ACF: Vârf semnificativ la lag 1 și lag 12  $\Rightarrow$  MA(1), SMA(1)
- PACF: Tipar de descreștere exponențială confirmă structura MA
- Sugerează SARIMA(0, 1, 1)  $\times$  (0, 1, 1)<sub>12</sub> (modelul airline)

## Pasul 3: Compararea modelelor




- Comparăm modelele SARIMA cândidate folosind criteriul AIC
- SARIMA(0, 1, 1) × (0, 1, 1)<sub>12</sub> oferă cea mai bună ajustare (AIC minim)
- Acesta este faimosul "model airline" identificat de Box & Jenkins

## Pasul 4: Diagnosticarea reziduurilor



- Reziduurile par aleatorii fără autocorelație remanentă
- Graficul Q-Q arată normalitate aproximativă
- Modelul captează adecvat atât trendul cât și structura sezonieră

## Pasul 5: Prognoză



- Prognoză pe 24 de luni cu interval de încredere de 95%
- Modelul captează tiparul sezonier și trendul ascendent
- Intervalele de predicție se largesc corespunzător cu orizontul prognozei

## Puncte principale

- ① **Sezonalitatea** este comună în datele economice și de afaceri
- ② **Diferențierea sezonieră**  $(1 - L^s)$  elimină sezonalitatea stochastică
- ③ **SARIMA** $(p, d, q) \times (P, D, Q)_s$  extinde ARIMA pentru date sezoniere
- ④ **Structura multiplicativă** captează interacțiunile sezon-trend
- ⑤ **ACF/PACF** prezintă tipare la ambele lag-uri obișnuite și sezoniere
- ⑥ **Selecția modelului:** Folosiți AIC/BIC sau algoritmi auto-SARIMA

## Pașii următorii

Capitolul 5 va acoperi seriile de timp multivariate: modele VAR, cauzalitatea Granger și cointegrarea.

### Întrebare


Pentru date lunare cu sezonalitate anuala, care este perioadă sezonieră  $s$ ?

- A  $s = 4$
- B  $s = 7$
- C  $s = 12$
- D  $s = 52$

## Întrebarea 1: Răspuns

Răspuns corect: (C)  $s = 12$  (12 luni pe an)

Perioade comune: Trimestrial=4, Lunar=12, Săptămânal=52, Zilnic=7, Orar=24



## Întrebarea 2

### Întrebare




Ce face operatorul de diferență sezonieră  $(1 - L^{12})$  unei serii lunare?

- A Calculează  $Y_t - Y_{t-1}$  (schimbarea luna-la-luna)
- B Calculează  $Y_t - Y_{t-12}$  (schimbarea an-la-an)
- C Calculează media mobilă pe 12 luni
- D Elimină doar componenta de trend

## Întrebarea 2: Răspuns

Răspuns corect: (B) Schimbarea an-la-an

$(1 - L^{12})Y_t = Y_t - Y_{t-12}$  elimină tiparul sezonier prin compararea acelorași luni.



## Întrebarea 3

### Întrebare

În notația SARIMA(1, 1, 1)  $\times$  (1, 1, 1)<sub>12</sub>, ce reprezintă partea (1, 1, 1)<sub>12</sub>?

- A AR(1), o diferențiere, MA(1) la nivelul obișnuit
- B AR sezonier(1), o diferențiere sezonieră, MA sezonier(1)
- C 12 termeni AR, 12 diferențe, 12 termeni MA
- D Modelul are 12 parametri în total

## Întrebarea 3: Răspuns

Răspuns corect: (B)

AR sezonier(1), o diferențiere sezonieră, MA sezonier(1)

### Descompunerea notăției SARIMA

SARIMA( $p, d, q$ )  $\times$  ( $P, D, Q$ )<sub>s</sub>:

- ( $p, d, q$ ) Non-sezonier: AR( $p$ ),  $d$  diferențe, MA( $q$ )
- ( $P, D, Q$ )<sub>s</sub> Sezonier: SAR( $P$ ),  $D$  dif. sezoniere, SMA( $Q$ )

Pentru  $(1, 1, 1) \times (1, 1, 1)_{12}$ :

- Non-sezonier: AR(1), o diferență obișnuită, MA(1)
- Sezonier: SAR(1) la lag-ul 12, un  $\Delta_{12}$ , SMA(1) la lag-ul 12

## Întrebarea 4

### Întrebare

"Modelul Airline" este SARIMA( $0, 1, 1$ )  $\times$  ( $0, 1, 1$ )<sub>12</sub>. Câte parametri trebuie estimati (excluzând varianța)?

- A 1
- B 2
- C 4
- D 12

## Întrebarea 4: Răspuns

Răspuns corect: (B)

2 parametri

### Structura modelului

SARIMA(0, 1, 1)  $\times$  (0, 1, 1)<sub>12</sub>:

$$(1 - L)(1 - L^{12})Y_t = (1 + \theta_1 L)(1 + \Theta_1 L^{12})\varepsilon_t$$

Parametri:

- $\theta_1$ : coeficient MA non-sezonier
- $\Theta_1$ : coeficient MA sezonier

Total: **2 parametri** (plus  $\sigma^2$ )

### De ce "Modelul Airline"?

Box & Jenkins (1970) au folosit acest model pentru a prognoză pasagerii companiilor aeriene internationale. Este remarcabil de eficient pentru multe serii economice sezoniere!

## Întrebarea 5

### Întrebare


Observați vârfuri ACF semnificățive la lag-urile 12, 24 și 36 într-o serie lunară. Ce sugerează aceasta?

- A Seria are o rădăcină unitară
- B Seria are sezonalitate anuala care necesită diferențiere sezonieră
- C Seria urmează un proces AR(36)
- D Seria este deja staționară

## Întrebarea 5: Răspuns

Răspuns corect: (B) Necesită diferențiere sezonieră

Vârfuri ACF la 12, 24, 36 = sezonalitate stochastică. Aplicați  $(1 - L^{12})$  pentru a o elimina.



## Întrebarea 6

### Întrebare

După aplicarea  $(1 - L)(1 - L^{12})$  unei serii lunare, ACF prezintă un vârf semnificativ doar la lag-ul 1 și lag-ul 12. Ce model SARIMA este sugerat?

- A SARIMA(1, 1, 0) × (1, 1, 0)<sub>12</sub>
- B SARIMA(0, 1, 1) × (0, 1, 1)<sub>12</sub>
- C SARIMA(1, 1, 1) × (1, 1, 1)<sub>12</sub>
- D SARIMA(0, 1, 0) × (0, 1, 0)<sub>12</sub>

## Întrebarea 6: Răspuns

Răspuns corect: (B)

SARIMA(0, 1, 1)  $\times$  (0, 1, 1)<sub>12</sub> (Modelul Airline)

### Reguli de identificare ACF/PACF

Pentru procese MA, ACF se opreste brusc după lag-ul  $q$ :

| Tipar                      | Sugerează                         |
|----------------------------|-----------------------------------|
| Vârf ACF doar la lag-ul 1  | MA(1) pentru partea non-sezonieră |
| Vârf ACF doar la lag-ul 12 | SMA(1) pentru partea sezonieră    |

Combinat: MA(1)  $\times$  SMA(1) = (0,  $d$ , 1)  $\times$  (0,  $D$ , 1)<sub>12</sub>

Cu  $d = 1$  și  $D = 1$  (deja diferențiată): (0, 1, 1)  $\times$  (0, 1, 1)<sub>12</sub>

-  Box, G.E.P., Jenkins, G.M., Reinsel, G.C., & Ljung, G.M. (2015). *Time Series Analysis: Forecasting and Control*. 5th ed. Wiley.
-  Hyndman, R.J. & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. 3rd ed. OTexts.
-  Hamilton, J.D. (1994). *Time Series Analysis*. Princeton University Press.
-  Brockwell, P.J. & Davis, R.A. (2016). *Introduction to Time Series and Forecasting*. 3rd ed. Springer.