



Analiza și Prognoza Seriilor de Timp

Capitolul 6: Modele VAR și Cauzalitate Granger



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Obiective de învățare

La finalul acestui capitol, veți fi capabili să:

1. Înțelegeți **motivația** pentru analiza multivariată a seriilor de timp
2. Specificați și estimați modele **VAR(p)**
3. Aplicați teste de **cauzalitate Granger**
4. Interpretați **funcțiile de răspuns la impuls (IRF)**
5. Efectuați **descompunerea varianței erorii de prognoză (FEVD)**
6. Selectați ordinul optimal al lag-urilor folosind criterii informaționale
7. Implementați analiza VAR în **Python**



Cuprins

Fundamente

- Motivație
- Introducere în seriile de timp multivariate
- Vector Autoregresiv (VAR)
- Cauzalitate Granger
- Funcții de răspuns la impuls
- Descompunerea varianței erorii de prognoză

Aplicații

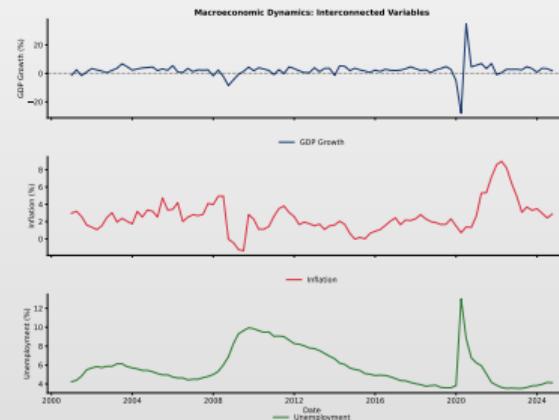
- Diagnosticarea VAR
- Prognoza VAR
- Exemplu practic
- Studiu de caz: PIB și Șomaj
- Rezumat și Quiz



Exemplu motivant: Dinamica macroeconomică

Observații

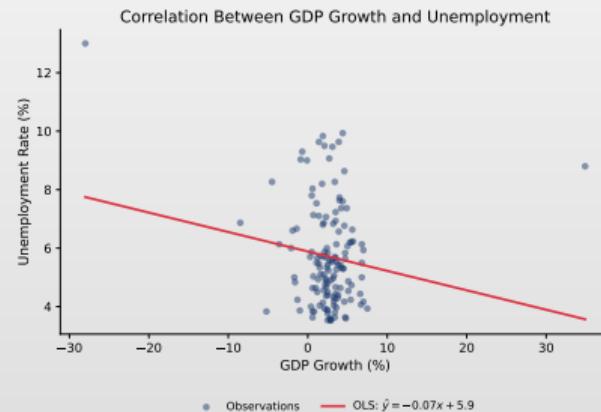
- Variabilele economice sunt **interconectate**: PIB afectează șomajul, inflația afectează ratele dobânzii
- Schimbările într-o variabilă se **propagă** prin sistem
- Înțelegerea acestor dinamici necesită analiză **multivariată**



Idea cheie: variabilele interacționează

Exemple

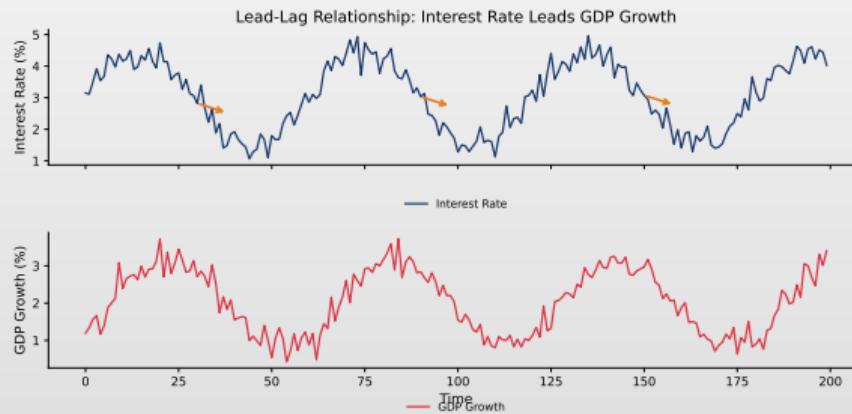
- Legea lui Okun:** PIB $\uparrow \Rightarrow$ șomaj \downarrow
- Regula Taylor:** Inflație $\uparrow \Rightarrow$ dobândă \uparrow
- Curba Phillips:** Compromis șomaj-inflație



Relații de avans-întârziere

Observații

- Unele variabile preced altele: creșterea PIB prezice scăderea șomajului
 - ▶ Corelația încrucișată relevă **sincronizarea relațiilor**
 - ▶ Corelație maximă la lag-ul 4: PIB-ul precede șomajul cu ~4 trimestre



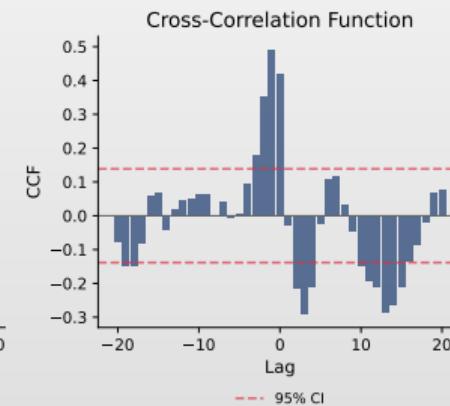
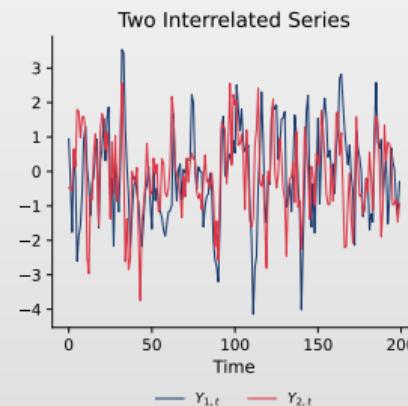
De ce modelele univariate nu sunt suficiente

Problema

ARIMA tratează fiecare variabilă **izolat**; ignoră **interacțiunile și efectele de feedback**

Exemple

PIB–Șomaj, Dobândă–Inflație, Acțiuni–Volum, Curs–Balanță comercială



Univariate AR(1)

$$Y_{1,t} = \phi_1 Y_{1,t-1} + \varepsilon_t$$

→ Ignores Y_2

VAR(1)

$$\mathbf{Y}_t = \mathbf{A}\mathbf{Y}_{t-1} + \boldsymbol{\varepsilon}_t$$

→ Captures all cross-dynamics



Ce vom învăța astăzi

Concepțe fundamentale

1. **Modele VAR:** Cum să modelăm mai multe serii de timp împreună
2. **Cauzalitate Granger:** Ajută X la prezicerea lui Y ?
3. **Funcții de răspuns la impuls:** Cum se propagă șocurile?
4. **Descompunerea varianței:** Ce determină fiecare variabilă?

Exemplu recurrent: Creșterea PIB și șomajul

- Y_{1t} : **Creșterea PIB** și Y_{2t} : **Rata șomajului** (*Legea lui Okun*)
- Întrebare centrală: Cauzează PIB-ul șomajul, sau invers, sau ambele?

Aplicații

- Politică macroeconomică
- Piete financiare
- Ciclul de afaceri
- Managementul riscului



Notația seriilor de timp multivariate

Vector de variabile

- $Y_t = (Y_{1t}, Y_{2t}, \dots, Y_{Kt})'$
 - Vector $K \times 1$ de serii de timp
- Exemplu cu $K = 2$:

$$Y_t = \begin{pmatrix} Y_{1t} \\ Y_{2t} \end{pmatrix} = \begin{pmatrix} \text{Creștere PIB}_t \\ \text{Somaj}_t \end{pmatrix}$$

Întrebări cheie

1. Ajută Y_1 la prezicerea lui Y_2 ? (Cauzalitate Granger)
2. Cum afectează řocurile în Y_1 pe Y_2 ? (Răspunsuri la impuls)
3. Ce proporție din varianța lui Y_2 se datorează lui Y_1 ? (Descompunerea varianței)

Staționaritate multivariată

Definiție: Staționaritate slabă

- O serie de timp K -dimensională \mathbf{Y}_t este **slab staționară** dacă:
 - ▶ $\mathbb{E}[\mathbf{Y}_t] = \boldsymbol{\mu}$ (vector de medie constant)
 - ▶ $\text{Cov}(\mathbf{Y}_t, \mathbf{Y}_{t-h}) = \boldsymbol{\Gamma}(h)$ depinde doar de h , nu de t

Matricea de autocovarianță

- **Formula:** $\boldsymbol{\Gamma}(h) = \mathbb{E}[(\mathbf{Y}_t - \boldsymbol{\mu})(\mathbf{Y}_{t-h} - \boldsymbol{\mu})'] = \begin{pmatrix} \gamma_{11}(h) & \gamma_{12}(h) \\ \gamma_{21}(h) & \gamma_{22}(h) \end{pmatrix}$
- **Proprietate:** $\boldsymbol{\Gamma}(-h) = \boldsymbol{\Gamma}(h)'$ (transpusa, nu egală!)

Proprietăți ale covarianței încrucișate

Funcția de covarianță încrucișată

Pentru variabilele Y_{it} și Y_{jt} : $\gamma_{ij}(h) = \text{Cov}(Y_{it}, Y_{j,t-h}) = \mathbb{E}[(Y_{it} - \mu_i)(Y_{j,t-h} - \mu_j)]$

Diferența cheie față de cazul univariat

- În general: $\gamma_{ij}(h) \neq \gamma_{ij}(-h)$
- Dar: $\gamma_{ij}(h) = \gamma_{ji}(-h)$
- Matricea de covarianță încrucișată **nu este simetrică** pentru $h \neq 0$

Exemplu

- Dacă Y_1 precede Y_2 :
 - ▶ $\gamma_{12}(h) > 0$ pentru $h > 0$
 - ▶ $\gamma_{12}(h) \approx 0$ pentru $h < 0$



Matricea funcției de corelație

Definiție

- Matricea de autocorelație la lag-ul h :

$$\mathbf{R}(h) = \mathbf{D}^{-1} \boldsymbol{\Gamma}(h) \mathbf{D}^{-1}$$

- $\mathbf{D} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_K)$ și $\sigma_i = \sqrt{\gamma_{ii}(0)}$

Pentru cazul bivariat

- Matricea: $\mathbf{R}(h) = \begin{pmatrix} \rho_{11}(h) & \rho_{12}(h) \\ \rho_{21}(h) & \rho_{22}(h) \end{pmatrix}$, unde $\rho_{ij}(h) = \frac{\gamma_{ij}(h)}{\sigma_i \sigma_j}$

- Interpretare:

- ▶ Diagonale: ACF obișnuite
- ▶ Extra-diagonale: corelații încrucișate



Portret de cercetător: Sims & Granger



Christopher Sims (*1942)

Premiul Nobel 2011

 [wikipedia \(en\)](#)



Clive Granger (1934–2009)

Premiul Nobel 2003

 [wikipedia \(en\)](#)

Biografie

- **Christopher Sims:** econometrist american la Princeton. Premiul Nobel (2011) „pentru cercetări empirice privind cauza și efectul în macroeconomie”
- **Clive Granger:** economist britanic-american la UC San Diego. Premiul Nobel (2003) „pentru metode de analiză a seriilor economice cu tendințe comune (cointegrare)”

Contribuții principale

- **Modele VAR** (Sims, 1980) — vectori autoregresivi pentru macroeconomie
- **Cauzalitatea Granger** (Granger, 1969) — concept de cauzalitate predictivă
- **Funcții impuls-răspuns și identificarea VAR structural**
- **Cointegrarea** (Granger, 1981) — relații de echilibru pe termen lung



Modelul VAR(p)

Definiție

- Un model VAR(p) pentru K variabile:

$$\mathbf{Y}_t = \mathbf{c} + \mathbf{A}_1 \mathbf{Y}_{t-1} + \mathbf{A}_2 \mathbf{Y}_{t-2} + \cdots + \mathbf{A}_p \mathbf{Y}_{t-p} + \boldsymbol{\varepsilon}_t$$

- \mathbf{Y}_t : vector $K \times 1$ de variabile endogene
- \mathbf{c} : vector $K \times 1$ de constante
- \mathbf{A}_i : matrice de coeficienți $K \times K$
- $\boldsymbol{\varepsilon}_t$: vector $K \times 1$ de termeni de eroare cu $\mathbb{E}[\boldsymbol{\varepsilon}_t] = 0$, $\mathbb{E}[\boldsymbol{\varepsilon}_t \boldsymbol{\varepsilon}'_t] = \boldsymbol{\Sigma}$



VAR(1) cu două variabile

VAR(1) bivariat

- Forma matriceală:

$$\begin{pmatrix} Y_{1t} \\ Y_{2t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} + \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \begin{pmatrix} Y_{1,t-1} \\ Y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

Ecuație cu ecuație

- Ecuăția 1:** $Y_{1t} = c_1 + a_{11} Y_{1,t-1} + a_{12} Y_{2,t-1} + \varepsilon_{1t}$
- Ecuăția 2:** $Y_{2t} = c_2 + a_{21} Y_{1,t-1} + a_{22} Y_{2,t-1} + \varepsilon_{2t}$
- Ideea cheie:** Fiecare ecuație include lag-uri ale **tuturor** variabilelor!



Exemplu numeric: VAR(1)

Model VAR(1) specific

Exemplu numeric:

$$\begin{pmatrix} Y_{1t} \\ Y_{2t} \end{pmatrix} = \begin{pmatrix} 0.5 \\ 0.3 \end{pmatrix} + \begin{pmatrix} 0.7 & 0.2 \\ -0.1 & 0.6 \end{pmatrix} \begin{pmatrix} Y_{1,t-1} \\ Y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

Interpretarea coeficientilor

- $a_{11} = 0.7$: Creștere de 1 în Y_1 la $t-1 \Rightarrow Y_1$ la t crește cu 0.7
- $a_{12} = 0.2$: Creștere de 1 în Y_2 la $t-1 \Rightarrow Y_1$ la t crește cu 0.2
- $a_{21} = -0.1$: Creștere de 1 în Y_1 la $t-1 \Rightarrow Y_2$ la t scade cu 0.1
- $a_{22} = 0.6$: Creștere de 1 în Y_2 la $t-1 \Rightarrow Y_2$ la t crește cu 0.6



VAR(2): dinamică de ordin superior

Specificația VAR(2)

- Forma generală: $Y_t = c + A_1 Y_{t-1} + A_2 Y_{t-2} + \varepsilon_t$
- Pentru $K = 2, p = 2$: fiecare ecuație are $1 + pK = 5$ parametri, total $K(1 + pK) = 10$

Dezvoltat

- Ecuațiile individuale:

$$Y_{1t} = c_1 + a_{11}^{(1)} Y_{1,t-1} + a_{12}^{(1)} Y_{2,t-1} + a_{11}^{(2)} Y_{1,t-2} + a_{12}^{(2)} Y_{2,t-2} + \varepsilon_{1t}$$

$$Y_{2t} = c_2 + a_{21}^{(1)} Y_{1,t-1} + a_{22}^{(1)} Y_{2,t-1} + a_{21}^{(2)} Y_{1,t-2} + a_{22}^{(2)} Y_{2,t-2} + \varepsilon_{2t}$$

Blestemul dimensionalității

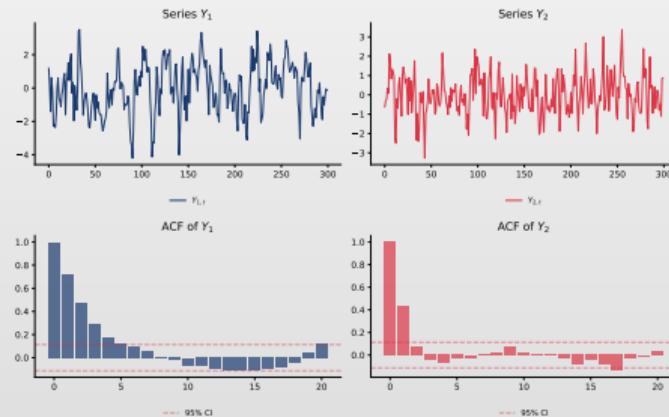
- VAR(p) cu K variabile are $K + pK^2$ parametri; cu $K = 5, p = 4$: $5 + 4 \times 25 = 105$ parametri!



Proces VAR simulat

Observații

- Proces VAR(1) bivariat simulat — interdependentă dintre serii
- Fiecare variabilă răspunde la propriul trecut și trecutul celeilalte variabile
- Dinamica încrucișată vizibilă



Forma companion

Conversia VAR(p) la VAR(1)

Orice VAR(p) poate fi scris ca VAR(1) în **forma companion**: $\xi_t = A\xi_{t-1} + v_t$

Pentru VAR(2)

Formă: $\underbrace{\begin{pmatrix} Y_t \\ Y_{t-1} \end{pmatrix}}_{\xi_t} = \underbrace{\begin{pmatrix} A_1 & A_2 \\ I_K & 0 \end{pmatrix}}_A \underbrace{\begin{pmatrix} Y_{t-1} \\ Y_{t-2} \end{pmatrix}}_{\xi_{t-1}} + \underbrace{\begin{pmatrix} \varepsilon_t \\ 0 \end{pmatrix}}_{v_t}$ **Dimensiune:** A este $Kp \times Kp$

Produsul Kronecker \otimes

Dacă A este $m \times n$ și B este $p \times q$, atunci $A \otimes B$ este matricea $mp \times nq$:

$$A \otimes B = \begin{pmatrix} a_{11}B & \cdots & a_{1n}B \\ \vdots & \ddots & \vdots \\ a_{m1}B & \cdots & a_{mn}B \end{pmatrix}$$

Utilizare: $\text{vec}(\Sigma_Y) = (I_{K^2} - A \otimes A)^{-1} \text{vec}(\Sigma_\varepsilon)$ — matricea de covarianță a VAR staționar.

Staționaritatea VAR

Condiția de stabilitate

- VAR(p) este **stabil** (staționar) dacă toate rădăcinile lui:

$$\det(I_K - A_1z - A_2z^2 - \cdots - A_pz^p) = 0$$

- Se află **în afara** cercului unitate (adică $|z| > 1$)

Pentru VAR(1)

- Modelul este stabil dacă toate **valorile proprii** ale lui A_1 sunt mai mici decât 1 în valoare absolută
- Exemplu: Pentru $A_1 = \begin{pmatrix} 0.5 & 0.1 \\ 0.2 & 0.3 \end{pmatrix}$, valorile proprii sunt $\lambda_1 \approx 0.54$ și $\lambda_2 \approx 0.26$
 - ▶ Ambele $< 1 \succ$ stabil!



Condiția de stabilitate: exemplu numeric

$$\text{Pentru } A = \begin{pmatrix} 0.7 & 0.2 \\ -0.1 & 0.6 \end{pmatrix}$$

Polinomul caracteristic: $\det(A - \lambda I) = 0$

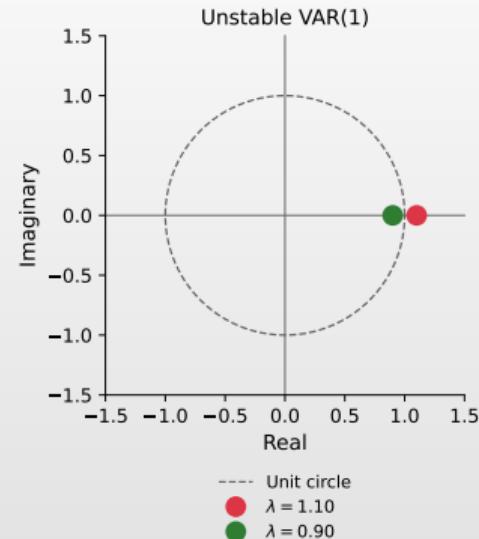
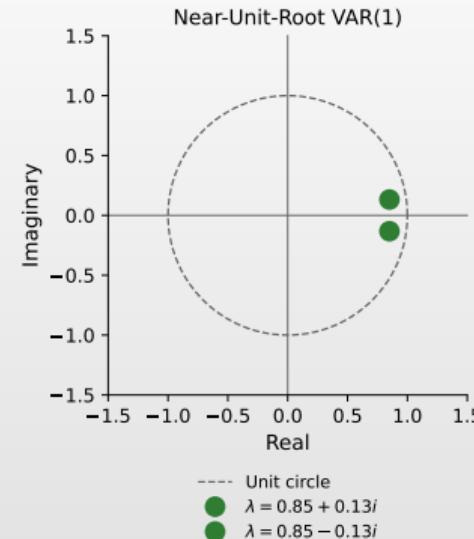
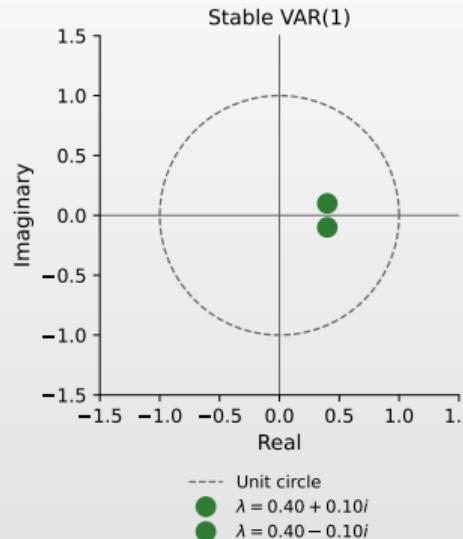
$$\det \begin{pmatrix} 0.7 - \lambda & 0.2 \\ -0.1 & 0.6 - \lambda \end{pmatrix} = (0.7 - \lambda)(0.6 - \lambda) + 0.02 = 0 \implies \lambda^2 - 1.3\lambda + 0.44 = 0$$

Soluție

$$\lambda = \frac{1.3 \pm \sqrt{1.69 - 1.76}}{2} = 0.65 \pm 0.132i, \quad |\lambda| = \sqrt{0.65^2 + 0.132^2} = \sqrt{0.44} = 0.663 < 1 \quad \checkmark \text{ Stabil!}$$



Condiția de stabilitate: interpretare vizuală



 TSA_ch6_stability_roots



Media unui VAR staționar

Media necondiționată

- Pentru un VAR(1) staționar: $Y_t = c + AY_{t-1} + \varepsilon_t$
- Luând medii: $\mathbb{E}[Y_t] = c + A\mathbb{E}[Y_{t-1}]$
- Deoarece $\mathbb{E}[Y_t] = \mathbb{E}[Y_{t-1}] = \mu$ (staționaritate):

$$\mu = c + A\mu \quad \succ \quad \mu = (I_K - A)^{-1}c$$

Exemplu

Dacă $c = \begin{pmatrix} 0.5 \\ 0.3 \end{pmatrix}$ și $A = \begin{pmatrix} 0.7 & 0.2 \\ -0.1 & 0.6 \end{pmatrix}$:

$$\mu = \begin{pmatrix} 0.3 & -0.2 \\ 0.1 & 0.4 \end{pmatrix}^{-1} \begin{pmatrix} 0.5 \\ 0.3 \end{pmatrix} = \frac{1}{0.14} \begin{pmatrix} 0.4 & 0.2 \\ -0.1 & 0.3 \end{pmatrix} \begin{pmatrix} 0.5 \\ 0.3 \end{pmatrix} = \begin{pmatrix} 1.86 \\ 0.29 \end{pmatrix}$$



Structura covarianței pentru VAR(1)

Matricea varianță-covariantă $\Gamma(0)$

Pentru VAR(1), varianța satisface ecuația discretă Lyapunov: $\Gamma(0) = A\Gamma(0)A' + \Sigma$

Autocovarianța la lag-ul h

Formula: $\Gamma(h) = A^h\Gamma(0)$, $h \geq 0$. Autocovarianțele scad geometric cu valorile proprii ale lui A.

Rezolvarea ecuației Lyapunov

Se rezolvă prin vectorizare: $\text{vec}(\Gamma(0)) = (I_{K^2} - A \otimes A)^{-1} \text{vec}(\Sigma)$, unde \otimes denotă produsul Kronecker.



Estimarea VAR

Estimarea OLS

- Fiecare ecuație poate fi estimată prin **OLS separat**:

$$\hat{A} = \left(\sum_{t=1}^T Y_{t-1} Y'_{t-1} \right)^{-1} \left(\sum_{t=1}^T Y_{t-1} Y'_t \right)$$

- Eficientă deoarece toate ecuațiile au **aceeași regresori**

Matricea de covarianță

Estimatorul: $\hat{\Sigma} = \frac{1}{T-K_p-1} \sum_{t=1}^T \hat{\epsilon}_t \hat{\epsilon}'_t$

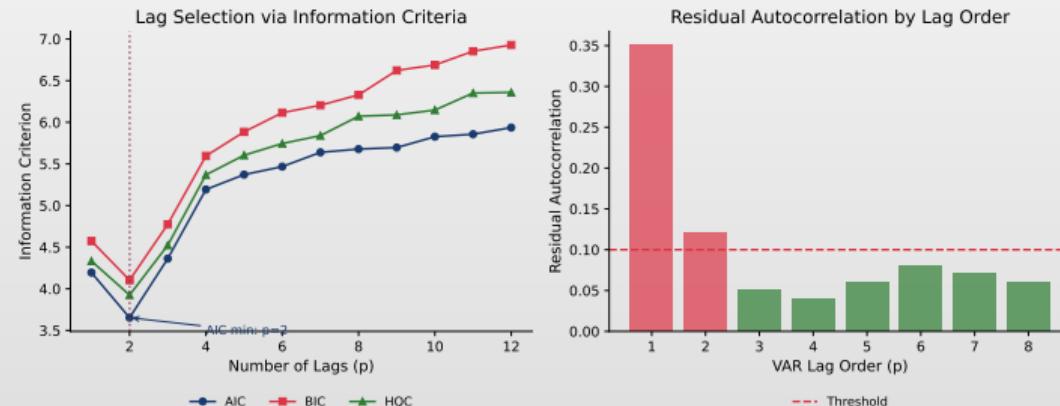
Erorile ε_{1t} și ε_{2t} pot fi **corelate contemporan**.



Selectia lag-ului: exemplu

Observatii

- Date reale SUA (FRED): PIB și Șomaj, $T = 140$ trimestre
- Criterii informaționale: AIC și BIC pentru lag $p = 1, \dots, 10$ (pot sugera ordine diferite)
- Interpretare: valori mici = ajustare mai bună; ambele selectează $p = 2$



Selectia ordinului lag-ului

Criterii informative

Alegem p care minimizează:

$$\begin{aligned} \text{AIC}(p) &= \ln |\hat{\Sigma}_p| + \frac{2pK^2}{T} \\ \text{BIC}(p) &= \ln |\hat{\Sigma}_p| + \frac{pK^2 \ln T}{T} \\ \text{HQ}(p) &= \ln |\hat{\Sigma}_p| + \frac{2pK^2 \ln \ln T}{T} \end{aligned}$$

unde: $\hat{\Sigma}_p$ = matricea de covarianță a reziduurilor, K = nr. variabile, p = nr. lag-uri, T = dimensiunea eșantionului

Îndrumări

- Comportamentul criteriilor:
 - ▶ AIC tinde să selecteze modele **mai mari** (mai bune pentru prognoză)
 - ▶ BIC tinde să selecteze modele **mai mici** (selecție consistentă)
- Începeți cu p_{max} bazat pe frecvența datelor (ex. 4 pentru trimestrial, 12 pentru lunar)



Modele VAR restricționate

De ce restricționăm?

- Modelele VAR complete pot fi **supraparametrizate**:
 - ▶ Mulți coeficienți pot fi nesemnificațивii
 - ▶ Prognoze slabe
 - ▶ Pierdere de grade de libertate

Restricții comune

- **Restricții de zero:** Setăm coeficienți mici la zero
- **Exogenitate de bloc:** Unele variabile nu afectează altele
- **Excluderea lag-urilor:** Excludem anumite lag-uri

Testarea restricțiilor

- Folosim testul raportului de verosimilitate:
- $LR = T(\ln |\hat{\Sigma}_R| - \ln |\hat{\Sigma}_U|) \sim \chi^2_r$, unde r = numărul de restricții



Ce este cauzalitatea Granger?

Clive Granger (1969, premiul Nobel 2003)

- “**X cauzează Granger pe Y**” dacă valorile trecute ale lui X ajută la prezicerea lui Y, **dincolo de ce pot prezice valorile trecute ale lui Y singure**

Distincție importantă: Cauzalitate Granger \neq cauzalitate reală

- Cauzalitatea Granger este despre **conținut predictiv**
- NU implică cauzare economică/structurală
- “**X cauzează Granger pe Y**” înseamnă: X conține informații utile pentru prognoza lui Y



Definiție formală

Cauzalitate Granger

- X nu cauzează Granger pe Y dacă:**
$$\mathbb{E}[Y_t | Y_{t-1}, Y_{t-2}, \dots, X_{t-1}, X_{t-2}, \dots] = \mathbb{E}[Y_t | Y_{t-1}, Y_{t-2}, \dots]$$
- Adăugarea istoricului lui X nu îmbunătățește predicția lui Y

În contextul VAR

- VAR(1): $Y_{1t} = c_1 + a_{11}Y_{1,t-1} + a_{12}Y_{2,t-1} + \varepsilon_{1t}$
► **Y_2 nu cauzează Granger pe Y_1 dacă $a_{12} = 0$**
- VAR(p): nu cauzează dacă $a_{12}^{(1)} = a_{12}^{(2)} = \dots = a_{12}^{(p)} = 0$

Testarea cauzalității Granger

Ipotezele testului

- H_0 : Y_2 nu cauzează Granger pe Y_1
 - $a_{12}^{(1)} = a_{12}^{(2)} = \dots = a_{12}^{(p)} = 0$
- H_1 : Cel puțin un $a_{12}^{(i)} \neq 0$
 - Există cauzalitate Granger

Statistica testului: Testul Wald

- Formula: $F = \frac{(RSS_R - RSS_U)/p}{RSS_U/(T-2p-1)} \sim F_{p, T-2p-1}$
- RSS_R : Reziduuri model restricționat (fără lag-urile lui Y_2)
- RSS_U : Reziduuri model nerestricționat (VAR complet)



Tipuri de cauzalitate Granger



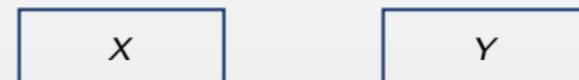
Unidirecțională: $X \succ Y$



Bidirecțională: $X \succ Y$



Unidirecțională: $Y \succ X$



Fără cauzalitate

Exemple economice

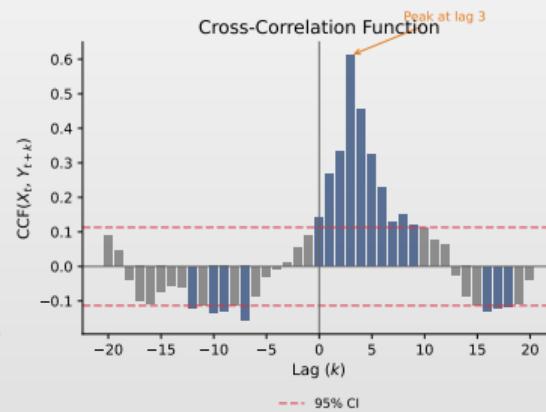
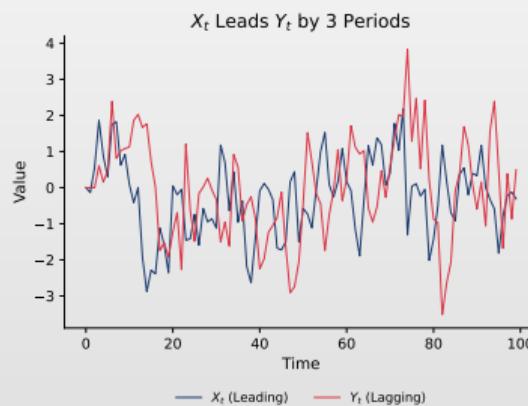
- Masa monetară \succ Producție? (viziunea monetaristă)
- Prețurile acțiunilor \succ Volumul tranzacționat (bidirecțională)
- Vremea \succ Recolta (unidirecțională, evident)



Corelație încrucișată: ilustrare vizuală

Interpretare

- Stânga: două serii înrudite; Dreapta: CCF relevă că X precede Y (corelații semnificative la lag-uri pozitive)



Funcția de corelație încrucișată

Definiție 1 (Funcția de corelație încrucișată)

- Corelația încrucișată între X_t și Y_t la lag-ul k :

$$\rho_{XY}(k) = \frac{\gamma_{XY}(k)}{\sigma_X \sigma_Y} = \frac{\text{Cov}(X_t, Y_{t+k})}{\sqrt{\text{Var}(X_t)\text{Var}(Y_t)}}$$

Interpretare

- $\rho_{XY}(k) > 0$ la $k > 0$: X este corelat pozitiv cu Y viitor (X poate precede Y)
- $\rho_{XY}(k) > 0$ la $k < 0$: X este corelat pozitiv cu Y trecut (Y poate precede X)

Notă

- Spre deosebire de ACF, corelația încrucișată **nu este simetrică**: $\rho_{XY}(k) \neq \rho_{XY}(-k)$ în general



Cauzalitate Granger: considerații practice

Capcane comune

- Variabile omise:** O a treia variabilă Z poate cauza atât X cât și Y
- Nestaționaritate:** Testul necesită date staționare (sau cointegrare)
- Selectia lag-ului:** Rezultatele pot fi sensibile la p
- Mărimea eșantionului:** Necesită suficiente observații

Bune practici

- Pregătirea datelor:** testați pentru rădăcini unitare; folosiți criterii multiple pentru selecția lag-ului
- Robustete:** verificați la diferite ordine ale lag-ului; raportați rezultatele pentru ambele direcții



Test cauzalitate Granger: exemplu numeric

Testare: Cauzează creșterea masei monetare Granger producția?

- Model nerestricționat (VAR cu 2 lag-uri):

$$\Delta Y_t = c + \alpha_1 \Delta Y_{t-1} + \alpha_2 \Delta Y_{t-2} + \beta_1 \Delta M_{t-1} + \beta_2 \Delta M_{t-2} + \varepsilon_t$$

- Model restricționat ($H_0: \beta_1 = \beta_2 = 0$):

$$\Delta Y_t = c + \alpha_1 \Delta Y_{t-1} + \alpha_2 \Delta Y_{t-2} + \varepsilon_t$$

Calculul testului

$T = 100$, $RSS_U = 45.2$, $RSS_R = 52.8$:

$$F = \frac{(52.8 - 45.2)/2}{45.2/(100 - 5)} = \frac{3.8}{0.476} = 7.98$$

$F_{0.05}(2, 95) = 3.09 \succ$ **Respingem** H_0 : Banii cauzează Granger producția!



Procedura Toda-Yamamoto

Problema cu datele nestaționare

- Testul Granger standard are **distribuții non-standard** când:
 - ▶ Variabilele au rădăcini unitare
 - ▶ Variabilele sunt cointegrate

Soluția Toda-Yamamoto (1995)

1. Determinăm ordinul maxim de integrare d_{max}
2. Estimăm VAR($p + d_{max}$) în **niveluri**
3. Testăm restricții doar pe primele p lag-uri
4. Lagurile suplimentare d_{max} **nu sunt** testate (doar pentru distribuția corectă)

Avantaj

- Testul Wald are distribuție asimptotică χ^2 indiferent de cointegrare!



Cauzalitate instantanee

Definiție

- **X cauzează instantaneu pe Y dacă:**
 - ▶ $\mathbb{E}[Y_t | \Omega_{t-1}, X_t] \neq \mathbb{E}[Y_t | \Omega_{t-1}]$
 - ▶ Ω_{t-1} : toate informațiile trecute

Testarea în VAR

Testăm $\sigma_{12} \neq 0$ în $\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix}$. $\sigma_{12} = 0 \succ$ fără cauzalitate instantanee.

Interpretare

Cauze posibile: şocuri comune sau agregarea datelor — nu neapărat efecte contemporane reale.



Cauzalitate Granger în sisteme multiple

Testul exogenității de bloc

- Într-un VAR cu $K > 2$ variabile, testăm dacă un **grup** de variabile cauzează Granger un alt grup
- Exemplu: Cauzează variabilele financiare (rate ale dobânzii, prețuri acțiuni) Granger variabilele reale (PIB, șomaj)?

Statistica testului

$$\chi^2 = T \left(\ln |\hat{\Sigma}_R| - \ln |\hat{\Sigma}_U| \right) \sim \chi^2_{K_1 \cdot K_2 \cdot p}, \text{ unde } K_1 = \text{variabile "cauzate"}, K_2 = \text{variabile "cauzatoare".}$$



Ce sunt funcțiile de răspuns la impuls?

Definiție

Funcție de Răspuns la Impuls (IRF)

- ▶ Efectul unui soc punctual la o variabilă
- ▶ Asupra valorilor curente și viitoare ale tuturor variabilelor

Întrebarea la care răspund IRF-urile

"Dacă apare un soc de 1 unitate la Y_1 astăzi, ce se întâmplă cu Y_1 și Y_2 în următoarele h perioade?"

Reprezentarea MA(∞)

Un VAR(p) stabil: $Y_t = \mu + \sum_{i=0}^{\infty} \Phi_i \varepsilon_{t-i}$, unde Φ_i = răspunsurile la impuls la orizontul i .



Calculul IRF pentru VAR(1)

Pentru VAR(1): $Y_t = c + AY_{t-1} + \varepsilon_t$

- Matricele de răspuns la impuls sunt:

$$\Phi_0 = I_K, \quad \Phi_1 = A, \quad \Phi_2 = A^2, \quad \dots, \quad \Phi_h = A^h$$

Interpretare

- $[\Phi_h]_{ij}$: Efectul asupra lui Y_i la $t+h$
 - ▶ Al unui soc unitar la Y_j la momentul t
- VAR stabil: $\Phi_h \succ 0$ când $h \succ \infty$
 - ▶ řocurile dispar în timp



Calculul IRF pentru VAR(p) general

Formula recursivă pentru VAR(p)

- Pentru $Y_t = c + A_1 Y_{t-1} + \cdots + A_p Y_{t-p} + \varepsilon_t$:

$$\Phi_h = \sum_{j=1}^{\min(h,p)} A_j \Phi_{h-j}, \quad h = 1, 2, 3, \dots$$

- Cu $\Phi_0 = I_K$ și $\Phi_h = 0$ pentru $h < 0$

Exemplu: IRF pentru VAR(2)

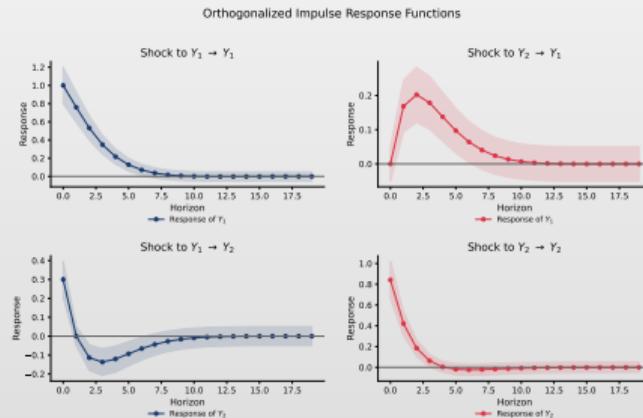
- $\Phi_0 = I_K$
- $\Phi_1 = A_1 \Phi_0 = A_1$
- $\Phi_2 = A_1 \Phi_1 + A_2 \Phi_0 = A_1^2 + A_2$
- $\Phi_3 = A_1 \Phi_2 + A_2 \Phi_1 = A_1(A_1^2 + A_2) + A_2 A_1$



Functii de răspuns la impuls: exemplu

Observații

- Răspunsul fiecărei variabile la un soc unitar
- Zonele umbrite = intervale de încredere
- VAR stabil: răspunsurile converg la zero



IRF ortogonalizate

Problema: Erori corelate

- Σ nu este diagonală
 - ▶ řocurile ε_{1t} și ε_{2t} sunt corelate
 - ▶ Un řoc la "Y₁" implică și un řoc la "Y₂"

Soluție: Descompunerea Cholesky

- Factorizare: $\Sigma = PP'$ (P: inferior triunghiulară)
- řouri ortogonalizate: $u_t = P^{-1}\varepsilon_t$ cu $\mathbb{E}[u_t u_t'] = I$
- IRF ortogonalizate: $\Theta_h = \Phi_h P$

Ordinea contează!

- De la "cea mai exogenă" la "cea mai endogenă"
 - ▶ Rezultatele depind de ordinea variabilelor



Descompunerea Cholesky: Cum funcționează

Exemplu numeric

Fie matricea de covarianță a reziduurilor VAR: $\Sigma = \begin{pmatrix} 4 & 2 \\ 2 & 5 \end{pmatrix}$. Factorul Cholesky P (inferior triunghiular) cu $\Sigma = PP'$:

$$P = \begin{pmatrix} 2 & 0 \\ 1 & 2 \end{pmatrix} \quad \Rightarrow \quad PP' = \begin{pmatrix} 2 & 0 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix} = \begin{pmatrix} 4 & 2 \\ 2 & 5 \end{pmatrix} = \Sigma \checkmark$$

Interpretare: Ce implică ordinea

- $P_{21} = 1 \neq 0$: Un soc unitar la Y_1 are **efect imediat asupra Y_2** (impact = 1)
- $P_{12} = 0$: Un soc la Y_2 **nu afectează contemporan** pe Y_1
- Y_1 este “mai exogenă” — afectează Y_2 instantaneu, dar nu și invers

Inversarea ordinii (Y_2 primul)

Schimbarea ordinii variabilelor dă un P diferit și IRF-uri diferite. De aceea **teoria economică** trebuie să ghideze ordinea — ex., PIB înainte de șomaj (legea lui Okun: șocurile de producție afectează piața muncii, nu invers pe termen scurt).



Exemplu numeric IRF

Pentru $A = \begin{pmatrix} 0.7 & 0.2 \\ -0.1 & 0.6 \end{pmatrix}$

Calculul matricelor IRF:

$$\Phi_0 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad \Phi_1 = A = \begin{pmatrix} 0.7 & 0.2 \\ -0.1 & 0.6 \end{pmatrix}, \quad \Phi_2 = A^2 = \begin{pmatrix} 0.47 & 0.26 \\ -0.13 & 0.34 \end{pmatrix}$$

Interpretare

- $[\Phi_2]_{12} = 0.26$: Un soc unitar la Y_2 crește Y_1 cu 0.26 după 2 perioade
- $[\Phi_2]_{21} = -0.13$: Un soc unitar la Y_1 scade Y_2 cu 0.13 după 2 perioade



Răspunsuri la impuls cumulative

Definiție

- IRF cumulativ** până la orizontul H : $\Psi_H = \sum_{h=0}^H \Phi_h$
- Măsoară **efectul total acumulat** al unui şoc

Multiplicatorul pe termen lung

- Pentru VAR stabil: $\Psi_\infty = (I_K - A_1 - A_2 - \dots - A_p)^{-1}$
- Aceasta dă **efectul permanent** al unui şoc punctual

Când să folosim

- IRF cumulative sunt utile când ne interesează impactul total (ex. pierderea cumulată de PIB după un şoc)



Intervale de încredere pentru IRF

Surse de incertitudine

- IRF sunt funcții de parametrii estimați $\hat{A}_1, \dots, \hat{A}_p$, deci au **incertitudine de eșantionare**

Metode pentru benzi de încredere

- Asimptotice:** Folosim metoda delta pentru a deriva erorile standard
- Monte Carlo:** Simulăm din distribuția asimptotică a lui \hat{A}
- Bootstrap:** Reesantionăm reziduurile și reestimăm VAR

Procedura Bootstrap

- Estimăm VAR, salvăm reziduurile $\{\hat{\epsilon}_t\}$
- Extragem cu înlocuire pentru a crea $\{\hat{\epsilon}_t^*\}$
- Generăm eșantion bootstrap folosind VAR estimat
- Reestimăm și calculăm IRF
- Repetăm de B ori; folosim percentilele pentru IC



VAR structural (SVAR)

Motivație

- řocurile VAR standard ε_t sunt inovații de formă redusă \succ combinații liniare de řocuri structurale
- Vrem să identificăm řocuri structurale semnificative economic

Forma structurală

- Modelul structural:

$$B_0 Y_t = \Gamma_0 + B_1 Y_{t-1} + \cdots + B_p Y_{t-p} + u_t$$

- u_t sunt řocuri structurale cu $\mathbb{E}[u_t u_t'] = I_K$

Relația cu forma redusă

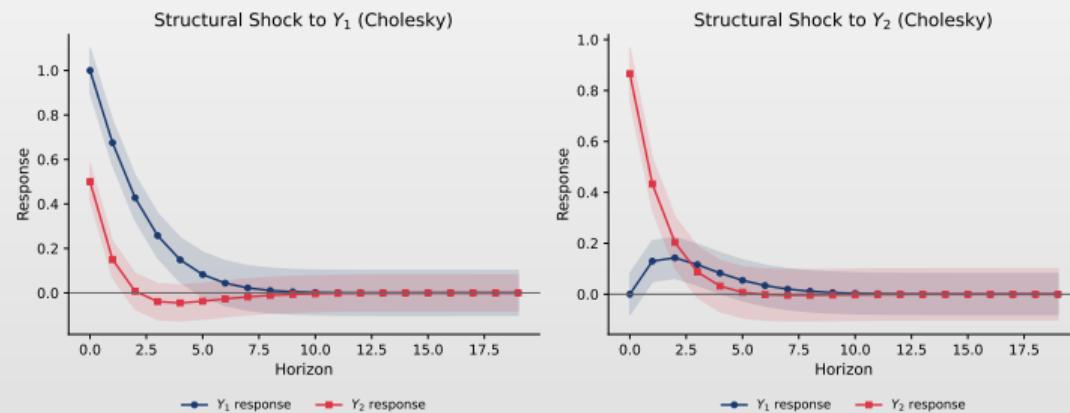
- $\varepsilon_t = B_0^{-1} u_t \quad \succ \quad \Sigma = B_0^{-1} (B_0^{-1})'$



Exemplu IRF structural

Observații

- IRF structurale (Cholesky) — ordinea variabilelor afectează interpretarea
- Restricții contemporane: prima variabilă reacționează doar la propriile șocuri



Q TSA_ch6_structural_irf



Identificare în SVAR

Problema identificării

- Σ are $K(K + 1)/2$ elemente unice, dar B_0^{-1} are K^2 elemente
- Avem nevoie de $K(K - 1)/2$ restricții suplimentare!

Scheme comune de identificare

- 1. Restricții pe termen scurt:** Efecte de impact zero (Cholesky)
- 2. Restricții pe termen lung:** Efecte zero pe termen lung (Blanchard-Quah)
- 3. Restricții de semn:** Constrângeri de inegalitate pe IRF
- 4. Instrumente externe:** Folosim informații din afară

Exemplu: Ordonare Cholesky (recursivă)

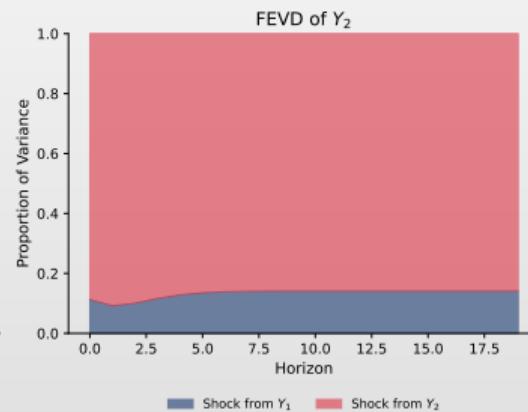
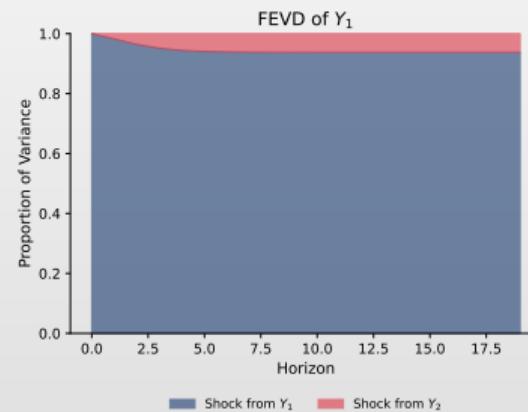
- Pentru $K = 2$: $B_0^{-1} = \begin{pmatrix} b_{11} & 0 \\ b_{21} & b_{22} \end{pmatrix}$
- Variabila 1 nu răspunde la şocul 2 contemporan



FEVD: Exemplu

Observații

- Proporția varianței prognozei atribuibilă fiecărui șoc structural
- Dinamica temporală: orizonturi scurte — șocuri proprii domină; efectele încrucișate cresc în timp



Q TSA_ch6_fevd



Descompunerea varianței

Întrebare

- Ce proporție din varianța erorii de prognoză a lui Y_i la orizontul h se datorează șocurilor la Y_j ?

Formula FEVD

$$\text{FEVD}_{ij}(h) = \frac{\sum_{s=0}^{h-1} [\Theta_s]_{ij}^2}{\sum_{s=0}^{h-1} \sum_{k=1}^K [\Theta_s]_{ik}^2}$$

- Dă **procentul** din varianța prognozei la h pași a lui Y_i explicat de șocurile la Y_j

Proprietăți

- $0 \leq \text{FEVD}_{ij}(h) \leq 1$
- $\sum_{j=1}^K \text{FEVD}_{ij}(h) = 1$ (suma la 100%)
- La $h = 1$: Șocurile proprii domină (prin construcția Cholesky)



FEVD: Exemplu numeric

Calculul FEVD pentru VAR bivariat

- Folosind IRF ortogonalizate Θ_h , FEVD la orizontul H :

$$\text{FEVD}_{11}(H) = \frac{\sum_{h=0}^{H-1} \theta_{11}^2(h)}{\sum_{h=0}^{H-1} [\theta_{11}^2(h) + \theta_{12}^2(h)]}$$

Exemplu de calcul

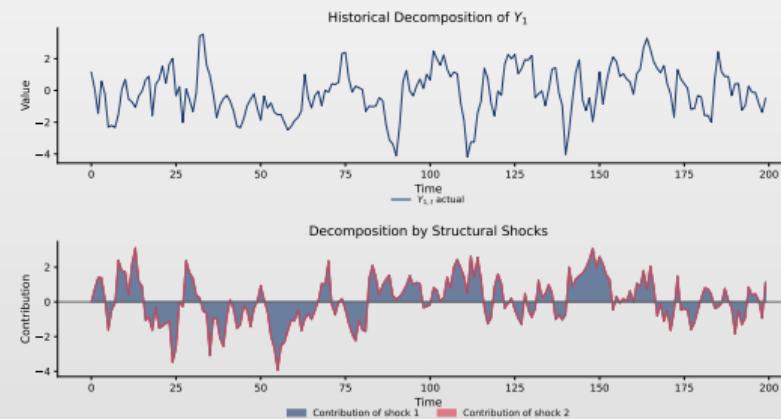
h	$\theta_{11}(h)$	$\theta_{12}(h)$	$\theta_{11}^2(h)$	$\theta_{12}^2(h)$
0	1.00	0.00	1.00	0.00
1	0.70	0.20	0.49	0.04
2	0.47	0.26	0.22	0.07

- $\text{FEVD}_{11}(3) = \frac{1.00+0.49+0.22}{1.00+0.49+0.22+0.00+0.04+0.07} = \frac{1.71}{1.82} = 94\%$

Descompunerea istorică: Exemplu

Observații

- Contribuții structurale: fiecare culoare = un soc diferit, stivuite însumează abaterea de la medie
- Utilitate: identifică șocurile din episoadele istorice



TSA_ch6_historical_decomp



Descompunerea istorică

Definiție

- Descompunerea istorică descompune fiecare valoare observată în contribuții de la fiecare șoc structural:

$$Y_{it} - \bar{Y}_i = \sum_{j=1}^K \sum_{s=0}^{t-1} \theta_{ij}(s) \cdot u_{j,t-s}$$

Aplicație

- "Cât din scăderea PIB din 2008 s-a datorat șocurilor financiare vs. șocurilor petroliere?"
 - ▶ Atribuie mișcările istorice unor șocuri identificate specifice
 - ▶ Util pentru analiza politicilor și interpretarea narativă



Diagnosticarea reziduurilor

Ce trebuie verificat

- După estimarea VAR, verificăm că reziduurile $\hat{\epsilon}_t$ se comportă ca zgomot alb:
 - ▶ Fără corelație serială
 - ▶ Varianță constantă (homoscedasticitate)
 - ▶ Normalitate (pentru inferență)

De ce contează

- Reziduuri autocorelate \succ estimări ineficiente
- Heteroscedasticitate \succ erori standard invalide
- Non-normalitate \succ inferența poate fi nesigură



Testarea corelației seriale

Testul Portmanteau (Ljung-Box)

Statistica de test: $Q_h = T(T+2) \sum_{j=1}^h \frac{1}{T-j} \text{tr}(\hat{C}_j' \hat{C}_0^{-1} \hat{C}_j \hat{C}_0^{-1})$

$\hat{C}_j = \frac{1}{T} \sum_{t=j+1}^T \hat{\epsilon}_t \hat{\epsilon}'_{t-j}$. Sub H_0 : $Q_h \sim \chi^2_{K^2(h-p)}$

Testul LM Breusch-Godfrey

Regresăm $\hat{\epsilon}_t$ pe $\hat{\epsilon}_{t-1}, \dots, \hat{\epsilon}_{t-h}$ și regresorii originali. $LM = T \cdot R^2 \sim \chi^2_{K^2 h}$ sub H_0 .

Dacă este respins

Creșterea ordinului lag-ului p sau adăugarea de variabile suplimentare.



Testarea heteroscedasticității

Testul ARCH-LM

- Testează pentru heteroscedasticitate condiționată autoregresivă:

$$\hat{\varepsilon}_{it}^2 = \alpha_0 + \alpha_1 \hat{\varepsilon}_{i,t-1}^2 + \dots + \alpha_q \hat{\varepsilon}_{i,t-q}^2 + v_t$$

- $H_0: \alpha_1 = \dots = \alpha_q = 0$ (homoscedasticitate)
- $LM = TR^2 \sim \chi_q^2$

Versiunea multivariată

- Testăm toate ecuațiile împreună folosind:

$$\text{vech}(\hat{\varepsilon}_t \hat{\varepsilon}_t') = c + \sum_{j=1}^q B_j \text{vech}(\hat{\varepsilon}_{t-j} \hat{\varepsilon}'_{t-j}) + v_t$$

Testarea normalității

Testul Jarque-Bera (univariat)

$$JB = \frac{T}{6} \left(S^2 + \frac{(K - 3)^2}{4} \right) \sim \chi_2^2$$

unde S = asimetrie, K = curtoză

Normalitate multivariată (Doornik-Hansen)

- Transformăm reziduurile și testăm asimetria și curtoza comune:

$$DH = s_1'(\Omega^{-1/2})'(\Omega^{-1/2})s_1 + s_2'(\Omega^{-1/2})'(\Omega^{-1/2})s_2 \sim \chi_{2K}^2$$

Notă

Normalitatea este adesea respinsă în datele financiare. Luați în considerare erori standard robuste dacă non-normalitatea este severă.

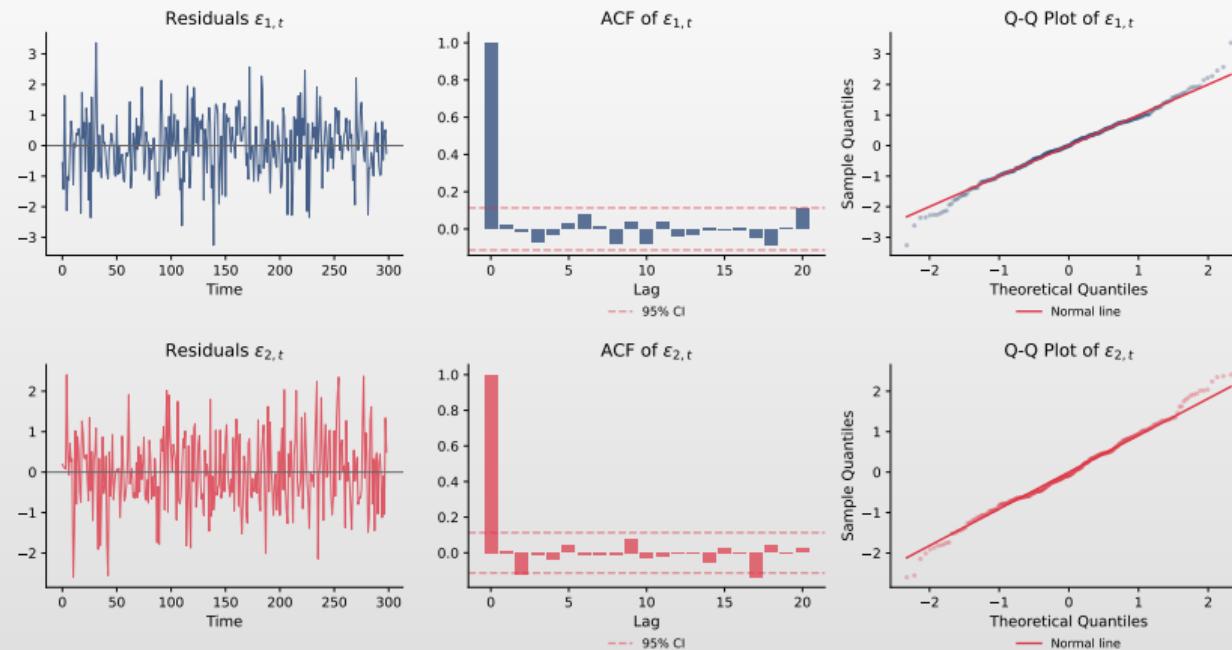


Grafic rezumat diagnostic

- ACF reziduurilor nu prezintă autocorelație semnificativă
- Histograma aproximează distribuția normală
- Q-Q plot urmează linia de 45°



Grafic rezumat diagnostic



Prognoze punctuale din VAR

Prognoză iterativă

- Pentru VAR(1): $Y_t = c + AY_{t-1} + \varepsilon_t$
- Prognoză la 1 pas:** $\hat{Y}_{T+1|T} = c + AY_T$
- Prognoză la 2 pași:** $\hat{Y}_{T+2|T} = c + A\hat{Y}_{T+1|T}$
- Prognoză la h pași:** $\hat{Y}_{T+h|T} = c + A\hat{Y}_{T+h-1|T}$

Formula directă

- $\hat{Y}_{T+h|T} = (I + A + A^2 + \dots + A^{h-1})c + A^h Y_T$
- Pentru VAR stabil: converge la $\mu = (I - A)^{-1}c$ când $h \rightarrow \infty$



Eroarea de prognoză și MSE

Eroarea de prognoză la h pași

$$\mathbf{e}_{T+h|T} = \mathbf{Y}_{T+h} - \hat{\mathbf{Y}}_{T+h|T} = \sum_{j=0}^{h-1} \mathbf{A}^j \boldsymbol{\varepsilon}_{T+h-j}$$

Matricea erorii medii pătratice

$$\text{MSE}(\hat{\mathbf{Y}}_{T+h|T}) = \mathbb{E}[\mathbf{e}_{T+h|T} \mathbf{e}'_{T+h|T}] = \sum_{j=0}^{h-1} \mathbf{A}^j \boldsymbol{\Sigma} (\mathbf{A}^j)'$$

Ideea cheie

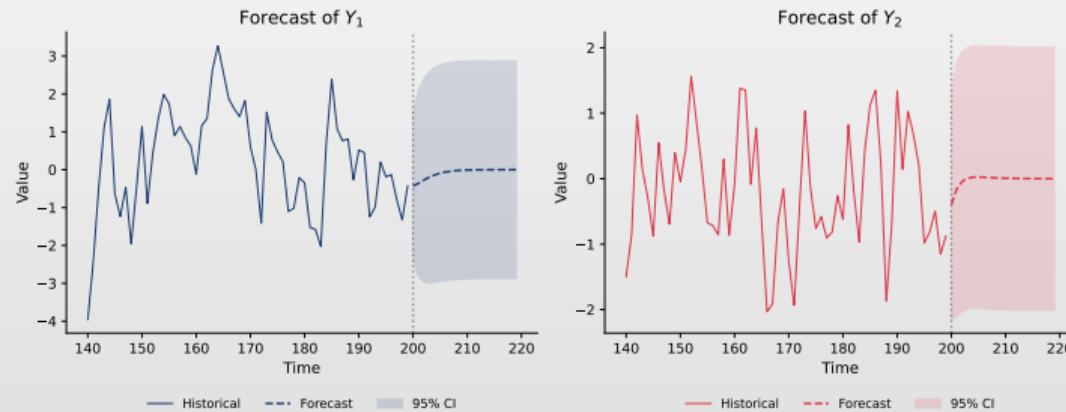
- MSE crește cu orizontul h
- Pentru VAR stabil: MSE converge la varianța necondiționată $\boldsymbol{\Gamma}(0)$
- Prognoze pe termen lung \succcurlyeq media necondiționată cu incertitudine $= \boldsymbol{\Gamma}(0)$



Prognoze VAR: Exemplu

Observații

- Prognoze punctuale: linie continuă dincolo de date, converg la media necondiționată
- Intervale de încredere: se largesc cu orizontul de prognoză



Q TSA_ch6_var_forecast



Intervale de încredere pentru prognoză

Construirea intervalelor

- Pentru erori distribuite normal, IC $(1 - \alpha)$: $\hat{Y}_{i,T+h|T} \pm z_{\alpha/2} \sqrt{[\text{MSE}(\hat{Y}_{T+h|T})]_{ii}}$

Regiuni de încredere comune

- Pentru mai multe variabile, folosim elipsoizi:

$$(Y_{T+h} - \hat{Y}_{T+h|T})' [\text{MSE}(\hat{Y}_{T+h|T})]^{-1} (Y_{T+h} - \hat{Y}_{T+h|T}) \leq \chi^2_{K,\alpha}$$

Notă

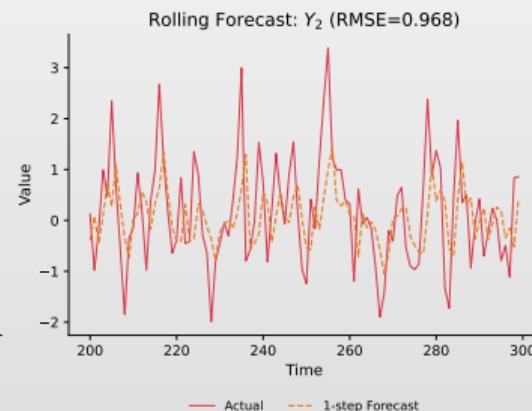
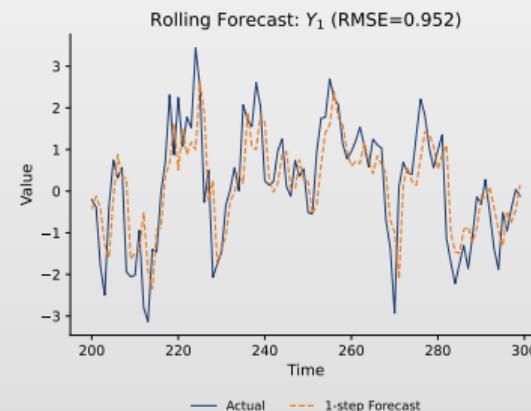
- Acestea presupun parametri cunoscuți
- Metodele bootstrap țin cont de incertitudinea parametrilor



Evaluare out-of-sample: VAR vs. AR

Metodologie generală

- Train / Test Split: împărțim datele antrenare + test; estimăm pe train, evaluăm pe test
- De ce VAR vs. AR? AR ignoră celelalte variabile; VAR exploatează interdependențele
- Metrică: RMSE = $\sqrt{\frac{1}{h} \sum e_i^2}$



Evaluarea prognozei

Evaluare out-of-sample

Împărțim datele: eșantion de estimare (1 la T_1) și eșantion de testare ($T_1 + 1$ la T). Erorile de prognoză:

$$e_{t+h} = Y_{t+h} - \hat{Y}_{t+h|t}$$

Metrici comune

RMSE: $\sqrt{\frac{1}{n} \sum e_{t+h}^2}$ MAE: $\frac{1}{n} \sum |e_{t+h}|$ MAPE: $\frac{100}{n} \sum \left| \frac{e_{t+h}}{Y_{t+h}} \right|$

Testul Diebold-Mariano

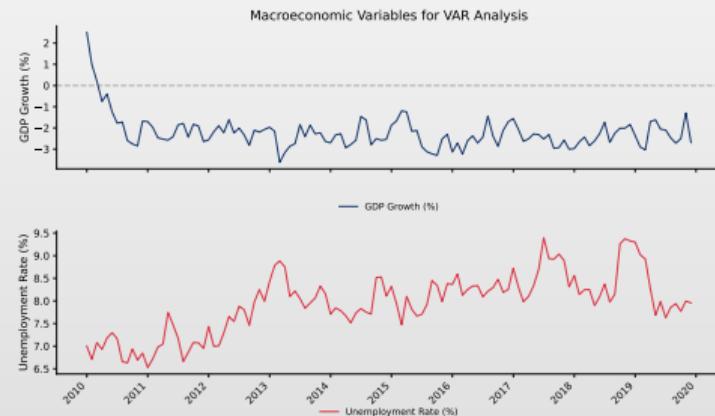
Testează dacă prognozele VAR sunt semnificativ mai bune decât alternativa: $DM = \frac{\bar{d}}{\sqrt{\hat{\sigma}_d^2/n}} \sim N(0, 1)$ unde
 $d_t = L(e_{1t}) - L(e_{2t})$



PIB și șomaj: Date trimestriale

Observații

- Creșterea PIB și rata șomajului: Legea lui Okun, tipare ciclice comune
- Sistem bivariat ideal pentru analiză VAR + cauzalitate Granger



Q TSA_ch6_gdp_unemployment



Exemplu: PIB și șomaj

Legea lui Okun

- Există o relație negativă între creșterea PIB și șomaj:

$$\Delta U_t \approx -\beta(\Delta Y_t - \bar{g})$$

- \bar{g} = creșterea tendențială a PIB, $\beta \approx 0.4$

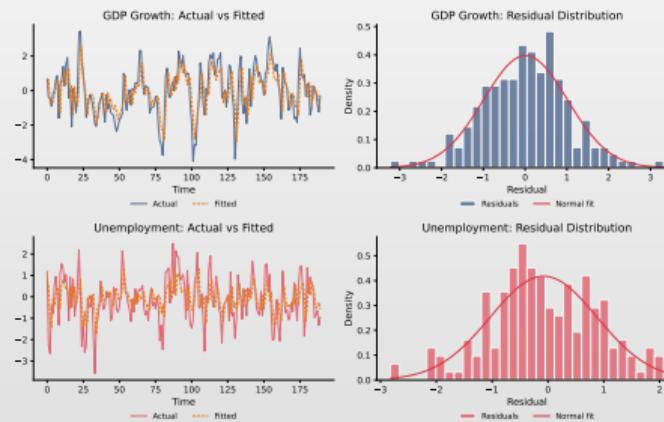
Întrebări pentru analiza VAR

- Cauzează creșterea PIB Granger modificările șomajului?
- Cauzează șomajul Granger creșterea PIB?
- Cum se propagă șocurile între variabile?

Rezultate VAR estimate

Observații

- Coeficienți estimați cu erori standard și statistici t
- Selectia modelului: criterii informaționale (AIC, BIC) și diagnostic reziduuri



Q TSA_ch6_var_results



Fluxul de lucru VAR

Etapele analizei VAR

1. **Pregătirea datelor:** Verificăm staționaritatea (teste de rădăcină unitară); transformăm dacă este necesar (diferențe, logaritmi)
2. **Selecția lag-ului:** Folosim criteriile AIC, BIC, HQ; verificăm autocorelația reziduurilor
3. **Estimare:** OLS ecuație cu ecuație; verificăm stabilitatea (valori proprii)
4. **Analiză:** Teste de cauzalitate Granger; funcții de răspuns la impuls; descompunerea varianței
5. **Prognoză:** Prognoze punctuale și intervale de încredere



Rezultate cauzalitate Granger

Rezultatele testului: PIB și șomaj

Ipoteza nulă	Statistica F	df	p-valoare	Decizie
PIB $\not\rightarrow$ Șomaj	8.42	(2, 95)	0.0004	Respingem
Șomaj $\not\rightarrow$ PIB	2.15	(2, 95)	0.1220	Nu respingem

Interpretare

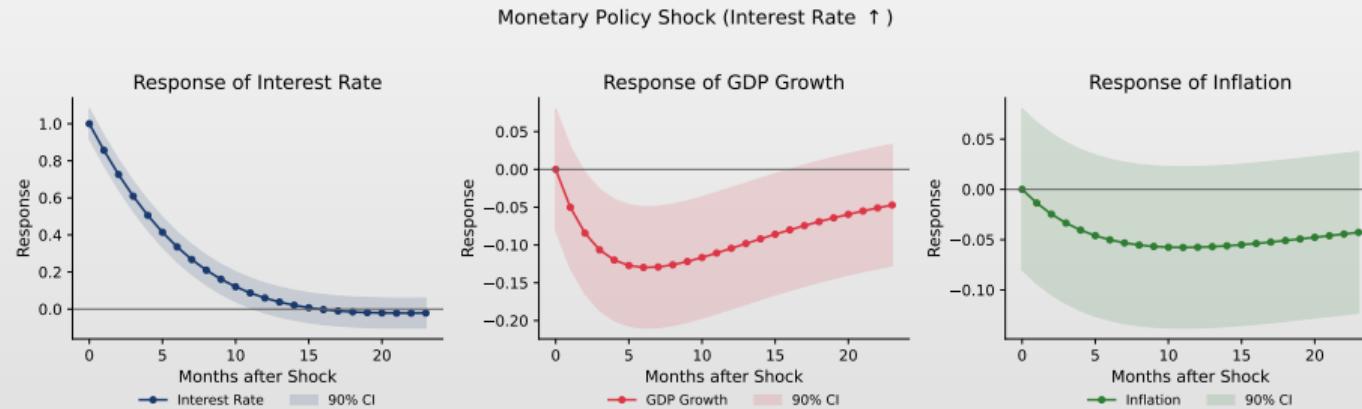
- Creșterea PIB cauzează Granger șomajul (în acord cu Legea lui Okun)
- Șomajul nu cauzează semnificativ Granger PIB (în acest eșantion)
- Pe date reale, cauzalitatea poate fi **bidirecțională** (a se vedea studiul de caz)



VAR politică monetară: IRF

Observații

- ☐ Soc monetar contractionist: creșterea ratei dobânzii
- ☐ Răspunsul variabilelor: producția — efect maxim la 4–6 trim.; inflația — răspuns mai lent



Q TSA_ch6_monetary_irf



Exemplu: Analiza politicii monetare

VAR cu trei variabile

- Studiem mecanismul de transmisie monetară cu:
 - ▶ Y_1 : Gap-ul de producție (devierea PIB de la trend)
 - ▶ Y_2 : Rata inflației
 - ▶ Y_3 : Rata dobânzii (instrument de politică)

Întrebări cheie

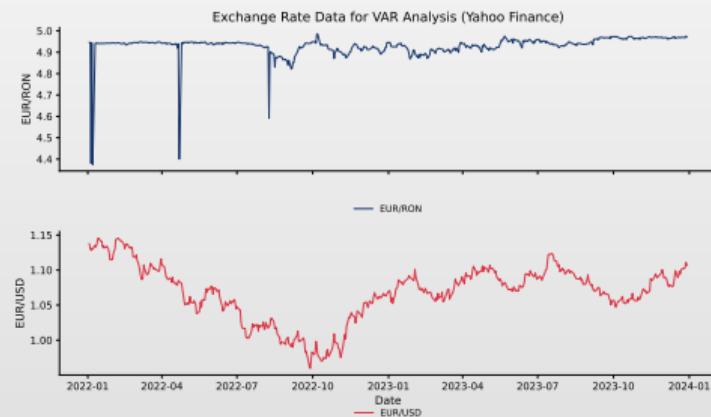
1. Cum afectează un soc al ratei dobânzii producția și inflația?
2. Cât timp trece până se simte efectul maxim?
3. Ce fracțiune din varianța producției se datorează șocurilor monetare?



Studiu de caz: Relația dintre PIB și șomaj

Date

- Date reale SUA (FRED, 1990–2024): Creștere PIB și Rata Șomajului ($T = 140$ trimestre)
- Corelație negativă vizibilă între serii (Legea lui Okun); dinamică bidirecțională



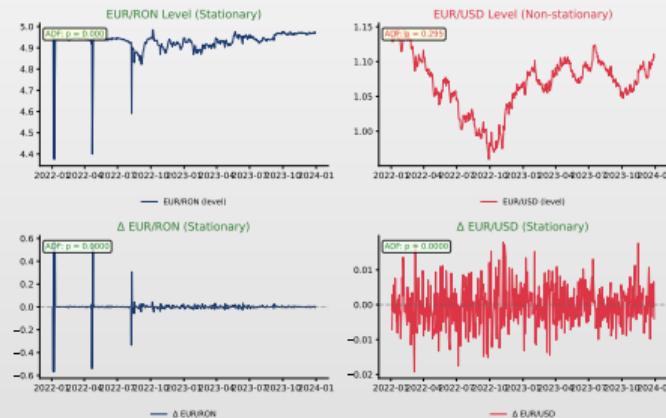
Q TSA_ch6_case_raw_data



Pasul 1: Analiză preliminară

Rezultate

- PIB: ACF scade rapid \succ staționar; Șomaj: ACF persistent (ADF: $p = 0.02$)
- Corelație negativă PIB–Șomaj ($\rho = -0.17$); cross-corelație sugerează relații bidirecționale



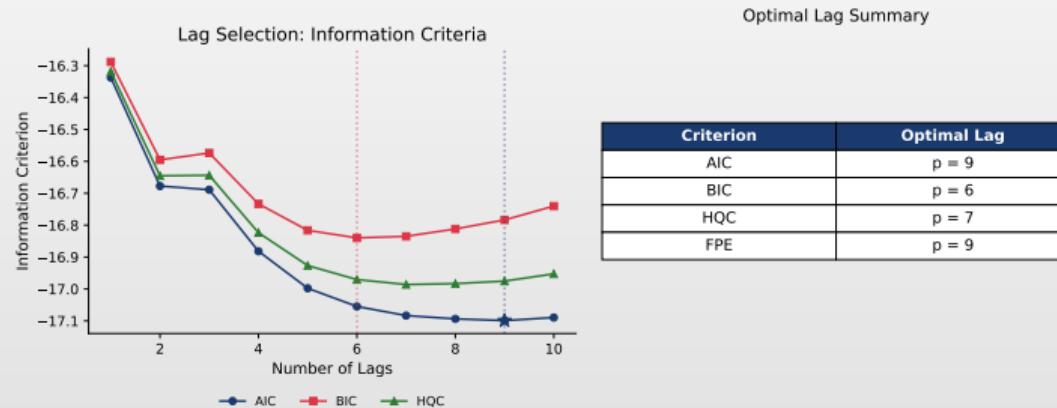
Q TSA_ch6_case_stationarity



Pasul 2: Selecția ordinului VAR

Rezultate

- Criteriile AIC și BIC sugerează VAR(2); compromis între complexitate și ajustare

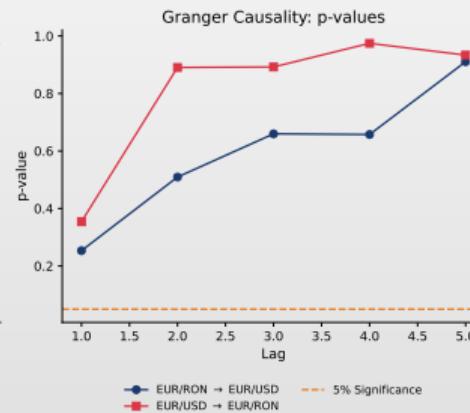
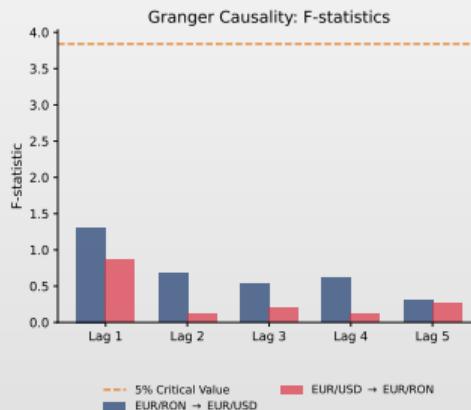


Q TSA_ch6_case_lag_selection

Pasul 3: Testul Granger de cauzalitate

Rezultate

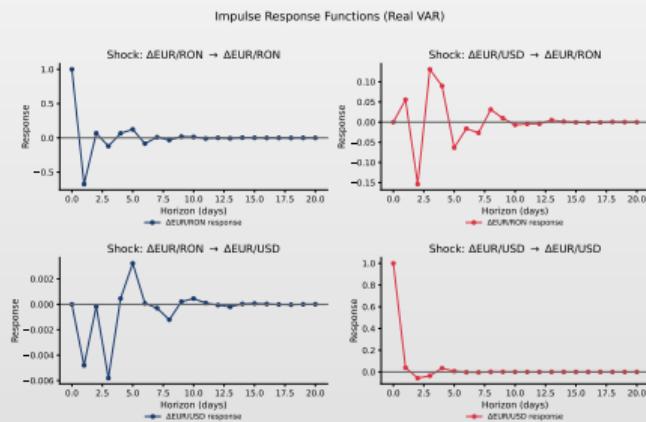
- ◻ PIB \succ Șomaj: $F = 17.35, p < 0.001 \succ$ PIB "cauzează Granger" Șomajul
- ◻ Șomaj \succ PIB: $F = 38.93, p < 0.001 \succ$ cauzalitate bidirecțională (Legea lui Okun)



Pasul 4: Funcții de răspuns la impuls (IRF)

Rezultate IRF

- ◻ řoc PIB ř efect negativ persistent asupra șomajului (Legea lui Okun, >20 trim.)
- ◻ řoc Șomaj ř efect pozitiv de scurtă durată asupra PIB (recuperare, 2–3 trim.)



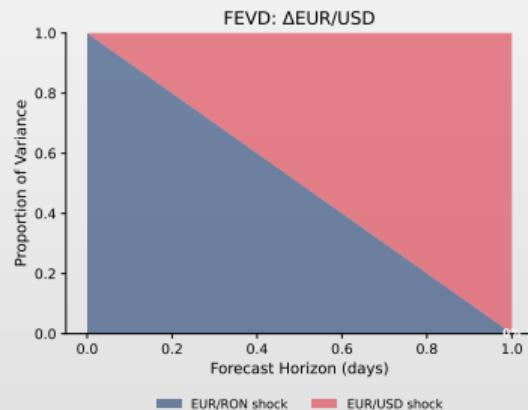
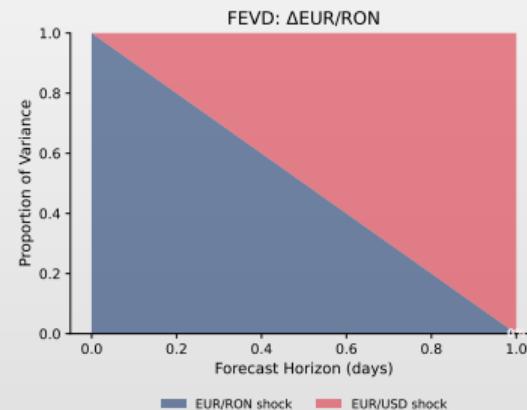
TSA_ch6_case_irf



Pasul 5: Descompunerea varianței (FEVD)

Rezultate FEVD

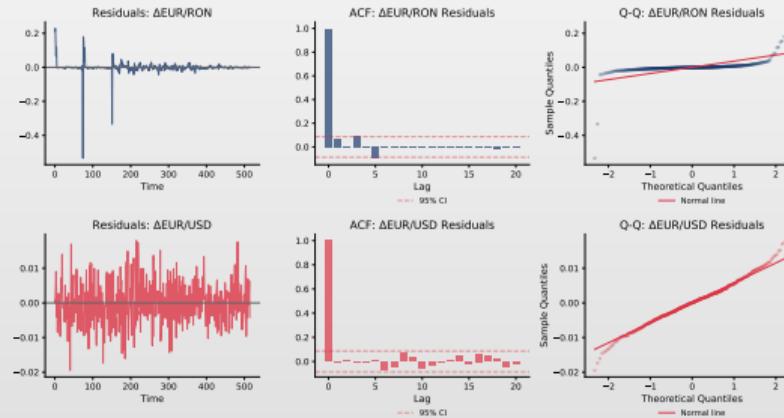
- PIB: ~65% din varianță explicată de propriile șocuri, ~35% de șocurile Șomaj
- Șomaj: dominat de șocurile PIB (~65% la $h = 1$, crescând la ~92% la $h = 20$)



Pasul 6: Diagnosticarea reziduurilor

Diagnostic

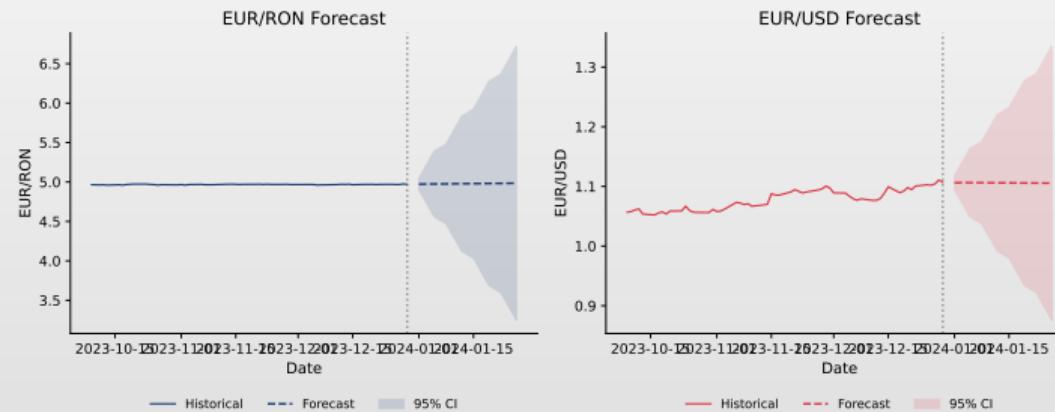
- Reziduurile nu prezintă autocorelație semnificativă (ACF în limite)
- Non-normalitate semnificativă (JB respins) > datorită valorilor extreme COVID-19



Pasul 7: Prognoza VAR

Rezultate prognoză

- ◻ Prognoză pe 12 trimestre; VAR captează interdependențele dintre serii
- ◻ Prognozele converg spre valorile de echilibru pe termen lung



Q TSA_ch6_case_forecast



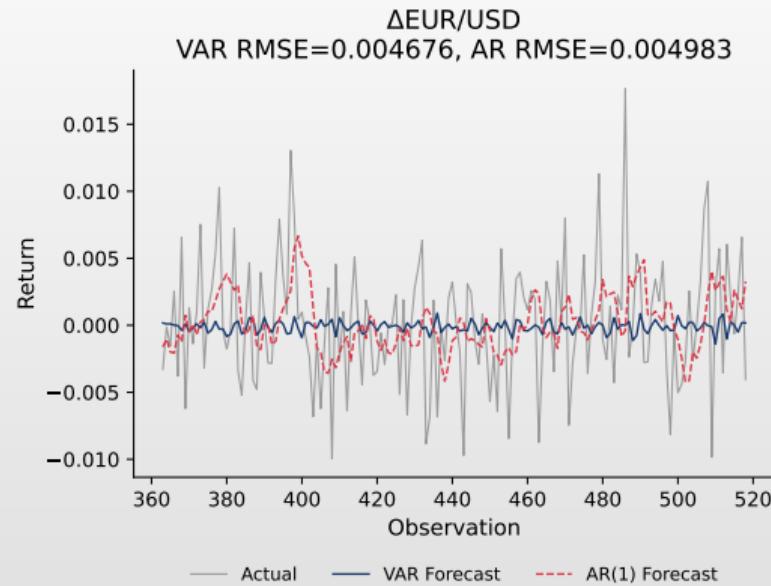
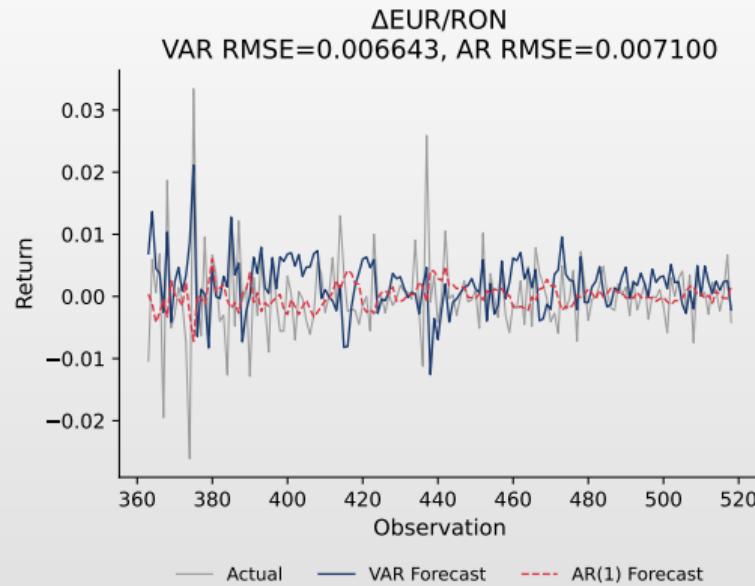
Pasul 8: Rolling forecast – VAR vs AR

Procedura

- Train/Test recursiv: $W = 80$, re-estimare la fiecare pas; modele AR(2) vs VAR(2)
- RMSE expanding: $\text{RMSE}_t = \sqrt{\frac{1}{t} \sum_{s=1}^t e_s^2}$; intervale de încredere 95%
- Rezultate mixte:
 - ▶ Șomaj — VAR -10% RMSE față de AR (informația din PIB ajută)
 - ▶ PIB — VAR +6% RMSE față de AR (informația din șomaj nu aduce beneficii)



Pasul 8: Rolling forecast – VAR vs AR



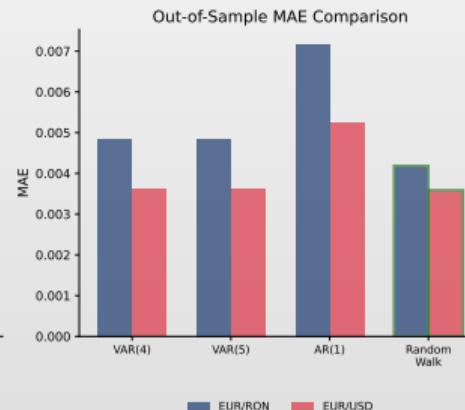
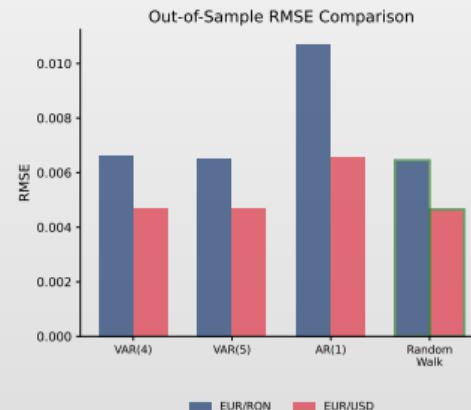
 TSA_ch6_case_rolling_forecast



Pasul 9: Comparație out-of-sample – AR vs VAR

Metodologie

- Prognoză recursivă: estimare pe $[1, \dots, t]$, prognoză $\hat{y}_{t+1|t}$
- RMSE: $RMSE_t = \sqrt{\frac{1}{t} \sum_{s=1}^t e_s^2}$
- VAR reduce RMSE pentru Șomaj ($\sim 10\%$), nu și pentru PIB



Exercițiu AI: Gândire critică

Prompt de testat în ChatGPT / Claude / Copilot

"Descarcă de pe FRED: rata trimestrială de creștere a PIB real SUA (A191RL1Q225SBEA) și rata lunară a șomajului (UNRATE, agregată trimestrial) din 2000-Q1 până în 2024-Q4 (100 observații). Testează cauzalitatea Granger în ambele direcții, estimează un model VAR și calculează funcțiile impuls-răspuns ortogonalizate. Vreau cod Python complet."

Exercițiu:

1. Rulați prompt-ul într-un LLM la alegere și analizați critic răspunsul.
2. Testează staționaritatea fiecărei variabile înainte de a estima VAR?
3. Cum selectează ordinul lag-urilor? Compară AIC, BIC, HQIC?
4. Funcțiile impuls-răspuns sunt ortogonalizate? Discută ordonarea Cholesky?
5. Verifică condiția de stabilitate (valorile proprii în interiorul cercului unitate)?

Atenție: Codul generat de AI poate rula fără erori și arăta profesional. *Asta nu înseamnă că e corect.*



Concluzii cheie

Modele VAR

- Modeleză **mai multe** serii de timp împreună
- Fiecare variabilă depinde de propriile lag-uri și lagurile altor variabile
- Estimate prin OLS ecuație cu ecuație; necesită staționaritate

Cauzalitate Granger

- Testează dacă X ajută la prezicerea lui Y dincolo de istoricul propriu al lui Y
- Nu** este la fel cu cauzalitatea reală; test F asupra restricțiilor coeficientilor

IRF și FEVD

- IRF: Cum se propagă şocurile prin sistem
- FEVD: Ce proporție din varianță se datorează fiecărui şoc
- Ambele depind de ordonarea variabilelor (descompunerea Cholesky)



Lista de verificare pentru selecția modelului VAR

Înainte de estimare

- Testați pentru rădăcini unitare în fiecare variabilă
- Aduceți seria la forma stationară dacă este necesar (diferențe, logaritmi)
- Verificați pentru valori extreme și rupturi structurale

Specificarea modelului

- Selectați ordinul lag-ului folosind AIC/BIC
- Estimați VAR prin OLS
- Verificați stabilitatea (valori proprii în interiorul cercului unitate)

După estimare

- Testați reziduurile pentru autocorelație
- Testați pentru efecte ARCH
- Testați pentru normalitate
- Calculați IRF, FEVD, teste Granger



Greșeli comune de evitat

Capcane în analiza VAR

- 1. Ignorarea nestaționarității:** Testați întotdeauna mai întâi pentru rădăcini unitare
- 2. Supraajustare:** Prea multe lag-uri \succ prognoze slabe
- 3. Ordonare greșită:** Rezultatele Cholesky depind de ordinea variabilelor
- 4. Confundarea corelației cu cauzalitatea:** Cauzalitate Granger \neq cauzalitate reală
- 5. Ignorarea incertitudinii parametrilor:** Folosiți IC bootstrap pentru IRF
- 6. Eșantioane mici:** VAR necesită multe observații ($T > 50$)



Ce urmează?

Subiecte pentru studiu aprofundat

- Cointegrare:** Relații pe termen lung între variabile nestaționare
- VECM:** Modele cu corecția erorii pentru sisteme cointegrate
- VAR Structural:** Impunerea restricțiilor din teoria economică
- Panel VAR:** VAR pentru date panel
- VAR Bayesian:** Distribuții prior de shrinkage pentru sisteme de dimensiuni mari

Întrebări?



Întrebarea 1

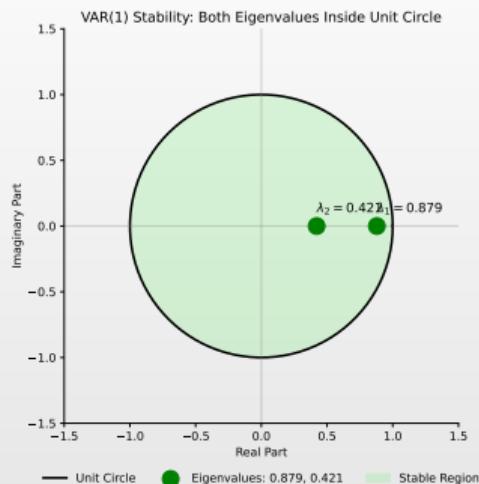
Întrebare

- Pentru un model VAR(1) cu matricea de coeficienți $A = \begin{pmatrix} 0.8 & 0.3 \\ 0.1 & 0.5 \end{pmatrix}$, este modelul stabil?

Variante de răspuns

- (A) Da, deoarece toate elementele diagonale sunt mai mici decât 1
- (B) Da, deoarece toate valorile proprii sunt în interiorul cercului unitate
- (C) Nu, deoarece suma coeficienților depășește 1
- (D) Nu poate fi determinat fără a cunoaște Σ

Întrebarea 1: Răspuns



Răspuns: (B)

- $\lambda_1 = 0.879, \lambda_2 = 0.421 \succ$ ambele $|\lambda| < 1 \succ$ stabil!

Q TSA_ch6_quiz1_var_stability



Întrebarea 2

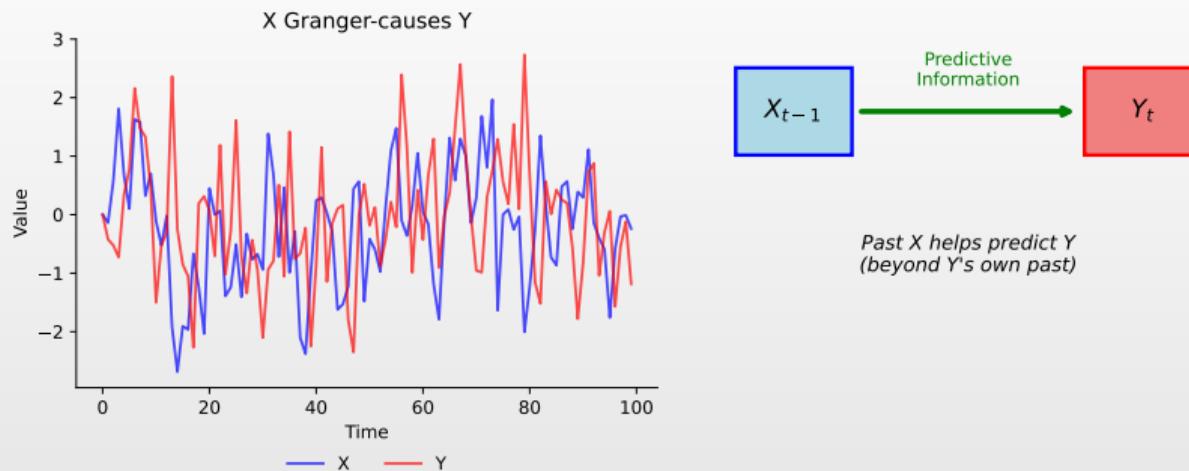
Întrebare

- Dacă X cauzează Granger pe Y la nivelul de semnificație de 5%, care dintre următoarele afirmații este ADEVĂRATĂ?

Variante de răspuns

- (A) X este cauza economică a lui Y
- (B) Valorile trecute ale lui X conțin informații utile pentru prezicerea lui Y
- (C) Y nu poate cauza Granger pe X
- (D) Corelația între X și Y este pozitivă

Întrebarea 2: Răspuns



Răspuns: (B)

- Cauzalitate Granger = conținut predictiv, nu cauzare economică reală
- X trecut ajută la prezicerea lui Y



Întrebarea 3

Întrebare

Într-un VAR cu IRF identificate Cholesky, ce determină ordinea variabilelor?

Variante de răspuns

- (A) Magnitudinea răspunsurilor la impuls
- (B) Viteza cu care şocurile dispara
- (C) Care variabile pot răspunde contemporan la care şocuri
- (D) Numărul de lag-uri în VAR



Întrebarea 3: Răspuns

Ordering: (GDP, Interest Rate)



GDP shock → IR responds at t=0
IR shock → GDP responds at t=1

Ordering: (Interest Rate, GDP)



IR shock → GDP responds at t=0
GDP shock → IR responds at t=1

Răspuns: (C)

- Ordonarea determină care variabile răspund imediat la care șocuri

 TSA_ch6_quiz3_cholesky_ordering



Întrebarea 4

Întrebare

- Pentru un VAR(1) bivariat, câți parametri trebuie estimați (excluzând matricea de covarianță a erorilor)?

Variante de răspuns

(A) 4

(B) 6

(C) 8

(D) 10



Întrebarea 4: Răspuns

Răspuns: (B)

- $K + K^2 = 2 + 4 = 6$ parametri (vezi detalii mai jos)

Numărare detaliată

- VAR(1) cu $K = 2$ variabile:

$$\begin{pmatrix} Y_{1t} \\ Y_{2t} \end{pmatrix} = \underbrace{\begin{pmatrix} c_1 \\ c_2 \end{pmatrix}}_{2 \text{ param}} + \underbrace{\begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}}_{4 \text{ param}} \begin{pmatrix} Y_{1,t-1} \\ Y_{2,t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

- Constant c: $K = 2$; matrice A: $K^2 = 4$; total: 6 parametri

Formula generală

- VAR(p) cu K variabile: $K + pK^2$ parametri (excluzând Σ)



Întrebarea 5

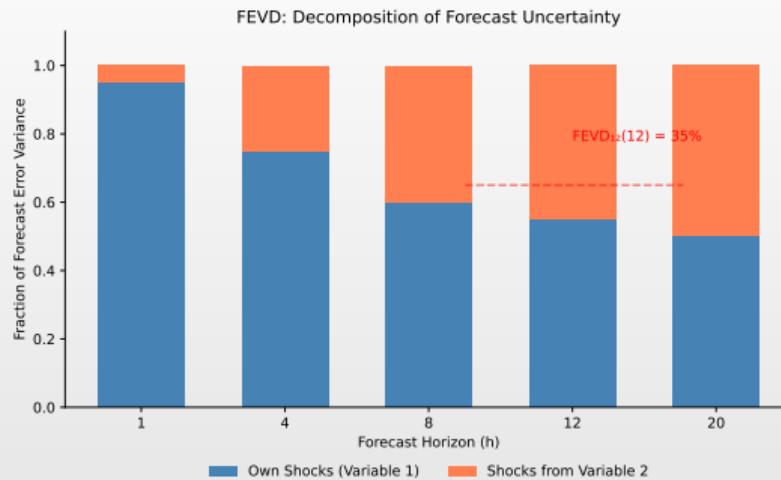
Întrebare

- Ce înseamnă $\text{FEVD}_{12}(h) = 0.35$?

Variante de răspuns

- (A)** 35% din varianța totală a variabilei 1 este explicată de variabila 2
- (B)** 35% din varianța erorii de prognoză la h pași a variabilei 1 se datorează șocurilor la variabila 2
- (C)** Corelația între variabilele 1 și 2 la lag-ul h este 0.35
- (D)** Variabila 2 explică 35% din răspunsul la impuls al variabilei 1

Întrebarea 5: Răspuns



Răspuns: (B)

- 35% din varianța erorii de prognoză la h pași a variabilei 1 se datorează șocurilor de la variabila 2

Formule cheie – Rezumat

Model VAR(p)

- $Y_t = c + \sum_{i=1}^p A_i Y_{t-i} + \epsilon_t$
- $\epsilon_t \sim \mathcal{N}(0, \Sigma)$, i.i.d.

Cauzalitate Granger

- H_0 : X nu cauzează Granger Y
- Test F sau Wald pe coeficienții lag-urilor lui X

Selecția lag-urilor

- $AIC = \ln |\hat{\Sigma}| + \frac{2pK^2}{T}$
- $BIC = \ln |\hat{\Sigma}| + \frac{pK^2 \ln T}{T}$

Funcții răspuns la impuls

- $Y_{t+h} = \sum_{i=0}^{\infty} \Phi_i \epsilon_{t+h-i}$
- Φ_i = multiplicatori la orizontul i

FEVD

- $FEVD_{jk}(h) = \frac{\sum_{i=0}^{h-1} (\epsilon_j' \Phi_i \Phi e_k)^2}{\sum_{i=0}^{h-1} \epsilon_j' \Phi_i \Sigma \Phi_i' \epsilon_j}$
- Contribuția şocului k la varianța lui j

Staționaritate VAR

- Toate valorile proprii ale A în interiorul cercului unitate

Bibliografie I

Lucrări fundamentale VAR și cauzalitate

- Sims, C.A. (1980). Macroeconomics and Reality, *Econometrica*, 48(1), 1–48.
- Granger, C.W.J. (1969). Investigating Causal Relations by Econometric Models and Cross-Spectral Methods, *Econometrica*, 37(3), 424–438.
- Toda, H.Y., & Yamamoto, T. (1995). Statistical Inference in Vector Autoregressions with Possibly Integrated Processes, *Journal of Econometrics*, 66(1-2), 225–250.

Manuale VAR

- Lütkepohl, H. (2005). *New Introduction to Multiple Time Series Analysis*, Springer.
- Kilian, L., & Lütkepohl, H. (2017). *Structural Vector Autoregressive Analysis*, Cambridge University Press.

Bibliografie II

Funcții impuls-răspuns și descompunere varianță

- Pesaran, H.H., & Shin, Y. (1998). Generalized Impulse Response Analysis in Linear Multivariate Models, *Economics Letters*, 58(1), 17–29.
- Hamilton, J.D. (1994). *Time Series Analysis*, Princeton University Press.
- Tsay, R.S. (2014). *Multivariate Time Series Analysis with R and Financial Applications*, Wiley.

Resurse online și cod

- **Quantlet:** <https://quantlet.com> ➔ Platformă de cod pentru metode cantitative
- **Quantinar:** <https://quantinar.com> ➔ Platformă de învățare pentru metode cantitative
- **GitHub TSA:** https://github.com/QuantLet/TSA/tree/main/TSA_ch6 ➔ Cod Python pentru acest capitol



Vă Mulțumim!

Întrebări?

Materialele cursului sunt disponibile la: <https://danpele.github.io/Time-Series-Analysis/>



Quantlet



Quantinar