



Analiza și Prognoza Seriilor de Timp

# Capitolul 10: Recapitulare Completă

Analiză Completă cu Date Reale



# Cuprins

- 1 Fluxul Complet de Analiză
- 2 Studiu de Caz 1: Analiza Volatilității Bitcoin
- 3 Studiu de Caz 2: Analiza Ciclului Petelor Solare
- 4 Studiu de Caz 3: Șomajul SUA cu Ruptură Structurală
- 5 Selecția Modelului: Ghid Practic
- 6 Rezumat și Concluzii Cheie

# Prezentare Generală: Metode Studiate

## Metode Clasice


- Cap 1: Fundamentele Seriilor de Timp
- Cap 2: Modele ARMA
- Cap 3: Modele ARIMA
- Cap 4: Modele SARIMA
- Cap 5: Modele GARCH

## Metode Avansate

- Cap 6: VAR & Cauzalitate Granger
- Cap 7: Cointegrare & VECM
- Cap 8: Extensii Moderne
- Cap 9: Prophet & TBATS

**Astăzi: Aplicăm TOATE pe Date Reale!**

# Fluxul Complet de Analiză



## Principiu Cheie

Diagnostichele pot necesita revenirea la selecția modelului (proces iterativ)

## Seturi de Date Reale pentru Acest Capitol

### Bitcoin Randamente


- Date zilnice crypto
- 2019-2024
- Volatilitate extremă
- ARIMA + GARCH

### Pete Solare

- Lunar 1990-2023
- Ciclu clasic de 11 ani
- Sezonabilitate lungă
- Analiză SARIMA

- Lunar 2015-2023
- Bureau of Labor Stats
- Șocul COVID-19
- Rupturi structurale

# Bitcoin: Prezentare Generală a Datelor



- **Date:** Prețuri zilnice Bitcoin și randamente logaritmice (2019-2024)
- **Evenimente cheie:** Crahul COVID, bull run 2021, iarna crypto 2022

## Pasul 1: Testarea Staționarității

### Testul Augmented Dickey-Fuller

- $H_0$ : Rădăcină unitară (nestaționară)
- $H_1$ : Staționară

### Rezultate pentru Bitcoin:

Serie	Statistică ADF	p-value
Prețuri	-0.87	0.79
Randamente Log	-42.1	< 0.001

⇒ Prețuri: nestaționare (random walk)

⇒ Randamente: staționare

### Testul KPSS (Confirmare)

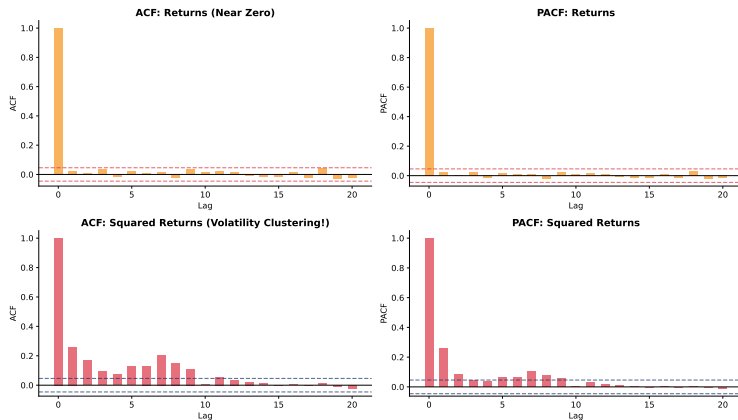
- $H_0$ : Staționară
- $H_1$ : Rădăcină unitară

Prețuri: KPSS = 5.83\*\*

Randamente: KPSS = 0.12

Ambele teste confirmă: folosim randamente log!

## Pasul 2: Analiza ACF/PACF a Randamentelor



- **Randamente:** Aproape zgomot alb (dependență liniară slabă)
- **Randamente pătratic:** Persistență puternică  $\Rightarrow$  clustering volatilitate
- **Implicație:** Modelul GARCH este esențial pentru Bitcoin!



## Pasul 3: Model ARIMA pentru Randamente

### Selecția Modelului folosind AIC/BIC:

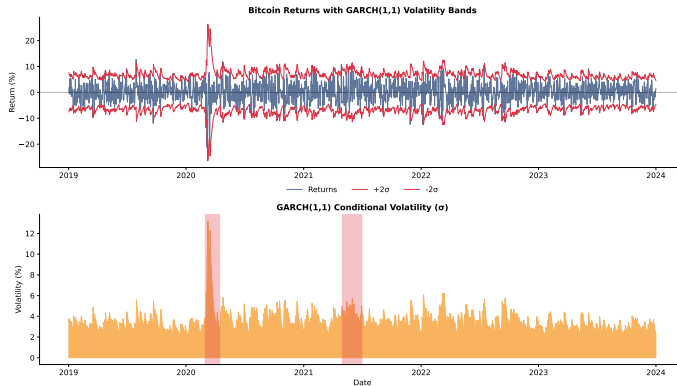
Model	AIC	BIC
ARIMA(0,0,0)	9524	9530
ARIMA(1,0,0)	9522	9534
ARIMA(0,0,1)	9523	9535
<b>ARIMA(1,0,1)</b>	<b>9520</b>	<b>9538</b>

Cel mai bun: ARIMA(1,0,1) dar îmbunătățire marginală

#### Observație Cheie

Randamentele crypto sunt notoriu imprevizibile.  
“Alpha” este în înțelegerea **dinamicii volatilității**, nu în predicția direcției!

## Pasul 4: Model GARCH pentru Volatilitate



**Modelul GARCH(1,1):**

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

- Bitcoin arată  $\alpha + \beta \approx 0.95$  (persistență ridicată)
- Perioadele COVID și Mai 2021 arată vârfuri masive de volatilitate

# Bitcoin: Rezumatul Abordării



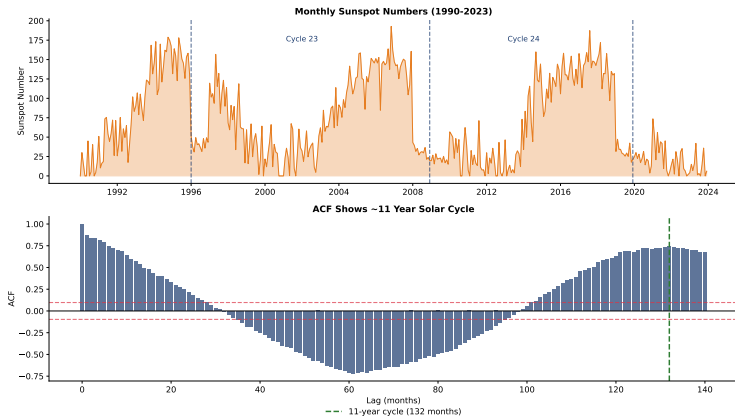
## Constatări Cheie:

- Randamentele sunt aproape imprevizibile
- Clustering extrem de volatilitate
- GARCH captează dinamica riscului

## Utilizare Practică:


- Managementul riscului (VaR, CVaR)
- Dimensionarea pozițiilor
- Strategii de trading pe volatilitate

# Pete Solare: Un Set de Date Clasic cu Ciclu Lung



- **Date:** Numere lunare de pete solare, 1990-2023
- **Caracteristici:** Celebrul ciclu solar de  $\sim 11$  ani (132 luni)

## Pasul 1: Analiza Descompunerii



- **Trend:** Media pe termen lung a activității solare
- **Ciclu:** Ciclul solar de 11 ani (ciclul Schwabe)
- **Provocare:** Perioadă sezonieră foarte lungă ( $m = 132$ )

## Pasul 2: Gestionarea Sezonalității Lungi

### Provocarea:

- SARIMA standard cu  $m = 132$  necesită estimarea multor parametri
- Diferențierea sezonieră la lag 132 pierde 11 ani de date!

### Opțiunea 1: Termeni Fourier

- Adăugăm regresori sinus/cosinus
- Perioadă = 132 luni
- Mai puțini parametri decât SARIMA complet

$$\sum_{k=1}^K \left[ a_k \sin \left( \frac{2\pi kt}{132} \right) + b_k \cos \left( \frac{2\pi kt}{132} \right) \right]$$


### Opțiunea 2: Model AR

- AR de ordin înalt captează ciclul
- AR(12) sau AR(24) adesea suficient
- Simplu și eficient

### Rezultat Clasic

Petele solare sunt bine modelate de modele AR(9) sau AR(12) (Yule, 1927)

## Pasul 3: Prognoza SARIMA



**Model:** AR(12) cu termeni Fourier pentru ciclul de 11 ani

- Captează comportamentul cvasi-periodic
- Incertitudinea prognozei crește semnificativ cu orizontul

Model	RMSE	MAE	Note
AR(12)	28.4	22.1	Simplu, interpretabil
ARIMA(2,0,2) + Fourier	26.8	20.5	Captură bună a ciclului
<b>TBATS</b>	<b>25.2</b>	<b>19.8</b>	Detecrie automată a ciclului
Prophet	29.1	23.4	Mai puțin potrivit pentru cicluri lungi


### Lecție Cheie

Pentru perioade sezoniere foarte lungi, considerați:

- Termeni de regresie Fourier
- TBATS (selecție automată a ciclului)
- Modele AR de ordin înalt



# Șomajul SUA: Șocul COVID-19



- **Date:** Rata Șomajului SUA, lunar, 2015-2023 (BLS)
- **Șoc:** De la 3.5% la 14.7% într-o singură lună (Aprilie 2020)!

## Opțiunea 1: Trunchierea Datelor

- Folosim doar date post-COVID
- Pro: Curate, fără rupturi
- Contra: Pierdem tipare istorice

## Opțiunea 2: Variabile Dummy

- Adăugăm indicator COVID
- Pro: Folosește toate datele
- Contra: Complex în ARIMA

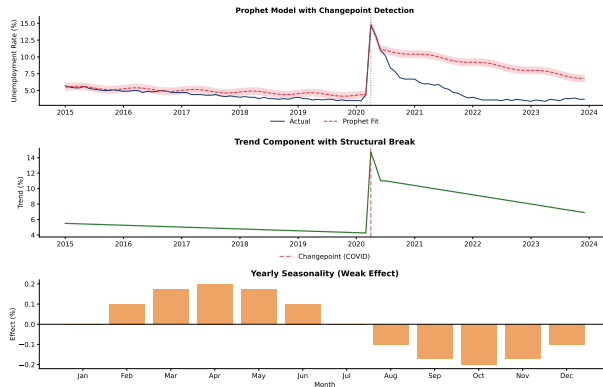
## Opțiunea 3: Prophet cu Changepoints

- Detecție automată
- Pro: Gestionează rupturile natural
- Contra: Poate necesita tuning

### Recomandare

Pentru date afectate de COVID, detecția changepoint-urilor Prophet sau modelele de schimbare de regim funcționează cel mai bine.

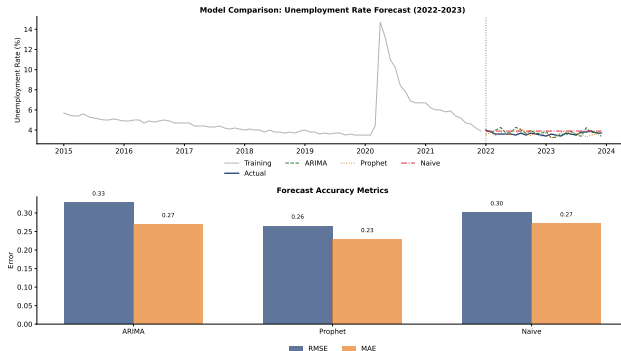
# Prophet pentru Șomaj



## Configurare Prophet:

- `changepoint_prior_scale = 0.5` (flexibil pentru șocul COVID)
- Changepoint automat în Aprilie 2020
- Captează tiparul de recuperare în V


# Comparația Modelelor pe Șomaj



## Lecție Cheie

Când datele au rupturi structurale extreme:

- ARIMA tradițional poate eșua sau necesită analiză de intervenție
- Flexibilitatea Prophet cu changepoints captează schimbările de regim
- Considerați modele de schimbare de regim (Markov-switching)



## Rezumat Selecție Model

Tip Date		Caracteristici	Model Recomandat	Alternative
Randamente	finan- ciare	Fără trend, clustering vol.	ARIMA-GARCH	EGARCH, GJR
Sezonalitate simplă		Trend + o perioadă sezon.	SARIMA	ETS, Prophet
Cicluri lungi		Pete solare, cicluri business	AR + Fourier, TBATS	Metode spectrale
Rupturi structurale		COVID, schimbări regim	Prophet	ARIMA intervenție
Serii multiple		Interdependențe	VAR, VECM	Modele factoriale

# Metrici de Evaluare a Prognozei

## Metrici pentru Prognoze Punctuale:

**RMSE** (Root Mean Square Error):

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

**MAE** (Mean Absolute Error):

$$\frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

**MAPE** (Mean Absolute % Error):

$$\frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

## Când să Folosim Fiecare:

- **RMSE**: Penalizează erorile mari
- **MAE**: Robust la outlieri
- **MAPE**: Independent de scală

## Validare Încrucișată

Folosiți întotdeauna CV pentru serii de timp:

- Fereastră rulantă
- Fereastră expandabilă
- Nu amestecați niciodată!

## Înțelegerea Datelor

- Vizualizare mai întâi!
- Testați staționaritatea (ADF, KPSS)
- Identificați tipare sezoniere
- Verificați rupturi structurale

## Modele Clasice

- ARIMA: Date nesezoniere
- SARIMA: Sezonaliitate simplă
- GARCH: Modelarea volatilității

## Abordări Moderne

- Prophet: Interpretabil, gestionează rupturi
- TBATS: Sezonaliități multiple/lungi
- VAR/VECM: Serii de timp multiple

## Cele Mai Bune Practici

- Verificați întotdeauna diagnosticele
- Folosiți validare încrucișată
- Comparați modele multiple
- Cunoașterea domeniului contează!



## Recomandări Finale

- ❶ **Începeți Simplu:** Începeți cu vizualizare și statistici de bază
- ❷ **Testați Ipotezele:** Staționaritate, normalitate, independență
- ❸ **Iterați:** Model → Diagnostice → Îmbunătățire
- ❹ **Comparați:** Nu vă bazați niciodată pe un singur model
- ❺ **Validați:** Testarea out-of-sample este esențială
- ❻ **Comunicați:** Vizualizări și interpretări clare

### Amintiți-vă

“Toate modelele sunt greșite, dar unele sunt utile.” — George Box

Scopul nu este predicția perfectă, ci perspective utile și prognoze rezonabile.

Întrebări?

Întrebări?

### Pași Următori:

- Exersați cu notebook-ul Jupyter
- Aplicați aceste metode pe propriile date
- Comparați diferite modele pe același set de date

Materiale Curs: [github.com/danpele/Time-Series-Analysis](https://github.com/danpele/Time-Series-Analysis)