



Analiza și Prognoza Seriilor de Timp

Capitolul 1: Procese Stochastice și Staționaritate



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Obiective de învățare

La finalul acestui capitol, veți fi capabili să:

1. Definiți procesele stochastice și să înțelegeți proprietățile acestora
2. Distingeți între staționaritatea strictă și slabă (covarianță)
3. Identificați procesele de zgomot alb și mers aleatoriu
4. Calculați și interpretați ACF (Funcția de Autocorelație) și PACF (Funcția de Autocorelație Parțială)
5. Aplicați operatorul lag și diferențierea
6. Efectuați teste de staționaritate: ADF (Augmented Dickey-Fuller) și KPSS (Kwiatkowski-Phillips-Schmidt-Shin)
7. Analizați date financiare de tip serie de timp
8. Distingeți între procesele cu rădăcină unitate și cele staționare în trend

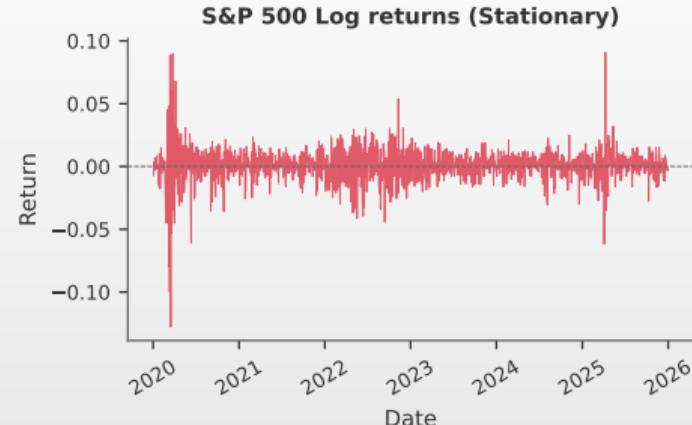


Cuprins

- Motivație
- Procese Stochastice
- Staționaritate
- Operatorul lag și Diferențierea
- Zgomot Alb și Mers Aleatoriu
- Funcții de Autocorelație
- Testarea Staționarității
- Aplicație pe Date Financiare
- Studiu de Caz: Testarea Staționarității
- Utilizare IA
- Rezumat
- Quiz
- Bibliografie



Exemple: serii staționare vs. nestaționare

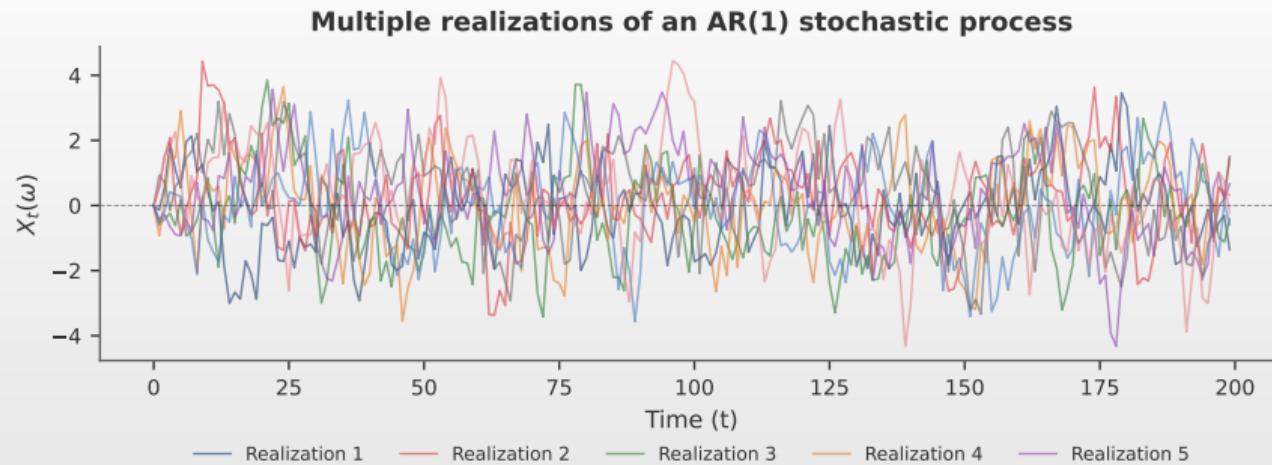


Observații

- Prețurile (stânga) sunt nestaționare: trend, media se schimbă în timp
- Randamentele (dreapta) sunt staționare: medie ≈ 0 , varianță aprox. constantă
- Randamente log: $r_t = \ln P_t - \ln P_{t-1} \Rightarrow$ nestaționar \rightarrow staționar



Proces stochastic: ilustrare vizuală



Interpretare

- Fiecare linie este o **realizare diferită** din același proces stochastic subiacent
- Observăm doar o **singură realizare**, dar vrem să înțelegem proprietățile procesului



Proces stochastic: definiție

Definiție 1 (Proces Stochastic)

- Un **proces stochastic** este o colecție de variabile aleatoare indexate după timp
 - ▶ $\{X_t(\omega) : t \in \mathcal{T}, \omega \in \Omega\}$
 - ▶ Ω este spațiul eșantion al rezultatelor posibile

Două perspective

- **ω fixat:** O realizare $\{X_t(\omega)\}_{t \in \mathcal{T}}$
- **t fixat:** O variabilă aleatoare X_t

De reținut

- O serie de timp pe care o observăm este o **singură realizare** a procesului stochastic subiacent



Momentele unui proces stochastic

Primele două momente caracterizează procesul

- **Funcția de Medie:** $\mu_t = \mathbb{E}[X_t]$
- **Autocovarianță (ACVF):** $\gamma(t, s) = \text{Cov}(X_t, X_s)$
 - ▶ $\gamma(t, s) = \mathbb{E}[(X_t - \mu_t)(X_s - \mu_s)]$
- **Autocorelația (ACF):**
 - ▶ $\rho(t, s) = \gamma(t, s) / \sqrt{\text{Var}(X_t) \cdot \text{Var}(X_s)}$

Proprietăți ACF

- **Interval:** $\rho(t, s) \in [-1, 1]$
- **Normalizare:** $\rho(t, t) = 1$ (corelație perfectă cu sine)

Important

- **General:** μ_t și $\gamma(t, s)$ pot depinde de t
- **Staționar:** Elimină această dependență



De ce contează staționaritatea

Fără staționaritate

- Media, varianța se schimbă în timp
 - ▶ Estimările sunt inconsistente
- Trecutul poate să nu prezică viitorul
- Metodele standard eșuează
- Corelații false

Cu staționaritate

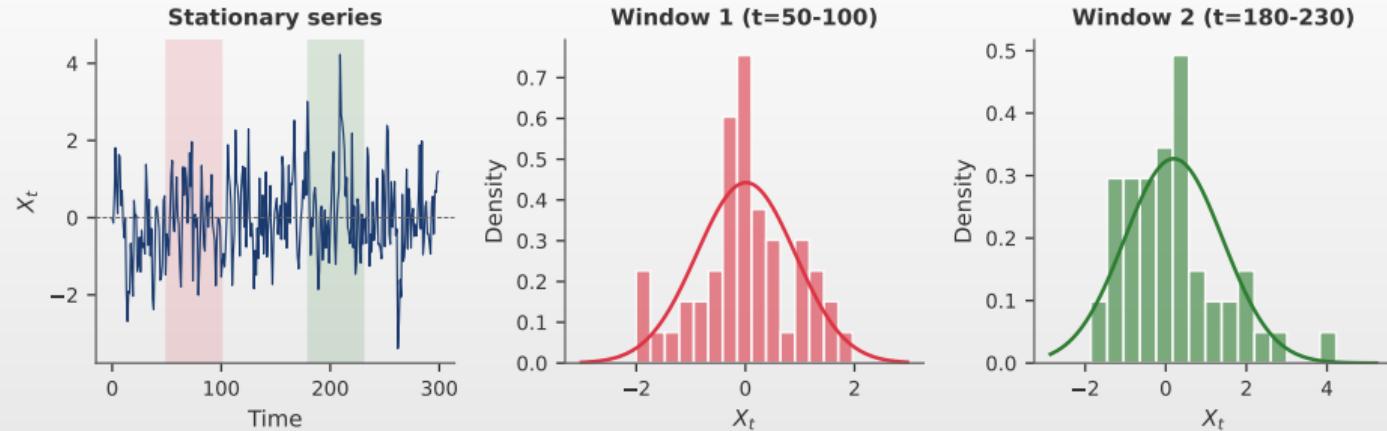
- Proprietăți statistice constante
 - ▶ Ergodicitate justificată
- Putem estima dintr-o singură realizare
- Inferență validă posibilă
- Modelele au sens

Principiu fundamental

- Majoritatea modelelor de serii de timp necesită staționaritate
- Exemple: ARMA (AutoRegressive Moving Average), ARIMA (AutoRegressive Integrated Moving Average)
- Seriile nestaționare trebuie transformate (de ex., diferențiere) înainte de modelare



Staționaritatea strictă: ilustrare vizuală



Interpretare

- Translația în timp nu schimbă distribuția comună a variabilelor
- Oricare două ferestre temporale au aceleași proprietăți statistice
- În practică: verificăm doar primele momente (staționaritate slabă)

Staționaritatea strictă

Definiție 2 (Staționaritate Strictă (Puternică))

- Un proces $\{X_t\}$ este **strict staționar** dacă pentru orice k , orice t_1, \dots, t_k , și orice h :
 - ▶ $(X_{t_1}, \dots, X_{t_k}) \stackrel{d}{=} (X_{t_1+h}, \dots, X_{t_k+h})$
- **Notătie:** $X \stackrel{d}{=} Y$ înseamnă *egalitate în distribuție*
 - ▶ $P(X \leq x) = P(Y \leq x)$

Implicații

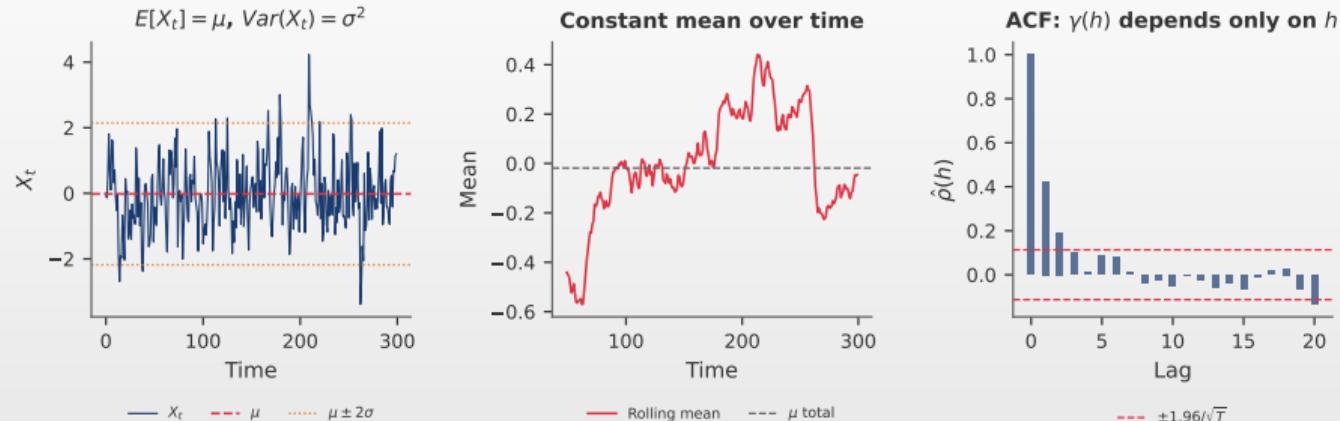
- **Distribuții identice:** $F_{X_t}(x)$ nu depinde de t
 - ▶ $\mathbb{E}[X_t] = \mu$ (medie constantă, dacă există)
 - ▶ $\text{Var}(X_t) = \sigma^2$ (varianță constantă, dacă există)
- **Dependență de lag:** Distribuțiile comune depind doar de lag

Notă

- Staționaritatea strictă este o condiție puternică, adesea imposibil de verificat în practică



Staționaritatea slabă: ilustrare vizuală



Cele trei condiții

- $\mathbb{E}[X_t] = \mu$ constantă \Rightarrow media nu depinde de timp
- $\text{Var}(X_t) = \sigma^2$ constantă \Rightarrow varianța nu depinde de timp
- $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$ \Rightarrow autocovarianța depinde doar de lag h



Staționaritatea slabă (covarianță)

Definiție 3 (Staționaritate Slabă)

- Un proces $\{X_t\}$ este **slab staționar** (sau staționar în covarianță) dacă:
 - ▶ $\mathbb{E}[X_t^2] < \infty$ pentru toți t
 - Momente finite de ordin 2
 - ▶ $\mathbb{E}[X_t] = \mu$ pentru toți t
 - Medie constantă
 - ▶ $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$
 - Covarianța depinde doar de lag-ul h , nu de t

Proprietăți

- **Autocovarianța** este funcție doar de lag:
 - ▶ $\gamma(h) = \text{Cov}(X_t, X_{t+h}) = \mathbb{E}[(X_t - \mu)(X_{t+h} - \mu)]$
- **Autocorelația:**
 - ▶ $\rho(h) = \gamma(h)/\gamma(0) = \text{Cov}(X_t, X_{t+h})/\text{Var}(X_t)$
- **Notă:** $\rho(0) = 1$, $|\rho(h)| \leq 1$, $\rho(h) = \rho(-h)$ (simetrie)



Relația între staționaritate strictă și slabă

Teoremă 1 (Implicație Fundamentală)

- Dacă $\{X_t\}$ este **strict staționar** și $\mathbb{E}[X_t^2] < \infty$, atunci $\{X_t\}$ este și **slab staționar**

Demonstrație.

- Fie t_1, t_2 oarecare și h deplasare temporală arbitrară
- Din invarianța distribuției comune: $(X_{t_1}, X_{t_2}) \stackrel{d}{=} (X_{t_1+h}, X_{t_2+h})$
- $\mathbb{E}[X_{t_1}] = \mathbb{E}[X_{t_1+h}] = \mu$ (medie constantă)
- $\text{Cov}(X_{t_1}, X_{t_2}) = \text{Cov}(X_{t_1+h}, X_{t_2+h})$
- Deci autocovarianța depinde doar de diferența $t_2 - t_1 = h$, nu de t_1

□

Atenție: Reciproca NU este adevărată!

- Există procese slab staționare dar **nu** strict staționare



Exemplu: modelul AR(1) este slab staționar

Modelul AR(1) (AutoRegressive de ordin 1)

- $X_t = \phi X_{t-1} + \varepsilon_t, \quad |\phi| < 1$
- $\varepsilon_t \sim WN(0, \sigma^2)$ — WN (White Noise) = zgomot alb

Verificarea celor trei condiții

1. **Medie constantă:** $\mathbb{E}[X_t] = \phi \mathbb{E}[X_{t-1}] + 0 = \phi \mathbb{E}[X_t] \Rightarrow \mathbb{E}[X_t] = 0$
2. **Varianță constantă:** $\text{Var}(X_t) = \phi^2 \text{Var}(X_{t-1}) + \sigma^2 \Rightarrow \text{Var}(X_t) = \frac{\sigma^2}{1 - \phi^2}$
3. **Autocovarianță depinde doar de lag:** $\gamma(h) = \phi^{|h|} \cdot \frac{\sigma^2}{1 - \phi^2}, \quad \rho(h) = \phi^{|h|}$

Exemplu numeric: $\phi = 0.8, \sigma^2 = 1$

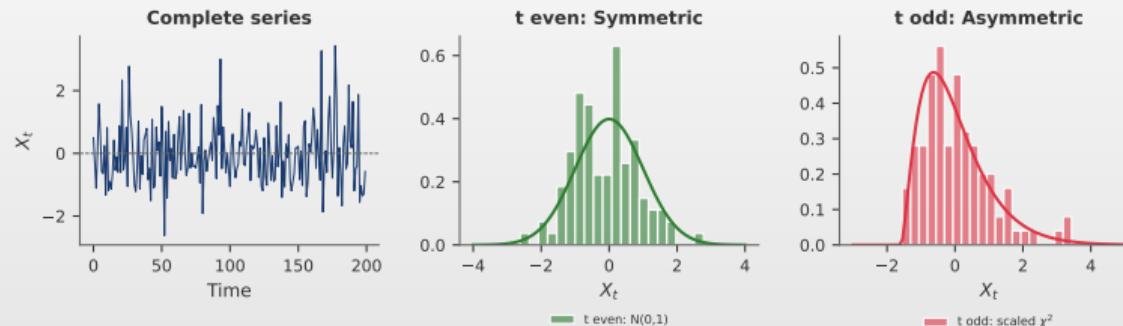
- $\mathbb{E}[X_t] = 0, \quad \text{Var}(X_t) = \frac{1}{1 - 0.64} = 2.78, \quad \rho(1) = 0.8, \quad \rho(2) = 0.64, \quad \rho(5) = 0.33$



Contraexemplu: slab staționar dar NU strict staționar

Construcție

- Fie $\{X_t\}$ variabile aleatoare **independente** cu: t par: $X_t \sim N(0, 1)$; t impar: $X_t \sim \frac{\chi^2(5)-5}{\sqrt{10}}$



Slab staționar ✓

- $\mathbb{E}[X_t] = 0$, $\text{Var}(X_t) = 1$, $\text{Cov}(X_t, X_{t+h}) = 0$

NU strict staționar ✗

- Asimetria diferă (0 vs > 0) $\Rightarrow X_1 \neq X_2$

Q TSA_ch1_stationarity

Proprietățile funcției de autocovarianță

Propoziție 1

Pentru un proces slab staționar, ACVF $\gamma(h)$ satisfac:

- Simetrie:** $\gamma(h) = \gamma(-h)$
- Maximum la zero:** $|\gamma(h)| \leq \gamma(0) = \text{Var}(X_t)$
- Definit nenegativ:** $\sum_{i,j} a_i a_j \gamma(i-j) \geq 0$ pentru orice a_1, \dots, a_n

Demonstrație (prop. 3)

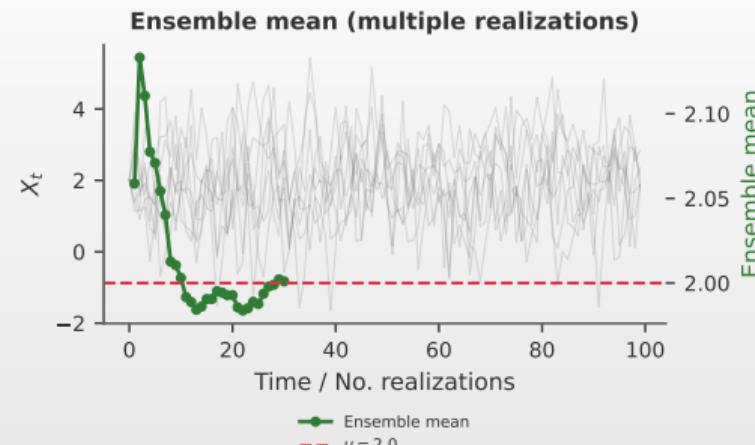
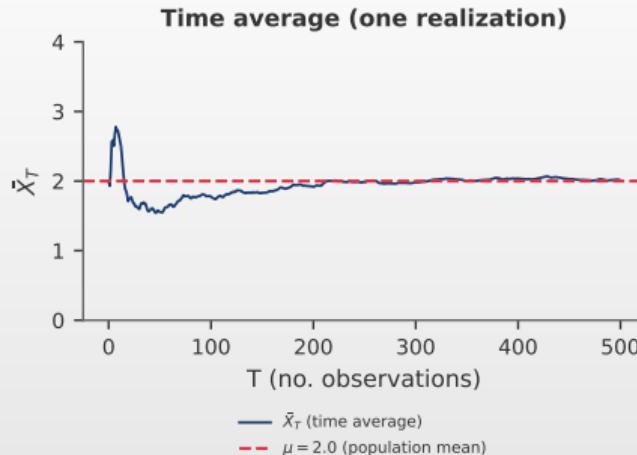
- $\text{Var}(\sum_{i=1}^n a_i X_{t+i}) = \sum_{i,j} a_i a_j \gamma(i-j) \geq 0$ (varianța ≥ 0)

Implicație

- Nu orice funcție poate fi o funcție de autocovarianță validă



Ergodicitatea: ilustrare vizuală



- Media temporală (o singură realizare) și media ansamblului (realizări multiple) converg ambele la μ
- Ergodicitatea garantează că putem estima μ dintr-o singură serie temporală suficient de lungă



Ergodicitatea: fundamentul inferenței din date

Definiție 4 (Ergodicitate pentru Medie)

- Un proces staționar $\{X_t\}$ este **ergodic pentru medie** dacă:
 - ▶ $\bar{X}_T = \frac{1}{T} \sum_{t=1}^T X_t \xrightarrow{P} \mathbb{E}[X_t] = \mu$ când $T \rightarrow \infty$

De ce contează ergodicitatea?

- **Problema:** Avem doar o **singură realizare** a procesului stochastic
- **Soluția:** Ergodicitatea permite estimarea lui μ din \bar{X}_T
 - ▶ Media temporală convergează la media populației
 - ▶ Fără ergodicitate, inferență statistică nu este posibilă!

Teoremă 2 (Condiție Suficientă)

- Dacă $\sum_{h=0}^{\infty} |\gamma(h)| < \infty$ (autocovarianțe absolut sumabile), procesul este ergodic



Densitatea spectrală: domeniul frecvențelor

Definiție 5 (Densitatea spectrală de putere)

- Pentru un proces staționar cu $\sum_{h=-\infty}^{\infty} |\gamma(h)| < \infty$, **densitatea spectrală** este:

$$S(\omega) = \frac{1}{2\pi} \sum_{h=-\infty}^{\infty} \gamma(h) e^{-i\omega h} = \frac{1}{2\pi} \left[\gamma(0) + 2 \sum_{h=1}^{\infty} \gamma(h) \cos(\omega h) \right], \quad \omega \in [-\pi, \pi]$$

- $S(\omega)$ descompune varianța procesului pe frecvențe: $\gamma(0) = \int_{-\pi}^{\pi} S(\omega) d\omega$

Interpretare

- $S(\omega)$ mare la ω mic \Rightarrow ciclu lung dominant
- Zgomot alb: $S(\omega) = \frac{\sigma^2}{2\pi}$ (plat)
- AR(1) $\phi > 0$: putere concentrată la frecvențe joase
- MA(1) $\theta > 0$: putere concentrată la frecvențe înalte

Conexiuni

- **Perechea Fourier:** $S(\omega) \leftrightarrow \gamma(h)$ (echivalente)
- Domeniul timp (ACF) \equiv domeniul frecvență (spectru)
- **Periodograma:** estimator empiric al lui $S(\omega)$
- Util pentru detectarea sezonalității ascunse



Teorema de descompunere Wold

Teoremă 3 (Wold, 1938)

- Orice proces **staționar în covariantă** $\{X_t\}$ poate fi scris ca: $X_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + \eta_t$
 - ▶ $\varepsilon_t \sim WN(0, \sigma^2) \Rightarrow$ zgomot alb, cu $\psi_0 = 1, \sum \psi_j^2 < \infty$
 - ▶ $\eta_t \Rightarrow$ componentă deterministă (perfect predictibilă)

Semnificația teoremei Wold

- **Descompunere:** Orice proces staționar = **MA(∞)** (Moving Average de ordin infinit) + componentă deterministă
 - ▶ Justifică teoretic modelele MA(q) și ARMA(p, q)
 - ▶ Coeficienții ψ_j măsoară impactul șocurilor trecute

Demonstrația teoremei Wold (schiță)

Schiță de demonstrație.

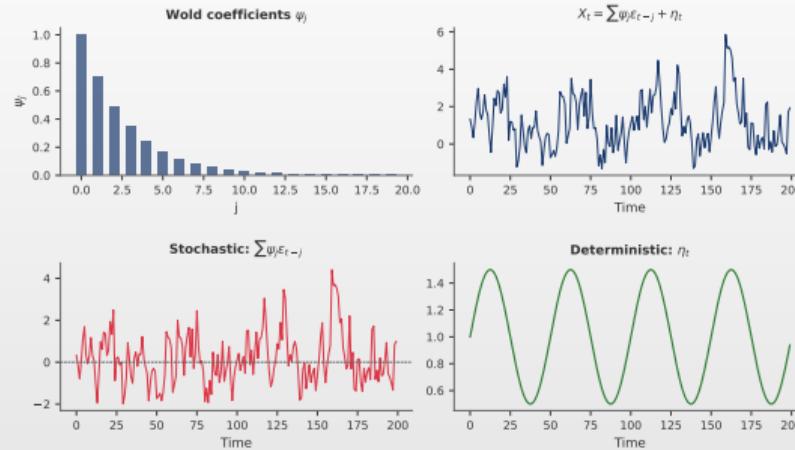
- Spațiul Hilbert al trecutului:** Definim $\mathcal{H}_t = \overline{\text{sp}}\{X_s : s \leq t\}$ — spațiul închis generat de valorile trecute și prezente, cu produsul scalar $\langle X, Y \rangle = \text{Cov}(X, Y)$.
- Inovația:** Definim $\varepsilon_t = X_t - \hat{X}_t$, unde $\hat{X}_t = \text{Proj}_{\mathcal{H}_{t-1}}(X_t)$ este proiecția ortogonală. Prin construcție, $\varepsilon_t \perp \mathcal{H}_{t-1}$, deci $\varepsilon_t \perp \varepsilon_s$ pentru $t \neq s \Rightarrow \{\varepsilon_t\}$ este zgomot alb.
- Reprezentarea iterativă:** Aplicând recursiv proiecția:

$$X_t = \varepsilon_t + \psi_1 \varepsilon_{t-1} + \psi_2 \varepsilon_{t-2} + \cdots + \eta_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + \eta_t$$

unde ψ_j rezultă din proiecțiile succesive, iar $\eta_t \in \mathcal{H}_{-\infty} = \bigcap_t \mathcal{H}_t$.

- Convergența:** $\sum_{j=0}^{\infty} \psi_j^2 < \infty$ deoarece $\text{Var}(X_t) < \infty$ (staționaritate).
- Componenta deterministă:** $\eta_t \in \mathcal{H}_{-\infty} \Rightarrow \eta_t$ este *perfect predictibilă* din trecutul infinit. □

Teorema Wold: ilustrare vizuală

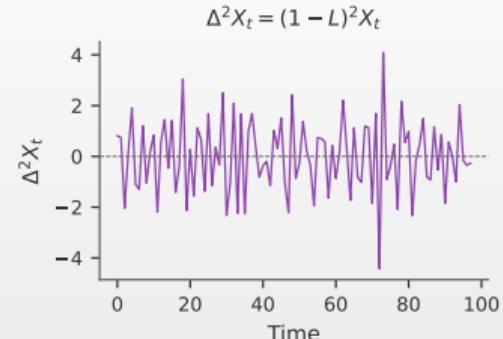
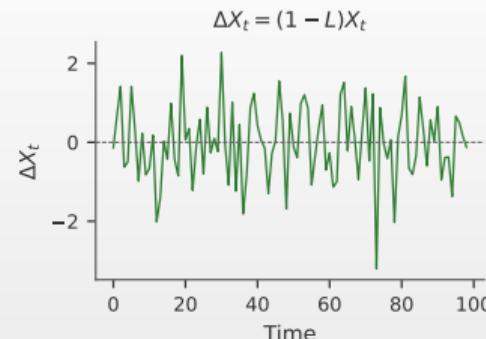
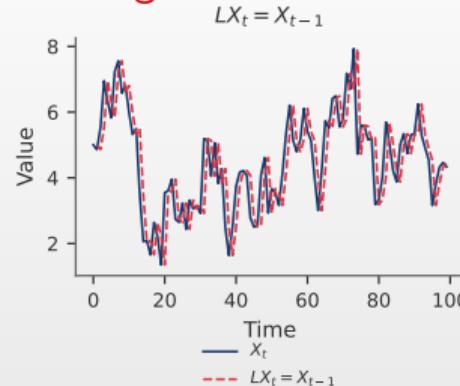


Interpretare

- X_t se descompune în componentă **stochastică** ($MA(\infty)$) și componentă **deterministă** (η_t)
- Coeficienții ψ_j descresc \Rightarrow șocurile recente au impact mai mare decât cele îndepărtate



Operatorul lag: ilustrare vizuală



Proprietăți

- $LX_t = X_{t-1} \Rightarrow$ operatorul lag deplasează seria cu o perioadă în trecut
- $L^k X_t = X_{t-k} \Rightarrow$ deplasare cu k perioade; $L^0 = I$ (identitate)
- **Operatorul diferență:** $\Delta = (1 - L)$, astfel $\Delta X_t = X_t - X_{t-1}$



Operatorul lag

Definiție 6 (Operatorul lag)

- **Operatorul lag** (sau operatorul de întârziere) L este definit prin: $LX_t = X_{t-1}$

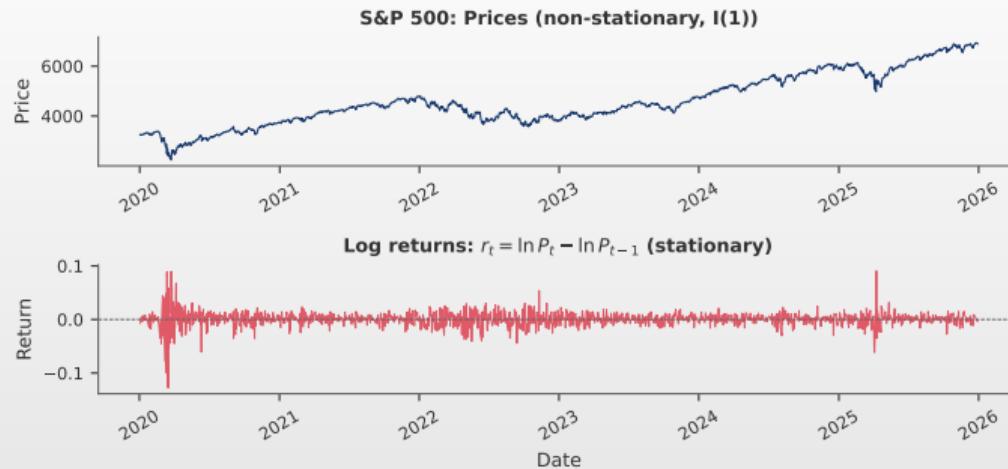
Proprietăți

- **Puteri:** $L^k X_t = X_{t-k}$ (întârzie cu k perioade)
 - ▶ Notație compactă pentru modele
- **Identitate:** $L^0 = I$
- **Polinom:** $(1 - \phi L)X_t = X_t - \phi X_{t-1}$

Exemple

- **Prima diferență:** $(1 - L)X_t = X_t - X_{t-1}$
- **A doua diferență:** $(1 - L)^2 X_t = \Delta^2 X_t$
- **Sezonieră:** $(1 - L^{12})X_t$

Efectul diferențierii: S&P 500



Interpretare

- Sus:** Prețuri S&P 500 \Rightarrow trend clar, nestaționar ($I(1)$)
- Jos:** Randamente log $r_t = \ln P_t - \ln P_{t-1} \Rightarrow$ fluctuează în jurul mediei ≈ 0 , staționar



Diferențierea

De ce diferențiem?

- Prima Diferență:** $\Delta X_t = X_t - X_{t-1} = (1 - L)X_t$
 - ▶ Elimină trendul și rădăcina unitate
 - ▶ Mers aleator: $\Delta X_t = \varepsilon_t$

Definiție 7 (Proces Integrat de Ordin d)

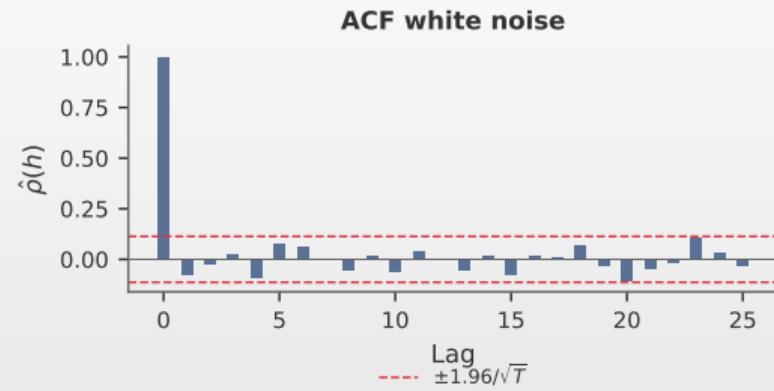
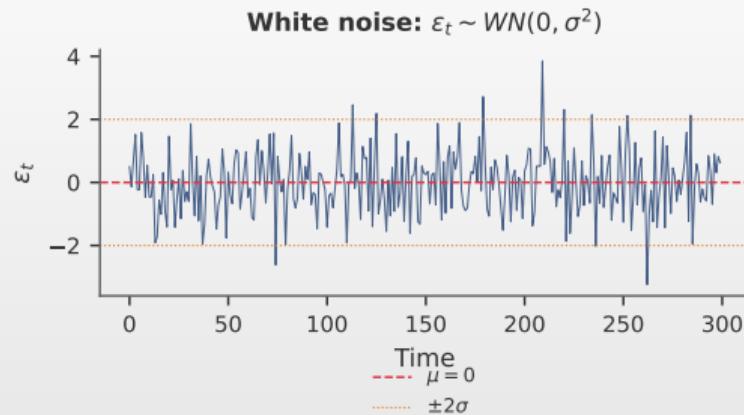
- Un proces $\{X_t\}$ este **integrat de ordin d** , notat $X_t \sim I(d)$, dacă:
 - ▶ $\Delta^d X_t = (1 - L)^d X_t$ este staționar ($I(0)$ proces)
 - ▶ $\Delta^{d-1} X_t$ nu este staționar

Exemple

- $I(0)$: Proces staționar (zgomot alb, AR staționar)
- $I(1)$: Mers aleator $\Rightarrow \Delta X_t = \varepsilon_t$ este staționar
- $I(2)$: Necesită două diferențieri pentru staționaritate



Zgomot alb: ilustrare vizuală



Q TSA_ch1_white_noise



Procesul de zgomot alb

Definiție 8 (Zgomot Alb)

- Un proces $\{\varepsilon_t\}$ este **zgomot alb**, notat $\varepsilon_t \sim WN(0, \sigma^2)$, dacă:
 - ▶ $E[\varepsilon_t] = 0$ pentru orice t (medie zero)
 - ▶ $Var(\varepsilon_t) = \sigma^2$ pentru orice t (varianță constantă)
 - ▶ $Cov(\varepsilon_t, \varepsilon_s) = 0$ pentru $t \neq s$ (necorelat)

ACF al zgomotului alb

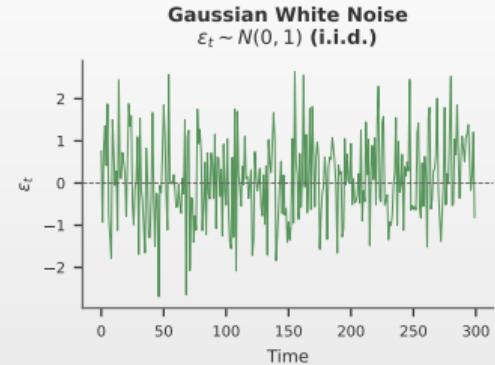
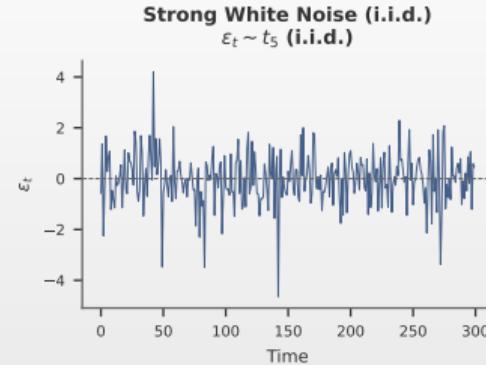
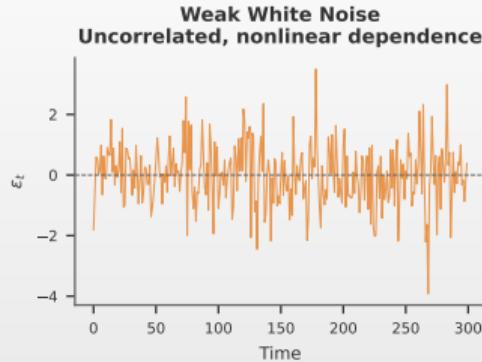
- Din definiție: $\gamma(0) = \sigma^2$ și $\gamma(h) = 0$ pentru $h \neq 0$; $\rho(h) = \begin{cases} 1 & h = 0 \\ 0 & h \neq 0 \end{cases}$

Observație

- Zgomotul alb este cel mai simplu proces staționar — element fundamental al modelelor ARMA
- Există trei tipuri: slab, puternic (i.i.d.) și Gaussian (vezi diapozitivul următor)



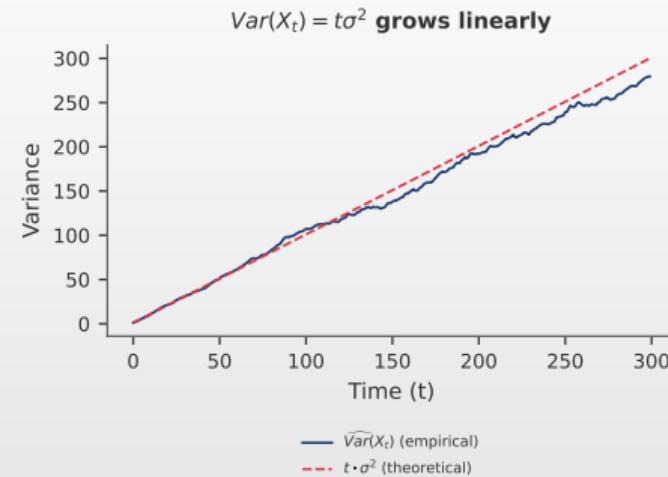
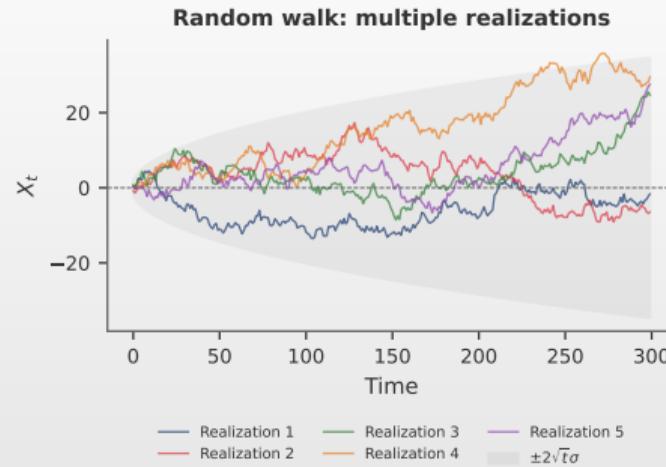
Cele trei tipuri de zgomot alb



Relația de incluziune: Gaussian \subset puternic (i.i.d.) \subset slab (necorelat)

- Slab:** $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$, dar pot exista dependențe neliniare (ex. GARCH)
- Puternic:** ε_t sunt i.i.d. (independente și identic distribuite) — orice distribuție (ex. Student- t)
- Gaussian:** $\varepsilon_t \stackrel{iid}{\sim} N(0, \sigma^2)$ — necorelat \Leftrightarrow independent

Mers aleator: vizualizare



Observații

- Fiecare șoc are **efect permanent**; $\text{Var}(X_t) = t\sigma^2$ crește liniar cu timpul
- Soluție** — diferențierea transformă în zgomot alb, $\Delta X_t = \varepsilon_t$



Procesul de mers aleatoriu

Definiție 9 (Mers Aleatoriu)

- $X_t = X_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim WN(0, \sigma^2), \quad X_0 = 0$
- Forma explicită:** $X_t = \sum_{i=1}^t \varepsilon_i$

Propoziție 2 (Proprietăți)

- $\mathbb{E}[X_t] = 0$
- $\text{Var}(X_t) = t\sigma^2$ (crește cu timpul!)
- $\text{Cov}(X_t, X_s) = \min(t, s) \cdot \sigma^2$

Demonstrații.

- $\mathbb{E}[X_t] = \mathbb{E}\left[\sum_{i=1}^t \varepsilon_i\right] = 0$
- $\text{Var}(X_t) = \text{Var}\left(\sum_{i=1}^t \varepsilon_i\right) = \sum_{i=1}^t \text{Var}(\varepsilon_i) = t\sigma^2 \quad (\text{independentă})$
- $\text{Cov}(X_t, X_s) = \min(t, s) \sigma^2 \quad (\text{pentru } s \leq t)$

Nestaționar!

Analiza $\text{Var}(X_t)$ arată că este dependență de $t \Rightarrow$ mersul aleatoriu **nu este staționar**



Mers aleator cu drift

Definiție 10 (Mers Aleatoriu cu Drift)

- $X_t = c + X_{t-1} + \varepsilon_t, \quad c \neq 0$ este **driftul**
- Forma explicită:** $X_t = ct + \sum_{i=1}^t \varepsilon_i$

Propoziție 3 (Proprietăți)

- $\mathbb{E}[X_t] = ct$ (trend liniar)
- $\text{Var}(X_t) = t\sigma^2$ (crește cu timpul)

Diferențiere

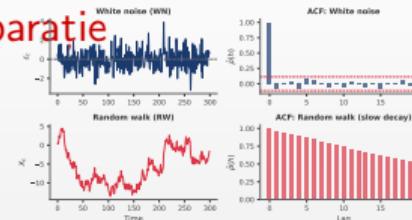
- $\Delta X_t = c + \varepsilon_t$ — constantă plus zgomot alb \Rightarrow seria diferențiată este staționară

Importanța practică

- PIB nominal, prețuri de acțiuni \Rightarrow adesea modele ca RW (Random Walk — mers aleatoriu) cu drift
- Testul ADF include variante: fără constantă, cu constantă, cu constantă și trend



Zgomot alb vs mers aleatoriu: comparație



Zgomot alb

- Staționar, $\text{Var} = \sigma^2$ (const.), $\text{ACF} = 0$ pentru $h \neq 0$, fără memorie

Mers aleator

- Nestaționar, $\text{Var} = t\sigma^2$ (crește), $\text{ACF} \approx 1$ (lent), șocuri permanente

Legătură

- $\Delta X_t = \varepsilon_t$



Staționaritate în trend vs. staționaritate în diferențe

Staționaritate în trend — TS (Trend Stationary)

- Model:** $Y_t = \alpha + \beta t + \varepsilon_t$
 - ▶ Trend **determinist**
 - ▶ Abaterile de la trend sunt temporare
- Soluție:** regresie pe t , se extrag reziduurile
- Efect:** Șocurile NU au efect permanent

Staționaritate în diferențe — DS (Difference Stationary)

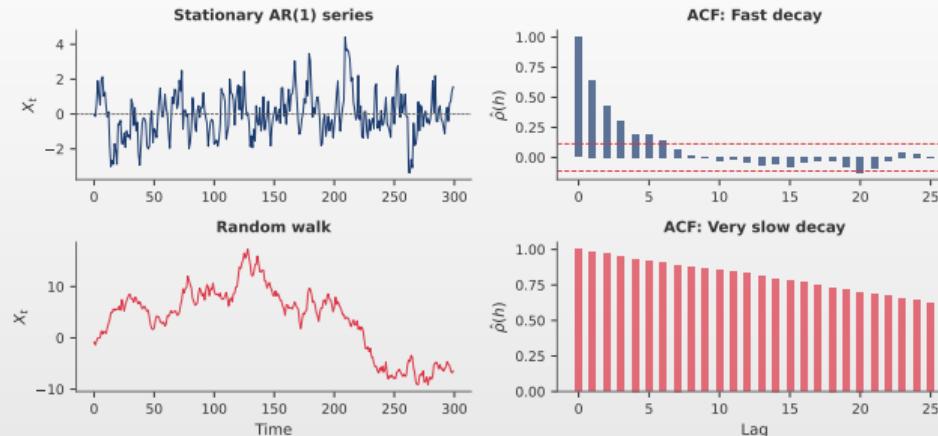
- Model:** $Y_t = c + Y_{t-1} + \varepsilon_t$
 - ▶ Trend **stochastic**
 - ▶ Abaterile de la trend sunt permanente
- Soluție:** diferențiere (ΔY_t)
- Efect:** Șocurile AU efect permanent

De ce contează distincția?

- Diferențiere pe TS:** introduce rădăcină unitară artificială în MA
- Regresie pe DS:** produce reziduuri tot nestaționare
- Soluție:** Testele ADF și KPSS ajută la distincție



Comparație ACF: staționar vs mers aleatoriu

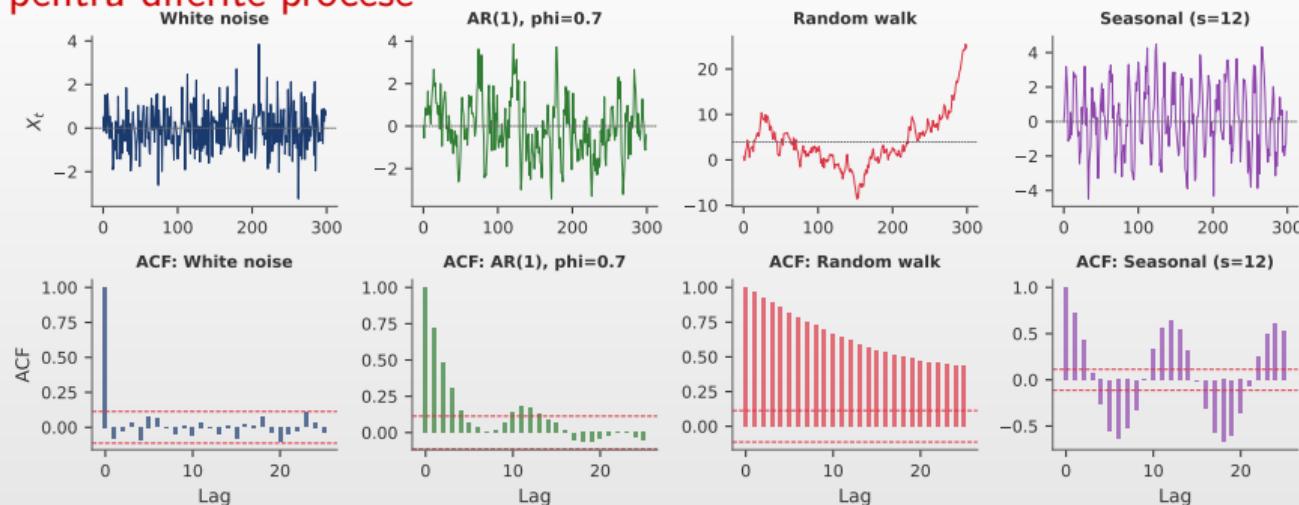


Interpretare

- Staționar:** ACF scade rapid (exponențial sau oscilant) spre zero
- Mers aleator:** ACF scade foarte lent, rămâne aproape de 1
- Regulă practică:** ACF lent \Rightarrow suspectăm rădăcină unitate \Rightarrow test ADF



Tipare ACF pentru diferite procese



Interpretare

- Zgomot alb:** $ACF = 0$; **Staționar:** scade rapid; **Nestaționar:** scade lent
- Sezonier:** Vârfuri la lag-uri sezonale (12, 24 pentru date lunare)



Funcția de autocorelație eșantion

ACF eșantion la lag-ul h

- $\hat{\rho}(h) = \frac{\sum_{t=1}^{T-h} (x_t - \bar{x})(x_{t+h} - \bar{x})}{\sum_{t=1}^T (x_t - \bar{x})^2}$
- Proprietăți: $\hat{\rho}(0) = 1$, $|\hat{\rho}(h)| \leq 1$

Teoremă 4 (Bartlett, 1946)

- Sub H_0 : zgomot alb, pentru T mare: $\hat{\rho}(h) \approx N(0, 1/T)$

Interval de încredere 95%

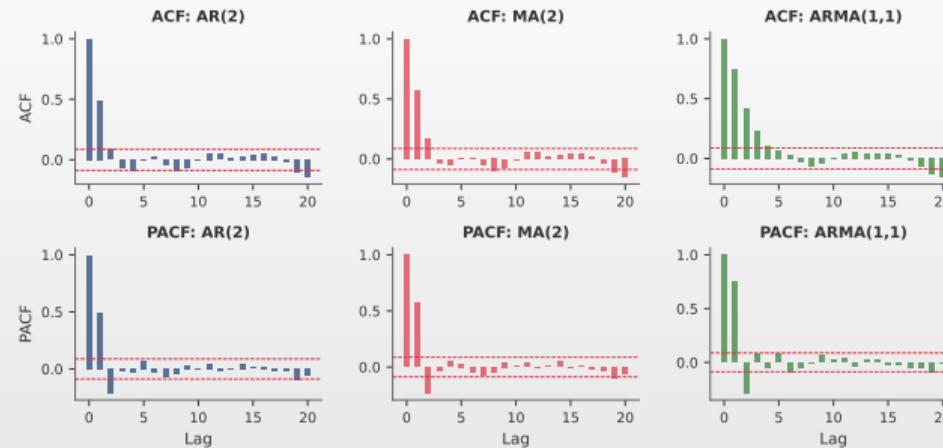
- $\pm 1.96/\sqrt{T}$ (benzile din graficele ACF)

Atenție

- Formula Bartlett validă doar sub H_0 : zgomot alb
- Pentru AR/MA, varianța asimptotică diferă



Tipare ACF și PACF



Reguli de identificare

- AR(p)**: ACF scade exponențial, PACF se anulează după lag p
- MA(q)**: ACF se anulează după lag q , PACF scade exponențial
- ARMA(p, q)**: Ambele scad exponențial \Rightarrow identificarea necesită criterii informaționale



Funcția de autocorelație parțială (PACF)

Definiție 11 (Autocorelația Parțială)

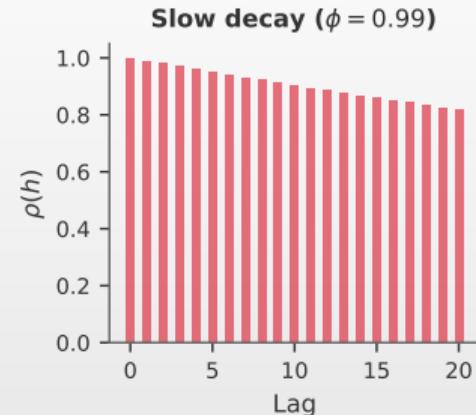
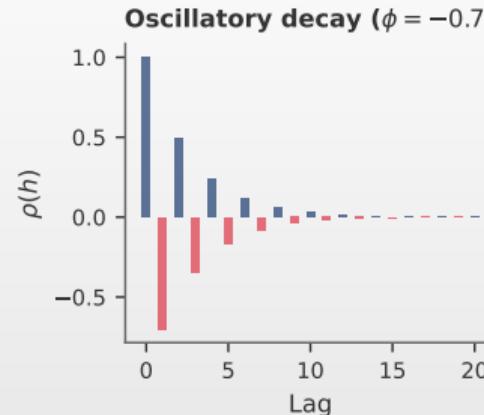
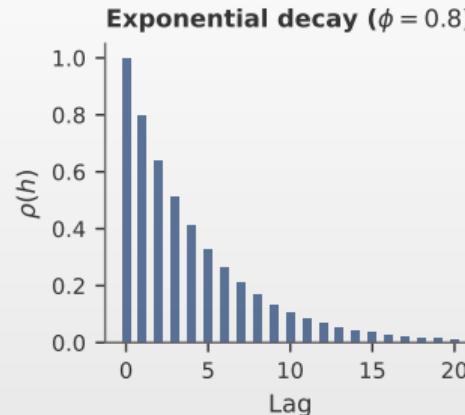
- **PACF** la lag-ul h , notat ϕ_{hh} : ultimul coeficient din regresia:
 - ▶ $X_t = \phi_{h1}X_{t-1} + \phi_{h2}X_{t-2} + \cdots + \phi_{hh}X_{t-h} + e_t$
- **Alternativ:**
 - ▶ $\phi_{hh} = \text{Corr}(X_t - \hat{X}_t^{(h-1)}, X_{t-h} - \hat{X}_{t-h}^{(h-1)})$
- **Interpretare:** Dependență *directă* la lag-ul h
 - ▶ Elimină efectul lag-urilor intermedieare

Aplicație practică

- PACF identifică direct ordinul p al unui model AR(p)
- $\phi_{hh} = 0$ pentru $h > p \Rightarrow$ PACF se anulează după lag-ul p



Tipare de scădere ACF



Interpretare

- Scădere exponențială:** Dependență pozitivă persistentă (AR cu $\phi > 0$)
- Scădere oscilantă:** Dependență alternantă (AR cu $\phi < 0$)
- Viteza de scădere indică puterea memoriei procesului

Testul Augmented Dickey-Fuller (ADF)

Modelul ADF

$\Delta X_t = \alpha + \gamma X_{t-1} + \sum_{i=1}^p \delta_i \Delta X_{t-i} + \varepsilon_t, \quad \gamma = \rho - 1, \quad H_0 : \gamma = 0 \Leftrightarrow \rho = 1$

Ipoteze

- $H_0: \gamma = 0$ (rădăcină unitate)
- $H_1: \gamma < 0$ (staționar)

Statistica de Test

- $\tau_{ADF} = \hat{\gamma} / SE(\hat{\gamma})$
- $\hat{\gamma}$ = coeficient OLS (Ordinary Least Squares) al X_{t-1}
- $SE(\hat{\gamma})$ din regresia OLS

Regula de decizie

- $\tau_{ADF} < \text{val. critică} \Rightarrow \text{Respingem } H_0 \Rightarrow \text{Staționar}$
- $\tau_{ADF} \geq \text{val. critică} \Rightarrow \text{Nestaționar (rădăcină unitate)}$
- Valorile critice urmează distribuția Dickey-Fuller (**nu t-Student!**)



Testul KPSS

Modelul

- $X_t = \xi t + r_t + \varepsilon_t$ unde $r_t = r_{t-1} + u_t$

Ipoteze (opus ADF)

- $H_0: \sigma_u^2 = 0$ (staționar)
- $H_1: \sigma_u^2 > 0$ (rădăcină unitate)

Statistica de Test

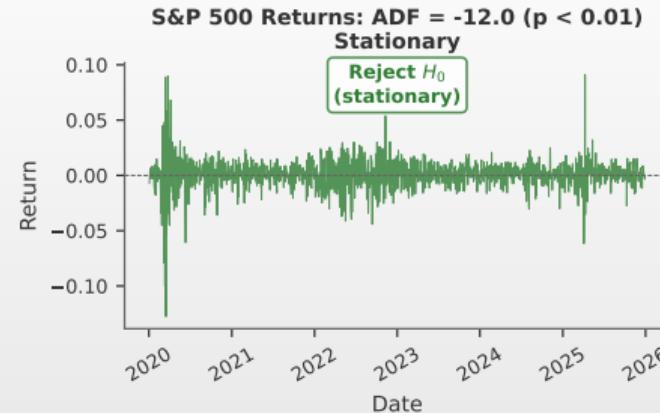
- $LM = \frac{\sum_{t=1}^T S_t^2}{T^2 \hat{\sigma}_{LR}^2}$
- $S_t = \sum_{i=1}^t \hat{e}_i, \quad \hat{\sigma}_{LR}^2 = \text{varianța de lungă durată}$

Regula de decizie

- $LM >$ valoarea critică \Rightarrow Respingerem $H_0 \Rightarrow$ **Nestăționar**
- $LM \leq$ valoarea critică \Rightarrow **Staționar**



Testul ADF: vizualizare cu S&P 500



Q TSA_ch1_unit_root_tests

Interpretarea testului ADF

- **Ipoteza:** H_0 : Rădăcină unitate
 - ▶ Valori critice: -3.43 (1%), -2.86 (5%), -2.57 (10%)
 - ▶ $\tau < \text{val. critică} \Rightarrow$ respingem $H_0 \Rightarrow$ serie staționară
- **S&P 500:** Prețuri nestaționare; Randamente staționare



Folosirea ADF și KPSS împreună

Testare confirmatorie

- ADF respinge H_0 + KPSS nu respinge: Staționar
- ADF nu respinge + KPSS respinge H_0 : Rădăcină Unitară
- Ambele resping sau ambele nu resping: Neconcludent
 - ▶ Necesită teste suplimentare: PP (Phillips-Perron)
 - ▶ Sau DF-GLS (Dickey-Fuller Generalized Least Squares)

Flux de lucru

- Pasul 1: Test ADF (H_0 : rădăcină)
- Pasul 2: Test KPSS (H_0 : staționar)
- Pasul 3: Rezultate concordante \Rightarrow OK
 - ▶ Altfel: teste PP, DF-GLS



Testul Phillips-Perron (PP)

Definiție 12 (Phillips-Perron, 1988)

- Testează aceeași ipoteză ca ADF: H_0 : rădăcină unitate ($\gamma = 0$)
- Modelul de bază (fără lag-uri augmentate): $\Delta y_t = \alpha + \gamma y_{t-1} + e_t$
- Corectează autocorelația și heteroscedasticitatea din e_t prin **corecție neparametrică** (Newey-West) a statisticii t

Statistica PP

- $Z_t = t_\gamma \cdot \sqrt{\frac{s_e^2}{\hat{\lambda}^2}} - \frac{T(\hat{\lambda}^2 - s_e^2)}{2\hat{\lambda}^2 \cdot SE(\hat{\gamma})}$
- $\hat{\lambda}^2$: varianța de lungă durată (kernel Newey-West)
- s_e^2 : varianța reziduală OLS
- Valorile critice: identice cu ADF (distribuția Dickey-Fuller)

PP vs ADF

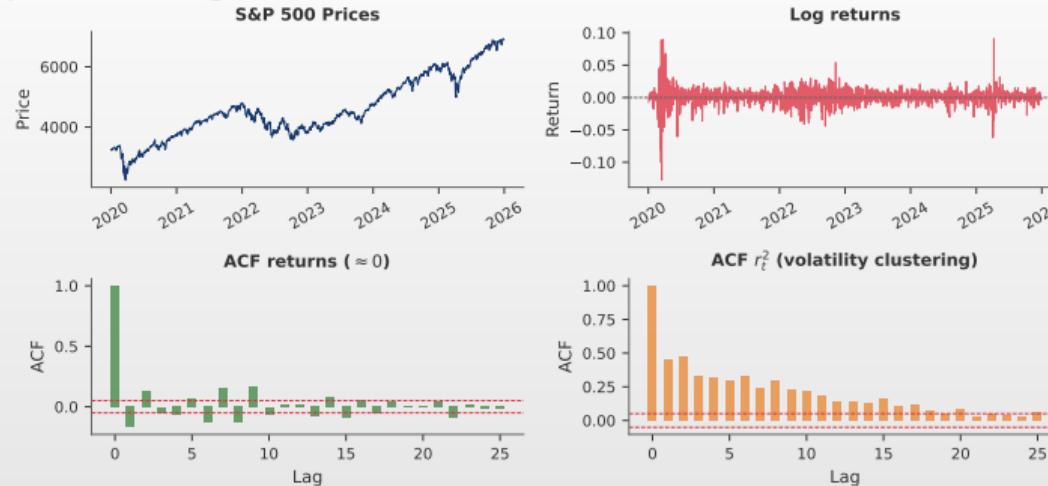
- **ADF**: adaugă lag-uri $\Delta y_{t-j} \Rightarrow$ parametric
- **PP**: corectează statistica $t \Rightarrow$ neparametric
- PP mai robust la heteroscedasticitate
- ADF mai robust la MA cu rădăcini aproape de -1

Python

```
from statsmodels.tsa.stattools import PhillipsPerron
```



Analiza S&P 500: prezentare generală

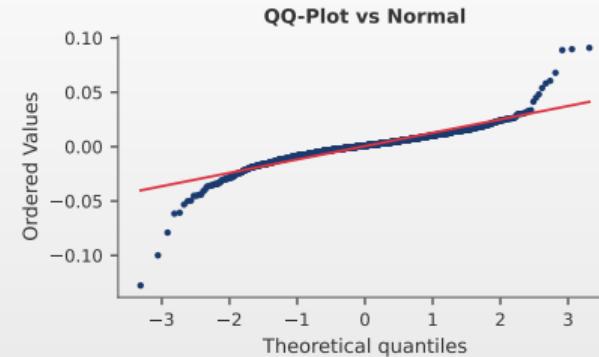
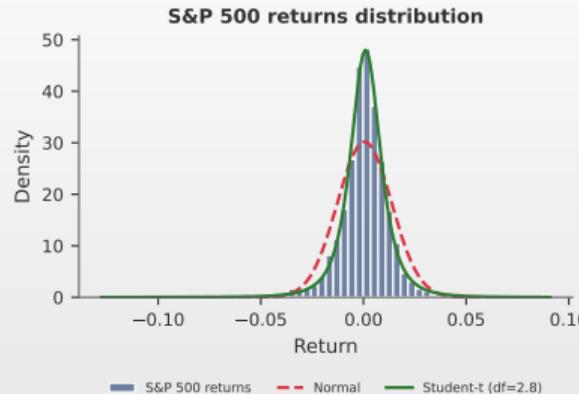


Observații

- **Prețuri:** Trend ascendent, nestaționar; **Randamente:** Medie ≈ 0 , staționar
- **ACF randamente:** ≈ 0 (eficient); **ACF r_t^2 :** Semnificativ (aglomerarea volatilității)



Fapte stilizate ale randamentelor financiare



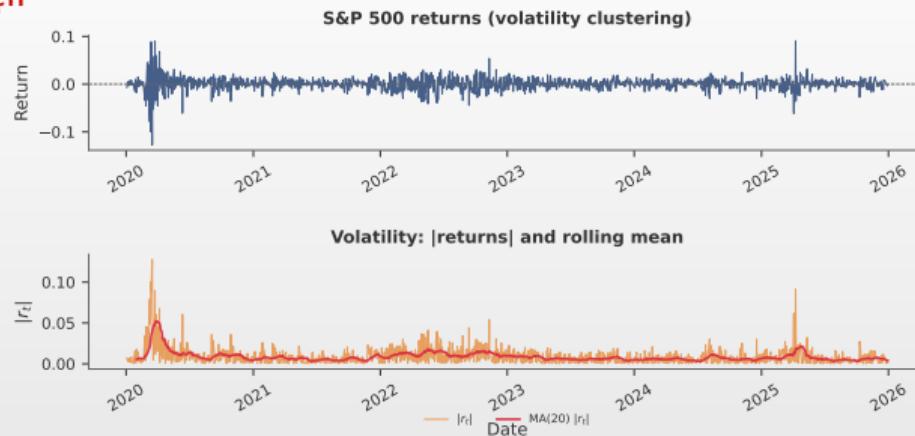
Proprietăți observate

- Asimetrie negativă (coadă stângă)
- Kurtosis excesiv ($\gg 3$)
- Cozi groase (heavy tails)

Implicații

- Distribuția normală inadecvată
- Evenimente extreme mai probabile
- Necesită distribuții cu cozi groase
- Ex.: Student- t , GED (Generalized Error Distribution)

Aglomerarea volatilității

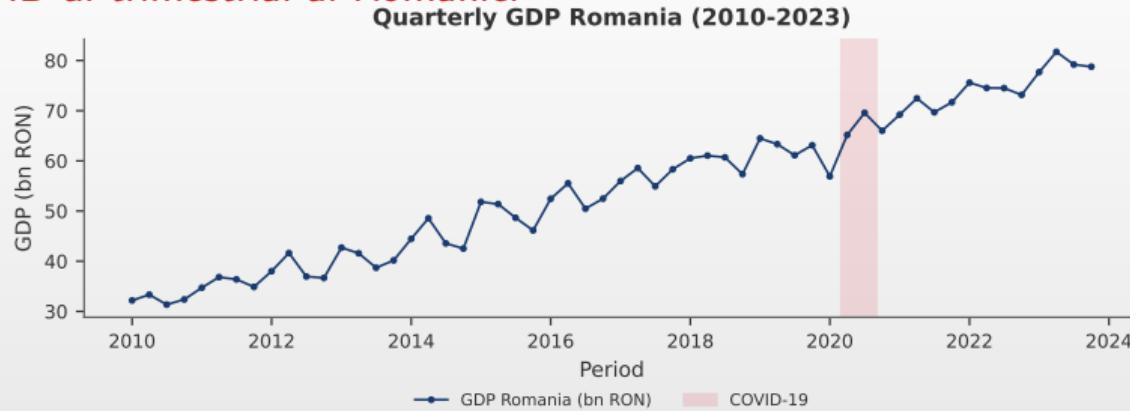


Observații

- Randamente mari (în valoare absolută) urmate de randamente mari
- Perioade de calm urmate de perioade de volatilitate ridicată
- **Volatilitate variabilă în timp** ⇒ necesită modele specializate (Cap. 5)
- Modele ARCH (AutoRegressive Conditional Heteroskedasticity) / GARCH (Generalized ARCH)



Studiu de caz: PIB-ul trimestrial al României



TSA_ch1_case_gdp

Analiza inițială

- **Date:** PIB trimestrial România 2010–2023 (56 obs., INS — Institutul Național de Statistică / Eurostat)
- **Observații:** Trend ascendent, posibil sezonier
 - ▶ řoc structural COVID-19 vizibil
- **Ipoteză:** Serie nestaționară ⇒ testăm cu ADF și KPSS



Testarea staționarității: ADF și KPSS

Testul ADF

- Ipoteză:** H_0 : Rădăcină unitate
- Rezultat:** Stat. ADF: -1.23
 - ▶ Val. critică: -2.89
 - ▶ Nu respingem H_0

Testul KPSS

- Ipoteză:** H_0 : Staționară
- Rezultat:** Stat. KPSS: 0.89
 - ▶ Val. critică: 0.46
 - ▶ Respingem H_0

Concluzie: Ambele teste concordă

- Seria PIB este **nestaționară** \Rightarrow necesită diferențiere



Diferențierea: obținerea staționarității

După diferențiere

- Teste:** Ambele confirmă staționaritate
 - ▶ ADF: -4.56 ($p < 0.01$)
 - ▶ KPSS: 0.21 ($p > 0.10$)

Concluzie

- PIB nivel:** nestaționar
- ΔPIB :** staționar
 - ▶ Folosim ΔPIB_t pentru modelare

Rezultat final

- PIB-ul necesită o diferențiere pentru a deveni staționar



Exercițiu AI: Gândire critică

Prompt de testat în ChatGPT / Claude / Copilot

"Folosind yfinance, descarcă cursul zilnic EUR/RON (EURRON=X) din 2020-01-01 până în 2024-12-31 (aprox. 1.250 observații). Testează dacă seria este staționară folosind testele ADF și KPSS. Ajustează un model adecvat și prognozează cursul pentru următoarele 5 zile lucrătoare. Evaluează fiabilitatea progronei."

Exercițiu:

1. Rulați prompt-ul într-un LLM (Large Language Model) la alegere și analizați critic răspunsul.
2. Descărcați date reale EUR/RON și reproduceți analiza. Rezultatele coincid?
3. Testul ADF e specificat corect (trend, lag-uri)? Ce se schimbă dacă modificați opțiunile?
4. Comparați progrona modelului AI cu un benchmark naiv ($\hat{X}_{t+1} = X_t$).
5. Dacă seria e un mers aleatoriu, are sens să ajustăm un model ARMA?

Atenție: Un RMSE (Root Mean Squared Error) mic și coeficienți semnificativi *nu garantează* o progrona utilă.



Concluzii principale

Rezumat

- **Proces stochastic:** colecție de variabile aleatoare indexate în timp
- **Stationaritate slabă:** medie, variantă, autocovariantă constante
- **Zgomot alb:** $\varepsilon_t \sim WN(0, \sigma^2)$
 - ▶ Staționar, $ACF = 0$ pentru $h \neq 0$
- **Mers aleator:** $X_t = X_{t-1} + \varepsilon_t$
 - ▶ Nestaționar, $Var(X_t) = t\sigma^2$
- **ACF/PACF:** instrumente esențiale pentru identificarea structurii
- **Diferențierea:** transformă serii nestaționare în staționare
- **Teste rădăcină unitate:**
 - ▶ ADF (H_0 : rădăcină unitate) vs KPSS (H_0 : staționar)



Formule importante

Stationaritate slabă

- **Momente constante:**
 - ▶ $\mathbb{E}[X_t] = \mu$ (medie constantă)
 - ▶ $\text{Var}(X_t) = \sigma^2$ (varianță constantă)
- **Autocovarianță:** $\gamma(h) = \text{Cov}(X_t, X_{t+h})$
- **Autocorelație:** $\rho(h) = \gamma(h)/\gamma(0)$

Operatorul lag

- **Lag:** $LX_t = X_{t-1}$
- **Diferență:** $\Delta X_t = (1 - L)X_t$

Zgomot alb (WN)

- **Model:** $\varepsilon_t \sim WN(0, \sigma^2)$
- **ACF:** $\rho(h) = 0$ pentru $h \neq 0$

Mers aleator (RW)

- **Model:** $X_t = X_{t-1} + \varepsilon_t$
- **Varianță:** $\text{Var}(X_t) = t\sigma^2$ (crește!)



Ce urmează

Capitolul 2: Modele ARMA

- AR(p):** Modele Autoregresive
- MA(q):** Modele Medie Mobilă
- ARMA(p, q):** Modele combinate
- Identificare:** Cu ACF/PACF

Ce vom învăța

- Estimare:** Parametrii modelului
- Diagnostic:** Verificarea modelului
- Prognoză:** Intervale de încredere
- Selectie:** AIC (Akaike Information Criterion), BIC (Bayesian Information Criterion)



Întrebarea 1

Întrebare

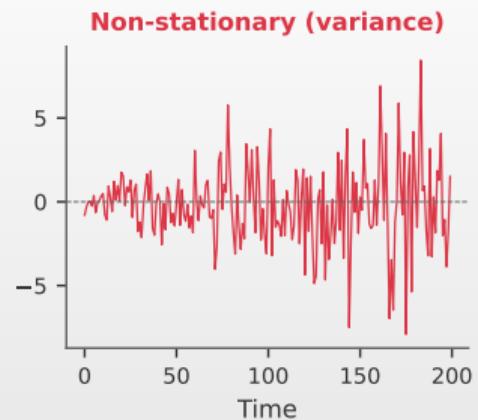
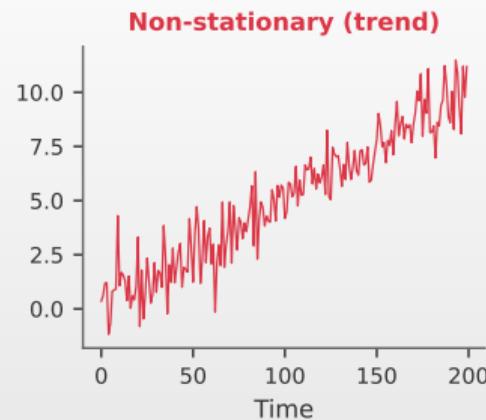
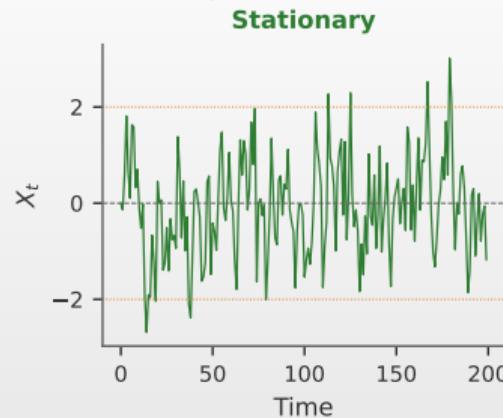
- Care sunt cele trei condiții pentru staționaritatea slabă (în covarianță)?

Variante de răspuns

- (A)** Media zero, varianța infinită, covarianță dependentă de timp
- (B)** Media constantă, varianța constantă, autocovarianța depinde doar de lag
- (C)** Distribuție normală, independentă, varianță unitară
- (D)** Trend liniar, sezonalitate constantă, reziduuri albe



Întrebarea 1: Răspuns



Răspuns: (B)

- $\mathbb{E}[X_t] = \mu, \text{Var}(X_t) = \sigma^2, \gamma(t, s) = \gamma(|t - s|)$

Q TSA_ch1_stationarity



Întrebarea 2

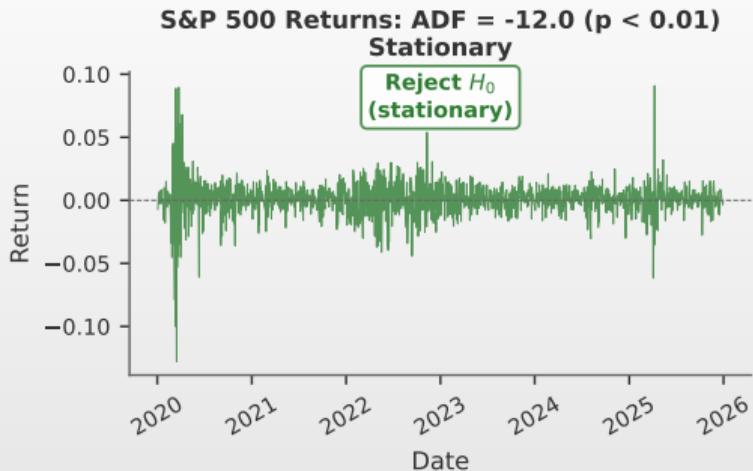
Întrebare

- Care este ipoteza nulă (H_0) în testul ADF (Augmented Dickey-Fuller)?

Variante de răspuns

- (A)** Seria este staționară
- (B)** Seria are rădăcină unitate (este nestaționară)
- (C)** Seria nu are autocorelație
- (D)** Seria are distribuție normală

Întrebarea 2: Răspuns



Răspuns: (B)

- H_0 : rădăcină unitate; $\tau <$ val. critică \Rightarrow staționară



Întrebarea 3

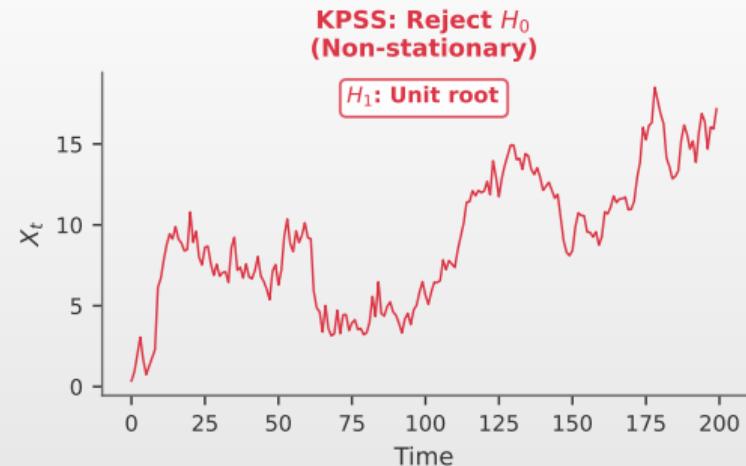
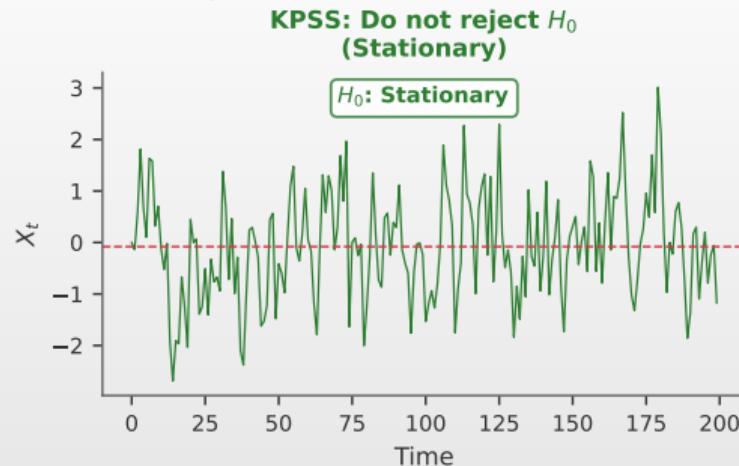
Întrebare

- Care este ipoteza nulă (H_0) în testul KPSS?

Variante de răspuns

- (A)** Seria are rădăcină unitate (nestaționară)
- (B)** Seria este staționară
- (C)** Seria este un mers aleatoriu
- (D)** Seria are trend determinist

Întrebarea 3: Răspuns



Răspuns: (B)

- KPSS: H_0 staționară (opus ADF). Folosiți ambele teste!



Întrebarea 4

Întrebare

Care este proprietatea fundamentală a varianței unui mers aleatoriu $X_t = X_{t-1} + \varepsilon_t$?

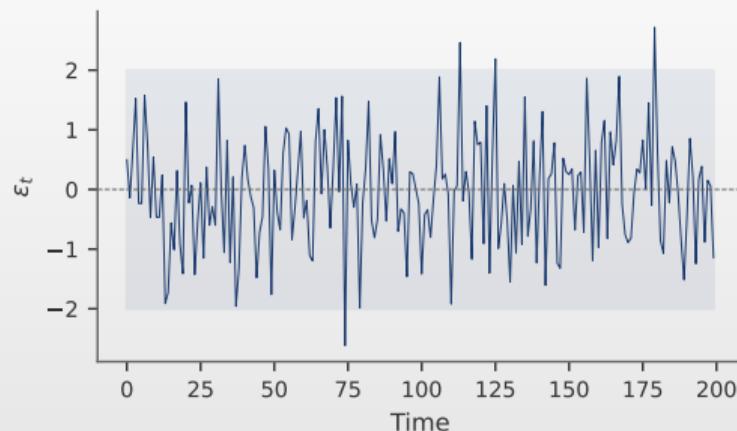
Variante de răspuns

- (A) Varianța este constantă: $\text{Var}(X_t) = \sigma^2$
- (B) Varianța crește liniar cu timpul: $\text{Var}(X_t) = t\sigma^2$
- (C) Varianța scade cu timpul
- (D) Varianța este zero

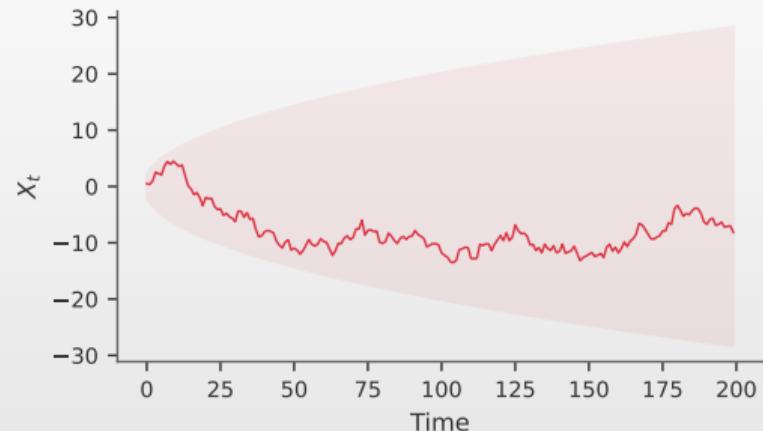


Întrebarea 4: Răspuns

White noise: $\text{Var} = \sigma^2$ (const.)



Random walk: $\text{Var} = t\sigma^2$ (grows!)



Răspuns: (B)

- $\text{Var}(X_t) = t\sigma^2$ crește liniar \Rightarrow nestaționar

Q TSA_ch1_random_walk



Întrebarea 5

Întrebare

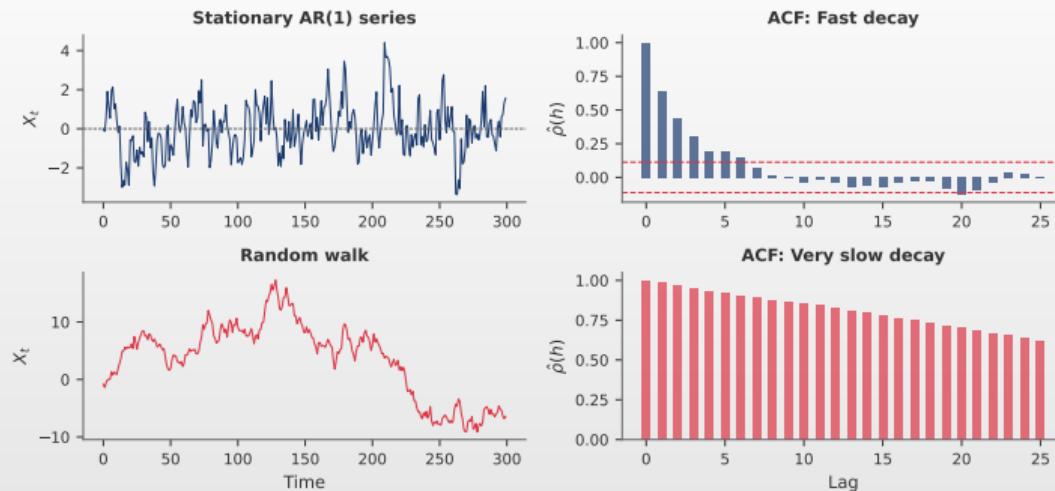
- Cum arată ACF-ul unui mers aleatoriu (serie nestaționară cu rădăcină unitate)?

Variante de răspuns

- (A)** Toate valorile sunt zero după lag 0
- (B)** Scade exponențial rapid
- (C)** Scade foarte lent (persistență ridicată)
- (D)** Oscilează între pozitiv și negativ



Întrebarea 5: Răspuns



Răspuns: (C)

- ACF ≈ 1 pentru multe lag-uri, scădere lentă \Rightarrow test ADF

Q TSA_ch1_random_walk



Întrebarea 6

Întrebare

Cum obținem randamente staționare dintr-o serie de prețuri financiare P_t ?

Variante de răspuns

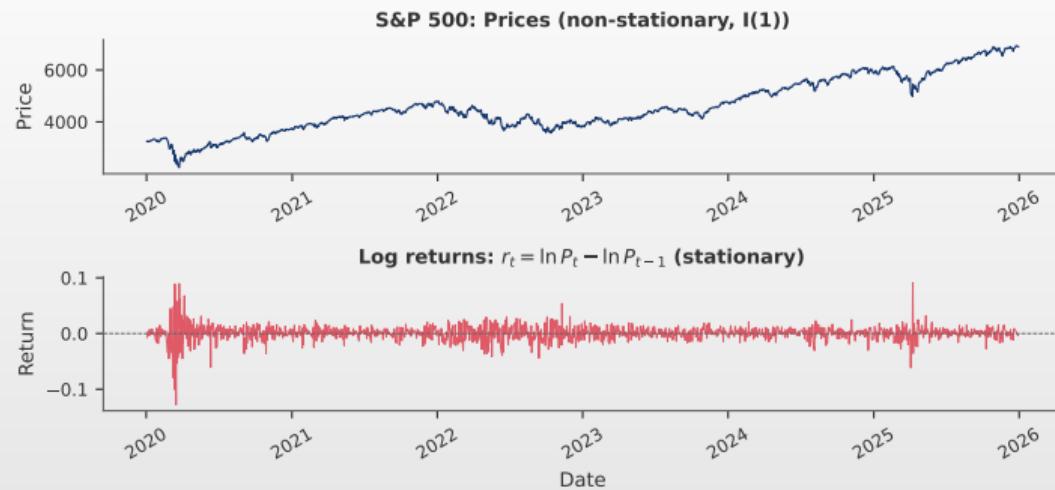
(A) Diferențiere simplă: $\Delta P_t = P_t - P_{t-1}$

(B) Logaritmare apoi diferențiere: $r_t = \ln P_t - \ln P_{t-1}$

(C) Doar logaritmare: $\ln P_t$

(D) Standardizare: $(P_t - \bar{P})/s_P$

Întrebarea 6: Răspuns



Răspuns: (B)

- Randamente log: $r_t = \ln P_t - \ln P_{t-1}$
- Mai întâi \ln (stabilizează varianța), apoi Δ (elimină trendul) \Rightarrow serie staționară



Bibliografie I

Manuale fundamentale

- Hamilton, J.D. (1994). *Time Series Analysis*, Princeton University Press.
- Hyndman, R.J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*, 3rd ed., OTexts.
- Shumway, R.H., & Stoffer, D.S. (2017). *Time Series Analysis and Its Applications*, 4th ed., Springer.

Referințe clasice

- Wold, H. (1938). *A Study in the Analysis of Stationary Time Series*, Almqvist & Wiksell.
- Bartlett, M.S. (1946). On the Theoretical Specification and Sampling Properties of Autocorrelated Time-Series, *JRSS Supplement*, 8(1), 27–41.
- Box, G.E.P., & Jenkins, G.M. (1970). *Time Series Analysis: Forecasting and Control*, Holden-Day.



Bibliografie II

Teste de staționaritate

- Dickey, D.A., & Fuller, W.A. (1979). Distribution of the Estimators for Autoregressive Time Series with a Unit Root, *JASA*, 74(366), 427–431.
- Kwiatkowski, D., et al. (1992). Testing the Null Hypothesis of Stationarity, *Journal of Econometrics*, 54(1–3), 159–178.

Resurse online și cod

- **Quantlet:** <https://quantlet.com> – Platformă de cod pentru metode cantitative
- **Quantinar:** <https://quantinar.com> – Platformă de învățare pentru metode cantitative
- **GitHub TSA:** https://github.com/QuantLet/TSA/tree/main/TSA_ch1 – Cod Python pentru acest capitol



Vă Mulțumim!

Întrebări?

Materialele cursului sunt disponibile la: <https://danpele.github.io/Time-Series-Analysis/>

