



Analiza și Prognoza Seriilor de Timp

Capitolul 5: Modele ARCH/GARCH pentru Volatilitate



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Obiective de învățare

La finalul acestui capitol, veți fi capabili să:

1. Înțelegeți **volatility clustering** și faptele stilizate ale randamentelor financiare
2. Estimați și interpretați modele **ARCH** (Autoregressive Conditional Heteroskedasticity) și **GARCH** (Generalized ARCH)
3. Aplicați modele asimetrice (**EGARCH** — Exponential GARCH, **GJR-GARCH** — Glosten-Jagannathan-Runkle) pentru efectul de levier
4. Efectuați validarea și selectarea modelelor
5. Prognozați volatilitatea și calculați **Value at Risk (VaR)**

Competențe practice

- Implementare Python cu pachetul `arch` (estimare, prognoză, diagnostic)
- Interpretarea parametrilor și a persistenței volatilității
- Calculul VaR pentru managementul riscului (backtesting și validare)

Cuprins

Fundamente teoretice


- ▣ Motivație și fapte stilizate (regularități empirice consistente)
- ▣ Modelul ARCH
- ▣ Modelul GARCH și extensii
- ▣ Modele GARCH asimetrice
- ▣ Selectarea și diagnosticarea modelelor
- ▣ Prognoza volatilității

Aplicații și studii de caz

- ▣ VaR, ES și backtesting
- ▣ Studiu de caz: S&P 500
- ▣ Studiu de caz: Bitcoin
- ▣ Modele GARCH multivariate → *Cap. 5b*
- ▣ Utilizare IA în econometrie
- ▣ Rezumat și quiz

Volatility clustering

- Perioadele de volatilitate mare sunt urmate de perioade de volatilitate mare, iar perioadele de volatilitate redusă sunt urmate de perioade de volatilitate redusă
- **Takeaway:** Volatility clustering este vizibil **chiar înainte de modelare** — este primul semn că varianța nu este constantă



De ce modelăm volatilitatea?

Observații empirice în seriile financiare

- ▣ Randamentele prezintă **volatility clustering** — perioadele de volatilitate ridicată sunt urmate de perioade similare
- ▣ Distribuția randamentelor are **cozi groase** (leptokurtosis — distribuție cu cozi mai groase decât normala, $kurtosis > 3$)
- ▣ Corelația randamentelor ≈ 0 , dar corelația pătratelor este semnificativă
- ▣ Volatilitatea răspunde **asimetric** la șocuri (leverage effect — scăderile de preț cresc volatilitatea mai mult decât creșterile de aceeași magnitudine)

Ideea centrală a capitolului

- ▣ Chiar dacă randamentele sunt greu de prognozat, volatilitatea lor este adesea prognozabilă.
- ▣ Modelele ARIMA presupun **varianță constantă** (homoscedasticitate) — ipoteză nerealistă pentru seriile financiare

De ce ne pasă de volatilitate condiționată?

Aplicații directe în finanțe

- ▣ **Value at Risk (VaR) și Expected Shortfall (ES):** cerințe de capital Basel III/IV (cadrul de reglementare bancară internațional)
- ▣ **Prețul opțiunilor:** volatilitatea implicită vs realizată
- ▣ **Hedging dinamic:** rapoarte de acoperire optime $h_t^* = \sigma_{12,t} / \sigma_{22,t}$
- ▣ **Margining:** casele de compensare recalculează zilnic marjele
- ▣ **Capital economic / reglementar:** FRTB (Fundamental Review of the Trading Book), stress testing
- ▣ **Alocarea portofoliului:** ponderi Markowitz cu H_t variabilă în timp

Concluzie

- ▣ Volatilitatea condiționată nu este un exercițiu academic — este **ingredientul central** al managementului cantitativ al riscului


Exemplu: DAX – volatility clustering

Observații

- ▣ Randamente zilnice DAX (2015–2024): volatility clustering pronunțat
 - ▶ Episoade de volatilitate extremă în perioadele de criză (Brexit 2016, COVID 2020, războiul din Ucraina 2022)
- ▣ Zonele roșii marchează regimurile de volatilitate ridicată (top 10% din volatilitatea pe 21 zile)
 - ▶ Perioadele de calm și agitație se succed — nu apar aleatoriu

Exemplu: DAX – volatility clustering

- **Takeaway:** Randamentele zilnice arată alternanța calm/criză — un model cu varianță constantă nu captează acest fenomen




Fapte stilizate ale randamentelor financiare

Proprietăți observate


- ▣ **Absența autocorelației** în randamente
 - ▶ $\text{Corr}(r_t, r_{t-k}) \approx 0$ — randamentele sunt imprevizibile
- ▣ **Autocorelație** în r_t^2 , $|r_t|$
 - ▶ $\text{Corr}(r_t^2, r_{t-k}^2) > 0$ — volatilitatea este predictibilă
- ▣ **Cozi groase** (kurtosis — măsura „grosimii” cozilor distribuției; Normal: $\kappa = 3$; aici > 3)
 - ▶ Mai multe valori extreme decât prevede distribuția normală
- ▣ **Leverage effect**
 - ▶ Șocurile negative cresc volatilitatea mai mult decât cele pozitive
- ▣ **Volatility clustering**
 - ▶ Perioadele de volatilitate mare sunt urmate de volatilitate mare

Fapte stilizate ale randamentelor financiare



Exemplu: Bitcoin – evidență pentru efecte ARCH

- ACF (Autocorrelation Function) pe r_t^2 semnificativă la multe lag-uri $\Rightarrow$ **efecte ARCH prezente**
- **Takeaway:** ACF pe pătrate sugerează dependență în momentul al doilea — chiar dacă ACF pe randamente ≈ 0



TSA_ch5_btc_arch

Heteroscedasticitate condiționată

Definiție 1 (Varianță Condiționată)

Pentru o serie de randamente $\{r_t\}$, varianța condiționată la momentul t :

$$\sigma_t^2 = \text{Var}(r_t \mid \mathcal{F}_{t-1}) = \mathbb{E}[(r_t - \mu_t)^2 \mid \mathcal{F}_{t-1}]$$

unde $\mathcal{F}_{t-1}$ = informația disponibilă până la $t-1$.

Modelul general


$$r_t = \mu_t + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \sim \text{i.i.d.}(0, 1) \quad (\text{independent și identic distribuit})$$

- μ_t = media condiționată (ARMA); σ_t^2 = varianța condiționată (GARCH)
- z_t = inovații standardizate (Normal, Student- t , GED — Generalized Error Distribution)

Volatilitate condiționată vs necondiționată

Interpretare

- ▣ **Volatilitate condiționată** σ_t (GARCH): variabilă în timp, reacționează la informații noi
- ▣ **Volatilitate necondiționată** $\bar{\sigma} = \sqrt{\omega/(1 - \alpha - \beta)}$: nivel constant pe termen lung
- ▣ Zone roșii: $\sigma_t > \bar{\sigma}$ (perioade de stres); zone albastre: $\sigma_t < \bar{\sigma}$ (perioade calme)



Cuprins

- Motivație
- Introducere în Modelarea Volatilității
- **Modelul ARCH**
- Modelul GARCH
- Modele GARCH Asimetrice
- Selectarea și Diagnosticarea modelelor
- Prognoza volatilității
- VaR Backtesting și Implementare
- Studiu de Caz: S&P 500
- Studiu de Caz: Bitcoin
- Utilizare IA
- Rezumat
- Quiz
- Bibliografie

Portret de cercetător: Engle & Bollerslev



Robert Engle (*1942)
Premiul Nobel 2003

 [Wikipedia \(en\)](#)



Tim Bollerslev (*1958)

 [Wikipedia \(en\)](#)

Biografie

- ▣ **Robert Engle:** economist american la NYU Stern. Premiul Nobel (2003) „pentru metode de analiză a seriilor economice cu volatilitate variabilă în timp (ARCH)”
- ▣ **Tim Bollerslev:** economist danez-american la Duke University, doctorand al lui Engle

Contribuții principale

- ▣ **Modelul ARCH** (Engle, 1982) — heteroscedasticitate condiționată autoregresivă
- ▣ **Modelul GARCH** (Bollerslev, 1986) — ARCH generalizat cu volatilitate persistentă
- ▣ **Volatilitatea realizată** și econometria de înaltă frecvență
- ▣ Fundamentul managementului modern al riscului financiar (VaR, ES)

Baza econometriei moderne a volatilității și a managementului cantitativ al riscului.

Modelul ARCH(q) — Engle (1982)

Definiție 1 (ARCH(q))

Modelul **Autoregressive Conditional Heteroskedasticity** de ordin q :

$$\varepsilon_t = \sigma_t z_t, \quad z_t \sim \text{i.i.d.}(0, 1), \quad \sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2$$


Restricții pentru staționaritate

- ▣ $\omega > 0$ (nivel de bază pozitiv), $\alpha_i \geq 0$ (non-negativitate)
- ▣ $\sum_{i=1}^q \alpha_i < 1$ (staționaritate)

Simulare ARCH(1): Efectul parametrului α

Interpretare

- Cu cât α este mai mare, cu atât volatilitatea reacționează mai puternic la șocuri recente



Simulare ARCH(1): ce observăm în serie?

Citirea graficului de simulare

- ▣ α **mic** (e.g., 0.1): seria arată aproape ca zgomot alb — clustering ușor, spike-uri rare
- ▣ α **moderat** (e.g., 0.5): spike-uri vizibile, dar se sting rapid (1–2 perioade) — “memorie scurtă”
- ▣ α **mare** (e.g., 0.9): volatilitate explozivă — spike-uri foarte mari, dar tot fără persistență reală

Diferența cheie: ARCH vs GARCH

- ▣ ARCH reacționează doar la **ultimul șoc** (ε_{t-1}^2) — volatilitatea crește brusc dar scade la fel de brusc
- ▣ Nu captează perioadele lungi de volatilitate ridicată observate pe piețe
- ▣ GARCH adaugă $\beta\sigma_{t-1}^2$ = “memorie”

Exemplu vizual

- ▣ Comparați: în simularea ARCH(1), benzile $\pm 2\sigma$ au spike-uri înguste (1 zi)
- ▣ Pe S&P 500 real, episoadele de volatilitate durează săptămâni $\Rightarrow$ ARCH este insuficient

Proprietăți ale modelului ARCH(1)

Propoziție 1 (Proprietăți ARCH(1): $\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2$)

- ▣ **Varianța necondiționată:** $\mathbb{E}[\varepsilon_t^2] = \frac{\omega}{1-\alpha_1}$ (dacă $\alpha_1 < 1$)
- ▣ **Kurtosis:** $\kappa = 3 \cdot \frac{1-\alpha_1^2}{1-3\alpha_1^2}$ (dacă $\alpha_1^2 < 1/3$; $z_t \sim N(0, 1)$)
- ▣ Kurtosis > 3 pentru $\alpha_1 > 0 \Rightarrow$ **cozi groase!**

Observație 1 (Dependența de distribuția inovațiilor)

Formula presupune $z_t \sim N(0, 1)$; sub Student- t , kurtosisul necondiționat se modifică.

Exemplu numeric

- ▣ Dacă $\omega = 0.0001$ și $\alpha_1 = 0.3$:
 - ▶ Varianța necondiționată: $\sigma^2 = \frac{0.0001}{1-0.3} = 0.000143$
 - ▶ Kurtosis: $\kappa = 3 \cdot \frac{1-0.09}{1-0.27} = 3.74 > 3$

Demonstrație: varianța necondiționată ARCH(1)**Demonstrație.**

Fie $\varepsilon_t = \sigma_t z_t$ cu $z_t \sim N(0, 1)$ și $\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2$.

Pasul 1: Aplicăm media necondiționată:

$$\mathbb{E}[\varepsilon_t^2] = \mathbb{E}[\sigma_t^2 z_t^2] = \mathbb{E}[\sigma_t^2] \cdot \mathbb{E}[z_t^2] = \mathbb{E}[\sigma_t^2]$$

(independență: σ_t^2 este $\mathcal{F}_{t-1}$ -măsurabil, $z_t \perp \mathcal{F}_{t-1}$)

Pasul 2: Aplicăm media ecuației varianței:

$$\mathbb{E}[\sigma_t^2] = \mathbb{E}[\omega + \alpha_1 \varepsilon_{t-1}^2] = \omega + \alpha_1 \mathbb{E}[\varepsilon_{t-1}^2]$$

Pasul 3: Prin staționaritate, $\mathbb{E}[\varepsilon_t^2] = \mathbb{E}[\varepsilon_{t-1}^2] = \sigma^2$:

$$\sigma^2 = \omega + \alpha_1 \sigma^2 \quad \Rightarrow \quad \sigma^2(1 - \alpha_1) = \omega$$

Rezultat:

$$\sigma^2 = \frac{\omega}{1 - \alpha_1}$$

(necesită $\alpha_1 < 1$ pentru staționaritate)



Demonstrație: kurtosis ARCH(1)

Pentru $\varepsilon_t = \sigma_t z_t$ cu $z_t \sim N(0, 1)$:

Pasul 1: $\mathbb{E}[\varepsilon_t^4] = \mathbb{E}[\sigma_t^4] \cdot \mathbb{E}[z_t^4] = 3\mathbb{E}[\sigma_t^4]$ (deoarece $\mathbb{E}[z^4] = 3$)

Pasul 2: Folosind $\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2$:

$$\mathbb{E}[\sigma_t^4] = \mathbb{E}[(\omega + \alpha_1 \varepsilon_{t-1}^2)^2] = \omega^2 + 2\omega\alpha_1\sigma^2 + \alpha_1^2\mathbb{E}[\varepsilon_{t-1}^4]$$

Pasul 3: Rezolvând recurența:

$$\kappa = \frac{\mathbb{E}[\varepsilon_t^4]}{(\mathbb{E}[\varepsilon_t^2])^2} = 3 \cdot \frac{1 - \alpha_1^2}{1 - 3\alpha_1^2}$$


Interpretare

- ▣ $\kappa > 3$ pentru orice $\alpha_1 > 0 \Rightarrow$ **cozi groase** (leptokurtosis)
- ▣ Necesită $\alpha_1 < 1/\sqrt{3} \approx 0.577$ pentru moment de ordin 4 finit
- ▣ ARCH generează în mod natural distribuții cu cozi groase.

Distribuția Normală (Gaussiană)

Densitatea de probabilitate (PDF)

- ▣ $f(x | \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$; Parametri: μ (medie), $\sigma > 0$ (abatere standard)
- ▣ Kurtosis: $\kappa = 3$ (referință — distribuția mesokurtică)
- ▣ Limitare: **subestimează** frecvența valorilor extreme în seriile financiare




Distribuția Student- t

PDF

$$f(x | \nu) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi} \Gamma(\frac{\nu}{2})} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

$\nu > 2$; $\nu \rightarrow \infty \Rightarrow N(0, 1)$; Kurtosis: $\kappa = 3 + 6/(\nu-4)$. **Avantaj:** cozi groase controlate de ν




 TSA_ch5_distributions

Distribuția GED (Generalized Error Distribution)

PDF

$$f(x | \nu) = \frac{\nu \exp\left(-\frac{1}{2} \left|\frac{x}{\lambda}\right|^\nu\right)}{\lambda \cdot 2^{1+1/\nu} \cdot \Gamma(1/\nu)}, \quad \lambda = \sqrt{2^{-2/\nu} \cdot \frac{\Gamma(1/\nu)}{\Gamma(3/\nu)}}$$

$\nu=2$: Normal; $\nu=1$: Laplace; $\nu \rightarrow \infty$: Uniform. **Avantaj**: un parametru controlează forma distribuției



Testarea efectelor ARCH

Testul Engle (ARCH-LM)

Procedură:

1. Estimează modelul pentru medie și obține reziduurile $\hat{\varepsilon}_t$
2. Regresează $\hat{\varepsilon}_t^2$ pe lag-urile sale:
$$\hat{\varepsilon}_t^2 = \beta_0 + \beta_1 \hat{\varepsilon}_{t-1}^2 + \cdots + \beta_q \hat{\varepsilon}_{t-q}^2 + u_t$$
3. Statistica $LM = T \cdot R^2 \sim \chi^2(q)$

Ipoteze


- H_0 : Nu există efecte ARCH ($\beta_1 = \cdots = \beta_q = 0$)
- H_1 : Există efecte ARCH (cel puțin un $\beta_i \neq 0$)

Corelograma pătratelor reziduurilor

Diagnostic vizual pentru efecte ARCH

- Dacă $\hat{\varepsilon}_t$ sunt i.i.d., atunci $\hat{\varepsilon}_t^2$ nu prezintă autocorelație
- ACF semnificativă a lui $\hat{\varepsilon}_t^2 \Rightarrow$ **heteroscedasticitate condiționată**

S&P 500 — Autocorrelation of Squared Returns



Limitări ale modelului ARCH

Probleme practice

1. **Ordin mare** — de obicei sunt necesare multe lag-uri (q mare)
2. **Mulți parametri** — dificultăți de estimare
3. **Restricții de non-negativitate** — greu de impus pentru q mare
4. **Nu capturează persistența** — volatilitatea observată este foarte persistentă

Soluția

- ☐ **Modelul GARCH** — introduce lag-uri ale varianței condiționate pentru a captura persistența cu mai puțini parametri.

Cuprins

- Motivație
- Introducere în Modelarea Volatilității
- Modelul ARCH
- **Modelul GARCH**
- Modele GARCH Asimetrice
- Selectarea și Diagnosticarea modelelor
- Prognoza volatilității
- VaR Backtesting și Implementare
- Studiu de Caz: S&P 500
- Studiu de Caz: Bitcoin
- Utilizare IA
- Rezumat
- Quiz
- Bibliografie

Modelul GARCH(1,1)

De ce GARCH? Limitările ARCH

- ▣ ARCH(q) necesită multe lag-uri pentru a captura persistența volatilității $\Rightarrow$ mulți parametri, restricții dificile
- ▣ **GARCH** rezolvă problema adăugând un singur termen: σ_{t-1}^2

Cel mai popular model de volatilitate

- ▣ $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$


Propoziție 1 (Restricții și proprietăți GARCH(1,1))

- ▣ $\omega > 0, \alpha \geq 0, \beta \geq 0; \quad \alpha + \beta < 1$ (staționaritate)
- ▣ $\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta}; \quad \text{Half-life: } HL = \frac{\ln(0.5)}{\ln(\alpha+\beta)}$

Modelul GARCH(1,1): volatilitate condiționată vs $|r_t|$

Interpretare

- ▣ $\hat{\sigma}_t$ (roșu) urmărește fidel $|r_t|$ (gri) — GARCH captează dinamica volatilității
- ▣ În crize (2020, 2022): $\hat{\sigma}_t$ crește rapid; în calm: revine la media de echilibru



Modelul GARCH(p,q) — Bollerslev (1986)

Definiție 1 (GARCH(p,q))

Modelul **Generalized ARCH**:

$$\varepsilon_t = \sigma_t z_t, \quad z_t \sim \text{i.i.d.}(0, 1)$$
$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$$

Interpretare

- ▣ ω = nivel de bază al volatilității
- ▣ α_i = reacția la șocuri recente (coeficienți de impact)
- ▣ β_j = persistența volatilității (memorie)
- ▣ $\alpha + \beta$ = persistența totală

Cum citesc un model GARCH în 30 de secunde

Structura unui model GARCH(1,1)

▣ **Ecuția mediei:** $r_t = \mu + \varepsilon_t$, $\varepsilon_t = \sigma_t z_t$, $z_t \sim D(0, 1)$

▣ **Ecuția varianței:**

$$\sigma_t^2 = \underbrace{\omega}_{\text{bază}} + \underbrace{\alpha \varepsilon_{t-1}^2}_{\text{reacție la șoc}} + \underbrace{\beta \sigma_{t-1}^2}_{\text{persistență}}$$

Interpretare economică a parametrilor

- ▣ α **mare** $\Rightarrow$ piață **foarte sensibilă** la informație nouă (șocuri bruște)
- ▣ β **mare** $\Rightarrow$ șocurile de volatilitate se **sting lent** (inerție)
- ▣ $\alpha + \beta$ aproape de 1 $\Rightarrow$ volatilitate **foarte persistentă** (aproape de IGARCH)
- ▣ $\omega / (1 - \alpha - \beta)$ = varianța necondiționată (nivelul de echilibru pe termen lung)


Alegerea distribuției z_t

- ▣ **Normal:** simplu, dar subestimează riscul de coadă
- ▣ **Student-t:** cozi mai groase $\Rightarrow$ VaR mai realist; **alegerea standard** în practică

Simulare GARCH(1,1): efectul persistenței

Interpretare

- ▣ α controlează reacția la șocuri
- ▣ β controlează persistența
- ▣ Suma $\alpha + \beta$ determină viteza de revenire la medie



Simulare GARCH(1,1): ce observăm în serie?

Citirea graficului de simulare

- ▣ $\alpha + \beta$ **mic** (0.7): volatilitatea revine rapid la medie — serie aproape de zgomot alb
- ▣ $\alpha + \beta$ **moderat** (0.95): episoade de volatilitate durează săptămâni — asemănător seriilor financiare
- ▣ $\alpha + \beta \approx 1$ (0.99): volatilitatea persistă luni de zile — half-life ≈ 69 zile

Identificare vizuală: half-life

- ▣ Half-life: $HL = \ln(0.5) / \ln(\alpha + \beta)$
- ▣ $\alpha + \beta = 0.95$: $HL \approx 14$ zile (2 săpt.) $\alpha + \beta = 0.988$: $HL \approx 58$ zile (3 luni, tipic S&P 500)

Regulă practică

Dacă benzile $\pm 2\sigma_t$ nu revin la normal în 1–2 luni, piața are persistență ridicată ($\alpha + \beta > 0.97$)

Demonstrație: varianța necondiționată GARCH(1,1)

Demonstrație.

Pentru $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$:

Pasul 1: Aplicăm media necondiționată: $\mathbb{E}[\sigma_t^2] = \omega + \alpha \mathbb{E}[\varepsilon_{t-1}^2] + \beta \mathbb{E}[\sigma_{t-1}^2]$

Pasul 2: Prin staționaritate, $\mathbb{E}[\sigma_t^2] = \mathbb{E}[\sigma_{t-1}^2] = \bar{\sigma}^2$ și $\mathbb{E}[\varepsilon_t^2] = \bar{\sigma}^2$: $\bar{\sigma}^2 = \omega + (\alpha + \beta)\bar{\sigma}^2$

Pasul 3: Rezolvăm: $\bar{\sigma}^2(1 - \alpha - \beta) = \omega \Rightarrow \bar{\sigma}^2 = \frac{\omega}{1 - \alpha - \beta}$



Condiție de staționaritate

▣ Necesită $\alpha + \beta < 1$ pentru varianță necondiționată finită

Demonstrație: kurtosis GARCH(1,1)

Pentru $\varepsilon_t = \sigma_t z_t$ cu $z_t \sim N(0, 1)$ și $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$:

Pasul 1: $\mathbb{E}[\varepsilon_t^4] = \mathbb{E}[\sigma_t^4 z_t^4] = 3\mathbb{E}[\sigma_t^4]$ (deoarece $\mathbb{E}[z^4] = 3$)

Pasul 2: Folosind $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$, ridicăm la pătrat:

$$\mathbb{E}[\sigma_t^4] = \mathbb{E}[(\omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2)^2]$$

Expandăm și folosim staționaritatea ($\mathbb{E}[\sigma_t^4] = \mathbb{E}[\sigma_{t-1}^4]$, $\mathbb{E}[\varepsilon_t^4] = 3\mathbb{E}[\sigma_t^4]$):

$$\mathbb{E}[\sigma_t^4] = \omega^2 + 2\omega(\alpha + \beta)\bar{\sigma}^2 + (3\alpha^2 + 2\alpha\beta + \beta^2)\mathbb{E}[\sigma_{t-1}^4]$$

Pasul 3: Rezolvând recurența:

$$\kappa_\varepsilon = \frac{\mathbb{E}[\varepsilon_t^4]}{(\mathbb{E}[\varepsilon_t^2])^2} = 3 \cdot \frac{1 - (\alpha + \beta)^2}{1 - (\alpha + \beta)^2 - 2\alpha^2}$$

Interpretare

- ▣ Necesită $1 - (\alpha + \beta)^2 - 2\alpha^2 > 0$ pentru moment de ordin 4 finit
- ▣ GARCH generează **mai mult kurtosis** decât ARCH deoarece $\beta > 0$ amplifică persistența
- ▣ Cu $\alpha = 0.088$, $\beta = 0.900$: $\kappa \approx 5.6$ (vs. ARCH(1): $\kappa \approx 3.05$)

Teorie vs. practică: decalajul de kurtosis

Kurtosis-ul modelului ARCH(1) este prea mic

- ▣ Pentru randamente tipice de acțiuni: $\alpha_1 \approx 0.09$ (S&P 500)
- ▣ Kurtosis-ul teoretic: $\kappa = 3 \cdot \frac{1-0.09^2}{1-3 \times 0.09^2} \approx 3.05$
- ▣ Kurtosis-ul empiric al S&P 500: $\kappa \approx 13.8$

Decalajul de kurtosis

$$\underbrace{3.05}_{\text{ARCH(1)-Normal}} \ll \underbrace{13.8}_{\text{Empiric}}$$

- ▣ ARCH(1) cu inovații gaussiene nu poate reproduce kurtosis-ul extrem observat în datele financiare

Soluții

- ▣ **Inovații Student- t :** $z_t \sim t_\nu$ adaugă kurtosis din distribuția însăși
- ▣ **GARCH(1,1):** persistența ($\beta > 0$) generează kurtosis suplimentar
- ▣ Ambele combinate: Student- t GARCH capturează $\kappa \gg 3$ observat în practică

GARCH(1,1) ca ARMA pentru ε_t^2

Propoziție 2 (Reprezentare ARMA(1,1) a GARCH(1,1))

- Definim $\nu_t = \varepsilon_t^2 - \sigma_t^2$ (șocul varianței). Atunci:

$$\varepsilon_t^2 = \omega + (\alpha + \beta)\varepsilon_{t-1}^2 + \nu_t - \beta\nu_{t-1}$$

- Aceasta este un **ARMA(1,1)** pentru ε_t^2 .

Implicații

- ACF al ε_t^2 decade exponențial (ca ARMA)
- Persistența este dată de $\alpha + \beta$
- PACF (Partial ACF) poate ajuta la identificarea ordinului

Demonstrație: Reprezentarea ARMA a GARCH(1,1)

Demonstrație.

Pasul 1: Definim șocul varianței: $\nu_t = \varepsilon_t^2 - \sigma_t^2$

$$\square \mathbb{E}[\nu_t | \mathcal{F}_{t-1}] = \mathbb{E}[\varepsilon_t^2 | \mathcal{F}_{t-1}] - \sigma_t^2 = \sigma_t^2 - \sigma_t^2 = 0$$

$\square \nu_t$ este o secvență diferență de martingal

Pasul 2: Înlocuim $\sigma_t^2 = \varepsilon_t^2 - \nu_t$ în ecuația GARCH:

$$\varepsilon_t^2 - \nu_t = \omega + \alpha \varepsilon_{t-1}^2 + \beta (\varepsilon_{t-1}^2 - \nu_{t-1})$$

Pasul 3: Rearanjăm:

$$\varepsilon_t^2 = \omega + (\alpha + \beta) \varepsilon_{t-1}^2 + \nu_t - \beta \nu_{t-1}$$

Rezultat: ARMA(1,1) cu coeficient AR $\phi = \alpha + \beta$ și coeficient MA $\theta = -\beta$. □

Demonstrație: persistența volatilității și half-life

Propoziție 3 (Proгноză multi-pas GARCH(1,1))

$$\square \mathbb{E}_t[\sigma_{t+h}^2] = \bar{\sigma}^2 + (\alpha + \beta)^{h-1}(\sigma_{t+1}^2 - \bar{\sigma}^2)$$

Demonstrație

- $\square$ **Pasul 1:** Notăm $\phi = \alpha + \beta$ și $q_t = \sigma_t^2 - \bar{\sigma}^2$ (deviația de la medie)
- $\square$ **Pasul 2:** Din ecuația GARCH: $\mathbb{E}_t[q_{t+1}] = \phi \cdot q_t$, deci $\mathbb{E}_t[q_{t+h}] = \phi^h \cdot q_t$
- $\square$ **Pasul 3:** Half-life: $\phi^{HL} = 0.5 \Rightarrow HL = \frac{-0.693}{\ln(\alpha+\beta)}$

Exemplu: S&P 500

- $\square$ Cu $\alpha + \beta = 0.988$: $HL = \frac{-0.693}{-0.012} \approx 58$ zile (șocurile persistă ~3 luni!)

De ce funcționează GARCH: intuiția centrală

Ideea fundamentală

- ▣ Randamentele financiare sunt greu de prognozat, dar **volatilitatea lor este prognozabilă**:

$$r_t = \sigma_t \cdot z_t, \quad z_t \sim \text{i.i.d.}(0, 1)$$
- ▶ r_t este impredictibil (piața eficientă), dar σ_t^2 **evoluează lent**
- ▶ GARCH capturează acest lucru: **șocurile afectează volatilitatea pentru multe perioade**

Mecanismul GARCH(1,1)

$$\sigma_t^2 = \underbrace{\omega}_{\text{echilibru}} + \underbrace{\alpha r_{t-1}^2}_{\text{șoc nou}} + \underbrace{\beta \sigma_{t-1}^2}_{\text{memorie}}$$

- ▣ r_{t-1}^2 mare (zi turbulentă) $\Rightarrow$ volatilitatea de azi crește
- ▣ σ_{t-1}^2 mare (volatilitate deja ridicată) $\Rightarrow$ persistă
- ▣ Termen lung: revenire la $\bar{\sigma}^2 = \omega / (1 - \alpha - \beta)$

De ce este important

- ▣ Fără GARCH: VaR constant $\Rightarrow$ subestimează riscul în crize. Cu GARCH: VaR dinamic $\Rightarrow$ se adaptează la condițiile pieței.

Estimarea modelelor GARCH

Metoda verosimilității maxime (MLE — Maximum Likelihood Estimation)

▣ Log-verosimilitate (normală): $\ell(\theta) = -\frac{T}{2} \ln(2\pi) - \frac{1}{2} \sum_{t=1}^T \left[\ln(\sigma_t^2) + \frac{\varepsilon_t^2}{\sigma_t^2} \right]$

Distribuții alternative pentru z_t

- ▣ **Student-t**: capturează cozile groase — cea mai frecventă alegere
- ▣ **GED**: flexibilitate pentru kurtosis
- ▣ **Skewed Student-t**: asimetrie și cozi groase

Notă practică

- ▣ Student-t oferă de regulă potrivire mai bună datorită cozilor groase (kurtosis > 3)

Log-verosimilitatea Student- t

De ce Student- t ?

- ▣ Inovațiile gaussiene subestimează cozile groase: kurtosis fixă la 3
- ▣ Student- t adaugă un parametru $\nu > 2$ (grade de libertate) care controlează grosimea cozilor

Definiție 2 (Log-verosimilitatea Student- t standardizată)

$$\ell_t(\theta, \nu) = \ln \Gamma\left(\frac{\nu+1}{2}\right) - \ln \Gamma\left(\frac{\nu}{2}\right) - \frac{1}{2} \ln[(\nu-2)\pi\sigma_t^2] - \frac{\nu+1}{2} \ln\left(1 + \frac{\varepsilon_t^2}{(\nu-2)\sigma_t^2}\right)$$

unde $\Gamma(\cdot)$ este funcția Gamma, $\nu > 2$, și σ_t^2 este din ecuația GARCH.

Proprietăți

- ▣ Când $\nu \rightarrow \infty$: converge la log-verosimilitatea normală
- ▣ Kurtosis Student- t : $3(\nu-2)/(\nu-4)$ pentru $\nu > 4$ (e.g., $\nu = 6 \Rightarrow \kappa = 6$)
- ▣ ν se estimează simultan cu (ω, α, β) prin MLE

Alegerea distribuției inovațiilor

Normal

- ▣ Simplu, rapid
- ▣ Kurtosis = 3 (fixă)
- ▣ Subestimează extremele
- ▣ VaR 1%: 2.326σ

Student- t

- ▣ Un parametru extra (ν)
- ▣ Kurtosis ajustabilă
- ▣ Cozi groase realiste
- ▣ VaR 1%: $> 2.326\sigma$

GED

- ▣ Parametru formă (ν)
- ▣ Include Normal ($\nu = 2$)
- ▣ Flexibil, dar mai puțin intuitiv
- ▣ Folosit rar în practică

Concluzie

- ▣ În risk management, alegerea distribuției este aproape la fel de importantă ca alegerea dinamicii varianței. Student- t este alegerea standard.

Quasi-MLE și robustețe

Ce se întâmplă dacă distribuția este greșit specificată?

- ▣ MLE standard presupune $z_t \sim N(0, 1)$, dar distribuția reală poate diferi
- ▣ **QMLE** (Quasi-MLE — presupunem distribuție greșită, dar estimatorul rămâne consistent): maximizează log-verosimilitatea gaussiană chiar dacă z_t nu este normal

Teoremă 1 (Consistența QMLE — Bollerslev & Wooldridge (1992))

Dacă media și varianța condiționate sunt corect specificate, QMLE este **consistent** pentru (ω, α, β) indiferent de distribuția reală a lui z_t . *Condiții*: interiorul spațiului parametric, identificabilitate, momente finite.

Erori standard sandwich (combinație Hessian + OPG, robustă la misspecificare)

- ▣ $\hat{V}_{\text{robust}} = \hat{A}^{-1} \hat{B} \hat{A}^{-1}$ (White, 1982); în Python: SE robuste implicit

QMLE vs MLE complet

- ▣ **QMLE**: robust — consistent chiar sub specificare greșită
- ▣ **MLE complet** (Student- t): mai eficient dacă distribuția este corectă

Provocări practice în estimare

Probleme frecvente

- ▣ **Eșec de convergență:** log-verosimilitatea este non-convexă; optimizatorul se poate bloca
- ▣ **Soluții la frontieră:** $\hat{\alpha} \approx 0$ sau $\hat{\alpha} + \hat{\beta} \approx 1$ (aproape IGARCH)
- ▣ **Sensibilitate la valori inițiale:** inițializări diferite $\Rightarrow$ estimări diferite

Bune practici

1. Mai mulți optimizatori: **BFGS** (rapid, bazat pe gradient) vs **Nelder-Mead** (fără derivate)
2. Inițializați σ_0^2 cu varianța eșantionului (backcast — inițializare retrospectivă)
3. Verificați $\alpha + \beta < 1$; dacă ≈ 1 , considerați IGARCH sau schimbare de regim
4. Comparați rezultatele între valori inițiale; estimări consistente $\Rightarrow$ model fiabil

Regulă practică

Dacă BFGS și Nelder-Mead dau estimări *diferite*, modelul poate fi greșit specificat sau datele insuficiente

Valori tipice pentru GARCH(1,1)

Serie	α	β	$\alpha + \beta$
S&P 500 zilnic	0.05–0.10	0.85–0.95	0.95–0.99
EUR/USD zilnic	0.03–0.08	0.90–0.95	0.95–0.99
Bitcoin zilnic	0.10–0.20	0.75–0.85	0.90–0.98
Obligațiuni	0.02–0.05	0.90–0.97	0.95–0.99


Observații

- ▣ $\alpha + \beta$ aproape de 1 $\Rightarrow$ **volatilitate foarte persistentă**
- ▣ α mic, β mare $\Rightarrow$ reacție lentă la șocuri, memorie lungă
- ▣ Bitcoin: α mai mare $\Rightarrow$ reacție mai rapidă la informații noi

GARCH vs IGARCH: comparație persistență

Interpretare

- GARCH standard revine la media necondiționată
- IGARCH nu are medie finită $\Rightarrow$ șocurile persistă indefinit



IGARCH: ce observăm în seria simulată?

Citirea graficului de comparație

- ▣ **GARCH** ($\alpha + \beta < 1$): volatilitatea revine la $\bar{\sigma}^2$ — “valuri” cu amplitudine descrescătoare
- ▣ **IGARCH** ($\alpha + \beta = 1$): fără ancoră — nivelul ridicat persistă indefinit
- ▣ Vizual: IGARCH “rătăcește”, GARCH oscilează în jurul mediei

Cum detectăm IGARCH în practică?

- ▣ Estimăm GARCH(1,1): dacă $\hat{\alpha} + \hat{\beta} > 0.99$, considerăm IGARCH
- ▣ ACF a lui ε_t^2 decade foarte lent (memorie lungă)
- ▣ Frecvent pe piețe valutare (FX — Foreign Exchange) și unele mărfuri

Atenție: IGARCH poate fi artefact al schimbărilor de regim — verificați cu Markov-switching!

IGARCH — integrated GARCH

De ce IGARCH? Persistența extremă

- ▣ Empiric, estimarea GARCH dă frecvent $\hat{\alpha} + \hat{\beta} \approx 0.99$
- ▣ IGARCH formalizează cazul limită $\alpha + \beta = 1$: șocurile au efect permanent, similar unei rădăcini unitare în varianță

Definiție 3 (IGARCH(1,1))

Când $\alpha + \beta = 1$:

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + (1 - \alpha) \sigma_{t-1}^2$$

Propoziție 4 (Proprietăți IGARCH(1,1))

- ▣ Varianța necondiționată nu există (infinită), dar procesul rămâne strict staționar (Nelson, 1990)
- ▣ Șocurile au efect **permanent** — analog cu rădăcina unitară în varianță

Observație 1 (Aplicație practică)

Util pentru **RiskMetrics** (J.P. Morgan): $\alpha = 0.06$, $\beta = 0.94$.

Teorema lui Nelson (1990): Staționaritate strictă IGARCH

Teoremă 2 (Nelson, 1990)

Fie procesul IGARCH(1,1): $\varepsilon_t = \sigma_t z_t$, $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + (1 - \alpha) \sigma_{t-1}^2$, z_t i.i.d., $\mathbb{E}[z_t^2] = 1$. Dacă $\omega > 0$ și $\mathbb{E}[\ln(\alpha z_t^2 + (1 - \alpha))] < 0$, atunci procesul $\{\varepsilon_t\}$ este **strict staționar** și **ergodic**, deși varianța necondiționată este infinită.

Condiția Lyapunov

- Condiția $\mathbb{E}[\ln(\alpha z_t^2 + (1 - \alpha))] < 0$ este echivalentă cu **exponentul Lyapunov de vârf negativ**
- Se verifică pentru distribuții standard ($z_t \sim \mathcal{N}(0, 1)$, t -Student) când $\alpha \in (0, 1)$
- Interpretare: log-volatilitatea $\ln \sigma_t^2$ are o tendință medie de contracție

Schiță de demonstrație

- Se rescrie σ_t^2 ca recurență stocastică: $Y_t = A_t Y_{t-1} + B_t$, unde $A_t = \alpha z_{t-1}^2 + (1 - \alpha)$, $B_t = \omega$
- Se aplică teorema Bougerol & Picard (1992): dacă $\mathbb{E}[\ln A_t] < 0$ și $\mathbb{E}[\ln^+ B_t] < \infty$, seria Y_t converge în distribuție

IGARCH: Staționaritate strictă vs. staționaritate în covarianță

Contrast fundamental

Proprietate	GARCH ($\alpha + \beta < 1$)	IGARCH ($\alpha + \beta = 1$)
Strict staționar	Da	Da (Nelson, 1990)
Staționar în covarianță	Da	Nu ($\text{Var}[\varepsilon_t] = \infty$)
Varianță necondiționată	$\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta}$	Nu există (infinită)
Persistența șocurilor	Geometrică (se estompează)	Permanentă

Implicație practică

- IGARCH este un **model valid**, în ciuda rădăcinii unitare în varianță
- Prognoza varianței condiționate: $\mathbb{E}_t[\sigma_{t+h}^2] = \sigma_t^2 + h\omega$ (creștere liniară)
- Nu implică explozie a procesului: ε_t rămâne bine definit

EWMA: GARCH restricționat pentru RiskMetrics

Definiție 4 (Exponentially Weighted Moving Average)

Modelul **EWMA** (J.P. Morgan RiskMetrics, 1996):

$$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2, \quad \lambda \in (0, 1)$$

Propoziție 5 (EWMA ca caz special al IGARCH)


- ▣ EWMA = **IGARCH(1,1)** cu $\omega = 0$: $\alpha = 1 - \lambda$, $\beta = \lambda$, $\alpha + \beta = 1$
- ▣ Standard industrial: $\lambda = 0.94$ (date zilnice), $\lambda = 0.97$ (date lunare)
- ▣ **Nicio estimare necesară** — parametru fix $\Rightarrow$ simplu, dar rigid

EWMA vs GARCH(1,1)

	EWMA	GARCH(1,1)
Parametri estimați	0 (λ fix)	3 (ω, α, β)
Mean-reversion	Nu (persistență infinită)	Da (dacă $\alpha + \beta < 1$)
Varianță pe termen lung	Nedefinită	$\omega / (1 - \alpha - \beta)$
Utilizare	Basel II, screening rapid	Estimare precisă, VaR

EWMA vs GARCH: comparație vizuală

- EWMA (albastru) reacționează similar cu GARCH (roșu), dar nu revine la nivelul necondiționat



EWMA: interpretare și ce observăm în serie

Citirea seriei EWMA

- ▣ Seria volatilității EWMA urmărește “fidel” pătratele randamentelor — reacție rapidă, fără filtrare
- ▣ Cu $\lambda = 0.94$: ponderea de ieri este 6%, restul vine din istoria exponențial atenuată
- ▣ Vizual: volatilitatea EWMA “lipește” de spike-uri — urcă rapid dar nu revine la un nivel fix

Când este suficient EWMA?

- ▣ **Screening rapid**: nu necesită estimare — calculabil imediat pe orice serie
- ▣ **Basel II/III**: RiskMetrics EWMA rămâne acceptat pentru VaR intern
- ▣ **Real-time monitoring**: simplu de implementat în sisteme de trading

Limitări vizibile în grafic

- ▣ EWMA nu revine la un nivel de echilibru $\bar{\sigma}^2$ (nu are $\omega > 0$)
- ▣ După crize, volatilitatea EWMA rămâne ridicată mai mult decât GARCH — **suprareacționează pe termen mediu**

CGARCH — Component GARCH (Engle & Lee, 1999)

Motivație

- GARCH(1,1) are o **singură componentă** de persistență: nu distinge între șocuri de scurtă și lungă durată
- CGARCH descompune varianța în componentă **permanentă** (trendul) + **tranzitorie**

Definiție 5 (CGARCH(1,1))

$$\sigma_t^2 = q_t + \alpha(\varepsilon_{t-1}^2 - q_{t-1}) + \beta(\sigma_{t-1}^2 - q_{t-1}) \quad (\text{componenta tranzitorie})$$

$$q_t = \bar{\omega} + \rho(q_{t-1} - \bar{\omega}) + \phi(\varepsilon_{t-1}^2 - \sigma_{t-1}^2) \quad (\text{componenta permanentă})$$


unde q_t este tendința pe termen lung, ρ controlează persistența permanentă ($\rho > \alpha + \beta$).

Interpretare

- q_t variază lent (factori macroeconomici); $\sigma_t^2 - q_t$ reacționează rapid la șocuri
- Permite half-life-uri diferite: permanent $\sim$ ani, tranzitoriu $\sim$ săptămâni
- Disponibil în Python: `arch` cu specificare manuală

Simulare CGARCH: componenta permanentă vs tranzitorie

□ q_t (albastru, gros) = trendul pe termen lung; σ_t^2 (roșu, subțire) = volatilitatea totală



CGARCH: ce observăm în practică?

Interpretarea celor două componente

- ▣ **Componenta permanentă** q_t : se mișcă lent — factori macroeconomici (inflație, ciclul economic)
- ▣ **Componenta tranzitorie** $\sigma_t^2 - q_t$: reacționează rapid la știri (earnings, Fed, geopolitică)
- ▣ Vizual: q_t = medie mobilă netedă; σ_t^2 oscilează în jurul ei

Exemplu: S&P 500

- ▣ Componenta permanentă crește 2005–2008, explodează 2008–2009, scade lent după
- ▣ Componenta tranzitorie: spike-uri la Flash Crash (2010), Brexit (2016), COVID (2020)
- ▣ Half-life: permanent ≈ 2 –3 ani; tranzitoriu ≈ 2 –4 săptămâni

Când folosim CGARCH?

- ▣ VaR pe termen lung (1 an+) — componenta permanentă contează pentru Solvency II, stress testing

FIGARCH — Fractionally Integrated GARCH

Motivație: memorie lungă în volatilitate

- ▣ ACF a r_t^2 descrește **hiperbolic** (nu exponențial) $\Rightarrow$ memorie lungă
- ▣ GARCH: descreștere exponențială; IGARCH: persistență infinită — niciunul nu captează memoria lungă

Definiție 6 (FIGARCH(1,d,1) — Baillie, Bollerslev & Mikkelsen (1996))

$$[1 - \beta L] \sigma_t^2 = \omega + [1 - \beta L - (1 - \phi L)(1 - L)^d] \varepsilon_t^2$$


unde $d \in [0, 1]$ este parametrul de integrare fracționară: $d = 0 \Rightarrow$ GARCH, $d = 1 \Rightarrow$ IGARCH.

Proprietăți cheie

- ▣ Ponderile impulsurilor $\lambda_k \sim k^{d-1}$ descrește hiperbolic: șocurile vechi contează, dar tot mai puțin
- ▣ Varianța necondiționată: finită doar dacă $d < 1$ (spre deosebire de IGARCH)
- ▣ Valori empirice tipice: $\hat{d} \approx 0.3\text{--}0.5$ pentru acțiuni (Baillie et al., 1996)

Simulare FIGARCH vs GARCH vs IGARCH

- GARCH: revenire exponențială; FIGARCH: revenire hiperbolică (lentă); IGARCH: persistență infinită



FIGARCH: interpretare și aplicații practice

Ce înseamnă d în practică?

- ▣ $d = 0$ (GARCH): ACF decade exponențial — șocuri se sting rapid
- ▣ $d = 1$ (IGARCH): ACF nu decade — șocuri persistă infinit
- ▣ $0 < d < 1$ (FIGARCH): ACF decade **hiperbolic** — șocuri vechi contează, dar tot mai puțin

Rezultate empirice

- ▣ **Acțiuni** (S&P 500, DAX): $\hat{d} \approx 0.35\text{--}0.50$ **Forex**: $\hat{d} \approx 0.40\text{--}0.60$ **Crypto**: $\hat{d} \approx 0.25\text{--}0.45$

FIGARCH vs IGARCH

- ▣ Dacă $\hat{\alpha} + \hat{\beta} \approx 1$, testați FIGARCH: dacă $\hat{d} < 1$, persistența e lungă, nu infinită

Schimbări de regim în volatilitate

Problemă

- GARCH presupune un **singur regim** cu parametri constanți
- Volatilitatea prezintă adesea **rupturi structurale** (ex. criza 2008, COVID-19)

Definiție 7 (GARCH cu schimbare de regim Markov)

Parametrii (ω, α, β) comută între K regimuri guvernate de un lanț Markov ascuns:

$$\sigma_t^2 = \omega_{s_t} + \alpha_{s_t} \varepsilon_{t-1}^2 + \beta_{s_t} \sigma_{t-1}^2, \quad s_t \in \{1, \dots, K\}$$

Testul ICSS (Iterated Cumulative Sums of Squares) — Inclán-Tiao


- Detectează **puncte de schimbare multiple** în varianța necondiționată (tip CUSUM)
- Rezultate tipice: S&P 500 arată rupturi la 2001, 2008, 2020

Implicații practice

- Dacă rupturile sunt prezente, persistența $(\alpha + \beta)$ este **distorsionată în sus** $\Rightarrow$ IGARCH fals
- Soluție: estimare per regim, ferestre rulante, sau GARCH Markov ($K = 2$)

Simulare Markov-switching GARCH: regimuri de volatilitate

- Regim calm (albastru) vs turbulent (roșu) — volatilitatea sare între niveluri discrete



Schimbări de regim: interpretare și aplicații

Ce vedem în practică?

- ▣ Markov-switching GARCH identifică 2–3 regimuri: **calm** ($\sigma \approx 0.5\text{--}1\%$) vs **turbulent** ($\sigma \approx 2\text{--}4\%$)
- ▣ Probabilitatea regimului turbulent crește brusc la crize (2008, 2020)

Rupturi detectate cu ICSS pe S&P 500

- ▣ **2001**: dot-com crash + 9/11; **2008**: criză financiară globală; **2020**: COVID-19
- ▣ Între rupturi: GARCH cu parametri diferiți este mai precis decât GARCH pe toată perioada

Implicație practică

- ▣ Dacă GARCH dă $\hat{\alpha} + \hat{\beta} \approx 1$, verificați dacă este IGARCH real sau artefact al schimbărilor de regim. Testul ICSS ajută la decizie.

Cuprins

- Motivație
- Introducere în Modelarea Volatilității
- Modelul ARCH
- Modelul GARCH
- **Modele GARCH Asimetrice**
- Selectarea și Diagnosticarea modelelor
- Prognoza volatilității
- VaR Backtesting și Implementare
- Studiu de Caz: S&P 500
- Studiu de Caz: Bitcoin
- Utilizare IA
- Rezumat
- Quiz
- Bibliografie

De la GARCH simetric la modele asimetrice

Ce am învățat până acum

- ▣ GARCH(1,1) capturează volatility clustering și cozi groase
- ▣ IGARCH, CGARCH, FIGARCH — diferite tipuri de persistență

Observație 1 (Limitația simetriei GARCH standard)

- ▣ GARCH tratează **simetric** șocurile: ε_{t-1}^2 nu distinge semnul ε_{t-1}
- ▣ Empiric: un șoc negativ de -5% crește volatilitatea mai mult decât $+5\%$ — **leverage effect** (Black, 1976)

Modele asimetrice prezentate

- ▣ EGARCH · GJR-GARCH · TGARCH · APARCH — toate disting semnul șocului

Leverage effect

Definiție

- ▣ **Leverage effect:** Șocurile negative cresc volatilitatea **mai mult** decât cele pozitive de aceeași magnitudine



Problema GARCH standard

- ▣ GARCH standard: $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$ — doar ε_{t-1}^2 contează, semnul se pierde
- ▣ Intuiție economică: Semnale negative $\Rightarrow$ prețul scade $\Rightarrow$ levierul crește $\Rightarrow$ volatilitatea crește

Evidență empirică

- ▣ Black (1976): prima documentare a efectului de levier pe piața de acțiuni
- ▣ Efectul este asimetric: căderi de 5% cresc volatilitatea mai mult decât creșteri de 5%
- ▣ Soluții: EGARCH, GJR-GARCH, TGARCH — modele care disting semnul șocului

Leverage effect



Modelul EGARCH — Nelson (1991)

De ce EGARCH? Două probleme ale GARCH

- ▣ GARCH tratează șocurile **simetric**: ε_{t-1}^2 nu distinge semnul $\Rightarrow$ nu captează leverage effect
- ▣ GARCH necesită restricții $\omega > 0$, $\alpha, \beta \geq 0$ pentru $\sigma_t^2 > 0 \Rightarrow$ dificil la estimare

Definiție 1 (EGARCH(1,1))

Exponential GARCH: $\ln(\sigma_t^2) = \omega + \alpha (|z_{t-1}| - \mathbb{E}[|z_{t-1}|]) + \gamma z_{t-1} + \beta \ln(\sigma_{t-1}^2)$

unde $z_t = \varepsilon_t / \sigma_t$.


Avantaje EGARCH

- ▣ **Nu necesită restricții de non-negativitate** — modelează $\ln(\sigma_t^2)$
- ▣ **Captează leverage effect**: $\gamma < 0 \Rightarrow$ șocuri negative cresc volatilitatea mai mult
- ▣ Persistența este dată de β

Simulare EGARCH: Efect simetric vs asimetric

Interpretare

- Când $\gamma < 0$, șocurile negative cresc volatilitatea mai mult decât cele pozitive



Simulare EGARCH: ce observăm în serie?

Citirea graficului de simulare

- ▣ **Simetric** ($\gamma = 0$): reacție egală la șocuri + și - (ca GARCH)
- ▣ **Asimetric** ($\gamma < 0$): după șocuri negative, volatilitatea crește brusc și persistent
- ▣ Vizual: spike-uri mai înalte și mai largi după scăderi de piață

Exemplu numeric ($\gamma = -0.15$, $\alpha = 0.10$)

- ▣ Șoc negativ $z_{t-1} = -2$: contribuție = $0.10 \times 2 + 0.15 \times 2 = 0.50$
- ▣ Șoc pozitiv $z_{t-1} = +2$: contribuție = $0.10 \times 2 - 0.15 \times 2 = -0.10$
- ▣ Diferența: **0.60** unități pe scala $\ln(\sigma_t^2)$


Piețele “iau liftul în jos și scările în sus” — volatilitatea crește rapid dar scade lent.

News impact curve – EGARCH

Interpretare

- ▣ **News Impact Curve:** relația între ε_t și σ_{t+1}^2
- ▣ **GARCH:** curba simetrică (parabolă)
 - ▶ Șocuri pozitive și negative au același impact
- ▣ **EGARCH:** curba asimetrică
 - ▶ Șocuri negative au impact mai mare asupra volatilității

News impact curve – EGARCH



EGARCH: aplicații practice

Când folosim EGARCH?

- ▣ **Piețe de acțiuni și indici** — leverage effect pronunțat (Black, 1976)
- ▣ **Avantaj unic:** nu necesită restricții de pozitivitate ($\ln \sigma_t^2$ poate lua orice valoare reală)
- ▣ Util când GARCH simetric dă $\hat{\alpha} + \hat{\beta} > 1$ (artefact al ignorării asimetriei)


Exemplu: S&P 500 — GARCH vs EGARCH

- ▣ GARCH(1,1): subestimează volatilitatea după crash-uri (tratează simetric)
- ▣ EGARCH: volatilitatea crește mai rapid după scăderi, scade mai lent
- ▣ În criza COVID (martie 2020), EGARCH prognozează VaR cu 15–20% mai mare

Regulă practică

- ▣ Testați EGARCH vs GARCH pe date reale: dacă AIC/BIC favorează EGARCH, piața are leverage semnificativ.

EGARCH vs GARCH: EUR/USD — comparație modele



Modelul GJR-GARCH

De ce GJR? Alternativă la EGARCH

- EGARCH modelează $\ln(\sigma_t^2) \Rightarrow$ greu de interpretat economic
- GJR-GARCH rămâne pe scara σ_t^2 dar adaugă un indicator I_{t-1} care activează un termen suplimentar la șocuri negative

Definiție 2 (GJR-GARCH(1,1))

Glosten, Jagannathan & Runkle (1993): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \gamma \varepsilon_{t-1}^2 \cdot I_{t-1} + \beta \sigma_{t-1}^2$ unde $I_{t-1} = 1$ dacă $\varepsilon_{t-1} < 0$, altfel 0.


Interpretare

- Șocuri pozitive: impact = α ; Șocuri negative: impact = $\alpha + \gamma$
- Leverage effect prezent dacă $\gamma > 0$
- Staționaritate: $\alpha + \gamma/2 + \beta < 1$

Simulare GJR-GARCH/TGARCH

Interpretare

- GJR-GARCH adaugă un termen indicator pentru a captura răspunsul asimetric la șocuri negative



GJR-GARCH: ce observăm în seria simulată?

Citirea graficului de simulare

- ▣ $I_{t-1} = \mathbb{1}(\varepsilon_{t-1} < 0)$ se activează doar la șocuri negative
- ▣ Șoc -3% : contribuție $= (\alpha + \gamma) \times 0.09$; Șoc $+3\%$: doar $\alpha \times 0.09$
- ▣ Vizual: benzile $\pm 2\sigma$ se lărgesc de **3**× mai mult după scăderi

Exemplu S&P 500 ($\alpha = 0.05$, $\gamma = 0.10$, $\beta = 0.88$)

- ▣ Zi bună ($+2\%$): $\Delta\sigma_t^2 \approx 0.002\%$
- ▣ Zi rea (-2%): $\Delta\sigma_t^2 \approx 0.006\%$ — **triplu!**

GJR vs EGARCH

- ▣ GJR: scala $\sigma_t^2 \Rightarrow$ interpretare directă
- ▣ EGARCH: scala $\ln(\sigma_t^2) \Rightarrow$ fără restricții de pozitivitate

Modelul APARCH — Ding, Granger & Engle (1993)

Definiție 3 (APARCH(1,1))

Asymmetric Power ARCH — modelul unificator al familiei GARCH:

$$\sigma_t^\delta = \omega + \alpha_1(|\varepsilon_{t-1}| - \gamma_1\varepsilon_{t-1})^\delta + \beta_1\sigma_{t-1}^\delta$$

unde $\delta > 0$ este parametrul de putere și $|\gamma_1| < 1$ captează asimetria.

Cazuri particulare

- ▣ $\delta = 2, \gamma_1 = 0$: **GARCH(1,1)** standard
- ▣ $\delta = 2, \gamma_1 \neq 0$: **GJR-GARCH**
- ▣ $\delta = 1, \gamma_1 \neq 0$: **TGARCH** (Zakoian, 1994)
- ▣ $\delta = 1, \gamma_1 = 0$: **AVGARCH** (Taylor, 1986)


De ce contează APARCH

- ▣ Estimarea lui δ din date (nu fixat la 1 sau 2) poate **îmbunătăți prognoza**
- ▣ Studii empirice: $\hat{\delta} \approx 1.0\text{--}1.5$ pentru acțiuni (Ding et al., 1993)
- ▣ Oferă un **cadru unificator** pentru compararea modelelor asimetrice

Simulare APARCH: cazuri particulare

- APARCH unifică toată familia GARCH: δ și γ controlează puterea și asimetria

APARCH Model: Effect of δ and γ_1 Parameters



APARCH: interpretare și aplicații practice

Ce spune estimarea lui δ ?

- ▣ $\hat{\delta} \approx 2$: piața se comportă ca un GARCH standard (varianța este măsura naturală)
- ▣ $\hat{\delta} \approx 1$: modelarea deviației standard (σ_t) este mai potrivită — ca TGARCH
- ▣ $\hat{\delta} < 1$: randamentele absolute au structură mai puternică decât pătratele

Rezultate empirice tipice

- ▣ **Acțiuni**: $\hat{\delta} \approx 1.0\text{--}1.5$, $\hat{\gamma} \approx 0.3\text{--}0.8$ (leverage puternic)
- ▣ **Forex**: $\hat{\delta} \approx 1.5\text{--}2.0$, $\hat{\gamma} \approx 0$ (simetric, fără leverage)
- ▣ **Crypto**: $\hat{\delta} \approx 1.0\text{--}1.3$, $\hat{\gamma}$ variabil (depinde de perioadă)

Când folosim APARCH?

- ▣ Când nu știm a priori ce putere (δ) sau ce nivel de asimetrie (γ) este optim — APARCH lasă datele să decidă
- ▣ Util ca model de referință pentru testarea restricțiilor (LR test vs GARCH, GJR etc.)

Staționaritatea modelelor asimetrice

Condiții de staționaritate — modele asimetrice

Model	Condiție	Observații
GARCH(1,1)	$\alpha + \beta < 1$	Covarianță-staționaritate
GJR-GARCH	$\alpha + \gamma/2 + \beta < 1$	$\gamma/2$ deoarece $P(\varepsilon < 0) = 1/2$
EGARCH(1,1)	$ \beta < 1$	$\ln \sigma_t^2$ este AR(1)-like
TGARCH(1,1)	$(\alpha^+ + \alpha^-)/2 + \beta < 1$	Media impactului pozitiv/negativ
APARCH(1,1)	$\alpha_1 \mathbb{E}[(z - \gamma z)^\delta] + \beta_1 < 1$	Depinde de distribuția lui z_t

Propoziție 1 (Staționaritate EGARCH (Nelson, 1991))

- EGARCH modelează $\ln \sigma_t^2$ ca proces AR(1) cu inovații $g(z_{t-1})$
- $|\beta| < 1$: **necesară și suficientă** pentru staționaritate strictă
- **Notă:** nu se confundă cu $\alpha + \beta < 1$ din GARCH — α din EGARCH are alt rol

TGARCH — threshold GARCH

De ce TGARCH? Modelarea directă a deviației standard

- GARCH/EGARCH/GJR modelează σ_t^2 . TGARCH modelează direct σ_t
- Permite coeficienți separați α^+ , α^- pentru șocuri pozitive și negative — interpretare mai intuitivă

Definiție 4 (TGARCH(1,1))

Zakoian (1994) modelează deviația standard: $\sigma_t = \omega + \alpha^+ \varepsilon_{t-1}^+ + \alpha^- \varepsilon_{t-1}^- + \beta \sigma_{t-1}$


Comparație modele asimetrice

Model	Specificație	Leverage
GARCH	σ_t^2	Nu
EGARCH	$\ln(\sigma_t^2)$	Da ($\gamma < 0$)
GJR-GARCH	σ_t^2 cu indicator	Da ($\gamma > 0$)
TGARCH	σ_t	Da ($\alpha^- > \alpha^+$)
APARCH	σ_t^δ	Da ($\gamma_i \neq 0$)

Simulare TGARCH: răspuns asimetric la volatilitate

Interpretare

- TGARCH cu $\alpha^+ = 0.03$ și $\alpha^- = 0.15 \Rightarrow$ șocurile negative amplifică volatilitatea de $5\times$
- Benzile de volatilitate $\pm 2\sigma$ se lărgesc asimetric în perioadele de criză



TGARCH: ce observăm în seria simulată?

Citirea graficului de simulare

- ▣ Cu $\alpha^- = 0.15$ și $\alpha^+ = 0.03$, un șoc negativ de -3% crește σ_t cu $0.15 \times 3 = 0.45$
- ▣ Același șoc pozitiv de $+3\%$ crește σ_t cu doar $0.03 \times 3 = 0.09$ — de **5× mai puțin**
- ▣ Vizual: benzile $\pm 2\sigma$ se lărgesc brusc și **asimetric** după scăderi de piață


Când folosim TGARCH?

- ▣ Când dorim să modelăm direct σ_t (nu σ_t^2 ca GJR, nici $\ln \sigma_t^2$ ca EGARCH)
- ▣ Piețe cu leverage puternic: acțiuni individuale, indici bursieri
- ▣ **Avantaj**: interpretare naturală — coeficienții acționează pe scala deviației standard

TGARCH vs GJR-GARCH

- ▣ Ambele captează asimetria, dar pe scări diferite (σ_t vs σ_t^2)
- ▣ Empiric, diferențele sunt mici; TGARCH este preferat în risk management (VaR folosește σ_t direct)

Comparație news impact curves



Interpretare

- ▣ **GARCH standard:** simetric
 - ▶ Tratează șocuri pozitive și negative identic
- ▣ **EGARCH și GJR-GARCH:** captează asimetria
 - ▶ Leverage effect: șocuri negative $\Rightarrow$ impact mai mare

Când aleg ARCH, GARCH, EGARCH sau GJR-GARCH?

Ghid de alegere — modele de bază

- ▣ **GARCH(1,1): benchmark-ul standard** — 3 parametri, suficient în $\sim 90\%$ din cazuri
- ▣ **EGARCH/GJR-GARCH**: când leverage effect este semnificativ (acțiuni, indici)
- ▣ **TGARCH**: alternativă la GJR pe scala σ_t (risk management direct)

Ghid de alegere — modele avansate

- ▣ **IGARCH/EWMA**: persistență extremă ($\hat{\alpha} + \hat{\beta} \approx 1$); EWMA = screening rapid (RiskMetrics)
- ▣ **FIGARCH**: memorie lungă ($0 < d < 1$); preferabil IGARCH când persistența e finită
- ▣ **CGARCH**: separarea componentei permanente de cea tranzitorie
- ▣ **APARCH**: generalizare maximă (δ, γ libere); util ca referință/benchmark
- ▣ **Markov-switching**: dacă IGARCH pare artefact al schimbărilor de regim
- ▣ **GARCH-M**: dacă prima de risc (risk premium) este de interes economic

Începe simplu (GARCH), complică doar dacă datele o cer.

Ghid de selecție pe clase de active

Ce model pentru ce piață?

Clasă de active	Model recomandat	De ce?
Indici (S&P 500, DAX)	EGARCH-t / GJR-t	Leverage puternic
Acțiuni individuale	GJR-GARCH-t	Leverage + interpretabilitate
Forex (EUR/USD)	GARCH(1,1)-t / FIGARCH	Persistență mare, fără leverage
Crypto (Bitcoin)	EGARCH-t / GJR-t	Leverage + cozi foarte groase
Mărfuri (petrol, aur)	GARCH(1,1)-t	Moderat, fără asimetrie clară
Rate dobânzi	IGARCH / CGARCH	Persistență extremă, regimuri


Reguli practice de selecție

- ▣ **Pasul 1:** GARCH(1,1)-t → **Pasul 2:** sign bias test → **Pasul 3:** dacă leverage ⇒ EGARCH/GJR
- ▣ **Pasul 4:** dacă $\hat{\alpha} + \hat{\beta} \approx 1$ ⇒ FIGARCH sau Markov-switching
- ▣ **Pasul 5:** compară AIC/BIC + Diebold-Mariano out-of-sample

Comparație familie GARCH

Interpretare

- Toate modelele capturează volatility clustering, dar diferă în modul de modelare a asimetriei



GARCH-in-Mean (GARCH-M) — Engle, Lilien & Robins (1987)

Definiție 5 (GARCH-M)

- ▣ **Model:** Volatilitatea intră direct în ecuația mediei:

$$r_t = \mu + \delta \cdot g(\sigma_t^2) + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t$$

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

- ▣ **Funcția g :** poate fi σ_t^2 , σ_t , sau $\ln(\sigma_t^2)$

Interpretare economică

- ▣ $\delta > 0$: **prima de risc** $\Rightarrow$ randamente mai mari când volatilitatea este ridicată
- ▣ Formalizează relația risc-randament (CAPM, Merton ICAPM); testul $H_0 : \delta = 0$ verifică semnificația

Exemplu tipic: acțiuni

- ▣ $r_t = 0.02 + \underbrace{0.15}_{\delta} \cdot \sigma_t + \varepsilon_t \quad \Rightarrow \text{La } \sigma_t = 2\%: \mathbb{E}[r_t] = 0.023 \text{ (0.3\% primă)}$

GARCH-M: Specificații alternative

Specificații comune

□ Prima de risc poate intra sub diferite forme:

- ▶ (1) $r_t = \mu + \lambda \sigma_t + \varepsilon_t$
- ▶ (2) $r_t = \mu + \lambda \sigma_t^2 + \varepsilon_t$
- ▶ (3) $r_t = \mu + \lambda \ln(\sigma_t^2) + \varepsilon_t$

Rezultate tipice pentru piețele de acțiuni

- λ estimat adesea pozitiv dar mic (0.01–0.10)
- Semnificația variază în funcție de piață și perioadă
- Specificația cu varianță produce estimări λ mai mari

Observație 2

- GARCH-M este utilizat în evaluarea activelor, optimizarea portofoliului și testarea CAPM

Cuprins

- Motivație
- Introducere în Modelarea Volatilității
- Modelul ARCH
- Modelul GARCH
- Modele GARCH Asimetrice
- **Selectarea și Diagnosticarea modelelor**
- Prognoza volatilității
- VaR Backtesting și Implementare
- Studiu de Caz: S&P 500
- Studiu de Caz: Bitcoin
- Utilizare IA
- Rezumat
- Quiz
- Bibliografie

Workflow complet: de la date la VaR validat

Algoritmul practic în 8 pași

1. **Estimează ecuația mediei:** ARMA sau $r_t = \mu + \varepsilon_t$ (verifică ACF randamente)
2. **Testează efecte ARCH:** ARCH-LM test + Ljung-Box pe $\hat{\varepsilon}_t^2$
3. **Estimează familia GARCH:** GARCH(1,1), EGARCH(1,1), GJR-GARCH(1,1)
4. **Compară distribuții ale inovațiilor:** Normal vs Student-t vs GED
5. **Verifică reziduurile standardizate:** $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$ i.i.d. (Ljung-Box, ARCH-LM rezidual, Q-Q plot — Quantile-Quantile plot)
6. **Compară modele cu AIC/BIC:** cel mai mic AIC/BIC = cel mai bun compromis
7. **Prognozează volatilitatea:** $\hat{\sigma}_{T+h}^2$ cu rolling window sau recursive
8. **Validează VaR:** backtesting cu Kupiec (acoperire) și Christoffersen (independență)

De reținut

- ▣ Acesta este **exact** fluxul de lucru pe care îl veți urma în studiile de caz S&P 500 și Bitcoin
- ▣ Chiar dacă randamentele sunt greu de prognozat, volatilitatea lor este adesea prognozabilă

Selectarea ordinului

Criterii informaționale

- ▣ **AIC** (Akaike Information Criterion) $= -2\ell + 2k$
- ▣ **BIC** (Bayesian Information Criterion) $= -2\ell + k \ln(T)$
- ▣ **HQIC** (Hannan-Quinn Information Criterion) $= -2\ell + 2k \ln(\ln(T))$

unde ℓ = maximul log-verosimilității, k = nr. parametri.


Recomandări practice

- ▣ GARCH(1,1) este suficient în **90% din cazuri**
- ▣ Verificați dacă modelul asimetric îmbunătățește semnificativ ajustarea
- ▣ Alege distribuția inovațiilor care minimizează AIC/BIC

Exemplu diagnostic — EUR/USD EGARCH(1,1,1)-t

Verificare

- Reziduurile standardizate trebuie să fie i.i.d. fără efecte ARCH reziduale



Diagnosticarea modelelor GARCH

Reziduuri standardizate

$$\hat{z}_t = \frac{\hat{\varepsilon}_t}{\hat{\sigma}_t}$$

- Dacă modelul este corect specificat, $\hat{z}_t$ ar trebui să fie i.i.d.(0,1)

Verificări diagnostic

1. **Ljung-Box pe $\hat{z}_t$:** $Q(m) = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k} \sim \chi^2(m)$; H_0 : fără autocorelație; H_1 : autocorelație prezentă
2. **Ljung-Box pe $\hat{z}_t^2$:** aceeași formulă aplicată pe $\hat{z}_t^2$; H_0 : fără efecte ARCH reziduale
3. **Test ARCH-LM pe $\hat{z}_t$:** confirmă absența heteroscedasticității
4. **Sign-bias test** (Engle & Ng, 1993): verifică asimetria neexploată
5. **Histogramă + QQ-plot:** verifică distribuția asumată

Testul Sign-Bias — Engle & Ng (1993)

Motivație

- ▣ Verifică dacă modelul GARCH captează **corect asimetria** în volatilitate
- ▣ Dacă testul respinge, modelul simetric este inadecvat $\Rightarrow$ trebuie EGARCH sau GJR

Definiție 1 (Regresii Sign-Bias)

Fie $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$ și $S_t^- = 1(\hat{\varepsilon}_t < 0)$. Se estimează:

$$\hat{z}_t^2 = c_0 + c_1 S_{t-1}^- + c_2 S_{t-1}^- \hat{\varepsilon}_{t-1} + c_3 (1 - S_{t-1}^-) \hat{\varepsilon}_{t-1} + u_t$$

- ▣ **Sign-bias:** $H_0 : c_1 = 0$; **Neg. size-bias:** $H_0 : c_2 = 0$; **Pos. size-bias:** $H_0 : c_3 = 0$
- ▣ **Test joint:** $H_0 : c_1 = c_2 = c_3 = 0$, statistica $TR^2 \sim \chi^2(3)$

Interpretare practică

- ▣ Respingere $\Rightarrow$ modelul nu captează leverage $\Rightarrow$ treceți la EGARCH/GJR
- ▣ Acceptare pe model asimetric $\Rightarrow$ asimetria bine specificată

Testul de stabilitate Nyblom (1989)

Motivație

- ▣ Testează dacă parametrii GARCH sunt **constanți pe întreaga perioadă**
- ▣ Instabilitatea parametrilor distorsionează persistența: $\hat{\alpha} + \hat{\beta}$ umflat artificial

Definiție 2 (Testul Nyblom)

$H_0: \theta = (\omega, \alpha, \beta, \dots)$ constanți; $H_1: \theta_t$ urmează random walk.

$$L_c = \frac{1}{T^2} \sum_{t=1}^T S_t' \hat{V}^{-1} S_t, \quad S_t = \sum_{s=1}^t \frac{\partial \ell_s}{\partial \theta} \Big|_{\hat{\theta}}$$

S_t = suma parțială a scorurilor; $\hat{V}$ = matricea de informație estimată.

Utilizare practică

- ▣ Python: `result.diagnostic_summary()` (pachetul arch)
- ▣ Respingere $\Rightarrow$ rolling window sau GARCH cu schimbare de regim

Matricea de informație estimată

Ce este matricea de informație?

- ▣ **Scorul** (gradientul): $s_t(\theta) = \nabla_{\theta} \ell_t$ — derivata log-verosimilitudinii observației t în raport cu parametrii
- ▣ **Matricea de informație Fisher**: $\mathcal{I}(\theta) = \mathbb{E}[s_t s_t']$ — măsoară cât de mult “informează” datele despre parametri
- ▣ Cu cât $\mathcal{I}$ este mai mare, cu atât parametrii sunt estimați mai precis

Estimarea matricei de informație

- ▣ **OPG** (Outer Product of Gradients): $\hat{V} = \frac{1}{T} \sum_{t=1}^T s_t s_t'$
- ▣ **Hessian observat**: $\hat{V} = -\frac{1}{T} \sum_{t=1}^T \nabla_{\theta}^2 \ell_t$
- ▣ **Sandwich** (robustă, Bollerslev-Wooldridge): $\hat{V} = H^{-1} G H^{-1}$, unde H = Hessian, G = OPG


De ce contează?

- ▣ Erorile standard ale parametrilor GARCH: $se(\hat{\theta}_j) = \sqrt{[\hat{V}^{-1}]_{jj}/T}$
- ▣ Versiunea sandwich este robustă la specificarea greșită a distribuției

Comparație modele GARCH – validare

Interpretare

- GARCH(1,1) obține cel mai mic MAE pe setul de validare
 - ▶ Mai parcimonios și mai stabil decât modelele de ordin mai mare
- GARCH(2,1) și GJR-GARCH: performanță similară, dar mai mulți parametri
- **Concluzie:** simplitatea câștigă $\Rightarrow$ GARCH(1,1) este greu de bătut

Comparație modele GARCH – validare

Testul Diebold-Mariano

Motivație

- ▣ Date fiind două modele de volatilitate concurente, care prognozează mai bine?

Definiție 3 (Diebold-Mariano (1995))

Diferența de pierdere: $d_t = L(e_{1t}) - L(e_{2t})$, unde $e_{it} = \sigma_t^2 - \hat{\sigma}_{it}^2$

$$DM = \frac{\bar{d}}{\sqrt{\hat{V}(\bar{d})}} \xrightarrow{d} N(0, 1) \quad \text{sub } H_0 : \mathbb{E}[d_t] = 0$$

Note practice

- ▣ H_0 : acuratețe predictivă egală; respingere $\Rightarrow$ un model semnificativ mai bun
- ▣ Funcții de pierdere: MSE, QLIKE (Quasi-Likelihood — robustă, Patton 2011); SE HAC dacă d_t autocorelat

Exemplu: S&P 500 (2015–2024, rolling 500 zile, QLIKE)

- ▣ EGARCH-t vs GARCH-N: $\bar{d} = -0.047$, $DM = -3.12$, $p = 0.002 \Rightarrow$ respinge H_0
- ▣ EGARCH-t vs GJR-t: $DM = -0.84$, $p = 0.40 \Rightarrow$ nu respinge: acuratețe echivalentă

Funcții de pierdere pentru evaluarea prognozei volatilității

De ce contează funcția de pierdere?

- ▣ Volatilitatea reală σ_t^2 este **neobservabilă** — folosim proxy-uri (r_t^2 , RV_t)
- ▣ Funcția de pierdere trebuie să fie **consistentă**: clasamentul nu depinde de proxy (Patton, 2011)

Definiție 4 (Funcții de pierdere standard)

$$L_{\text{MSE}} = (\sigma_t^2 - \hat{\sigma}_t^2)^2 \quad (\text{sensibilă la extreme})$$

$$L_{\text{QLIKE}} = \ln \hat{\sigma}_t^2 + \sigma_t^2 / \hat{\sigma}_t^2 \quad (\text{robustă, consistentă — recomandată})$$

$$L_{\text{MAE}} = |\sigma_t - \hat{\sigma}_t| \quad (\text{nu este consistentă pentru } \sigma^2)$$

Recomandare

- ▣ **QLIKE**: robustă la proxy zgomotos; disponibilă în DM și MCS

Model Confidence Set — Hansen, Lunde & Nason (2011)

Motivație: de la comparație pereche la comparație multiplă

- ▣ Diebold-Mariano compară **2 modele**; ce facem cu 5, 10, sau 20 candidate?
- ▣ MCS: identifică **setul de modele echivalente statistic** (“cele mai bune”)

Definiție 5 (Model Confidence Set (MCS))

Pornind de la $\mathcal{M}_0 = \{M_1, \dots, M_m\}$ (toate modelele candidate):

1. Testează H_0 : toate modelele din set au acuratețe predictivă egală
2. Dacă respinsă: elimină modelul cel mai slab ($t_{\max}$ sau T_R)
3. Repetă până H_0 nu mai este respinsă $\Rightarrow \hat{\mathcal{M}}_{1-\alpha}^*$

Avantaj față de Diebold-Mariano

- ▣ Controlează **eroarea de testare multiplă** (familywise error rate)
- ▣ Fiecare model primește un **MCS p-value**; disponibil: `arch.bootstrap.MCS`

Regresia Mincer-Zarnowitz

Test de eficiență a prognozei

- ▣ Regresăm volatilitatea realizată pe volatilitatea prognozată: $\sigma_{t,\text{realized}}^2 = a + b \hat{\sigma}_t^2 + u_t$

Definiție 6 (Ipoteze)

- ▣ $H_0 : a = 0, b = 1$ (prognoză nedirecționată și eficientă)
- ▣ Test prin F-test sau Wald; respingere $\Rightarrow$ prognoza este biasată sau ineficientă

Exemplu: S&P 500, GARCH(1,1)-t (2015–2024)

- ▣ $\hat{a} = 0.12, \hat{b} = 0.87, R^2 = 0.08$; F-test: $p = 0.03 \Rightarrow$ respinge H_0
- ▣ Prognoza ușor biasată ($a > 0, b < 1$); cu RV_t ca proxy: $R^2 = 0.42, \hat{b} = 0.95$

Atenție

- ▣ Varianța realizată (r_t^2) este un proxy zgomotos; R^2 de regulă mic (< 0.10); preferați RV_t

Cuprins

- Motivație
- Introducere în Modelarea Volatilității
- Modelul ARCH
- Modelul GARCH
- Modele GARCH Asimetrice
- Selectarea și Diagnosticarea modelelor
- **Proгноза volatilității**
- VaR Backtesting și Implementare
- Studiu de Caz: S&P 500
- Studiu de Caz: Bitcoin
- Utilizare IA
- Rezumat
- Quiz
- Bibliografie

De la modelare la prognoză și managementul riscului

Ce am construit până acum

- ▣ Am estimat modele GARCH (simetrice și asimetrice)
- ▣ Am validat cu teste de diagnostic (Ljung-Box, ARCH-LM, Sign-bias, Nyblom)
- ▣ Am selectat cel mai bun model (AIC/BIC, Diebold-Mariano, MCS)

Următorul pas: la ce servește modelul?


- ▣ **Proгноza volatilității:** $\hat{\sigma}_{T+h}^2$ — convergență la $\bar{\sigma}^2$
- ▣ **Value at Risk (VaR):** pierderea maximă cu o anumită probabilitate
- ▣ **Expected Shortfall (ES):** pierderea medie dincolo de VaR (Basel III/IV)
- ▣ **Backtesting:** validarea modelului VaR pe date istorice

Structura secțiunii

Proгноză → VaR/ES → Backtesting (Kupiec, Christoffersen) → Studii de caz aplicate

Proгноза volatilității — vizualizare

- Prognoza pe termen scurt reflectă volatilitatea curentă; pe termen lung converge către $\bar{\sigma}^2$
- Zona umbrită: incertitudinea prognozei crește cu orizontul



 TSA_ch5_vol_forecast

Proгноза cu GARCH(1,1)

Proгноză un pas înainte

$$\square \hat{\sigma}_{T+1}^2 = \omega + \alpha \varepsilon_T^2 + \beta \sigma_T^2$$

Proгноză multi-pas

$$\square \text{ Pentru } h > 1: \mathbb{E}_T[\sigma_{T+h}^2] = \bar{\sigma}^2 + (\alpha + \beta)^{h-1}(\sigma_{T+1}^2 - \bar{\sigma}^2)$$

$$\square \bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta} = \text{varianța necondiționată}$$

Convergență


$$\square \lim_{h \rightarrow \infty} \mathbb{E}_T[\sigma_{T+h}^2] = \bar{\sigma}^2 \text{ — prognoza converge către varianța necondiționată.}$$

Convergența prognozei GARCH către varianța necondiționată

Interpretare

- Prognoza multi-pas converge exponențial către $\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta}$
- Cu cât $\alpha + \beta$ este mai aproape de 1, cu atât convergența este mai lentă
 - ▶ S&P 500: $\alpha + \beta \approx 0.99 \Rightarrow$ convergență în ~ 50 zile
 - ▶ Bitcoin: $\alpha + \beta \approx 0.95 \Rightarrow$ convergență mai rapidă


Convergența prognozei GARCH către varianța necondiționată



Volatilitate condiționată vs necondiționată

Interpretare

- ▣ **Volatilitatea condiționată** σ_t (GARCH): variabilă în timp, reacționează la știri
- ▣ **Volatilitatea necondiționată** $\bar{\sigma} = \sqrt{\omega/(1 - \alpha - \beta)}$: nivel constant pe termen lung
- ▣ Zonele roșii: $\sigma_t > \bar{\sigma}$ (perioade de stres); zonele albastre: $\sigma_t < \bar{\sigma}$ (perioade calme)



Volatilitate realizată și HAR-RV

Volatilitate realizată (RV)

- Cu randamente intra-zilnice $r_{t,i}$ (M obs./zi): $RV_t = \sum_{i=1}^M r_{t,i}^2$ — măsură **fără model, observabilă** (vs. GARCH: latentă)

Definiție 1 (Modelul HAR-RV — Corsi (2009))

$$RV_t = \beta_0 + \beta_D RV_{t-1} + \beta_W RV_{t-1}^{(w)} + \beta_M RV_{t-1}^{(m)} + u_t$$

unde $RV^{(w)} = \frac{1}{5} \sum_{i=1}^5 RV_{t-i}$ (săptămânală) și $RV^{(m)} = \frac{1}{22} \sum_{i=1}^{22} RV_{t-i}$ (lunară).

Avantaj principal

- Regresie OLS simplă care capturează **memoria lungă**; traderi eterogeni explică dinamica multi-scală
- Adesea depășește GARCH când datele intra-zilnice sunt disponibile (5 min, $M \approx 78/\text{zi}$)
- Atenție: zgomot de microstructură la frecvență foarte înaltă $\Rightarrow$ estimatori kernel

Realized GARCH

Motivație

- GARCH standard tratează volatilitatea ca **latentă**; cu date de frecvență înaltă, o putem **observa** prin RV_t

Definiție 2 (Realized GARCH — Hansen, Huang & Shek (2012))

Randamente: $r_t = \mu + \sigma_t z_t$, $z_t \sim D(0, 1)$ **GARCH:** $\log \sigma_t^2 = \omega + \beta \log \sigma_{t-1}^2 + \gamma \log RV_{t-1}$

Măsurare: $\log RV_t = \xi + \varphi \log \sigma_t^2 + \tau(z_t) + u_t$

Beneficii

- **Model comun:** leagă randamentele, volatilitatea latentă și măsurile realizate
- Funcția de levier $\tau(z_t)$ capturează asimetria; prognoze **mai precise** decât GARCH standard


Comparație: GARCH vs HAR-RV vs Realized GARCH

- **GARCH:** nu necesită date intra-zilnice; cel mai utilizat
- **HAR-RV:** simplu, fără model; necesită date la 5 min
- **Realized GARCH:** combină avantajele; necesită date la 5 min + structură parametrică

VaR și ES: ilustrație grafică

Interpretare

- VaR 1% = pierderea depășită doar în 1% din cazuri
- Zona roșie = pierderi extreme (dincolo de VaR)



TSA_ch5_var_plot

Aplicații ale prognozei volatilității

Value at risk (VaR)

- ▣ $\text{VaR}_\alpha = z_\alpha \cdot \sigma_{T+1}$
- ▣ Pierdere maximă cu probabilitate $1 - \alpha$

Expected shortfall (ES)

- ▣ $\text{ES}_\alpha = \mathbb{E}[-r | r < -\text{VaR}_\alpha]$
- ▣ Pierdere medie când VaR este depășit


Alte aplicații

- ▣ Prețul opțiunilor
- ▣ Hedging dinamic
- ▣ Alocarea portofoliului
- ▣ Stress testing

VaR vs expected shortfall: normal vs Student-t

Interpretare

- ES măsoară pierderea medie când VaR este depășit
- Student-t: VaR și ES mai mari decât sub distribuția normală



Value at risk — exemplu numeric

Calculul VaR

- Portofoliu: **1.000.000 EUR**, volatilitate prognozată $\hat{\sigma}_{T+1} = 1.5\%$

VaR cu distribuție normală

Nivel	z_{α}	VaR (%)	VaR (EUR)
5% (1 zi)	1.645	2.47%	24.675
1% (1 zi)	2.326	3.49%	34.890

Observație 1 (Scalarea VaR sub heteroscedasticitate)

- Regula $\sqrt{h}$ (scalarea volatilității zilnice: $\sigma_h = \sigma_1 \sqrt{h}$, valabilă doar sub i.i.d.): $\text{VaR}_{h \text{ zile}} = \text{VaR}_{1 \text{ zi}} \cdot \sqrt{h}$
- Atenție:** Sub modelele GARCH, randamentele **nu** sunt i.i.d. $\Rightarrow$ regula $\sqrt{h}$ este doar o **aproximare**; pentru VaR multi-perioadă, folosiți prognoza GARCH iterată

Value at risk — distribuție Student-t

De ce Student-t?

- ▣ Distribuția normală **subestimează** riscul de coadă
- ▣ Student-t cu ν grade de libertate capturează mai bine cozile groase (kurtosis > 3)

Comparație VaR 1% (1 zi): $\sigma = 1.5\%$, portofoliu = 1M EUR

Distribuție	Cuantilă	VaR (EUR)
Normal	2.326	34.890
Student-t ($\nu = 6$)	3.143	47.145
Student-t ($\nu = 4$)	3.747	56.205

Observație

- ▣ Cu $\nu = 6$ (tipic pentru acțiuni), VaR este cu **35% mai mare** decât cel normal.

VaR — exemplu complet cu GARCH

Procedura de calcul VaR

1. Estimează modelul GARCH(1,1) cu distribuție Student-t
2. Obține prognoza volatilității: $\hat{\sigma}_{T+1}$
3. Calculează VaR: $\text{VaR}_\alpha = t_\alpha(\nu) \cdot \hat{\sigma}_{T+1} \cdot \sqrt{\frac{\nu-2}{\nu}}$

Exemplu: S&P 500

- ▣ Parametri estimați: $\alpha = 0.088$, $\beta = 0.900$, $\nu = 6.4$
- ▣ Volatilitate prognozată: $\hat{\sigma}_{T+1} = 1.2\%$
- ▣ Portofoliu: 10.000.000 EUR

VaR 1% (1 zi): $\text{VaR} = 3.05 \times 0.012 \times 10,000,000 = 366,000 \text{ EUR}$

Ce este VaR backtesting?

Definiție

- ▣ **Backtesting** = verificarea ex-post a calității modelului VaR
- ▣ Compară pierderile realizate cu pragul VaR prognozat
 - ▶ O **încălcare** (violation) apare când $r_t < -\text{VaR}_t$

Principiul Backtesting-ului

- ▣ Indicatorul de încălcare: $I_t = 1(r_t < -\text{VaR}_{\alpha,t})$
- ▣ Pentru un model corect la nivel α :
 - ▶ Frecvența: $\hat{p} = \frac{1}{T} \sum I_t \approx \alpha$; încălcări **independente**
- ▣ VaR 1% pe 250 zile $\Rightarrow$ așteptăm ~ 2.5 încălcări/an


Importanță

- ▣ Cerință regulamentară **Basel III/IV** pentru bănci: backtesting obligatoriu

VaR backtesting: vizualizare

Interpretare

- ▣ Linia roșie: pragul VaR 1% estimat cu GARCH(1,1)
- ▣ Punctele roșii: 13 încălcări din 250 zile ($\hat{p} = 5.2\%$)
 - ▶ **Zonă roșie Basel** $\Rightarrow$ modelul subestimează semnificativ riscul
 - ▶ Soluții: distribuție Student-t, model EGARCH, sau nivel VaR mai conservator



Backtesting VaR: semaforul Basel (sistem de clasificare verde/galben/roșu a calității modelului VaR)

Zonele de semaforizare Basel III/IV

Zonă	Încălcări/250 zile	Interpretare	Penalizare
Verde	0–4	Model acceptabil	Fără penalizare
Galben	5–9	Necesită investigare	Factor k crește
Roșu	≥ 10	Model inadecvat	Penalizare maximă

Exemplu practic

- ▣ Portofoliu cu VaR 1%: 250 zile de backtesting
- ▣ 3 încălcări $\Rightarrow$ **Zonă verde** $\Rightarrow$ model acceptabil
- ▣ 7 încălcări $\Rightarrow$ **Zonă galbenă** $\Rightarrow$ revizuire necesară
- ▣ 13 încălcări $\Rightarrow$ **Zonă roșie** $\Rightarrow$ model respins

Metodologia Rolling Window pentru VaR

Conceptul Rolling Window

- ▣ O **fereastră mobilă** de dimensiune fixă W (ex. 500 zile) se deplasează zi cu zi
- ▣ La fiecare pas t : re-estimare GARCH pe $[t - W, t - 1]$, prognoză $\hat{\sigma}_{t|t-1}$, calcul VaR_t


Procedura pas cu pas (pentru fiecare zi $t = W + 1, \dots, T$)

1. Estimează GARCH pe $\{r_{t-W}, \dots, r_{t-1}\} \Rightarrow$ parametri $\hat{\omega}, \hat{\alpha}, \hat{\beta}, \hat{\nu}$
2. Prognozează: $\hat{\sigma}_{t|t-1}^2 = \hat{\omega} + \hat{\alpha}r_{t-1}^2 + \hat{\beta}\hat{\sigma}_{t-1}^2$
3. Calculează: $\text{VaR}_{\alpha,t} = -t_{\alpha}(\hat{\nu}) \cdot \sqrt{\frac{\hat{\nu}-2}{\hat{\nu}}} \cdot \hat{\sigma}_{t|t-1}$
4. Verifică încălcarea: $I_t = 1(r_t < -\text{VaR}_{\alpha,t})$

Rolling vs Expanding window

- ▣ **Rolling** (W fix): reflectă regimul curent; recomandat dacă sunt schimbări structurale
- ▣ **Expanding**: folosește toate datele; mai stabil, dar mai lent la adaptare

Rolling Window VaR: schema procedurii




Rezultat

- Obținem seria $\{\text{VaR}_{\alpha,t}\}_{t=W+1}^T \Rightarrow$ un prag **diferit** în fiecare zi
- VaR-ul se adaptează la regimul curent: crește în perioadele volatile, scade în perioadele de volatilitate redusă
- Comparăm r_t cu $-\text{VaR}_{\alpha,t}$ pentru a identifica încălcările

Proгноза volatilității cu intervale de încredere

Interpretare

- Prognoza converge către $\bar{\sigma}$
- Incertitudinea crește cu orizontul de prognoză



Rolling forecast – prognoza pas cu pas

Procedura

S&P 500, $W=500$, GARCH(1,1)-t


- ▣ Re-estimare GARCH pe $[t-W, t-1]$; prognoză $\hat{\sigma}_t|_{t-1}$
- ▣ Comparăție cu vol. realizată (std. rulantă 20 zile)

Rezultate (2015 zile OOS)

- ▣ $\rho = 0.938 \Rightarrow$ urmărire excelentă; MAE = 0.15%, RMSE = 0.24%
- ▣ COVID-19: sub-predicție temporară, adaptare rapidă

Rolling forecast – prognoza pas cu pas

Rolling vs Multi-Step GARCH Forecasts



TSA_ch5_rolling_forecast

Cuprins

- Motivație
- Introducere în Modelarea Volatilității
- Modelul ARCH
- Modelul GARCH
- Modele GARCH Asimetrice
- Selectarea și Diagnosticarea modelelor
- Prognoza volatilității
- **VaR Backtesting și Implementare**
- Studiu de Caz: S&P 500
- Studiu de Caz: Bitcoin
- Utilizare IA
- Rezumat
- Quiz
- Bibliografie

VaR backtesting: testul Kupiec

Testul acoperirii necondiționate

- ▣ Testează dacă rata de încălcare observată este egală cu rata așteptată p (ex. 1% pentru VaR 1%)
- ▣ Fie N = numărul de încălcări VaR, T = totalul observațiilor, $\hat{p} = N/T$
- ▣ **Statistica Likelihood Ratio:**

$$LR_{uc} = -2 \ln \left[\frac{(1-p)^{T-N} p^N}{(1-\hat{p})^{T-N} \hat{p}^N} \right] \sim \chi^2(1)$$

Ipoteze

- ▣ H_0 : $\hat{p} = p$ (modelul VaR este corect calibrat)
- ▣ H_1 : $\hat{p} \neq p$ (modelul VaR sub- sau supra-estimează riscul)

VaR backtesting: testul Christoffersen

Propoziție 1 (Proprietăți ale unui model VaR corect calibrat (Christoffersen, 1998))

- ▣ **Acoperire necondiționată:** frecvența încălcărilor = nivelul nominal α
- ▣ **Independență:** încălcările trebuie să fie serial independente (fără clusterizare)

Componente ale testului

- ▣ **Testul de independență** (LR_{ind}): Testează dacă încălcările sunt serial independente
- ▣ **Acoperire condiționată:** $LR_{cc} = LR_{uc} + LR_{ind} \sim \chi^2(2)$

Interpretare

- ▣ Respinge LR_{uc} : frecvență greșită
- ▣ Respinge LR_{ind} : încălcări clusterizate
- ▣ Respinge LR_{cc} : modelul nu este validat

Backtesting complet – rezultate și decizie

Aplicare S&P 500 (T=500, VaR 1%)

- Rolling window: $W = 500$ zile, model EGARCH(1,1)-t
- Fereastră de test: $T - W$ zile out-of-sample (evaluare pe date nefolosite la estimare)
- Se compară VaR prognozat cu randamentul realizat în fiecare zi

Output tipic

- Număr încălcări vs așteptat $\Rightarrow$ zona Basel (verde/galben/roșu)
- Kupiec (frecvență): $H_0: \hat{p} = \alpha \Rightarrow p\text{-value} > 0.05 \Rightarrow$ acceptat
- Christoffersen (independență): $H_0: \text{încălcări i.i.d.} \Rightarrow p\text{-value} > 0.05 \Rightarrow$ acceptat
- Test combinat: ambele condiții îndeplinite $\Rightarrow$ **model validat**

Backtesting-ul Expected Shortfall

De ce backtesting ES?

- ▣ VaR măsoară doar *pragul* pierderilor extreme, nu *magnitudinea* lor
- ▣ ES = pierderea medie *dacă* VaR este depășit $\Rightarrow$ mai informativ pentru riscul de coadă

Definiție 1 (Testul Z Acerbi-Székely (2014))

$Z_{ES} = \frac{1}{n_\alpha} \sum_{t:r_t < -\text{VaR}_t} \frac{r_t}{\text{ES}_t} + 1$. H_0 : model ES corect ($\mathbb{E}[Z_{ES}] = 0$); H_1 : ES subestimat ($Z_{ES} < 0$); se respinge dacă $Z_{ES} < z_\alpha$

Exemplu: S&P 500, ES 2.5%, EGARCH-t (2015–2024, T=2015)

- ▣ $n_\alpha = 51$ încălcări VaR, $Z_{ES} = -0.38$, p-value = 0.35 $\Rightarrow$ nu respinge H_0 : ES corect
- ▣ Sub GARCH-Normal: $Z_{ES} = -1.92$, p-value = 0.03 $\Rightarrow$ respinge: ES subestimat (cozi prea subțiri)

Observație

- ▣ Spre deosebire de backtesting VaR (binar), backtesting ES folosește *magnitudinea* pierderilor
- ▣ Necesită eșantioane mari ($T > 1000$); alternativă: bootstrap McNeil & Frey (2000)

Basel IV: de la VaR la ES

Schimbarea reglementară

- ▣ **Basel II/III**: Capital bazat pe VaR 99% (10 zile)
- ▣ **Basel IV** (FRTB, 2023+): Capital bazat pe **ES 97.5%** (10 zile)
- ▣ Motivație: ES este **coerent** (subaditivitate — riscul portofoliului $\leq$ suma riscurilor individuale), VaR nu este

Echivalență sub normalitate

$$ES_{97.5\%}^{\text{Normal}} = \frac{\phi(z_{0.025})}{0.025} \cdot \sigma \approx 2.338 \sigma \approx VaR_{99\%}^{\text{Normal}} = 2.326 \sigma$$

- ▣ Sub normalitate, $ES_{97.5\%} \approx VaR_{99\%}$; sub cozi groase, $ES \gg VaR$

Implicație practică

- ▣ Modelele GARCH Student-*t* devin **esențiale** pentru estimarea precisă a ES
- ▣ Băncile trebuie să modeleze *întreaga coadă*, nu doar o singură cuantilă

ARMA-GARCH: modelarea combinată a mediei și varianței

De ce modelare combinată?

- ▣ **Corelație serială** $\Rightarrow$ ARMA pentru medie
- ▣ **Volatility clustering** $\Rightarrow$ GARCH pentru varianță

Definiție 2 (ARMA(p,q)-GARCH(r,s))

Ecuția mediei:

$$r_t = \mu + \sum_{i=1}^p \phi_i (r_{t-i} - \mu) + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t$$

Ecuția varianței: $\varepsilon_t = \sigma_t Z_t$,

$$\sigma_t^2 = \omega + \sum_{i=1}^r \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^s \beta_j \sigma_{t-j}^2$$

ARMA-GARCH: strategie de selecție a modelului

Abordare pas cu pas

1. **Identifică modelul pentru medie:** Verifică ACF/PACF al randamentelor
2. **Testează efectele ARCH:** Aplică testul ARCH-LM pe reziduuri
3. **Specifică modelul pentru varianță:** De obicei GARCH(1,1) este suficient
4. **Estimare combinată:** Estimează ambele ecuații prin MLE
5. **Diagnostic:** Reziduurile standardizate trebuie să fie i.i.d.

Specificații comune

- ▣ **Randamente acțiuni:** AR(1)-GARCH(1,1) sau ARMA(1,1)-GARCH(1,1)
- ▣ **Cursuri de schimb:** Adesea doar GARCH(1,1) (fără dinamică în medie)
- ▣ **Rate ale dobânzii:** AR(1)-EGARCH(1,1) pentru efecte de levier

Python: Estimarea GARCH cu arch

Pași principali

```
from arch import arch_model
import numpy as np; from scipy.stats import norm

# Fit GARCH(1,1) with Student-t innovations
model = arch_model(returns, vol='Garch', p=1, q=1,
                  dist='StudentsT', mean='AR', lags=1)
result = model.fit(dispatch='off')
print(result.summary())

# Forecast 20-step ahead volatility
forecast = result.forecast(horizon=20)
sigma_forecast = np.sqrt(forecast.variance.iloc[-1])

# Compute 1-day VaR (1%) from conditional distribution
sigma_1 = sigma_forecast.iloc[0]
VaR_1pct = norm.ppf(0.01) * sigma_1 # Normal approx
```

Notă: Pentru VaR Student- t , înlocuiți `norm.ppf` cu `scipy.stats.t.ppf(0.01, df=nu)` scalat cu $\sqrt{(\nu - 2)/\nu}$.

Checklist practic: modelarea GARCH (I)

Workflow recomandat — Pașii 1–5

1. **Date:** Calculați randamentele logaritmice: $r_t = \ln(P_t/P_{t-1}) \times 100$
2. **Explorare:** Verificați faptele stilizate — kurtosis $\gg 3$, $ACF(r_t^2)$ semnificativ, QQ-plot
3. **Test ARCH:** Testul Engle LM pe reziduurile unui model $AR(p)$ — H_0 : fără efecte ARCH
4. **Estimare:** Începeți cu GARCH(1,1)-t; comparați cu EGARCH, GJR-GARCH
5. **Distribuție:** **Nu** Normal — folosiți **Student-t** (cozi groase) sau Skewed-t

Observație

- Pașii 1–3 sunt **obligatorii** înainte de orice estimare GARCH
- Pasul 4: GARCH(1,1) este suficient în 90% din cazuri — ordine mai mari rareori îmbunătățesc prognoza

Checklist practic: modelarea GARCH (II)

Workflow recomandat — Pași 6–9

6. **Persistență:** Verificați $\alpha + \beta$ — dacă ≈ 1 , considerați IGARCH
7. **Diagnostic:** Reziduuri standardizate $\hat{z}_t = r_t / \hat{\sigma}_t$ trebuie să fie i.i.d.
8. **Selecție:** AIC/BIC + Diebold-Mariano pe forecasting out-of-sample
9. **Aplicare:** VaR/ES cu rolling window (250–500 zile) + backtesting Kupiec/Christoffersen

Capcane frecvente

- ▣ **Convergență:** Dacă optimizatorul eșuează, schimbați algoritmul (`method='Nelder-Mead'`) sau valorile inițiale
- ▣ **Rupturi structurale:** Pe serii lungi (2000–2024), parametrii GARCH **nu sunt constanți** — rolling windows sunt esențiale

Cuprins

- Motivație
- Introducere în Modelarea Volatilității
- Modelul ARCH
- Modelul GARCH
- Modele GARCH Asimetrice
- Selectarea și Diagnosticarea modelelor
- Prognoza volatilității
- VaR Backtesting și Implementare
- **Studiu de Caz: S&P 500**
- Studiu de Caz: Bitcoin
- Utilizare IA
- Rezumat
- Quiz
- Bibliografie

Pasul 1: Datele – randamente zilnice S&P 500

Descrierea datelor


- ▣ **Sursă:** Yahoo Finance, S&P 500, date zilnice 2000–2024 ($T > 6000$)
- ▣ **Randamente:** $r_t = \ln(P_t/P_{t-1}) \times 100$

Statistici descriptive

Medie	Std. Dev.	Skewness	Kurtosis	Min	Max
0.034%	1.21%	-0.29	13.8	-12.8%	+11.0%

- ▣ Cozi groase (kurtosis $\gg 3$) și asimetrie negativă $\Rightarrow$ efecte ARCH

Pasul 1: Datele – randamente zilnice S&P 500



Pasul 2: Testarea efectelor ARCH

Cod Python $\Rightarrow$ ARCH-LM și Ljung-Box pe r_t^2

- Testăm prezența efectelor ARCH în reziduurile modelului pentru medie

Rezultate

Test	Statistică	p-value
ARCH-LM (10 lags)	892.4	< 0.0001
Ljung-Box r_t^2 (lag 20)	4217.6	< 0.0001

- **Concluzie:** Efecte ARCH puternice $\Rightarrow$ heteroscedasticitate semnificativă

Pasul 3: Parametri estimați – comparație


Tabel parametri estimați (erori standard robuste Bollerslev-Wooldridge)

Model	ω	α	β	γ	$\alpha + \beta$	ν	HL
GARCH-N	0.011 (0.003)	0.088 (0.011)	0.901 (0.012)	—	0.989	—	60 zile
GARCH-t	0.011 (0.003)	0.088 (0.012)	0.900 (0.013)	—	0.989	6.42 (0.82)	60 zile
EGARCH-t	0.003 (0.008)	0.103 (0.015)	0.987 (0.004)	-0.120 (0.014)	—	6.38 (0.80)	53 zile
GJR-t	0.010 (0.003)	0.022 (0.011)	0.906 (0.012)	0.126 (0.018)	0.991	6.51 (0.85)	78 zile

Interpretare

- EGARCH $\gamma = -0.120$ (SE = 0.014, $t = -8.6$) $\Rightarrow$ **leverage effect puternic semnificativ**
- GJR: $\alpha_{\text{neg}} = \alpha + \gamma = 0.148$ vs $\alpha_{\text{poz}} = 0.022 \Rightarrow$ **asimetrie puternică**
- Toate SE sunt robuste (sandwich Bollerslev-Wooldridge, 1992)


Pasul 3: Volatilitatea condiționată estimată – S&P 500



Pasul 4: Leverage effect – vizualizare

GARCH vs EGARCH $\Rightarrow$ diferențe de volatilitate

- EGARCH produce volatilitate **mai mare** după șocuri negative (2008, 2020)
- GARCH simetric **subestimează** riscul în perioadele de criză
- Diferența: până la 2–3 puncte procentuale în volatilitate zilnică



Pasul 5: Selecția modelului – AIC/BIC

Criterii informaționale

Model	Log-Lik	AIC	BIC	Rang
GARCH(1,1)-N	-8042.3	16090.6	16111.0	4
GARCH(1,1)-t	-7981.5	15971.0	15997.8	3
EGARCH(1,1)-t	-7964.2	15938.4	15971.6	1
GJR-GARCH(1,1)-t	-7968.1	15946.2	15979.4	2

Decizia


- **EGARCH(1,1)-t câștigă:** cel mai mic AIC și BIC
- Student-t superior normalei ($\Delta AIC \approx 120$) $\Rightarrow$ cozi groase contează.
- Leverage effect justifică modele asimetrice ($\Delta AIC \approx 33$ față de GARCH-t)

Pasul 6: Diagnostic – EGARCH(1,1)-t

Verificări pe reziduuri standardizate $z_t = \varepsilon_t / \hat{\sigma}_t$

- ▣ **Ljung-Box** pe z_t : p-value = 0.38 $\Rightarrow$ fără autocorelație reziduală
- ▣ **Ljung-Box** pe z_t^2 : p-value = 0.52 $\Rightarrow$ efecte ARCH eliminate
- ▣ **Sign-bias test** (joint): p-value = 0.61 $\Rightarrow$ asimetria captată adecvat de EGARCH
- ▣ **Nyblom stability**: $L_c = 0.34 < 0.47$ (cv 5%) $\Rightarrow$ parametri stabili
- ▣ **Q-Q plot**: punctele urmează dreapta teoretică Student-t

Pasul 6: Diagnostic – EGARCH(1,1)-t




Pasul 7: Backtesting rolling VaR – S&P 500

Rezultate Kupiec + Christoffersen (2015 zile out-of-sample)

Test	Statistică	p-value	Decizia
Încălări	27/2015 ($\hat{p} = 1.34\%$)	—	Zona verde
Kupiec (uc)	2.13	0.145	Acceptat
Christoffersen (ind)	0.79	0.375	Acceptat
Combinat (cc)	2.91	0.233	Acceptat

Pasul 7: Rolling VaR – S&P 500



Pasul 8: Concluzii – studiu S&P 500

Rezumatul metodologiei pas cu pas

1. **Date:** randamente log, statistici descriptive $\Rightarrow$ cozi groase, asimetrie
2. **Test ARCH:** ARCH-LM + Ljung-Box pe $r_t^2 \Rightarrow$ efecte ARCH semnificative
3. **Estimare:** 4 modele candidate (simetric/asimetric $\times$ Normal/Student-t)
4. **Selecție:** AIC/BIC $\Rightarrow$ **EGARCH(1,1)-t** câștigător
5. **Diagnostic:** reziduuri standardizate $\Rightarrow$ model adecvat
6. **VaR:** rolling window + backtesting Kupiec/Christoffersen $\Rightarrow$ model **validat**

Concluzii

- ▣ Distribuția Student-t este **esențială** pentru date financiare
- ▣ Leverage effect: modelele asimetrice **obligatorii** pentru acțiuni
- ▣ Backtesting sistematic: nu doar „arată bine”, ci **testat statistic**
- ▣ **Chiar dacă randamentele sunt greu de prognozat, volatilitatea lor este prognozabilă**

Cuprins

- Motivație
- Introducere în Modelarea Volatilității
- Modelul ARCH
- Modelul GARCH
- Modele GARCH Asimetrice
- Selectarea și Diagnosticarea modelelor
- Prognoza volatilității
- VaR Backtesting și Implementare
- Studiu de Caz: S&P 500
- **Studiu de Caz: Bitcoin**
- Utilizare IA
- Rezumat
- Quiz
- Bibliografie

Pasul 1: Datele – randamente zilnice Bitcoin

Descrierea datelor


- ▣ **Sursă:** Yahoo Finance (BTC-USD), date zilnice 2018–2024
- ▣ Randamente log: media $\approx 0.05\%$, volatilitate $\approx 3.5\%$

Statistici descriptive


Medie	Std. Dev.	Skewness	Kurtosis	Min	Max
0.05%	3.48%	-0.72	12.1	-46.5%	+22.5%

- ▣ Volatilitate $\sim 3\times$ mai mare decât S&P 500
- ▣ Kurtosis extremă $\Rightarrow$ riscul de pierderi mari

Pasul 1: Datele – randamente zilnice Bitcoin



Pasul 2: Testarea efectelor ARCH – Bitcoin




 TSA_ch5_btc_arch

Pasul 3: Volatilitatea condiționată – Bitcoin

Diagnostic GJR-GARCH(1,1)-t

- ▣ Ljung-Box pe z_t^2 : p-value = 0.41; ARCH-LM(10): p-value = 0.38 $\Rightarrow$ efecte ARCH eliminate
- ▣ Sign-bias test (joint): p-value = 0.54 $\Rightarrow$ asimetria captată de GJR
- ▣ Vârfuri volatilitate: martie 2020 (COVID), mai 2022 (Terra/Luna)



Pasul 4: Estimare și selecție modele – Bitcoin

Parametri estimați (SE robuste Bollerslev-Wooldridge)

Model	ω	α	β	γ	$\alpha + \beta$	ν	AIC
GARCH-t	0.42 (0.18)	0.131 (0.028)	0.848 (0.032)	—	0.979	4.82 (0.54)	9284
EGARCH-t	0.08 (0.03)	0.184 (0.033)	0.976 (0.008)	-0.061 (0.022)	—	4.79 (0.52)	9276
GJR-t	0.40 (0.17)	0.088 (0.026)	0.854 (0.033)	0.078 (0.030)	0.976	4.85 (0.56)	9271

Interpretare

- **GJR-GARCH-t câștigă** (cel mai mic AIC)
- $\nu \approx 4.8$: cozi **mult mai groase** decât S&P 500 ($\nu = 6.4$)
- $\alpha = 0.131$ (BTC) vs 0.088 (S&P) $\Rightarrow$ Bitcoin reacționează mai rapid la informații noi
- Leverage effect mai slab decât la acțiuni ($\gamma_{\text{BTC}} = 0.078$ vs 0.126)

Pasul 5: Backtesting rolling VaR – Bitcoin


Teste statistice (2421 zile out-of-sample)

Test	Statistică	p-value	Decizia
Încălcări	28/2421 ($\hat{p} = 1.16\%$)	—	Zona verde
Kupiec (uc)	0.57	0.450	Acceptat
Christoffersen (ind)	0.94	0.333	Acceptat
Combinat (cc)	1.51	0.471	Acceptat

Interpretare

- ▣ Volatilitatea variază de la 3% la 38% $\Rightarrow$ rolling window **esențial**
- ▣ Toate testele **acceptate**: model valid pentru managementul riscului

Pasul 5: Rolling VaR – Bitcoin



Pasul 5: VaR rolling window – Bitcoin

Rolling window GJR-GARCH-t (W=500 zile, VaR 1%)

- Estimare rolling pe fereastră de 500 zile cu prognoză VaR zilnică

Caracteristici VaR rolling Bitcoin (2018–2024)

- VaR mediu: 9.34% ($\approx$ EUR 93.400 / 1M EUR)
- VaR maxim: 37.54% $\Rightarrow$ crash COVID martie 2020
- VaR minim: 2.90% $\Rightarrow$ perioadă calmă
- Bitcoin: VaR rolling $\sim 4\times$ mai mare decât S&P 500 la aceeași expunere

Comparație finală: S&P 500 vs Bitcoin

Rezumat comparativ

	S&P 500	Bitcoin
Volatilitate medie	1.2%	3.5%
Kurtosis	13.8	12.1
Student-t ν	6.42	4.82
Cel mai bun model	EGARCH(1,1)-t	GJR-GARCH(1,1)-t
Leverage effect	Puternic ($\gamma = -0.12$)	Moderat ($\gamma = 0.078$)
Half-life	~60 zile	~42 zile
Rolling VaR 1% mediu	2.53%	9.34%
Rolling VaR 1% maxim	22.02% (COVID)	37.54% (COVID)
Rolling ES 1% mediu	3.42%	12.87%
Kupiec	Acceptat ($p=0.145$)	Acceptat ($p=0.450$)
Christoffersen (ind)	Acceptat ($p=0.375$)	Acceptat ($p=0.333$)

Comparație finală: S&P 500 vs Bitcoin (cont.)

Concluzie generală

- Re-estimare GARCH la fiecare pas: Kupiec + Christoffersen **acceptate**
- Rolling window VaR: **obligatoriu** $\Rightarrow$ VaR static complet inadecvat
- Student-t + model asimetric: **esențiale** pentru ambele piețe

Formule principale

Modele de volatilitate

- ▣ **ARCH(q):** $\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2$
- ▣ **GARCH(1,1):** $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$
- ▣ **EGARCH:** $\ln(\sigma_t^2) = \omega + \alpha(|z_{t-1}| - \mathbb{E}[|z|]) + \gamma z_{t-1} + \beta \ln(\sigma_{t-1}^2)$
- ▣ **GJR-GARCH:** $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \gamma \varepsilon_{t-1}^2 I_{t-1} + \beta \sigma_{t-1}^2$

Proprietăți și măsuri

- ▣ **Var. necond.:** $\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta}$ **Half-life:** $HL = \frac{\ln(0.5)}{\ln(\alpha+\beta)}$
- ▣ **VaR:** $\text{VaR}_\alpha = z_\alpha \cdot \sigma_{T+1}$ **Staționaritate:** $\alpha + \beta < 1$
- ▣ **ARCH-LM:** $LM = T \cdot R^2 \sim \chi^2(q)$

Exercițiu AI: Gândire critică

Prompt de testat în ChatGPT / Claude / Copilot

"Folosind yfinance, descarcă prețurile zilnice de închidere S&P 500 (^GSPC) din 2018-01-01 până în 2024-12-31 (aprox. 1.750 observații). Calculează randamentele logaritmice zilnice. Testează efectele ARCH, ajustează un model GARCH(1,1) și prognozează volatilitatea pe următoarele 20 de zile de tranzacționare. Vreau cod Python complet."

Exercițiu:

1. Rulați prompt-ul într-un LLM la alegere și analizați critic răspunsul
2. Calculează randamentele logaritmice corect? Elimină media înainte de GARCH?
3. Cum testează efectele ARCH? Folosește testul LM al lui Engle?
4. Separă ecuația mediei de ecuația varianței?
5. Discută efectele asimetrice (GJR-GARCH, EGARCH)?

Exercițiu AI: Gândire critică (cont.)

Exercițiu (continuare):

6. Estimările VaR sunt calculate din distribuția condițională?
7. Identificați cel puțin **două erori factuale** sau presupuneri discutabile din output-ul LLM
8. Verifică codul constrângerea de staționaritate $\alpha + \beta < 1$? Dacă nu, adăugați-o
9. Comparați estimarea VaR a LLM-ului cu rezultatele din acest capitol. Sunt consistente?

Atenție: Codul generat de AI poate rula fără erori și arăta profesional. *Asta nu înseamnă că e corect.*

Rezumat – capitolul 5: Modele de volatilitate

Concepte fundamentale

- ▣ **ARCH(q)**: varianța condiționată depinde de pătratele erorilor trecute (Nobel 2003)
- ▣ **GARCH(p,q)**: adaugă lag-uri ale varianței pentru persistență (GARCH(1,1) în 90% din cazuri)
- ▣ **EGARCH**: permite leverage effect, fără restricții de pozitivitate
- ▣ **GJR-GARCH/TGARCH**: captură asimetria cu variabile indicator

Aplicații

- ▣ Măsurarea și prognoza riscului (VaR, ES)
- ▣ Prețul derivatelor, hedging dinamic, managementul portofoliului

Sfat practic

- ▣ Începe cu GARCH(1,1), verifică leverage effect, alege distribuția care minimizează AIC/BIC.
 - ▶ Student-t adesea superior distribuției normale

Întrebarea 1


Întrebare

- ☐ Ce descrie cel mai bine fenomenul de *volatility clustering* în seriile financiare?

Variante de răspuns

- (A) Randamentele financiare sunt distribuite normal și independente
- (B) Perioadele de volatilitate ridicată sunt urmate de perioade de volatilitate ridicată, și invers
- (C) Volatilitatea este constantă în timp (homoscedasticitate)
- (D) Corelația dintre randamente este întotdeauna pozitivă

Întrebarea 1: Răspuns



Răspuns: (B)

- ☐ Volatility clustering este un fapt stilizat fundamental. Implică faptul că varianța condiționată este **predictibilă**, motivând modelele ARCH/GARCH.

Întrebarea 2

Întrebare


- ☐ Care este diferența principală dintre un model ARCH(q) și un model GARCH(p,q)?

Variante de răspuns

- (A) GARCH modelează media condiționată, ARCH modelează varianța
- (B) ARCH include lag-uri ale varianței condiționate, GARCH nu
- (C) GARCH adaugă lag-uri ale varianței condiționate (σ_{t-j}^2) pe lângă pătratele erorilor
- (D) ARCH este mai parcimonios decât GARCH

Întrebarea 2: Răspuns

ARCH vs GARCH: Parsimony



Răspuns: (C)

- GARCH(1,1) captează aceeași persistență ca ARCH(q) cu doar 2 parametri în loc de q . În practică, GARCH(1,1) este suficient în 90% din cazuri.

Întrebarea 3


Întrebare

□ Ce este *leverage effect* și ce modele GARCH îl captează?

Variante de răspuns

- (A) Șocurile pozitive cresc volatilitatea mai mult; captat de GARCH standard
- (B) Șocurile negative cresc volatilitatea mai mult; captat de EGARCH și GJR-GARCH
- (C) Volatilitatea este simetrică; captat de toate modelele GARCH
- (D) Efectul de levier financiar asupra prețului acțiunilor; captat de IGARCH

Întrebarea 3: Răspuns



Răspuns: (B)

- ☐ Scăderile de preț cresc volatilitatea **mai mult** decât creșterile de aceeași magnitudine. GARCH standard folosește ε_{t-1}^2 , pierzând informația de semn.

Întrebarea 4

Întrebare


□ Care este condiția de staționaritate pentru un model GARCH(1,1)?

Variante de răspuns

- (A) $\alpha + \beta = 1$
- (B) $\alpha > 0$ și $\beta > 0$
- (C) $\alpha + \beta < 1$, cu $\omega > 0$, $\alpha \geq 0$, $\beta \geq 0$
- (D) $\alpha \cdot \beta < 1$

Întrebarea 4: Răspuns

GARCH(1,1) Stationarity: $\alpha + \beta < 1$



Răspuns: (C)

- ☐ Asigură existența varianței necondiționate finite: $\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta}$. Când $\alpha + \beta = 1$ (IGARCH), varianța este infinită.

Întrebarea 5

Întrebare computațională aplicată

Un model GARCH(1,1) estimat pe randamente zilnice logaritmice (%) dă: $\omega = 0.05$, $\alpha = 0.15$, $\beta = 0.82$.

- (a) Calculați varianța necondiționată $\bar{\sigma}^2$ și volatilitatea anualizată.
- (b) Calculați half-life-ul unui șoc de volatilitate.
- (c) Pentru un portofoliu de 2 000 000 EUR, calculați VaR pe 1 zi la 1% sub distribuția normală și Student- t ($\nu = 5$). (Folosiți $\sigma_{T+1} = \bar{\sigma}$.)

Întrebarea 5: Răspuns

Rezolvare


(a) $\bar{\sigma}^2 = \frac{0.05}{1-0.97} = 1.667 \Rightarrow \bar{\sigma} = 1.291\%$ zilnic, $\sigma_{an} = 1.291\% \times \sqrt{252} \approx 20.5\%$

(b) $HL = \frac{\ln 0.5}{\ln(0.97)} = \frac{-0.693}{-0.0305} \approx 23$ zile

(c) $V = 2,000,000$ EUR, $\sigma_{T+1} = 1.291\%$:

Normal: $\text{VaR}_{1\%} = 2.326 \times 0.01291 \times 2M = 60\,066$ EUR

Student-t(5): $\text{VaR}_{1\%} = \frac{3.365}{\sqrt{5/3}} \times 0.01291 \times 2M = 67\,300$ EUR (+12%!)



TSA_ch5_quiz5_halflife

Bibliografie I — Lucrări fundamentale

ARCH/GARCH — modele fondatoare

- Engle, R.F. (1982). Autoregressive Conditional Heteroscedasticity, *Econometrica*, 50(4), 987–1007.
- Bollerslev, T. (1986). Generalized Autoregressive Conditional Heteroskedasticity, *J. Econometrics*, 31(3), 307–327.
- Nelson, D.B. (1991). Conditional Heteroskedasticity in Asset Returns, *Econometrica*, 59(2), 347–370.

Modele asimetrice și extensii

- Glosten, L.R., Jagannathan, R., & Runkle, D.E. (1993). Expected Value and Volatility of Nominal Excess Return on Stocks, *J. Finance*, 48(5), 1779–1801.
- Ding, Z., Granger, C.W.J., & Engle, R.F. (1993). A Long Memory Property of Stock Market Returns, *J. Empirical Finance*, 1(1), 83–106.
- Engle, R.F. & Ng, V.K. (1993). Measuring and Testing the Impact of News on Volatility, *J. Finance*, 48(5), 1749–1778.
- Zakoïan, J.-M. (1994). Threshold Heteroskedastic Models, *J. Econ. Dynamics & Control*, 18(5), 931–955.

Bibliografie II — Estimare și inferență

Estimare, robustețe și persistență

- Bollerslev, T., & Wooldridge, J.M. (1992). Quasi-MLE and Inference in Dynamic Models with Time-Varying Covariances, *Econometric Reviews*, 11(2), 143–172.
- White, H. (1982). Maximum Likelihood Estimation of Misspecified Models, *Econometrica*, 50(1), 1–25.
- Engle, R.F., & Bollerslev, T. (1986). Modelling the Persistence of Conditional Variances, *Econometric Reviews*, 5(1), 1–50.
- Nyblom, J. (1989). Testing for the Constancy of Parameters Over Time, *JASA*, 84(405), 223–230.

Memorie lungă și componente

- Baillie, R.T., Bollerslev, T., & Mikkelsen, H.O. (1996). Fractionally Integrated GARCH, *J. Econometrics*, 74(1), 3–30.
- Engle, R.F., & Lee, G.J. (1999). A Long-Run and Short-Run Component Model of Stock Return Volatility, in *Cointegration, Causality, and Forecasting*, Oxford UP.

Bibliografie III — Prognoze și management al riscului

Comparare de modele și prognoze

- Mincer, J.A., & Zarnowitz, V. (1969). The Evaluation of Economic Forecasts, NBER, 1–46.
- Diebold, F.X., & Mariano, R.S. (1995). Comparing Predictive Accuracy, *JBES*, 13(3), 253–263.
- Hansen, P.R., & Lunde, A. (2005). A Forecast Comparison of Volatility Models, *J. Appl. Econometrics*, 20(7), 873–889.
- Hansen, P.R., Lunde, A., & Nason, J.M. (2011). The Model Confidence Set, *Econometrica*, 79(2), 453–497.

VaR și Expected Shortfall

- Kupiec, P.H. (1995). Techniques for Verifying the Accuracy of Risk Measurement Models, *J. Derivatives*, 3(2), 73–84.
- Christoffersen, P.F. (1998). Evaluating Interval Forecasts, *Int. Econ. Review*, 39(4), 841–862.
- McNeil, A.J., & Frey, R. (2000). Tail-Related Risk Measures for Heteroscedastic Financial Time Series, *J. Emp. Finance*, 7, 271–300.
- Acerbi, C., & Székely, B. (2014). Backtesting Expected Shortfall, *Risk Magazine*, December.

Bibliografie IV — Volatilitate realizată

Frecvență înaltă și volatilitate realizată

- ▣ Barndorff-Nielsen, O.E., & Shephard, N. (2002). Econometric Analysis of Realized Volatility, *JRSS-B*, 64(2), 253–280.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., & Labys, P. (2003). Modeling and Forecasting Realized Volatility, *Econometrica*, 71(2), 579–625.
- ▣ Corsi, F. (2009). A Simple Approximate Long-Memory Model of Realized Volatility, *J. Fin. Econometrics*, 7(2), 174–196.
- ▣ Hansen, P.R., Huang, Z., & Shek, H.H. (2012). Realized GARCH, *J. Appl. Econometrics*, 27(6), 877–906.

Manuale și monografii

- ▣ Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed., Wiley.
- ▣ Francq, C., & Zakoïan, J.-M. (2019). *GARCH Models*, 2nd ed., Wiley.
- ▣ McNeil, A.J., Frey, R., & Embrechts, P. (2015). *Quantitative Risk Management*, 2nd ed., Princeton UP.
- ▣ Franke, J., Härdle, W.K., & Hafner, C.M. (2019). *Statistics of Financial Markets*, 4th ed., Springer.

Bibliografie V — Resurse și referințe suplimentare

Referințe suplimentare

- ▣ Hamilton, J.D. (1994). *Time Series Analysis*, Princeton UP.
- ▣ Bollerslev, T., Engle, R.F., & Nelson, D.B. (1994). ARCH Models, in *Handbook of Econometrics*, Vol. 4, Elsevier.
- ▣ Patton, A.J. (2011). Volatility Forecast Comparison Using Imperfect Volatility Proxies, *J. Econometrics*, 160(1).

Resurse online și cod

- ▣ **Quantlet**: <https://quantlet.com> — Platformă de cod pentru metode cantitative
- ▣ **Quantinar**: <https://quantinar.com> — Platformă de învățare pentru metode cantitative
- ▣ **GitHub TSA**: https://github.com/QuantLet/TSA/tree/main/TSA_ch5 — Cod Python pentru acest capitol
- ▣ **Cursul online**: <https://danpele.github.io/Time-Series-Analysis/> — Materialele complete ale cursului

Ce urmează?

Capitolul 5b: Modele GARCH Multivariate

- ▣ **Covarianță condiționată:** modelarea dinamicii comune a mai multor active
- ▣ **DCC-GARCH** (Dynamic Conditional Correlation — Engle, 2002): corelații dinamice condiționate
- ▣ **BEKK** (Baba-Engle-Kraft-Kroner, 1995): garantarea pozitivității matricei H_t
- ▣ **CCC-GARCH** (Constant Conditional Correlation — Bollerslev, 1990): corelații condiționate constante
- ▣ **Aplicații:** hedging optim, alocarea portofoliului, contagiune financiară

Întrebări?

Competențe dobândite

La finalul capitolului, studentul trebuie să poată:

1. **Recunoaște** efecte ARCH în date (ARCH-LM, Ljung-Box pe r_t^2 , Q-Q plot)
2. **Estima și interpreta** un GARCH(1,1) — rolul lui α , β , varianța necondiționată, half-life
3. **Decide** dacă este nevoie de asimetrie (leverage effect $\Rightarrow$ EGARCH / GJR-GARCH)
4. **Alege** o distribuție a inovațiilor (Normal vs Student-t vs GED)
5. **Produce** un forecast de volatilitate (rolling window, convergența la $\bar{\sigma}^2$)
6. **Calcula și valida** un VaR (backtesting Kupiec + Christoffersen)

Mesajul central al capitolului

- ☐ Chiar dacă randamentele sunt greu de prognozat, volatilitatea lor este adesea prognozabilă.
- ☐ Aceasta este ideea fundamentală care justifică întreaga econometrie a volatilității.

Vă Mulțumim!

Întrebări?

Materialele cursului sunt disponibile la:

<https://danpele.github.io/Time-Series-Analysis/>



Quantlet



Quantinar