

Analiza și Prognoza Seriilor de Timp

Capitolul 5b: Modele GARCH Multivariate



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Obiective de învățare

La finalul acestui capitol, veți fi capabili să:

1. Explicați de ce **modelarea multivariată a volatilității** este necesară
2. Formulați și estimați modele **VEC**, **BEKK**, **CCC** și **DCC**
3. Interpretați **corelații dinamice** și descompuneri ale covarianței
4. Aplicați GARCH multivariat pentru **optimizare de portofoliu**, **hedging** și **managementul riscului**

Competențe practice

- ⊡ Implementare Python cu pachetele `rmgarch` / `mgarch`
- ⊡ Interpretarea matricelor de covariață variabile în timp
- ⊡ Rapoarte de hedging dinamic și ponderi de portofoliu

Concluzie cheie: *Nu învățați modele — învățați cum să măsurați riscul real de portofoliu.*

Cuprins

Fundamente

- ⊡ Motivație: De la univariat la multivariat
- ⊡ Cadrul GARCH multivariat
- ⊡ Modele VEC și VEC diagonal
- ⊡ Modelul BEKK
- ⊡ Corelația condițională constantă (CCC)
- ⊡ Corelația condițională dinamică (DCC)

Aplicații

- ⊡ Alte modele GARCH multivariate
- ⊡ Estimare și *curse of dimensionality*
- ⊡ Studii de caz pe date reale
- ⊡ Optimizare de portofoliu
- ⊡ Hedging dinamic și VaR
- ⊡ Rezumat și Test

Povestea acestui capitol: problema

Întrebare fundamentală: *Cum modelăm riscul când activele se mișcă împreună — și acea co-mișcare se schimbă în timp?*

Problema

- Corelațiile dintre active **se schimbă în timp** — și cresc brusc în perioade de criză
- Ignorarea lor duce la portofolii greșite, hedging ineficient și risc subestimat

Dificultatea

- Modelarea a N active necesită $N(N+1)/2$ elemente de covarianță variabile în timp
- **Blestemul dimensionalității** face cele mai multe abordări infezabile
- Matricea de covarianță trebuie să fie **pozitiv definită** la fiecare pas

Povestea acestui capitol: soluțiile

Foaie de parcurs: *Fiecare model rezolvă o problemă dar creează alta — până la DCC.*

De la general la practic

- **VEC**: cel mai general model — dar inutilizabil în practică ($O(N^4)$ parametri)
- **BEKK**: garantează pozitiv-definirea — dar nu scalează peste $N = 5$
- **CCC**: simplu și rapid — dar corelațiile sunt *constante* (greșit empiric)
- **DCC**: compromisul optim — corelații dinamice cu **doar 2 parametri suplimentari**

Concluzie cheie: *Acest capitol este o călătorie de la generalitate la practicabilitate. DCC câștigă pentru că scalează.*

De ce multivariat?

Problema

- GARCH univariat modelează volatilitatea fiecărui activ **în izolare**
- Ignoră **co-mișcările** (*co-movements*) dintre active:
  - Cum se propagă volatilitatea activului A la activul B?
  - Cum se schimbă corelațiile între active în timp?

Dar în realitate...

- Piețele sunt interconectate — șocurile se propagă între active
- Deciziile financiare necesită **întreaga matrice de covarianță** H_t, nu doar variațe individuale

Concluzie cheie: *Riscul nu este suma riscurilor individuale.*

Ce modelăm: matricea de covarianță H_t

O propoziție: H_t *este "prognoza meteo" pentru risc — se actualizează zilnic pe măsură ce sosesc informații noi.*

Formulare

- Având N active cu vectorul de randamente $r_t = (r_{1t}, \ldots, r_{Nt})'$, trebuie să modelăm:

$$H_t = \mathrm{Var}(r_t \mid \mathcal{F}_{t-1})$$

- **matricea de covarianță condițională variabilă în timp**
- H_t conține toate variațele **și** toate covariațele perechi la momentul t

De ce este dificilă modelarea lui H_t

O propoziție: *Numărul de parametri explodează odată cu dimensiunea portofoliului.*

Trei provocări simultane

- H_t are $N(N+1)/2$ elemente unice — pentru $N = 50$: **1.275 parametri** la fiecare t
- Trebuie să fie **pozitiv definită** la fiecare pas (altfel: variantă negativă de portofoliu)
- Trebuie să capteze corelații **dinamice**, nu doar volatilități

Concluzie cheie: *Fiecare model GARCH multivariat este un răspuns diferit la același compromis: flexibilitate vs. fezabilitate.*

Aplicația 1: alocarea portofoliului

Markowitz cu input-uri variabile în timp

- Ponderi optime: $w_t^* = \frac{H_t^{-1}\mu_t}{1' H_t^{-1}\mu_t}$
- Ponderile se schimbă **zilnic** pe măsură ce H_t se actualizează
- Matricele de covarianță statice duc la **alocări sub-optime** în perioade turbulente

Problema

- Dacă H_t este tratat ca constant $\Rightarrow$ ponderile sunt greșite în criză
- Rebalansare prea lentă $\Rightarrow$ risc excesiv; prea rapidă $\Rightarrow$ cost excesiv

Concluzie cheie: *Portofoliile optime sunt dinamice, nu statice.*

Aplicația 2: hedging dinamic

Raportul de hedging cu variantă minimă

- Hedge optim: $h_t^* = \frac{\sigma_{12,t}}{\sigma_{22,t}}$
- Hedge mai mult când **covarianța** spot–futures crește
- Necesită **covariațe variabile în timp**, nu doar variațe

De ce eșuează hedging-ul constant

- În criză: structura covarianței se schimbă rapid
- Un raport de hedging fix **sub-acoperă** sau **supra-acoperă** în funcție de regim

Concluzie cheie: *Protecția depinde de relația dintre active, nu de volatilitățile individuale.*

Aplicația 3: managementul riscului (VaR)

VaR de portofoliu

- $\text{VaR}_t^p = -\text{w}'\boldsymbol{\mu}_t + z_\alpha\sqrt{\text{w}'\text{H}_t\text{w}}$
- Riscul depinde de **întreaga matrice de covarianță**, nu doar de volatilitățile individuale

Problema critică

- Ignorarea corelațiilor variabile $\Rightarrow$ **subestimarea riscului** în criză
- Corelațiile cresc **exact atunci când diversificarea este cel mai necesară**

Concluzie cheie: *Corelațiile cresc exact când ai cea mai mare nevoie de diversificare.*

Fapt stilizat: corelațiile NU sunt constante

Evidențe empirice

- Corelațiile între active **nu sunt constante** — cresc în perioadele de turbulență
- Fenomenul este cunoscut ca **ruptura corelațiilor** (*correlation breakdown*) sau **contagiune**
- Corelația S&P 500 – DAX a sărit de la 0.5 la 0.9 în criza din 2008
- **Diversificarea eșuează exact atunci când este cel mai necesară**

Concluzie cheie: *Corelațiile sunt dependente de regim — cresc brusc în criză și se comprimă în perioade calme.*

Exemplu numeric: impactul corelațiilor asupra riscului

Portofoliu echilibrat: 50% acțiuni, 50% obligațiuni

- $\sigma_1 = 20\%$ (acțiuni), $\sigma_2 = 5\%$ (obligațiuni)
- Varianța portofoliului: $\sigma_p^2 = w_1^2\sigma_1^2 + w_2^2\sigma_2^2 + 2w_1w_2\rho\sigma_1\sigma_2$

Regim	ρ	σ_p	VaR 99% (1 zi)
Piață calmă	-0.20	9.22%	-2.14%
Piață normală	$+0.10$	10.25%	-2.38%
Criză (2008)	$+0.60$	11.73%	-2.73%

Interpretare: *Riscul crește cu* ***27%*** *doar din schimbarea corelației — sincronizarea mișcărilor, nu volatilitatea individuală, determină riscul.*

De ce contează: implicații practice

Modelele cu corelații constante sunt periculoase

- **Portofolii**: ponderile bazate pe corelații depășite sunt sub-optime
- **Hedging**: rapoartele fixe sub-performează în schimbări de regim
- **VaR**: modelele cu ρ constant subestimează riscul de coadă în criză

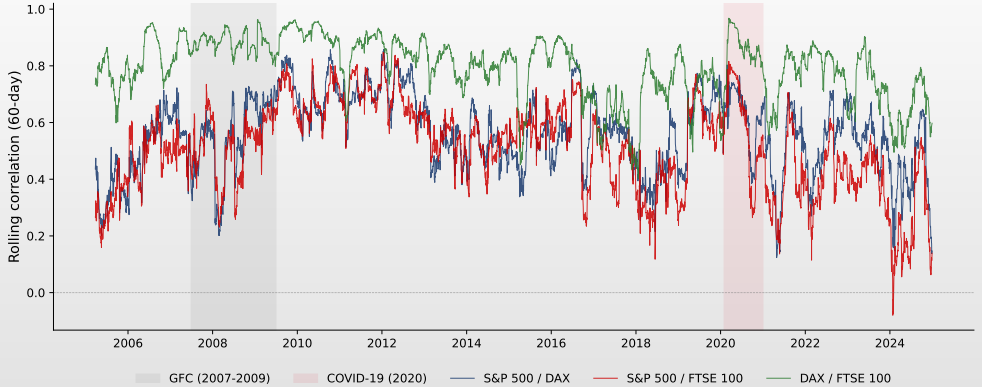
Implicații reglementare

Modelele cu corelații constante sunt **inadecvate** pentru:

- Testare de stres și analiză de scenarii
- Rebalansarea portofoliului în timp real
- Calculul capitalului reglementar (Basel III/IV)

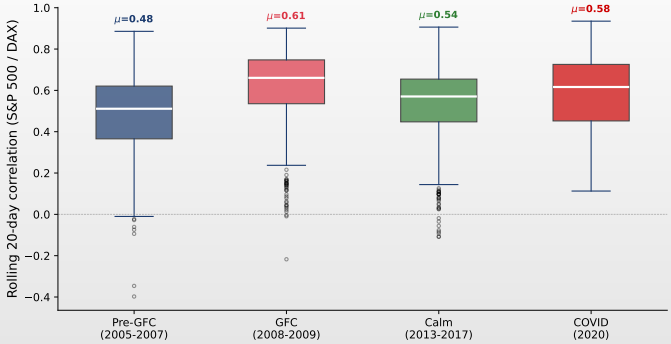
Concluzie cheie: *Modelele cu corelații constante sunt periculoase în practică.*

Evidență empirică: corelații mobile S&P 500, DAX, FTSE 100



TSA_ch5b_rolling_corr

Distribuția corelațiilor: regimuri de criză vs. calm



Observații cheie

- Mediana corelației crește semnificativ în perioade de criză (GFC — *Global Financial Crisis*, COVID)
- Dispersia corelațiilor crește — mai multă incertitudine în relațiile între piețe

TSA_ch5b_crisis_boxplot

Formularea generală

Procesul multivariat de randamente

- Fie $r_t = (r_{1t}, \ldots, r_{Nt})'$ un vector N-dimensional de randamente:

$$r_t = \mu_t + \varepsilon_t \tag{1}$$

$$\varepsilon_t = H_t^{1/2} z_t, \qquad z_t \overset{iid}{\sim} \mathcal{N}(0, I_N) \tag{2}$$

- μ_t = vectorul mediei condiționale (adesea un VAR sau o constantă)
- $H_t = \mathrm{Var}(\varepsilon_t \mid \mathcal{F}_{t-1})$ = matricea de covarianță condițională $N \times N$
- $H_t^{1/2}$ = orice rădăcină pătratică a.î. $H_t^{1/2}(H_t^{1/2})' = H_t$

Intuiție: $H_t^{1/2} z_t$ *transformă șocuri independente în randamente corelate — "rădăcina pătrată" imprimă structura de dependență.*

Provocarea dimensionalității (*curse of dimensionality*)

- H_t are $N(N+1)/2$ elemente unice
- Pentru $N = 50$ active: **1.275 de parametri variabili în timp** la fiecare t

Semi-vectorizarea — operatorul vech(·) (*half-vectorization*)

Definiție

- Operatorul vech : $\mathbb{R}^{N\times N} \to \mathbb{R}^{N^*}$ stochează **coloană cu coloană** elementele de pe și sub diagonala principală a unei matrice simetrice
- Dimensiunea vectorului rezultat: $N^* = N(N+1)/2$
- Matricea H_t este **simetrică**: $h_{ij,t} = h_{ji,t}$ — vech elimină cele $N(N-1)/2$ elemente redundante

$$\mathrm{H}_t = \begin{pmatrix} h_{11,t} & h_{12,t} & h_{13,t} \\ h_{12,t} & h_{22,t} & h_{23,t} \\ h_{13,t} & h_{23,t} & h_{33,t} \end{pmatrix} \xrightarrow{\text{vech}} \begin{pmatrix} h_{11,t} \\ h_{12,t} \\ h_{13,t} \\ h_{22,t} \\ h_{23,t} \\ h_{33,t} \end{pmatrix}$$

Elementele gri sunt duplicate — vech le elimină.

Rol central în GARCH multivariat

- Permite scrierea modelului ca ecuație vectorială: $\text{vech}(\mathrm{H}_t) = \mathrm{c} + \mathrm{A}\,\text{vech}(\varepsilon_{t-1}\varepsilon_{t-1}') + \mathrm{B}\,\text{vech}(\mathrm{H}_{t-1})$
- Dimensiune: $N^* = N(N+1)/2$ — pentru $N=2$: 3 elemente; $N=10$: 55; $N=100$: 5.050

Cerința de pozitiv-definire

De ce contează pozitiv-definirea

- Matricea H_t trebuie să fie **pozitiv definită** (p.d.) $\forall t$:
  - Varianța portofoliului: $\sigma_p^2 = w' H_t w > 0$ pentru orice $w \neq 0$
  - Log-verosimilitatea implică $\log|H_t|$ și H_t^{-1} — ambele necesită p.d.
  - Descompunerea Cholesky pentru simulare necesită p.d.

Strategii pentru asigurarea pozitiv-definirii

1. **Restricționarea parametrilor** a.î. H_t p.d. prin construcție (BEKK)
2. **Descompunerea** $H_t = D_t R_t D_t$ și modelarea separată (DCC)
3. **Spațiul factorilor** pentru reducerea dimensionalității (Factor GARCH, GO-GARCH)

Descompunerea Cholesky (*Cholesky Decomposition*)

Definiție

- Orice matrice **simetrică pozitiv definită** H ($N \times N$) admite o **factorizare unică**: $H = LL'$
- L este o matrice **inferior triunghiulară** cu elemente diagonale **strict pozitive**
- Complexitate: $O(N^3/3)$ — de **două ori mai rapidă** decât inversarea directă

Exemplu: cazul 2×2

- Fie $H = \begin{pmatrix} h_{11} & h_{12} \\ h_{12} & h_{22} \end{pmatrix}$. Atunci $L = \begin{pmatrix} \sqrt{h_{11}} & 0 \\ h_{12}/\sqrt{h_{11}} & \sqrt{h_{22} - h_{12}^2/h_{11}} \end{pmatrix}$

Rolul în GARCH multivariat

- **Simulare**: $\varepsilon_t = L_t z_t$, unde $z_t \sim N(0, I)$ — generează șocuri corelate
- **Log-verosimilitate**: $\log |H_t| = 2 \sum_i \log L_{ii}$ — evită calculul direct al determinantului
- **Inversare**: rezolvă $L_t x = \varepsilon_t$ prin substituție directă ($O(N^2)$ vs. $O(N^3)$)

Proliferarea parametrilor: *curse of dimensionality*

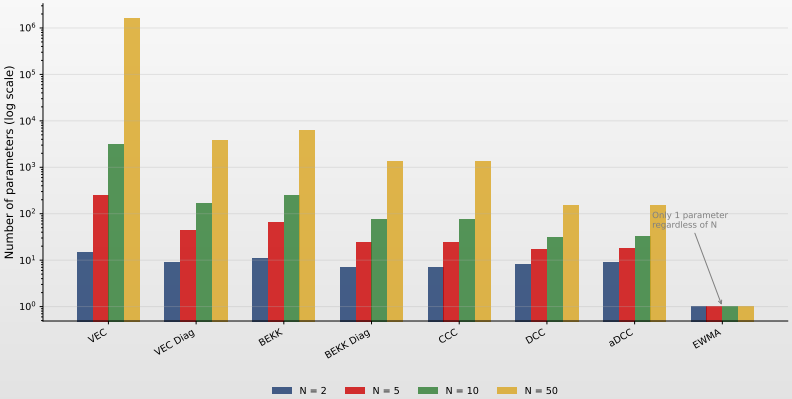
Numărul de parametri pe model

Model	Parametri	$N = 5$
VEC(1,1)	$N(N+1)/2 + 2[N(N+1)/2]^2$	465
VEC Diagonal(1,1)	$3 \times N(N+1)/2$	45
BEKK(1,1)	$N(N+1)/2 + 2N^2$	65
BEKK Diagonal(1,1)	$N(N+1)/2 + 2N$	25
CCC(1,1)	$3N + N(N-1)/2$	25
DCC(1,1)	$3N + N(N-1)/2 + 2$	27

Implicație practică

- Pentru N mare, doar modelele **puternic *parsimonious*** (CCC, DCC, BEKK scalar) sunt fezabile
- VEC/BEKK complet devin intractabile computațional pentru $N > 5$

Curse of dimensionality: vizualizare



TSA_ch5b_param_comparison

Log-verosimilitatea normală multivariată

Log-verosimilitatea generală

- Pentru T observații de randamente N-dimensionale:

$$\mathcal{L}(\theta) = -\frac{TN}{2}\log(2\pi) - \frac{1}{2}\sum_{t=1}^{T}\left[\underbrace{\log|\mathrm{H}_t|}_{\text{penalizare volum}} + \underbrace{\varepsilon_t'\mathrm{H}_t^{-1}\varepsilon_t}_{\text{distanța Mahalanobis}}\right]$$

Intuiție: verosimilitatea penalizează atât covarianța mare ("prognoză difuză") cât și reziduurile standardizate mari ("prognoză proastă").

Provocări computaționale

- La fiecare t: calculează H_t ($O(N^2)$), inversa ($O(N^3)$) și determinantul ($O(N^3)$)
- **Truc Cholesky**: dacă $\mathrm{H}_t = \mathrm{L}_t\mathrm{L}_t'$:
  - $\log|\mathrm{H}_t| = 2\sum_i \log L_{ii}$
  - Rezolvă $\mathrm{L}_t x = \varepsilon_t$ prin substituție directă
- Pentru DCC: estimarea în două etape reduce dramatic costul

Modelul VEC — *VECtorized* (Bollerslev, Engle & Wooldridge, 1988)

Definiție

- **VEC** = *VECtorized* — denumire derivată din operatorul vech(·) (semi-vectorizare). Modelul VEC(1,1):

$$\text{vech}(H_t) = \underbrace{c}_{\text{interceptare}} + \underbrace{A\,\text{vech}(\varepsilon_{t-1}\varepsilon_{t-1}')}_{\text{impactul șocurilor}} + \underbrace{B\,\text{vech}(H_{t-1})}_{\text{persistență}}$$

- unde c: vector $N^* \times 1$; A, B: matrice $N^* \times N^*$; $N^* = N(N+1)/2$

Intuiție: covariança de azi = nivel de bază + șocurile de ieri + covariança de ieri. A *complet permite oricărui șoc să afecteze orice element de covariață.*

Probleme

- Pentru $N = 3$: $N^* = 6$, deci A și B sunt matrice $6 \times 6 \Rightarrow$ **78 parametri**
- **Nicio garanție** că H_t este pozitiv definită
- Condițiile pentru p.d. sunt complexe și greu de impus la estimare

Produsul Hadamard (*Hadamard Product*)

Definiție

- Fie $\mathrm{A}, \mathrm{B} \in \mathbb{R}^{m \times n}$. **Produsul Hadamard** $\mathrm{A} \odot \mathrm{B}$ este multiplicarea **element cu element**:

$$(\mathrm{A} \odot \mathrm{B})_{ij} = a_{ij} \cdot b_{ij}$$

- Matricele trebuie să aibă **aceeași dimensiune** — rezultatul păstrează dimensiunea $m \times n$

Exemplu: cazul 2×2

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \odot \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix} = \begin{pmatrix} 1 \cdot 5 & 2 \cdot 6 \\ 3 \cdot 7 & 4 \cdot 8 \end{pmatrix} = \begin{pmatrix} 5 & 12 \\ 21 & 32 \end{pmatrix}$$

Rolul în GARCH multivariat

- VEC Diagonal: $\mathrm{vech}(\mathrm{H}_t) = \mathrm{c} + \mathrm{a} \odot \mathrm{vech}(\varepsilon_{t-1}\varepsilon'_{t-1}) + \mathrm{b} \odot \mathrm{vech}(\mathrm{H}_{t-1})$
- Fiecare element al lui H_t primește **proprii coeficienți** a_k, b_k — fără interacțiuni încrucișate
- Reduce parametrii de la N^{*2} (VEC complet) la $3N^*$ (VEC Diagonal)

Modelul VEC Diagonal

Definiție (Bollerslev, Engle & Wooldridge, 1988)

- Se restricționează A și B să fie **diagonale**: $\text{vech}(H_t) = c + a \odot \text{vech}(\varepsilon_{t-1}\varepsilon'_{t-1}) + b \odot \text{vech}(H_{t-1})$
- $\odot$ = produsul Hadamard; a, b: vectori $N^* \times 1$

Element cu element pentru $N = 2$

$$h_{11,t} = c_{11} + a_{11}\,\varepsilon^2_{1,t-1} + b_{11}\,h_{11,t-1} \tag{3}$$

$$h_{12,t} = c_{12} + a_{12}\,\varepsilon_{1,t-1}\varepsilon_{2,t-1} + b_{12}\,h_{12,t-1} \tag{4}$$

$$h_{22,t} = c_{22} + a_{22}\,\varepsilon^2_{2,t-1} + b_{22}\,h_{22,t-1} \tag{5}$$

Intuiție: fiecare variață/covariață urmează propriul GARCH — șocul activului 2 nu poate afecta varianța activului 1.

Compromis

- $3N^*$ parametri (gestionabil), dar fiecare element evoluează **independent** — fără propagare între active

VEC: exemplu bivariat

Exemplu: două active ($N = 2$)

- Cu modelul VEC complet, $N^* = 3$:

$$\begin{pmatrix} h_{11,t} \\ h_{12,t} \\ h_{22,t} \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \\ c_3 \end{pmatrix} + \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} \begin{pmatrix} \varepsilon_{1,t-1}^2 \\ \varepsilon_{1,t-1}\varepsilon_{2,t-1} \\ \varepsilon_{2,t-1}^2 \end{pmatrix} + \mathrm{B} \begin{pmatrix} h_{11,t-1} \\ h_{12,t-1} \\ h_{22,t-1} \end{pmatrix}$$

Interpretare

- Elementele off-diagonal ale lui A captează **propagarea șocurilor între active**
  - a_{13}: impactul șocului activului 2 asupra variației activului 1
- Elementele off-diagonal ale lui B captează **propagarea persistenței volatilității**
- Total parametri: $3 + 9 + 9 = 21$ (doar pentru 2 active!)

VEC: perspectivă cheie și capcane frecvente

: VEC este "mama" tuturor modelelor MGARCH

- Fiecare model GARCH multivariat (BEKK, CCC, DCC) este o **versiune restricționată** a VEC
- Ecuația VEC este cea mai generală dinamică liniară pentru H_t
- Toate restricțiile de aici sunt alegeri despre care parametri se elimină

: confuzia între VEC și VEC Diagonal

- VEC Diagonal (A, B diagonale) elimină *toate efectele încrucișate*
- Fiecare $h_{ij,t}$ depinde doar de propriul lag și de $\varepsilon_{i,t-1}\varepsilon_{j,t-1}$
- **Nu înseamnă** doar "mai puțini parametri": elimină fundamental propagarea volatilității

- **Niciodată** VEC complet pentru $N > 2$ — $O(N^4)$ parametri, estimarea diverge
- **Evitați** VEC Diagonal când spillovers contează (ex.: studii de contagiune bancară)
- **Săriți** peste VEC dacă aveți nevoie doar de varianța portofoliului — CCC/DCC sunt mai rapide și garantat p.d.

Rezumatul secțiunii VEC

3 lucruri de reținut

1. VEC este cel mai **general** model MGARCH liniar — toate celelalte modele îl restricționează
2. VEC Diagonal este estimabil dar elimină propagarea; VEC complet este bogat dar neestimabil pentru $N > 2$
3. Problema centrală nerezolvată: **nicio garanție de pozitiv-definire**

Poziționarea modelului

- **Utilizare**: $N = 2$ și necesitate de flexibilitate maximă
- **vs. BEKK**: BEKK garantează p.d. cu aceeași expresivitate — preferați BEKK

De la VEC la BEKK: ce nu a funcționat?

O propoziție: *VEC este cel mai general model, dar nu garantează matrici pozitiv definite.*

Ce nu a funcționat la VEC?

- VEC este cel mai **general** GARCH multivariat — fiecare element al lui H_t are dinamica proprie
- Dar: (1) **nicio garanție** că H_t este pozitiv definită, (2) parametrii **explodează** ($O(N^4)$)
- VEC Diagonal rezolvă (2) dar eșuează la (1) — și pierde efectele de spillover

Problema fundamentală

- VEC scrie $\mathrm{vech}(\mathrm{H}_t) = \mathrm{c} + \mathrm{A}\,\mathrm{vech}(\varepsilon_{t-1}\varepsilon'_{t-1}) + \mathrm{B}\,\mathrm{vech}(\mathrm{H}_{t-1})$
- Nimic din această ecuație **nu forțează** H_t să fie p.d. la fiecare t

Intuiția BEKK: construiește PD în structură

O propoziție: *BEKK garantează pozitiv-definirea prin forma pătratică* $A'MA$.

Soluția BEKK

- Scrie $H_t = CC' + A'\varepsilon_{t-1}\varepsilon'_{t-1}A + B'H_{t-1}B$
- Fiecare termen este p.s.d. **prin construcție** ($X'MX \succeq 0$ pentru orice $M \succeq 0$)
- Suma de matrice p.s.d. + o matrice p.d. = p.d. întotdeauna

Prețul plătit

- $2N^2 + N(N+1)/2$ parametri — pentru $N = 10$: **255 parametri**
- Estimare numerică instabilă cu optima locale multiple

Modelul BEKK (Engle & Kroner, 1995)

Definiție: BEKK(1,1)

$$H_t = \underbrace{CC'}_{\text{interceptare (p.d.)}} + \underbrace{A'\varepsilon_{t-1}\varepsilon'_{t-1}A}_{\text{impactul șocurilor (p.s.d.)}} + \underbrace{B'H_{t-1}B}_{\text{persistență (p.s.d.)}}$$

- C: $N \times N$ inferior triunghiulară; A, B: matrice $N \times N$

Intuiție: forma pătratică $A'MA$ *este întotdeauna p.s.d. — pozitiv-definirea vine "gratuit."*

Proprietăți cheie

- H_t este **pozitiv definită prin construcție** (dacă CC' este p.d.)
  - $A'MA$ este pozitiv semi-definită pentru orice matrice p.s.d. M
- Captează atât **persistența propriei volatilități** cât și **propagarea între active**
- Parametri: $N(N+1)/2 + 2N^2$ — pentru $N = 3$: $6 + 18 = 24$

▶ Avertisment practic: BEKK nu scalează — $2N^2$ parametri $\Rightarrow$ intractabil pentru $N > 5$. BEKK: Baba, Engle, Kraft și Kroner (1990, working paper).

BEKK: cazul bivariat

Dezvoltarea BEKK(1,1) pentru $N = 2$

- Fie $A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}$, $B = \begin{pmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{pmatrix}$, $C = \begin{pmatrix} c_{11} & 0 \\ c_{21} & c_{22} \end{pmatrix}$

$$h_{11,t} = c_{11}^2 + a_{11}^2 \varepsilon_{1,t-1}^2 + 2a_{11}a_{21}\varepsilon_{1,t-1}\varepsilon_{2,t-1} + a_{21}^2 \varepsilon_{2,t-1}^2 + b_{11}^2 h_{11,t-1} + 2b_{11}b_{21}h_{12,t-1} + b_{21}^2 h_{22,t-1} \tag{6}$$

$$h_{12,t} = c_{11}c_{21} + a_{11}a_{12}\varepsilon_{1,t-1}^2 + (a_{11}a_{22} + a_{12}a_{21})\varepsilon_{1,t-1}\varepsilon_{2,t-1} + a_{21}a_{22}\varepsilon_{2,t-1}^2 + b_{11}b_{12}h_{11,t-1} + (b_{11}b_{22} + b_{12}b_{21})h_{12,t-1} + b_{21}b_{22}h_{22,t-1} \tag{7}$$

Interpretarea spillover-ului

- Termenul $a_{21}^2 \varepsilon_{2,t-1}^2$ în $h_{11,t}$: șocul din activul 2 afectează varianța activului 1
- Aceasta este o **propagare de volatilitate** (spillover) — specifică BEKK

BEKK Diagonal și BEKK Scalar

BEKK Diagonal

- Se restricționează A și B să fie **diagonale**:

$$H_t = CC' + \text{diag(a)}'\varepsilon_{t-1}\varepsilon'_{t-1}\text{diag(a)} + \text{diag(b)}'H_{t-1}\text{diag(b)}$$

- Parametri: $N(N+1)/2 + 2N$. Element cu element: $h_{ij,t} = c^*_{ij} + a_i a_j \varepsilon_{i,t-1}\varepsilon_{j,t-1} + b_i b_j h_{ij,t-1}$

BEKK Scalar

- Restricție suplimentară: $A = aI_N$, $B = bI_N$:

$$H_t = CC' + a^2\varepsilon_{t-1}\varepsilon'_{t-1} + b^2 H_{t-1}$$

- Parametri: $N(N+1)/2 + 2$ — toate elementele au **aceeași dinamică**

Intuiție: BEKK scalar = "un buton pentru sensibilitatea la șocuri, unul pentru memorie" — identic pentru toate perechile.

Compromis

- BEKK Diagonal/Scalar: fezabil pentru N mare, dar **fără propagare între active**.

Produsul Kronecker (*Kronecker Product*)

Definiție

- Fie $A \in \mathbb{R}^{m \times n}$ și $B \in \mathbb{R}^{p \times q}$. **Produsul Kronecker** $A \otimes B$ este matricea bloc $mp \times nq$:

$$A \otimes B = \begin{pmatrix} a_{11}B & \cdots & a_{1n}B \\ \vdots & \ddots & \vdots \\ a_{m1}B & \cdots & a_{mn}B \end{pmatrix}$$

- Dimensiunile **nu** trebuie să fie egale (diferit de Hadamard)

Exemplu: 2×2

- $\begin{pmatrix} a & b \\ c & d \end{pmatrix} \otimes \begin{pmatrix} e & f \\ g & h \end{pmatrix} = \begin{pmatrix} ae & af & be & bf \\ ag & ah & bg & bh \\ ce & cf & de & df \\ cg & ch & dg & dh \end{pmatrix}$ (rezultat 4×4)

Rolul în GARCH multivariat

- Condiția de stationaritate BEKK: $\rho(A \otimes A + B \otimes B) < 1$
- Covarianța necondiționată: $\text{vech}(\bar{H}) = (I - A \otimes A - B \otimes B)^{-1}\text{vech}(CC')$

BEKK: stationaritate și covariață necondiționată

Condiția de stationaritate

- Procesul BEKK(1,1) este staționar în covariață dacă și numai dacă:

$$\rho(\mathrm{A} \otimes \mathrm{A} + \mathrm{B} \otimes \mathrm{B}) < 1$$

- unde $\rho(\cdot)$ denotă raza spectrală și $\otimes$ este produsul Kronecker

Intuiție: analogul multivariat al $\alpha + \beta < 1$ — șocurile trebuie să se atenueze, nu să explodeze.

Matricea de covariață necondiționată

- Dacă condiția de stationaritate este satisfăcută:

$$\mathrm{vech}(\bar{\mathrm{H}}) = (\mathrm{I}_{N^*} - \mathrm{A} \otimes \mathrm{A} - \mathrm{B} \otimes \mathrm{B})^{-1} \mathrm{vech}(\mathrm{CC}')$$

Intuiție: matricea de covariață pe termen lung spre care gravitează H_t — precum $\bar{\sigma}^2 = \omega/(1 - \alpha - \beta)$ în GARCH univariat.

BEKK: avantaje, dezavantaje și alegerea variantei

Avantaje ale BEKK

- **Pozitiv-definire prin construcție** — nu necesită restricții suplimentare
- Captează **volatility spillovers** — singura clasă care le modelează direct
- Interpretare directă a matricelor A și B: transmitere de șocuri și persistență

Dezavantaje

- **Explozie de parametri**: BEKK complet pentru $N = 10 \Rightarrow 255$ parametri
- Optimizare numerică **instabilă** — multiple optima locale, convergență lentă
- Rezultatele pot fi **sensibile la valorile inițiale** ale algoritmului
- Nu se descompune în etape — estimare simultană obligatorie

Regulă practică

- $N \leq 3$: BEKK complet (dacă spillovers sunt relevante)
- $3 < N \leq 10$: BEKK diagonal
- $N > 10$: treceți la DCC sau modele factoriale

BEKK: perspectivă cheie și capcane frecvente

: BEKK este o "reparametrizare inteligentă" a VEC

- BEKK nu adaugă economie nouă — scrie *aceeași* dinamică într-o formă în care p.d. este automată
- Forma pătratică A′MA este p.s.d. prin algebră liniară, nu prin teorie economică
- BEKK schimbă flexibilitate contra comoditate matematică

: folosirea BEKK complet pentru $N > 5$

- BEKK complet pentru $N = 10$: **255 parametri** — optimizatorul găsește optima locale, rezultatele sunt fragile
- Caporin & McAleer (2012): "BEKK complet este esențial neinterpretabil pentru $N > 3$"
- BEKK diagonal este adesea alegerea practică, dar atunci spillovers dispar — anulând scopul BEKK

- $N > 5$: folosiți DCC sau modele factoriale
- Când nu vă interesează *direcția* spillover-urilor (DCC captează co-mișcarea fără canale de spillover)
- Când aveți nevoie de re-estimare rapidă (BEKK: ore vs. DCC: secunde pentru $N = 50$)

Rezumatul secțiunii BEKK

3 lucruri de reținut

1. BEKK garantează p.d. prin forma pătratică A′MA — **singurul** model care captează direct propagarea
2. BEKK complet: bogat dar infezabil pentru $N > 5$; BEKK diagonal: scalabil dar fără propagare
3. Estimarea necesită optimizare simultană — fără scurtătură în două etape

Poziționarea modelului

- **Utilizare**: $N \leq 5$ și *direcția* spillover-ului contează
- **vs. VEC**: aceeași flexibilitate, p.d. garantată **vs. DCC**: DCC scalează mai bine dar nu identifică direcția spillover-ului

Concluzie cheie: *Folosiți BEKK când $N \leq 5$ și trebuie să știți* ***cine transmite volatilitate cui****.*

De la BEKK la CCC: descompunerea care a schimbat totul

Ce ne-a învățat BEKK — și unde eșuează

- BEKK a **rezolvat** problema PD și modelează spillover-uri de volatilitate direct
- Dar: $N(N+1)/2 + 2N^2$ parametri $\Rightarrow$ estimarea se prăbușește pentru $N > 5$
- Estimare simultană a tuturor parametrilor — fără descompunere în sub-probleme mai simple
- Practicienii au abandonat BEKK pentru portofolii mari la sfârșitul anilor 1990

Intuiția lui Bollerslev (1990): separă ce se schimbă de ce nu se schimbă

- **Observație**: variațele se schimbă zilnic, dar *corelațiile* se mișcă lent
- **Idee**: descompune $H_t = D_t R D_t$ unde D_t variază dar R este fixat
- Aceasta separă o problemă **dificilă** simultană în N probleme **ușoare** univariate + o estimare de corelație

Compromisul (*trade-off*)

- Câștigat: scalabilitate ($3N + N(N-1)/2$ param.), estimare în 2 etape, funcționează pt. $N > 100$
- Pierdut: spillover-uri de volatilitate, corelații variabile în timp (R constant!)
- Acest compromis a motivat CCC — și apoi DCC pentru a restabili corelațiile dinamice

CCC: descompunerea $H_t = D_t R D_t$

O propoziție: *Covariațele se schimbă doar pentru că volatilitățile se schimbă — "cablajul" între active rămâne fix.*

Ideea cheie: separarea variațelor de corelații

- Se descompune matricea de covariață condițională:

$$H_t = \underbrace{D_t}_{\text{volatilități}} \underbrace{R}_{\text{corelații}} \underbrace{D_t}_{\text{volatilități}}$$

- $D_t = \text{diag}(\sqrt{h_{11,t}}, \ldots, \sqrt{h_{NN,t}})$ — abatere standard condițională
- R — matrice de corelație **constantă** (invariabilă în timp)
- Fiecare $h_{ii,t}$ urmează un **GARCH(1,1) univariat**: $h_{ii,t} = \omega_i + \alpha_i \varepsilon^2_{i,t-1} + \beta_i h_{ii,t-1}$

CCC: proprietăți și număr de parametri

O propoziție: *CCC reduce o problemă imensă de estimare la N GARCH-uri univariate simple plus o matrice de corelație.*

Proprietăți

- H_t p.d. iff R p.d. și toți $h_{ii,t} > 0$
- Covarianțe: $h_{ij,t} = \rho_{ij}\sqrt{h_{ii,t}}\sqrt{h_{jj,t}}$
- Parametri: $3N$ (GARCH univariat) $+N(N-1)/2$ (corelații)

Comparație

- $N = 50$: CCC necesită **1.375** parametri vs. BEKK ≈ 6.275
- Estimare în două etape: fiecare etapă este de dimensiune redusă

Concluzie cheie: *CCC presupune corelații fixe — covarianțele se schimbă doar pentru că volatilitățile se schimbă.*

CCC: estimare în două etape

Etapa 1: estimare modele GARCH univariate

- Pentru fiecare activ $i = 1, \ldots, N$:
  1. Se estimează un model GARCH(1,1) pentru r_{it}
  2. Se obțin reziduurile standardizate: $z_{it} = \varepsilon_{it} / \sqrt{h_{ii,t}}$

Etapa 2: estimarea matricei de corelație

- Corelația eșantionară a reziduurilor standardizate: $\hat{\mathrm{R}} = \frac{1}{T} \sum_{t=1}^{T} \mathrm{z}_t \mathrm{z}_t'$

Avantaj

- Fiecare etapă implică **optimizare de dimensiune redusă**: N optimizări univariate (3 param. fiecare)
- Etapa 2: corelație eșantionară simplă — fără optimizare numerică

CCC: puncte forte și limitări

Puncte forte

- **Parcimonie**: puțini parametri, ușor de estimat chiar pentru N mare
- **Pozitiv-definire**: garantată prin construcție
- **Interpretabilitate**: covariațele variabile în timp sunt determinate doar de variațe
- Bun **model de referință** pentru comparație

Limitări

- **Corelațiile constante** sunt respinse empiric în majoritatea datelor financiare
- Nu poate captura efectele de **contagiune** sau **flight-to-quality**
- Covariațele se schimbă doar prin variațe, nu prin **relația** între active
- Tse (2000) și Engle (2002) au propus teste pentru corelație constantă

Concluzie cheie: *CCC este benchmark-ul ideal — simplu, rapid și întotdeauna punctul de plecare.*

CCC: perspectivă cheie și capcane frecvente

: CCC a făcut MGARCH practic — nu precis

- Geniulitatea CCC este **computațională**, nu statistică
- Prin fixarea lui R, problema se descompune în N GARCH-uri univariate independente
- CCC este rareori modelul "corect", dar este întotdeauna **benchmark-ul** corect
- Dacă DCC nu poate bate CCC out-of-sample, complexitatea suplimentară este irosită

: folosirea CCC pentru managementul riscului în crize

- CCC **subestimează** VaR-ul portofoliului în perioade de stres: corelațiile reale cresc, dar CCC folosește media eșantionară
- Empiric: CCC subestimează VaR-ul de criză cu 20–30% vs. DCC (vezi Studiul de caz 1)
- Autoritățile de reglementare (Basel III/IV) se așteaptă ca modelele să capteze dependență **variabilă în timp**

- Orizonturi scurte (< 1 an) unde corelațiile nu s-au schimbat mult
- Perechi de active cu corelații genuine stabile (ex.: acțiuni din același sector)
- Ca **instrument de diagnostic**: dacă CCC și DCC dau rezultate similare, corelațiile sunt stabile

Rezumatul secțiunii CCC

3 lucruri de reținut

1. CCC descompune $H_t = D_t R D_t$ — **variațele se mișcă, corelațiile nu**
2. Estimare în două etape: N GARCH-uri univariate + corelație eșantion — rapid, scalabil, p.d. garantată
3. Corelațiile constante sunt **respinse** empiric în majoritatea datelor financiare

Poziționarea modelului

- **Utilizare**: **benchmark** implicit — dacă DCC nu-l poate depăși, complexitatea e inutilă
- **vs. BEKK**: mult mai simplu, fără propagare **vs. DCC**: aceeași structură, dar R e fix

Concluzie cheie: *Estimați întotdeauna CCC mai întâi — este ipoteza nulă pe care DCC trebuie s-o depășească.*

Dovezile împotriva corelațiilor constante

O propoziție: *Ipoteza de corelație constantă a CCC este respinsă în practic toate datele financiare.*

Dovezile empirice

- CCC presupune ρ_{ij} **fix** — dar crizele încalcă repetat această ipoteză
- Corelația S&P 500–DAX: $\approx 0{,}40$ în piețe calme, $> 0{,}85$ în GFC (2008)
- Corelația acțiuni–obligațiuni **și-a schimbat semnul**: $+0{,}30$ pre-2000 $\rightarrow$ $-0{,}30$ post-2000 (flight to quality)

Teste statistice

- Tse (2000) și Engle–Sheppard (2001): corelația constantă respinsă la 1% în majoritatea perechilor
- CCC subestimează VaR-ul de portofoliu în perioade de stres cu 20–30% față de DCC

Soluția lui Engle (2002): R_t dinamic

O propoziție: *Păstrează structura CCC, dar lasă corelațiile să răspundă la șocuri — pentru doar 2 parametri suplimentari.*

Ideea DCC

- Înlocuiește R cu R_t — corelațiile răspund acum la șocuri simultane
- Truc cheie: modelează un proxy Q_t (care *nu* este matrice de corelație), apoi rescalează
- **Doar 2 parametri suplimentari** (a, b) indiferent de dimensiunea portofoliului N

Ce păstrează DCC de la CCC

- Aceeași estimare în două etape: Etapa 1 este identică (GARCH-uri univariate)
- Aceeași scalabilitate: $3N + N(N-1)/2 + 2$ parametri — doar 2 mai mult decât CCC
- Dacă $a = b = 0$, DCC **se reduce exact la CCC** — CCC este inclus ca subcaz

DCC într-o propoziție

DCC = CCC cu corelații dinamice

$H_t = D_t R_t D_t$ unde R_t urmează un proces de tip GARCH cu **2 parametri** (a, b)

	CCC	**DCC**	**Diferență**
Corelații	constante R	dinamice R_t	+2 parametri
Estimare	2 etape	2 etape	aceeași structură
$N = 50$ param.	1.375	**1.377**	neglijabilă

⋆ Model Central: DCC — *Dynamic Conditional Correlation* (Engle, 2002)

DCC = CCC + corelații dinamice + doar 2 parametri suplimentari

- Descompunerea $H_t = D_t R_t D_t$ cu R_t **variabil în timp**

Dinamica corelațiilor

- Matricea de corelație R_t derivată dintr-o pseudo-matrice Q_t:

$$Q_t = (1 - a - b)\bar{Q} + a\, z_{t-1} z_{t-1}' + b\, Q_{t-1} \tag{8}$$

$$R_t = \operatorname{diag}(Q_t)^{-1/2}\, Q_t \operatorname{diag}(Q_t)^{-1/2} \tag{9}$$

- $\bar{Q} = \frac{1}{T}\sum_t z_t z_t'$ = corelația necondiționată; $a \geq 0$, $b \geq 0$, $a + b < 1$

Intuiție: corelațiile cresc când activele se mișcă împreună ($z_{t-1} z_{t-1}'$ mare) și revin la media $\bar{Q}$ în rest.

DCC: intuiție și interpretare

Procesul Q_t

$$Q_t = \underbrace{(1-a-b)\bar{Q}}_{\text{revenire la medie}} + \underbrace{a\, z_{t-1} z_{t-1}'}_{\text{impactul știrilor}} + \underbrace{b\, Q_{t-1}}_{\text{persistență}}$$

- a măsoară cât de **rapid reacționează corelațiile** la șocuri noi
- b măsoară **persistența** corelațiilor
- $a + b$ aproape de 1: corelațiile sunt foarte persistente (tip IGARCH)
- Dacă $a = b = 0$: DCC se reduce la CCC

Etapa de rescalare

- Q_t **nu este** matrice de corelație propriu-zisă (diagonala $\neq 1$)
- Rescalarea $R_t = \text{diag}(Q_t)^{-1/2} Q_t \, \text{diag}(Q_t)^{-1/2}$ asigură $R_{ii,t} = 1$
- Garantează $-1 \leq R_{ij,t} \leq 1$ și R_t p.d.

DCC: estimare în două etape

Etapa 1: GARCH univariat (identică cu CCC)

- Se estimează GARCH(1,1) pentru fiecare activ i separat
- Se calculează reziduurile standardizate $z_{it} = \varepsilon_{it} / \sqrt{h_{ii,t}}$
- Se calculează $\bar{\mathrm{Q}} = T^{-1} \sum_t \mathrm{z}_t \mathrm{z}_t'$

Etapa 2: estimarea parametrilor DCC (a, b)

- Se maximizează **componenta de corelație** a log-verosimilității:

$$\mathcal{L}_2(a, b) = -\frac{1}{2} \sum_{t=1}^{T} \left[\log |\mathrm{R}_t| + \mathrm{z}_t' \mathrm{R}_t^{-1} \mathrm{z}_t - \mathrm{z}_t' \mathrm{z}_t \right]$$

- Optimizare de **2 parametri** indiferent de N!

Intuiție: doar "partea de corelație" a verosimilității — volatilitatea a fost rezolvată în Etapa 1.

Verosimilitate compozită

- Consistent dar nu pe deplin eficient. Erori standard: sandwich Bollerslev–Wooldridge (1992).

DCC: exemplu bivariat

Exemplu: două active ($N = 2$)

- Cu $z_t = (z_{1t}, z_{2t})'$, dinamica DCC se simplifică:

$$q_{12,t} = (1 - a - b)\bar{q}_{12} + a\, z_{1,t-1} z_{2,t-1} + b\, q_{12,t-1} \tag{10}$$

$$\rho_{12,t} = \frac{q_{12,t}}{\sqrt{q_{11,t}\, q_{22,t}}} \tag{11}$$

- $q_{11,t} = (1 - a - b) + a\, z_{1,t-1}^2 + b\, q_{11,t-1}$ (analog pentru $q_{22,t}$)

Interpretare

- Dacă $z_{1,t-1}$ și $z_{2,t-1}$ sunt ambele mari și au **același semn**: corelația crește
- Șocurile negative comune (crize) **împing corelațiile în sus** — captează contagiunea
- Corelațiile **revin la medie** spre $\bar{q}_{12}$ cu rata $(1 - a - b)$

Exemplu numeric: calculul DCC pas cu pas

Date: S&P 500 și DAX, ziua $t-1$

- Reziduuri standardizate: $z_{1,t-1} = -2.1$ (S&P 500), $z_{2,t-1} = -1.8$ (DAX)
- Parametri: $a = 0.05$, $b = 0.93$, $\bar{q}_{12} = 0.65$
- Stare precedentă: $q_{11,t-1} = 1.02$, $q_{22,t-1} = 0.98$, $q_{12,t-1} = 0.68$

Etapa 1: actualizare Q_t

$$q_{11,t} = 0.02 \cdot 1 + 0.05 \cdot (-2.1)^2 + 0.93 \cdot 1.02 = 0.02 + 0.2205 + 0.9486 = 1.189$$

$$q_{22,t} = 0.02 + 0.05 \cdot (-1.8)^2 + 0.93 \cdot 0.98 = 0.02 + 0.162 + 0.9114 = 1.093$$

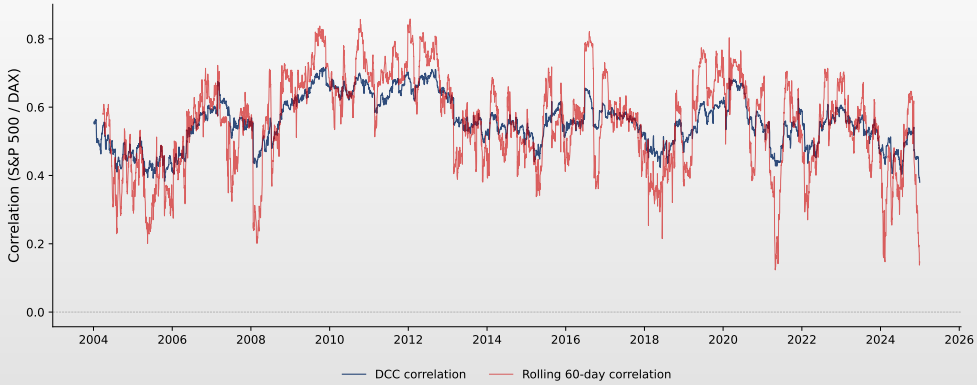
$$q_{12,t} = 0.02 \cdot 0.65 + 0.05 \cdot (-2.1)(-1.8) + 0.93 \cdot 0.68 = 0.013 + 0.189 + 0.6324 = 0.834$$

Etapa 2: rescalare $\rightarrow$ corelația $\rho_{12,t}$

$$\rho_{12,t} = \frac{q_{12,t}}{\sqrt{q_{11,t} \cdot q_{22,t}}} = \frac{0.834}{\sqrt{1.189 \cdot 1.093}} = \frac{0.834}{1.140} = 0.732$$

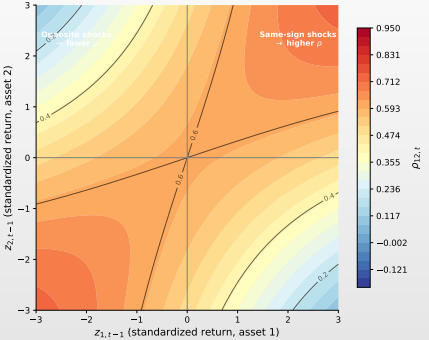
- Corelația a crescut de la ≈ 0.67 la 0.73 ca urmare a șocurilor negative comune!

Studiu de caz: DCC vs. corelații mobile (S&P 500 – DAX)



TSA_ch5b_dcc_estimation

Impactul știrilor asupra corelației DCC

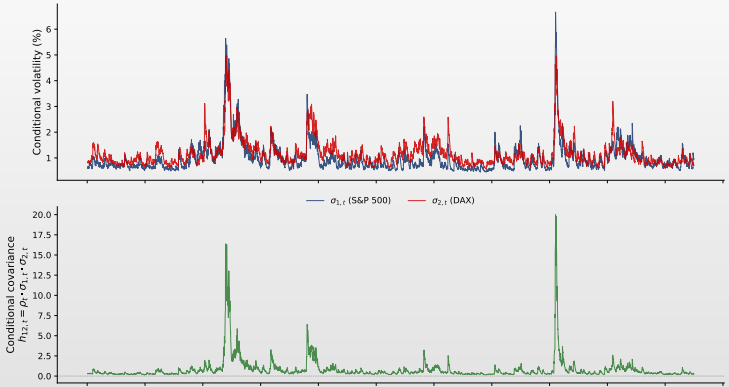


Interpretare

- Când ambele active au șocuri de **același semn** (ambele pozitive sau ambele negative), corelația **crește**
- Șocurile de **semn opus** reduc corelația — efect de decuplare

TSA_ch5b_news_impact_corr

Descompunerea covarianței: $H_t = D_t R_t D_t$



TSA_ch5b_cov_decomp

DCC vs CCC: când contează?

Testarea corelației constante

- **Testul Engle–Sheppard (2001)**: H_0: corelațiile sunt constante
  - Se regresează $\text{vech}(z_t z_t' - \hat{R})$ pe valori decalate
  - $T \cdot R^2 \sim \chi^2$ sub H_0

Evidențe empirice

- CCC este aproape **întotdeauna respins** în datele financiare
- DCC oferă performanță out-of-sample mai bună pentru portofolii
- Îmbunătățirea este maximă în **perioadele de criză**

Regulă practică

- Utilizați CCC ca **benchmark** și DCC ca **model de bază**
- Dacă testul Engle–Sheppard respinge CCC, folosiți DCC

Testul LM Tse (2000) pentru corelație constantă

Ipoteze

- H_0: $\rho_{ij,t} = \rho_{ij}\ \forall t$ (corelațiile sunt **constante** — modelul CCC este corect)
- H_1: $\rho_{ij,t}$ variază în timp (este necesar un model DCC)

Construcția testului

- Se estimează modelul CCC și se obțin reziduurile standardizate $\hat{z}_{it} = \hat{\varepsilon}_{it}/\hat{\sigma}_{it}$
- Se calculează produsele pereche: $\hat{u}_{ij,t} = \hat{z}_{it}\hat{z}_{jt} - \hat{\rho}_{ij}$ pentru fiecare pereche (i, j)
- Se regresează $\hat{u}_{ij,t}$ pe p valori decalate $\hat{u}_{ij,t-1}, \ldots, \hat{u}_{ij,t-p}$
- Statistica: $LM = T \sum_{i<j} R_{ij}^2 \xrightarrow{d} \chi^2\left(\frac{N(N-1)}{2} \cdot p\right)$ sub H_0

Diferența față de Engle–Sheppard (2001)

- **Engle–Sheppard**: regresează vectorul vech$(z_t z_t' - \hat{R})$ **simultan** pe valori decalate — testează toate perechile într-o singură regresie
- **Tse**: testează fiecare pereche (i, j) **separat**, apoi combină statisticile — mai ușor de interpretat dar mai puțin puternic pentru dependențe complexe

DCC: perspectivă cheie și capcane frecvente

: DCC captează dinamica corelațiilor cu doar 2 parametri

- Puterea DCC: a și b sunt **comuni tuturor perechilor**
- Pentru 100 active, 4.950 de corelații evoluează cu aceeași viteză de reacție (a) și persistență (b)
- Aceasta este simultan cea mai mare forță și cea mai mare limitare

- **Ignorarea Aielli (2013)**: DCC original cu $\bar{Q} = E[z_t z_t']$ este inconsistent ($E[Q_t] \neq \bar{Q}$). cDCC corectează.
- **Presupunerea vitezei uniforme**: acțiuni-obligațiuni rapide, acțiuni-acțiuni lente — un singur (a, b) compromite
- **Forgetting the sandwich**: erorile standard naive din estimarea în 2 etape sunt **greșite** — folosiți Bollerslev–Wooldridge

- Nevoie de **direcția spillover**: DCC captează co-mișcarea dar nu care activ a cauzat șocul — folosiți BEKK
- Corelații **genuine constante**: DCC adaugă zgomot; CCC este mai eficient
- Active cu **dinamici de corelație foarte diferite**: considerați block-DCC sau copula

Rezumatul secțiunii DCC

3 lucruri de reținut

1. DCC = CCC cu R_t dinamic: doar **2 parametri suplimentari** (a, b) pentru toate cele $N(N-1)/2$ corelații
2. Ecuația Q_t este un GARCH(1,1) pentru corelații: a = reactivitate la șocuri, b = persistență
3. Estimarea în două etape este consistentă dar necesită **erori standard sandwich**

Poziționarea modelului

- **Utilizare**: **calul de bătaie** al industriei — cel mai bun echilibru între flexibilitate și scalabilitate
- **vs. CCC**: captează vârfurile de corelație din crize **vs. BEKK**: fără direcție de spillover, dar scalează la $N > 100$

Concluzie cheie: *DCC este standardul industrial — 2 parametri captează toate cele $N(N-1)/2$ corelații dinamice.*

DCC Asimetric (aDCC) – Cappiello, Engle & Sheppard (2006)

Motivație: levier în corelații

- Corelațiile răspund asimetric la șocuri negative vs. pozitive
- aDCC extinde DCC cu un termen asimetric:

$$Q_t = (\bar{Q} - a\bar{Q} - b\bar{Q} - g\bar{N}) + a\, z_{t-1} z_{t-1}' + b\, Q_{t-1} + g \underbrace{n_{t-1} n_{t-1}'}_{\text{termen asimetric}}$$

- $n_t = z_t \odot \mathbb{1}(z_t < 0)$ și $\bar{N} = T^{-1} \sum_t n_t n_t'$

Intuiție: pierderile comune (termenul g) pot crește corelațiile mai mult decât câștigurile comune — "amplificatorul de vești proaste."

Proprietăți

- Adaugă doar **un parametru** (g) la modelul DCC
- Captează empiric: corelațiile cresc mai mult după **șocuri negative comune**
- Include DCC ($g = 0$) și CCC ($a = b = g = 0$) ca și cazuri particulare

GO-GARCH (van der Weide, 2002)

Ideea: GARCH ortogonal generalizat

- Se transformă vectorul N-dimensional în N **factori necorelați**:

$$\varepsilon_t = \mathrm{Z} f_t, \qquad f_t = (f_{1t}, \ldots, f_{Nt})'$$

- Z: matrice de mixare; fiecare factor f_{it} are dinamică GARCH individuală:

$$\sigma^2_{f_i,t} = \omega_i + \alpha_i f^2_{i,t-1} + \beta_i \sigma^2_{f_i,t-1}$$

Reconstrucție

$$\mathrm{H}_t = \mathrm{Z}\,\mathrm{diag}(\sigma^2_{f_1,t}, \ldots, \sigma^2_{f_N,t})\,\mathrm{Z}'$$

Intuiție: se modelează volatilitatea în "spațiul factorilor" (simplu), apoi se rotește înapoi în "spațiul activelor" (complex).

- Pozitiv definită **prin construcție**
- Parametri: $N(N-1)/2 + 3N$ — scalează bine cu N
- Legat de Analiza Componentelor Independente (ICA)

Modele GARCH factoriale

Ideea: reducerea dimensionalității cu factori ($K \ll N$)

- Model factorial: $\varepsilon_t = \tilde{}\mathrm{f}_t + \mathrm{u}_t$
- $\tilde{}$: $N \times K$ (încărcături); f_t: $K \times 1$ (factori comuni); u_t: idiosincratic
- Covarianța condițională: $\mathrm{H}_t = \underbrace{\tilde{}\mathrm{H}_t^{f}\tilde{}'}_{\text{risc sistematic}} + \underbrace{\boldsymbol{\Sigma}_t^{u}}_{\text{risc idiosincratic}}$

Intuiție: se modelează câțiva factori comuni, restul se tratează ca zgomot.

Variante

- **O-GARCH** (Alexander, 2001): factori din PCA (*Principal Component Analysis*), GARCH pe componente principale
- **Factor GARCH** (Engle, Ng & Rothschild, 1990): structură parametrică
- **DCC-MIDAS** (Colacito, Engle & Ghysels, 2011): frecvență mixtă

Când se utilizează

- Abordarea **de referință** pentru N mare (50–500 active): *parsimony* + interpretabilitate economică.

Modelul DCC Tse–Tsui (2002)

O alternativă la DCC-ul lui Engle

- Tse & Tsui (2002) propun o dinamică diferită pentru R_t:

$$R_t = (1 - \theta_1 - \theta_2) \underbrace{R}_{\text{termen lung}} + \theta_1 \underbrace{\Psi_{t-1}}_{\text{fereastră locală}} + \theta_2 \underbrace{R_{t-1}}_{\text{persistență}}$$

- *Intuiție: se combină corelația pe termen lung, fereastra recentă și corelația de ieri — rezultatul este automat o matrice de corelație validă.*
- Ψ_{t-1} = corelația reziduurilor standardizate din ultimele M observații

Comparație cu DCC Engle

- **Avantaj**: R_t este matrice de corelație **prin construcție** (fără rescalare)
- **Dezavantaj**: necesită alegerea ferestrei M; mai puțin folosit în practică
- Ambele modele produc rezultate similare empiric

Copula-GARCH: o abordare flexibilă

Ideea: separarea marginilelor de structura de dependență

- **Teorema lui Sklar**: $F(x_1, \ldots, x_N) = C(F_1(x_1), \ldots, F_N(x_N))$
- *Intuiție: se modelează profilul de risc al fiecărui activ separat, apoi se "lipesc" împreună cu o copulă.*
- F_i = distribuțiile marginale (fiecare modelată cu GARCH + distribuție flexibilă)
- C = copula care captează structura de dependență

Avantaje față de DCC

- Permite **dependență asimetrică în cozi** (*tail dependence*)
- Marginilele pot avea distribuții **diferite** (Student-t, skewed-t, GED — *Generalized Error Distribution*)
- Copula t-Student: ρ_t din DCC + dependență de coadă parametrizată de ν

Implementare

- Pachetul R `copula` + `rugarch`; Python: `copulae`

EWMA și RiskMetrics

EWMA (*Exponentially Weighted Moving Average*)

- Cel mai simplu model multivariat de volatilitate — fără estimare:

$$H_t = (1-\lambda)\varepsilon_{t-1}\varepsilon_{t-1}' + \lambda H_{t-1}, \qquad \lambda = 0.94 \text{ (date zilnice)}$$

Intuiție: o medie ponderată între prognoza de ieri și șocurile realizate ieri — fără estimare necesară.

Legătura cu MGARCH

- EWMA $\equiv$ BEKK Scalar cu $\omega = 0$, $a^2 = 1-\lambda$, $b^2 = \lambda$
- Echivalent cu IGARCH ($\alpha + \beta = 1$) fără interceptare
- RiskMetrics (J.P. Morgan, 1996): **standard industrial** bazat pe EWMA

Limitări

- Fără estimare $\Rightarrow$ nu se poate adapta la condiții diferite de piață
- $\lambda = 0.94$ poate să nu fie optim pentru toate clasele de active
- Fără efecte asimetrice, fără revenire la medie a variației

Taxonomia modelelor: rezumat

Model	P.D.	Spillovers	ρ dinamic	Max N
VEC	Nu*	Da	Da	~ 3
VEC Diagonal	Da*	Nu	Da	~ 10
BEKK (complet)	Da	Da	Da	~ 5
BEKK Diagonal	Da	Nu	Da	~ 20
BEKK Scalar / EWMA	Da	Nu	Da	~ 100
CCC	Da	Nu	Nu	~ 100
DCC	Da	Nu	Da	~ 500
aDCC	Da	Nu	Da	~ 500
GO-GARCH	Da	Nu	Da	~ 50
Factor GARCH	Da	Nu	Da	~ 500

* Necesită restricții suplimentare pe parametri.

- Alegerea modelului depinde de: (1) numărul de active, (2) nevoia de spillovers, (3) corelații dinamice, (4) bugetul computațional

Ierarhia modelelor GARCH multivariate

Relații de includere (*nesting*)

- EWMA $\subset$ BEKK Scalar $\subset$ BEKK Diagonal $\subset$ BEKK Complet $\subset$ VEC Complet
- CCC $\subset$ DCC $\subset$ aDCC
- DCC și BEKK Diagonal: **nu** sunt incluse unul în celălalt

Alegerea în funcție de obiectiv

Obiectiv	Model recomandat	De ce
VaR de portofoliu	DCC / aDCC	Corelații dinamice, scalabil
Hedging optim	DCC / BEKK Diag	Cov. variabilă în timp
Propagare șocuri	BEKK Complet	Captează spillovers
$N > 100$ active	Factor GARCH / DCC	Parcimonie, fezabilitate
Asimetrie corelații	aDCC	Termenul g pentru levier
Dependență de coadă	Copula-GARCH	Flexibilitate distribuțională

Când eșuează modelele MGARCH

Specificare greșită a modelului

- Toate modelele MGARCH presupun o **structură parametrică** pentru H_t — procesul real poate să nu aparțină acestei clase
- DCC presupune **o singură dinamică a corelației pentru toate perechile**: a, b scalari, deși perechile acțiuni-obligațiuni și acțiuni-acțiuni se comportă diferit
- BEKK impune dinamici **pătratice** — nu poate capta schimbări de regim sau *structural breaks*
- QML Gaussian: **consistent dar ineficient** sub cozi groase — pierderile de eficiență cresc cu N

Tail risk failures

- MGARCH cu inovații normale **subestimează riscul comun din cozi**: Pr(toate activele cad) prea mic
- Copula Student-t ajută, dar presupune dependență de coadă **simetrică** — activele cad împreună dar nu cresc împreună
- Violările VaR în crize sunt **grupate** — chiar DCC cu acoperire corectă are violări concentrate

Concluzie

- Modelele MGARCH sunt **aproximări locale** — funcționează bine în regimuri stabile dar subperformează în tranziții de regim

Instabilitate în criză și paradoxul DCC

Paradoxul DCC

- DCC este **cel mai necesar** în crize — dar crizele sunt exact momentul când este **cel mai puțin fiabil**
- Estimările parametrilor din perioade de calm pot **să nu se aplice** dinamicilor de criză
- Aielli (2013): estimatorul DCC standard are **bias** în procedura în două etape — cDCC corectează

Structural breaks în corelații

- **Euro (1999)**: corelațiile acțiunilor europene au crescut permanent
- **GFC (2008)**: corelațiile *cross-asset* au sărit și nu au revenit complet ani de zile
- **COVID (2020)**: salt de corelație fără precedent urmat de *decorrelation* rapidă
- Revenirea la medie DCC ($a + b < 1$) forțează corelațiile la $\bar{Q}$ — poate fi **greșit** după *structural breaks*

Remedii

- **DCC-MIDAS** (Colacito, Engle & Ghysels, 2011): separă corelația pe termen scurt și lung
- ***Markov-Switching* DCC**: schimbări discrete de regim în dinamica corelațiilor
- **Ferestre mobile**: re-estimare la fiecare 1–2 ani pentru schimbări structurale

Overfitting vs. *parsimony*: compromisul *bias-variance*

Capcana *overfitting*-ului

- BEKK complet pentru $N = 5$: **55 parametri** — se potrivește perfect *in-sample*, slab *out-of-sample*
- aDCC (+1 parametru) ajută pentru acțiuni dar poate face *overfit* pe perechi obligațiuni-mărfuri
- Gradele de libertate Student-t (ν) pot **compensa** specificarea greșită, mascând problema reală

Evidențe empirice (Caporin & McAleer, 2012; Laurent et al., 2012)

- **Scalar BEKK** $\approx$ **DCC** în previziunea *out-of-sample* pentru majoritatea portofoliilor
- Adăugarea complexității dincolo de DCC(1,1) rareori îmbunătățește VaR-ul sau eficacitatea *hedging*-ului
- **EWMA simplu** ($\lambda = 0.94$) rămâne un *benchmark* competitiv — greu de bătut consistent
- Criteriile informaționale (AIC/BIC) favorizează DCC față de BEKK pentru $N > 3$

Regulă practică

- Începeți simplu (EWMA sau CCC), adăugați complexitate **doar dacă testele *out-of-sample* o justifică**
- Utilizați ***Model Confidence Sets*** (Hansen, Lunde & Nason, 2011) în loc de selecție pe un singur model

Comparație empirică între modele: ce arată literatura

Performanța *out-of-sample* (bazat pe Laurent et al., 2012; Caporin & McAleer, 2014)

Model	VaR portf.	*Hedge*	GMVP	Viteză	Max N
EWMA ($\lambda = 0.94$)	Bun	Mediu	Mediu	⋆⋆⋆⋆⋆	1000+
CCC-GARCH	Mediu	Mediu	Slab	⋆⋆⋆⋆	500
DCC-GARCH	**Bun**	**Bun**	Bun	⋆⋆⋆⋆	500
aDCC-GARCH	**Bun**	**Bun**	**Bun**	⋆⋆⋆	300
Diagonal BEKK	Bun	Bun	Bun	⋆⋆⋆	20
BEKK complet	Mediu*	Bun	Mediu*	⋆	5
GO-GARCH	Bun	Mediu	Bun	⋆⋆	50
Copula-DCC	**Cel mai bun**	Bun	Bun	⋆⋆	100

*BEKK complet face *overfit in-sample*, se degradează *out-of-sample* pentru $N > 3$. GMVP = *Global Minimum Variance Portfolio*.

Concluzii cheie

- DCC este **cea mai bună alegere ajustată la risc** pentru majoritatea aplicațiilor
- Copula-DCC domină pentru ***tail risk*** (ES, VaR extrem) dar la cost computațional mai mare
- Complexitatea dincolo de aDCC produce **randamente descrescătoare** pentru majoritatea portofoliilor

Metode de estimare

Estimare prin verosimilitate maximă (MLE)

- **MLE complet**: estimare simultană a tuturor parametrilor — optimal dar costisitor
- **MLE în două etape (compozit)**: univariat mai întâi, apoi corelație
  - Utilizat de CCC, DCC, aDCC
  - Consistent dar mai puțin eficient decât MLE complet

Quasi-verosimilitate maximă (QML)

- Se utilizează verosimilitatea Gaussiană chiar dacă distribuția reală este non-Gaussiană
- Estimatorul QML este **consistent** sub condiții de regularitate ușoare
- **Erori standard robuste (sandwich)**: $\hat{V} = \hat{J}^{-1}\hat{I}\hat{J}^{-1}$

Alternativă: Student-t multivariat

- Captează mai bine cozile groase: $z_t \sim t_\nu(0, I_N)$
- Adaugă un parametru (ν) pentru grade de libertate

Estimatorul sandwich (*Sandwich Estimator*)

De ce este necesar?

- QML presupune distribuție Gaussiană, dar datele financiare au **cozi groase** și **asimetrie**
- Parametrii sunt **consistenți**, dar erorile standard clasice sunt **incorecte**
- Soluția: estimatorul **sandwich** Bollerslev–Wooldridge (1992) corectează erorile standard

Structura "sandwich" — de unde vine numele

- Matricea de varianță-covarianță a estimatorului: $\hat{V}(\hat{\theta}) = \underbrace{\hat{\mathsf{J}}^{-1}}_{\text{"pâine"}} \underbrace{\hat{\mathsf{I}}}_{\text{"umplutură"}} \underbrace{\hat{\mathsf{J}}^{-1}}_{\text{"pâine"}}$
- $\hat{\mathsf{J}} = -\frac{1}{T}\sum_t \frac{\partial^2 \ell_t}{\partial\theta\partial\theta'}$ (Hessianul — presupune modelul corect)
- $\hat{\mathsf{I}} = \frac{1}{T}\sum_t \frac{\partial \ell_t}{\partial\theta}\frac{\partial \ell_t}{\partial\theta'}$ (produsul exterior al gradienților — *empiric*, fără presupuneri)
- *Intuiție:* $\hat{\mathsf{J}}$ *are încredere în model;* $\hat{\mathsf{I}}$ *are încredere în date. Dacă modelul e corect,* $\mathsf{I} = \mathsf{J}$ *și* $\hat{V} = \mathsf{J}^{-1}$.

Când se folosește

- **Întotdeauna** la estimare QML (GARCH cu verosimilitate Gaussiană pe date non-Gaussiene)
- La estimarea DCC în două etape: erorile standard din etapa 2 trebuie corectate pentru incertitudinea din etapa 1

Verificări diagnostice

Diagnostice pe reziduuri

- Se calculează reziduurile standardizate $\hat{z}_t = \hat{D}_t^{-1}\hat{\epsilon}_t$ și se verifică:
  1. **Absența corelației seriale** în $\hat{z}_{it}$ și $\hat{z}_{it}^2$ (Ljung–Box)
  2. **Absența corelației încrucișate** în $\hat{z}_{it}\hat{z}_{jt}$ (Hosking, 1980)
  3. **Normalitatea** lui $\hat{z}_t$ (dacă s-a presupus verosimilitate Gaussiană)

Compararea modelelor

- **Criterii informaționale**: AIC, BIC (*Akaike/Bayesian Information Criterion*) (penalizează supra-parametrizarea)
- **Teste ale raportului de verosimilitate**: modele imbricate (CCC vs DCC)
- **Evaluare out-of-sample**: performanța portofoliului, backtesting VaR
- **Regresie Mincer–Zarnowitz**: prognoza $\hat{h}_{ij,t}$ vs covarianța realizată

Estimare practică: sfaturi și capcane

Sfaturi practice (*tips & tricks*)

- **Valori inițiale**: porniți de la estimări OLS (*Ordinary Least Squares*) sau de la EWMA ($\lambda = 0.94$)
- **Randamente**: folosiți log-randamente $\times 100$ (în procente) — stabilizează optimizarea
- **Date lipsă**: aliniați seriile pe datele comune; nu interpolați
- **Convergență**: rulați optimizarea din mai multe puncte de start

Capcane frecvente

- **Tranzacționare nesincronizată** (*nonsynchronous trading*): DAX închide la 17:30 CET, NYSE la 16:00 EST — corelațiile intra-zilnice sunt subestimate
  - Soluție: corecția Scholes–Williams (1977) sau utilizarea randamentelor deschidere-la-deschidere
- **Rupturi structurale**: crize modifică permanent regimul de corelații — DCC presupune un singur regim
- **Supraevaluarea Student-t**: gradele de libertate ν pot compensa alte probleme de specificare

Selecția modelului: ghid practic

Diagramă de decizie

1. **Câte active?**
   - $N \leq 5$: BEKK, DCC sau aDCC
   - $5 < N \leq 50$: DCC, aDCC, GO-GARCH
   - $N > 50$: Factor GARCH, DCC-MIDAS, EWMA
2. **Aveți nevoie de propagare de volatilitate (spillovers)?**
   - Da: BEKK complet (N mic) sau modele factoriale
   - Nu: familia DCC
3. **Există asimetrie în corelații?**
   - Testați $\Rightarrow$ dacă da, utilizați aDCC
4. **Validare**: diagnostice pe reziduuri, performanța out-of-sample

Studiu de caz 1: propagarea volatilității între piețe

Obiectiv didactic: cum elementele off-diagonale din BEKK indică direcția transmisiei șocurilor între piețe.

Indicatori de propagare (*spillover*)

- Din modelul BEKK: $H_t = C'C + A'\varepsilon_{t-1}\varepsilon'_{t-1}A + B'H_{t-1}B$
- **Intensitatea propagării** de la activul j la activul i: $\text{Spillover}_{j\to i} = a_{ij}^2 + b_{ij}^2$
- Indicele **Diebold–Yilmaz** (2012): $S^H = \frac{1}{N}\sum_{i\neq j}\theta_{ij}^H$ unde θ_{ij}^H = contribuția șocului j la varianța lui i

Metodologie

- Date: randamente zilnice S&P 500, DAX, FTSE 100, Nikkei 225 (2004–2024, $T \approx 5000$)
- BEKK(1,1) bivariat pe fiecare pereche de active

Studiu de caz 1: ce este un spillover de volatilitate?

Definiție

- Un **spillover de volatilitate** apare atunci când un șoc pe piața j crește varianța condițională a pieței i, dincolo de ceea ce propria istorie a lui i (șocuri și varianțe trecute) ar fi prezis

Canale de transmisie

- **Legături financiare directe**: deținere transfrontaliere, credite interbancare, contrapărți comune
- **Canal informațional**: descoperirea prețurilor curge de la piețele dezvoltate la cele emergente
- **Canal comportamental**: comportament de turmă (*herding*), *flight to quality*, *margin calls* corelate
- **Efect de fus orar**: închidere NY $\rightarrow$ deschidere Asia $\rightarrow$ deschidere Europa — transmisie secvențială

De ce contează pentru managementul riscului

- VaR-ul de portofoliu depinde de covarianța **între piețe**, nu doar de volatilitățile individuale
- În crize, toate canalele se activează simultan $\Rightarrow$ corelații explodează $\Rightarrow$ diversificarea eșuează
- Exemplu: colapsul Lehman (sep 2008) $\rightarrow$ vol SUA triplează $\rightarrow$ DAX deschide cu -5% a doua zi

Studiu de caz 1: matricea parametrilor BEKK — citirea elementelor off-diagonale

Structura BEKK 2×2 (cazul bivariat)

$$A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}, \qquad B = \begin{pmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{pmatrix}$$

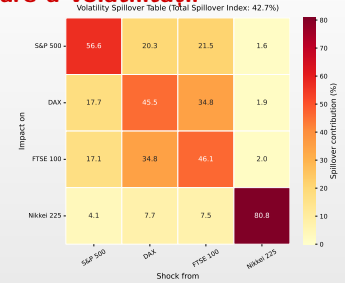
- a_{12}: șoc în activul 2 $\Rightarrow$ creștere **imediată** a volatilității activului 1
- b_{12}: varianța condițională a activului 2 $\Rightarrow$ efect **persistent** asupra variației activului 1
- Spillover total: $\text{Spillover}_{2\to1} = a_{12}^2 + b_{12}^2$

Exemplu numeric: S&P 500 $\leftrightarrow$ DAX

	a_{12}	a_{21}	b_{12}	b_{21}
Estimare	0.18	0.09	0.31	0.15
Pătrat	0.032	0.008	0.096	0.023

- $\text{Spillover}_{\text{SP}\to\text{DAX}} = 0.008 + 0.023 = 0.031$ vs. $\text{Spillover}_{\text{DAX}\to\text{SP}} = 0.032 + 0.096 = 0.128$
- $\Rightarrow$ S&P $\to$ DAX este de **4**$\times$ **mai puternic** decât DAX $\to$ S&P

Studiu de caz 1: harta de propagare a volatilității



Rezultate principale

- S&P 500 este principalul **exportator** de volatilitate — șocurile americane se propagă global în 24h
- Pieţele europene (DAX, FTSE) sunt puternic **interconectate** (spillover reciproc ridicat)
- Nikkei este cel mai **independent** — decalajul de fus orar reduce transmisia directă
- **Implicație**: un portofoliu global nu poate ignora canalul US → Europa

TSA_ch5b_spillover_heatmap

Studiu de caz 1: propagare direcționată — cine exportă, cine importă?

Spillover net = Transmis − Primit

Piață	Transmis	Primit	Net	Rol
S&P 500	66	55	$+11$	Exportator net
DAX	61	62	-1	Echilibrat
FTSE 100	58	60	-2	Ușor importator
Nikkei	32	40	-8	Importator net

Interpretare

- S&P 500 este **hub-ul de volatilitate**: transmite mai mult către fiecare piață decât primește
- DAX și FTSE sunt aproape **echilibrate** — primesc șocuri din SUA și le transmit reciproc
- Nikkei este cel mai **izolat**: primește cu 8 p.p. mai mult decât transmite — decalajul de fus orar acționează ca o barieră naturală
- **Practic**: acoperirea expunerii pe acțiuni americane este cea mai eficientă acțiune de reducere a riscului

Studiu de caz 1: tabelul de propagare Diebold–Yilmaz

VAR(5) pe volatilități realizate; orizont $H = 10$ zile

De la →	S&P	DAX	FTSE	Nikkei	**Primit**
S&P 500	45	22	20	13	55
DAX	25	38	28	9	62
FTSE 100	23	27	40	10	60
Nikkei	18	12	10	60	40
Transmis	66	61	58	32	$S^H \approx 54\%$

Interpretare

- S&P 500: cel mai mare **exportator net** (transmis − primit $= 66 - 55 = +11$ p.p.)
- DAX și FTSE: propagare bilaterală puternică (28%/27%) — piețe europene strâns legate
- Nikkei: cel mai **izolat** ($32 - 40 = -8$ p.p.) — primește mai mult decât transmite
- $S^H \approx 54\%$: peste jumătate din variabilitatea volatilității este datorată **contagiunii între piețe**

TSA_ch5b_spillover_heatmap

Studiu de caz 1: dinamica propagării — calm vs. criză

Indicele Diebold–Yilmaz rulant ($H = 10$, fereastră 252 zile)

Perioadă	S^H	Canal principal	Eveniment
2004–2006	42%	SP → DAX	Calm pre-criză
2008–2009	72%	SP → toate	Criza financiară globală
2011–2012	65%	DAX → FTSE	Criza datoriilor suverane
2014–2019	48%	SP → DAX	Recuperare post-criză
2020 (mar)	70%	SP → toate	COVID-19
2022	58%	SP → DAX	Înăsprire monetară

Concluzie cheie

- Indicele de propagare aproape se **dublează** în crize (42% → 72%) — diversificarea dispare exact când este cel mai necesară
- Piața americană domină propagarea în **toate** episoadele de criză — nu există regim unde Europa conduce
- Recuperarea este asimetrică: post-GFC S^H a avut nevoie de 3 ani să se normalizeze; post-COVID doar 6 luni

Studiu de caz 1: mecanisme de contagiune în crize

De ce crește propagarea în crize?

- ***Margin calls***: vânzări forțate pe o piață $\Rightarrow$ *deleveraging* simultan pe toate piețele
- ***Liquidity spirals*** (Brunnermeier & Pedersen, 2009): pierdere $\rightarrow$ *margin call* $\rightarrow$ lichidare $\rightarrow$ scădere de preț $\rightarrow$ nou *margin call*
- ***Information contagion***: incertitudinea privind expunerea la contrapărți creează dinamici *"who's next?"*
- **Flight to quality**: ieșire corelată din active riscante către valori de refugiu (USD, Bund-uri, Aur)

Evidențe empirice din estimări BEKK

- **GFC**: a_{12} (S&P$\rightarrow$DAX) a crescut de la 0.12 la 0.31 — transmisia șocurilor s-a *triplat*
- **COVID**: toate elementele off-diagonale b_{ij} au explodat simultan — volatilitate *persistentă* între piețe
- **Criza euro**: asimetrică — DAX$\rightarrow$FTSE a dominat, SUA relativ izolate

Studiu de caz 1: implicații pentru construcția portofoliului global

Lecții practice de management al riscului

- **Diversificarea depinde de regim**: în perioade calme, un portofoliu pe 4 piețe reduce vol cu 30%; în crize, doar cu 10%
- **Expunerea pe SUA domină riscul**: chiar și o alocare de 25% pe SUA generează 40%+ din varianța portofoliului în crize
- **Diversificarea regională în Europa este limitată**: corelația DAX–FTSE > 0.85 sub stres
- **Expunerea pe Asia oferă cel mai bun beneficiu rezidual**: Nikkei rămâne cel mai independent ($\rho < 0.6$ chiar și în crize)

Recomandare pentru testarea de stres

- Folosiți estimări BEKK de spillover sub **calibrare de criză** pentru scenarii de stres
- Presupuneți $S^H > 70\%$ pentru evaluarea riscului de coadă — $S^H = 42\%$ din perioade calme este **periculos de optimist**
- Recalculați VaR-ul portofoliului cu H_t condițional de criză pentru a capta amplificarea între piețe

Studiu de caz 1: sumar — cifre cheie

Tabel de referință: propagarea volatilității (2004–2024)

Statistică	Valoare
Indicele total de spillover S^H (eșantion complet)	54%
S^H în perioade calme (VIX < 15)	42%
S^H în GFC (2008–2009)	72%
S^H în COVID (mar 2020)	70%
Cel mai mare exportator net	S&P 500 ($+11$ p.p.)
Cel mai mare importator net	Nikkei (-8 p.p.)
Cel mai puternic canal bilateral	DAX $\leftrightarrow$ FTSE (27–28%)
Timp de recuperare (GFC $\rightarrow$ normal)	$\sim$3 ani
Timp de recuperare (COVID $\rightarrow$ normal)	$\sim$6 luni

Concluzie

- Peste jumătate din variabilitatea volatilității acțiunilor se datorează contagiunii între piețe
- Modelele statice care ignoră acest canal **subestimează sistematic** riscul de portofoliu în perioadele când măsurarea precisă a riscului contează cel mai mult

Studiu de caz 2: optimizarea dinamică a portofoliului

Obiectiv didactic: cum matricele de covarianță actualizate prin DCC produc ponderi mai bune decât abordările statice sau CCC, mai ales la schimbări de regim.

Portofoliu de varianță minimă (*minimum variance*)

- Ponderile optime la momentul t: $\mathrm{w}_t^{\mathrm{MV}} = \frac{\mathrm{H}_t^{-1}\mathbf{1}}{\mathbf{1}'\mathrm{H}_t^{-1}\mathbf{1}}$
- Rebalansare la fiecare t pe măsură ce H_t evoluează

Indicatori de performanță

- **Volatilitate anualizată**: $\sigma_{\mathbf{an}} = \hat{\sigma}_{\mathbf{zilnic}} \times \sqrt{252}$
- **Raportul Sharpe**: $SR = \frac{\bar{r}_p - r_f}{\sigma_p}$ — randament ajustat la risc
- **Pierderea maximă** (*maximum drawdown*): $MDD = \max_t \left(\frac{\max_{s \leq t} V_s - V_t}{\max_{s \leq t} V_s} \right)$
- **Turnover**: $TO_t = \sum_{i=1}^{N} |w_{i,t} - w_{i,t-1}|$ — costul implicit al rebalansării

Studiu de caz 2: de ce covariață dinamică? Problema Markowitz

Markowitz static: ce nu funcționează

- MVO (*Mean-Variance Optimization*) clasic folosește $\hat{H} = \frac{1}{T}\sum_{t=1}^{T} r_t r_t'$ — o **singură** matrice pentru întreg eșantionul
- Problemă: în perioade calme, $\rho_{SP,DAX} \approx 0.5$; în GFC, $\rho_{SP,DAX} \approx 0.9$
- $\hat{H}$ static mediază ambele regimuri $\Rightarrow$ **subestimează** corelația din criză
- Rezultat: prea multă expunere pe acțiuni, insuficientă pe aur $\Rightarrow$ drawdown-uri catastrofale

Soluția DCC

- Se înlocuiește $\hat{H}$ cu H_t din DCC-GARCH — matricea de covariață se **actualizează zilnic**
- Ponderile w_t răspund la regimul **curent** de corelație
- Când $\rho_{SP,DAX,t}$ crește $\Rightarrow$ ambele acțiuni devin **redundante** $\Rightarrow$ modelul mută ponderea pe aur

Studiu de caz 2: pas cu pas — calculul ponderilor DCC

Ziua t: S&P 500, DAX, Aur — covarianța condițională

$$\mathrm{H}_t = \begin{pmatrix} 2.89 & 2.52 & -0.36 \\ 2.52 & 3.61 & -0.28 \\ -0.36 & -0.28 & 1.44 \end{pmatrix} \times 10^{-4}$$

Pasul 1: Inversarea H_t

$$\mathrm{H}_t^{-1} = \begin{pmatrix} 7821 & -5204 & 894 \\ -5204 & 6112 & 568 \\ 894 & 568 & 7543 \end{pmatrix}$$

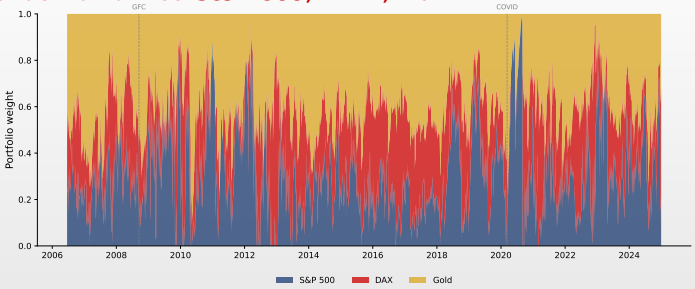
Pasul 2: Formula MV $\mathrm{w}_t = \mathrm{H}_t^{-1}1/(1'\mathrm{H}_t^{-1}1)$

- $\mathrm{H}_t^{-1}1 = (3511, 1476, 9005)'$, $\quad 1'\mathrm{H}_t^{-1}1 = 13992$
- $\mathrm{w}_t = (0.251, 0.106, 0.643)'$ — aurul primește **64%** (varianță scăzută + corelație negativă cu acțiunile)

Contrast cu perioada calmă

- Când $\rho_{\mathrm{SP,Aur}} \approx 0$: ponderea aurului scade la $\sim$40%
- DCC mută 24 p.p. către aur pe măsură ce corelațiile de criză apar

Studiu de caz 2: ponderi dinamice S&P 500, DAX, Aur



Interpretare

- În crize (2008, 2020): ponderea **aurului crește** — corelația scăzută cu acțiunile oferă diversificare
- Corelația S&P–DAX crește în crize $\Rightarrow$ modelul reduce expunerea pe **ambele piețe de acțiuni**
- DCC reacționează **zilnic** la schimbările din structura de covarianță

TSA_ch5b_dcc_portfolio

Studiu de caz 2: zoom pe crize — cum s-au schimbat ponderile în 2008 și 2020

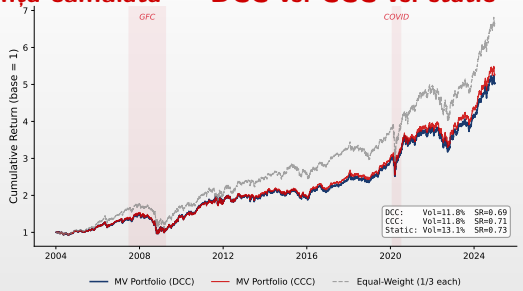
Variația ponderilor în crizele majore

	GFC (sep 2008)			COVID (mar 2020)		
Activ	Pre	Vârf	Δ	Pre	Vârf	Δ
S&P 500	32%	18%	−14	28%	15%	−13
DAX	25%	12%	−13	22%	10%	−12
Aur	43%	70%	+27	50%	75%	+25

Ce determină schimbarea?

- $\rho_{\text{SP,DAX}}$ crește de la 0.55 la 0.90 $\Rightarrow$ ambele acțiuni devin **redundante** pentru diversificare
- $\rho_{\text{SP,Aur}}$ scade de la 0.05 la -0.25 $\Rightarrow$ aurul devine un **hedging mai eficient**
- Schimbarea durează 5–10 zile de tranzacționare — DCC reacționează rapid dar nu instantaneu
- CCC ratează complet această dinamică: ponderea aurului rămâne constantă deoarece ρ este fix

Studiu de caz 2: performanța cumulată — DCC vs. CCC vs. static



Concluzii

- DCC reduce **drawdown-ul maxim** cu ∼13 p.p. față de portofoliul static
- Câștigul în Sharpe vine din **rotalocarea către aur** când corelațiile acțiunilor explodează
- Costul: turnover mai mare — necesită evaluarea costurilor de tranzacționare

TSA_ch5b_dcc_portfolio

Studiu de caz 2: indicatori de performanță — DCC vs. CCC vs. static

Rezultate comparative (S&P 500, DAX, Aur; 2004–2024)

Indicator	DCC	CCC	Static (1/3)
Randament anualizat	8.2%	7.8%	7.1%
Volatilitate anualizată	10.5%	11.8%	13.2%
Raportul Sharpe	0.78	0.66	0.54
Drawdown maxim	−22%	−29%	−35%
Turnover mediu zilnic	3.8%	1.2%	0%

Analiză

- DCC îmbunătățește Sharpe cu **44%** vs. static (0.78/0.54) — cele mai mari câștiguri în perioade de criză
- Reducerea drawdown-ului (−22% vs. −35%) prin realocarea către aur în GFC și COVID
- Compromis: turnover-ul DCC este 3× CCC — la 10 bps cost round-trip, randamentul scade ∼0.5%
- **Beneficiu net**: chiar după costuri de tranzacționare, DCC domină pe bază ajustată la risc

Studiu de caz 2: analiza costurilor de tranzacționare

Impactul costurilor de rebalansare asupra portofoliului DCC

Ipoteză de cost	SR net DCC	SR net CCC	Avantaj DCC
0 bps (fără costuri)	0.78	0.66	+0.12
5 bps per tranzacție	0.73	0.64	+0.09
10 bps per tranzacție	0.68	0.63	+0.05
20 bps per tranzacție	0.58	0.60	−0.02

Analiza punctului de echilibru (*breakeven*)

- DCC domină CCC până la $\sim$18 bps per tranzacție — deasupra, turnover-ul mai mare erodează câștigurile
- Pentru active lichide (ETF-uri, futures): costurile tipice sunt 2–5 bps $\Rightarrow$ DCC este **clar superior**
- Pentru active nelichide (small-cap, piețe emergente): costurile pot ajunge la 30–50 bps $\Rightarrow$ CCC sau rebalansare lunară pot fi preferabile

Studiu de caz 2: frecvența rebalansării — zilnic vs. săptămânal vs. lunar

Performanța pe orizonturi de rebalansare (portofoliu DCC, cost 10 bps)

Frecvență	SR net	MDD	Turnover	Tracking error
Zilnic	0.68	−22%	3.8%/zi	0%
Săptămânal	0.71	−24%	2.1%/zi	0.3%
Lunar	0.67	−28%	0.8%/zi	1.2%

Concluzii cheie

- Rebalansarea **săptămânală** oferă cel mai bun Sharpe net — reduce turnover-ul cu 45% cu creștere minimă a MDD
- Rebalansarea **lunară** ratează schimbările rapide de regim (COVID s-a prăbușit în 5 zile) $\Rightarrow$ drawdown mai mare
- Rebalansarea zilnică este optimă *înainte de costuri* dar nu și după — "blestemul frecvenței"
- Recomandare practică: săptămânal pentru piețe lichide; lunar pentru piețe nelichide

Studiu de caz 2: când este suficientă alocarea statică?

Condiții în care portofoliile statice performează bine

- **Structură stabilă de corelații**: dacă ρ_{ij} variază cu < 0.1 între regimuri, DCC adaugă puțin
- **Orizont lung**: pe 10+ ani, revenirea la medie a corelațiilor diluează beneficiul DCC
- **Costuri mari de tranzacționare**: activele nelichide (imobiliare, PE) erodează câștigurile din rebalansare
- **Puține active**: cu $N = 2$, matricea de corelații are un singur element liber — câștig limitat din dinamică

Când DCC este esențial

- **Active predispuse la crize**: acțiuni, obligațiuni HY, mărfuri — corelații variază cu 0.3+ între regimuri
- **Orizont scurt/mediu**: managementul riscului zilnic până la trimestrial, raportare regulatorie
- **Controlul riscului de coadă**: dacă obiectivul este minimizarea MDD, nu maximizarea randamentului
- Regulă empirică: dacă $\max(\rho_{ij,t}) - \min(\rho_{ij,t}) > 0.2$ în eșantion $\Rightarrow$ folosiți DCC

Studiu de caz 3: hedging dinamic

Obiectiv didactic: de ce ratele de hedging trebuie să se adapteze în timp real și cum apare supra-/sub-hedging-ul din estimări de covarianță depășite.

Raportul de hedging cu variană minimă

- Acoperirea activului spot folosind futures:

$$h_t^* = \frac{h_{12,t}}{h_{22,t}} = \frac{\mathrm{Cov}_t(r_{\text{spot}}, r_{\text{futures}})}{\mathrm{Var}_t(r_{\text{futures}})}$$

- Din CCC: $h_t^* = \rho \cdot \frac{\sqrt{h_{11,t}}}{\sqrt{h_{22,t}}}$ — variază doar prin **raportul variațelor**
- Din DCC: $h_t^* = \rho_t \cdot \frac{\sqrt{h_{11,t}}}{\sqrt{h_{22,t}}}$ — variază prin **corelație și variațe**

Indicatori de evaluare

- **Eficacitatea hedging-ului**: $HE = 1 - \frac{\mathrm{Var}(r_{\text{acoperit}})}{\mathrm{Var}(r_{\text{neacoperit}})}$ $\quad (HE = 1 =$ acoperire perfectă$)$
- **Randamentul acoperit**: $r_{\text{acoperit},t} = r_{\text{spot},t} - h_t^* \cdot r_{\text{futures},t}$

Studiu de caz 3: de ce hedging dinamic? Înțelegerea riscului de bază

Ce este riscul de bază (*basis risk*)?

- **Baza** $= S_t - F_t$ (preț spot minus preț futures)
- Într-o acoperire perfectă ($h = 1$), poziția acoperită este expusă doar la variațiile bazei
- Problemă: baza **nu este constantă** — depinde de ratele dobânzii, dividende și stresul de piață

De ce eșuează rapoartele statice de hedging

- OLS: $h^* = \frac{\text{Cov}(r_s, r_f)}{\text{Var}(r_f)}$ estimat *o singură dată* pe date istorice
- În crize: $\text{Cov}(r_s, r_f)$ și $\text{Var}(r_f)$ se schimbă ambele $\Rightarrow$ *raportul* se schimbă și el
- Un raport pre-criză de 0.91 poate fi optim la $\rho = 0.95$ dar catastrofal la $\rho = 0.82$

Avantajul DCC

- DCC actualizează h_t^* zilnic folosind ρ_t și $\sigma_{i,t} \Rightarrow$ se adaptează la regimul curent de risc al bazei $\Rightarrow$ **varianță reziduală minimă** în fiecare moment

Studiu de caz 3: corelația spot-futures — de ce variază ρ_t

Factori care determină $\rho_t(r_{\text{spot}}, r_{\text{futures}})$ variabil în timp

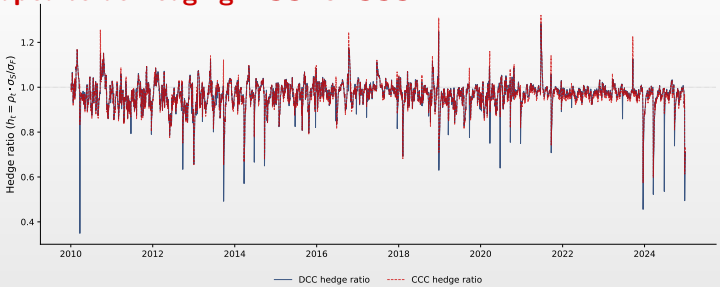
- **Decalaj de lichiditate**: în crize, piața spot îngheață în timp ce futures rămâne lichid $\Rightarrow$ prețurile diverge $\Rightarrow$ ρ_t scade
- ***Margin calls***: lichidarea forțată a pozițiilor futures distorsionează prețurile futures
- **Riscul de rollover**: pe măsură ce contractele se apropie de expirare, dinamica de roll introduce zgomot
- **Perioade normale**: arbitrajul menține spot și futures strâns legate $\Rightarrow$ $\rho_t \approx 0.95$

Evidență empirică: S&P 500 – E-mini (2004–2024)

Perioadă	ρ_t (DCC)	h_t^* (DCC)	h^* (CCC)
Calmă (VIX $<$ 15)	0.96	0.93	0.93
Turbulentă (VIX 15–30)	0.91	0.88	0.93
Criză (VIX $>$ 30)	0.83	0.78	0.93

CCC ratează *decorrelation* din criză $\Rightarrow$ face *over-hedging* cu 15 p.p. exact când contează cel mai mult.

Studiu de caz 3: rapoarte de hedging DCC vs. CCC

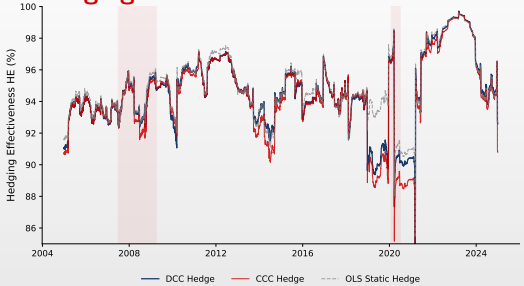


Interpretare

- Raportul DCC fluctuează mai mult — reflectă **schimbările reale** din corelația spot-futures
- CCC produce un raport mai **neted** dar suboptimal: ignoră variația corelației
- Diferența maximă apare în perioade de stres, unde DCC ajustează hedgingul cu 15–30%

TSA_ch5b_hedge_ratio

Studiu de caz 3: eficacitatea hedging-ului — DCC vs. CCC vs. OLS



Concluzii (S&P 500 spot vs. E-mini futures, 2004–2024)

- DCC menține $HE > 95\%$ chiar și în crize — OLS static scade sub 90% în perioade turbulente
- CCC: performanță intermediară — captează variația variațelor, dar nu și a corelației
- **Concluzie**: DCC evită *over-hedging*-ul în crize, unde corelația spot-futures scade temporar

TSA_ch5b_hedge_ratio

Studiu de caz 3: exemplu numeric — over-hedging în criză

Scenariu: S&P 500 spot vs. E-mini futures — zi de GFC (oct. 2008)

- Volatilități condiționale: $\sigma_{\text{spot}} = 3.5\%$, $\sigma_{\text{futures}} = 4.0\%$
- DCC: $\rho_t = 0.88$ (*decorrelation* în criză); CCC: $\rho = 0.95$ (media pe eșantion)

Comparația rapoartelor de hedging

- DCC: $h^*_{\text{DCC}} = 0.88 \times \frac{3.5}{4.0} = 0.77$ CCC: $h^*_{\text{CCC}} = 0.95 \times \frac{3.5}{4.0} = 0.83$ OLS: $h^*_{\text{OLS}} = 0.91$

Consecința *over-hedging*

- CCC face *over-hedging* cu **6 p.p.** $(0.83 - 0.77)$; OLS cu **14 p.p.** $(0.91 - 0.77)$
- *Over-hedging* $\Rightarrow$ exces de short pe futures $\Rightarrow$ dacă *basis*-ul se lărgește (frecvent în GFC), ambele *legs* pierd
- Pentru o poziție de \$100M, 14 p.p. *over-hedging* = \$14M expunere excesivă short

Studiu de caz 3: descompunerea HE — varianță vs. corelație

Descompunerea eficacității hedging-ului

- Raportul de hedging $h_t^* = \rho_t \cdot \frac{\sigma_{\mathbf{spot},t}}{\sigma_{\mathbf{fut},t}}$ are două componente dinamice:
- **Raportul varianțelor**: $\sigma_{\text{spot},t}/\sigma_{\text{fut},t}$ — se schimbă când regimurile de volatilitate diferă între piețe
- **Corelația**: ρ_t — se schimbă când microstructura pieței se modifică
- CCC captează doar prima componentă; DCC le captează pe ambele

Contribuția la variația lui h_t^* (S&P 500 – E-mini, 2004–2024)

Sursă	Perioade calme	Perioade de criză
Variația raportului de varianță	75%	45%
Variația corelației	25%	55%

Implicație

- În perioade calme, CCC captează 75% din dinamica raportului de hedging $\Rightarrow$ aproape la fel de bun ca DCC
- În crize, variația corelației devine **dominantă** — CCC ratează 55% din semnal

Studiu de caz 3: considerații practice

Provocări de implementare

- **Cerințe de marjă**: hedging-ul dinamic schimbă zilnic numărul de contracte futures $\Rightarrow$ contul de marjă fluctuează $\Rightarrow$ necesită management al numerarului
- **Rebalansare discretă**: nu se pot tranzacționa contracte fracționare — erorile de rotunjire se acumulează
- **Risc de estimare**: parametrii DCC sunt estimați cu incertitudine; α, β greșit specificați produc ρ_t zgomotos
- **Costuri de rollover**: contractele E-mini expiră trimestrial — rollover-ul introduce 2–5 bps cost per roll

Strategii de atenuare

- Rebalansare doar când $|h_t^* - h_{t-1}^*| > \delta$ (strategie "deadband") — reduce turnover-ul cu 40%
- Folosiți fereastră de estimare rulantă (ex. 1000 zile) pentru a menține parametrii DCC actuali
- Complementați cu limite de poziție: $h_t^* \in [0.7, 1.1]$ pentru a preveni rapoarte extreme din erori de estimare

Studiu de caz 3: cross-hedging — când futures-ul exact nu există

Cross-hedging cu DCC

- Nu toate activele au futures lichid (ex. acțiuni individuale, piețe emergente)
- **Cross-hedge**: se folosește un proxy corelat și lichid (ex. hedging unei acțiuni DAX cu futures Euro Stoxx 50)
- Raportul de hedging DCC: $h_t^* = \rho_t^{\text{cross}} \cdot \frac{\sigma_{\text{activ},t}}{\sigma_{\text{proxy},t}}$
- Provocare cheie: ρ_t^{cross} este mai scăzut și mai volatil decât ρ_t pe același activ

Exemplu: hedging BET (România) cu Euro Stoxx 50

	ρ_t	h_t^*	HE
Perioade calme	0.52	0.48	68%
Perioade de criză	0.71	0.65	82%

Cross-hedging-ul este **mai eficient** în crize (corelațiile converg) — exact când acoperirea contează cel mai mult.

Studiu de caz 3: cadrul decizional — alegerea modelului potrivit

Ghid de selecție a modelului

Criteriu	OLS	CCC	DCC
Cost computațional	Scăzut	Mediu	Ridicat
Cerință de date	60+ obs	500+ obs	1000+ obs
Regim de corelație	Stabil	Stabil	Variabil în timp
Cel mai potrivit pt.	FX, rate	Mărfuri	Acțiuni, HY
Performanță în criză	Slabă	Medie	Cea mai bună

Reguli practice

- Dacă $\text{Var}(\rho_t) < 0.01$ în eșantion $\Rightarrow$ CCC este suficient
- Dacă controlul drawdown-ului maxim este prioritar $\Rightarrow$ DCC
- Dacă rebalansarea este costisitoare (> 20 bps) $\Rightarrow$ OLS cu revizuire lunară
- **Întotdeauna**: testați acoperirea pe date out-of-sample înainte de implementare

Studiu de caz 4: VaR de portofoliu cu GARCH multivariat

Obiectiv didactic: calcularea VaR portofoliu din DCC, backtesting, și de ce VaR static eșuează la testul semafor Basel.

Formulele VaR și ES de portofoliu

- **Volatilitatea portofoliului**: $\sigma_{p,t} = \sqrt{\mathrm{w}' \mathrm{H}_t \mathrm{w}}$
- **VaR**: $\mathrm{VaR}_t^{\alpha} = z_\alpha \cdot \sigma_{p,t}$ **ES**: $\mathrm{ES}_t^{\alpha} = \frac{\phi(z_\alpha)}{\alpha} \cdot \sigma_{p,t}$

Backtesting: testul Christoffersen (1998)

- Violarea: $I_t = 1\{r_{p,t} < -\mathrm{VaR}_t^{\alpha}\}$ — ar trebui să fie i.i.d. Bernoulli(α)
- **Test de acoperire necondiționată** (UC): proporția violărilor $= \alpha$?
- **Test de independență**: violările nu trebuie să fie grupate (*clustered*)

Studiu de caz 4: de ce VaR multivariat?

VaR de portofoliu $\neq$ suma VaR-urilor individuale

- **Sumă naivă**: $\text{VaR}_{\text{sumă}} = \sum_i w_i \cdot \text{VaR}_i$ — presupune $\rho = 1$ (cel mai rău caz)
- **VaR de portofoliu**: $\text{VaR}_p = z_\alpha \cdot \sqrt{w' H_t w}$ — ține cont de diversificare

Exemplu: 60/40 S&P/DAX, $\rho_t = 0.73$

- $\text{VaR}_{\text{sumă}} = 4.47\%$ vs. $\text{VaR}_{\text{portofoliu}} = 4.16\%$ — **reducere de 7%** din diversificare
- Dacă $\rho_t \to 0.95$ (criză): beneficiul scade la doar 2%

Concluzia cheie

- Beneficiul diversificării este **maxim** când ρ este scăzut și **dispare** în crize — VaR-ul static ratează acest lucru.

Studiu de caz 4: exemplu numeric — VaR de portofoliu cu DCC

Portofoliu: 60% S&P 500, 40% DAX — ziua t

- Volatilități condiționale: $\sigma_{1,t} = 1.8\%$, $\sigma_{2,t} = 2.1\%$; corelație DCC: $\rho_{12,t} = 0.73$
- Matrice de covarianță: $\mathrm{H}_t = \begin{pmatrix} 3.24 & 2.76 \\ 2.76 & 4.41 \end{pmatrix} \times 10^{-4}$

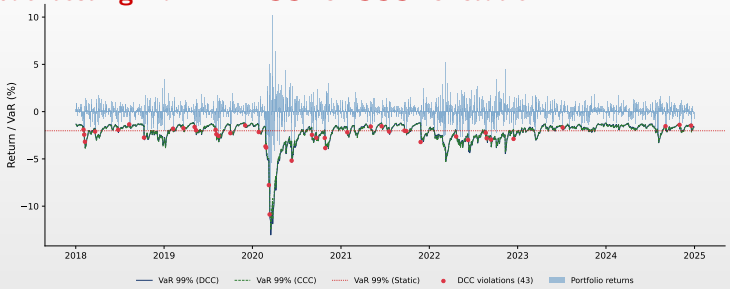
Calculul VaR 99%

- $\mathrm{w} = (0.6,\ 0.4)'$, $\quad z_{0.01} = -2.326$
- $\sigma^2_{p,t} = 0.36 \cdot 3.24 + 0.16 \cdot 4.41 + 2 \cdot 0.24 \cdot 2.76 = 3.197 \times 10^{-4} \quad \Rightarrow \quad \sigma_{p,t} = 1.788\%$
- $\mathrm{VaR}_{99\%} = 2.326 \times 1.788\% = 4.16\%$
- $\mathrm{ES}_{99\%} = \frac{\phi(-2.326)}{0.01} \times 1.788\% = 4.79\%$

Comparație: dacă ρ este constant ($= 0.5$)

- VaR = 3.72%, ES = 4.28% — subestimează riscul cu **0.44 p.p. (VaR)** și **0.51 p.p. (ES)**

Studiu de caz 4: backtesting VaR — DCC vs. CCC vs. static

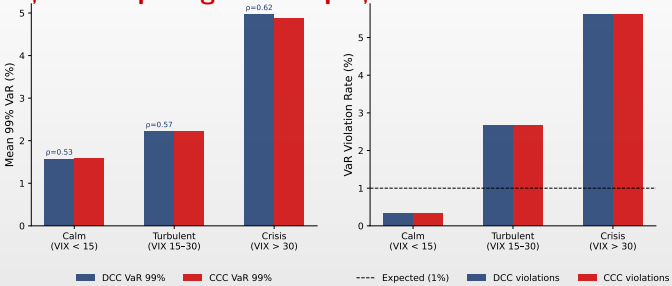


Interpretare

- VaR-ul **DCC** se ajustează rapid la creșterea corelațiilor din crize — mai puține violări
- VaR-ul **CCC/static** subestimează riscul în perioade turbulente (corelații presupuse constante)
- Violările grupate (*clustered violations*) semnalează eșecul testului de independență Christoffersen

TSA_ch5b_var_backtest

Studiu de caz 4: VaR și violări pe regimuri de piață



Concluzii

- VaR-ul DCC crește **automat** cu regimul de piață: ρ_t urcă odată cu VIX (*CBOE Volatility Index*)
- CCC subestimează VaR-ul în criză (VIX $>$ 30) cu până la **30%** — violări excesive
- **Lecție**: alege DCC/aDCC pentru active care devin mai corelate în crize (acțiuni, obligațiuni HY)

TSA_ch5b_var_backtest

Studiu de caz 4: rezultatele testului Christoffersen

Backtesting VaR 99% (60/40 S&P 500/DAX, 2004–2024, $T = 5{,}000$)

	Violări			p-values Christoffersen		
Model	Nr.	Rată	Așteapt.	UC	Ind	CC
DCC	52	1.04%	1%	0.82	0.45	0.67
CCC	71	1.42%	1%	0.02	0.03	0.01
Static	89	1.78%	1%	<0.01	<0.01	<0.01

Interpretarea rezultatelor

- **DCC**: trece toate cele trei teste — rata violărilor aproape de 1% nominal, fără clustering
- **CCC**: eșuează UC ($p = 0.02$) și independența ($p = 0.03$) — prea multe violări, grupate în crize
- **Static**: eșuează toate testele decisiv — covariația constantă este inadecvată pe 20 de ani
- Basel III cere $p > 0.05$ pentru aprobarea modelului intern de VaR — **doar DCC se califică**

Studiu de caz 4: testul Kupiec — acoperire necondiționată

Setup (Kupiec, 1995)

- Indicator de violare: $I_t = 1\{r_{p,t} < -\text{VaR}_t^{\alpha}\}$, violări: $x = \sum_{t=1}^{T} I_t$, rata: $\hat{\pi} = x/T$
- H_0: $\hat{\pi} = \alpha$ (modelul produce acoperirea corectă)

Statistica *Likelihood Ratio*

- Sub H_0: $x \sim \text{Binomial}(T, \alpha)$. Statistica LR:

$$LR_{UC} = -2 \ln \frac{\alpha^x (1-\alpha)^{T-x}}{\hat{\pi}^x (1-\hat{\pi})^{T-x}} \xrightarrow{d} \chi^2(1) \quad \text{sub } H_0$$

- Se respinge H_0 dacă $LR_{UC} > \chi^2_{1,0.05} = 3.84$

Kupiec vs. Christoffersen

- **Kupiec** testează doar **acoperirea** (“sunt prea multe violări?”)
- **Christoffersen** adaugă test de **independență** (“sunt violările grupate?”) — mai puternic
- **Combinat** (CC) = UC + Independență: abordarea recomandată

Studiu de caz 4: sistemul semafor Basel

Evaluarea regulatorie a modelului VaR (Comitetul Basel, fereastră de 250 zile)

Zonă	Violări	Multipl. capital	Acțiune
Verde	0–4	3.0×	Model acceptat
Galben	5–9	3.4–3.85×	Revizie supraveghere
Roșu	10+	4.0×	Model respins

Cum se clasează modelele noastre? (per fereastră de 250 zile)

Model	Violări medii	Violări max.	Zonă
DCC	2.6	4	Verde
CCC	3.6	7	Galben (criză)
Static	4.5	11	Roșu (criză)

Implicație

- Doar DCC rămâne în zona verde consistent — băncile cu CCC/static suportă **cerințe de capital mai mari** în crize

Studiu de caz 4: ES vs. VaR — de ce reglementatorii preferă ES

Limitările VaR

- VaR răspunde la: *"Care este pierderea maximă cu 99% încredere?"*
- Nu spune **nimic** despre dimensiunea pierderilor din coada de 1%
- **Nu este *subadditive***: $\text{VaR}(A+B)$ poate depăși $\text{VaR}(A)+\text{VaR}(B)$

Expected Shortfall (ES) — măsură de risc coerentă

- ES răspunde la: *"Fiind în coada de 1%, cât de mare este pierderea medie?"*
- $\text{ES}_\alpha = \mathbb{E}[L \mid L > \text{VaR}_\alpha]$ — întotdeauna $\geq$ VaR
- **Subaditivă**: $\text{ES}(A+B) \leq \text{ES}(A)+\text{ES}(B)$ — diversificarea e recunoscută

Tranziția FRTB (*Fundamental Review of the Trading Book*) (2023+)

- **FRTB** înlocuiește VaR 99% cu ES 97.5% ca metrică principală de capital
- GARCH multivariat furnizează H_t necesar pentru calculul VaR și ES
- DCC-ES captează **dependența de coadă** pe care DCC-VaR singur o ratează

Studiu de caz 4: *backtesting* ES — Acerbi & Szekely (2014)

Problema *backtesting*-ului ES

- VaR: numără violări (binar). ES: evaluează **cât de mari** sunt pierderile când VaR e depășit — mai dificil
- ES nu este **elicitabil** (Gneiting, 2011) — nu există scoring simplu doar pentru ES

Statistica de test Acerbi–Szekely

- H_0: modelul ES este corect specificat. Se definește: $Z_t = \frac{r_{p,t}}{\mathrm{ES}_t^{\alpha}} \cdot 1\{r_{p,t} < -\mathrm{VaR}_t^{\alpha}\} + 1$
- Sub H_0: $\mathbb{E}[Z_t] = 0$. Statistica: $\bar{Z} = \frac{1}{T}\sum_{t=1}^{T} Z_t$
- $\bar{Z} < 0$: ES **subestimează** pierderile; $\bar{Z} > 0$: ES conservator. Val. p prin simulare

Implicații practice

- Sub FRTB, băncile fac *backtesting* **atât** VaR (Christoffersen/Kupiec) cât și ES (Acerbi–Szekely)
- DCC cu inovații Student-t trece testele ES; DCC Gaussiană eșuează frecvent

Studiu de caz 4: VaR multi-orizont — scalare și agregare

Scalarea VaR pe orizonturi diferite

- **Regula $\sqrt{T}$**: $\text{VaR}_h = \text{VaR}_1 \times \sqrt{h}$ — presupune randamente i.i.d.
- Cu GARCH: regula **supraestimează** VaR pe orizont lung (ignoră revenirea la medie a σ_t)
- Abordarea DCC: se simulează $H_{t+1}, \ldots, H_{t+h}$ folosind recursia GARCH

Exemplu: VaR pe 1 zi vs. 10 zile (portofoliu 60/40)

	VaR 1 zi	VaR 10 zile	Factor scalare
Regula $\sqrt{T}$	4.16%	13.16%	$\sqrt{10} = 3.16$
Simulare DCC	4.16%	11.84%	2.85

- Regula $\sqrt{T}$ supraestimează VaR-ul pe 10 zile cu **11%** deoarece ignoră revenirea la medie

Cerința Basel

- Basel cere VaR pe 10 zile pentru capitalul de risc de piață
- Simularea DCC în loc de $\sqrt{T}$ poate reduce cerințele de capital cu 8–15%

Studiu de caz 4: sumar — cifre cheie

Tabel de referință: rezultate backtesting VaR (2004–2024)

Statistică	Valoare
Rata violărilor DCC (nominal 1%)	1.04%
Rata violărilor CCC	1.42% (+42% exces)
Rata violărilor static	1.78% (+78% exces)
DCC: Christoffersen CC p-value	0.67 (trece)
CCC: Christoffersen CC p-value	0.01 (eșuează)
Subestimarea VaR de criză CCC	până la 30%
Zona Basel (DCC)	Verde mereu
Zona Basel (Static, criză)	Roșu
Beneficiul diversificării ($\rho = 0.5$)	15% reducere VaR
Beneficiul diversificării ($\rho = 0.95$)	2% reducere VaR

Concluzie

- DCC este singurul model care trece consistent backtesting-ul regulatoriu pe toate regimurile de piață
- Costul utilizării CCC sau static este atât regulatoriu (capital mai mare) cât și economic (subestimarea riscului de coadă)

Studiu de caz 5: ce este riscul sistemic?

Obiectiv didactic: legătura dintre corelațiile DCC și măsurile de risc sistemic (ΔCoVaR, MES, SRISK) și identificarea G-SIB.

Definiție

- **Riscul sistemic**: dificultățile unei instituții declanșează eșecuri în cascadă în întregul sistem financiar

Caracteristici cheie

- **Too Big / Too Connected to Fail**: eșecul destabilizează sistemul prin contagiune
- **Explozie de corelații**: în crize, corelațiile cresc $\Rightarrow$ diversificarea dispare
- **Non-liniaritate**: riscul sistemic apare din **interacțiuni**, nu din suma riscurilor individuale

De ce MGARCH?

- Riscul sistemic = **comportament comun de coadă** al mai multor instituții
- DCC-GARCH furnizează H_t variabil în timp, necesar pentru calculul măsurilor condiționale de risc
- Corelațiile statice ratează amplificarea din criză care definește evenimentele sistemice

Studiu de caz 5: monitorizarea riscului sistemic

Indicatori de risc sistemic bazați pe MGARCH

- **CoVaR** (*Conditional Value at Risk*; Adrian & Brunnermeier, 2016): VaR-ul sistemului condițional de stresul unei instituții

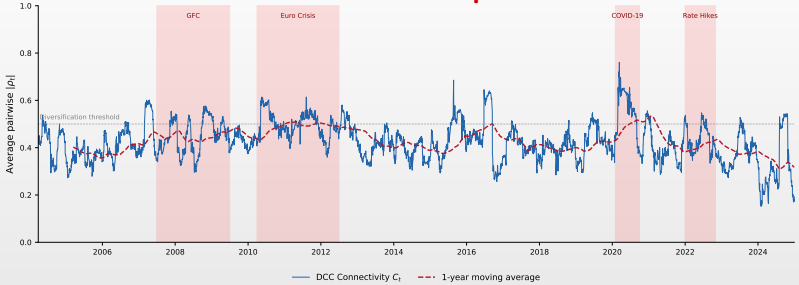
$$\Delta\text{CoVaR}_{i,t} = \text{VaR}_t^{\text{sistem}|i \text{ în stres}} - \text{VaR}_t^{\text{sistem}|i \text{ normal}}$$

- **Indicele de conectivitate DCC**: $C_t = \frac{2}{N(N-1)} \sum_{i<j} |\rho_{ij,t}|$ — media corelațiilor
- Când $C_t \to 1$ simultan $\Rightarrow$ diversificarea dispare $\Rightarrow$ **semnal de criză**

Cerințe reglementare

- **Basel III/IV**: băncile trebuie să raporteze VaR pe orizonturi multiple cu corelații dinamice
- **FRTB** (*Fundamental Review of the Trading Book*): înlocuiește VaR cu ES, necesită GARCH multivariat
- **DCC-GARCH** furnizează matricea H_t necesară pentru calculul CoVaR și stress testing

Studiu de caz 5: indicele de conectivitate DCC în timp



Interpretare

- C_t sare de la $\sim$0.45 (normal) la $>$0.85 în GFC și COVID — **diversificarea dispare**
- Creșterea conectivității **precede** vârful pierderilor cu 2–3 săptămâni — semnal de avertizare
- Normalizarea post-criză durează 6–12 luni, creând o fereastră de ***false security***
- Când $C_t > 0.5$: beneficiile diversificării sunt **semnificativ reduse**

Studiu de caz 5: exemplu numeric — ΔCoVaR

4 bănci: $\sigma_i = 2.5\%$, $\rho_{i,\text{sys}} = 0.72$, $\sigma_{\text{sys}} = 1.8\%$

- Normal: $\text{VaR}^{\text{sys}} = 2.326 \times 1.8\% = 4.19\%$. Sub stres ($\kappa \approx 2.5$):

$$\sigma_{\text{sys}|i} = \sigma_{\text{sys}} \sqrt{1 + \rho_{i,\text{sys}}^2 (\kappa - 1)} = 1.8\% \times 1.33 = 2.39\%$$

Rezultat

- $\text{CoVaR}^{\text{sys}|i} = 2.326 \times 2.39\% = 5.56\%$
- $\Delta\text{CoVaR}_i = 5.56\% - 4.19\% = 1.37\%$ — stresul băncii i adaugă **33%** la riscul sistemic

Implicație regulatorie

- Băncile cu ΔCoVaR ridicat suportă **suplimente de capital** (buffere G-SIB — *Global Systemically Important Bank*)
- DCC este esențial: cu CCC (ρ fix), ΔCoVaR ratează amplificarea din crize
- În GFC, ΔCoVaR pentru top-5 bănci americane a depășit **3%** — de trei ori nivelul normal

Studiu de caz 5: MES — Marginal Expected Shortfall

Definiție (Acharya et al., 2017)

- **MES** (*Marginal Expected Shortfall*): pierderea așteptată a instituției i când sistemul se află în coadă: $\text{MES}_{i,t} = \mathbb{E}\left[r_{i,t} \mid r_{\text{sys},t} < \text{VaR}^{\alpha}_{\text{sys},t}\right]$
- DCC: $\mathbb{E}[r_i | r_{\text{sys}}] = \rho_{i,\text{sys},t} \cdot \frac{\sigma_{i,t}}{\sigma_{\text{sys},t}} \cdot r_{\text{sys}}$

Exemplu numeric

- Banca i: $\sigma_i = 2.5\%$, $\rho_{i,\text{sys}} = 0.72$; Sistem: $\sigma_{\text{sys}} = 1.8\%$
- Crash sistemic de 2σ ($r_{\text{sys}} = -3.6\%$): $\text{MES}_i = 0.72 \times \frac{2.5}{1.8} \times 3.6\% = 3.60\%$

MES vs. CoVaR

- MES măsoară contribuția **băncii la sistem** (expunere)
- CoVaR măsoară impactul **sistemului asupra băncii** (contagiune)
- Ambele necesită DCC-GARCH

Studiu de caz 5: SRISK — deficit de capital sub stres

Definiție (Brownlees & Engle, 2017)

- **SRISK** (*Systemic Risk*): deficitul de capital așteptat în cazul unei crize sistemice

$$\text{SRISK}_{i,t} = k \cdot D_{i,t} - (1-k) \cdot W_{i,t} \cdot (1 - \text{LRMES}_{i,t})$$

- $k = 8\%$ (raport prudențial), D: datorie, W: capitalizare bursieră, **LRMES** (*Long-Run Marginal Expected Shortfall*): pierderea capitalului propriu într-o scădere de 40% a pieței (6 luni)

Rolul DCC-GARCH în SRISK

- DCC furnizează $\rho_{i,\text{sys},t}$ și $\sigma_{i,t} \Rightarrow$ MES $\Rightarrow$ LRMES (simulare DCC pe 6 luni)
- SRISK se actualizează **zilnic** pe măsură ce capitalizarea și corelațiile DCC se schimbă

Aplicație

- NYU Stern V-Lab publică **clasamente SRISK zilnice** pentru peste 1200 firme financiare globale, bazate pe DCC-GARCH: `vlab.stern.nyu.edu`

Studiu de caz 5: identificarea G-SIB și suplimente de capital

Cum identifică reglementatorii băncile de importanță sistemică

- **FSB** (*Financial Stability Board*)/**Basel**: scor G-SIB = dimensiune + interconectare + substituibilitate + complexitate + activitate transfrontalieră
- **Măsuri bazate pe piață**: ΔCoVaR, MES, SRISK complementează scorurile regulatorii

Suplimentele de capital G-SIB (2024)

Bucket	Supliment	Exemple bănci
5 (cel mai înalt)	3.5%	JPMorgan
4	2.5%	HSBC, Citi
3	2.0%	BNP Paribas, Goldman Sachs
2	1.5%	Deutsche Bank, UBS
1	1.0%	Santander, Standard Chartered

Punct cheie

- Conectivitate DCC mai mare $\Rightarrow$ importanță sistemică mai mare $\Rightarrow$ buffere de capital mai mari $\Rightarrow$ ROE (*Return on Equity*) mai mic
- Măsurarea precisă a $\rho_{ij,t}$ are **consecințe financiare directe**

Studiu de caz 5: rețele de contagiune — vizualizarea interconectivității

De la corelații pereche la topologia rețelei

- DCC produce $N(N-1)/2$ corelații pereche $\rho_{ij,t}$ la fiecare moment t
- Se construiește un **graf ponderat**: noduri = instituții, *edge weight* = $|\rho_{ij,t}|$
- Metrici de rețea: **centralitate de grad**, **betweenness** (rol de punte), **centralitate de vector propriu**

Structura rețelei: criză vs. normal

Proprietatea rețelei	Normal	Criză
Media $\lvert\rho_{ij}\rvert$	0.45	0.85
Densitatea rețelei	0.35	0.90
Coeficient de clustering	0.52	0.88
Nodul cel mai central	JPMorgan	JPMorgan

Concluzie

- În perioade normale, rețeaua este ***sparse*** — șocurile rămân locale
- În crize, devine **densă și complet conectată** — diversificarea devine imposibilă

Studiu de caz 5: DCC pentru testarea de stres regulatorie

Cum folosesc băncile centrale DCC-GARCH

- **Testele de stres ECB (*European Central Bank*)/Fed**: simularea randamentelor activelor în scenarii adverse
- DCC furnizează **structura corelațiilor** pentru scenariu: "dacă acțiunile scad cu 40%, ce se întâmplă cu spread-urile de credit?"
- Cheie: folosiți parametri DCC **calibrați pe criză**, nu medii pe întreg eșantionul

Fluxul de lucru pentru testarea de stres

1. Estimați DCC-GARCH pe 10+ ani de date
2. Extrageți parametrii α, β din subperioada de criză (ex. GFC)
3. Simulați 10.000 de traiectorii $H_{t+1}, \ldots, H_{t+h}$ sub parametri de stres
4. Calculați distribuția pierderilor portofoliului $\Rightarrow$ VaR, ES, SRISK sub stres

De ce nu simulare istorică?

- Simularea istorică folosește randamente **trecute** direct — dar nicio criză nu seamănă cu alta
- Testarea de stres DCC generează scenarii **noi** de criză consistente cu dinamica estimată a corelațiilor

Studiu de caz 5: sumar — setul de instrumente pentru risc sistemic

Măsuri de risc sistemic bazate pe DCC

Măsură	Ce captează	Input cheie din DCC
C_t (conectivitate)	Corelație la nivel de sistem	media $\lvert\rho_{ij,t}\rvert$
ΔCoVaR	Impactul unei bănci asupra VaR sistem	$\rho_{i,\text{sys},t}$, $\sigma_{i,t}$
MES	Pierderea băncii la crash sistemic	$\rho_{i,\text{sys},t}$, $\sigma_{i,t}$
SRISK	Deficit de capital sub stres	LRMES din simulare DCC
Spillover DY	Transmisia volatilității între piețe	VAR pe reziduuri DCC

Concluzii cheie

- DCC-GARCH este **coloana vertebrală** a măsurării moderne a riscului sistemic
- Toți indicatorii majori (ΔCoVaR, MES, SRISK) necesită $\rho_{ij,t}$ variabil în timp
- Indicele de conectivitate $C_t > 0.7$ este un **semnal de avertizare** fiabil pentru crize sistemice
- Aplicații regulatorii: identificarea G-SIB, suplimente de capital, testare de stres

Realized Covariance și HAR-DRD

De la parametric la nonparametric: *Realized Covariance*

- În loc de a *modela* H_t, o **măsurăm** direct din date intraday: $RC_t = \sum_{k=1}^{M} r_{t,k} r'_{t,k}$ (M = nr. intervale, ex. 5 min)
- **Fără model**: nu sunt necesare presupuneri GARCH — datele "vorbesc de la sine"
- Necesită **date de înaltă frecvență** — indisponibile pentru toate activele (obligațiuni, derivate OTC)

Modelul HAR-DRD (Shephard & Sheppard, 2010; Oh & Patton, 2016)

- Descompunere: $RC_t = D_t^{RC} R_t^{RC} D_t^{RC}$ (analog DCC dar cu măsuri realizate)
- Volatilități realizate cu dinamici HAR: $d_{i,t+1} = c + \beta_d d_{i,t} + \beta_w \bar{d}_{i,t}^{(w)} + \beta_m \bar{d}_{i,t}^{(m)} + \varepsilon_{t+1}$
- $\bar{d}^{(w)}$, $\bar{d}^{(m)}$ = medii săptămânale, lunare — captează traderi eterogeni

Când se utilizează

- **De preferat** când datele intraday sunt disponibile — domină MGARCH în previziuni (Lunde et al., 2016)

DCC-MIDAS: separarea dinamicilor pe termen scurt și lung

Motivație

- DCC standard are **o singură scală temporală** — nu distinge fluctuațiile zilnice de tendințele seculare
- Corelațiile au componentă **pe termen lung** (factori macro) și **pe termen scurt** (știri)

DCC-MIDAS (Colacito, Engle & Ghysels, 2011)

- $\bar{Q}_t$ variabil în timp: $\bar{q}_{ij,t} = \sum_{k=1}^{K} \varphi_k(\omega_1, \omega_2)\, c_{ij,t-k}, \quad c_{ij,t} = \frac{1}{N_v} \sum_{n=1}^{N_v} z_{i,t_n} z_{j,t_n}$
- φ_k = schema de ponderare Beta (MIDAS — *Mixed Data Sampling*)
- Dinamici DCC pe termen scurt în jurul lui $\bar{q}_{ij,t}$ care se mișcă lent

Avantaj față de DCC standard

- Captează ***structural breaks*** natural — $\bar{q}_{ij,t}$ se adaptează la noile regimuri
- Previziuni mai bune pe orizont lung (1 lună+) — DCC standard revine prea rapid la $\bar{Q}$

Machine Learning pentru previziunea covarianței

De ce ML? Limitări ale MGARCH parametric

- MGARCH presupune o **formă funcțională fixă** — ML poate învăța dinamici neliniare direct din date
- Previziunea covarianței în dimensiune mare ($N > 100$) este intractabilă pentru MGARCH clasic — ML scalează mai bine

Abordări (Bucci, 2020; De Nard et al., 2021; Zhang et al., 2023)

- **Rețele LSTM / GRU**: tratează vech(H_t) ca serie temporală multivariată — captează dependențe de lungă durată
- **Modele *Transformer***: mecanismul de atenție identifică care corelații trecute sunt cele mai relevante
- ***Graph Neural Networks***: modelează relațiile între active ca graf — natural pentru analiză de contagiune
- **Hibrid DCC-ML**: DCC ca bază, ML corectează reziduurile (Gu, Kelly & Xiu, 2020)

Status actual

- Abordările ML sunt promițătoare pentru N **mare** și **regimuri neliniare**, dar le lipsește interpretabilitatea
- **Fără consens** că ML bate consistent DCC pentru N moderat (< 50)
- Abordările hibride (DCC + corecții ML) sunt cea mai promițătoare direcție curentă

Conformal Prediction pentru calibrarea covarianței

Problema calibrării

- VaR-ul MGARCH presupune o **distribuție specifică** (Gaussiană, Student-t) — specificarea greșită duce la acoperire slabă
- Chiar cu covariança corectă, **presupunerea distribuțională** poate eșua în cozi

Conformal Prediction (Vovk et al., 2005; Gibbs & Candès, 2021)

- Garanție de acoperire **fără distribuție**: produce mulțimi de predicție cu acoperire exactă $1 - \alpha$
- Aplicată la VaR: ajustează cuantila folosind reziduurile trecute, nu presupuneri parametrice
- ***Adaptive Conformal Inference*** (ACI): ajustează acoperirea în timp real — se strânge în calm, se lărgește în criză

Integrare cu MGARCH

- Se folosește DCC-GARCH pentru **previziunea punctuală** a lui H_t, apoi se conformalizează limitele VaR/ES
- Obține **acoperire garantată** chiar când DCC este specificat greșit — ce e mai bun din ambele lumi
- Domeniu activ de cercetare — Nolde & Ziegel (2017), Barber et al. (2023)

Rezumat: concluzii cheie

Ce am învățat

1. GARCH multivariat modelează **matricea de covarianță variabilă în timp** H_t
2. Provocarea principală: **curse of dimensionality** — $N(N+1)/2$ elemente unice
3. **VEC/BEKK**: parametrizare directă — flexibil dar limitat la N mic
4. **CCC**: corelații constante — *parsimonious* dar nerealist
5. **DCC**: corelații dinamice cu doar 2 parametri suplimentari — modelul de referință
6. **aDCC**: adaugă asimetrie în corelații (efect de levier)
7. **Factor/GO-GARCH**: pentru N mare prin reducerea dimensionalității
8. Estimarea în două etape face DCC/CCC fezabile pentru sute de active

Mesajul central

- ⊡ Corelațiile **nu sunt constante** — ignorarea lor duce la **subestimarea riscului**
- ⊡ Deciziile sub-optime de hedging și alocare rezultă din covariante statice

Pipeline practic: pregătirea datelor

Pasul 1: colectarea și curățarea datelor

- Se utilizează **log-randamente** $\times 100$ (procente) — stabilizează optimizarea
- Se aliniază toate seriile pe **date comune de tranzacționare** (se elimină sărbătorile, zilele fără suprapunere)
- Se gestionează **tranzacționarea nesincronă**: pentru active din fusuri orare diferite, se folosesc randamente *open-to-open* sau corecția Scholes–Williams

Pasul 2: analiză preliminară

- **Corelații pe fereastră mobilă** (60 zile, 252 zile) — verificare vizuală a variației în timp
- Test **corelație constantă**: Engle–Sheppard (2001) sau LM Tse (2000)
- Test **efecte ARCH**: LM Engle (1982) pe randamentele pătrate
- Verificare ***structural breaks***: grafic corelații vs. VIX

Punct de decizie

- CCC **nu este respins**: se folosește CCC (mai simplu, mai puțini parametri)
- CCC **este respins**: se trece la DCC/aDCC

Pipeline practic: estimare și selecția modelului

Pasul 3: specificarea GARCH univariat

- Se estimează **GARCH(1,1)** sau **GJR-GARCH(1,1)** pentru fiecare serie individual
- Se utilizează AIC/BIC pentru a selecta cea mai bună specificare univariată **per activ**
- Se verifică: $\alpha + \beta < 1$ (stationaritate), reziduurile trec testul Ljung–Box

Pasul 4: estimarea modelului multivariat

- $N \leq 5$: se estimează DCC, aDCC și Diagonal BEKK; comparare cu AIC/BIC
- $5 < N \leq 50$: se estimează doar DCC și aDCC (BEKK infezabil)
- $N > 50$: DCC cu *composite likelihood*, sau Factor GARCH
- Se inițializează din **EWMA** ($\lambda = 0.94$) sau matricea de corelație din eșantion

Pasul 5: diagnostice

- Se verifică reziduurile standardizate $\hat{z}_{it}$: fără corelație serială (Ljung–Box), fără efecte ARCH reziduale
- Se verifică produsele încrucișate $\hat{z}_{it}\hat{z}_{jt}$: fără corelație încrucișată reziduală (Hosking, 1980)
- Se compară CCC vs. DCC prin testul LR: $LR = 2(\mathcal{L}_{DCC} - \mathcal{L}_{CCC}) \sim \chi^2(2)$

Pipeline practic: validare și aplicare

Pasul 6: validare *out-of-sample*

- Date: **70% antrenare**, **30% testare** (sau fereastră expandabilă)
- Previzionare $\hat{H}_{t+1}$ cu un pas înainte, calcul VaR/ES portofoliu
- *Backtesting*: Kupiec (UC), Christoffersen (CC), Acerbi–Szekely (ES)
- Comparare modele: ***Model Confidence Sets*** sau Diebold–Mariano pe funcții de pierdere

Pasul 7: aplicare

- **Optimizare portofoliu**: $w_t = H_t^{-1}1/(1'H_t^{-1}1)$ (variață minimă)
- ***Hedging***: $h_t^* = \sigma_{12,t}/\sigma_{22,t}$ (raport dinamic)
- **Raportare risc**: VaR/ES zilnic cu corelații variabile în timp
- **Re-estimare** la fiecare 1–2 ani sau după *structural breaks*

Regula de aur

- **Cel mai simplu model care trece testele *out-of-sample*** este cel mai bun model

Python: estimarea DCC-GARCH și VaR de portofoliu

```
import numpy as np
from arch import arch_model
from scipy.optimize import minimize

# Etapa 1: estimare GARCH(1,1) univariat pentru fiecare serie
models, std_resids = [], []
for col in returns.columns:
    mod = arch_model(returns[col]*100, vol='Garch', p=1, q=1, dist='t')
    res = mod.fit(disp='off')
    models.append(res);  std_resids.append(res.std_resid)
Z = np.column_stack(std_resids)   # T x N reziduuri standardizate
Q_bar = np.corrcoef(Z.T)          # corelatie neconditionala

# Etapa 2: dinamica DCC (a, b) via verosimilitate compusa
def dcc_loglik(params, Z, Q_bar):
    a, b = params;  T, N = Z.shape;  Qt = Q_bar.copy();  ll = 0.0
    for t in range(T):
        zt = Z[t:t+1].T
        Qt = (1-a-b)*Q_bar + a*(zt @ zt.T) + b*Qt
        Dt_inv = np.diag(1.0 / np.sqrt(np.diag(Qt)))
        Rt = Dt_inv @ Qt @ Dt_inv
        ll += np.log(np.linalg.det(Rt)) + zt.T @ np.linalg.inv(Rt) @ zt - zt.T @ zt
    return 0.5 * float(ll)
res = minimize(dcc_loglik, [0.05, 0.90], args=(Z, Q_bar),
               bounds=[(1e-6,0.5),(1e-6,0.9999)], method='L-BFGS-B')

# Etapa 3: VaR de portofoliu (99%)
w = np.array([0.6, 0.4])                    # ponderi portofoliu
port_var = np.sqrt(w @ H_t @ w) * 2.326     # scor z 99%
```

TSA_ch5b_dcc_estimation

Arborele de decizie pentru selecția modelului

Pasul 1: câte active (N)?

- $N \leq 3$: toate modelele (BEKK, CCC, DCC, aDCC)
- $3 < N \leq 50$: DCC / aDCC / GO-GARCH
- $N > 50$: DCC, Factor GARCH, shrinkage

Pasul 2: aveți nevoie de spillover-uri?

- **Da** (contagiune, risc sistemic): BEKK ($N \leq 5$) sau Diebold–Yilmaz
- **Nu** (VaR, hedging): $\rightarrow$ Pasul 3

Pasul 3: corelații variabile în timp?

- Se rulează testul Engle–Sheppard sau Tse LM
- Nerespins $\rightarrow$ CCC
- Respins $\rightarrow$ DCC, apoi: asimetrie?

Pasul 4: corelații asimetrice?

- Test $g = 0$ în aDCC: semnificativ $\rightarrow$ aDCC; altfel $\rightarrow$ DCC
- **Final**: comparați prin backtest out-of-sample (nu AIC)

Hartă de selecție a modelului: referință rapidă

Context	Model	De ce
$N \leq 3$, spillovers contează	BEKK (complet)	Identifică direcția șocurilor
$N \leq 10$, fără focus pe spillover	BEKK diagonal	PD prin construcție, scalabil
Orice N, benchmark / estimare rapidă	CCC	Cel mai simplu, întotdeauna start
Orice N, corelații dinamice	DCC	Standard industrial, doar 2 param.
Piețe de acțiuni (leverage în ρ)	aDCC	Captează asimetria corelațiilor
$N > 50$, portofolii mari	Factor GARCH	Reducerea dimensionalității
$N > 100$, timp real	EWMA / RiskMetrics	Fără estimare, actualizare instant

Concluzie cheie: *Nu există model universal optim — doar modelul potrivit pentru N-ul, întrebarea și datele tale.*

Ultra-sumar: ce folosim în practică

#	Regulă	Model
1	Întotdeauna pornește cu benchmark-ul	**CCC**
2	Modelul implicit pentru orice aplicație	**DCC**
3	Dacă șocurile negative $\Rightarrow$ corelație mai mare	**aDCC**
4	Dacă ai nevoie de *direcția* spillover-ului ($N \leq 5$)	**BEKK**
5	Dacă $N > 100$	**Factor / GO-GARCH**

Versiunea de 10 secunde

⊡ **90% din practicieni**: DCC. **Dacă asimetria contează**: aDCC. **Restul**: modele de nișă.

Concluzie cheie: *Estimează CCC mai întâi. Dacă este respins, folosește DCC. Dacă șocurile negative domină, aDCC. Gata.*

Formule cheie: card de referință rapidă

Model	Ecuația fundamentală	Parametri
VEC	$\text{vech}(\mathbf{H}_t) = \mathbf{c} + \mathbf{A}\,\text{vech}(\boldsymbol{\varepsilon}_{t-1}\boldsymbol{\varepsilon}'_{t-1}) + \mathbf{B}\,\text{vech}(\mathbf{H}_{t-1})$	$N^*(1+2N^*)$
BEKK	$\mathbf{H}_t = \mathbf{C}\mathbf{C}' + \mathbf{A}'\boldsymbol{\varepsilon}_{t-1}\boldsymbol{\varepsilon}'_{t-1}\mathbf{A} + \mathbf{B}'\mathbf{H}_{t-1}\mathbf{B}$	$N(N+1)/2 + 2N^2$
CCC	$\mathbf{H}_t = \mathbf{D}_t\mathbf{R}\mathbf{D}_t, \quad h_{ii,t} = \omega_i + \alpha_i\varepsilon^2_{i,t-1} + \beta_i h_{ii,t-1}$	$3N + N(N-1)/2$
DCC	$\mathbf{Q}_t = (1-a-b)\bar{\mathbf{Q}} + a\mathbf{z}_{t-1}\mathbf{z}'_{t-1} + b\mathbf{Q}_{t-1}$	$3N + N(N-1)/2 + 2$
aDCC	$\mathbf{Q}_t = \bar{\mathbf{Q}}^* + a\tilde{\mathbf{z}}_{t-1}\tilde{\mathbf{z}}'_{t-1} + g\mathbf{n}_{t-1}\mathbf{n}'_{t-1} + b\mathbf{Q}_{t-1}$	$3N + N(N-1)/2 + 3$

Mărime cheie	Formulă
Varianța portofoliului	$\sigma^2_{p,t} = \mathbf{w}'\mathbf{H}_t\mathbf{w}$
Raport de hedging min-var	$h^*_t = \sigma_{12,t}/\sigma_{22,t}$
VaR de portofoliu (99%)	$\text{VaR}_{0,99} = -\mu_{p,t} + z_{0,99}\sqrt{\mathbf{w}'\mathbf{H}_t\mathbf{w}}$
Staționaritate DCC	$a + b < 1$
Staționaritate BEKK	$\rho(\mathbf{A}\otimes\mathbf{A} + \mathbf{B}\otimes\mathbf{B}) < 1$

Test: GARCH multivariat (1/2)

Întrebarea 1

☐ De ce modelul CCC presupune $H_t = D_t R D_t$ în loc să modeleze direct toate elementele lui H_t?

Întrebarea 2

☐ În modelul DCC, ce se întâmplă cu corelațiile dinamice când $a = b = 0$?

Întrebarea 3

☐ Aveți un portofoliu de 200 de acțiuni. Ce model GARCH multivariat ați recomanda și de ce?

Întrebarea 4

☐ Explicați de ce corelațiile tind să crească în perioade de criză. Cum captează modelul DCC acest fenomen?

Test: GARCH multivariat (2/2)

Întrebarea 5

- Care este avantajul principal al modelului BEKK față de DCC? Dar dezavantajul principal?

Întrebarea 6

- Un fond de hedging are un portofoliu de 50 de acțiuni și vrea să calculeze VaR zilnic. Ce model GARCH multivariat este cel mai potrivit? Ce tradeoff-uri implică?

Întrebarea 7

- Ce este tranzacționarea nesincronizată (*nonsynchronous trading*) și cum afectează estimarea corelațiilor între piețe din fusuri orare diferite?

Întrebarea 8

- Cum diferă modelul aDCC de DCC standard? În ce situații practice aDCC ar performa semnificativ mai bine?

Test: GARCH multivariat (3/3) — nivel examen

Întrebarea 9 (Analitică)

- Arătați că rescalarea DCC $R_t = \text{diag}(Q_t)^{-1/2} Q_t \, \text{diag}(Q_t)^{-1/2}$ garantează $R_{ii,t} = 1 \; \forall i$. Sub ce condiție este R_t p.d.?

Întrebarea 10 (Aplicată)

- DCC-GARCH, portofoliu 60/40 acțiuni–obligațiuni. În criză, corelația sare de la $+0{,}20$ la $-0{,}30$. Explicați mecanismul economic și impactul asupra VaR-ului vs. CCC.

Întrebarea 11 (Selecție model)

- Estimați CCC, DCC și aDCC pentru 20 acțiuni. In-sample: aDCC are cel mai bun AIC; out-of-sample: CCC are cele mai puține încălcări VaR. Ce model implementați și de ce?

Întrebarea 12 (Conceptuală)

- De ce BEKK și DCC răspund la întrebări fundamental diferite? Dați un exemplu de întrebare de cercetare pentru fiecare.

Test: răspunsuri (1/6)

Răspuns 1

- $H_t = D_t R D_t$ separă **varianțe** (GARCH univariat) de **corelații** (estimare din reziduuri)
- P.d. garantată dacă R p.d. și toți $h_{ii,t} > 0$
- Modelarea directă a tuturor $N(N+1)/2$ elemente ar necesita prea mulți parametri

Răspuns 2

- Când $a = b = 0$: $Q_t = \bar{Q}\ \forall t \Rightarrow R_t = \bar{R}$ constantă
- DCC **se reduce la CCC** — CCC este un caz particular al DCC

Test: răspunsuri (2/6)

Răspuns 3

- Pentru $N = 200$: **Factor GARCH** sau **DCC** cu verosimilitate compozită
- BEKK complet este nefezabil — DCC necesită doar 2 parametri de corelație indiferent de N
- Modelele factoriale reduc dimensionalitatea extragând $K \ll N$ factori

Răspuns 4

- În crize, activele experimentează **șocuri negative comune mari** ($z_{1,t-1}, z_{2,t-1} \ll 0$)
- $q_{12,t}$ crește deoarece $z_{1,t-1}z_{2,t-1} > 0$ este mare, împingând $\rho_{12,t}$ în sus
- Modelul aDCC captează acest efect și mai explicit prin termenul asimetric g

Test: răspunsuri (3/6)

Răspuns 5

- **Avantaj BEKK**: captează *volatility spillovers* — transmiterea directă de șocuri și volatilitate între active prin A și B off-diagonale
- **Dezavantaj**: explozia parametrilor ($N(N+1)/2 + 2N^2$) face estimarea impracticabilă pentru $N > 5$

Răspuns 6

- **DCC**: doar $3N + 2 = 152$ parametri (vs. BEKK: 6.275)
- Estimare: 50 GARCH univariate + optimizare pe 2 parametri
- Tradeoff: DCC **nu captează spillovers**

Test: răspunsuri (4/6)

Răspuns 7

- Piețe din fusuri orare diferite nu tranzacționează simultan — corelația la închidere subestimează legătura reală
- Soluție: corecția Scholes–Williams sau randamente deschidere-la-deschidere

Răspuns 8

- aDCC adaugă $g\, \mathrm{n}_{t-1}\mathrm{n}'_{t-1}$ care crește corelația mai mult după șocuri **negative** comune
- Performează mai bine pentru perechi acțiuni–obligațiuni sau piețe emergente cu levier puternic

Test: răspunsuri (5/6)

Răspuns 9

- Elementul (i, i): $q_{ii,t}/\sqrt{q_{ii,t} \cdot q_{ii,t}} = q_{ii,t}/q_{ii,t} = 1$ — valabil pentru orice $q_{ii,t} > 0$
- R_t este p.d. $\Leftrightarrow$ Q_t este p.d., deoarece rescalarea este o transformare de congruență
- $R_t = PQ_tP$ cu $P = \text{diag}(Q_t)^{-1/2}$ diag. pozitivă — conservă definirea

Răspuns 10

- Schimbarea de semn ($+0{,}20 \to -0{,}30$) = **flight-to-quality**: acțiunile scad, obligațiunile cresc
- Sub CCC: corelația pozitivă constantă $\Rightarrow$ modelul *așteaptă* ca ambele să scadă $\Rightarrow$ **supraestimează** riscul
- Sub DCC: corelația negativă arată corect că obligațiunile *acoperă* acțiunile $\Rightarrow$ VaR mai mic și mai precis
- CCC poate declanșa de-risking inutil — greșit într-o direcție periculoasă

Test: răspunsuri (6/6)

Răspuns 11

- Implementați **CCC** — performanța out-of-sample este singurul criteriu relevant
- aDCC câștigă in-sample dar CCC câștigă out-of-sample = caz clasic de **overfitting**
- Parametrii suplimentari ai aDCC captează tipare care nu se generalizează
- Regula de aur: cel mai simplu model care trece backtestele este cel mai bun model

Răspuns 12

- **BEKK**: "*de unde provin șocurile și cum se propagă?*" — spillover-uri direcționale prin A, B
  - Ex.: "Volatilitatea din băncile americane se propagă în cele europene?"
- **DCC**: "*cum se schimbă co-mișcarea în timp?*" — corelație variabilă, fără cauzalitate
  - Ex.: "Cât de corelate au fost acțiunile și obligațiunile în COVID-19?"
- BEKK = model *structural*; DCC = model *descriptiv*

Referințe cheie (1/2)

Bollerslev, T. (1990). Modelling the coherence in short-run nominal exchange rates: A multivariate generalized ARCH model. *Review of Economics and Statistics*, 72(3), 498–505.

Bollerslev, T., Engle, R.F., & Wooldridge, J.M. (1988). A capital asset pricing model with time-varying covariances. *Journal of Political Economy*, 96(1), 116–131.

Engle, R.F. (2002). Dynamic conditional correlation: A simple class of multivariate GARCH models. *Journal of Business & Economic Statistics*, 20(3), 339–350.

Engle, R.F. & Kroner, K.F. (1995). Multivariate simultaneous generalized ARCH. *Econometric Theory*, 11(1), 122–150.

Cappiello, L., Engle, R.F., & Sheppard, K. (2006). Asymmetric dynamics in the correlations of global equity and bond returns. *Journal of Financial Econometrics*, 4(4), 537–572.

van der Weide, R. (2002). GO-GARCH: A multivariate generalized orthogonal GARCH model. *Journal of Applied Econometrics*, 17(5), 549–564.

Bauwens, L., Laurent, S., & Rombouts, J.V.K. (2006). Multivariate GARCH models: A survey. *Journal of Applied Econometrics*, 21(1), 79–109.

Tse, Y.K. & Tsui, A.K.C. (2002). A multivariate GARCH model with time-varying correlations. *JBES*, 20(3), 351–362.

Diebold, F.X. & Yilmaz, K. (2012). Better to give than to receive: Predictive directional measurement of volatility spillovers. *Int. J. Forecasting*, 28(1), 57–66.

Adrian, T. & Brunnermeier, M.K. (2016). CoVaR. *American Economic Review*, 106(7), 1705–1741.

Referințe cheie (2/2)


Aielli, G.P. (2013). Dynamic conditional correlation: On properties and estimation. *Journal of Business & Economic Statistics*, 31(3), 282–299.


Patton, A.J. (2006). Modelling asymmetric exchange rate dependence. *International Economic Review*, 47(2), 527–556.


Caporin, M. & McAleer, M. (2012). Do we really need both BEKK and DCC? *Journal of Economic Surveys*, 26(4), 736–751.


Laurent, S., Rombouts, J.V.K., & Violante, F. (2012). On the forecasting accuracy of multivariate GARCH models. *Journal of Applied Econometrics*, 27(6), 934–955.


Colacito, R., Engle, R.F., & Ghysels, E. (2011). A component model for dynamic correlations. *Journal of Econometrics*, 164(1), 45–59.


Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.


Christoffersen, P.F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.


Acerbi, C. & Szekely, B. (2014). Back-testing expected shortfall. *Risk*, 27(11), 76–81.


Shephard, N. & Sheppard, K. (2010). Realising the future: forecasting with high-frequency-based volatility (HEAVY) models. *Journal of Applied Econometrics*, 25(2), 197–231.


Brownlees, C. & Engle, R.F. (2017). SRISK: A conditional capital shortfall measure of systemic risk. *Review of Financial Studies*, 30(1), 48–79.


Hansen, P.R., Lunde, A., & Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.