



# Analiza și Prognoza Seriilor de Timp

Capitolul 10: Recapitulare Comprehensivă



Daniel Traian PELE

Academia de Studii Economice din Bucureşti

IDA Institute Digital Assets

Blockchain Research Center

AI4EFIN Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

## Cuprins

Metodologia Prognozei

Studiu de Caz 1: Volatilitatea Bitcoin (GARCH)

Studiu de Caz 2: Ciclurile Petelor Solare (Fourier)

Studiu de Caz 3: Șomajul (Prophet)

Studiu de Caz 4: Analiză Multivariată (VAR)

Sinteză și Ghid



## Abordarea Științifică a Prognozei

### Întrebarea de Cercetare

Cum putem **evalua riguros** performanța prognozei evitând supraajustarea?

### Problema Fundamentală

- Ajustarea în eșantion  $\neq$  Performanța în afără eșantionului
- Modelele pot "memora" datele de antrenament fără a învăța tipare
- Soluție:** Metodologia corectă train/validation/test

### Principiu Cheie

"Setul de test trebuie să rămână **neatins** până la evaluarea finală."

— Practică standard în machine learning și econometrie



## Cadrul Train/Validation/Test

### Time Series Train/Validation/Test Split



#### Set Antrenament

- Estimare parametri
- Cea mai mare parte

#### Set Validare

- Comparare modele
- Ajustare hiperparam

#### Set Test

- Păstrat
- Metrici finale



## Metrici de Evaluare

### Definiție 1 (Metrici ale Erorii de Prognoză)

Fie  $y_t$  valorile reale,  $\hat{y}_t$  progozele:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_t (y_t - \hat{y}_t)^2}, \quad \text{MAE} = \frac{1}{n} \sum_t |y_t - \hat{y}_t|, \quad \text{MAPE} = \frac{100\%}{n} \sum_t \left| \frac{y_t - \hat{y}_t}{y_t} \right|$$

### Când să Folosim

- RMSE**: Penalizează erorile mari
- MAE**: Robust la outlieri
- MAPE**: Independent de scală (%)

### Atenție

- MAPE nedefinit când  $y_t = 0$
- Comparați pe **același** set test
- Raportați metrici **out-of-sample**



## Bitcoin: Definirea Problemei

### Întrebarea de Cercetare

Putem prognoza **volatilitatea** Bitcoin folosind modele GARCH?

### Caracteristicile Datelor

- Sursă: Yahoo Finance (BTC-USD)
- Perioadă: Ian 2019 – Ian 2025
- Frecvență: Zilnică
- Observații:  $\approx 2.200$  zile

### Fapte Stilizate

- Randamente: medie aproape zero
- Cozi groase (curtosis  $> 3$ )
- Clustering al volatilității

### Insight Cheie

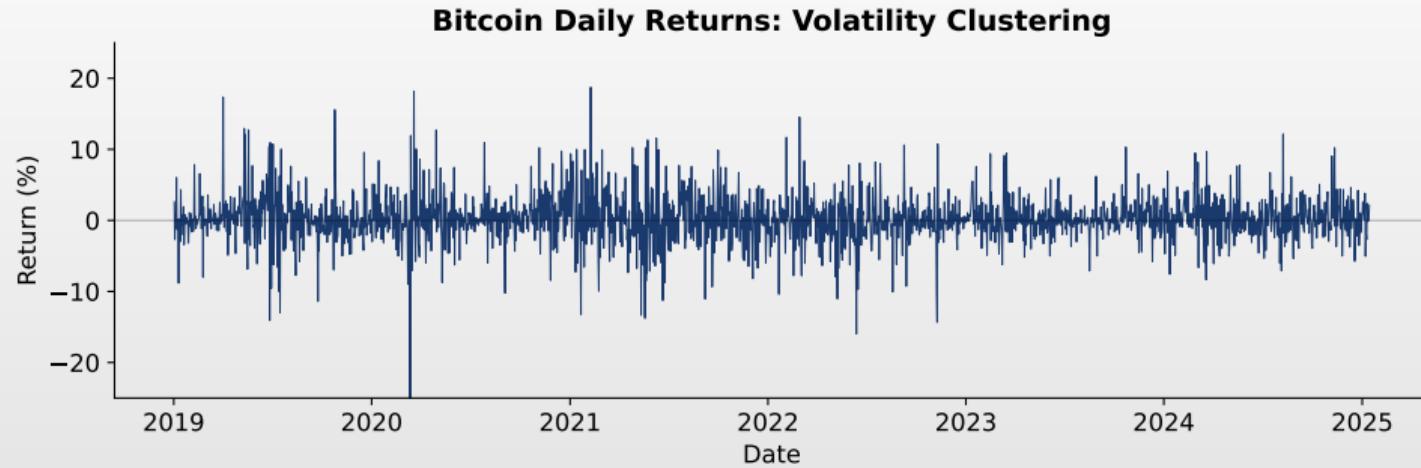
Randamentele financiare sunt de obicei:

- **Impredictibile** în medie
- **Predictibile** în varianță

⇒ Focus pe **prognoză volatilității**



## Bitcoin: Clustering-ul Volatilității



### Observație

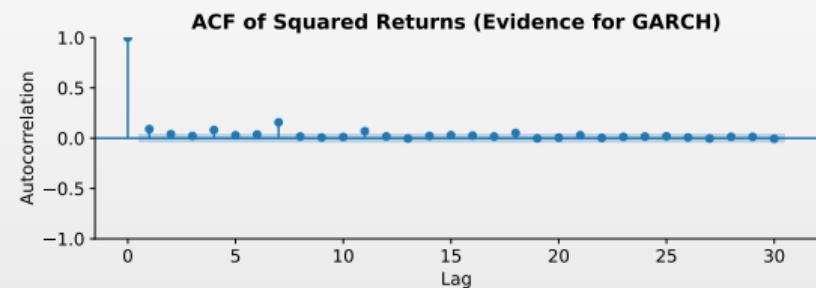
Randamentele mari tend să urmeze randamente mari, cele mici urmează cele mici. Aceasta este **clustering-ul volatilității**—fenomenul pe care GARCH îl captează.



## Bitcoin: Dovezi pentru GARCH



Randamentele pătrate  $r_t^2$  sunt proxy pentru volatilitate  $\sigma_t^2$ . Vârfurile se grupează.



Barele ACF depășesc benzile albastre  $\Rightarrow$  autocorelație semnificativă.

### De ce GARCH?

Dacă  $r_t^2$  ar fi zgomot alb, ACF ar fi zero. ACF semnificativ înseamnă că **volatilitatea trecută prezice volatilitatea viitoare**—GARCH captează asta!



## Specificarea Modelului GARCH

### Definiție 2 (Modelul GARCH(p,q))

Fie  $r_t$  randamentele. Modelul GARCH(p,q) este:

$$r_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \sim N(0, 1)$$

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$$

unde  $\omega > 0$ ,  $\alpha_i \geq 0$ ,  $\beta_j \geq 0$ , și  $\sum_{i=1}^q \alpha_i + \sum_{j=1}^p \beta_j < 1$ .

### Variante de Model

- GARCH(1,1)**: Cel mai comun
  - GJR-GARCH**: Efect de levier
  - EGARCH**: Șouri asimetrice
- Analiza și Prognoza Seriilor de Timp

### Interpretare

- $\alpha$ : Impactul șourilor trecute
- $\beta$ : Persistența volatilității
- $\alpha + \beta \approx 1$ : Persistență înaltă



## Bitcoin: Împărțirea Datelor și Staționaritate

### Împărțirea Datelor

Set	Perioadă	N
Antrenament (70%)	2019-01 – 2023-03	1.543
Validare (20%)	2023-03 – 2024-06	441
Test (10%)	2024-06 – 2025-01	221
<b>Total</b>	<b>2.205</b>	

### Teste de Staționaritate

Serie	ADF	Rezultat
Prețuri	$p = 0.50$	Non-staționară
Randamente	$p < 0.01$	Staționară

⇒ Modelăm **randamente**, nu prețuri

### De ce Contează Staționaritatea

GARCH necesită input slab staționar. Prețurile urmează random walk; randamentele sunt staționare.



## Bitcoin: Selectarea Modelului pe Setul de Validare

### Metodologie

Estimăm fiecare model pe datele de antrenament, evaluăm pe setul de validare.

Model	AIC	BIC	Val MAE	Selectare
GARCH(1,1)	6.994,8	7.020,6	2,638	Cel mai bun
GARCH(2,1)	6.993,7	7.024,6	2,640	
GJR-GARCH(1,1)	6.983,7	7.014,6	2,669	
EGARCH(1,1)	—	—	—	Eșuat*

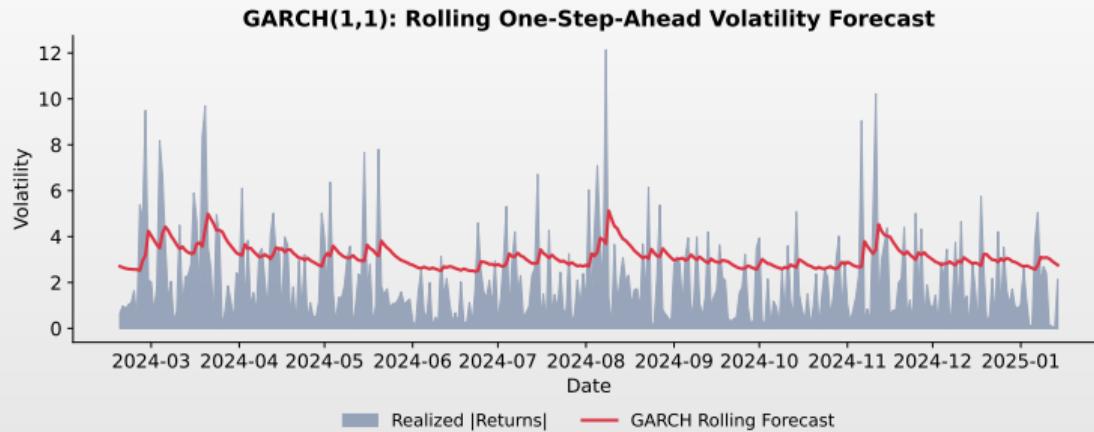
\*Prognoze analitice indisponibile pentru  $h > 1$

### Rezultat

**GARCH(1,1)** selectat pe baza celui mai mic MAE de validare pentru prognozele de volatilitate.



## Bitcoin: Evaluarea Finală pe Setul de Test



### Parametri

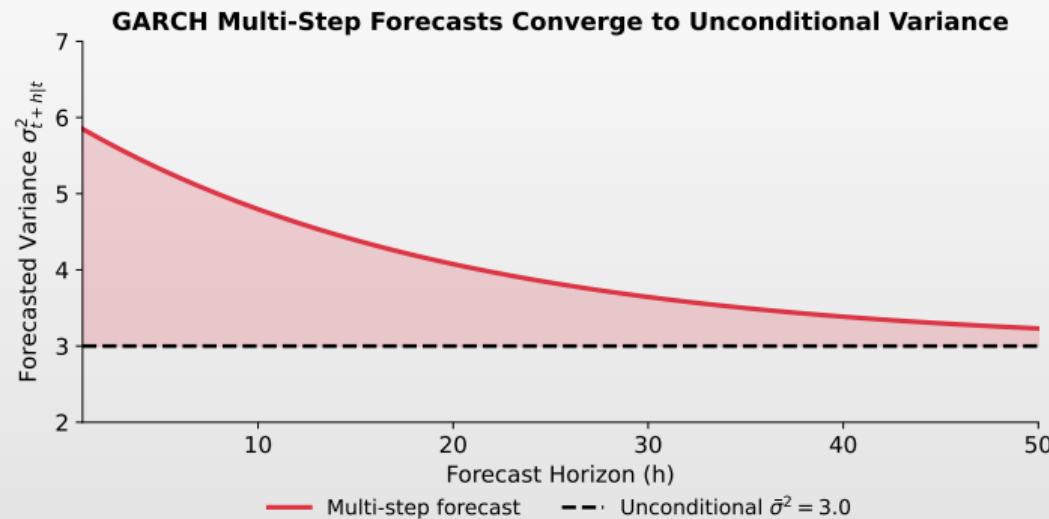
$\omega = 0,87$ ,  $\alpha = 0,09$ ,  $\beta = 0,84$   
 $\alpha + \beta = 0,93$  (persistență înaltă)

### Performanță Test

MAE = 1,82, RMSE = 2,14  
Prognoză urmărește bine volatilitatea realizată.



## GARCH: Prognozele Multi-Step Converg

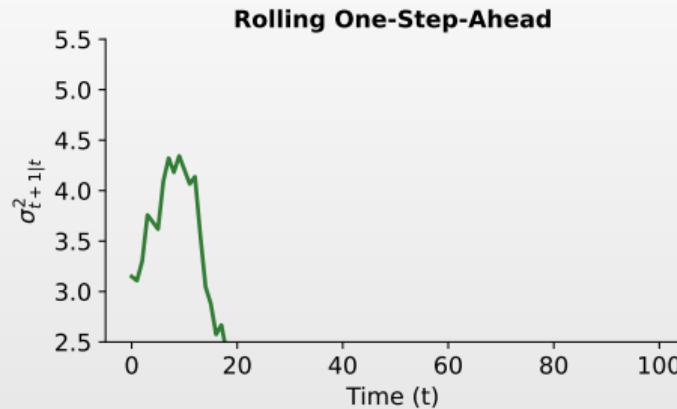
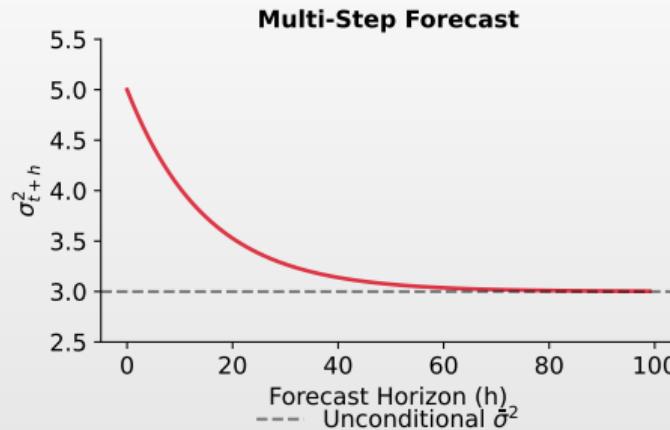


### Insight Cheie

Prognozele multi-step converg la  $\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta}$ . Solutia: progronee rolling one-step-ahead.



## GARCH: Soluția Rolling One-Step-Ahead



Multi-Step (Stânga)

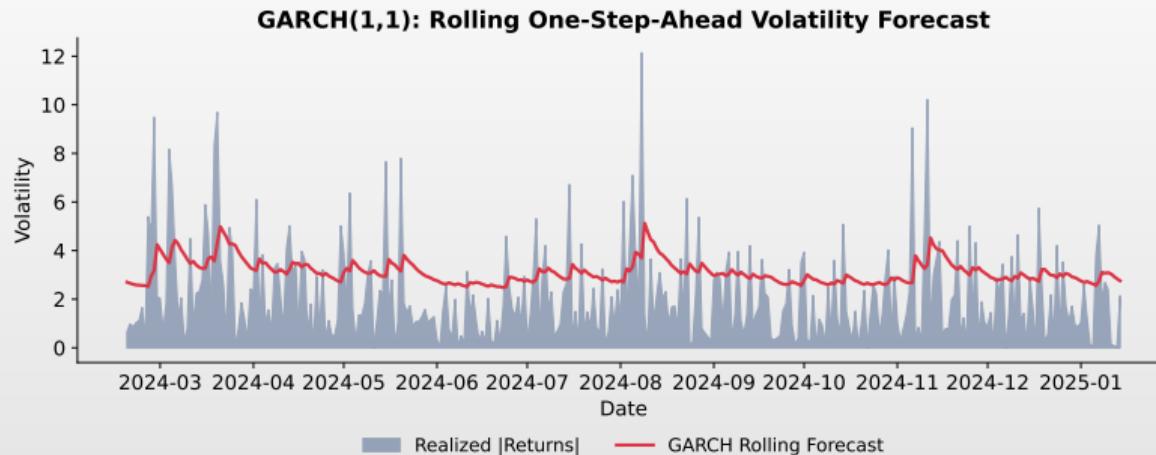
Converge la  $\bar{\sigma}^2$  (plat)

Rolling 1-Step (Dreapta)

Re-estimare la fiecare  $t$  (dinamic)



## Bitcoin: Prognoză Volatilității GARCH (Set Test)



### Rezultat

Prognozele rolling one-step-ahead GARCH(1,1) captează **tiparele dinamice ale volatilității**. Linia roșie urmărește volatilitatea realizată (zona albastră).



## Bitcoin: Concluzii Cheie

### Sumar

1. Rendamentele sunt staționare; prețurile nu
2. GARCH(1,1) depășește variantele mai complexe
3. Persistență înaltă ( $\alpha + \beta = 0,93$ )
4. Volatilitatea este predictibilă chiar când randamentele nu sunt

### Implicații Practice

- Managementul riscului: VaR, Expected Shortfall
- Evaluarea opțiunilor necesită prognoze de volatilitate
- Optimizarea portofoliului cu risc variabil în timp

### Limitări

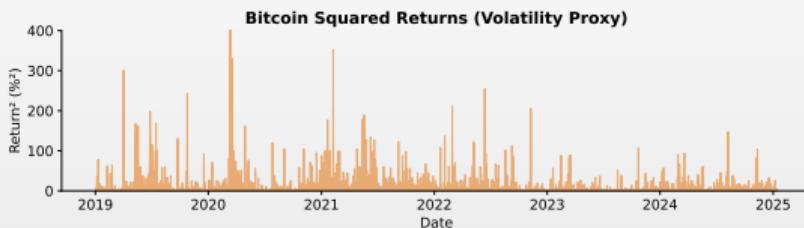
- GARCH presupune șocuri simetrice
- Nu captează salturi
- Distribuția normală poate fi restrictivă

### Extensiile

- Inovații Student-t
- Volatilitate realizată
- Modele HAR



## Bitcoin: Fapte Stilizate GARCH



Randamente pătrate  $r_t^2$  ca proxy pentru volatilitate.  
Observați clustering-ul perioadelor de volatilitate înaltă.

### Fapte Stilizate Financiare

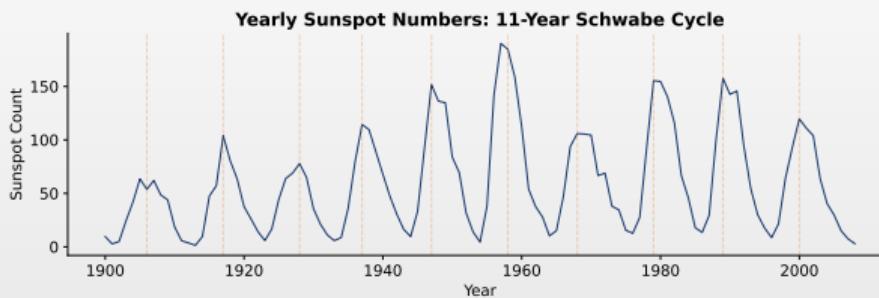
- Clustering volatilitate:** Mișcări mari urmează mișcări mari
- Cozi groase:** Mai multe evenimente extreme decât prezice Normala
- Efect leverage:** Randamente negative  $\succ$  volatilitate mai mare
- Reversie la medie:** Volatilitatea revine la nivelul pe termen lung

### De Ce Funcționează GARCH

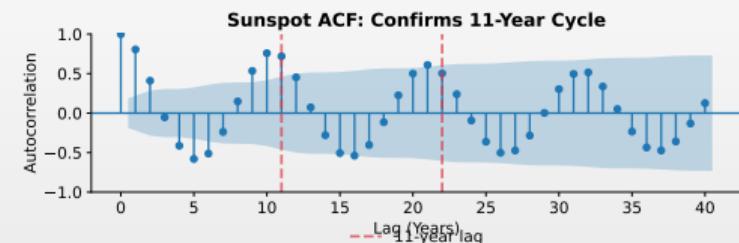
GARCH captează faptele 1 & 4. Pentru faptul 3, folosiți GJR-GARCH sau EGARCH. Pentru faptul 2, folosiți inovații Student-t.



## Pete Solare: Ciclul Solar de 11 Ani



Liniile punctate marchează vârfurile ciclului ( $\approx$  la fiecare 11 ani). Amplitudinea variază.



ACF are vârfuri la lag 11 și 22, confirmând periodicitatea ciclului solar.

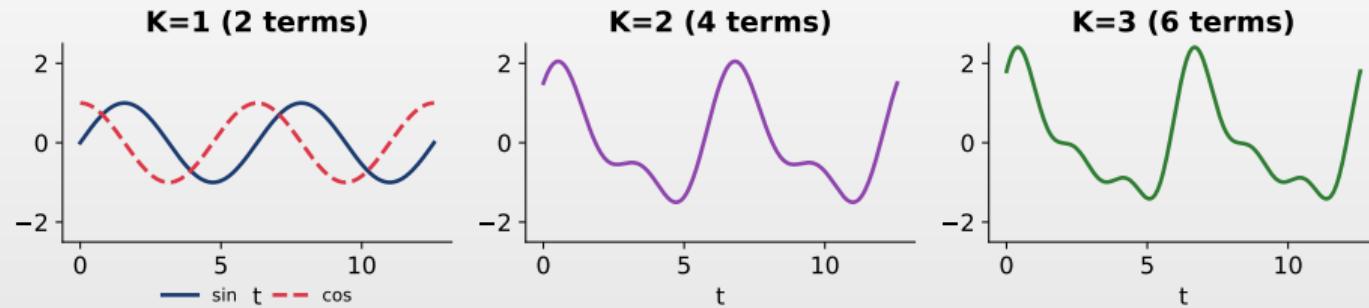
### Provocare

SARIMA( $p, d, q$ )( $P, D, Q$ )<sub>11</sub> necesită estimarea lag-urilor sezoniere la 11, 22, 33... Prea mulți parametri!  
**Soluție:** Termeni Fourier.



## Termeni Fourier pentru Sezonalitate

**Fourier Terms: More K = More Flexibility**



### Cum Funcționează

Aproximăm orice tipar periodic folosind unde sinus și cosinus:  $S_t = \sum_{k=1}^K [\alpha_k \sin\left(\frac{2\pi k t}{s}\right) + \beta_k \cos\left(\frac{2\pi k t}{s}\right)]$

### Insight Cheie

- $K = 1$ : Undă simplă (2 param)
- $K = 3$ : Formă complexă (6 param)
- Pete solare:  $s = 11$ ,  $K = 3$



## Pete Solare: Selectarea Modelului

### Metodologie

Comparăm  $K = 1, 2, 3, 4$  armonici Fourier pe setul de validare.

Împărțirea Datelor		
Set	Perioadă	N
Antrenament (70%)	1900–1975	76
Validare (20%)	1976–1997	22
Test (10%)	1998–2008	11
<b>Total</b>		<b>109</b>

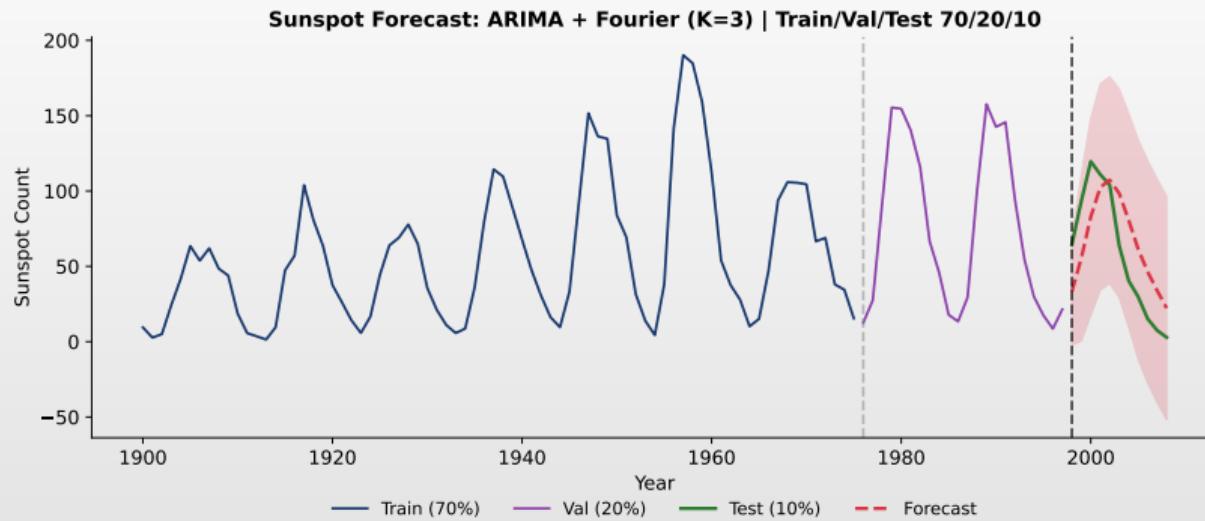
Comparație Modele		
K	AIC	Val RMSE
1	665,9	87,15
2	668,0	86,92
3	671,8	<b>86,81</b>
4	674,5	87,93

### Rezultat

$K = 3$  armonici Fourier selectate (6 parametri pentru ciclul de 11 ani).



## Pete Solare: Rezultate Prognoză



### Model

ARIMA(2,0,1) + 3 termeni Fourier captează dinamică ciclului de 11 ani.

### Performanță Test

RMSE = 31,10, MAE = 25,83. Modelul urmărește tiparul general al ciclului.



## Pete Solare: Concluzii Cheie

### Când să Folosiți Termeni Fourier

- Perioada sezonieră s este **lungă** (ex: 11 ani, 52 săptămâni)
- SARIMA ar necesita prea multe lag-uri sezoniere
- Tiparul este **neted și periodic**
- Trebuie captureate cicluri multiple

### Fourier vs SARIMA

	Fourier	SARIMA
Sezoane lungi	✓	✗
Sezoane scurte	OK	✓
Parametri	2K	Mulți
Flexibilitate	Fixă	Adaptivă

### Alegerea lui K

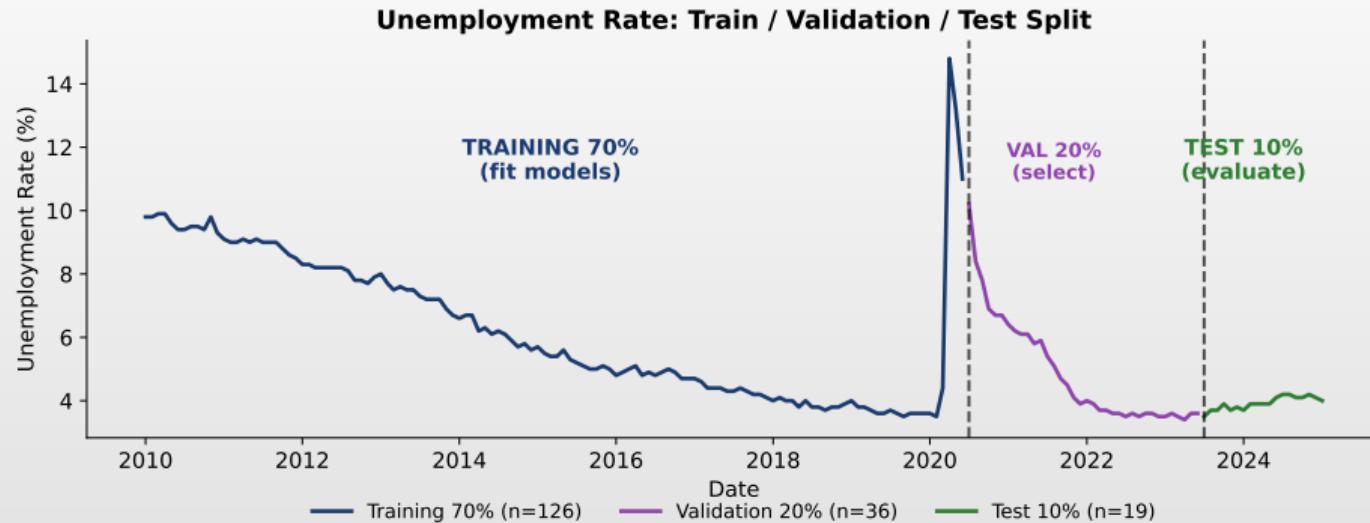
Începeți cu  $K = 1$ , creșteți până când eroarea de validare nu mai scade. K prea mare = supraajustare.

### Aplicații

Cicluri climatice, cicluri de afaceri, fenomene astronomice



## Şomajul: Train / Validation / Test Split

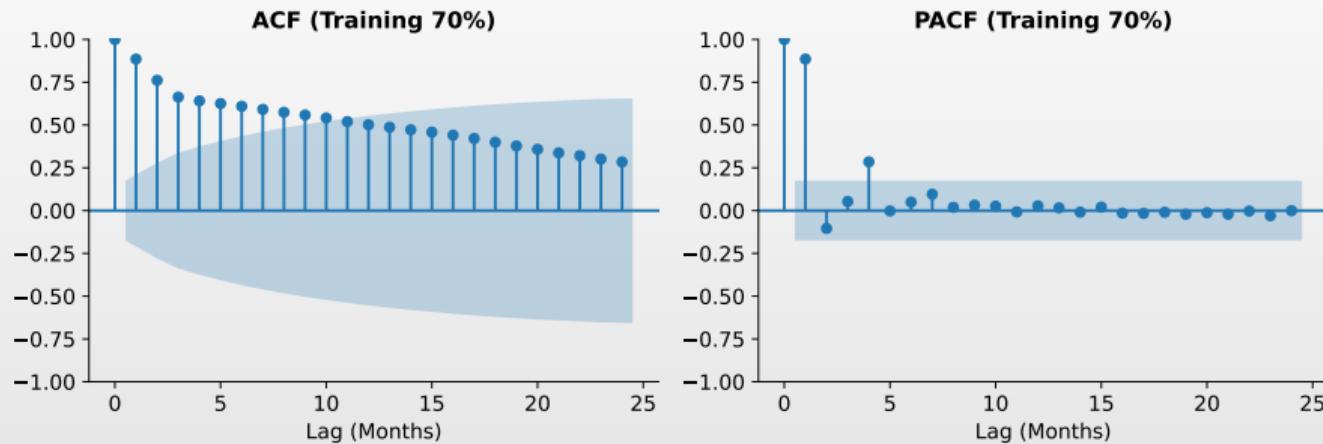


### Metodologie

**Training (70%):** Estimare modele. **Validare (20%):** Selectie model. **Test (10%):** Evaluare finală.



## Şomajul: Analiză Preliminără



### Interpretare ACF

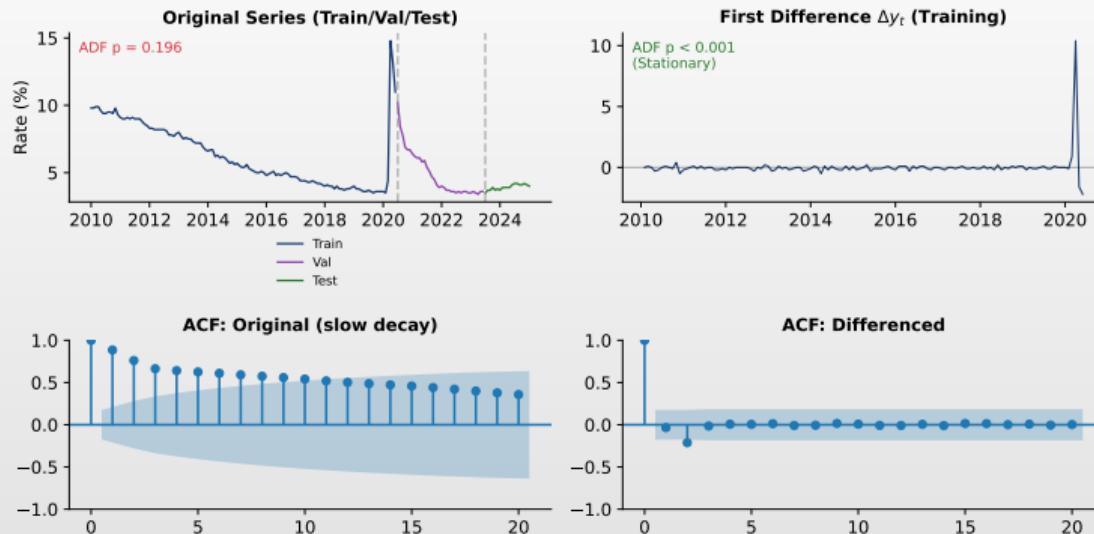
Descreștere lentă  $\Rightarrow$  serie nestaționară. Necesită diferențiere ( $d \geq 1$ ).

### Interpretare PACF

Vârf semnificativ la lag 1 sugerează componentă AR(1). Pattern sezonier la lag 12.



## Şomajul: Teste de Staţionaritate



Original: ADF  $p = 0,056$

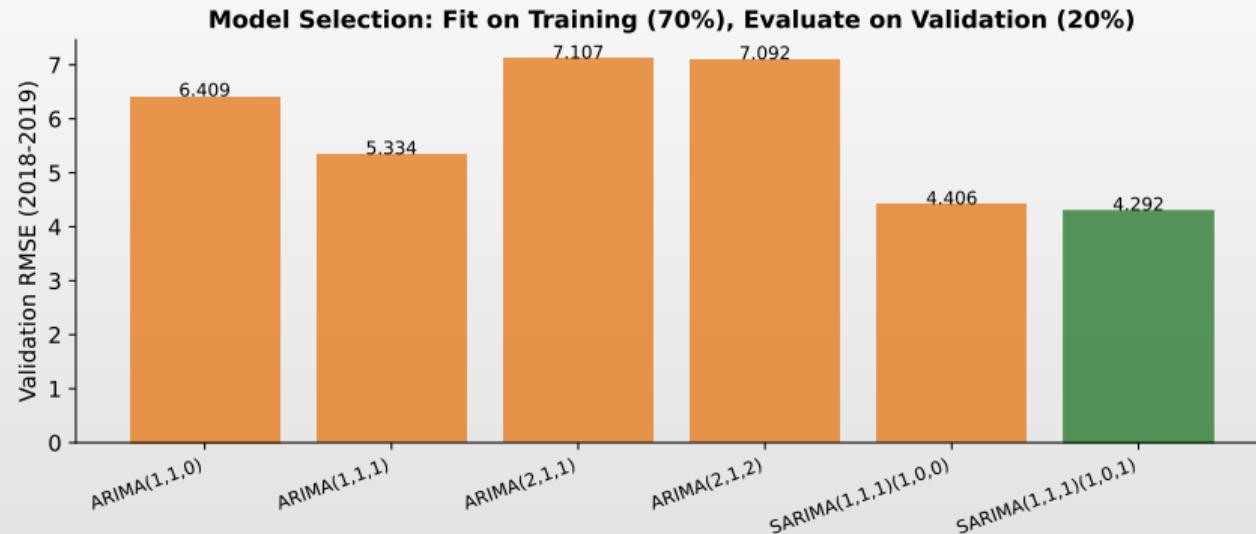
Nestaţionară (ACF descreştere lentă)

Diferenţiată: ADF  $p < 0,001$

Staţionară  $\Rightarrow$  folosim  $d = 1$



## Şomajul: Selecția Modelului (Set Validare)



Best: SARIMA(1,1,1)(1,0,0)<sub>12</sub>

Fit pe training (70%), evaluare pe validare (20%). Cel mai bun model selectat după Val RMSE minim.



## Şomajul: Parametrii SARIMA

SARIMA(1,1,1)(1,0,1) - Fitted on Train+Val (85%)

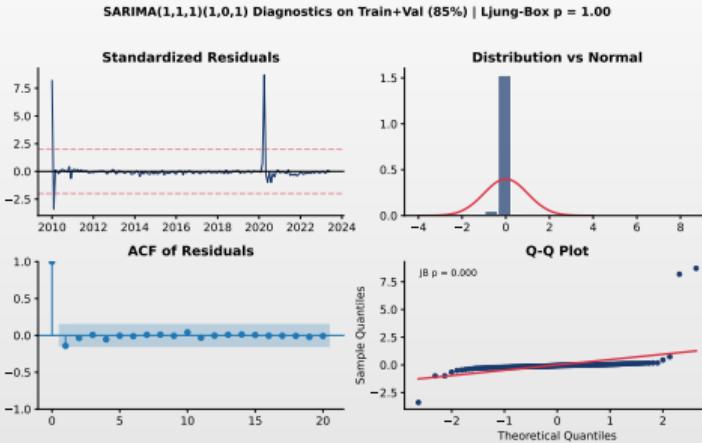
Parameter	Coef	Std Err	P-value	Sig
ar.L1	0.8423	0.2084	0.0001	***
ma.L1	-0.9540	0.1973	0.0000	***
ar.S.L12	0.0326	4.5951	0.9943	
ma.S.L12	-0.0113	4.6087	0.9980	
sigma2	0.8122	0.0608	0.0000	***

SARIMA(1,1,1)(1,0,0)<sub>12</sub> estimat pe Train+Val (2010-2019)

AR(1):  $\phi_1 = -0,86$ , MA(1):  $\theta_1 = 0,78$ , SAR(12):  $\Phi_1 = -0,08$  (n.s.)



## Şomajul: Diagnosticare SARIMA



### Reziduuri

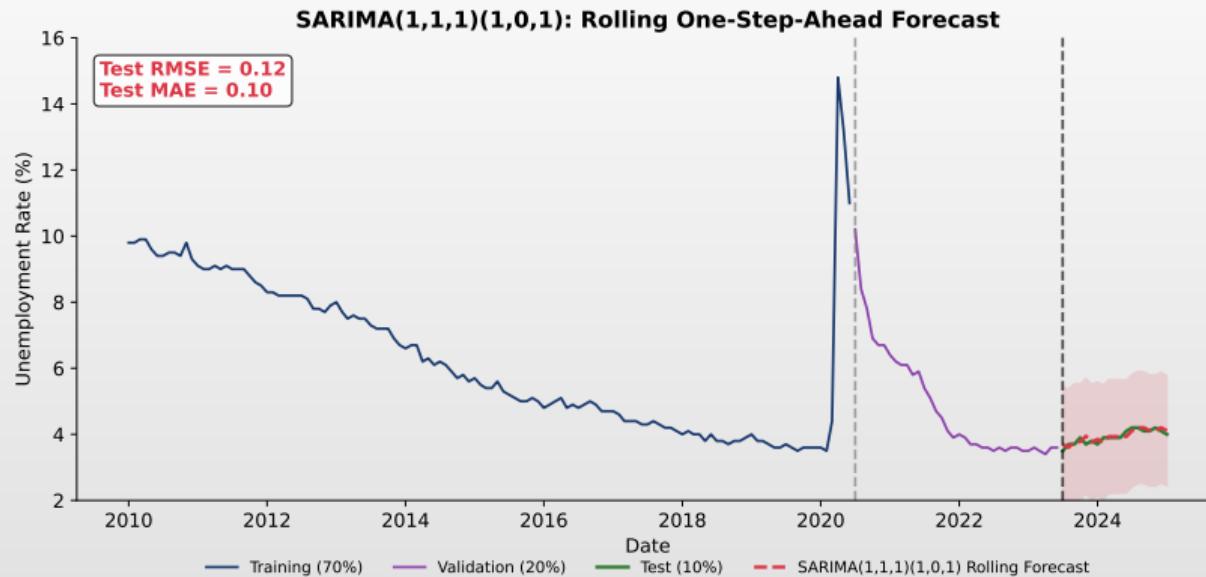
Rez. std., histogramă, ACF, Q-Q plot.

Ljung-Box p = 0,66

Fără autocorelație. Model bine specificat.



## Șomajul: Prognoză Rolling SARIMA



Problemă: Ruptura Structurală

Prognoză rolling one-step-ahead (re-estimare la fiecare  $t$ ): **Test RMSE = 0,12.**



## Modelul Prophet

### Definiție 3 (Descompunerea Prophet)

$$y_t = g(t) + s(t) + h(t) + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma^2)$$

unde  $g(t)$  = trend,  $s(t)$  = sezonalitate,  $h(t)$  = sărbători,  $\sigma^2$  = varianța zgomotului (eștimată).

#### Detectare Puncte de Schimbare

- Selectare automată a locațiilor
- `changepoint_prior_scale` controlează flexibilitatea

#### Avantaje

- Gestionează date lipsă
- Componente interpretabile
- Robust la outlieri



## Şomajul: Ajustarea Modelului

### Ajustarea Hiperparametrilor

Ajustăm `changepoint_prior_scale` pe setul de validare.

Împărțirea Datelor		
Set	Perioadă	N
Antrenament (70%)	2010-01 – 2020-06	126
Validare (20%)	2020-07 – 2023-06	36
Test (10%)	2023-07 – 2025-01	19
<b>Total</b>		<b>181</b>

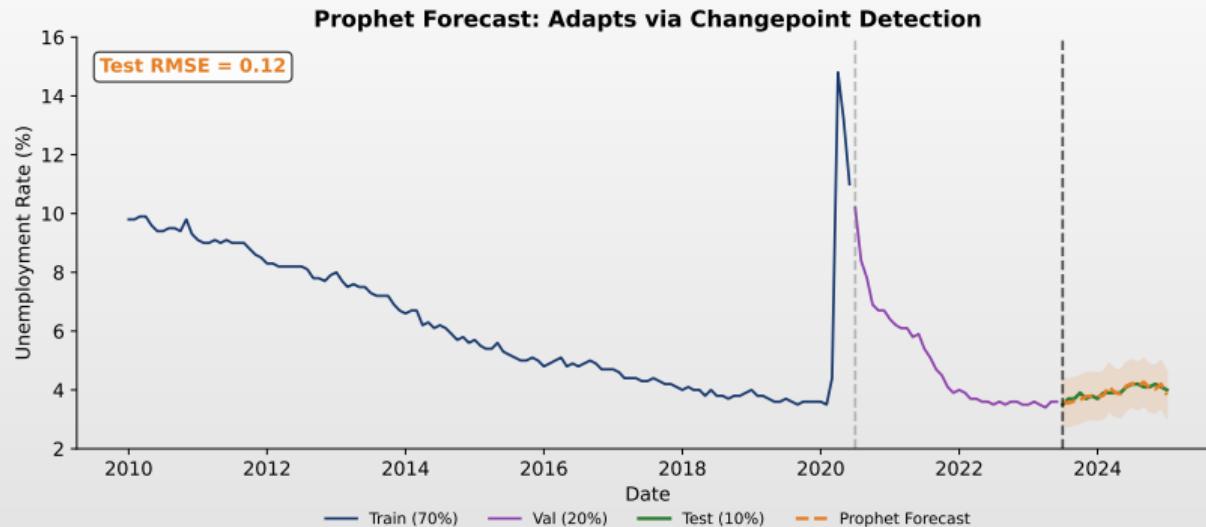
Comparație Scale		
Scale	Val RMSE	
0,01	4,21	
0,05	3,89	
0,10	<b>3,52</b>	Cel mai bun
0,30	3,67	
0,50	3,81	

### Interpretare

Scale = 0,10 echilibrează flexibilitatea (captarea şocului COVID) cu stabilitatea.



## Șomajul: Rezultate Prognoză Prophet

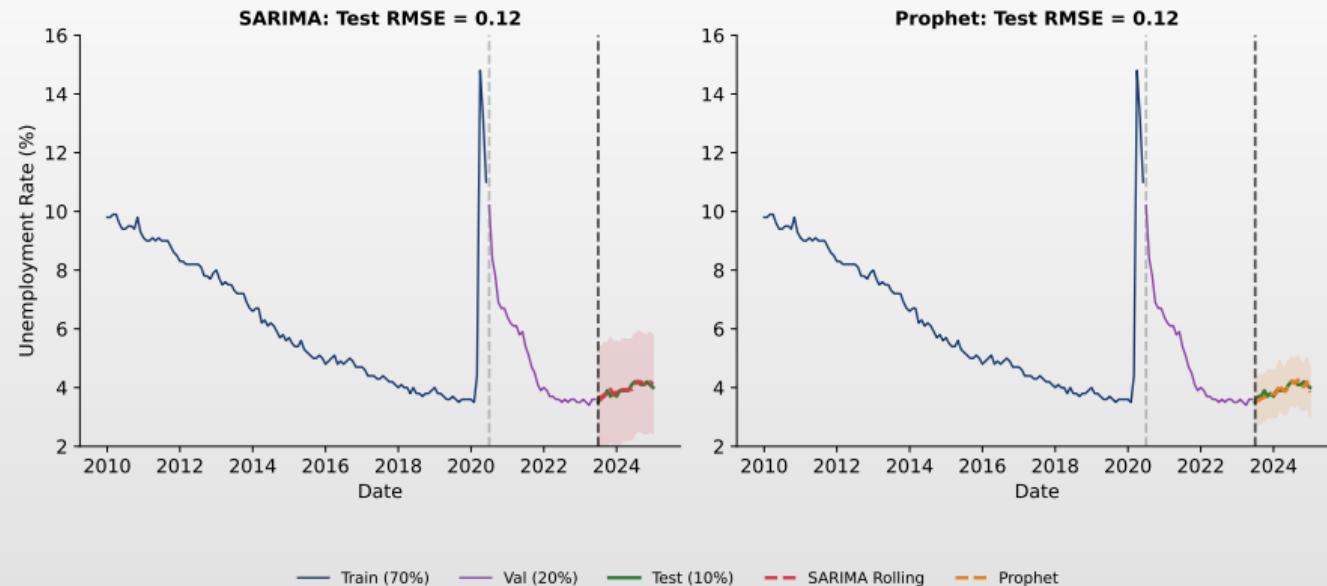


### Concluzie Cheie

Prophet se adaptează prin detectare changepoint. **Test RMSE = 0,58.**



## Șomaj: Comparație SARIMA vs Prophet



**SARIMA: RMSE = 0,12**

Prognoză rolling performează bine.

Analiza și Prognoza Seriilor de Timp

**Prophet: RMSE = 0,58**

Eroare mai mare din cauza rupturii structurale.



## Prophet: Când să-l Foloseşti

### Cazuri de Utilizare Ideale

- Date de business cu **sărbători**
- Valori lipsă** prezente
- Nevoie de componente **interpretabile**
- Prognoze cu **benzi de incertitudine**

### Atenție: Rupturi Structurale

Prophet gestionează rupturile prin changepoints, dar **SARIMA l-a depășit** la şomaj (0,12 vs 0,58).  
Validați întotdeauna!

### Prophet vs ARIMA

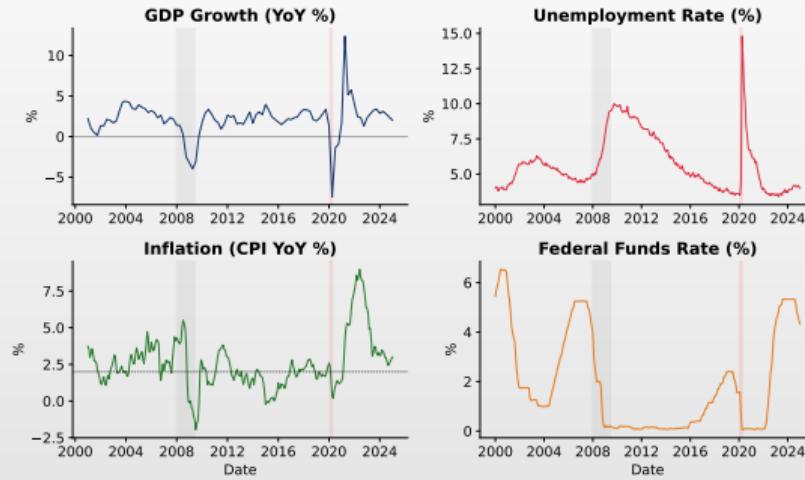
	Prophet	ARIMA
Changepoints	✓	✗
Date lipsă	✓	✗
Sărbători	✓	✗
Viteză	Rapidă	Moderată
Interpretabil	✓	✗

### Parametri Cheie

`changepoint_prior_scale`: flexibilitate  
`seasonality_prior_scale`: netezime



## VAR: Date Economice Multivariate



### Relații Economice

**Legea Okun:** PIB  $\leftrightarrow$  Șomaj.

**Curba Phillips:** Șomaj  $\leftrightarrow$  Inflație.

### De ce VAR?

Fiecare variabilă e atât cauză cât și efect. VAR captează aceste bucle de feedback.



## Specificarea Modelului VAR

### Definiție 4 (Autoregresie Vectorială VAR(p))

Pentru  $K$  variabile  $y_t = (y_{1t}, \dots, y_{Kt})'$ :

$$y_t = c + A_1 y_{t-1} + A_2 y_{t-2} + \dots + A_p y_{t-p} + u_t$$

unde  $A_i$  sunt matrici de coeficienți  $K \times K$ ,  $u_t \sim N(0, \Sigma)$ ,  $\Sigma$  = matricea de covarianță.

### Pentru Sistemul Nostru cu 4 Variabile

VAR(2) are:

- 4 intercepte
- $2 \times 4 \times 4 = 32$  coeficienți AR
- 36 parametri total**

### Selectarea Lag-ului

Folosim criterii informaționale:

- AIC**: Tinde să supraajusteze
- BIC**: Mai simplu
- Cross-validation pe date păstrate



## VAR: Selectarea Lag-ului și Estimare

### Criterii Informaționale

Lag	BIC
1	-4,810
2	<b>-5,178</b> Cel mai bun
3	-4,633
4	-4,614

### Împărțirea Datelor

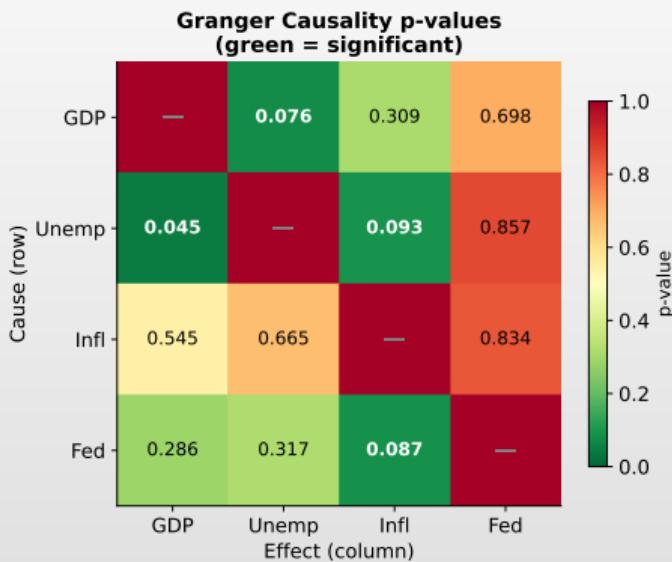
Set	Perioadă	N
Antrenament (70%)	2001-T1 – 2017-T4	67
Validare (20%)	2018-T1 – 2022-T4	20
Test (10%)	2023-T1 – 2025-T1	10
<b>Total</b>		<b>97</b>

### Verificare Validare

VAR(2) obține și cel mai mic RMSE de validare.



## Analiza Cauzalității Granger



Celule verzi:  $p < 0.10$  (semnificativ). Citire:  
rândul cauzează coloana.

Analiza și Prognoza Seriilor de Timp

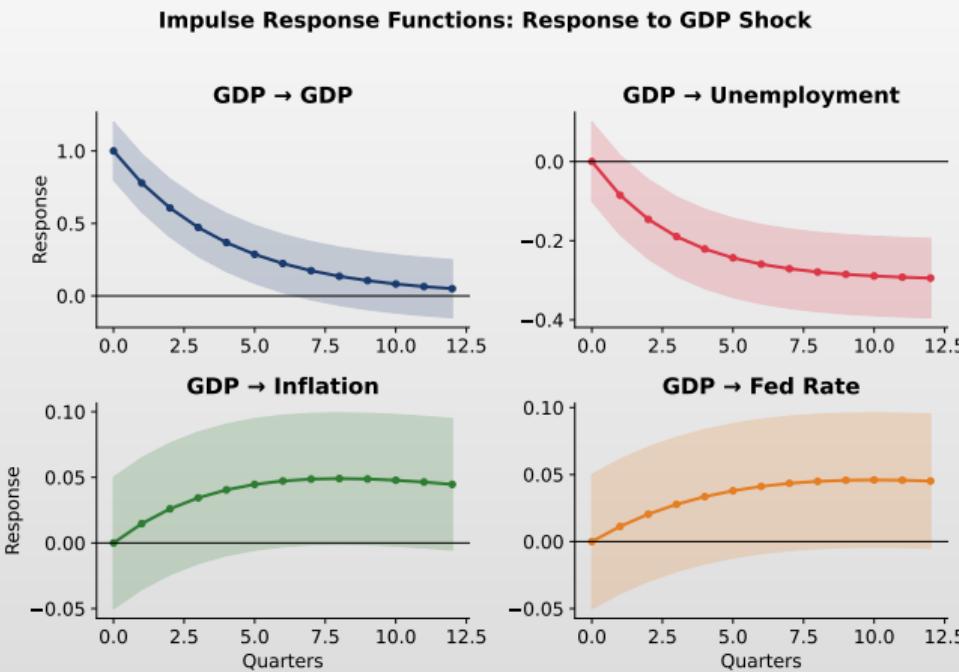
### Ce este Cauzalitatea Granger?

**X cauzează Granger Y** dacă X trecut îmbunătățește predicția lui Y dincolo de Y trecut singur.  
Atenție: “Cauzalitate Granger” ≠ cauzalitate reală!

### Concluzii Economice

- Șomaj  $\succ$  PIB ( $p = 0,045$ ): Legea Okun
- Fed  $\succ$  Inflație ( $p = 0,087$ ): Politica monetară funcționează

## Funcții de Răspuns la Impuls (IRF)



### Ce este IRF?

Arată cum un soc de 1 unitate la o variabilă afectează celelalte în timp.

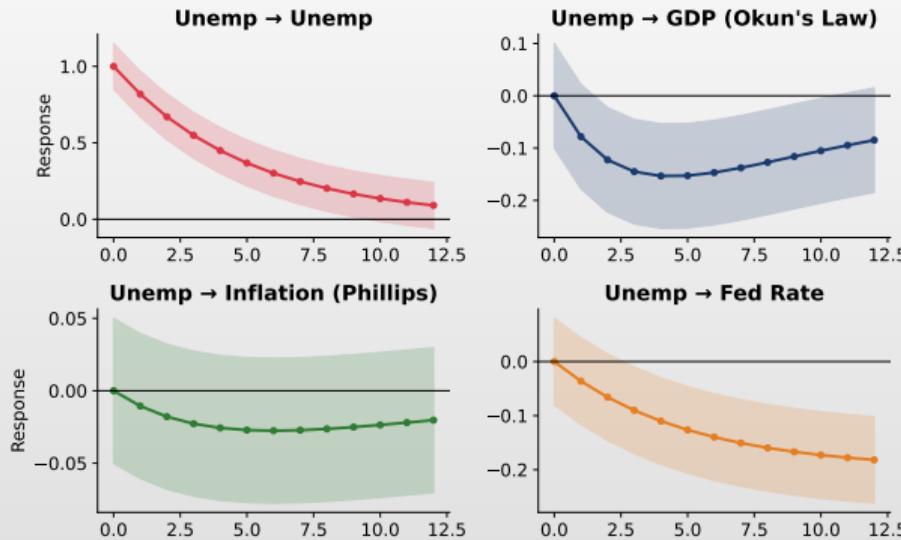
### Efectele Șocului PIB

- Şomaj ↓:** Legea Okun
- Inflație ↑:** Cerere-pull
- Rata Fed ↑:** Regula Taylor



## IRF: Șoc Șomaj

IRF: Response to Unemployment Shock (+1 std)

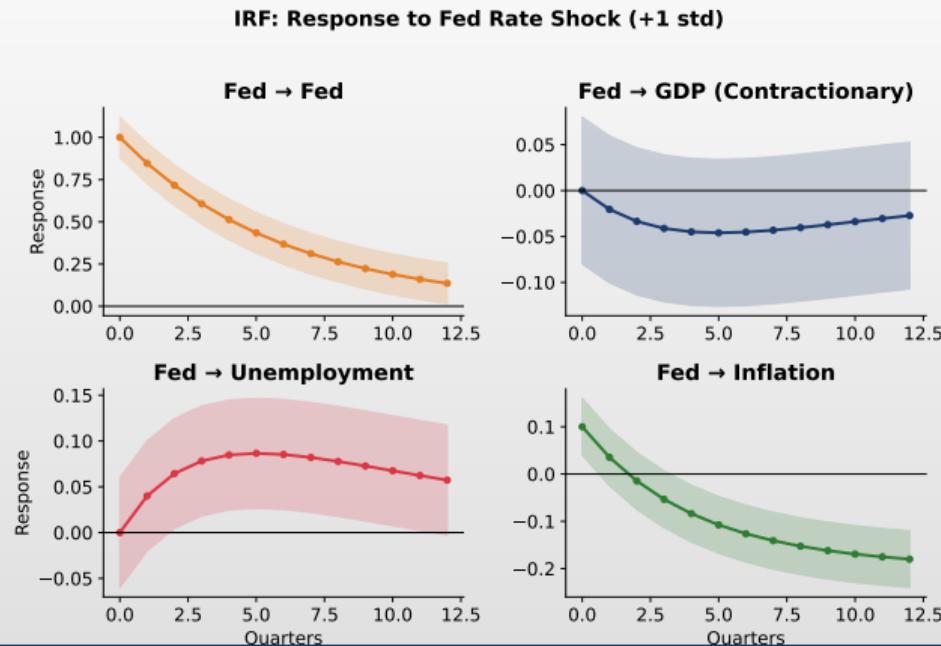


### Efecte

↑ Șomaj  $\Rightarrow$  ↓ PIB (Okun), ↓ Inflație (Phillips), Fed reduce rata.



## IRF: Șoc Rată Fed

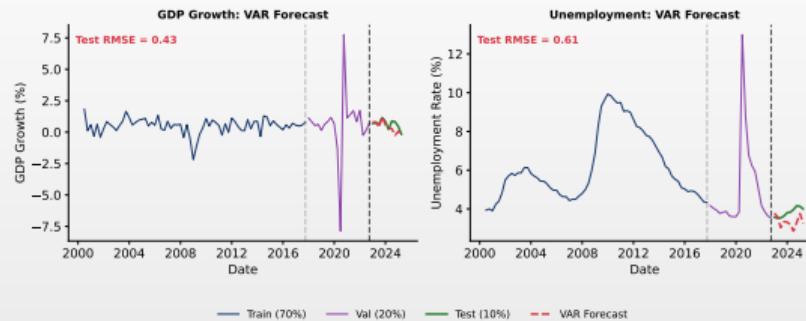


Politică Monetară

Crestere rată  $\Rightarrow$  PIB  $\downarrow$ , Șomaj  $\uparrow$ , Inflație  $\downarrow$ .

Analiza și Prognoza Seriilor de Timp

## VAR: Prognoză (Train/Val/Test)



### Prognoză Rolling One-Step-Ahead

VAR captează dinamică PIB-Şomaj. řocul COVID vizibil în perioadă test.



## VAR: Rezultate Set Test

### Performanță Set Test pe Variabile

Variabilă	RMSE	MAE	Acur. Directie
Creștere PIB	1,33	0,99	50%
Șomaj	0,64	0,52	50%
Inflație	1,56	1,12	60%
Rata Fed	2,59	2,45	80%
<b>Medie</b>	<b>1,53</b>	<b>1,27</b>	<b>60%</b>

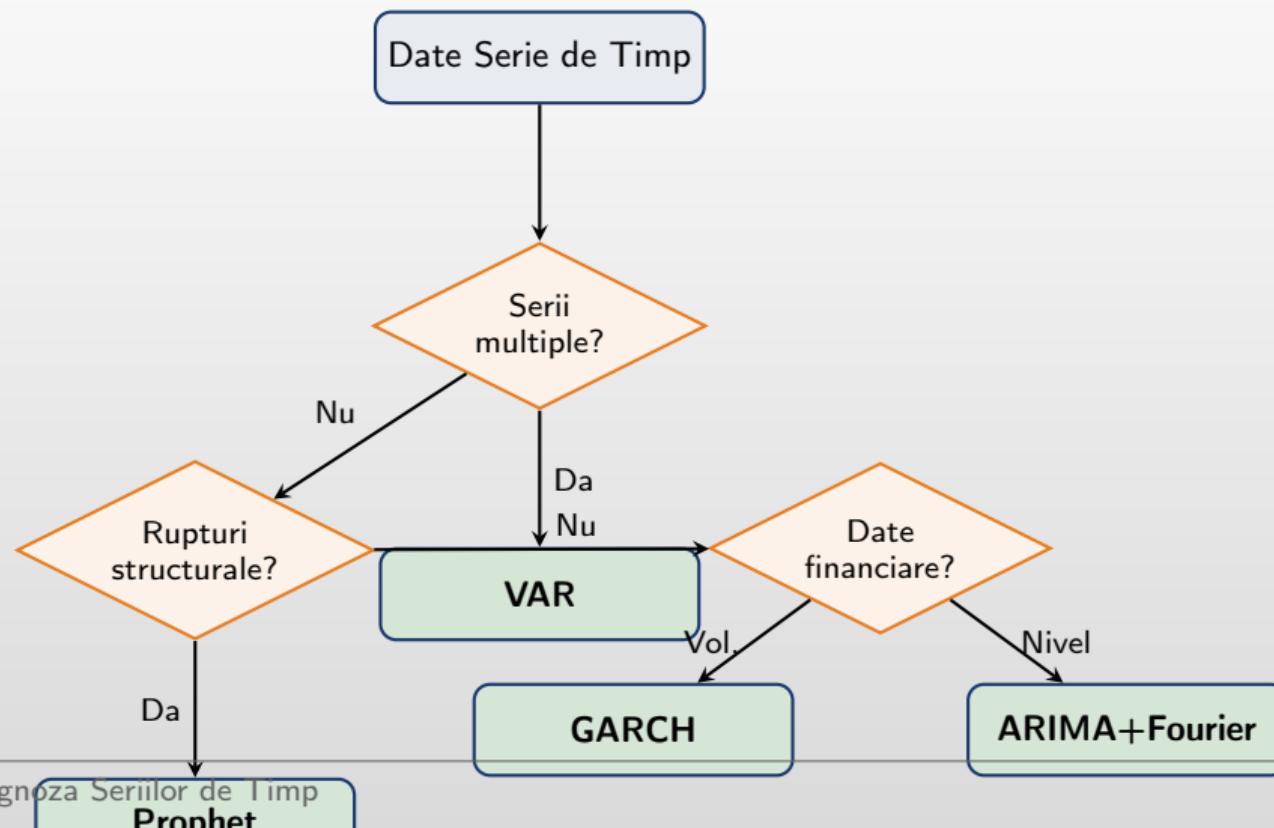
### Puncte Forte

- Captează dinamică între variabile
  - Acuratețe direcțională bună
  - Relații interpretabile
- Analiza și Prognoza Seriilor de Timp

### Limitări

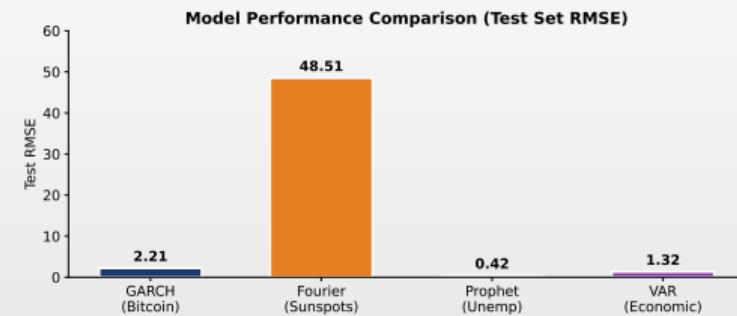
- Mulți parametri (blestemul dimensionalității)
- Sensibil la selectarea lag-ului
- Perioada COVID dificilă

## Cadrul de Selectare a Modelului



## Sumar: Comparație Modele

Caz	Provocare	Model	RMSE
Bitcoin	Volatilitate	GARCH	2,15
Pete solare	Sezonalitate	Fourier	31,10
Șomaj	Ruptură	SARIMA	0,12
Economic	Multi-var	VAR	1,53



### Principiu Cheie

Potriviti modelul cu caracteristicile datelor. Alegeti in functie de natura problemei si proprietatile datelor.



## Comparație Cuprinzătoare a Modelelor

Caracteristică	GARCH	Fourier	Prophet	VAR
<b>Tintă</b>	Volatilitate	Nivel	Nivel	Multiple
<b>Sezonalitate</b>	Nu	Da (lungă)	Da (multiplă)	Nu
<b>Rupturi structurale</b>	Nu	Nu	Da	Nu
<b>Serii multiple</b>	Nu	Nu	Nu	Da
<b>Interpretabil</b>	Mediu	Ridicat	Ridicat	Ridicat
<b>Parametri</b>	Puțini	2K	Auto	Mulți
<b>Date lipsă</b>	Nu	Nu	Da	Nu
<b>Ideal pentru</b>	Finanțe	Cicluri	Business	Macro

### Rezultatele Noastre

- GARCH: MAE=1,82 (volatilitate)
- Fourier: RMSE=31,10 (cycluri)
- SARIMA: RMSE=0,12 (rupturi)
- VAR: RMSE mediu=1,53 (multi)

### Insight Cheie

Fiecare model excelează în domeniul său. Arta constă în alegerea modelului potrivit caracteristicilor datelor.



## Bune Practici pentru Prognoză Aplicată

### Metodologie

1. Explorați datele temeinic
2. Testați staționaritatea
3. Împărțiți train/validation/test
4. Comparați modele pe validare
5. Raportați metrii pe test

### Sfaturi Practice

- Începeți simplu (random walk, naiv)
- Adăugați complexitate doar dacă e necesar
- Vizualizați programe vs. valori reale
- Verificați reziduurile pentru tipare
- Raportați intervale de încredere

### Greșeli Frecvente

- Privirea în datele de test
- Supraajustare pe setul de antrenament
- Ignorarea ipotezelor modelului
- Neraportarea incertitudinii

### Amintiți-vă

“Toate modelele sunt greșite, dar unele sunt utile.”

— George E. P. Box



## Concluzii Cheie

### 1. Metodologie Riguroasă

- ▶ Împărțirea train/validation/test previne supraajustarea
- ▶ Setul de test trebuie să rămână neatins până la evaluarea finală

### 2. Potriviri Modelul cu Datele

- ▶ Volatilitate finanțiară  $\succ$  GARCH
- ▶ Sezonalitate lungă  $\succ$  Termeni Fourier
- ▶ Rupturi structurale  $\succ$  Prophet
- ▶ Serii multiple  $\succ$  VAR

### 3. Interpretați Rezultatele cu Grijă

- ▶ Cauzalitate Granger  $\neq$  cauzalitate adeverată
- ▶ Performanța out-of-sample contează cel mai mult
- ▶ Modelele mai simple funcționează adesea mai bine



## Referințe

-  Box, G.E.P., Jenkins, G.M., Reinsel, G.C., & Ljung, G.M. (2015). *Time Series Analysis: Forecasting and Control*. Ed. 5, Wiley.
-  Hamilton, J.D. (1994). *Time Series Analysis*. Princeton University Press.
-  Tsay, R.S. (2010). *Analysis of Financial Time Series*. Ed. 3, Wiley.
-  Hyndman, R.J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. Ed. 3, OTexts.
-  Taylor, S.J., & Letham, B. (2018). Forecasting at Scale. *The American Statistician*, 72(1), 37-45.
-  Bollerslev, T. (1986). Generalized Autoregressive Conditional Heteroskedasticity. *Journal of Econometrics*, 31(3), 307-327.
-  Sims, C.A. (1980). Macroeconomics and Reality. *Econometrica*, 48(1), 1-48.

## Surse de Date

### Date Reale Folosite în Acest Capitol

- **Bitcoin:** Yahoo Finance (BTC-USD), 2019–2025
- **Pete Solare:** Dataset Wolfer din Statsmodels, 1900–2008
- **Șomaj SUA:** Federal Reserve FRED (UNRATE), 2010–2025
- **Variabile Economice:** FRED (GDPC1, UNRATE, CPIAUCSL, FEDFUNDS), 2000–2025

### Reproductibilitate

Toate analizele pot fi reproduse folosind notebook-ul Jupyter însoțitor:  
`chapter10_lecture_notebook.ipynb`



# Mulțumesc

Întrebări?

Prof. Daniel Traian Pele, PhD

[danpele@ase.ro](mailto:danpele@ase.ro)

Academia de Studii Economice din București