



Analiza și Prognoza Seriilor de Timp

Capitolul 10: Recapitulare Comprehensivă



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Obiective de învățare

La finalul acestui capitol, veți fi capabili să:

1. Aplicați fluxul complet de prognoză, de la date la evaluare
2. Selectați modelul potrivit în funcție de caracteristicile datelor
3. Evaluați acuratețea prognozelor folosind metrici și validare încrucișată
4. Integrați cunoștințele din toate capitolele anterioare în practică

Cuprins

Fundamente

- ▣ Metodologia Prognozei
- ▣ Studiu de Caz 1: Volatilitatea Bitcoin (GARCH)
- ▣ Studiu de Caz 2: Ciclurile Petelor Solare (Fourier)

Aplicații

- ▣ Studiu de Caz 3: Șomajul (Prophet)
- ▣ Studiu de Caz 4: Analiză Multivariată (VAR)
- ▣ Sinteză și Ghid
- ▣ Quiz

Abordarea științifică a prognozei

Întrebarea de cercetare

- Cum putem **evalua riguros** performanța prognozei evitând supraajustarea?

Problema fundamentală

- Ajustarea în eșantion \neq Performanța în afara eșantionului
- Modelele pot “memora” datele de antrenament fără a învăța tipare
- **Soluție:** Metodologia corectă train/validation/test

Principiu cheie

- “Setul de test trebuie să rămână **neatins** până la evaluarea finală.”
- Practică standard în machine learning și econometrie

Cadrul Train/Validation/Test

Time Series Train/Validation/Test Split



 TSA_ch10_train_val_test_split

Metrici de evaluare

Definiție 1 (Metrici ale Erorii de Prognoză)

▣ **Date:** Fie y_t valorile reale, \hat{y}_t prognozele

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_t (y_t - \hat{y}_t)^2}, \quad \text{MAE} = \frac{1}{n} \sum_t |y_t - \hat{y}_t|, \quad \text{MAPE} = \frac{100\%}{n} \sum_t \left| \frac{y_t - \hat{y}_t}{y_t} \right|$$

Când să folosim

- ▣ **RMSE** (Root Mean Square Error): Penalizează erorile mari
- ▣ **MAE** (Mean Absolute Error): Robust la outliers
- ▣ **MAPE** (Mean Absolute Percentage Error): Independent de scală (%)

Atenție

- ▣ MAPE nedefinit când $y_t = 0$
- ▣ Comparați pe **același** set test
- ▣ Raportați metrice **out-of-sample**

Evaluarea prognozelor dincolo de RMSE

Metrici alternative

- **MASE** (Mean Absolute Scaled Error): $\frac{MAE_{\text{model}}}{MAE_{\text{naïve}}}$; $< 1 \Rightarrow$ bate naïve
- **DA** (Directional Accuracy): $\frac{1}{h} \sum_{t=1}^h 1(\text{sgn } \Delta \hat{y}_t = \text{sgn } \Delta y_t)$
- **QL** (Quantile Loss): penalizare asimetrică α vs $1-\alpha$

$$QL_{\alpha} = \begin{cases} \alpha(y_t - \hat{q}_t), & y_t > \hat{q}_t \\ (1 - \alpha)(\hat{q}_t - y_t), & y_t \leq \hat{q}_t \end{cases}$$

- **CRPS** (Continuous Ranked Probability Score): $\int_{-\infty}^{\infty} (F(x) - 1_{x \geq y})^2 dx$

Evaluarea prognozelor: Rezultate Bitcoin

- Aplicăm GARCH (Generalized Autoregressive Conditional Heteroskedasticity) pentru prognoza volatilității Bitcoin

Rezultate Bitcoin (GARCH volatilitate)

| Metrică | Valoare |
|---------------|---------|
| RMSE | 2.21 |
| MAE | 1.89 |
| MASE | 0.98 |
| Dir. Accuracy | 28.7% |

- $MASE < 1$: GARCH bate naïve
- DA 28.7%: direcția volatilității e dificilă

Interpretare

- **RMSE/MAE**: eroarea absolută a prognozei volatilității
- **MASE** < 1 : modelul GARCH performează mai bine decât naïve
- **DA 28.7%**: direcția volatilității e extrem de dificil de prezis
- Evaluarea trebuie făcută pe **setul de test**

Compararea formală a prognozelor: Diebold–Mariano

Definiție 2 (Testul Diebold–Mariano)

Diferența de pierdere: $d_t = L(e_{1t}) - L(e_{2t})$, Statistica: $DM = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}(\bar{d})}} \xrightarrow{d} N(0, 1)$

Ipoteze

- H_0 : performanță predictivă egală
- H_1 : un model e semnificativ mai bun
- $|DM|$ mare \Rightarrow respingem H_0

Rezultat Bitcoin (GARCH volatilitate)

- Normal vs Student-t: $DM = -0.51$
- $p = 0.612$ — **nu respingem** H_0
- Acuratețe similară, dar Student-t preferabil prin AIC (Akaike Information Criterion) ($\Delta = 509$)


Mesaj cheie

- RMSE mai mic \neq diferență semnificativă — testarea formală este **obligatorie**

Bitcoin: volatility clustering

Observație

- Randamentele mari tind să urmeze randamente mari, cele mici urmează cele mici
- Acesta este **volatility clustering** \Rightarrow fenomenul pe care GARCH îl captează



Bitcoin: definirea problemei

Întrebarea de cercetare

- Putem prognoza **volatilitatea** Bitcoin folosind modele GARCH?

Caracteristicile Datelor

- Sursă: Yahoo Finance (BTC-USD)
- Perioadă: Ian 2019 – Ian 2025
- Frecvență: Zilnică
- Observații: ≈ 2.200 zile

Fapte stilizate

- Randamente: medie aproape zero
- Cozi groase (curtoză > 3)
- Clustering al volatilității

Analiza și Prognoza Seriilor de Timp


Insight cheie

- Randamentele financiare** sunt de obicei:
 - ▶ Impredictibile în medie
 - ▶ Predictibile în varianță
- \Rightarrow Focus pe **prognoza volatilității**

Bitcoin: dovezi pentru GARCH

Observație

- Randamentele pătrate r_t^2 prezintă autocorelație semnificativă \Rightarrow efecte GARCH
- ACF (Autocorrelation Function – Funcția de Autocorelație) cu descreștere lentă \Rightarrow persistență ridicată a volatilității



Specificarea modelului GARCH

Definiție 3 (Modelul GARCH(p,q))

▣ **Date:** Fie r_t randamentele. Modelul GARCH(p,q) este:

$$r_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \sim N(0, 1)$$

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$$

▣ **Condiții:** $\omega > 0$, $\alpha_i \geq 0$, $\beta_j \geq 0$, și $\sum_{i=1}^q \alpha_i + \sum_{j=1}^p \beta_j < 1$

Variante de model

- ▣ **GARCH(1,1):** Cel mai comun
- ▣ **GJR-GARCH** (Glosten-Jagannathan-Runkle):
Efect de levier
- ▣ **EGARCH** (Exponential GARCH): Șocuri

asimetric

Interpretare

- ▣ α : Impactul șocurilor trecute
- ▣ β : Persistența volatilității
- ▣ $\alpha + \beta \approx 1$: Persistență înaltă



GARCH: Staționaritate și varianța necondiționată

Teoremă 1 (Staționaritatea în Covarianță a GARCH(1,1))

Dacă $\alpha_1 + \beta_1 < 1$, atunci $\{\varepsilon_t\}$ este staționar în covarianță cu:

$$\bar{\sigma}^2 = \mathbb{E}[\sigma_t^2] = \frac{\omega}{1 - \alpha_1 - \beta_1}$$

Derivare

▣ Luăm speranța ambelor părți ale ecuației varianței:

$$\mathbb{E}[\sigma_t^2] = \omega + \alpha_1 \mathbb{E}[\varepsilon_{t-1}^2] + \beta_1 \mathbb{E}[\sigma_{t-1}^2]$$

$$\bar{\sigma}^2 = \omega + (\alpha_1 + \beta_1) \bar{\sigma}^2 \quad (\text{staționaritate})$$

$$\bar{\sigma}^2 = \frac{\omega}{1 - \alpha_1 - \beta_1}$$

Proгноzele multi-step converg la $\bar{\sigma}^2$

▣ Când $h \rightarrow \infty$: $\mathbb{E}_t[\sigma_{t+h}^2] \rightarrow \bar{\sigma}^2$ cu rata $(\alpha_1 + \beta_1)^h$

Bitcoin: selectarea modelului pe setul de validare

Metodologie

- Estimăm fiecare model pe **datele de antrenament**, evaluăm pe **setul de validare**
- Criterii: AIC, BIC (Bayesian Information Criterion) și MAE de validare

| Model | AIC | BIC | Val MAE | Selectare |
|----------------|---------|---------|---------|-------------|
| GARCH(1,1) | 6.994,8 | 7.020,6 | 2,638 | Cel mai bun |
| GARCH(2,1) | 6.993,7 | 7.024,6 | 2,640 | |
| GJR-GARCH(1,1) | 6.983,7 | 7.014,6 | 2,669 | |
| EGARCH(1,1) | — | — | — | Eșuat* |

*Proгноze analitice indisponibile pentru $h > 1$


Rezultat

- GARCH(1,1)** selectat pe baza celui mai mic MAE de validare pentru prognozele de volatilitate

Bitcoin: prognoza volatilității

Interpretare

- Zona umbrită: interval de încredere 95% al prognozei de volatilitate
- GARCH(1,1) captează bine dinamica volatilității Bitcoin



Bitcoin: împărțirea datelor și staționaritate

Împărțirea datelor

| Set | Perioadă | N |
|-------------------|-------------------|--------------|
| Antrenament (70%) | 2019-01 – 2023-03 | 1.543 |
| Validare (15%) | 2023-04 – 2024-02 | 333 |
| Test (15%) | 2024-03 – 2025-01 | 329 |
| Total | | 2.205 |

Teste de staționaritate (ADF – Augmented Dickey-Fuller)

| Serie | ADF | Rezultat |
|------------|------------|----------------|
| Prețuri | $p = 0.50$ | Non-staționară |
| Randamente | $p < 0.01$ | Staționară |

⇒ Modelăm **randamente**, nu prețuri


De ce contează staționaritatea

- **GARCH**: necesită input slab staționar
- **Prețuri vs Randamente**: prețuri = random walk, randamente = staționare



GARCH: prognozele multi-step converg

Insight cheie

- Prognozele multi-step converg la $\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta}$
- Soluția: prognoze rolling one-step-ahead



GARCH: soluția rolling one-step-ahead



 TSA_ch10_rolling_vs_multistep

GARCH: Distribuții pentru inovații

Model

$$r_t = \mu + \sigma_t Z_t$$

- ▣ Variante pentru z_t : $\mathcal{N}(0, 1)$ (normală) sau t_ν (cozi groase)

Bitcoin: dovezi empirice

- ▣ Curtoză reziduuri: **13.81** (Normal = 3)
- ▣ Skewness: -0.29
- ▣ Jarque-Bera: 9085, $p < 0.001$
- ▣ Normalitatea **subestimează** riscul extrem


Student-t: alegerea corectă

- ▣ $\hat{\nu} = 2.96$ grade de libertate
- ▣ AIC Normal: 9769 vs Student-t: **9260**
- ▣ $\Delta AIC = 509$ — dovadă **copleșitoare**
- ▣ Cozi groase = estimări VaR **mai realiste**

VaR și ES: ilustrație grafică

Interpretare


- VaR (Value at Risk – Valoarea la Risc) 1% = pierderea depășită doar în 1% din cazuri
- Zona roșie = pierderi extreme (dincolo de VaR)



VaR vs expected shortfall: normal vs Student-t

Interpretare

- ES (Expected Shortfall – Pierdere Așteptată) măsoară pierderea medie când VaR este depășit
- Student-t: VaR și ES mai mari decât sub distribuția normală



Value at Risk: exemplu numeric

Calculul VaR: Portofoliu 1M EUR, $\hat{\sigma}_{T+1} = 1.5\%$

| Nivel | z_{α} | VaR (%) | VaR (EUR) |
|--------------|-------------------------|---------|-----------|
| 5% (1 zi) | 1.645 | 2.47% | 24.675 |
| 1% (1 zi) | 2.326 | 3.49% | 34.890 |
| 1% (10 zile) | $2.326 \cdot \sqrt{10}$ | 11.03% | 110.314 |

Scalare pentru perioade mai lungi

$$\square \text{ VaR}_{h \text{ zile}} = \text{VaR}_{1 \text{ zi}} \cdot \sqrt{h} \quad (\text{presupune randamente i.i.d.})$$

Value at Risk: distribuție Student-t

De ce Student-t?

- ▣ Normala **subestimează** riscul de coadă; randamentele au **cozi groase** (curtoză > 3)
- ▣ Student-t capturează mai bine extremele

Comparație VaR 1% (1 zi) pentru $\sigma = 1.5\%$, portofoliu = 1M EUR

| Distribuție | Cuantilă | VaR (EUR) |
|--------------------------|----------|-----------|
| Normal | 2.326 | 34.890 |
| Student-t ($\nu = 10$) | 2.764 | 41.460 |
| Student-t ($\nu = 6$) | 3.143 | 47.145 |
| Student-t ($\nu = 4$) | 3.747 | 56.205 |

- ▣ Cu $\nu = 6$ (tipic pentru acțiuni), VaR este cu **35% mai mare** decât cel normal!

VaR: exemplu complet cu GARCH

Procedura de calcul VaR

1. Estimează modelul GARCH(1,1) cu distribuție Student-t
2. Obține prognoza volatilității: $\hat{\sigma}_{T+1}$
3. Calculează VaR: $\text{VaR}_{\alpha} = t_{\alpha}(\nu) \cdot \hat{\sigma}_{T+1}$

Exemplu: S&P 500

- ▣ Parametri estimați: $\alpha = 0.088$, $\beta = 0.900$, $\nu = 6.4$
- ▣ Volatilitate prognozată: $\hat{\sigma}_{T+1} = 1.2\%$, Portofoliu: 10.000.000 EUR
- ▣ **VaR 1% (1 zi):** $\text{VaR} = 3.05 \times 0.012 \times 10.000.000 = \mathbf{366.000 \text{ EUR}}$

Ce este VaR backtesting?

Definiție

- ▣ **Backtesting** = verificarea ex-post a calității modelului VaR
- ▣ Compară pierderile realizate cu pragul VaR prognozat
 - ▶ O **încălcare** (violation) apare când $r_t < -\text{VaR}_t$

Principiul Backtesting-ului

- ▣ Indicatorul de încălcare: $I_t = 1(r_t < -\text{VaR}_{\alpha,t})$
- ▣ Pentru un model corect la nivel α :
 - ▶ Frecvența: $\hat{p} = \frac{1}{T} \sum I_t \approx \alpha$; încălcări **independente**
- ▣ VaR 1% pe 250 zile \Rightarrow așteptăm ~ 2.5 încălcări/an

Importanță

- ▣ Cerință regulamentară **Basel III/IV** pentru bănci: backtesting obligatoriu

Testul Kupiec (1995): acoperire necondiționată

Ipoteze

- ▣ H_0 : Rata de încălcare este egală cu nivelul VaR ($p = \alpha$)
- ▣ H_1 : Rata de încălcare diferă de nivelul VaR ($p \neq \alpha$)

Statistica de test (Likelihood Ratio)

- ▣ **Formula:** $LR_{uc} = -2 \ln \left[\frac{\alpha^x (1-\alpha)^{T-x}}{\hat{p}^x (1-\hat{p})^{T-x}} \right] \sim \chi^2(1)$
- ▣ **Notăție:** x = nr. încălcări, T = nr. observații, $\hat{p} = x/T$

Exemplu

- ▣ VaR 1%, $T = 250$ zile, $x = 5$ încălcări: $\hat{p} = 2\%$
 - ▶ Prea multe încălcări \Rightarrow modelul **subestimează** riscul
- ▣ VaR 1%, $T = 250$ zile, $x = 1$ încălcare: $\hat{p} = 0.4\% \Rightarrow$ acceptabil

Testul Christoffersen (1998): acoperire condiționată

Motivație

- ▣ Kupiec testează doar **frecvența** încălcărilor
- ▣ Nu detectează **clusterizarea** încălcărilor (încălcări consecutive)
 - ▶ Dacă încălcările apar în clustere \Rightarrow modelul nu captează dinamica volatilității

Testul de independență + acoperire condiționată

- ▣ **Formula:** $LR_{cc} = LR_{uc} + LR_{ind} \sim \chi^2(2)$
- ▣ LR_{ind} : testează independența încălcărilor
- ▣ Un model bun: încălcări rare **și** distribuite uniform în timp


Recomandare

- ▣ Folosește **ambele** teste: Kupiec (frecvență) + Christoffersen (independență)

VaR backtesting: vizualizare

Interpretare

- ▣ Linia roșie: pragul VaR 1% estimat cu GARCH(1,1)
- ▣ Punctele roșii: 13 încălcări din 250 zile ($\hat{p} = 5.2\%$)
 - ▶ **Zonă roșie Basel** \Rightarrow modelul subestimează semnificativ riscul
 - ▶ Soluții: distribuție Student-t, model EGARCH, sau nivel VaR mai conservator



Backtesting VaR: semaforul Basel

Zonele de semaforizare Basel III/IV

| Zonă | Încălcări/250 zile | Interpretare | Penalizare |
|--------|--------------------|----------------------|-------------------|
| Verde | 0–4 | Model acceptabil | Fără penalizare |
| Galben | 5–9 | Necesită investigare | Factor k crește |
| Roșu | ≥ 10 | Model inadecvat | Penalizare maximă |


Exemplu practic

- Portofoliu cu VaR 1%: 250 zile de backtesting
- 3 încălcări \Rightarrow **Zonă verde** \Rightarrow model acceptabil
- 7 încălcări \Rightarrow **Zonă galbenă** \Rightarrow revizuire necesară
- 13 încălcări \Rightarrow **Zonă roșie** \Rightarrow model respins

Aplicație: VaR rolling pe multiple modele

Metodologie

- VaR rolling one-step-ahead: $\text{VaR}_{t+1}^{\alpha} = \mu + \hat{\sigma}_{t+1} \cdot z_{\alpha}$
- 4 modele comparate pe setul de test Bitcoin (329 zile, 2024)



VaR Backtesting: comparație modele

Rezultate Bitcoin — VaR 5% (T = 329 zile, așteptat: 16,4 încălcări)

| Model | Încălcări | Rată | Kupiec p | Chr. p | Concluzie |
|------------------|-----------|-------------|--------------|----------|-------------------------------|
| GARCH(1,1)-N | 12 | 3,6% | 0,238 | 1,000 | Prea conservator |
| GARCH(1,1)-t | 17 | 5,2% | 0,890 | 0,272 | \approx 5% target |
| GJR-GARCH(1,1)-t | 17 | 5,2% | 0,890 | 0,272 | $\gamma \approx 0$ (simetric) |
| Hist. Simulation | 16 | 4,9% | 0,909 | 0,216 | \approx 5% target |

Concluzii

- ▣ **Student-t**: acoperire perfectă ($5,2\% \approx 5\%$)
- ▣ Normal: prea conservator ($3,6\% < 5\%$)
- ▣ GJR \approx GARCH: levier absent pt. Bitcoin
- ▣ Toate trec Kupiec și Christoffersen


Lecții practice

- ▣ GARCH-t și HistSim: ambele $\approx 5\%$ target
- ▣ Simularea istorică: alternativă simplă și eficientă
- ▣ Testarea statistică formală (Kupiec, Christoffersen) este **obligatorie**

Aplicație: VaR 1% rolling pe multiple modele

Metodologie

- ▣ VaR rolling one-step-ahead la nivel $\alpha = 1\%$ (risc extrem)
- ▣ Aceleași 4 modele; așteptat: $T \times 0,01 = 3,3$ încălcări



VaR 1% Backtesting: comparație modele

Rezultate Bitcoin — VaR 1% ($T = 329$ zile, așteptat: 3,3 încălcări)

| Model | Încălcări | Rată | Kupiec p | Chr. p | Concluzie |
|------------------|-----------|------|--------------|----------|----------------------------|
| GARCH(1,1)-N | 1 | 0,3% | 0,137 | 1,000 | Acceptabil |
| GARCH(1,1)-t | 0 | 0,0% | 0,010 | 1,000 | Respins |
| GJR-GARCH(1,1)-t | 0 | 0,0% | 0,010 | 1,000 | Respins |
| Hist. Simulation | 4 | 1,2% | 0,704 | 1,000 | \approx 1% target |

Concluzii VaR 1%

- GARCH-t/GJR-t: 0 încălcări \Rightarrow Kupiec **respinge** ($p = 0,01$)
- Cozi Student-t prea groase ($\nu \approx 3$) \Rightarrow VaR 1% **prea conservator**
- **Hist. Simulation:** $1,2\% \approx 1\%$ — singurul model precis

Lecție: 5% vs 1%

- La 5%: GARCH-t și HistSim ambele excelente
- La 1%: GARCH-t **respins** (prea conservator)
- **Modelul optim depinde de nivelul α !**

Limitările GARCH și extensii moderne

Limitări

- Nu captează **jump-uri** (salturi bruște)
- Parametri constanți în timp
- Sensibil la distribuția aleasă
- Nu modelează **regimuri** diferite

Extensii

- **GJR-GARCH**: efect de levier
- **EGARCH**: șocuri asimetrice
- **Markov-Switching GARCH**: regimuri
- Volatilitate realizată (HAR – Heterogeneous Autoregressive)
- Hybrid GARCH + ML (Machine Learning)

Mesaj cheie

- GARCH este un **punct de plecare**, nu finalul modelării riscului

Bitcoin: Concluzii cheie

Sumar

1. **Randamentele sunt staționare**; prețurile nu
2. **GARCH(1,1)** depășește variantele mai complexe
3. **Persistență înaltă** ($\alpha + \beta = 0,93$)
4. Volatilitatea este **predictibilă** chiar când randamentele nu sunt

Implicații practice

- ▣ Managementul riscului: VaR, Expected Shortfall
- ▣ Evaluarea opțiunilor necesită prognoze de volatilitate
- ▣ Optimizarea portofoliului cu risc variabil în timp


Lecții metodologice

- ▣ Simplu > Complex (GARCH(1,1) vs variante)
- ▣ Student-t **esențial** ($\Delta AIC = 509$)
- ▣ Rolling one-step-ahead > multi-step
- ▣ Testarea formală (Diebold-Mariano) obligatorie

Pete solare: ciclul solar de 11 ani

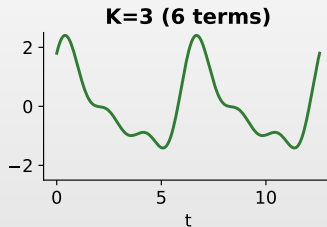
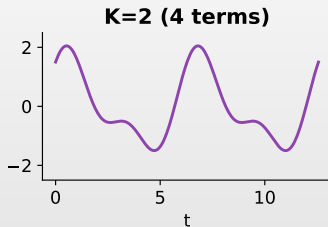

Observație

- Ciclu solar clar de ≈ 11 ani; amplitudine variabilă între cicluri
- ACF periodică \Rightarrow sezonabilitate lungă, ideală pentru termeni Fourier



Termeni Fourier pentru sezonabilitate

Fourier Terms: More K = More Flexibility



Pete solare: selectarea modelului

Metodologie

- **Comparație:** $K = 1, 2, 3, 4$ armonici Fourier pe setul de validare

Împărțirea Datelor

| Set | Perioadă | N |
|-------------------|-----------|------------|
| Antrenament (70%) | 1900–1975 | 76 |
| Validare (20%) | 1976–1997 | 22 |
| Test (10%) | 1998–2008 | 11 |
| Total | | 109 |

Comparație Modele

| K | AIC | Val RMSE | |
|---|-------|--------------|-------------|
| 1 | 665,9 | 87,15 | |
| 2 | 668,0 | 86,92 | |
| 3 | 671,8 | 86,81 | Cel mai bun |
| 4 | 674,5 | 87,93 | |

Rezultat

- $K = 3$ armonici Fourier selectate (6 parametri pentru ciclul de 11 ani)

Overfitting în alegerea lui K

Riscul de overfitting

- ▣ K prea mare = memorare ciclu istoric
- ▣ Modelul se potrivește pe zgomot, nu pe semnal
- ▣ Performanța pe test se **degradează**

Fourier \approx regresie periodică

- ▣ Fiecare armonic adaugă 2 parametri (sin, cos)
- ▣ $K = 3$: 6 parametri suplimentari
- ▣ $K = 6$: 12 parametri — risc supraajustare


Soluția: validare

- ▣ Selectăm K pe setul de **validare**
- ▣ Evaluăm pe **test** — neatins
- ▣ Trade-off: complexitate vs generalizare

La noi

- ▣ $K = 3$ minimizează Val RMSE
- ▣ $K = 4$ crește eroarea \Rightarrow overfitting

Pete solare: rezultate prognoză



Pete solare: concluzii cheie

Când să folosiți termeni Fourier

- Perioada sezonieră s este **lungă** (ex: 11 ani, 52 săptămâni)
- SARIMA (Seasonal ARIMA) ar necesita prea multe lag-uri sezoniere
- Tiparul este **neted și periodic**
- Trebuie capturate cicluri multiple

Alegerea lui K

- **Strategie:** Începeți cu $K = 1$, creșteți progresiv
 - ▶ Opriti când eroarea de validare nu mai scade
 - ▶ K prea mare = supraajustare

Fourier vs SARIMA

| | Fourier | SARIMA |
|----------------|---------|----------|
| Sezoane lungi | ✓ | × |
| Sezoane scurte | OK | ✓ |
| Parametri | $2K$ | Mulți |
| Flexibilitate | Fixă | Adaptivă |


Aplicații

- **Domenii:** Cicluri climatice, cicluri de afaceri, fenomene astronomice



Șomajul: Train / Validation / Test Split

Metodologie

- ▣ **Training (70%):** Estimare modele
- ▣ **Validare (20%):** Selecție model
- ▣ **Test (10%):** Evaluare finală







Șomajul: analiză preliminară



 TSA_ch10_unemployment_acf_pacf

Șomajul: teste de staționaritate



Rupturi structurale: abordare formală

Metode clasice

- **Chow Test**: ruptură la punct cunoscut
- **Bai–Perron**: rupturi multiple, necunoscute
- **CUSUM** (Cumulative Sum): detectare secvențială

Problemă

- ADF poate confunda **break** cu **unit root**
- Test Zivot–Andrews: ADF cu ruptură endogenă

Rezultat: Șomaj la COVID (martie 2020)

- Chow Test: $F = 21.73$, $p < 0.001$
- Ruptură structurală **confirmată**
- SARIMA: parametri constanți — risc
- Prophet: detectează changepoints automat


Mesaj cheie

- Modelul trebuie adaptat la **stabilitatea parametrilor**

Șomajul: selecția modelului (set validare)

Best: SARIMA(1,1,1)(1,0,0)₁₂

- Fit pe training (70%), evaluare pe validare (20%)
- Cel mai bun model selectat după Val RMSE minim



Șomajul: parametrii SARIMA

SARIMA(1,1,1)(1,0,0)₁₂ estimat pe Train+Val (2010–2023)

- ▣ AR(1): $\phi_1 = -0,86$
- ▣ MA(1): $\theta_1 = 0,78$
- ▣ SAR(12): $\Phi_1 = -0,08$ (n.s.)

SARIMA(1,1,1)(1,0,1) - Fitted on Train+Val (85%)

| Parameter | Coef | Std Err | P-value | Sig |
|-----------|---------|---------|---------|-----|
| ar.L1 | 0.8423 | 0.2084 | 0.0001 | *** |
| ma.L1 | -0.9540 | 0.1973 | 0.0000 | *** |
| ar.S.L12 | 0.0326 | 4.5951 | 0.9943 | |
| ma.S.L12 | -0.0113 | 4.6087 | 0.9980 | |
| sigma2 | 0.8122 | 0.0608 | 0.0000 | *** |

Testul Ljung-Box pentru autocorelația reziduurilor

Definiție 4 (Testul Ljung-Box)

Pentru reziduurile $\hat{\varepsilon}_t$ cu autocorelații eșantion $\hat{\rho}_k$, statistica de test:

$$Q(h) = n(n+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n-k} \stackrel{H_0}{\sim} \chi^2(h-p-q)$$


unde p, q sunt ordinele ARMA. H_0 : Reziduurile sunt zgomot alb.

Interpretare

- ▣ Q mare (p-value mic): Respingem H_0 , reziduurile au structură
- ▣ Q mic (p-value mare): Nu respingem H_0 , modelul este adecvat
- ▣ Regulă practică: $h = \min(10, n/5)$ pentru ordinul lag-ului

Șomajul: Diagnosticare SARIMA


SARIMA(1,1,1)(1,0,1) Diagnostics on Train+Val (85%) | Ljung-Box $p = 1.00$



Șomajul: prognoza rolling SARIMA

Problemă: Ruptura structurală

- Prognoză rolling one-step-ahead (re-estimare la fiecare t)
- **Test RMSE = 0,12**



Modelul Prophet

Definiție 5 (Descompunerea Prophet)

- **Model:** $y_t = g(t) + s(t) + h(t) + \varepsilon_t$, $\varepsilon_t \sim N(0, \sigma^2)$
- **Componente:** $g(t) = \text{trend}$, $s(t) = \text{sezonalitate}$, $h(t) = \text{sărbători}$

Detectare puncte de schimbare

- Selectare automată a locațiilor
- `changepoint_prior_scale` controlează flexibilitatea


Avantaje

- Gestionează date lipsă
- Componente interpretabile
- Robust la outliers

Șomajul: rezultate prognoză Prophet

Concluzie cheie

- **Prophet:** se adaptează prin detectare changepoint
- **Test RMSE** = 0,58



Șomajul: Ajustarea modelului

Ajustarea hiperparametrilor

- Ajustăm `changepoint_prior_scale` pe setul de validare

| Împărțirea Datelor | | |
|--------------------|-------------------|------------|
| Set | Perioadă | N |
| Antrenament (70%) | 2010-01 – 2020-06 | 126 |
| Validare (20%) | 2020-07 – 2023-06 | 36 |
| Test (10%) | 2023-07 – 2025-01 | 19 |
| Total | | 181 |


Comparație Scale

| Scale | Val RMSE | |
|-------------|-------------|-------------|
| 0,01 | 4,21 | |
| 0,05 | 3,89 | |
| 0,10 | 3,52 | Cel mai bun |
| 0,30 | 3,67 | |
| 0,50 | 3,81 | |

Interpretare

- Scale = 0,10 echilibrează flexibilitatea (captarea șocului COVID) cu stabilitatea

Șomaj: comparație SARIMA vs Prophet



Prophet: când să-l folosești

Cazuri de utilizare ideale

- Date de business cu **sărbători**
- **Valori lipsă** prezente
- Nevoie de componente **interpretabile**
- Prognoze cu **benzi de incertitudine**

Atenție: Rupturi structurale

- Prophet gestionează rupturile prin changepoints
- Dar **SARIMA** l-a depășit la șomaj (RMSE: 0,12 vs 0,58)
- Validați întotdeauna pe date out-of-sample!

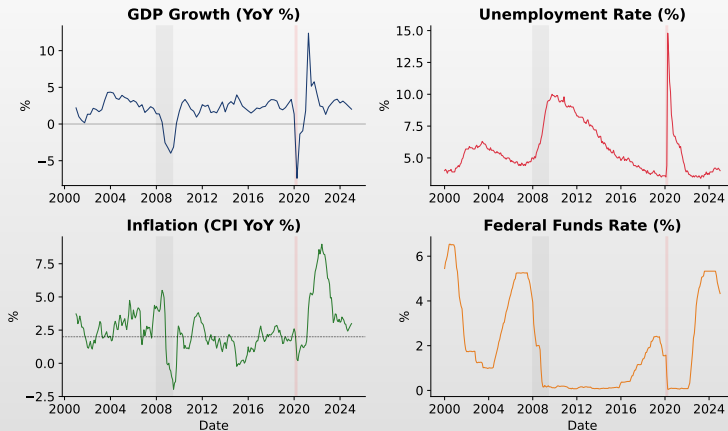
Prophet vs ARIMA (AutoRegressive Integrated Moving Average)

| | Prophet | ARIMA |
|---------------|---------|----------|
| Changepoints | ✓ | × |
| Date lipsă | ✓ | × |
| Sărbători | ✓ | × |
| Viteză | Rapidă | Moderată |
| Interpretabil | ✓ | × |

Parametri cheie

- `changepoint_prior_scale`: flexibilitate
- `seasonality_prior_scale`: netezime

VAR: date economice multivariate



Specificarea modelului VAR

Definiție 6 (VAR(p) – Vector Autoregression (Autoregresie Vectorială))

- **Date:** Pentru K variabile $y_t = (y_{1t}, \dots, y_{Kt})'$:
$$y_t = c + A_1 y_{t-1} + A_2 y_{t-2} + \dots + A_p y_{t-p} + u_t$$
- **Notăție:** A_i sunt matrici de coeficienți $K \times K$, $u_t \sim N(0, \Sigma)$

Pentru sistemul nostru cu 4 variabile

- **VAR(2):** 4 constante
- $2 \times 4 \times 4 = 32$ coeficienți AR
- **36 parametri total**

Selectarea lag-ului

- Folosim criterii informaționale:
 - ▶ AIC: Tinde să supraajusteze
 - ▶ BIC: Mai simplu
 - ▶ Cross-validare pe date păstrate

Criterii informaționale pentru selectarea modelului

Definiție 7 (Criteriile Informaționale Akaike și Bayesian)

Pentru un model cu log-verosimilitate \mathcal{L} , k parametri și n observații:

$$\text{AIC} = -2\mathcal{L} + 2k$$

$$\text{BIC} = -2\mathcal{L} + k \ln(n)$$

AIC

- Asimptotic eficient
- Poate supraajusta cu n mic
- Minimiza eroarea de predicție

BIC

- Consistent (găsește modelul adevărat)
- Penalizare mai mare: $\ln(n) > 2$ dacă $n \geq 8$
- Mai parcimonios

VAR: selectarea lag-ului și estimare

Criterii informaționale

| Lag | BIC | |
|-----|---------------|-------------|
| 1 | -4,810 | |
| 2 | -5,178 | Cel mai bun |
| 3 | -4,633 | |
| 4 | -4,614 | |

Împărțirea datelor

| Set | Perioadă | N |
|-------------------|-------------------|-----------|
| Antrenament (70%) | 2001-T1 – 2017-T4 | 67 |
| Validare (20%) | 2018-T1 – 2022-T4 | 20 |
| Test (10%) | 2023-T1 – 2025-T2 | 10 |
| Total | | 97 |

Verificare validare

- VAR(2) obține și cel mai mic RMSE de validare

Stabilitatea modelului VAR


Condiția de stabilitate

- ☐ Toate valorile proprii ale **matricei companion**:
 $|\lambda_i| < 1, \quad \forall i$

Rezultate VAR(2) — date economice

| | |
|----------------------------|--------------|
| $ \lambda_1 , \lambda_2 $ | 0.324 |
| $ \lambda_3 , \lambda_4 $ | 0.463 |
| $ \lambda_5 $ | 0.461 |
| $ \lambda_6 $ | 0.872 |
| $ \lambda_7 , \lambda_8 $ | 0.810 |

- ☐ $\text{Max } |\lambda| = 0.872 < 1$ — **stabil**



VAR vs VECM (Vector Error Correction Model): cointegrare

Problemă

- ▣ Dacă variabilele sunt $I(1) \Rightarrow$ VAR pe niveluri produce regresii spurioase

Definiție 8 (VECM)

$$\Delta y_t = \Pi y_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \Delta y_{t-i} + u_t, \quad \Pi = \alpha \beta'$$

Johansen Test — date economice

| r | Trace | CV 5% | Respins? |
|-----|--------------|-------|-----------|
| 0 | 64.09 | 47.85 | Da |
| 1 | 24.03 | 29.80 | Nu |
| 2 | 11.89 | 15.49 | Nu |
| 3 | 1.28 | 3.84 | Nu |

- ▣ **1 relație de cointegrare** găsită
- ▣ VECM e mai adecvat decât VAR pe niveluri

Mesaj cheie

- ▣ VAR pe diferențe: pierde relația pe termen lung; VECM: o păstrează prin $\Pi = \alpha \beta'$

Cauzalitatea Granger: Rezultate empirice

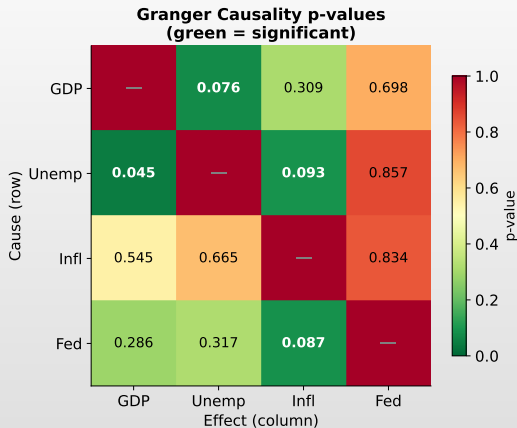
Interpretare

- ▣ Fiecare celulă arată p-value-ul testului Granger: rând → coloană
- ▣ Verde: $p < 0,10$ (semnificativ la 10%)

Concluzii economice

- ▣ Șomaj \succ PIB ($p = 0,045$): Legea lui Okun
- ▣ Fed \succ Inflație ($p = 0,087$): Transmisia politicii monetare
- ▣ PIB \succ Șomaj: Dovezi slabe

Cauzalitatea Granger: heatmap p -values



Cauzalitatea Granger: Definiție formală

Definiție 9 (Cauzalitatea Granger)

X **Granger-cauzează** Y dacă, pentru un $h > 0$:

$$\mathbb{E} \left[(Y_{t+h} - \mathbb{E}[Y_{t+h} | \mathcal{F}_t^{X,Y}])^2 \right] < \mathbb{E} \left[(Y_{t+h} - \mathbb{E}[Y_{t+h} | \mathcal{F}_t^Y])^2 \right]$$

unde $\mathcal{F}_t^{X,Y}$ include valorile trecute ale lui X și Y , iar \mathcal{F}_t^Y include doar trecutul lui Y .

Observație importantă

- ▣ Cauzalitatea Granger = **cauzalitate predictivă**, nu cauzalitate reală
- ▣ “ X Granger-cauzează Y ” \Rightarrow X conține informație utilă pentru prognoza lui Y
- ▣ **Nu** implică faptul că X cauzează Y în sens structural


Procedura de testare

- ▣ Testul F (sau Wald): H_0 : coeficienții lag-urilor lui X sunt simultan zero în ecuația lui Y
- ▣ **Respingem $H_0 \Rightarrow X$ Granger-cauzează Y**

Funcții de răspuns la impuls – IRF (Impulse Response Functions)

Efecte

□ \uparrow PIB \Rightarrow \downarrow Șomaj (Okun), \uparrow Inflație (cerere), Fed crește rata




 TSA_ch10_irf_gdp_shock

IRF: șoc șomaj

Efecte

□ ↑ Șomaj \Rightarrow ↓ PIB (Okun), ↓ Inflație (Phillips), Fed reduce rata




TSA_ch10_irf_unemp_shock

IRF: șoc rată Fed

Politică monetară

Creștere rată \Rightarrow PIB \downarrow , Șomaj \uparrow , Inflație \downarrow




TSA_ch10_irf_fed_shock

VAR: Prognoza (Train/Val/Test)

Prognoză Rolling one-step-ahead

- VAR captează dinamică PIB-Şomaj
- Şocul COVID vizibil în perioadă validare (2020)



VAR: rezultate set test

Performanță set Test pe variabile

| Variabilă | RMSE | MAE | Acur. Direcție |
|--------------|-------------|-------------|----------------|
| Creștere PIB | 1,33 | 0,99 | 50% |
| Șomaj | 0,64 | 0,52 | 50% |
| Inflație | 1,56 | 1,12 | 60% |
| Rata Fed | 2,59 | 2,45 | 80% |
| Medie | 1,53 | 1,27 | 60% |


Puncte forte

- Captează dinamică între variabile
- Acuratețe direcțională bună
- Relații interpretabile

Limitări

- Mulți parametri (blestemul dimensionalității)
- Sensibil la selectarea lag-ului
- Perioada COVID dificilă

Cadrul de selectare a modelului



Sinteză: Comparația modelelor

| Caracteristică | GARCH | Fourier | Prophet | VAR |
|---------------------|--------------|------------|---------------|----------|
| Țintă | Volatilitate | Nivel | Nivel | Multiple |
| Sezonalitate | Nu | Da (lungă) | Da (multiplă) | Nu |
| Rupturi structurale | Nu | Nu | Da | Nu |
| Serii multiple | Nu | Nu | Nu | Da |
| Interpretabil | Mediu | Ridicat | Ridicat | Ridicat |
| Parametri | Puțini | 2K | Auto | Mulți |
| Date lipsă | Nu | Nu | Da | Nu |
| Ideal pentru | Finanțe | Cicluri | Business | Macro |

Concluzii empirice

- ▣ **GARCH**: Student-t > Normal ($\Delta AIC = 509$)
- ▣ **Fourier**: $K = 3$ armonici, validat pe set de validare
- ▣ **Prophet**: adaptare la rupturi via changepoints
- ▣ **VAR**: interacțiuni macro semnificative (Granger)

Insight cheie

- ▣ RMSE nu se compară între seturi de date diferite!
- ▣ Fiecare model excelează în domeniul său
- ▣ Alegerea: potrivirea model \leftrightarrow date

Bune practici pentru prognoza aplicată

Metodologie

1. **Explorați** datele temeinic
2. **Testați** staționaritatea
3. **Împărțiți** train/validation/test
4. **Comparați** modele pe validare
5. **Raportați** metrice pe test

Greșeli frecvente

- Privirea în datele de test
- Supraajustare pe setul de antrenament
- Ignorarea ipotezelor modelului
- Neraportarea incertitudinii

Sfaturi practice

- Începeți simplu (random walk, naiv)
- Adăugați complexitate doar dacă e necesar
- Vizualizați prognoze vs. valori reale
- Verificați reziduurile pentru tipare
- Raportați intervale de încredere

Amintiți-vă

- “Toate modelele sunt greșite, dar unele sunt utile.”
— George E. P. Box

Prognoză vs Cauzalitate vs Decizie

| Obiectiv | Model | Focalizare |
|---------------------|------------------------------|---------------------------|
| Predicție pură | ARIMA / ML | Acuratețe out-of-sample |
| Risc financiar | GARCH | Volatilitate, VaR |
| Dinamici macro | VAR | Interacțiuni multivariate |
| Relații structurale | SVAR (Structural VAR) / VECM | Identificare cauzală |
| Regimuri | Markov Switching | Schimbări de regim |

Mesaj cheie

- Nu există model universal
- Există **potrivire între model și problemă**

Concluzii cheie

1. Metodologie Riguroasă

- ▶ Împărțirea train/validation/test previne supraajustarea
- ▶ Setul de test trebuie să rămână neatins până la evaluarea finală

2. Potrivești Modelul cu Datele

- ▶ Volatilitate financiară \Rightarrow GARCH
- ▶ Sezonalitate lungă \Rightarrow Termeni Fourier
- ▶ Rupturi structurale \Rightarrow Prophet
- ▶ Serii multiple \Rightarrow VAR

3. Interpretați Rezultatele cu Grijă

- ▶ Cauzalitate Granger \neq cauzalitate adevărată
- ▶ Performanța out-of-sample contează cel mai mult
- ▶ Modelele mai simple funcționează adesea mai bine

Rolul AI în modelarea seriilor de timp

AI poate

- ▣ Genera cod pentru estimare și prognoză
- ▣ Selecta modele (AutoML, grid search)
- ▣ Combina prognoze (ensemble)
- ▣ Detecta anomalii și pattern-uri

Dar nu poate

- ▣ Înlocui validarea statistică
- ▣ Detecta automat **data leakage**
- ▣ Garanta interpretare economică corectă
- ▣ Verifica ipotezele modelului

Principiu

- ▣ AI este **instrument**, nu autoritate
- ▣ Validarea statistică rămâne responsabilitatea cercetătorului

Exercițiu AI: Gândire critică

Prompt de testat în ChatGPT / Claude / Copilot

“Descarcă de pe FRED vânzările lunare cu amănuntul din SUA (seria RSXFS) din 2010-01 până în 2024-12 (180 observații). Fă o analiză completă a seriei de timp: descompunere, teste de staționaritate, selecție model (compară ETS, SARIMA și Prophet), prognoză pe 12 luni, evaluare cu RMSE/MAE/MASE pe un split temporal 70/15/15. Vreau cod Python de calitate publicabilă.”

Exercițiu

1. Rulați prompt-ul într-un LLM (Large Language Model) la alegere și analizați critic răspunsul.
2. Urmează fluxul corect? (grafic → descompunere → test → model → diagnostic → prognoză)
3. Compară mai multe modele (ETS – Error, Trend, Seasonality; ARIMA; SARIMA) cu benchmark-uri adecvate?
4. Împărțirea train/test este făcută corect? Există scurgeri de date (data leakage)?
5. Discută limitările și ipotezele modelului ales?

Atenție

- Codul generat de AI poate rula fără erori și arăta profesional
- *Asta nu înseamnă că e corect*

Întrebarea 1


Întrebare

☐ Ce model alegeți pentru a prognoza volatilitatea randamentelor financiare?

Variante de răspuns

- (A) ARIMA — captează tendințe și autocorelații
- (B) GARCH — modelează varianța condiționată
- (C) Prophet — detectează puncte de schimbare
- (D) VAR — model multivariat pentru interdependențe

Întrebarea 1: Răspuns



Răspuns: (B)

- ☐ GARCH captează volatility clustering și riscul variabil în timp
- ☐ ARIMA modelează nivelul, Prophet sezonality, VAR relațiile între serii
- ☐ Niciunul dintre celelalte nu modelează varianța direct

Întrebarea 2


Întrebare

- ☐ Un model SARIMA obține $RMSE = 0,05$ pe antrenament, dar $RMSE = 2,30$ pe test. Ce indică aceasta?

Variante de răspuns

- (A) Modelul este excelent — eroare mică pe antrenament
- (B) Modelul suferă de overfitting — memorează zgomotul
- (C) Setul de test este greșit — trebuie schimbat
- (D) Diferența este normală — nu e nicio problemă

Întrebarea 2: Răspuns



Răspuns: (B)

- Raport de $46\times$ între RMSE test și train \Rightarrow overfitting sever
- Modelul se potrivește zgomotului din antrenament și nu generalizează
- Soluție: model mai simplu, validare pe set separat

Întrebarea 3


Întrebare

☐ De ce este importantă separarea datelor în train/validation/test?

Variante de răspuns

- (A) Pentru a avea mai multe date de antrenament
- (B) Pentru a preveni supraajustarea și a evalua corect
- (C) Este doar o convenție, nu are importanță reală
- (D) Pentru a reduce timpul de calcul

Întrebarea 3: Răspuns



Răspuns: (B)

- **Train:** estimează parametrii; **Validare:** selectează modelul; **Test:** evaluare finală nebiasată
- Amestecarea acestor roluri duce la estimări optimiste ale performanței

Întrebarea 4

Întrebare


☐ Cauzalitatea Granger este echivalentă cu cauzalitatea reală (structurală)?

Variante de răspuns


- (A) Da — dacă X prezice Y , atunci X cauzează Y
- (B) Nu — testează doar conținut predictiv, nu cauzalitate
- (C) Depinde de numărul de lag-uri selectate
- (D) Da, dacă $p\text{-value} < 0,05$

Întrebarea 4: Răspuns

Granger Causality \neq True Causality



True Causal Structure



Răspuns: (B)

- Testul Granger verifică dacă trecutul lui X îmbunătățește predicția lui Y
- Corelații false (ex: vânzări de înghețată și înecuri) pot trece testul din cauza cauzelor comune

Întrebarea 5

Întrebare

▣ Ce model folosiți pentru o serie cu sezonalitate lungă (ex: $s = 365$ zile)?

Variante de răspuns

(A) $\text{SARIMA}(p, d, q)(P, D, Q)_{365}$


(B) GARCH — modelează variația

(C) ARIMA + Termeni Fourier sau Prophet/TBATS (Trigonometric, Box-Cox, ARMA, Trend, Seasonal)

(D) VAR cu 365 lag-uri

Întrebarea 5: Răspuns

Long Seasonality ($s = 365$): Fourier Terms vs SARIMA



Răspuns: (C)

- SARIMA₃₆₅ necesită polinoame lag de ordin 365 — imposibil de estimat
- Termenii Fourier cu $K = 3$ folosesc doar 6 parametri (sin/cos)
- Prophet și TBATS gestionează sezonalități multiple automat

Bibliografie I

Manuale fundamentale (referințe comune tuturor capitolelor)

- ▣ Hamilton, J.D. (1994). *Time Series Analysis*, Princeton University Press.
- ▣ Hyndman, R.J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*, 3rd ed., OTexts.
- ▣ Shumway, R.H., & Stoffer, D.S. (2017). *Time Series Analysis and Its Applications*, 4th ed., Springer.

Lucrări de referință pe domenii

- ▣ Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed., Wiley. (GARCH, VAR)
- ▣ Lütkepohl, H. (2005). *New Introduction to Multiple Time Series Analysis*, Springer. (VAR, VECM)
- ▣ Francq, C., & Zakoïan, J.-M. (2019). *GARCH Models*, 2nd ed., Wiley. (Volatilitate)

Bibliografie II

Abordări moderne și competiții de prognoză

- ▣ Petropoulos, F., et al. (2022). Forecasting: Theory and Practice, *International Journal of Forecasting*, 38(3), 845–1054.
- ▣ Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition, *International Journal of Forecasting*, 36(1), 54–74.
- ▣ Taylor, S.J., & Letham, B. (2018). Forecasting at Scale, *The American Statistician*, 72(1), 37–45.

Resurse online și cod

- ▣ **Quantlet:** <https://quantlet.com> > Platformă de cod pentru metode cantitative
- ▣ **Quantinar:** <https://quantinar.com> > Platformă de învățare pentru metode cantitative
- ▣ **GitHub TSA:** https://github.com/QuantLet/TSA/tree/main/TSA_ch10 > Cod Python pentru acest capitol

Vă Mulțumim!

Întrebări?

Materialele cursului sunt disponibile la: <https://danpele.github.io/Time-Series-Analysis/>

 Quantlet

 Quantinar