



Serii de timp

Seminarul 0: Introducere: componente și netezire exponențială



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material

- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ CV: Cross-Validation (validare încrucișată)
- ▣ LLM: Large Language Model (model lingvistic de mari dimensiuni)
- ▣ MA: Moving Average (medie mobilă)
- ▣ MA-5: 5-period Moving Average (medie mobilă pe 5 perioade)
- ▣ MAE: Mean Absolute Error (eroarea absolută medie)
- ▣ MAPE: Mean Absolute Percentage Error (eroarea procentuală absolută medie)
- ▣ MSE: Mean Squared Error (eroarea pătratică medie)
- ▣ RMSE: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ SES: Simple Exponential Smoothing (netezire exponențială simplă)

Cuprins Seminar

- ▣ **Test grilă** – Verificare cunoștințe
- ▣ **Adevărat/Fals** – Verificări conceptuale
- ▣ **Exerciții de calcul** – Practică aplicată
- ▣ **Exercițiu cu asistență AI** – Gândire critică
- ▣ **Rezumat** – Concluzii cheie

Quiz 1: Bazele seriilor de timp

Întrebare

Care dintre următoarele *nu* este o caracteristică a datelor de tip serie de timp?

Variante de răspuns

- (A) Observațiile sunt ordonate în timp
- (B) Observațiile consecutive sunt de obicei corelate
- (C) Observațiile sunt independente și identic distribuite
- (D) Datele au o ordonare temporală naturală

Răspunsul pe slide-ul următor...

Quiz 1: Răspuns

Răspuns: C – Observațiile sunt independente și identic distribuite

▣ Întrebare: Care *nu* este o caracteristică a datelor de tip serie de timp?

Variante de răspuns

- (A) Observațiile sunt ordonate în timp ✗
- (B) Observațiile consecutive sunt de obicei corelate ✗
- (C) **Observațiile sunt independente și identic distribuite** ✓
- (D) Datele au o ordonare temporală naturală ✗

- ▣ Observațiile seriilor de timp sunt **dependente** (autocorelate), nu independente
- ▣ Ipoteza i.i.d. este fundamentală pentru analiza transversală, dar este **încălcată** în seriile de timp
- ▣ Această dependență temporală necesită **metode specializate**

Quiz 2: Descompunere

Întrebare

Când ar trebui să folosiți descompunerea multiplicativă în loc de cea aditivă?

Variante de răspuns

- (A) Când tiparul sezonier are amplitudine constantă
- (B) Când varianța seriei este stabilă în timp
- (C) Când fluctuațiile sezoniere cresc proporțional cu nivelul
- (D) Când seria nu are componentă de trend


Răspunsul pe slide-ul următor...

Quiz 2: Răspuns

Răspuns: C – Când fluctuațiile sezoniere cresc proporțional cu nivelul

Variante de răspuns

- (A) Când tiparul sezonier are amplitudine constantă ✗
- (B) Când varianța seriei este stabilă în timp ✗
- (C) Când fluctuațiile sezoniere cresc proporțional cu nivelul ✓
- (D) Când seria nu are componentă de trend ✗



- ▣ **Multiplicativă:** $X_t = T_t \times S_t \times \varepsilon_t$ — amplitudinea sezonieră scalează cu nivelul
- ▣ **Aditivă:** $X_t = T_t + S_t + \varepsilon_t$ — amplitudine constantă

Quiz 3: Netezire exponențială

Întrebare

În Netezirea exponențială Simplă cu $\alpha = 0.9$, ce se întâmplă?

Variante de răspuns

- (A) Prognozele sunt foarte netede și stabile
- (B) Observațiile recente au foarte puțină pondere
- (C) Prognozele reacționează rapid la schimbările recente
- (D) Prognoza este în esență o medie pe termen lung

Răspunsul pe slide-ul următor...

Quiz 3: Răspuns

Răspuns: C – Prognozele reacționează rapid la schimbările recente

Variante de răspuns

- (A) Prognozele sunt foarte netede și stabile ✗
- (B) Observațiile recente au foarte puțină pondere ✗
- (C) **Prognozele reacționează rapid la schimbările recente** ✓
- (D) Prognoza este în esență o medie pe termen lung ✗

- ☐ Cu $\alpha = 0.9$: $\hat{X}_{t+1} = 0.9X_t + 0.1\hat{X}_t$
- ☐ α **mare** (ex. 0.9): 90% pondere pe ultima observație
 - ▶ Prognoze foarte receptive la date noi
- ☐ α **mic** (ex. 0.1): prognoze mai netede, mai stabile
 - ▶ la în calcul mai multe observații din trecut

Quiz 4: Medii mobile

Întrebare

Ce observații folosește o medie mobilă centrată de ordin 5 (MA-5) pentru a estima trendul la momentul t ?

Variante de răspuns

- (A) $X_t, X_{t+1}, X_{t+2}, X_{t+3}, X_{t+4}$
- (B) $X_{t-4}, X_{t-3}, X_{t-2}, X_{t-1}, X_t$
- (C) $X_{t-2}, X_{t-1}, X_t, X_{t+1}, X_{t+2}$
- (D) X_{t-1}, X_t, X_{t+1}


Răspunsul pe slide-ul următor...

Quiz 4: Răspuns

Răspuns: C – $X_{t-2}, X_{t-1}, X_t, X_{t+1}, X_{t+2}$

Variante de răspuns

- (A) $X_t, X_{t+1}, X_{t+2}, X_{t+3}, X_{t+4}$ ✗
(B) $X_{t-4}, X_{t-3}, X_{t-2}, X_{t-1}, X_t$ ✗
(C) $X_{t-2}, X_{t-1}, X_t, X_{t+1}, X_{t+2}$ ✓
(D) X_{t-1}, X_t, X_{t+1} ✗



- **MA centrată:** folosește $(k - 1)/2$ observații de fiecare parte a lui t
- **MA-5:** 2 înainte + t + 2 după $\Rightarrow$ fereastră mai mare = mai neted

Quiz 5: Evaluarea prognozei

Întrebare

Care metrică este cea mai potrivită pentru compararea acurateții prognozei între serii cu scale diferite?

Variante de răspuns

- (A) Eroarea Absolută Medie (MAE)
- (B) Rădăcina Erorii Medii Pătratică (RMSE)
- (C) Eroarea Absolută Medie Procentuală (MAPE)
- (D) Eroarea Medie Pătratică (MSE)

Răspunsul pe slide-ul următor...

Quiz 5: Răspuns

Răspuns: C – Eroarea Absolută Medie Procentuală (MAPE)

Variante de răspuns

- (A) Eroarea Absolută Medie (MAE) ✗
- (B) Rădăcina Erorii Medii Pătratice (RMSE) ✗
- (C) **Eroarea Absolută Medie Procentuală (MAPE)** ✓
- (D) Eroarea Medie Pătratică (MSE) ✗

- $MAPE = \frac{100}{n} \sum \left| \frac{e_t}{X_t} \right|$ exprimă erorile ca **procente**
- MAE, RMSE, MSE sunt **dependente de scală** (unități ale lui X_t)
- MAPE este **independentă de scală** (întotdeauna în %)
- Atenție: MAPE devine instabilă când $X_t \approx 0$



Quiz 6: Validare încrucișată

Întrebare

De ce nu putem folosi validarea încrucișată standard k-fold pentru seriile de timp?

Variante de răspuns

- (A) Datele seriilor de timp sunt prea mici
- (B) Ar încălca ordonarea temporală (viitorul prezicând trecutul)
- (C) Validarea încrucișată este întotdeauna invalidă
- (D) Seriile de timp nu au nevoie de validare


Răspunsul pe slide-ul următor...

Quiz 6: Răspuns

Răspuns: B – Ar încălca ordonarea temporală


Variante de răspuns

- (A) Datele seriilor de timp sunt prea mici ✗
- (B) **Ar încălca ordonarea temporală (viitorul prezicând trecutul) ✓**
- (C) Validarea încrucișată este întotdeauna invalidă ✗
- (D) Seriile de timp nu au nevoie de validare ✗



- ☐ **Principiu:** datele viitoare nu pot fi folosite pentru a prezice trecutul. Se recomandă CV cu fereastră mobilă/în expansiune.

Vizual: Descompunerea seriei de timp



Componentele descompunerii

☐ **Trend:** mișcare pe termen lung **Sezonalitate:** tipar periodic **Reziduu:** zgomot aleatoriu

Adevărat sau Fals? — Întrebări

Afirmație	A/F?
1. Prognozele SES sunt plate (constante pentru toate orizonturile).	?
2. RMSE penalizează erorile mari mai mult decât MAE.	?
3. Descompunerea multiplicativă necesită date pozitive.	?
4. Un α mai mare înseamnă mai multă netezire.	?
5. Setul de test se folosește pentru ajustarea hiperparametrilor.	?
6. Naive sezonier folosește valoarea de acum un sezon.	?
7. MAPE poate fi infinit dacă valorile reale sunt zero.	?

Adevărat sau Fals? — Răspunsuri

Afirmație	A/F	Explicație
1. Prognozele SES sunt plate (constante pentru toate orizonturile).	A	Fără trend
2. RMSE penalizează erorile mari mai mult decât MAE.	A	Erori pătratice
3. Descompunerea multiplicativă necesită date pozitive.	A	Nu se poate aplica pe valori negative α mare = mai puțin neted
4. Un α mai mare înseamnă mai multă netezire.	F	
5. Setul de test se folosește pentru ajustarea hiperparametrilor.	F	Folosiți validare.
6. Naive sezonier folosește valoarea de acum un sezon.	A	$\hat{X}_{t+h} = X_{t+h-m}$
7. MAPE poate fi infinit dacă valorile reale sunt zero.	A	Împărțire la zero

Exercițiu 1: Netezire Exponențială Simplă

Problemă

- ▣ **Date:** $X = [10, 12, 11, 14, 13]$ cu $\alpha = 0.3$, $\hat{X}_1 = 10$
- ▣ **Calculați:** a) Prognozele $\hat{X}_2$ până la $\hat{X}_6$; b) MAE și RMSE
- ▣ **Formula:** $\hat{X}_{t+1} = \alpha X_t + (1 - \alpha)\hat{X}_t$

Soluție

t	1	2	3	4	5	6
X_t	10	12	11	14	13	?
$\hat{X}_t$	10	10	10.6	10.72	11.70	12.09

- ▣ **MAE** = 1.745 **RMSE** = 2.04

Exercițiu 2: Metrici de eroare

Problemă

- ▣ **Date:** $X = [100, 110, 105, 120]$, $\hat{X} = [95, 108, 110, 115]$
- ▣ **Calculați:** MAE, MSE, RMSE, MAPE

Soluție

- ▣ **Erori:** $e = [5, 2, -5, 5]$
- ▣ **MAE** $= (|5| + |2| + |-5| + |5|)/4 = 4.25$
- ▣ **MSE** $= (25 + 4 + 25 + 25)/4 = 19.75$
- ▣ **RMSE** $= \sqrt{19.75} = 4.44$
- ▣ **MAPE** $= 25 \times (0.05 + 0.018 + 0.048 + 0.042) = 3.95\%$

Exercițiu 3: Indici sezonieri

Problemă

- ▣ **Date:** Indici sezonieri: $S = [0.85, 1.05, 0.90, 1.20]$, Trend T4: $T = 1000$
- ▣ **Calculați:** a) Verificați normalizarea. b) Prognoza T4. c) Desezonalizați $X_{T4} = 1150$

Soluție

- ▣ **a) Normalizare:** $\sum S_i = 0.85 + 1.05 + 0.90 + 1.20 = 4.00 \checkmark$
- ▣ **b) Prognoză:** $\hat{X}_{T4} = 1000 \times 1.20 = \mathbf{1200}$
- ▣ **c) Desezonalizare:** $X_{desezonalizat} = 1150/1.20 = \mathbf{958.33}$ (sub trend)

Exercițiu AI: Gândire critică

Prompt de testat în ChatGPT / Claude / Copilot

“Folosind yfinance, descarcă prețurile de închidere ajustate pentru SPY din 2015 până în 2024. Aplică descompunerea sezonieră (aditivă și multiplicativă) și compară rezultatele vizual. Apoi împarte datele în set de antrenare (2015–2023) și set de test (2024). Ajustează trei modele de netezire exponențială (SES, Holt, Holt-Winters) pe setul de antrenare și evaluează-le pe setul de test folosind RMSE și MAPE. Care model e cel mai bun? Arată graficele și tabelul comparativ.”

Exercițiu:

1. Rulați prompt-ul într-un LLM la alegere și analizați critic răspunsul.
2. AI alege descompunere aditivă sau multiplicativă? Alegerea e justificată?
3. Cum evaluează modelele — folosește RMSE pe antrenare sau pe test?
4. Verificați parametrii de netezire (α , β , γ). Valori aproape de 1,0 sunt problematice?
5. Codul împarte corect datele în antrenare/test, sau evaluează pe date de antrenare?

Atenție: Codul generat de AI poate rula fără erori și arăta profesional. *Asta nu înseamnă că e corect.*

Rezumat: Capitolul 0

Concepte cheie

1. **Serii de timp:** observații ordonate temporal, cu dependență (autocorelație)
2. **Descompunere:** aditivă ($X_t = T_t + S_t + \varepsilon_t$) vs multiplicativă ($X_t = T_t \times S_t \times \varepsilon_t$)
3. **Netezire exponențială:** SES, Holt, Holt-Winters — parametrul α controlează reactivitatea
4. **Evaluarea prognozei:** MAE, RMSE, MAPE — alegerea depinde de context
5. **Sezonalitate:** indici sezonieri, prognoză și desezonalizare

Întrebări?

Bibliografie I

Fundamentele Seriilor de Timp

- ▣ Hyndman, R.J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*, 3rd ed., OTexts.
- ▣ Shumway, R.H., & Stoffer, D.S. (2017). *Time Series Analysis and Its Applications*, 4th ed., Springer.
- ▣ Brockwell, P.J., & Davis, R.A. (2016). *Introduction to Time Series and Forecasting*, 3rd ed., Springer.

Serii de Timp Financiare

- ▣ Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed., Wiley.
- ▣ Franke, J., Härdle, W.K., & Hafner, C.M. (2019). *Statistics of Financial Markets*, 4th ed., Springer.

Bibliografie II

Abordări Moderne și Machine Learning

- ▣ Nielsen, A. (2019). *Practical Time Series Analysis*, O'Reilly Media.
- ▣ Petropoulos, F., et al. (2022). *Forecasting: Theory and Practice*, International Journal of Forecasting.
- ▣ Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition, International Journal of Forecasting.

Resurse Online și Cod

- ▣ **Quantlet**: <https://quantlet.com> — Depozit de cod pentru statistică
- ▣ **Quantinar**: <https://quantinar.com> — Platformă de învățare metode cantitative
- ▣ **GitHub TSA**: https://github.com/QuantLet/TSA/tree/main/TSA_ch0 — Cod Python pentru acest seminar

Vă mulțumesc!

Întrebări?

Materialele seminarului sunt disponibile la:

<https://danpele.github.io/Time-Series-Analysis/>

 Quantlet

 Quantinar