



Serii de timp

Seminarul 2: Modele ARMA



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material

- ▣ **ACF**: Autocorrelation Function (funcția de autocorelație)
- ▣ **AI**: Artificial Intelligence (inteligență artificială)
- ▣ **AIC**: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ **AR**: AutoRegressive (model) — model autoregresiv
- ▣ **ARMA**: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **BET**: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BIC**: Bayesian Information Criterion (criteriul informațional bayesian al lui Schwarz)
- ▣ **BNR**: Banca Națională a României
- ▣ **EODHD**: EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ **IAPC**: Indicele armonizat al prețurilor de consum
- ▣ **JB**: Jarque–Bera (test) — testul de normalitate Jarque–Bera
- ▣ **MA**: Moving Average (medie mobilă)
- ▣ **MAE**: Mean Absolute Error (eroarea absolută medie)
- ▣ **MLE**: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- ▣ **PACF**: Partial AutoCorrelation Function (funcția de autocorelație parțială)
- ▣ **PIB**: Produsul intern brut
- ▣ **RMSE**: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ **SUA**: Statele Unite ale Americii
- ▣ **WN**: White Noise (zgomot alb)

Întrebarea de azi și structura seminarului

- ▣ Întrebarea seminarului
 - ▶ **cum alegem, estimăm, verificăm și folosim un model ARMA pentru o serie staționară?**
- ▣ Rezultate de obținut (nu se predă nimic)
 - ▶ răspunsurile la exercițiile A
 - ▶ câte o figură și un tabel pentru fiecare exercițiu B
 - ▶ răspunsul A1 corectat din [C2](#)
 - ▶ o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#)
 - ▶ fiecare cerință indică secțiunea din notebook
- ▣ Exercițiile, tipurile și ordinea lor: [harta exercițiilor](#) (slide-ul următor)
- ▣ Seminar: prof. Daniel Traian Pele, danpele@ase.ro

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	AR(1): momente și prognoze; AR(2): rădăcini și autocorelații	Rezolvat, Propus	A1
A3, A4	invertibilitatea MA(1); ponderile ARMA(1,1) și un factor comun	Rezolvat, Propus	A3
A5, A6	Yule–Walker și criterii informaționale; criterii și gradele de libertate Ljung–Box	Rezolvat, Propus	A5
B1, B2	Box–Jenkins: creșterea PIB-ului real al SUA; creșterea PIB-ului real al României	Rezolvat, Propus	B1
B3, B4	AR(1) pentru randamente zilnice: BET; EUR/RON	Rezolvat, Propus	B3
C1, C2	depășește un AR prognozele simple ale inflației? ce este greșit într-un răspuns AI?	Propus	B1, A1

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model; rezolvarea se discută la seminar
- Partea A: calcule pe hîrtie; Partea B: date reale, în notebook, fiecare cerință încheindu-se cu o întrebare de interpretare; Partea C: întrebări deschise și critica unui răspuns AI

Datele folosite

Seria	Sursa	Frecvența	Perioada
PIB real, SUA	statsmodels macrodata	trimestrial	1959–2009
PIB real, România	Eurostat (namq_10_gdp)	trimestrial, ajustat sezonier	2000–2026
BET	EODHD	zilnic, închidere	2000–2026
EUR/RON	cursul de referință BNR	zilnic	2005–2026
IAPC, România	Eurostat (prc_hicp_minr)	lunar, 2015 = 100	2005–2026

- ▣ Ratele de creștere în %: $400 \Delta \ln Y_t$ (SUA, anualizat), $100 \Delta \ln Y_t$ (România, față de trimestrul anterior); randamente logaritmice zilnice $100 \Delta \ln P_t$
- ▣ Inflația pe 12 luni: $100 (\ln P_t - \ln P_{t-12})$
- ▣ În notebook: `fit_arma(x, p, q)`, `box_jenkins(y, name)`, `b3_returns('bet')`; nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/17): modelele

- $\varepsilon_t \sim \text{WN}(0, \sigma^2)$: zgomot alb (Seminarul 1); **operatorul lag** L : $LX_t = X_{t-1}$, $L^j X_t = X_{t-j}$
- **AR**(p) (autoregresiv): valoarea de azi pe baza ultimelor p valori

$$X_t = c + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t, \quad \phi(L)X_t = c + \varepsilon_t$$

► c : termenul liber; ϕ_i : ponderile valorilor trecute; $\phi(z) = 1 - \phi_1 z - \cdots - \phi_p z^p$: polinomul AR

- **MA**(q) (medie mobilă): valoarea de azi pe baza ultimelor q șocuri

$$X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} = \mu + \theta(L)\varepsilon_t$$

► μ : media; θ_j : ponderile șocurilor trecute; $\theta(z) = 1 + \theta_1 z + \cdots + \theta_q z^q$: polinomul MA

- **ARMA**(p, q): ambele părți; p, q : ordinele

$$\phi(L)(X_t - \mu) = \theta(L)\varepsilon_t$$

Noțiuni necesare azi (2/17): staționaritate și invertibilitate

- **Staționar (cauzal):** toate rădăcinile ecuației $\phi(z) = 0$ se află în afara cercului unitate, $|z| > 1$

$$X_t = \mu + \sum_{j \geq 0} \psi_j \varepsilon_{t-j}, \quad \psi_0 = 1$$


- ▶ ψ_j : efectul asupra lui X_t al unui șoc produs cu j perioade în urmă (forma $MA(\infty)$)
- ▶ $AR(1)$: $|\phi| < 1$; $AR(2)$: $\phi_1 + \phi_2 < 1$, $\phi_2 - \phi_1 < 1$, $|\phi_2| < 1$ (un triunghi)
- ▶ o rădăcină cu $|z| < 1$: procesul explodează; o rădăcină $z = 1$: rădăcină unitară (Seminarul 3)

- **Invertibil:** toate rădăcinile ecuației $\theta(z) = 0$ au $|z| > 1$

$$\varepsilon_t = \sum_{j \geq 0} \pi_j (X_{t-j} - \mu), \quad \pi_0 = 1$$


- ▶ șocurile pot fi recuperate din valorile trecute (forma $AR(\infty)$); $MA(1)$: $|\theta| < 1$, $\pi_j = (-\theta)^j$
- ▶ staționaritatea depinde doar de $\phi(z)$, invertibilitatea doar de $\theta(z)$

Noțiuni necesare azi (3/17): triunghiul AR(2)



- Stînga: perechile (ϕ_1, ϕ_2) din interiorul triunghiului dau un AR(2) staționar; sub parabola punctată rădăcinile sînt complexe
- Trei exemple
 - ▶ A = (0,5, 0,3): rădăcini reale, 1,17 și 2,84; ACF descrește lin
 - ▶ B = (1,0, -0,5): rădăcini complexe cu $|z| = 1,41$; ACF este o undă amortizată
 - ▶ C = (1,3, 0,3): $\phi_1 + \phi_2 = 1,6 > 1$, o rădăcină de 0,67, în interiorul cercului: exploziv

Noțiuni necesare azi (4/17): AR(1): momente și timp de înjumătățire



- AR(1), $\phi = 0.8$
- AR(1), $\phi = 0.3$
- ARMA(1,1), $\phi = 0.8$, $\theta = -0.5$

□ **AR(1)** $X_t = c + \phi X_{t-1} + \varepsilon_t$, $|\phi| < 1$

$$\mu = \frac{c}{1 - \phi}, \quad \gamma(0) = \frac{\sigma^2}{1 - \phi^2}, \quad \rho(h) = \phi^h, \quad \psi_j = \phi^j$$

► μ : media, nu termenul liber c ; $\gamma(0)$: varianța; $\rho(h)$: autocorelația la lagul h


□ **Timpul de înjumătățire** al unui șoc: numărul de perioade după care rămîne jumătate din efectul lui

$$\phi^j = 0,5 \iff j = \frac{\ln 0,5}{\ln \phi}$$

► graficul: $\phi = 0,8$ dă $\ln 0,5 / \ln 0,8 = 3,1$ perioade; $\phi = 0,3$ dă 0,6

► linia ARMA(1,1): $\psi_1 = \phi + \theta$, apoi fiecare ψ_j este de ϕ ori precedentul

Noțiuni necesare azi (5/17): trei traectorii AR(1)



- ▣ Simulate cu aceleași șocuri, $T = 150$, $c = 0$; titlul dă ϕ și $\hat{\rho}(1)$ de selecție
- ▣ Mărima și semnul lui ϕ
 - ▶ $\phi = 0,9$: unde lungi, revenire lentă la medie (timp de înjumătățire de 6,6 perioade)
 - ▶ $\phi = 0,3$: aproape de zgomotul alb; $\phi = -0,6$: un zigzag, o valoare mare este de obicei urmată de una mică
 - ▶ în fiecare caz, $\hat{\rho}(1)$ este apropiat de ϕ , deoarece $\rho(1) = \phi$

Noțiuni necesare azi (6/17): momentele modelelor AR(2), MA(1) și ARMA(1,1)

- **AR(2)**, ecuațiile Yule–Walker: fiecare $\rho(h)$ urmează recursia AR

$$\rho(1) = \frac{\phi_1}{1 - \phi_2}, \quad \rho(h) = \phi_1 \rho(h-1) + \phi_2 \rho(h-2), \quad h \geq 2$$

- rădăcini complexe când $\phi_1^2 + 4\phi_2 < 0$: ACF este o undă amortizată; $\psi_j = \phi_1 \psi_{j-1} + \phi_2 \psi_{j-2}$, $\psi_0 = 1$, $\psi_1 = \phi_1$

- **MA(1)** $X_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}$

$$\gamma(0) = \sigma^2(1 + \theta^2), \quad \gamma(1) = \theta\sigma^2, \quad \rho(1) = \frac{\theta}{1 + \theta^2}, \quad \rho(h) = 0 \quad (h \geq 2)$$


- $|\rho(1)| \leq 0,5$ pentru orice θ

- **ARMA(1,1)** $X_t = \phi X_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$

$$\psi_j = \phi^{j-1}(\phi + \theta), \quad \gamma(0) = \sigma^2 \frac{1 + 2\phi\theta + \theta^2}{1 - \phi^2}, \quad \rho(1) = \frac{(1 + \phi\theta)(\phi + \theta)}{1 + 2\phi\theta + \theta^2}, \quad \rho(h) = \phi \rho(h-1)$$

- ψ_j pentru $j \geq 1$; după lagul 1, ACF descrește ca la un AR(1)

Noțiuni necesare azi (7/17): invertibilitatea unui MA(1)



- Două procese MA(1) cu aceeași ACF: θ cu σ^2 și $1/\theta$ cu $\theta^2 \sigma^2$
 - ▶ $\rho(1) = \theta/(1 + \theta^2)$ este același pentru θ și $1/\theta$: graficul, $\theta = 0,4$ și $\theta = 2,5$, $\rho(1) = 0,345$
 - ▶ datele nu le pot deosebi: prin convenție se raportează cel invertibil
- Ponderile $\pi_j = (-\theta)^j$ din $\varepsilon_t = \sum_j \pi_j X_{t-j}$
 - ▶ $|\theta| < 1$: ponderile scad, valorile vechi contează puțin: șocurile pot fi recuperate
 - ▶ $|\theta| > 1$: ponderile explodează (scală logaritmică): șocurile nu pot fi recuperate în mod rezonabil
 - ▶ orice MA finit este staționar, oricare ar fi θ

Noțiuni necesare azi (8/17): identificarea cu ACF și PACF

- **PACF** (partial autocorrelation function, funcția de autocorelație parțială): ϕ_{hh} , ultimul coeficient al unui $AR(h)$ ajustat seriei


$$X_t = \phi_{h1}X_{t-1} + \dots + \phi_{hh}X_{t-h} + u_t$$

- ▶ ϕ_{hh} : legătura dintre X_t și X_{t-h} după eliminarea efectului valorilor intermediare
- ▶ $\phi_{11} = \rho(1)$; pentru un $AR(p)$, $\phi_{hh} = 0$ pentru $h > p$

- **Regulile de identificare**

- ▶ $AR(p)$: PACF se anulează după lagul p , ACF descrește
- ▶ $MA(q)$: ACF se anulează după lagul q , PACF descrește
- ▶ $ARMA(p, q)$: ambele descresc; valorile de selecție se compară cu banda $\pm 1,96/\sqrt{T}$

Noțiuni necesare azi (9/17): ACF și PACF teoretice



- AR(2) cu $\phi = (0,5, 0,3)$: ACF descrește, PACF are două bare ($\phi_{22} = 0,3$), apoi 0
- MA(1) cu $\theta = 0,6$: o bară în ACF ($\rho(1) = 0,44$), o PACF alternantă, descrescătoare
- ARMA(1,1) cu $\phi = 0,7$, $\theta = 0,4$: niciuna nu se anulează; ambele descresc


Noțiuni necesare azi (10/17): estimarea

- **Yule–Walker** pentru AR(2): înlocuim $\rho(1), \rho(2)$ cu valorile de selecție $\hat{\rho}_1, \hat{\rho}_2$ și rezolvăm

$$\hat{\phi}_1 = \frac{\hat{\rho}_1(1 - \hat{\rho}_2)}{1 - \hat{\rho}_1^2}, \quad \hat{\phi}_2 = \frac{\hat{\rho}_2 - \hat{\rho}_1^2}{1 - \hat{\rho}_1^2}, \quad \hat{\sigma}^2 = \hat{\gamma}(0)(1 - \hat{\phi}_1\hat{\rho}_1 - \hat{\phi}_2\hat{\rho}_2)$$

- ▶ $\hat{\sigma}^2$: varianța estimată a șocurilor; $\hat{\gamma}(0)$: varianța de selecție
- **Verosimilitatea maximă (MLE)**: parametrii care fac seria observată cea mai probabilă
 - ▶ metoda implicită a lui ARIMA(x, order=(p, 0, q)) din statsmodels; const este media μ
- **Interpretarea rezultatelor**
 - ▶ raportul $t = \hat{\phi}/\text{SE}(\hat{\phi})$, SE: eroarea standard; $|t| > 1,96$: semnificativ la 5%
 - ▶ $R^2 = 1 - \hat{\sigma}^2/\hat{\gamma}(0)$: ponderea varianței explicată de model; pentru un AR(1), $R^2 \approx \hat{\phi}^2$

Noțiuni necesare azi (11/17): criterii informaționale



- **AIC** (Akaike) și **BIC** (bayesian, Schwarz): ajustarea plus o penalizare pentru fiecare parametru

$$\text{AIC} = -2\ln L + 2k, \quad \text{BIC} = -2\ln L + k\ln T$$

- ▶ $\ln L$: log-verosimilitatea maximizată; $-2\ln L$ măsoară lipsa de ajustare și scade când se adaugă parametri
- ▶ k : numărul parametrilor ($\phi, \theta, \mu, \sigma^2$); T : numărul de observații
- ▶ câștigă valoarea cea mai mică; $\ln T > 2$ pentru $T \geq 8$, deci BIC preferă modele mai mici

- **Graficul**: AR(p) ajustate unui AR(2) simulat

- ▶ $-2\ln L$ continuă să scadă, dar cu mai puțin decât penalizarea după $p = 2$: ambele criterii aleg $p = 2$ (cercurile)


Noțiuni necesare azi (12/17): diagnosticarea reziduurilor

- **Reziduurile** $\hat{\varepsilon}_t = X_t - \hat{X}_{t|t-1}$: erorile pe un pas ale modelului estimat
 - ▶ $\hat{X}_{t|t-1}$: valoarea prognozată de model pentru t cu datele pînă la $t - 1$; un model bun lasă reziduuri de tip zgomot alb
- **Ljung–Box pentru reziduuri**: H_0 : reziduurile sînt zgomot alb pînă la lagul m

$$Q^*(m) = T(T+2) \sum_{h=1}^m \frac{\hat{\rho}_{\hat{\varepsilon}}(h)^2}{T-h} \approx \chi^2(m-p-q)$$


- ▶ $\hat{\rho}_{\hat{\varepsilon}}(h)$: ACF de selecție a reziduurilor; m : numărul de laguri testate
- ▶ $m - p - q$ grade de libertate: fiecare coeficient ARMA estimat consumă unul
- ▶ respingem dacă $Q^*(m) > \chi_{0,95}^2(m-p-q)$: modelul a lăsat autocorelație
- ▶ valori critice de 5%: $\chi_{0,95}^2(5) = 11,07$, $\chi_{0,95}^2(7) = 14,07$, $\chi_{0,95}^2(8) = 15,51$, $\chi_{0,95}^2(9) = 16,92$, $\chi_{0,95}^2(10) = 18,31$

Noțiuni necesare azi (13/17): reziduurile unui model prea mic



- AR(2)-ul simulat din graficele anterioare, $T = 200$, ajustat cu un AR(1) și cu un AR(2)
- ACF a reziduurilor și testul Ljung–Box cu 8 – p grade de libertate
 - ▶ AR(1): bare în afara benzii, $Q^*(8) = 28,6, p < 0,001$: coeficientul ϕ_2 care lipsește rămâne în reziduuri
 - ▶ AR(2): toate barele în interior, $Q^*(8) = 3,7, p = 0,71$: reziduuri de tip zgomot alb

Noțiuni necesare azi (14/17): asimetria, kurtosis-ul și Jarque–Bera



- **Asimetria S și kurtosis-ul K ale reziduurilor standardizate**
 $z_t = (\hat{\varepsilon}_t - \bar{\hat{\varepsilon}})/\hat{\sigma}$

$$S = \frac{1}{T} \sum_{t=1}^T z_t^3, \quad K = \frac{1}{T} \sum_{t=1}^T z_t^4$$

- ▶ distribuția Normală: $S = 0, K = 3$; $K > 3$: cozi groase, mai multe valori extreme

- **Jarque–Bera (JB): H_0 : reziduurile au distribuția Normală**

$$JB = \frac{T}{6} \left(S^2 + \frac{(K - 3)^2}{4} \right) \approx \chi^2(2)$$

- ▶ respingem la 5% dacă $JB > 5,99$; graficul: $T = 1\,000$, $K = 6,8$ dă $JB = 609$
- ▶ cu intervale calculate pe baza distribuției Normale, valorile extreme sînt mai frecvente decît cele 5% promise

Noțiuni necesare azi (15/17): prognoze

- **Prognoze:** înlocuim șocurile viitoare cu 0 și valorile viitoare cu prognozele lor
 - ▶ $\hat{X}_{T+h}$: prognoza făcută la momentul T pentru h perioade înainte; X_T : ultima observație
- **AR(1):** prognoza revine geometric la medie; **MA(q):** media după q pași


$$\hat{X}_{T+h} = \mu + \phi^h(X_T - \mu), \quad \text{MA}(q): \hat{X}_{T+h} = \mu \quad (h > q)$$

- **Varianța erorii de prognoză:** șocurile care apar între $T+1$ și $T+h$

$$\sigma_h^2 = \sigma^2(1 + \psi_1^2 + \cdots + \psi_{h-1}^2)$$

- ▶ pentru un model staționar $\sigma_h^2 \rightarrow \gamma(0)$: intervalul nu se mai lărgeste
- ▶ intervalul de 95% $\hat{X}_{T+h} \pm 1,96 \sigma_h$; 1,96: cuantila de 97,5% a distribuției Normale standard


Noțiuni necesare azi (16/17): prognoze AR(1) și intervale



- Un AR(1) simulat cu $\mu = 10$, $\phi = 0,8$, $\sigma = 1$; ultima valoare este $X_T = 13$
- Prognozele și intervalele lor
 - ▶ $\hat{X}_{T+1} = 10 + 0,8 \cdot 3 = 12,4$, $\hat{X}_{T+2} = 11,92$: distanța față de medie scade cu 20% în fiecare perioadă
 - ▶ $\sigma_1 = 1$, $\sigma_2 = \sqrt{1 + 0,64} = 1,28$; banda tinde spre $\mu \pm 1,96\sqrt{\gamma(0)} = 10 \pm 3,27$

Noțiuni necesare azi (17/17): măsurarea acurateții prognozelor

Expanding window, $h = 3$



- **Erorile de prognoză** $e_i = X_{o_i+h} - \hat{X}_{o_i+h}$, $i = 1, \dots, n$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n e_i^2}, \quad \text{MAE} = \frac{1}{n} \sum_{i=1}^n |e_i|$$

- ▶ o_i : originea prognozei, ultima dată folosită; n : numărul de prognoze
- ▶ RMSE (rădăcina erorii pătratice medii) penalizează mai mult erorile mari; MAE (eroarea absolută medie): mărimea medie ([Capitolul 0](#))
- **Fereastră extinsă**: la fiecare origine, estimăm pe toate datele pînă la o_i și prognozăăm cu h pași înainte
 - ▶ fiecare prognoză folosește doar date din trecut: o comparație corectă, în afara eșantionului
 - ▶ repere: media istorică și ultima valoare (prognoza naivă)

A1: un proces AR(1) [Rezolvat]

Cerință

- $X_t = 1 + 0,6X_{t-1} + \varepsilon_t$, $\varepsilon_t \sim \text{WN}(0; 0,64)$, gaussian.
- 1. Verificați staționaritatea și calculați media și $\gamma(0)$.
- 2. Calculați $\rho(2)$, $\rho(3)$ și timpul de înjumătățire al unui șoc.
- 3. Cu $X_T = 4$, prognozați X_{T+1} și X_{T+2} .
- 4. Calculați intervalele de 95% pentru ambele prognoze.
- Raportați: opt valori și o frază despre revenirea la medie.

Rezolvare

- 1. $|0,6| < 1$: staționar; $\mu = 1/0,4 = 2,5$;
 $\gamma(0) = 0,64/(1 - 0,36) = 1,00$
- 2. $\rho(2) = 0,6^2 = 0,36$, $\rho(3) = 0,216$; timpul de înjumătățire $\ln 0,5 / \ln 0,6 = 1,36$ perioade
- 3. $\hat{X}_{T+1} = 2,5 + 0,6 \cdot 1,5 = 3,40$;
 $\hat{X}_{T+2} = 2,5 + 0,36 \cdot 1,5 = 3,04$
- 4. $\sigma_1 = 0,8$: $[1,832; 4,968]$;
 $\sigma_2^2 = 0,64(1 + 0,36) = 0,8704$, $\sigma_2 = 0,933$: $[1,21; 4,87]$
- Prognozele revin de la 4 spre 2,5, iar intervalele se largesc spre $\pm 1,96$.

A2: un proces AR(2) [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ $X_t = 0,7X_{t-1} - 0,1X_{t-2} + \varepsilon_t$, $\varepsilon_t \sim \text{WN}(0, 1)$. Model: A1.
- ▣ 1. Scrieți modelul cu operatorul lag și factorizați $\phi(z)$.
- ▣ 2. Găsiți rădăcinile și decideți dacă procesul este staționar; verificați cele trei condiții ale triunghiului.
- ▣ 3. Calculați $\rho(1)$, $\rho(2)$ și $\rho(3)$ din ecuațiile Yule–Walker.
- ▣ 4. Calculați ψ_1 , ψ_2 și ψ_3 .
- ▣ Raportați: factorizarea, două rădăcini și șase valori.



A3: un MA(1) care nu este invertibil [Rezolvat]

Cerință

- ▣ $X_t = \varepsilon_t + 2\varepsilon_{t-1}$, $\varepsilon_t \sim \text{WN}(0, 1)$.
- ▣ 1. Calculați $\gamma(0)$, $\gamma(1)$ și $\rho(1)$.
- ▣ 2. Precizați dacă procesul este staționar și dacă este invertibil.
- ▣ 3. Găsiți procesul MA(1) invertibil cu aceleași autocovarianțe.
- ▣ 4. Scrieți primele patru ponderi ale formei lui $\text{AR}(\infty)$ și prognoza $\hat{X}_{T+2}$.
- ▣ Raportați: cinci valori, două verdicte și noul model.

Rezolvare

- ▣ 1. $\gamma(0) = 1 + 4 = 5$, $\gamma(1) = 2 \cdot 1 = 2$, $\rho(1) = 2/5 = 0,4$
- ▣ 2. Staționar (orice MA finit este); nu este invertibil: rădăcina lui $1 + 2z$ este $-0,5$, în interiorul cercului
- ▣ 3. $\theta^* = 1/2$, $\sigma^{*2} = 2^2 \cdot 1 = 4$: $\gamma(0) = 4 \cdot 1,25 = 5$, $\gamma(1) = 0,5 \cdot 4 = 2$
- ▣ 4. $u_t = X_t - 0,5X_{t-1} + 0,25X_{t-2} - 0,125X_{t-3} + \dots$;
 $\hat{X}_{T+2} = \mu = 0$ (după $q = 1$)

A4: un proces ARMA(1,1) [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ $X_t = 0,5X_{t-1} + \varepsilon_t + 0,3\varepsilon_{t-1}$, $\varepsilon_t \sim \text{WN}(0, 1)$. Model: [A1](#), [A3](#).
- ▣ 1. Verificați staționaritatea și invertibilitatea.
- ▣ 2. Calculați ψ_1 , ψ_2 și ψ_3 .
- ▣ 3. Calculați $\gamma(0)$, $\rho(1)$ și $\rho(2)$.
- ▣ 4. Arătați că $X_t = 0,5X_{t-1} + \varepsilon_t - 0,5\varepsilon_{t-1}$ este zgomot alb și precizați ce ar raporta un program de estimare pentru el.
- ▣ Raportați: două verdicte, șase valori și o frază.

A5: Yule–Walker și criterii informaționale [Rezolvat]

Cerință

- ▣ O serie staționară are $T = 100$, $\hat{\gamma}(0) = 4$, $\hat{\rho}(1) = 0,75$, $\hat{\rho}(2) = 0,65$.
- ▣ 1. Estimați un AR(2) prin Yule–Walker: $\hat{\phi}_1$, $\hat{\phi}_2$, $\hat{\sigma}^2$.
- ▣ 2. Verificați că modelul estimat este staționar.
- ▣ 3. Verosimilitatea maximă dă $\ln L = -214,6$ pentru AR(1) ($k = 3$) și $-210,9$ pentru AR(2) ($k = 4$); calculați AIC și BIC.
- ▣ 4. Alegeți un model după fiecare criteriu.
- ▣ Raportați: trei estimări, patru valori ale criteriilor și o alegere.

Rezolvare

- ▣ 1. $1 - 0,75^2 = 0,4375$; $\hat{\phi}_1 = 0,75 \cdot 0,35 / 0,4375 = 0,6$;
 $\hat{\phi}_2 = (0,65 - 0,5625) / 0,4375 = 0,2$
- ▣ $\hat{\sigma}^2 = 4(1 - 0,6 \cdot 0,75 - 0,2 \cdot 0,65) = 1,68$
- ▣ 2. $\hat{\phi}_1 + \hat{\phi}_2 = 0,8 < 1$, $\hat{\phi}_2 - \hat{\phi}_1 = -0,4 < 1$, $|\hat{\phi}_2| < 1$:
staționar
- ▣ 3. $\ln 100 = 4,605$; AR(1): AIC = 435,2, BIC = 443,02;
AR(2): AIC = 429,8, BIC = 440,22
- ▣ 4. Ambele criterii aleg AR(2): câștigul în $\ln L$ (3,7)
depășește ambele penalizări pe parametru (1 și $\ln(100)/2$).

A6: patru candidați și testul Ljung–Box [Propus]

Rezolvarea se discută la seminar




Cerință

- ▣ $T = 120$; MLE dă $\ln L = -250,3$ (AR(1), $k = 3$), $-247,1$ (AR(2), $k = 4$), $-247,6$ (ARMA(1,1), $k = 4$), $-246,9$ (ARMA(2,1), $k = 5$). Model: A5.
- ▣ 1. Calculați AIC și BIC pentru cele patru modele.
- ▣ 2. Alegeți un model după fiecare criteriu.
- ▣ 3. Reziduurile modelului AR(2) dau $Q^*(10) = 14,2$; găsiți gradele de libertate și decideți la 5%.
- ▣ 4. Explicați ce se schimbă dacă se folosesc 10 grade de libertate.
- ▣ Raportați: un tabel cu opt valori, două alegeri și o decizie.

B1: creșterea PIB-ului real al SUA [Rezolvat]

- **Întrebarea:** ce model ARMA descrie creșterea trimestrială a PIB-ului real al SUA și cât de persistente sînt șocurile de creștere?
- **Date:** statsmodels macrodata, PIB real, T2 1959–T3 2009; $y_t = 400 \Delta \ln Y_t$ (% anualizat)
- **Cerințe**
 1. Reprezentați grafic y_t și ACF și PACF pînă la lagul 12 și propuneți modele candidate.
 2. Estimați zgomotul alb, AR(1), AR(2), MA(2) și ARMA(1,1) prin verosimilitate maximă și tabelați AIC și BIC.
 3. Testați reziduurile modelului ales de BIC cu Ljung–Box $Q^*(8)$, cu $8 - p - q$ grade de libertate, și cu Jarque–Bera.
 4. Interpretare: cîte trimestre trec pînă cînd se stinge jumătate dintr-un șoc de creștere?
- **Raportați:** graficul, un tabel cu zece valori ale criteriilor, două rezultate de test și o frază
- Notebook: secțiunea [B1](#)

B1: rezolvare (1/2) [Rezolvat]



--- sample mean --- $\pm 1.96/\sqrt{T}$

B1: rezolvare (2/2) [Rezolvat]

	WN	AR(1)	AR(2)	MA(2)	ARMA(1,1)
AIC	1084,56	1066,98	1063,70	1065,59	1065,02
BIC	1091,17	1076,91	1076,93	1078,83	1078,25

- $T = 202$, ACF 0,30; 0,24; 0,09 și PACF 0,30; 0,16; $-0,02$ (banda $\pm 0,14$): AR(1) sau AR(2)
- BIC: AR(1), $\hat{\mu} = 3,12$, $\hat{\phi} = 0,306$ (0,060); AIC: AR(2), $\hat{\phi}_2 = 0,163$ (0,062); valorile BIC diferă cu 0,02
- Reziduurile AR(1): $Q^*(8) = 11,08$ cu 7 grade de libertate, $p = 0,135$; Jarque–Bera 16,0, $p < 0,001$
- Interpretare: timpul de înjumătățire $\ln 0,5 / \ln 0,306 = 0,59$ trimestre: șocurile de creștere sînt de scurtă durată; persistența se află în nivelul producției, nu în ritmul de creștere



B2: creșterea PIB-ului real al României [Propus]

- **Întrebarea:** are creșterea trimestrială a PIB-ului real al României vreo structură ARMA?
- **Date:** Eurostat, volume înlănțuite, ajustate sezonier și pentru zilele lucrătoare, T1 2000–T2 2026; $y_t = 100 \Delta \ln Y_t$; model: B1
- **Cerințe**
 1. Repetați cei patru pași din B1 pentru y_t (`ro_gdp_growth('qoq')`).
 2. Aplicați testul Ljung–Box $Q^*(8)$ seriei însăși.
 3. Repetați analiza fără cele patru trimestre din 2020 și comparați.
 4. Interpretare: de ce cea mai bună prognoză a creșterii din trimestrul următor este pur și simplu media?
- **Raportați:** graficul, un tabel cu zece valori ale criteriilor, testele și două fraze
- Notebook: secțiunea B2

B3: randamentele zilnice ale BET [Rezolvat]

- ▣ **Întrebarea:** este autocorelația de ordinul 1 a randamentelor BET utilă pentru prognoză?
- ▣ **Date:** închiderile BET din 2000 (EODHD); $r_t = 100 \Delta \ln P_t$, $T = 6\,670$, ultima zi 18 septembrie 2026
- ▣ **Cerințe**
 1. Estimați un AR(1) prin verosimilitate maximă și raportați $\hat{\phi}$, eroarea standard, raportul t și R^2 .
 2. Testați reziduurile cu Ljung–Box $Q^*(10)$, cu 9 grade de libertate, și pătratele reziduurilor cu $Q^*(10)$.
 3. Calculați kurtosis-ul și statistica Jarque–Bera a reziduurilor.
 4. Prognozați randamentul de mâine cu intervalul de 95%.
 5. Interpretare: este coeficientul AR(1) semnificativ statistic și este el util din punct de vedere economic?
- ▣ **Raportați:** șase valori, graficul, o prognoză cu intervalul ei și două fraze
- ▣ **Notebook:** secțiunea [B3](#)

B3: rezolvare (1/2) [Rezolvat]



----- $\pm 1.96/\sqrt{T}$

B3: rezolvare (2/2) [Rezolvat]

- $\hat{\phi} = 0,109$ (eroarea standard 0,0052), $t = 20,9$; $R^2 = 1,2\%$; $\hat{\sigma} = 1,390\%$
- Reziduurile: $Q^*(10) = 29,7$, $p < 0,001$ (rămîne puțină corelație); pătratele: $Q^*(10) = 2496$; kurtosis-ul 14,0, Jarque–Bera 34128
- Ultimul randament 2,17%: prognoza 0,294%, intervalul de 95% $[-2,43; 3,02]$ (construit cu distribuția Normală, prea îngust în cozi)
- Interpretare: foarte semnificativ, dar explică aproximativ 1% din varianță, iar prognoza este foarte mică în raport cu intervalul; valoarea mare a lui Q^* pentru pătrate trimite la modelele de volatilitate ([Capitolul 5](#))

B4: randamentele zilnice EUR/RON [Propus]

- ▣ **Întrebarea:** se comportă cursul EUR/RON ca BET?
- ▣ **Date:** cursul de referință BNR din iulie 2005, $T = 5\,352$ randamente; model: [B3](#)
- ▣ **Cerințe**
 1. Repetați cei patru pași din [B3](#) (`b3_returns('eurron')`).
 2. Comparați $\hat{\phi}$, R^2 și kurtosis-ul cu cele ale BET.
 3. Interpretare: de ce poate un curs de schimb în regim de managed float să aibă o autocorelație de ordinul 1 mai mare decât un indice bursier?
- ▣ **Raportați:** un tabel (două serii, câte șase valori) și două fraze
- ▣ **Notebook:** secțiunea [B4](#)

C1: depășește un model AR prognozele simple ale inflației? [Propus]

- ▣ **Întrebarea:** este un AR(2) mai bun decât media istorică și ultima valoare la prognoza inflației pe 12 luni din România, cu un an înainte?
- ▣ **Date:** inflația IAPC din 2005 (Eurostat); origini de prognoză în fiecare lună începînd cu ianuarie 2015; modele: [B1](#), [A1](#)
- ▣ **Cerințe**
 1. La fiecare origine, estimați un AR(2) pe toate datele pînă în luna respectivă și prognozați cu 12 luni înainte.
 2. Calculați aceleași prognoze din media istorică și din ultima valoare observată.
 3. Comparați RMSE și MAE pentru cele trei metode, pe întreaga perioadă și înainte de iulie 2021.
 4. Interpretare: de ce eșuează toate cele trei metode în 2022?
- ▣ **Raportați:** un tabel cu RMSE și MAE, graficul și un plan de proiect
- ▣ **Notebook:** secțiunea [C1](#)

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI informații despre modelele ARMA din acest seminar. Răspunsul:
- (a) Procesul $X(t) = 0,6 X(t-1) + 0,5 X(t-2) + e(t)$ este staționar, deoarece ambii coeficienți sînt sub 1.
- (b) Un MA(1) cu $\theta = 2$ nu este staționar, deoarece $|\theta| > 1$.
- (c) Modelul AR(1) pentru randamentele BET are $t = 21$, deci randamentul de ieri explică cea mai mare parte a randamentului de azi.
- (d) Pentru reziduurile unui ARMA(1,1), statistica Ljung-Box $Q(8)$ se compară cu distribuția hi-pătrat cu 8 grade de libertate.
- (e) Prognoza unui MA(2) cu trei pași înainte este egală cu media seriei.
- (f) Într-un AR(1), $X(t) = c + \phi X(t-1) + e(t)$, media seriei este c .
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu, dați afirmația corectă și, unde se poate, valoarea corectă din notebook (secțiunea C2).
 - ▶ 2. Raportați: o listă de șase verdicte, fiecare cu un rînd de justificare.

Idei de reținut

- ▣ Staționaritatea se citește din rădăcinile lui $\phi(z)$, invertibilitatea din rădăcinile lui $\theta(z)$, niciodată din coeficienți luați separat
- ▣ Media unui model AR este $c/\phi(1)$, nu termenul liber c
- ▣ Box–Jenkins: ACF și PACF propun, AIC și BIC aleg, testele pe reziduuri verifică, prognozele se compară cu repere simple
- ▣ Testul Ljung–Box pentru reziduuri folosește $m - p - q$ grade de libertate
- ▣ Semnificativ statistic nu înseamnă mare din punct de vedere economic: comparați $\hat{\phi}^2$ cu intervalul de prognoză

După seminar

- Cursul 2 deduce formulele de azi: rădăcini, invertibilitate, ponderi ψ , estimatori, criterii informaționale, intervale de prognoză, studiul Box–Jenkins pentru PIB-ul României
- C1 poate deveni un proiect de echipă: prognoze ARMA ale inflației în România și în regiune, comparate cu repere simple
- Lectură: Huang și Petukhina (2022), cap. 3–4; Hyndman și Athanasopoulos (2021), cap. 9; Brockwell și Davis (2016), cap. 3

Bibliografie

- ▣ Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716–723. doi:10.1109/TAC.1974.1100705
- ▣ Box, G. E. P., Jenkins, G. M., & Reinsel, G. C. (2008). *Time Series Analysis: Forecasting and Control* (4th ed.). Wiley. doi:10.1002/9781118619193
- ▣ Box, G. E. P., & Pierce, D. A. (1970). Distribution of residual autocorrelations in autoregressive-integrated moving average time series models. *Journal of the American Statistical Association*, 65(332), 1509–1526. doi:10.1080/01621459.1970.10481180
- ▣ Brockwell, P. J., & Davis, R. A. (2016). *Introduction to Time Series and Forecasting* (3rd ed.). Springer. doi:10.1007/978-3-319-29854-2
- ▣ Huang, C., & Petukhina, A. (2022). *Applied Time Series Analysis and Forecasting with Python*. Springer. doi:10.1007/978-3-031-13584-2
- ▣ Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. otexts.com/fpp3
- ▣ Jarque, C. M., & Bera, A. K. (1987). A test for normality of observations and regression residuals. *International Statistical Review*, 55(2), 163–172. doi:10.2307/1403192
- ▣ Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303. doi:10.1093/biomet/65.2.297
- ▣ Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics*, 6(2), 461–464. doi:10.1214/aos/1176344136