



Serii de timp

Seminarul 4: Sezonabilitate și prognoză: SARIMA, TBATS, Prophet



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **ACF**: Autocorrelation Function (funcția de autocorelație)
- ▣ **AI**: Artificial Intelligence (inteligență artificială)
- ▣ **AR**: AutoRegressive (model) — model autoregresiv
- ▣ **ARMA**: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **DHR**: Dynamic Harmonic Regression (regresie armonică dinamică)
- ▣ **DM**: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ **ENTSO-E**: European Network of Transmission System Operators for Electricity (rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică)
- ▣ **HLN**: Harvey–Leybourne–Newbold (small-sample correction of the DM test) — corecția Harvey–Leybourne–Newbold a testului DM pentru eșantioane mici
- ▣ **IAPC**: Indicele armonizat al prețurilor de consum
- ▣ **MA**: Moving Average (medie mobilă)
- ▣ **MAE**: Mean Absolute Error (eroarea absolută medie)

Acronime folosite în acest material (2/2)

- ▣ **MAPE**: Mean Absolute Percentage Error (eroarea procentuală absolută medie)
- ▣ **MASE**: Mean Absolute Scaled Error (eroarea absolută medie scalată)
- ▣ **MSE**: Mean Squared Error (eroarea pătratică medie)
- ▣ **PACF**: Partial AutoCorrelation Function (funcția de autocorelație parțială)
- ▣ **PIB**: Produsul intern brut
- ▣ **RMSE**: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ **SARIMA**: Seasonal ARIMA (model) — model ARIMA sezonier
- ▣ **SCA**: Seasonally and Calendar Adjusted (ajustat sezonier și pentru efectele de calendar)
- ▣ **SE**: Standard Error (eroare standard)
- ▣ **TBATS**: Trigonometric seasonality, Box–Cox, ARMA errors, Trend, Seasonal components (model) — model cu sezonalitate trigonometrică, transformare Box–Cox, erori ARMA, trend și componente sezoniere
- ▣ **WD**: Working Days (regresor) — zile lucrătoare (regresor)
- ▣ **WN**: White Noise (zgomot alb)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum modelăm, prognozăm și comparăm prognozele unor serii care repetă un tipar în fiecare an, săptămână sau zi?
 - ▶ seminarul are loc **înaintea** Cursului 4: secțiunea „Noțiuni necesare azi” dă toate formulele folosite în cerințe
- ▣ Traseul
 - ▶ Partea A: diferențe sezoniere, polinoamele și autocorelațiile SARIMA, testul Diebold–Mariano și combinarea prognozelor, pe hîrtie
 - ▶ Partea B: PIB-ul României, producția industrială, consumul zilnic de electricitate și inflația lunară
 - ▶ Partea C: turismul după pandemie și un răspuns AI de verificat
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); fiecare cerință indică secțiunea din notebook

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	diferențe sezoniere și prognoze sezoniere naive; polinoamele SARIMA	Rezolvat, Propus	A1
A3, A4	ACF a modelului airline; un AR sezonier și estimări prin metoda momentelor	Rezolvat, Propus	A3
A5, A6	MASE și testul Diebold–Mariano; combinarea a două prognoze	Rezolvat, Propus	A5
B1, B2	SARIMA: PIB-ul României; producția industrială cu zile lucrătoare	Rezolvat, Propus	B1
B3, B4	validare încrucișată: consumul de electricitate; inflația lunară	Rezolvat, Propus	B3
C1, C2	turismul după pandemie; ce este greșit într-un răspuns AI?	Propus	B1, A5

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model

Datele folosite

Seria	Sursa	Frecvența	Perioada
PIB real, neajustat	Eurostat (namq_10_gdp)	trimestrial	2000–2026
Producția industrială	Eurostat (sts_inpr_m)	lunar, 2021 = 100	2010–2026
Consumul de electricitate	ENTSO-E	media zilnică a datelor orare	2022–2026
IAPC, România	Eurostat (prc_hicp_minr)	lunar, 2015 = 100	2010–2026
Înnoptări turistice	Eurostat (tour_occ_nim)	lunar	2005–2025

- ▣ Logaritmi înmulțiți cu 100: $100 \ln Y_t$, astfel încât diferențele sînt rate de creștere în %
- ▣ ENTSO-E: rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică; consumul este exprimat în MW (media orară)
- ▣ În notebook: `fit_sarima`, `b1_gdp()`, `b3_load_cv()`; nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/21): sezonality și operatorul lag

- ▣ **Sezonality:** un tipar care se repetă cu o **perioadă** fixă s
 - ▶ $s = 4$ (trimestre), $s = 12$ (luni), $s = 7$ (zilele săptămânii), $s = 24$ (orele zilei)
 - ▶ cauze: vremea, calendarul (zile lucrătoare, sărbători), instituțiile (termene fiscale, anul școlar)
- ▣ **Operatorul lag L :** deplasează o serie înapoi în timp

$$Ly_t = y_{t-1}, \quad L^k y_t = y_{t-k}$$

- ▶ k : numărul de perioade al deplasării; polinoamele în L se înmulțesc ca polinoamele obișnuite
- ▶ exemplu: $(1 - L)(1 - L^4) = 1 - L - L^4 + L^5$
- ▣ **Logaritmi înmulțiți cu 100:** diferențele devin rate de creștere în %

$$y_t = 100 \ln Y_t, \quad y_t - y_{t-k} = 100 \ln \frac{Y_t}{Y_{t-k}} \approx 100 \frac{Y_t - Y_{t-k}}{Y_{t-k}}$$

- ▶ Y_t : seria inițială (PIB, producție, un indice de prețuri); aproximarea este bună pentru variații sub circa 10%

Noțiuni necesare azi (2/21): diferențe sezoniere

- ▣ **Diferența sezonieră:** fiecare valoare minus valoarea din același sezon cu un an în urmă

$$\Delta_s y_t = (1 - L^s) y_t = y_t - y_{t-s}$$

- ▶ elimină un tipar sezonier care se repetă exact; cu $y_t = 100 \ln Y_t$ și $s = 4$: creșterea față de același trimestru al anului anterior, în %

- ▣ **Diferența obișnuită și cea sezonieră**, împreună

$$\Delta \Delta_s y_t = (1 - L)(1 - L^s) y_t = y_t - y_{t-1} - y_{t-s} + y_{t-s-1}$$


- ▶ $\Delta = 1 - L$ elimină și trendul; $\Delta \Delta_s y_t$: variația creșterii anuale

- ▣ **Proгноza sezonieră naivă:** copiază același sezon din ultimul an observat

$$\hat{y}_{T+h|T} = y_{T+h-s}, \quad h = 1, \dots, s$$

- ▶ T : ultima observație; $\hat{y}_{T+h|T}$: prognoza pentru h perioade înainte, făcută la momentul T
- ▶ reperul pe care orice model sezonier trebuie să îl depășească ([Capitolul 0](#))

Noțiuni necesare azi (3/21): o serie trimestrială simulată și diferențele ei



- ▣ Serie simulată: $y_t = 100 + 0,8 t + \text{un tipar sezonier } (-6, 2, 5, -1) + \text{zgomot}$, 40 de trimestre
- ▣ $\Delta_4 y_t$ fluctuează în jurul valorii $4 \times 0,8 = 3,2$: sezonul dispăre, iar trendul devine o constantă
 - $\Delta\Delta_4 y_t$ fluctuează în jurul lui 0: nici trend, nici sezon; cu roșu: prognoza sezonieră naivă

Noțiuni necesare azi (4/21): ACF a unui proces MA

- ▣ Procesul **MA**(q): o sumă ponderată a șocului curent și a șocurilor trecute

$$w_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2)$$

- ▶ WN: zgomot alb, șocuri necorelate cu media 0 și varianța σ^2 ; θ_j : ponderea șocului de acum j perioade

- ▣ **Autocovarianța** $\gamma(k) = \text{Cov}(w_t, w_{t-k})$ și **autocorelația** ρ_k

$$\gamma(k) = \sigma^2 \sum_{j=0}^{q-k} \theta_j \theta_{j+k} \quad (\theta_0 = 1), \quad \rho_k = \frac{\gamma(k)}{\gamma(0)}$$

- ▶ $\gamma(0) = \sigma^2(1 + \theta_1^2 + \cdots + \theta_q^2)$ este varianța; $\rho_k = 0$ pentru $k > q$: ACF se anulează după lagul q
- ▶ MA(1): $\rho_1 = \theta/(1 + \theta^2)$, mereu între $-0,5$ și $0,5$

- ▣ **ACF de selecție** $\hat{\rho}_k$: pentru zgomot alb, aproximativ $N(0, 1/T)$

- ▶ banda de 95%: $\pm 1,96/\sqrt{T}$, T : volumul eșantionului; o valoare în afara benzii este semnificativă la 5%

Noțiuni necesare azi (5/21): PACF, inversabilitatea și estimarea prin metoda momentelor

- ▣ **PACF** ϕ_{kk} : ultimul coeficient al unei regresii $AR(k)$

$$y_t = \phi_{k1}y_{t-1} + \cdots + \phi_{kk}y_{t-k} + e_t$$

- ▶ corelația dintre y_t și y_{t-k} după eliminarea efectului lagurilor intermediare; pentru un $AR(p)$ se anulează după lagul p

- ▣ **Inversabilitatea** unui $MA(1)$: $|\theta| < 1$

- ▶ șocurile ε_t pot fi atunci reconstituite din valorile trecute ale seriei
- ▶ θ și $1/\theta$ dau același ρ_1 : păstrăm rădăcina cu $|\theta| < 1$

- ▣ **Metoda momentelor**: egalăm ρ_1 teoretic cu valoarea de selecție

$$\frac{\theta}{1 + \theta^2} = \hat{\rho}_1 \iff \hat{\rho}_1\theta^2 - \theta + \hat{\rho}_1 = 0, \quad \hat{\theta} = \frac{1 - \sqrt{1 - 4\hat{\rho}_1^2}}{2\hat{\rho}_1}$$

- ▶ cele două rădăcini au produsul 1; formula o dă pe cea inversabilă; o soluție există doar dacă $|\hat{\rho}_1| \leq 0,5$

Noțiuni necesare azi (6/21): modele SARIMA

- ▣ **SARIMA**(p, d, q)(P, D, Q) $_s$: un ARMA obișnuit și unul sezonier, înmulțite

$$\phi(L) \Phi(L^s) (1 - L)^d (1 - L^s)^D y_t = \theta(L) \Theta(L^s) \varepsilon_t$$

- ▣ Notățiile

- ▶ $\phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p$, $\theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q$: polinoamele AR și MA obișnuite ([Capitolul 2](#))
- ▶ $\Phi(L^s) = 1 - \Phi_1 L^s - \dots - \Phi_P L^{Ps}$, $\Theta(L^s) = 1 + \Theta_1 L^s + \dots + \Theta_Q L^{Qs}$: polinoamele AR și MA sezoniere
- ▶ d, D : numărul diferențelor obișnuite și al celor sezoniere; ε_t : zgomot alb cu varianța σ^2

- ▣ **Polinoame înmulțite**: apar termeni încrucișați, fără parametri noi

- ▶ $(1 + \theta L)(1 + \Theta L^s) = 1 + \theta L + \Theta L^s + \theta \Theta L^{s+1}$
- ▶ parametri: $p + q + P + Q$ coeficienți și σ^2 ; o constantă doar când nu există nicio diferență

Noțiuni necesare azi (7/21): modelul airline

- ▣ **Modelul airline** (Box și Jenkins): SARIMA(0, 1, 1)(0, 1, 1)_s

$$w_t = \Delta \Delta_s y_t = (1 + \theta L)(1 + \Theta L^s) \varepsilon_t = \varepsilon_t + \theta \varepsilon_{t-1} + \Theta \varepsilon_{t-s} + \theta \Theta \varepsilon_{t-s-1}$$

- ▶ doi parametri, θ și Θ ; w_t este un MA($s + 1$) cu doar patru coeficienți nenuli

- ▣ **ACF a lui** w_t , din formula procesului MA


$$\rho_1 = \frac{\theta}{1 + \theta^2}, \quad \rho_s = \frac{\Theta}{1 + \Theta^2}, \quad \rho_{s-1} = \rho_{s+1} = \rho_1 \rho_s$$

- ▶ toate celelalte autocorelații sînt 0

- ▣ **Rolul lui** Θ : cît de repede se schimbă tiparul sezonier


- ▶ prognoza sezonieră este o medie ponderată exponențial a tiparelor trecute, cu ponderea $1 + \Theta$ pentru anul cel mai recent
- ▶ $\Theta \rightarrow -1$: un tipar fix; $\Theta = 0$: un tipar care se schimbă liber de la un an la altul

Noțiuni necesare azi (8/21): ACF și PACF ale modelelor sezoniere



- Stînga: airline, $s = 12$: $\rho_1 = -0,28$, $\rho_{12} = -0,47$ și „sateliții” $\rho_{11} = \rho_{13} = \rho_1 \rho_{12} = 0,13$
- Mijloc și dreapta: AR(1) sezonier, $y_t = \Phi y_{t-12} + \varepsilon_t$: $\rho_{12k} = \Phi^k$, PACF o singură valoare nenulă, la lagul 12
 - ACF care se anulează după s și PACF care descrește la $s, 2s, \dots$: MA(1) sezonier; invers: AR(1) sezonier

Noțiuni necesare azi (9/21): un tipar sezonier stabil sau unul care se schimbă



- Două serii airline simulate, $\theta = -0,4$, aceleași șocuri; fiecare linie: lunile unui an minus media celui an
- $\Theta = -0,95$: anii 1, 6 și 12 aproape coincid (corelația dintre anul 1 și anul 12 este 0,98)
 - ▶ $\Theta = 0$: tiparul se deplasează (corelația 0,93); prognoza urmează atunci în principal ultimul an

Noțiuni necesare azi (10/21): estimare și diagnosticare

- ▣ **Verosimilitatea maximă:** $\hat{\theta}$, $\hat{\Theta}$ maximizează log-verosimilitatea ℓ a seriei observate
 - ▶ SE: eroarea standard a unei estimări; $|\hat{\theta}/\text{SE}| > 1,96$: semnificativ la 5%
- ▣ Testul **Ljung–Box** pe reziduurile $\hat{\varepsilon}_t$


$$Q^*(m) = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k} \sim \chi^2(m - n_c)$$

- ▶ $\hat{\rho}_k$: ACF a reziduurilor; m : numărul de laguri testate; $n_c = p + q + P + Q$: coeficienții ARMA (airline: $m - 2$)
- ▶ H_0 : reziduurile sînt zgomot alb; un p-value mic: modelului îi scapă o parte din dinamică
- ▣ **AICc**: criteriul informațional Akaike corectat

$$\text{AICc} = -2\ell(\hat{\vartheta}) + 2k + \frac{2k(k+1)}{T-k-1}$$

- ▶ $\hat{\vartheta}$: parametrii estimați; k : numărul lor, inclusiv σ^2 ; cîștigă cel mai mic AICc (aceleași date, aceleași diferențe)

Noțiuni necesare azi (11/21): prognoze și intervalele lor



- Intervalul de 95%: $\hat{y}_{T+h|T} \pm 1,96 \hat{\sigma}_h$; $\hat{\sigma}_h$: abaterea standard a erorii de prognoză la h pași
 - serie airline simulată ($\theta = -0,4$, $\Theta = -0,6$): lățimea 4,4 la $h = 1$, 8,8 la $h = 12$, 14,7 la $h = 24$
- Creșterea anuală implicată de o prognoză: $\hat{y}_{T+h|T} - y_{T+h-s}$ (în % când $y_t = 100 \ln Y_t$)

Noțiuni necesare azi (12/21): regresia cu erori SARIMA

- Regresori cunoscuți dinainte, plus dinamică SARIMA în eroare

$$y_t = \beta^\top \mathbf{x}_t + u_t, \quad u_t \sim \text{SARIMA}$$

- ▶ $\mathbf{x}_t$: vectorul regresorilor; β : coeficienții lor; $^\top$: transpusa
- ▶ **zile lucrătoare**: zilele de luni până vineri din lună care nu sînt sărbători legale
- ▶ **variabilă dummy**: 1 într-o anumită perioadă (o sărbătoare, o valoare aberantă precum aprilie 2020), 0 în rest

- **Efectul în %**: cu $y_t = 100 \ln Y_t$, un coeficient β modifică Y_t cu

$$100 (e^{\beta/100} - 1)\% \approx \beta\%$$

- Serie **SCA**: ajustată sezonier și în funcție de calendar de institutul de statistică
 - ▶ un trimestru SCA se compară cu trimestrul anterior; un trimestru neajustat doar cu același trimestru din anul anterior

Noțiuni necesare azi (13/21): un test pentru mediile lunare

- ▣ **Variabile dummy lunare:** $D_{mt} = 1$ dacă t cade în luna m , 0 în rest

$$\pi_t = \delta_1 D_{1t} + \cdots + \delta_{12} D_{12t} + e_t$$

- ▶ $\pi_t = 100 \Delta \ln P_t$: inflația lunară în %, P_t : indicele prețurilor; δ_m : media lui π_t în luna m

- ▣ **Testul F** pentru $H_0: \delta_1 = \cdots = \delta_{12}$ (nicio sezonalitate în medie)

$$F = \frac{(RSS_R - RSS_U)/q}{RSS_U/(T - k)} \sim F(q, T - k)$$

- ▶ RSS_U : suma pătratelor reziduurilor cu cele 12 variabile dummy ($k = 12$ coeficienți); RSS_R : doar cu o constantă
- ▶ $q = 11$ restricții; un F mare, cu un p-value mic: mediile lunare diferă

Noțiuni necesare azi (14/21): termeni Fourier și regresia armonică dinamică

- ▣ **Termeni Fourier** pentru o perioadă m


$$\sin\left(\frac{2\pi kt}{m}\right), \quad \cos\left(\frac{2\pi kt}{m}\right), \quad k = 1, \dots, K$$

- ▶ k : armonica, o undă cu k cicluri pe perioadă; K : numărul de perechi
- ▶ $2K$ coeficienți în locul celor $m - 1$ variabile dummy; m poate fi neîntreg (365,25 de zile într-un an)
- ▣ **DHR** (dynamic harmonic regression, regresia armonică dinamică): termeni Fourier, variabile dummy de calendar și erori ARMA

$$y_t = \beta_0 + \sum_{k=1}^K \left[a_k \sin \frac{2\pi kt}{m} + b_k \cos \frac{2\pi kt}{m} \right] + \gamma^\top \mathbf{x}_t + u_t$$

- ▶ a_k, b_k : ponderile armoniciei k ; $\mathbf{x}_t$: variabile dummy pentru zilele săptămânii și sărbători, cu coeficienții γ ; u_t : erori ARMA
- ▶ TBATS și Prophet (Cursul 4): variante automate ale aceleiași idei, cu mai multe perioade

Noțiuni necesare azi (15/21): armonici și un tipar anual



- Stînga: primele trei armonici, cu 1, 2 și 3 cicluri pe an
- Dreapta: un tipar anual cu o scădere la trecerea dintre ani, ajustat prin metoda celor mai mici pătrate
 - ▶ ponderea varianței explicate: 86% cu $K = 1$, 97% cu $K = 2$, 98% cu $K = 4$
 - ▶ scăderea scurtă de sărbători rămîne: este nevoie de o variabilă dummy, nu de mai multe armonici

Noțiuni necesare azi (16/21): măsuri ale acurateții prognozelor

- ▣ Erorile de prognoză $e_i = y_i - \hat{y}_i$, $i = 1, \dots, n$, adunate pe toate originile și orizonturile


$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |e_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n e_i^2}, \quad \text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{e_i}{y_i} \right|$$

- ▶ MAE (mean absolute error, eroarea absolută medie), RMSE (root mean squared error, rădăcina erorii pătratice medii): în unitățile lui y ; RMSE penalizează mai mult erorile mari
- ▶ MAPE (mean absolute percentage error, eroarea procentuală absolută medie): în %, are sens doar pentru y_i departe de 0
- ▣ **MASE**: MAE raportată la metoda sezonieră naivă în eșantion

$$\text{MASE} = \frac{\text{MAE}}{\frac{1}{T-s} \sum_{t=s+1}^T |y_t - y_{t-s}|}$$

- ▶ MASE (mean absolute scaled error, eroarea absolută medie scalată) < 1 : mai bună decât prognoza sezonieră naivă în eșantion; comparabilă între serii

Noțiuni necesare azi (17/21): validarea încrucișată pentru serii de timp

Origins $T_1 < T_2 < \dots$ 

- **Originea mobilă:** nu folosim niciodată viitorul
 - ▶ la fiecare origine T_i : estimăm pe datele pînă la T_i
 - ▶ apoi prognozăm $h = 1, \dots, H$ pași înainte
- Erorile tuturor originilor și orizonturilor
 - ▶ dau MAE, RMSE și MASE
 - ▶ aici: 6 origini, cîte 6 pași, 36 de erori
- Erorile aceleiași origini se suprapun
 - ▶ sînt corelate, deci testele folosesc o valoare pe origine

Noțiuni necesare azi (18/21): testul Diebold–Mariano

- ▣ **Diferența de pierdere** dintre două prognoze ale acelorași valori

$$d_t = L(e_{1t}) - L(e_{2t}), \quad L(e) = e^2 \text{ sau } |e|$$


- ▶ e_{1t} , e_{2t} : erorile prognozelor 1 și 2; $\bar{d}$: media lui d_t pe n valori; H_0 : $E[d_t] = 0$ (acuratețe egală)

- ▣ Statistica **DM** pentru pierderi la un pas (sau care nu se suprapun) și corecția **HLN**

$$DM = \frac{\bar{d}}{\sqrt{\hat{\sigma}_d^2/n}}, \quad \hat{\sigma}_d^2 = \frac{1}{n} \sum_t (d_t - \bar{d})^2, \quad HLN = \sqrt{\frac{n-1}{n}} DM$$

- ▶ HLN (Harvey, Leybourne și Newbold): o corecție de eșantion mic, comparată cu distribuția Student $t(n-1)$
- ▶ $\bar{d} < 0$: prognoza 1 este mai precisă; respingem H_0 dacă $|HLN| > t_{0,975}(n-1)$
- ▶ valori critice de 5%: $t_{0,975}(5) = 2,571$, $t_{0,975}(7) = 2,365$

Noțiuni necesare azi (19/21): un test Diebold–Mariano pe erori simulate



- Erori simulate a două prognoze, $n = 30$; erorile pătratice medii 0,80 și 1,15
- $\bar{d} = -0,35$: prognoza 1 este mai bună în medie, dar d_t este foarte dispersată
 - ▶ HLN = $-1,03$ este în intervalul $\pm 2,045$: acuratețea egală nu se respinge (p-value 0,31)

Noțiuni necesare azi (20/21): combinarea prognozelor

- ▣ **Prognoza combinată:** o medie ponderată a două prognoze

$$f_c = w f_1 + (1 - w) f_2$$

- ▶ f_1, f_2 : cele două prognoze; w : ponderea lui f_1

- ▣ **MSE** (mean squared error, eroarea pătratică medie) a combinației, pentru prognoze nedeplasate

$$\text{MSE}(w) = w^2 \sigma_1^2 + (1 - w)^2 \sigma_2^2 + 2w(1 - w)\rho\sigma_1\sigma_2$$


- ▶ σ_1, σ_2 : abaterile standard ale celor două erori; ρ : corelația erorilor

- ▣ **Ponderea optimă:** valoarea w care minimizează $\text{MSE}(w)$

$$w^* = \frac{\sigma_2^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}$$

- ▶ câștigul față de prognoza mai bună este mare când ρ este mic sau negativ

Noțiuni necesare azi (21/21): câștigul combinării



- $\sigma_1 = 1, \sigma_2 = 1.5$: prognoza 1 este mai bună singură
 - ▶ $w = 1$: $\text{MSE} = \sigma_1^2 = 1$
- $\rho = -0.5$: $w^* = 0.63$, MSE 0,36
 - ▶ erorile se compensează: o treime din MSE a prognozei 1
- $\rho = 0.3$: $w^* = 0.77$, MSE 0,87
- $\rho = 0.6$: $w^* = 0.93$, MSE 0,99
 - ▶ erori asemănătoare: aproape niciun câștig

A1: diferențe sezoniere calculate de mînă [Rezolvat]

Cerință

- O serie trimestrială, $t = 1, \dots, 9$: 10, 14, 16, 18, 12, 16, 19, 21, 14.
- 1. Calculați $\Delta_4 y_t$ pentru $t = 5, \dots, 9$.
- 2. Calculați $\Delta\Delta_4 y_t$ pentru $t = 6, \dots, 9$.
- 3. Dezvoltați $(1 - L)(1 - L^4)$ și verificați rezultatul pentru $t = 9$.
- 4. Dați prognozele sezoniere naive pentru $t = 10, \dots, 13$.
- Raportați: treisprezece valori și o frază despre ce elimină Δ_4 .

Rezolvare

- 1. $\Delta_4 y$: 2; 2; 3; 3; 2 (de exemplu $12 - 10, 16 - 14$)
- 2. $\Delta\Delta_4 y$: 0; 1; 0; -1
- 3. $1 - L - L^4 + L^5$; $t = 9$: $14 - 21 - 12 + 18 = -1$
- 4. $\hat{y}_{10}, \dots, \hat{y}_{13} = 16; 19; 21; 14$ (ultimele patru valori)
- Δ_4 elimină un tipar sezonier care se repetă exact; valorile mici și stabile ale lui $\Delta_4 y$ arată creșterea de la un an la altul.

A2: polinoamele SARIMA [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Date lunare, $s = 12$. Model: A1.
- ▣ 1. Scrieți modelul airline SARIMA(0, 1, 1)(0, 1, 1)₁₂ cu $\theta = -0,4$, $\Theta = -0,6$ ca ecuație pentru y_t .
- ▣ 2. Enumerați lagurile lui y și ale lui ε care apar și coeficientul lui ε_{t-13} .
- ▣ 3. Dezvoltați $(1 - 0,5L)(1 - 0,3L^{12})$ pentru SARIMA(1, 0, 0)(1, 0, 0)₁₂.
- ▣ 4. Numărați parametrii modelului SARIMA(1, 1, 1)(1, 1, 1)₁₂, inclusiv σ^2 .
- ▣ Raportați: două ecuații, două liste de laguri și un număr.

A3: ACF a modelului airline [Rezolvat]

Cerință

- Modelul airline trimestrial:
 $w_t = \Delta\Delta_4 y_t = (1 - 0,5L)(1 - 0,6L^4)\varepsilon_t$,
 $\varepsilon_t \sim \text{WN}(0, \sigma^2)$.
- 1. Scrieți w_t ca MA(5) și enumerați coeficienții nenuli.
- 2. Calculați $\gamma(0)/\sigma^2$.
- 3. Calculați $\rho_1, \dots, \rho_5$.
- 4. Precizați cum ar trebui să arate ACF de selecție a lui w_t .
- Raportați: cinci autocorelații și o frază.

Rezolvare

- 1. $w_t = \varepsilon_t - 0,5\varepsilon_{t-1} - 0,6\varepsilon_{t-4} + 0,3\varepsilon_{t-5}$
- 2. $\gamma(0)/\sigma^2 = 1 + 0,25 + 0,36 + 0,09 =$
 $(1 + 0,25)(1 + 0,36) = 1,70$
- 3. $\rho_1 = -0,5/1,25 = -0,400$; $\rho_4 = -0,6/1,36 = -0,441$;
 $\rho_3 = \rho_5 = \rho_1\rho_4 = 0,176$; $\rho_2 = 0$
- 4. Valori semnificative la lagurile 1 și 4, cu „sateliți” mici la 3 și 5; nimic după lagul 5: semnătura modelului airline.

A4: un AR sezonier și estimări prin metoda momentelor [Propus]

Rezolvarea se discută la seminar

Cerință

- Model: A3.
- 1. Pentru $y_t = 0,7y_{t-4} + \varepsilon_t$, calculați ρ_4 , ρ_8 , ρ_{12} și precizați care alte laguri sînt zero.
- 2. Descrieți PACF a acestui proces.
- 3. ACF de selecție a lui $\Delta\Delta_{12}y_t$ este $-0,40$ la lagul 1, $-0,45$ la lagul 12, mică la lagurile 11 și 13 și în interiorul benzii în rest; propuneți un model.
- 4. Estimați θ și Θ din ρ_1 și ρ_{12} , păstrînd rădăcinile invertibile.
- Raportați: trei autocorelații, un model și două estimări.

A5: MASE și testul Diebold–Mariano [Rezolvat]

Cerință

- ▣ Șase ferestre de prognoză care nu se suprapun; erorile metodei 1: 0,4; -0,6; 0,9; -0,3; 0,5; -0,8; ale metodei 2: 1,1; -0,9; 0,7; -1,2; 0,8; -1,0; MAE în eșantion a metodei sezoniere naive este 1.
- ▣ 1. Calculați MAE și MASE pentru ambele metode.
- ▣ 2. Calculați $d_t = e_{1t}^2 - e_{2t}^2$, $\bar{d}$ și $\hat{\sigma}_d^2$.
- ▣ 3. Calculați DM și HLN.
- ▣ 4. Decideți la 5% cu distribuția $t(5)$.
- ▣ Raportați: patru măsuri de acuratețe, statistica testului și o decizie.

Rezolvare

- ▣ 1. MAE: 0,583 și 0,950; MASE: aceleași (scala 1): ambele sub 1, metoda 1 mai bună
- ▣ 2. d : -1,05; -0,45; 0,32; -1,35; -0,39; -0,36;
 $\bar{d} = -0,547$; $\hat{\sigma}_d^2 = 0,2864$
- ▣ 3. $DM = -0,547 / \sqrt{0,2864/6} = -2,50$;
 $HLN = 0,913 \cdot (-2,50) = -2,28$
- ▣ 4. $|-2,28| < 2,571$ ($p = 0,071$): acuratețea egală nu se respinge; șase ferestre sînt prea puține pentru a dovedi avantajul vizibil.

A6: două prognoze și combinarea lor [Propus]

Rezolvarea se discută la seminar



Cerință

- Opt ferestre; erorile e_1 : 2,0; -1,5; 1,0; -2,5; 3,0; 0,5; -1,0; 1,5; e_2 : 1,0; -2,5; 2,0; -0,5; 1,5; 2,0; -2,0; 0,5. Model: A5.
- 1. Calculați MAE pentru ambele metode și statisticile DM și HLN cu pierderi pătratice.
- 2. Decideți la 5% cu distribuția $t(7)$.
- 3. Combinarea cu ponderi egale are erorile $(e_1 + e_2)/2$: calculați MAE și RMSE ale acesteia.
- 4. Pentru prognoze nedeplasate cu $\sigma_1 = 2$, $\sigma_2 = 3$, $\rho = 0,3$, calculați $MSE(0,5)$, w^* și $MSE(w^*)$.
- Raportați: șase valori, o decizie și trei valori pentru combinare.

B1: modelul airline pentru PIB-ul României [Rezolvat]

- ▣ **Întrebarea:** cât de stabil este tiparul sezonier al PIB-ului României și ce prognozează modelul airline pentru următoarele patru trimestre?
- ▣ **Date:** Eurostat, PIB real neajustat, T1 2000–T2 2026, $T = 106$; $y_t = 100 \ln Y_t$
- ▣ **Cerințe**
 1. Estimați SARIMA(0, 1, 1)(0, 1, 1)₄ prin verosimilitate maximă și raportați $\hat{\theta}$, $\hat{\sigma}^2$ și erorile lor standard.
 2. Testați reziduurile cu Ljung–Box $Q^*(8)$, cu $8 - 2 = 6$ grade de libertate.
 3. Prognozați următoarele patru trimestre, în mld. EUR, cu intervale de 95%.
 4. Calculați creșterea anuală implicată pentru fiecare trimestru prognozat.
 5. Interpretare: ce spune $\hat{\sigma}^2$ despre cât de repede se schimbă tiparul sezonier al PIB-ului?
- ▣ **Raportați:** două estimări cu erorile standard, un test, patru prognoze cu intervale și o frază
- ▣ Notebook: secțiunea B1

B1: rezolvare (1/2) [Rezolvat]



----- $\pm 1.96/\sqrt{T}$

— GDP, not adjusted (bn EUR)

—•— forecast

95% interval

B1: rezolvare (2/2) [Rezolvat]

- $\hat{\theta} = -0,171$ (0,109): nesemnificativ; $\hat{\Theta} = -0,585$ (0,072); $\hat{\sigma} = 3,05\%$; $Q^*(8) = 9,30$, $p = 0,157$: fără autocorelație în reziduuri
- Prognozele din T3 2026: 53,1; 58,7; 38,7; 46,1 mld. EUR; primul interval [50,0; 56,4], al patrulea [41,5; 51,2]
- Creșterea anuală implicată: $-0,84\%$; $0,52\%$; $0,83\%$; $0,53\%$
- Interpretare: prognoza sezonieră este o medie ponderată exponențial a tiparelor sezoniere trecute, cu ponderea $1 + \hat{\Theta} = 0,42$ pentru anul cel mai recent; $\Theta = -1$ ar însemna un tipar fix, $\Theta = 0$ un tipar care se schimbă liber: tiparul PIB-ului evoluează lent


B2: producția industrială și zilele lucrătoare [Propus]

- **Întrebarea:** explică numărul zilelor lucrătoare o parte din mișcările lunare ale producției industriale din România?
- **Date:** Eurostat, producția industrială neajustată, 2010–iulie 2026, $y_t = 100 \ln Y_t$; variabile dummy pentru aprilie și mai 2020; model: B1
- **Cerințe**
 1. Estimați modelul airline cu și fără numărul zilelor lucrătoare ca regresor și comparați AICc și $Q^*(24)$.
 2. Adăugați două alternative cu zile lucrătoare, $(2, 1, 0)(0, 1, 1)_{12}$ și $(1, 1, 1)(0, 1, 1)_{12}$, și alegeți un model.
 3. Raportați coeficientul zilelor lucrătoare cu eroarea lui standard și prognozați următoarele 12 luni.
 4. Interpretare: de ce trebuie eliminat efectul zilelor lucrătoare înainte de a compara două luni?
- **Raportați:** un tabel cu AICc și p-value-uri, un coeficient, graficul prognozei și o frază
- Notebook: secțiunea B2

B3: validare încrucișată pentru consumul zilnic de electricitate [Rezolvat]

- **Întrebarea:** prognozează o regresie cu termeni Fourier și variabile dummy pentru sărbători consumul zilnic mai bine decât SARIMA și metoda sezonieră naivă?
- **Date:** ENTSO-E, consumul mediu zilnic în România (GW), 2022–2026; 13 origini la 28 de zile, de la 30 iunie 2025 la 1 iunie 2026, orizont de 14 zile
- **Cerințe**
 1. La fiecare origine, estimați metoda sezonieră naivă (perioada 7), SARIMA(1, 0, 1)(0, 1, 1)₇ și o DHR (4 perechi Fourier anuale, variabile dummy pentru zilele săptămânii și sărbători, erori ARMA(1,1)).
 2. Calculați MAE și MASE pentru fiecare metodă, pe toate originile și orizonturile.
 3. Testați DHR față de SARIMA cu testul DM pe media erorilor pătratice din fiecare fereastră (o valoare pe origine), cu corecția HLN.
 4. Comparați MAE în zilele de sărbătoare legală cu MAE în zilele obișnuite.
 5. Interpretare: de ce este câștigul DHR cel mai mare în zilele de sărbătoare legală?
- **Raportați:** un tabel cu MAE și MASE, un test, graficul și o frază
- Notebook: secțiunea B3

B3: rezolvare (1/2) [Rezolvat]



B3: rezolvare (2/2) [Rezolvat]

Metoda	MAE (MW)	MASE	sărbători	alte zile
Sezonieră naivă	395	1,28	723	372
SARIMA	340	1,10	630	319
DHR	289	0,94	422	280

- Scala MASE: MAE în eșantion a metodei sezoniere naive săptămânale, 309 MW; DM (HLN), DHR față de SARIMA: $-1,96$, $p = 0,073$; față de metoda sezonieră naivă: $-2,73$, $p = 0,018$
- Interpretare: SARIMA și metoda sezonieră naivă folosesc doar valoarea de „acum o săptămână”; o sărbătoare care cade într-o zi lucrătoare arată pentru ele ca o zi obișnuită, în timp ce DHR are variabile dummy care scad 0,37 GW într-o zi de sărbătoare legală și 0,56 GW în zilele de Paște

B4: sezonalitatea inflației lunare [Propus]

- **Întrebarea:** este tiparul sezonier al inflației lunare din România suficient de puternic pentru a îmbunătăți prognozele pe o lună?
- **Date:** IAPC, România, 2010–2026; $\pi_t = 100 \Delta \ln P_t$ (% pe lună); model: B3
- **Cerințe**
 1. Regresați π_t (2010–2019) pe 12 variabile dummy lunare și testați egalitatea mediilor lunare cu un test F .
 2. Estimați modelul airline pentru $100 \ln P_t$ și raportați $\hat{\theta}$ și $\hat{\Theta}$.
 3. Din origini lunare începînd cu ianuarie 2016, prognozați π din luna următoare cu SARIMA, metoda sezonieră naivă și media ultimelor 12 luni; comparați MAE.
 4. Testați SARIMA față de ambele repere cu testul DM (erori pătratice).
 5. Interpretare: este tiparul sezonier suficient de puternic pentru a îmbunătăți prognozele pe o lună?
- **Raportați:** un test F , două estimări, trei valori MAE, două teste DM și o frază
- Notebook: secțiunea B4

C1: turismul după pandemie [Propus]

- ▣ **Întrebarea:** ce eșantion de antrenare dă prognoze mai bune ale înnoptărilor turistice pentru 2023–2025: datele pînă în 2019 sau datele pînă în 2022?
- ▣ **Date:** Eurostat, înnoptări în unitățile de cazare turistică, România, lunar, 2005–2025; model: B1
- ▣ **Cerințe**
 1. Estimați modelul airline pentru $\ln y_t$ pînă în decembrie 2019 și prognozați 2023–2025.
 2. Repetați cu datele pînă în decembrie 2022.
 3. Comparați ambele cu prognoza sezonieră naivă care repetă anul 2022, folosind MAPE (eroarea procentuală absolută medie).
 4. Propuneți un tratament mai bun pentru 2020–2021 (variabile dummy de intervenție, un eșantion mai scurt, TBATS sau Prophet) și schițați-l ca proiect de echipă.
- ▣ **Raportați:** trei valori MAPE, graficul și un plan de proiect
- ▣ Notebook: secțiunea C1

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI informații despre modelele sezoniere. Răspunsul:
- (a) SARIMA(0,1,1)(0,1,1)₄ are patru parametri MA, la lagurile 1, 4 și 5, plus varianța zgomotului.
- (b) Dacă ACF a seriei lunare diferențiate are o singură valoare semnificativă la lagul 12, iar PACF descrește la 12, 24, 36, folosiți un AR(1) sezonier.
- (c) PIB-ul neajustat al României a scăzut cu aproximativ 34% în primul trimestru din 2026 față de al patrulea trimestru din 2025: o recesiune profundă.
- (d) $DM = -2,3$ cu $d = L(e_1) - L(e_2)$ arată că prognoza 2 este semnificativ mai precisă.
- (e) TBATS cu perioadele 7 și 365,25 surprinde scăderea consumului de electricitate de Paște.
- (f) Media cu ponderi egale a două prognoze nedeplasate nu are niciodată un MSE mai mare decât media celor două MSE.
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu, dați afirmația corectă și, unde se poate, valoarea corectă din notebook (secțiunea C2).
 - ▶ 2. Raportați: o listă de șase verdicte, fiecare cu un rând de justificare.

Idei de reținut

- ▣ Δ_s elimină un tipar sezonier stabil; $\Delta\Delta_s$ elimină și trendul; prognoza sezonieră naivă este reperul
- ▣ SARIMA înmulțește un polinom obișnuit și unul sezonier: modelul airline are doi parametri și valori nenule ale ACF la 1, $s - 1$, s , $s + 1$
- ▣ Efectele de calendar (zile lucrătoare, Paște, sărbători legale) sînt cunoscute dinainte: introduceți-le ca regresori
- ▣ Comparați prognozele în afara eșantionului, cu origini mobile, MASE și testul DM; un câștig vizibil nu este întotdeauna unul semnificativ
- ▣ Combinarea prognozelor este o asigurare ieftină: rareori este cea mai slabă și deseori este aproape de cea mai bună

După seminar

- Cursul 4 deduce formulele de azi și adaugă rădăcinile unitare sezoniere, ajustarea sezonieră (X-13ARIMA-SEATS), sezonalitatea multiplă, TBATS și Prophet
- Încercați cerințele [Propus] în notebook; TBATS și Prophet se instalează opțional acolo
- C1 poate deveni un proiect de echipă: prognoza turismului sau a consumului de electricitate din România, cu o comparație pe origini mobile a mai multor modele
- Lectură: Huang și Petukhina (2022), cap. 4–5; FPP3, secțiunea 9.9; FPP3, secțiunea 5.10; Diebold și Mariano (1995)
- **Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar**

Bibliografie

- ▣ Bates, J. M., & Granger, C. W. J. (1969). The combination of forecasts. *Journal of the Operational Research Society*, 20(4), 451–468. doi:10.1057/jors.1969.103
- ▣ Box, G. E. P., Jenkins, G. M., & Reinsel, G. C. (2008). *Time Series Analysis: Forecasting and Control* (4th ed.). Wiley. doi:10.1002/9781118619193
- ▣ Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- ▣ Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281–291. doi:10.1016/S0169-2070(96)00719-4
- ▣ Huang, C., & Petukhina, A. (2022). *Applied Time Series Analysis and Forecasting with Python*. Springer. doi:10.1007/978-3-031-13584-2
- ▣ Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. otexts.com/fpp3
- ▣ Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. doi:10.1016/j.ijforecast.2006.03.001
- ▣ Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303. doi:10.1093/biomet/65.2.297
- ▣ Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: an analysis and review. *International Journal of Forecasting*, 16(4), 437–450. doi:10.1016/S0169-2070(00)00065-0