



## Serii de timp

Seminarul 4: Sezonabilitate și prognoză: SARIMA, TBATS, Prophet



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

## Acronime folosite în acest material (1/2)

- ▣ **ACF**: Autocorrelation Function (funcția de autocorelație)
- ▣ **AI**: Artificial Intelligence (inteligență artificială)
- ▣ **AR**: AutoRegressive (model) — model autoregresiv
- ▣ **ARMA**: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **DHR**: Dynamic Harmonic Regression (regresie armonică dinamică)
- ▣ **DM**: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ **ENTSO-E**: European Network of Transmission System Operators for Electricity (rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică)
- ▣ **HLN**: Harvey–Leybourne–Newbold (small-sample correction of the DM test) — corecția Harvey–Leybourne–Newbold a testului DM pentru eșantioane mici
- ▣ **IAPC**: Indicele armonizat al prețurilor de consum
- ▣ **MA**: Moving Average (medie mobilă)
- ▣ **MAE**: Mean Absolute Error (eroarea absolută medie)

## Acronime folosite în acest material (2/2)

- ▣ **MAPE**: Mean Absolute Percentage Error (eroarea procentuală absolută medie)
- ▣ **MASE**: Mean Absolute Scaled Error (eroarea absolută medie scalată)
- ▣ **MSE**: Mean Squared Error (eroarea pătratică medie)
- ▣ **PACF**: Partial AutoCorrelation Function (funcția de autocorelație parțială)
- ▣ **PIB**: Produsul intern brut
- ▣ **RMSE**: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ **SARIMA**: Seasonal ARIMA (model) — model ARIMA sezonier
- ▣ **SCA**: Seasonally and Calendar Adjusted (ajustat sezonier și pentru efectele de calendar)
- ▣ **TBATS**: Trigonometric seasonality, Box–Cox, ARMA errors, Trend, Seasonal components (model) — model cu sezonalitate trigonometrică, transformare Box–Cox, erori ARMA, trend și componente sezoniere
- ▣ **WD**: Working Days (regressor) — zile lucrătoare (regresor)

## Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum modelăm, prognozăm și comparăm prognozele unor serii care repetă un tipar în fiecare an, săptămână sau zi?
  - ▶ seminarul are loc **înaintea** Cursului 4: secțiunea „Noțiuni necesare azi” dă toate formulele folosite în cerințe
- ▣ Traseul
  - ▶ Partea A: diferențe sezoniere, polinoamele și autocorelațiile SARIMA, testul Diebold–Mariano și combinarea prognozelor, pe hîrtie
  - ▶ Partea B: PIB-ul României, producția industrială, consumul zilnic de electricitate și inflația lunară
  - ▶ Partea C: turismul după pandemie și un răspuns AI de verificat
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); fiecare cerință indică secțiunea din notebook

## Harta exercițiilor

| Cerința | Întrebarea                                                                 | Tipul            | Model  |
|---------|----------------------------------------------------------------------------|------------------|--------|
| A1, A2  | diferențe sezoniere și prognoze sezoniere naive; polinoamele SARIMA        | Rezolvat, Propus | A1     |
| A3, A4  | ACF a modelului airline; un AR sezonier și estimări prin metoda momentelor | Rezolvat, Propus | A3     |
| A5, A6  | MASE și testul Diebold–Mariano; combinarea a două prognoze                 | Rezolvat, Propus | A5     |
| B1, B2  | SARIMA: PIB-ul României; producția industrială cu zile lucrătoare          | Rezolvat, Propus | B1     |
| B3, B4  | validare încrucișată: consumul de electricitate; inflația lunară           | Rezolvat, Propus | B3     |
| C1, C2  | turismul după pandemie; ce este greșit într-un răspuns AI?                 | Propus           | B1, A5 |

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model

## Datele folosite

| Seria                     | Sursa                    | Frecvența                     | Perioada  |
|---------------------------|--------------------------|-------------------------------|-----------|
| PIB real, neajustat       | Eurostat (namq_10_gdp)   | trimestrial                   | 2000–2026 |
| Producția industrială     | Eurostat (sts_inpr_m)    | lunar, 2021 = 100             | 2010–2026 |
| Consumul de electricitate | ENTSO-E                  | media zilnică a datelor orare | 2022–2026 |
| IAPC, România             | Eurostat (prc_hicp_minr) | lunar, 2015 = 100             | 2010–2026 |
| Înnoptări turistice       | Eurostat (tour_occ_nim)  | lunar                         | 2005–2025 |

- ▣ Logaritmi înmulțiți cu 100:  $100 \ln Y_t$ , astfel încât diferențele sînt rate de creștere în %
- ▣ ENTSO-E: rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică; consumul este exprimat în MW (media orară)
- ▣ În notebook: `fit_sarima`, `b1_gdp()`, `b3_load_cv()`; nu este nevoie de cont sau de cheie

## Noțiuni necesare azi (1/5): sezonalitate și diferențe sezoniere

- **Sezonalitatea:** un tipar care se repetă cu o **perioadă** fixă  $s$ :  $s = 4$  (trimestre),  $s = 12$  (luni),  $s = 7$  (zilele săptămânii),  $s = 24$  (orele zilei)
  - ▶ cauze: vremea, calendarul (zile lucrătoare, sărbători), instituțiile (termene fiscale, anul școlar)
- **Diferența sezonieră:**  $\Delta_s y_t = (1 - L^s)y_t = y_t - y_{t-s}$ ; cu logaritmi,  $100 \Delta_4 \ln Y_t$  este rata de creștere față de același trimestru al anului anterior
  - ▶  $L$ : operatorul lag,  $L^s y_t = y_{t-s}$ ;  $\Delta_s y_t$  compară fiecare valoare cu același sezon din anul anterior
  - ▶ ambele diferențe:  $\Delta \Delta_s y_t = (1 - L)(1 - L^s)y_t = y_t - y_{t-1} - y_{t-s} + y_{t-s-1}$
- **Prognoza sezonieră naivă:**  $\hat{y}_{T+h} = y_{T+h-s}$  pentru  $h \leq s$ : valoarea din același sezon cu o perioadă în urmă ([Capitolul 0](#))
  - ▶ reperul pe care orice model sezonier trebuie să îl depășească

## Noțiuni necesare azi (2/5): modele SARIMA

- **SARIMA**( $p, d, q$ )( $P, D, Q$ ) $_s$ :  $\phi(L)\Phi(L^s)(1-L)^d(1-L^s)^D y_t = \theta(L)\Theta(L^s)\varepsilon_t$ 
  - ▶  $\phi(L)$ ,  $\theta(L)$ : polinoamele AR și MA obișnuite (ordinea  $p$ ,  $q$ , [Capitolul 2](#));  $d$ ,  $D$ : numerele de diferențe obișnuite și sezoniere
  - ▶  $\Phi(L^s) = 1 - \phi_1 L^s - \dots - \phi_P L^{Ps}$  (AR sezonier),  $\Theta(L^s) = 1 + \theta_1 L^s + \dots + \theta_Q L^{Qs}$  (MA sezonier)
  - ▶ polinoamele se **înmulțesc**: apar termeni încrucișați precum  $\theta\Theta L^{s+1}$ , fără parametri noi
- **Modelul airline** (Box și Jenkins): SARIMA(0, 1, 1)(0, 1, 1) $_s$ 
  - ▶  $w_t = \Delta\Delta_s y_t = (1 + \theta L)(1 + \Theta L^s)\varepsilon_t$ : doi parametri,  $\theta$  și  $\Theta$
  - ▶ ACF pentru  $w_t$ :  $\rho_1 = \frac{\theta}{1+\theta^2}$ ,  $\rho_s = \frac{\Theta}{1+\Theta^2}$ ,  $\rho_{s-1} = \rho_{s+1} = \rho_1\rho_s$ , celelalte laguri 0
- **Identificarea** la lagurile sezoniere  $s, 2s, 3s$ : ca în [Capitolul 2](#), dar cu un sezon distanță
  - ▶ ACF se anulează după lagul  $s$ , PACF descrește la  $s, 2s, \dots$ : MA(1) sezonier; invers: AR(1) sezonier

## Noțiuni necesare azi (3/5): regresori de calendar și termeni Fourier

- **Regresia cu erori SARIMA:**  $y_t = \beta^\top x_t + u_t$ ,  $u_t \sim \text{SARIMA}$ ;  $x_t$  cunoscut dinainte: zile lucrătoare, sărbători, valori aberante
  - ▶  $x_t$ : vectorul regresorilor;  $\beta$ : coeficienții lor;  $u_t$ : eroarea, cu dinamică SARIMA
  - ▶ **zile lucrătoare:** numărul zilelor de luni până vineri din lună care nu sînt sărbători legale
  - ▶ cu  $100 \ln y_t$ , coeficientul unei variabile dummy este aproximativ efectul în %
- **Termeni Fourier** pentru o perioadă  $m$ :  $\sin(2\pi kt/m)$ ,  $\cos(2\pi kt/m)$ ,  $k = 1, \dots, K$ 
  - ▶  $k$ : armonica, o undă cu  $k$  cicluri pe perioadă;  $K$ : numărul de armonici folosite
  - ▶  $2K$  coeficienți în locul celor  $m - 1$  variabile dummy;  $m$  poate fi neîntreg (365,25 de zile într-un an)
  - ▶ **regresia armonică dinamică (DHR):** termeni Fourier plus variabile dummy de calendar, cu erori ARMA
- TBATS și Prophet (Cursul 4) sînt două variante automate ale aceleiași idei: mai multe perioade sezoniere, sezonalitate de tip Fourier

## Noțiuni necesare azi (4/5): compararea prognozelor

- **Validarea încrucișată pentru serii de timp:** originile  $T_1 < T_2 < \dots$ ; la fiecare origine, estimăm pe datele pînă la ea și prognozăm  $h$  pași
  - ▶  $e_i$ : cele  $n$  erori de prognoză adunate pe toate originile și orizonturile
  - ▶  $MAE = \frac{1}{n} \sum |e_i|$ ;  $RMSE = \sqrt{\frac{1}{n} \sum e_i^2}$ ;  $MASE = MAE / (MAE \text{ în eșantion a metodei sezoniere naive})$  (Capitolul 0)
- **Testul Diebold–Mariano (DM)** al acurateței egale:  $d_t = L(e_{1t}) - L(e_{2t})$ , pierderea  $L(e) = e^2$  sau  $|e|$ 
  - ▶  $e_{1t}, e_{2t}$ : erorile prognozelor 1 și 2;  $d_t$ : diferența de pierdere;  $\bar{d}$ : media ei pe cele  $n$  valori
  - ▶  $DM = \bar{d} / \sqrt{\hat{\sigma}_d^2 / n}$ ,  $\hat{\sigma}_d^2 = \frac{1}{n} \sum (d_t - \bar{d})^2$  pentru pierderi la un pas (sau care nu se suprapun)
  - ▶ corecția de eșantion mic (Harvey, Leybourne, Newbold):  $HLN = \sqrt{(n-1)/n} DM$ , comparată cu distribuția Student  $t(n-1)$
  - ▶  $\bar{d} < 0$ : prognoza 1 este mai precisă; valori critice de 5%:  $t_{0,975}(5) = 2,571$ ,  $t_{0,975}(7) = 2,365$

## Noțiuni necesare azi (5/5): combinarea prognozelor

□ **Combinarea prognozelor:**  $f_c = wf_1 + (1 - w)f_2$ ; pentru prognoze nedeplasate

▶  $f_1, f_2$ : cele două prognoze;  $w$ : ponderea lui  $f_1$ ;  $\sigma_1, \sigma_2$ : abaterile standard ale erorilor lor;  $\rho$ : corelația erorilor

▶  $MSE(w) = w^2\sigma_1^2 + (1 - w)^2\sigma_2^2 + 2w(1 - w)\rho\sigma_1\sigma_2$ ; cea mai bună pondere  $w^* = \frac{\sigma_2^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}$

▶ MSE: eroarea pătratică medie;  $w^*$  o minimizează; câștigul față de prognoza mai bună este mare când  $\rho$  este mic

## A1: diferențe sezoniere calculate de mînă [Rezolvat]

## Cerință

- O serie trimestrială,  $t = 1, \dots, 9$ : 10, 14, 16, 18, 12, 16, 19, 21, 14.
- 1. Calculați  $\Delta_4 y_t$  pentru  $t = 5, \dots, 9$ .
- 2. Calculați  $\Delta\Delta_4 y_t$  pentru  $t = 6, \dots, 9$ .
- 3. Dezvoltați  $(1 - L)(1 - L^4)$  și verificați rezultatul pentru  $t = 9$ .
- 4. Dați prognozele sezoniere naive pentru  $t = 10, \dots, 13$ .
- Raportați: treisprezece valori și o frază despre ce elimină  $\Delta_4$ .

## Rezolvare

- 1.  $\Delta_4 y$ : 2; 2; 3; 3; 2 (de exemplu  $12 - 10$ ,  $16 - 14$ )
- 2.  $\Delta\Delta_4 y$ : 0; 1; 0; -1
- 3.  $1 - L - L^4 + L^5$ ;  $t = 9$ :  $14 - 21 - 12 + 18 = -1$
- 4.  $\hat{y}_{10}, \dots, \hat{y}_{13} = 16; 19; 21; 14$  (ultimele patru valori)
- $\Delta_4$  elimină un tipar sezonier care se repetă exact; valorile mici și stabile ale lui  $\Delta_4 y$  arată creșterea de la un an la altul.

## A2: polinoamele SARIMA [Propus]

Rezolvarea se discută la seminar

### Cerință

- ▣ Date lunare,  $s = 12$ . Model: A1.
- ▣ 1. Scrieți modelul airline SARIMA(0, 1, 1)(0, 1, 1)<sub>12</sub> cu  $\theta = -0,4$ ,  $\Theta = -0,6$  ca ecuație pentru  $y_t$ .
- ▣ 2. Enumerați lagurile lui  $y$  și ale lui  $\varepsilon$  care apar și coeficientul lui  $\varepsilon_{t-13}$ .
- ▣ 3. Dezvoltați  $(1 - 0,5L)(1 - 0,3L^{12})$  pentru SARIMA(1, 0, 0)(1, 0, 0)<sub>12</sub>.
- ▣ 4. Numărați parametrii modelului SARIMA(1, 1, 1)(1, 1, 1)<sub>12</sub>, inclusiv  $\sigma^2$ .
- ▣ Raportați: două ecuații, două liste de laguri și un număr.

## A3: ACF a modelului airline [Rezolvat]

## Cerință

- Modelul airline trimestrial:  
 $w_t = \Delta\Delta_4 y_t = (1 - 0,5L)(1 - 0,6L^4)\varepsilon_t$ ,  
 $\varepsilon_t \sim \text{WN}(0, \sigma^2)$ .
- 1. Scrieți  $w_t$  ca MA(5) și enumerați coeficienții nenuli.
- 2. Calculați  $\gamma(0)/\sigma^2$ .
- 3. Calculați  $\rho_1, \dots, \rho_5$ .
- 4. Precizați cum ar trebui să arate ACF de selecție a lui  $w_t$ .
- Raportați: cinci autocorelații și o frază.

## Rezolvare

- 1.  $w_t = \varepsilon_t - 0,5\varepsilon_{t-1} - 0,6\varepsilon_{t-4} + 0,3\varepsilon_{t-5}$
- 2.  $\gamma(0)/\sigma^2 = 1 + 0,25 + 0,36 + 0,09 =$   
 $(1 + 0,25)(1 + 0,36) = 1,70$
- 3.  $\rho_1 = -0,5/1,25 = -0,400$ ;  $\rho_4 = -0,6/1,36 = -0,441$ ;  
 $\rho_3 = \rho_5 = \rho_1\rho_4 = 0,176$ ;  $\rho_2 = 0$
- 4. Valori semnificative la lagurile 1 și 4, cu „sateliți” mici la 3 și 5; nimic după lagul 5: semnătura modelului airline.

## A4: un AR sezonier și estimări prin metoda momentelor [Propus]

Rezolvarea se discută la seminar

### Cerință

- Model: A3.
- 1. Pentru  $y_t = 0,7y_{t-4} + \varepsilon_t$ , calculați  $\rho_4$ ,  $\rho_8$ ,  $\rho_{12}$  și precizați care alte laguri sînt zero.
- 2. Descrieți PACF a acestui proces.
- 3. ACF de selecție a lui  $\Delta\Delta_{12}y_t$  este  $-0,40$  la lagul 1,  $-0,45$  la lagul 12, mică la lagurile 11 și 13 și în interiorul benzii în rest; propuneți un model.
- 4. Estimați  $\theta$  și  $\Theta$  din  $\rho_1$  și  $\rho_{12}$ , păstrînd rădăcinile invertibile.
- Raportați: trei autocorelații, un model și două estimări.

## A5: MASE și testul Diebold–Mariano [Rezolvat]

## Cerință

- ▣ Șase ferestre de prognoză care nu se suprapun; erorile metodei 1: 0,4; -0,6; 0,9; -0,3; 0,5; -0,8; ale metodei 2: 1,1; -0,9; 0,7; -1,2; 0,8; -1,0; MAE în eșantion a metodei sezoniere naive este 1.
- ▣ 1. Calculați MAE și MASE pentru ambele metode.
- ▣ 2. Calculați  $d_t = e_{1t}^2 - e_{2t}^2$ ,  $\bar{d}$  și  $\hat{\sigma}_d^2$ .
- ▣ 3. Calculați DM și HLN.
- ▣ 4. Decideți la 5% cu distribuția  $t(5)$ .
- ▣ Raportați: patru măsuri de acuratețe, statistica testului și o decizie.

## Rezolvare

- ▣ 1. MAE: 0,583 și 0,950; MASE: aceleași (scala 1): ambele sub 1, metoda 1 mai bună
- ▣ 2.  $d$ : -1,05; -0,45; 0,32; -1,35; -0,39; -0,36;  
 $\bar{d} = -0,547$ ;  $\hat{\sigma}_d^2 = 0,2864$
- ▣ 3.  $DM = -0,547 / \sqrt{0,2864/6} = -2,50$ ;  
 $HLN = 0,913 \cdot (-2,50) = -2,28$
- ▣ 4.  $|-2,28| < 2,571$  ( $p = 0,071$ ): acuratețea egală nu se respinge; șase ferestre sînt prea puține pentru a dovedi avantajul vizibil.

## A6: două prognoze și combinarea lor [Propus]

Rezolvarea se discută la seminar



### Cerință

- Opt ferestre; erorile  $e_1$ : 2,0; -1,5; 1,0; -2,5; 3,0; 0,5; -1,0; 1,5;  $e_2$ : 1,0; -2,5; 2,0; -0,5; 1,5; 2,0; -2,0; 0,5. Model: A5.
- 1. Calculați MAE pentru ambele metode și statisticile DM și HLN cu pierderi pătratice.
- 2. Decideți la 5% cu distribuția  $t(7)$ .
- 3. Combinarea cu ponderi egale are erorile  $(e_1 + e_2)/2$ : calculați MAE și RMSE ale acesteia.
- 4. Pentru prognoze nedeplasate cu  $\sigma_1 = 2$ ,  $\sigma_2 = 3$ ,  $\rho = 0,3$ , calculați  $MSE(0,5)$ ,  $w^*$  și  $MSE(w^*)$ .
- Raportați: șase valori, o decizie și trei valori pentru combinare.

## B1: modelul airline pentru PIB-ul României [Rezolvat]

- ▣ **Întrebarea:** cât de stabil este tiparul sezonier al PIB-ului României și ce prognozează modelul airline pentru următoarele patru trimestre?
- ▣ **Date:** Eurostat, PIB real neajustat, T1 2000–T2 2026,  $T = 106$ ;  $y_t = 100 \ln Y_t$
- ▣ **Cerințe**
  1. Estimați SARIMA(0, 1, 1)(0, 1, 1)<sub>4</sub> prin verosimilitate maximă și raportați  $\hat{\theta}$ ,  $\hat{\sigma}^2$  și erorile lor standard.
  2. Testați reziduurile cu Ljung–Box  $Q^*(8)$ , cu  $8 - 2 = 6$  grade de libertate.
  3. Prognozați următoarele patru trimestre, în mld. EUR, cu intervale de 95%.
  4. Calculați creșterea anuală implicată pentru fiecare trimestru prognozat.
  5. Interpretare: ce spune  $\hat{\sigma}^2$  despre cât de repede se schimbă tiparul sezonier al PIB-ului?
- ▣ **Raportați:** două estimări cu erorile standard, un test, patru prognoze cu intervale și o frază
- ▣ Notebook: secțiunea B1

# B1: rezolvare (1/2) [Rezolvat]



-----  $\pm 1.96/\sqrt{T}$

— GDP, not adjusted (bn EUR)

—•— forecast

95% interval

TSA\_ch4\_seminar

## B1: rezolvare (2/2) [Rezolvat]

- $\hat{\theta} = -0,171$  (0,109): nesemnificativ;  $\hat{\Theta} = -0,585$  (0,072);  $\hat{\sigma} = 3,05\%$ ;  $Q^*(8) = 9,30$ ,  $p = 0,157$ : fără autocorelație în reziduuri
- Prognozele din T3 2026: 53,1; 58,7; 38,7; 46,1 mld. EUR; primul interval [50,0; 56,4], al patrulea [41,5; 51,2]
- Creșterea anuală implicată:  $-0,84\%$ ;  $0,52\%$ ;  $0,83\%$ ;  $0,53\%$
- Interpretare: prognoza sezonieră este o medie ponderată exponențial a tiparelor sezoniere trecute, cu ponderea  $1 + \hat{\Theta} = 0,42$  pentru anul cel mai recent;  $\Theta = -1$  ar însemna un tipar fix,  $\Theta = 0$  un tipar care se schimbă liber: tiparul PIB-ului evoluează lent


## B2: producția industrială și zilele lucrătoare [Propus]

- **Întrebarea:** explică numărul zilelor lucrătoare o parte din mișcările lunare ale producției industriale din România?
- **Date:** Eurostat, producția industrială neajustată, 2010–iulie 2026,  $y_t = 100 \ln Y_t$ ; variabile dummy pentru aprilie și mai 2020; model: B1
- **Cerințe**
  1. Estimați modelul airline cu și fără numărul zilelor lucrătoare ca regresor și comparați AICc și  $Q^*(24)$ .
  2. Adăugați două alternative cu zile lucrătoare,  $(2, 1, 0)(0, 1, 1)_{12}$  și  $(1, 1, 1)(0, 1, 1)_{12}$ , și alegeți un model.
  3. Raportați coeficientul zilelor lucrătoare cu eroarea lui standard și prognozați următoarele 12 luni.
  4. Interpretare: de ce trebuie eliminat efectul zilelor lucrătoare înainte de a compara două luni?
- **Raportați:** un tabel cu AICc și p-value-uri, un coeficient, graficul prognozei și o frază
- Notebook: secțiunea B2

## B3: validare încrucișată pentru consumul zilnic de electricitate [Rezolvat]

- ▣ **Întrebarea:** prognozează o regresie cu termeni Fourier și variabile dummy pentru sărbători consumul zilnic mai bine decât SARIMA și metoda sezonieră naivă?
- ▣ **Date:** ENTSO-E, consumul mediu zilnic în România (GW), 2022–2026; 13 origini la 28 de zile, de la 30 iunie 2025 la 1 iunie 2026, orizont de 14 zile
- ▣ **Cerințe**
  1. La fiecare origine, estimați metoda sezonieră naivă (perioada 7), SARIMA(1, 0, 1)(0, 1, 1)<sub>7</sub> și o DHR (4 perechi Fourier anuale, variabile dummy pentru zilele săptămânii și sărbători, erori ARMA(1,1)).
  2. Calculați MAE și MASE pentru fiecare metodă, pe toate originile și orizonturile.
  3. Testați DHR față de SARIMA cu testul DM pe media erorilor pătratice din fiecare fereastră (o valoare pe origine), cu corecția HLN.
  4. Comparați MAE în zilele de sărbătoare legală cu MAE în zilele obișnuite.
  5. Interpretare: de ce este câștigul DHR cel mai mare în zilele de sărbătoare legală?
- ▣ **Raportați:** un tabel cu MAE și MASE, un test, graficul și o frază
- ▣ Notebook: secțiunea B3

## B3: rezolvare (1/2) [Rezolvat]



## B3: rezolvare (2/2) [Rezolvat]

| Metoda          | MAE (MW)   | MASE        | sărbători | alte zile |
|-----------------|------------|-------------|-----------|-----------|
| Sezonieră naivă | 395        | 1,28        | 723       | 372       |
| SARIMA          | 340        | 1,10        | 630       | 319       |
| DHR             | <b>289</b> | <b>0,94</b> | 422       | 280       |

- Scala MASE: MAE în eșantion a metodei sezoniere naive săptămânale, 309 MW; DM (HLN), DHR față de SARIMA:  $-1,96$ ,  $p = 0,073$ ; față de metoda sezonieră naivă:  $-2,73$ ,  $p = 0,018$
- Interpretare: SARIMA și metoda sezonieră naivă folosesc doar valoarea de „acum o săptămână”; o sărbătoare care cade într-o zi lucrătoare arată pentru ele ca o zi obișnuită, în timp ce DHR are variabile dummy care scad 0,37 GW într-o zi de sărbătoare legală și 0,56 GW în zilele de Paște

## B4: sezonalitatea inflației lunare [Propus]

- ▣ **Întrebarea:** este tiparul sezonier al inflației lunare din România suficient de puternic pentru a îmbunătăți prognozele pe o lună?
- ▣ **Date:** IAPC, România, 2010–2026;  $\pi_t = 100 \Delta \ln P_t$  (% pe lună); model: B3
- ▣ **Cerințe**
  1. Regresați  $\pi_t$  (2010–2019) pe 12 variabile dummy lunare și testați egalitatea mediilor lunare cu un test  $F$ .
  2. Estimați modelul airline pentru  $100 \ln P_t$  și raportați  $\hat{\theta}$  și  $\hat{\Theta}$ .
  3. Din origini lunare începînd cu ianuarie 2016, prognozați  $\pi$  din luna următoare cu SARIMA, metoda sezonieră naivă și media ultimelor 12 luni; comparați MAE.
  4. Testați SARIMA față de ambele repere cu testul DM (erori pătratice).
  5. Interpretare: este tiparul sezonier suficient de puternic pentru a îmbunătăți prognozele pe o lună?
- ▣ **Raportați:** un test  $F$ , două estimări, trei valori MAE, două teste DM și o frază
- ▣ **Notebook:** secțiunea B4

## C1: turismul după pandemie [Propus]

- **Întrebarea:** ce eșantion de antrenare dă prognoze mai bune ale înnoptărilor turistice pentru 2023–2025: datele pînă în 2019 sau datele pînă în 2022?
- **Date:** Eurostat, înnoptări în unitățile de cazare turistică, România, lunar, 2005–2025; model: B1
- **Cerințe**
  1. Estimați modelul airline pentru  $\ln y_t$  pînă în decembrie 2019 și prognozați 2023–2025.
  2. Repetați cu datele pînă în decembrie 2022.
  3. Comparați ambele cu prognoza sezonieră naivă care repetă anul 2022, folosind MAPE (eroarea procentuală absolută medie).
  4. Propuneți un tratament mai bun pentru 2020–2021 (variabile dummy de intervenție, un eșantion mai scurt, TBATS sau Prophet) și schițați-l ca proiect de echipă.
- **Raportați:** trei valori MAPE, graficul și un plan de proiect
- Notebook: secțiunea C1

## C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI informații despre modelele sezoniere. Răspunsul:
- (a) SARIMA(0,1,1)(0,1,1)<sub>4</sub> are patru parametri MA, la lagurile 1, 4 și 5, plus varianța zgomotului.
- (b) Dacă ACF a seriei lunare diferențiate are o singură valoare semnificativă la lagul 12, iar PACF descrește la 12, 24, 36, folosiți un AR(1) sezonier.
- (c) PIB-ul neajustat al României a scăzut cu aproximativ 34% în primul trimestru din 2026 față de al patrulea trimestru din 2025: o recesiune profundă.
- (d)  $DM = -2,3$  cu  $d = L(e_1) - L(e_2)$  arată că prognoza 2 este semnificativ mai precisă.
- (e) TBATS cu perioadele 7 și 365,25 surprinde scăderea consumului de electricitate de Paște.
- (f) Media cu ponderi egale a două prognoze nedeplasate nu are niciodată un MSE mai mare decât media celor două MSE.
- Cerințe
  - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu, dați afirmația corectă și, unde se poate, valoarea corectă din notebook (secțiunea C2).
  - ▶ 2. Raportați: o listă de șase verdicte, fiecare cu un rând de justificare.

## Idei de reținut

- ▣  $\Delta_s$  elimină un tipar sezonier stabil;  $\Delta\Delta_s$  elimină și trendul; prognoza sezonieră naivă este reperul
- ▣ SARIMA înmulțește un polinom obișnuit și unul sezonier: modelul airline are doi parametri și valori nenule ale ACF la 1,  $s - 1$ ,  $s$ ,  $s + 1$
- ▣ Efectele de calendar (zile lucrătoare, Paște, sărbători legale) sînt cunoscute dinainte: introduceți-le ca regresori
- ▣ Comparați prognozele în afara eșantionului, cu origini mobile, MASE și testul DM; un câștig vizibil nu este întotdeauna unul semnificativ
- ▣ Combinarea prognozelor este o asigurare ieftină: rareori este cea mai slabă și deseori este aproape de cea mai bună

## După seminar

- Cursul 4 deduce formulele de azi și adaugă rădăcinile unitare sezoniere, ajustarea sezonieră (X-13ARIMA-SEATS), sezonalitatea multiplă, TBATS și Prophet
- Încercați cerințele [Propus] în notebook; TBATS și Prophet se instalează opțional acolo
- C1 poate deveni un proiect de echipă: prognoza turismului sau a consumului de electricitate din România, cu o comparație pe origini mobile a mai multor modele
- Lectură: Huang și Petukhina (2022), cap. 4–5; FPP3, secțiunea 9.9; FPP3, secțiunea 5.10; Diebold și Mariano (1995)
- **Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar**

## Bibliografie

- ▣ Bates, J. M., & Granger, C. W. J. (1969). The combination of forecasts. *Journal of the Operational Research Society*, 20(4), 451–468. doi:10.1057/jors.1969.103
- ▣ Box, G. E. P., Jenkins, G. M., & Reinsel, G. C. (2008). *Time Series Analysis: Forecasting and Control* (4th ed.). Wiley. doi:10.1002/9781118619193
- ▣ Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- ▣ Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281–291. doi:10.1016/S0169-2070(96)00719-4
- ▣ Huang, C., & Petukhina, A. (2022). *Applied Time Series Analysis and Forecasting with Python*. Springer. doi:10.1007/978-3-031-13584-2
- ▣ Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. [otexts.com/fpp3](https://otexts.com/fpp3)
- ▣ Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. doi:10.1016/j.ijforecast.2006.03.001
- ▣ Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303. doi:10.1093/biomet/65.2.297
- ▣ Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: an analysis and review. *International Journal of Forecasting*, 16(4), 437–450. doi:10.1016/S0169-2070(00)00065-0