



Serii de timp



Seminarul 5: Volatilitate condiționată: ARCH și GARCH

Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **ACF**: Autocorrelation Function (funcția de autocorelație)
- ▣ **AI**: Artificial Intelligence (inteligență artificială)
- ▣ **AR**: AutoRegressive (model) — model autoregresiv
- ▣ **AR-GARCH**: AR model for the mean with GARCH errors (model AR pentru medie cu erori GARCH)
- ▣ **ARCH**: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ **ARCH-LM**: ARCH Lagrange Multiplier (test) — testul multiplicatorului Lagrange pentru efecte ARCH
- ▣ **ARMA**: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **ARMA-GARCH**: ARMA model for the mean with GARCH errors (model ARMA pentru medie cu erori GARCH)
- ▣ **BET**: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BIC**: Bayesian Information Criterion (criteriul informațional bayesian al lui Schwarz)
- ▣ **BNR**: Banca Națională a României
- ▣ **DM**: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ **EGARCH**: Exponential GARCH (GARCH exponențial)
- ▣ **EODHD**: EOD Historical Data (market-data provider) — furnizor de date de piață

Acronime folosite în acest material (2/2)

- ▣ **EWMA**: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ **GJR**: Glosten–Jagannathan–Runkle (GARCH model) — modelul GARCH asimetric Glosten–Jagannathan–Runkle
- ▣ **GJR-GARCH**: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- ▣ **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- ▣ **IGARCH**: Integrated GARCH (GARCH integrat)
- ▣ **LM**: Lagrange Multiplier (multiplicatorul Lagrange)
- ▣ **LR**: Likelihood Ratio (test) — testul raportului de verosimilitate
- ▣ **MLE**: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- ▣ **OLS**: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **QLIKE**: Quasi-LIKelihood (loss function) — funcția de pierdere de tip cvasi-verosimilitate
- ▣ **SE**: Standard Error (eroare standard)

Întrebarea de azi și structura seminarului

- ▣ Întrebarea seminarului
 - ▶ **cum detectăm, modelăm, estimăm și prognozăm o varianță care se schimbă în fiecare zi?**
- ▣ Rezultate de obținut (nu se predă nimic)
 - ▶ răspunsurile la exercițiile A
 - ▶ câte o figură și un tabel pentru fiecare exercițiu B
 - ▶ răspunsul A1 corectat din [C2](#)
 - ▶ o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#)
 - ▶ fiecare cerință indică secțiunea din notebook
- ▣ Exercițiile, tipurile și ordinea lor: [harta exercițiilor](#) (slide-ul următor)
- ▣ Seminar: prof. Daniel Traian Pele, danpele@ase.ro

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	persistența, varianța de lungă durată, timpul de înjumătățire și un pas GARCH(1,1)	Rezolvat, Propus	A1
A3, A4	proгноze pe mai mulți pași, volatilitatea pe 10 zile și VaR 1%	Rezolvat, Propus	A3
A5, A6	un test ARCH-LM din rezultatele unei regresii; impactul știrilor în GJR și EGARCH	Rezolvat, Propus	A5, A1
B1, B2	efecte ARCH și AR(1)-GARCH(1,1)-t: BET; EUR/RON și Bitcoin	Rezolvat, Propus	B1
B3, B4	asimetria și efectul de levier: S&P 500; BET, EUR/RON, Bitcoin	Rezolvat, Propus	B3
B5, B6	GARCH față de EWMA în afara eșantionului, VaR 1%: S&P 500; BET, EUR/RON	Rezolvat, Propus	B5
C1, C2	este leul mai liniștit decât înainte? ce este greșit într-un răspuns AI?	Propus	B1, A1

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model; rezolvarea se discută la seminar
- Partea A: calcule pe hîrtie; Partea B: date reale, în notebook, fiecare cerință încheindu-se cu o întrebare de interpretare; Partea C: întrebări deschise și critica unui răspuns AI

Datele folosite

Seria	Sursa	Frecvența	Perioada
S&P 500, BET	EODHD	zilnic, închidere	2000–2026
EUR/RON	cursul de referință BNR	zilnic	2005–2026
Bitcoin	EODHD	zilnic, 7 zile pe săptămână	2014–2026

- Randamente logaritmice zilnice r_t , în % ([Noțiuni necesare 1/21](#)); weekendurile și închiderile repetate din zilele libere se elimină (cu excepția Bitcoin)
- EUR/RON variază cu circa 0,3% pe zi: notebook-ul estimează modelele pe 10 r_t și convertește rezultatele înapoi în %
- În notebook: `returns('bet')`, `arch_lm(x)`, `fit(r, mean='AR', dist='t')` (pachetul `arch`); nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/21): randamente, media condiționată și varianța condiționată

- ▣ **Randamentul logaritmic zilnic**, în %

$$r_t = 100 \ln \frac{P_t}{P_{t-1}}$$

- ▶ P_t : prețul de închidere (sau nivelul indicelui, cursul de schimb) din ziua t

- ▣ **Modelul pentru medie și volatilitate**: randamentul este o parte previzibilă plus un șoc scalat

$$r_t = \mu_t + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \text{ i.i.d., } E[z_t] = 0, \text{ Var}(z_t) = 1$$

- ▶ $\mathcal{F}_{t-1}$: informația pînă în ziua $t - 1$; $\mu_t = E[r_t | \mathcal{F}_{t-1}]$: **media condiționată** (un model ARMA, [Capitolul 2](#))
- ▶ $\sigma_t^2 = \text{Var}(r_t | \mathcal{F}_{t-1})$: **varianța condiționată**; σ_t : volatilitatea condiționată
- ▶ z_t : **inovațiile**; i.i.d.: independente și identic distribuite

- ▣ **Volatilitatea anualizată**: $\sqrt{252} s$ pentru randamente zilnice

- ▶ s : abaterea standard de selecție a lui r_t ; 252: numărul de zile de tranzacționare dintr-un an


Noțiuni necesare azi (2/21): volatility clustering și kurtosis-ul

- ▣ **Volatility clustering** Mandelbrot (1963): variațiile mari urmează după variații mari, cele mici după variații mici
 - ▶ randamentele zilnice sînt aproape necorelate, dar $|r_t|$ și r_t^2 sînt autocorelate pozitiv
 - ▶ în model: σ_t^2 se modifică lent, deci o zi agitată este urmată de alte zile agitate
- ▣ **Kurtosis-ul**: greutatea cozilor, măsurată prin momentul de ordinul patru

$$K = \frac{E[(r_t - \mu)^4]}{\sigma^4}, \quad \hat{K} = \frac{\frac{1}{T} \sum_{t=1}^T (r_t - \bar{r})^4}{\left(\frac{1}{T} \sum_{t=1}^T (r_t - \bar{r})^2\right)^2}$$

- ▶ μ, σ^2 : media și varianța necondiționate; $\bar{r}$: media de selecție; T : numărul de zile
- ▶ $K = 3$ pentru distribuția Normală; $K > 3$: cozi groase, mai multe zile extreme decît sub distribuția Normală
- ▶ un σ_t variabil în timp mărește K chiar dacă z_t are distribuția Normală

Noțiuni necesare azi (3/21): o serie GARCH simulată



- Stînga: randamente i.i.d. cu distribuția Normală; dreapta: randamente GARCH(1,1) cu aceeași varianță de lungă durată, 1
- Dreapta: perioadele liniștite și cele agitate alternează; banda $\pm 2\sigma_t$ se lărgțește după șocuri mari
 - kurtosis-ul de selecție: 3,07 (stînga) și 3,51 (dreapta), deși z_t are distribuția Normală în ambele

Noțiuni necesare azi (4/21): ACF și testul Ljung–Box

- ▣ **Autocorelația de selecție** la lagul k

$$\hat{\rho}_k = \frac{\sum_{t=k+1}^T (x_t - \bar{x})(x_{t-k} - \bar{x})}{\sum_{t=1}^T (x_t - \bar{x})^2}$$


- ▶ x_t : r_t , r_t^2 sau reziduurile; pentru zgomot alb $\hat{\rho}_k \approx N(0, 1/T)$: banda de 95% $\pm 1,96/\sqrt{T}$

- ▣ **Ljung–Box** Ljung și Box (1978): primele m autocorelații testate împreună

$$Q(m) = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k} \sim \chi^2(m)$$

- ▶ H_0 : $\rho_1 = \dots = \rho_m = 0$; valoarea de 5% a distribuției $\chi^2(10)$: 18,31
- ▶ pe r_t : predictibilitatea liniară a randamentelor; pe r_t^2 sau $\hat{\varepsilon}_t^2$: volatility clustering (efecte ARCH)

Noțiuni necesare azi (5/21): ACF a randamentelor și a pătratelor lor



- Seria GARCH de pe slide-ul anterior, $T = 2\,500$ de zile; banda $\pm 1,96/\sqrt{T} = \pm 0,039$
- r_t : în interiorul benzii, $Q(10) = 6,8$ sub 18,31: nicio predictibilitate liniară
 - r_t^2 : 0,21 la lagul 1, încă 0,12 la lagul 10; $Q(10) = 746$: volatility clustering puternic

Noțiuni necesare azi (6/21): testul ARCH-LM

- ▣ **ARCH-LM Engle (1982)**: o regresie OLS a pătratului reziduului de azi pe ultimele q pătrate

$$\hat{\varepsilon}_t^2 = a_0 + a_1 \hat{\varepsilon}_{t-1}^2 + \cdots + a_q \hat{\varepsilon}_{t-q}^2 + u_t$$

- ▶ $\hat{\varepsilon}_t$: reziduurile modelului pentru medie (de exemplu un AR(1)); a_j : coeficienții; u_t : eroarea
- ▶ OLS: metoda celor mai mici pătrate; H_0 : $a_1 = \cdots = a_q = 0$, fără efecte ARCH

- ▣ **Statistica**: numărul de observații înmulțit cu R^2 al regresiei

$$LM = nR^2 \sim \chi^2(q), \quad R^2 = 1 - \frac{RSS}{TSS}$$

- ▶ n : numărul de observații din regresie; RSS : suma pătratelor reziduurilor; TSS : suma totală a pătratelor abaterilor lui $\hat{\varepsilon}_t^2$
- ▶ valorile de 5%: $\chi^2(5)$ 11,07, $\chi^2(10)$ 18,31; LM peste valoare: respingem H_0

Noțiuni necesare azi (7/21): modelul ARCH(1)

- ▣ **ARCH(1)** Engle (1982): varianța de azi depinde de pătratul șocului de ieri

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2, \quad \omega > 0, \quad 0 \leq \alpha < 1$$

- ▶ ω : nivelul minim al varianței; α : reacția la pătratul șocului de ieri

- ▣ **Varianța necondiționată și kurtosis-ul** (z_t cu distribuția Normală, $3\alpha^2 < 1$)

$$\text{Var}(\varepsilon_t) = \frac{\omega}{1 - \alpha}, \quad K = \frac{3(1 - \alpha^2)}{1 - 3\alpha^2} > 3$$

- ▶ cu cât α este mai mare, cu atît cozile lui ε_t sînt mai groase, deși z_t are distribuția Normală
- ▶ un singur lag este rareori suficient: datele zilnice cer multe laguri ale lui ε^2 , de aici GARCH

Noțiuni necesare azi (8/21): modelul GARCH(1,1)

- ▣ **GARCH(1,1)** Bollerslev (1986): intră și varianța de ieri

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2, \quad \omega > 0, \quad \alpha, \beta \geq 0$$

- ▶ α : reacția la cel mai recent șoc; β : memoria, ponderea varianței de ieri

- ▣ **Persistența** $\alpha + \beta$ și **varianța de lungă durată** (dacă $\alpha + \beta < 1$)

$$\bar{\sigma}^2 = \frac{\omega}{1 - \alpha - \beta}, \quad \text{volatilitatea anuală} = \sqrt{252 \bar{\sigma}^2}$$

- ▶ $\alpha + \beta < 1$: staționar în covarianță, σ_t^2 revine la $\bar{\sigma}^2$; aproape de 1: șocurile durează mult

- ▣ **Timpul de înjumătățire**: numărul de zile în care dispare jumătate dintr-un șoc de varianță

$$h_{1/2} = \frac{\ln 0,5}{\ln(\alpha + \beta)}$$

- ▶ din $(\alpha + \beta)^h = 0,5$; $\alpha + \beta = 0,97$: circa 23 de zile

Noțiuni necesare azi (9/21): prognoze ale varianței

- Prognoze făcute la sfârșitul zilei t , cu $E_t[\cdot] = E[\cdot \mid \mathcal{F}_t]$

$$\sigma_{t+1}^2 = \omega + \alpha(r_t - \mu)^2 + \beta\sigma_t^2, \quad E_t[\sigma_{t+h}^2] = \bar{\sigma}^2 + (\alpha + \beta)^{h-1}(\sigma_{t+1}^2 - \bar{\sigma}^2)$$


- ▶ μ : media constantă; varianța de mîine este cunoscută azi; distanța față de $\bar{\sigma}^2$ scade cu factorul $\alpha + \beta$ pe zi

- **Varianța pe H zile:** suma prognozelor zilnice

$$\sum_{h=1}^H E_t[\sigma_{t+h}^2] = H\bar{\sigma}^2 + (\sigma_{t+1}^2 - \bar{\sigma}^2) \frac{1 - (\alpha + \beta)^H}{1 - \alpha - \beta}$$

- ▶ regula rădăcinii pătrate a timpului, $\sqrt{H}\sigma_{t+1}$, presupune că varianța rămîne σ_{t+1}^2 ; $\sqrt{H}\bar{\sigma}^2$ presupune că ea este deja $\bar{\sigma}^2$

Noțiuni necesare azi (10/21): revenirea la medie a prognozelor



- $E_t[\sigma_{t+h}^2]$ pentru $\bar{\sigma}^2 = 1$, pornind de la 3 (după un șoc) sau de la 0,4 (o perioadă calmă)
- Timpul de înjumătățire: 6,6 zile pentru $\alpha + \beta = 0,90$, 22,8 zile pentru 0,97 (punctele)
 - IGARCH, $\alpha + \beta = 1$: prognoza nu mai revine, fiecare orizont repetă σ_{t+1}^2

Noțiuni necesare azi (11/21): EWMA, IGARCH și AR-GARCH

- ▣ **EWMA** J.P. Morgan/Reuters (1996): o medie mobilă ponderată exponențial a lui r_t^2 (Capitolul 0)

$$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2 = (1 - \lambda) \sum_{j=1}^{\infty} \lambda^{j-1} r_{t-j}^2$$

- ▶ λ : ponderea varianței de ieri, 0,94 pentru date zilnice în RiskMetrics; niciun parametru de estimat

- ▣ **IGARCH** (GARCH integrat): $\alpha + \beta = 1$


- ▶ EWMA este un IGARCH cu $\omega = 0$: fără varianță de lungă durată și fără timp de înjumătățire

- ▣ **AR(1)-GARCH(1,1)**: un AR(1) pentru medie, cu erori GARCH, estimate împreună

$$r_t = c + \phi r_{t-1} + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad \sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

- ▶ c : termenul liber; ϕ : coeficientul AR(1); $-t$ în GARCH- t : inovații Student- t

Noțiuni necesare azi (12/21): ponderile EWMA



- Pondere a pătratului randamentului de acum j zile
 - ▶ $(1 - \lambda)\lambda^{j-1}$; ponderile însumează 1
- Pondere a ultimelor 20 de zile
 - ▶ $\lambda = 0,94$: 71%
 - ▶ $\lambda = 0,97$: 46%
 - ▶ $\lambda = 0,99$: 18%
- Un λ mai mic
 - ▶ reacționează mai repede, dar este mai zgomotos

Noțiuni necesare azi (13/21): valoarea expusă la risc

- ▣ **VaR 1%** (value at risk, valoarea expusă la risc) pentru mâine: pierderea depășită cu probabilitatea 1%

$$P(r_{t+1} < -\text{VaR}_{t+1} \mid \mathcal{F}_t) = 0,01, \quad \text{VaR}_{t+1} = -(\mu + \sigma_{t+1} q_{0,01}(z))$$


- ▶ $q_{0,01}(z)$: cuantila de 1% a inovației z , negativă; VaR se raportează ca o pierdere pozitivă, în %
- ▶ pe H zile: σ_{t+1} se înlocuiește cu rădăcina pătrată a varianței pe H zile

- ▣ **Cuantilele:** Normală și Student-t rescalată la varianța 1 [Bollerslev \(1987\)](#)

$$q_{0.01} = -2.326 \text{ (Normală)}, \quad q_{0.01} = t_{\nu}^{-1}(0.01) \sqrt{\frac{\nu-2}{\nu}} \text{ (Student-t)}$$

- ▶ $\nu > 2$: gradele de libertate, un ν mai mic înseamnă cozi mai groase; t_{ν}^{-1} : funcția cuantilă a distribuției $t(\nu)$
- ▶ $\text{Var}(t_{\nu}) = \nu/(\nu-2)$, de aici factorul $\sqrt{(\nu-2)/\nu}$; exemplu: $t_5^{-1}(0,01) = -3,365$

Noțiuni necesare azi (14/21): cuantila de 1% cu cozi groase



- Ambele inovații au varianța 1; distribuția Student-t cu $\nu = 4$ are vârful mai înalt și cozile mai groase
- Cuantila de 1%: $-2,326$ (Normală), $-2,649$ (Student-t, $\nu = 4$)
 - la același σ_{t+1} , VaR 1% Student-t este cu 14% mai mare

Noțiuni necesare azi (15/21): verosimilitatea maximă și compararea modelelor

- ▣ **MLE** (maximum likelihood estimation, estimarea prin verosimilitate maximă), inovații Normale

$$\ell(\boldsymbol{\vartheta}) = -\frac{1}{2} \sum_{t=1}^T \left[\ln 2\pi + \ln \sigma_t^2 + \frac{(r_t - \mu_t)^2}{\sigma_t^2} \right]$$

- ▶ $\boldsymbol{\vartheta}$: toți parametrii ($c, \phi, \omega, \alpha, \beta$ și ν pentru Student-t); $\hat{\boldsymbol{\vartheta}}$ maximizează ℓ
- ▶ SE (erori standard) robuste [Bollerslev și Wooldridge \(1992\)](#): valide chiar dacă z_t nu are distribuția Normală

- ▣ **Testul LR** (likelihood ratio, raportul de verosimilitate) al unui model mai mic față de unul mai mare

$$\text{LR} = 2(\ell_1 - \ell_0) \sim \chi^2(r), \quad \text{BIC} = -2\ell + k \ln T$$

- ▶ ℓ_1, ℓ_0 : log-verosimilitățile maximizate ale modelului mai mare și ale celui mai mic; r : numărul de restricții; $\chi_{0,95}^2(1) = 3,84$
- ▶ BIC [Schwarz \(1978\)](#): k parametri, T observații; câștigă BIC-ul mai mic; penalizează parametrii suplimentari mai mult decât LR

Noțiuni necesare azi (16/21): modele GARCH asimetrice

- ▣ **GJR-GARCH** [Glosten, Jagannathan și Runkle \(1993\)](#): o scădere adaugă reacția suplimentară γ

$$\sigma_t^2 = \omega + (\alpha + \gamma I_{t-1}) \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2, \quad I_{t-1} = \mathbf{1}\{\varepsilon_{t-1} < 0\}$$


- ▶ $\mathbf{1}\{\cdot\}$: 1 dacă este îndeplinită condiția, 0 altfel; **efectul de levier** [Christie \(1982\)](#): $\gamma > 0$, scăderile cresc mai mult volatilitatea
- ▶ persistența $\alpha + \beta + \gamma/2$ (o scădere apare în jumătate din cazuri)

- ▣ **EGARCH** [Nelson \(1991\)](#): un model pentru $\ln \sigma_t^2$, mereu pozitiv

$$\ln \sigma_t^2 = \omega + \alpha(|z_{t-1}| - E|z_{t-1}|) + \gamma z_{t-1} + \beta \ln \sigma_{t-1}^2$$

- ▶ α : efectul de mărime; γ : efectul de semn, levier dacă $\gamma < 0$; $E|z| = \sqrt{2/\pi} = 0,7979$ pentru z cu distribuția Normală
- ▣ **Curba de impact al știrilor**: σ_{t+1}^2 ca funcție de șocul de azi ε_t , cu σ_t^2 fixat

Noțiuni necesare azi (17/21): curbe de impact al știrilor



- $\sigma_t^2 = 1$; aceeași persistență
 - ▶ GARCH: $\alpha = 0,07$, $\beta = 0,90$
 - ▶ GJR: $\alpha = 0,02$, $\gamma = 0,10$, $\beta = 0,90$
 - ▶ EGARCH: $\alpha = 0,15$, $\gamma = -0,06$, $\beta = 0,97$
- GARCH este simetric: 1,21 după ± 2
- GJR: 1,41 după -2 , 1,01 după $+2$
 - ▶ EGARCH: 1,35 față de 1,06

Noțiuni necesare azi (18/21): testul de asimetrie (sign bias)

- ▣ **Reziduurile standardizate:** inovațiile estimate

$$\hat{z}_t = \frac{r_t - \hat{\mu}_t}{\hat{\sigma}_t}$$

- ▶ pentru un model corect, $\hat{z}_t$ și $\hat{z}_t^2$ nu au autocorelație (Ljung–Box)

- ▣ **Testul de asimetrie (sign bias) Engle și Ng (1993):** poate semnul șocului de ieri să prezică $\hat{z}_t^2$?

$$\hat{z}_t^2 = b_0 + b_1 S_{t-1}^- + b_2 S_{t-1}^- \hat{z}_{t-1} + b_3 S_{t-1}^+ \hat{z}_{t-1} + e_t$$

- ▶ $S_{t-1}^- = \mathbf{1}\{\hat{z}_{t-1} < 0\}$, $S_{t-1}^+ = 1 - S_{t-1}^-$; b_1 : asimetria de semn, b_2 , b_3 : asimetria de mărime a scăderilor și a creșterilor
- ▶ testul comun $H_0: b_1 = b_2 = b_3 = 0$, statistica $nR^2 \sim \chi^2(3)$; o respingere: modelului îi lipsește o asimetrie

Noțiuni necesare azi (19/21): compararea prognozelor de varianță

- ▣ **În afara eșantionului:** prognoza h_t pentru ziua t folosește doar date pînă la $t - 1$
 - ▶ modelul se reestimează periodic (la 250 de zile) pe toate datele pînă în acea zi; r_t^2 : o aproximare zgomotoasă a varianței adevărate
- ▣ Pierderea **QLIKE** Patton (2011)


$$L_t = \frac{r_t^2}{h_t} + \ln h_t$$

- ▶ minimă la $h_t = r_t^2$; robustă la zgomotul aproximării; o medie QLIKE mai mică este mai bună
- ▣ **Testul DM** Diebold și Mariano (1995): modelele A și B, diferența de pierdere $d_t = L_t^A - L_t^B$

$$DM = \frac{\bar{d}}{SE_{HAC}(\bar{d})} \approx N(0, 1)$$


- ▶ $\bar{d}$: media lui d_t ; HAC: o eroare standard robustă la heteroscedasticitatea și autocorelația lui d_t
 - ▶ $DM < -1,96$: A semnificativ mai bun la 5%; $> 1,96$: B mai bun

Noțiuni necesare azi (20/21): pierderea QLIKE



- $r_t^2 = 1$; ambele pierderi sînt 0 la $h_t = 1$
- QLIKE: subestimarea costă mai mult
 - ▶ $h_t = 0,5$: 0,31; $h_t = 2$: 0,19
- Eroarea pătratică: invers
 - ▶ $h_t = 0,5$: 0,25; $h_t = 2$: 1,00
 - ▶ dominată de cîteva zile cu r_t^2 foarte mare
- Un manager de risc se teme de subestimare
 - ▶ deci QLIKE se potrivește modelelor de risc

Noțiuni necesare azi (21/21): depășirile VaR



- **Depășire:** o zi cu $r_t < -\text{VaR}_t$; un VaR 1% corect este depășit în circa 1% dintre cele n zile
- randamente GARCH-t simulate, $n = 1000$, 10 depășiri așteptate: VaR GARCH-t 10, VaR Normal constant 16, grupate în lunile agitate

A1: algebra GARCH(1,1) [Rezolvat]

Cerință

- ▣ Randamente zilnice în %: $\omega = 0,02$, $\alpha = 0,08$, $\beta = 0,90$, $\mu = 0$, 252 de zile de tranzacționare pe an.
- ▣ 1. Calculați persistența și varianța de lungă durată.
- ▣ 2. Calculați volatilitatea de lungă durată anualizată.
- ▣ 3. Calculați timpul de înjumătățire al unui șoc de varianță.
- ▣ 4. Azi $\sigma_t^2 = 1,5$ și $r_t = -3\%$; calculați σ_{t+1}^2 și σ_{t+1} .
- ▣ Raportați: patru valori și o frază.

Rezolvare

- ▣ 1. $\alpha + \beta = 0,98$; $\bar{\sigma}^2 = 0,02 / (1 - 0,98) = 1,000$
- ▣ 2. $\sqrt{252 \times 1,000} = 15,87\%$ pe an
- ▣ 3. $\ln 0,5 / \ln 0,98 = -0,69315 / (-0,02020) = 34,3$ zile
- ▣ 4. $0,02 + 0,08 \times 9 + 0,90 \times 1,5 = 2,090$; $\sigma_{t+1} = 1,446\%$
- ▣ O scădere de 3% crește varianța cu 39%; jumătate din excedent dispare după 34,3 zile de tranzacționare, circa 7 săptămîni.

A2: o piață mai reactivă [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ $\omega = 0,05$, $\alpha = 0,12$, $\beta = 0,85$, $\mu = 0$; azi $\sigma_t^2 = 2,0$ și $r_t = +1,5\%$. Model: [A1](#).
- ▣ 1. Calculați persistența, varianța de lungă durată și volatilitatea de lungă durată anualizată.
- ▣ 2. Calculați timpul de înjumătățire.
- ▣ 3. Calculați σ_{t+1}^2 .
- ▣ 4. Scrieți EWMA cu $\lambda = 0,94$ ca un GARCH(1,1) și precizați care dintre mărimile de la 1–2 există pentru el.
- ▣ Raportați: patru valori și două fraze.

A3: prognoze și VaR 1% [Rezolvat]

Cerință

- ▣ Modelul din A1, cu $\sigma_{t+1}^2 = 2,090$ și inovații Normale.
- ▣ 1. Calculați $E_t[\sigma_{t+5}^2]$ și $E_t[\sigma_{t+10}^2]$.
- ▣ 2. Calculați varianța și volatilitatea pe 10 zile.
- ▣ 3. Comparați cu regula rădăcinii pătrate a timpului, $\sqrt{10}\sigma_{t+1}$, și cu $\sqrt{10}\bar{\sigma}^2$.
- ▣ 4. Calculați VaR 1% pe o zi și pe 10 zile.
- ▣ Raportați: șase valori și o frază.

Rezolvare

- ▣ 1. $1 + 0,98^4(2,090 - 1) = 1 + 0,9224 \times 1,09 = 2,005$;
 $1 + 0,98^9 \times 1,09 = 1,909$
- ▣ 2. $10 \times 1 + 1,09 \times (1 - 0,98^{10})/0,02 =$
 $10 + 1,09 \times 9,146 = 19,97$; volatilitatea 4,47%
- ▣ 3. $\sqrt{10 \times 2,090} = 4,57\%$ (prea mare), $\sqrt{10} = 3,16\%$
 (prea mică)
- ▣ 4. $2,326 \times 1,446 = 3,36\%$; $2,326 \times 4,47 = 10,40\%$
- ▣ Varianța ridicată scade lent: riscul pe 10 zile este între cele două reguli simple, mai aproape de prima.

A4: prognoze cu inovații Student-t [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Modelul din A2, cu $\sigma_{t+1}^2 = 2,020$ și inovații Student-t standardizate cu $\nu = 5$ ($t_5^{-1}(0,01) = -3,365$). Model: A3.
- ▣ 1. Calculați $E_t[\sigma_{t+10}^2]$ și varianța pe 10 zile.
- ▣ 2. Calculați cuantila $q_{0,01}$ a distribuției t standardizate.
- ▣ 3. Calculați VaR 1% pe o zi și pe 10 zile, cu inovații t și cu inovații Normale.
- ▣ Raportați: șase valori și o frază.

A5: un test ARCH-LM din rezultatele unei regresii [Rezolvat]

Cerință

- ▣ Pe randamentele zilnice ale unui indice bursier se estimează un AR(1). Regresia lui $\hat{\varepsilon}_t^2$ pe o constantă și cinci laguri folosește $n = 1000$ de observații și dă $R^2 = 0,062$; statistica Ljung-Box a lui $\hat{\varepsilon}_t^2$ este $Q(10) = 95,3$.
- ▣ 1. Calculați statistica ARCH-LM și comparați-o cu valoarea de 5% a distribuției $\chi^2(5)$.
- ▣ 2. Comparați $Q(10)$ cu valoarea de 5% a distribuției $\chi^2(10)$.
- ▣ 3. Precizați ce model ați estima în continuare.
- ▣ 4. Pentru un ARCH(1) cu $\omega = \alpha = 0,5$ și z_t Normale, calculați varianța necondiționată și kurtosis-ul.
- ▣ Raportați: două decizii, două valori și o frază.

Rezolvare

- ▣ 1. $LM = 1000 \times 0,062 = 62,0 > 11,07$ ($p < 0,001$): respingem H_0 , efecte ARCH
- ▣ 2. $95,3 > 18,31$ ($p < 0,001$): pătratele sînt autocorelate; aceeași concluzie
- ▣ 3. AR(1)-GARCH(1,1), estimat simultan; apoi aceleași teste pe $\hat{z}_t$
- ▣ 4. $\bar{\sigma}^2 = 0,5/(1 - 0,5) = 1,0$; $K = 3 \times 0,75/0,25 = 9,0$: inovații Normale, dar randamente cu cozi groase

A6: știri bune și știri proaste [Propus]

Rezolvarea se discută la seminar


Cerință

- ▣ GJR-GARCH: $\omega = 0,02$, $\alpha = 0,03$, $\gamma = 0,12$, $\beta = 0,90$; EGARCH: $\omega = 0$, $\alpha = 0,12$, $\gamma = -0,08$, $\beta = 0,98$; în ambele $\sigma_t^2 = 1$, $\mu = 0$. Model: [A1](#).
- ▣ 1. Calculați σ_{t+1}^2 GJR după $\varepsilon_t = -2$ și după $\varepsilon_t = +2$, precum și raportul lor.
- ▣ 2. Calculați persistența și timpul de înjumătățire GJR.
- ▣ 3. Calculați σ_{t+1}^2 EGARCH pentru aceleași două șocuri (folosiți $E|z| = 0,7979$).
- ▣ Raportați: șase valori și o frază.

B1: efecte ARCH și AR(1)-GARCH(1,1)-t pentru BET [Rezolvat]

- ▣ **Întrebarea:** are BET efecte ARCH, cât de persistentă este volatilitatea lui și unde se află azi față de nivelul de lungă durată?
- ▣ **Date:** închiderile BET din 2000, randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați un AR(1) pentru medie prin OLS, apoi aplicați ARCH-LM(5) și Ljung–Box $Q(10)$ pe pătratele reziduurilor.
 2. Estimați AR(1)-GARCH(1,1)-t și raportați parametrii cu erorile standard robuste.
 3. Calculați persistența, timpul de înjumătățire și volatilitatea de lungă durată anualizată și comparați-le cu volatilitatea de selecție.
 4. Verificați $Q(10)$ pentru $\hat{z}_t$ și $\hat{z}_t^2$ și desenați randamentele din 2018 cu benzile $\pm 2\hat{\sigma}_t$.
 5. Interpretare: este volatilitatea BET din ultima zi peste sau sub nivelul de lungă durată și ce așteaptă modelul pentru lunile următoare?
- ▣ **Raportați:** două statistici de test, un tabel cu șase parametri, cinci valori, graficul și două fraze
- ▣ Notebook: secțiunea [B1](#)

B1: rezolvare (1/2) [Rezolvat]



B1: rezolvare (2/2) [Rezolvat]

	c	ϕ	ω	α	β	ν
estimare	0,077	0,091	0,0441	0,189	0,801	5,09
SE robustă	0,010	0,013	0,0085	0,023	0,023	0,32

- Reziduurile AR(1): ARCH-LM = $nR^2 = 1017$ ($R^2 = 0,153$), $Q(10)$ al pătratelor = 2496: efecte ARCH puternice
- $T = 6\,669$; $\alpha + \beta = 0,990$, timpul de înjumătățire $\ln 0,5 / (-0,01028) = 67,4$ zile; volatilitatea de lungă durată 32,8%, față de 22,1% în eșantion; $\hat{z}_t$: $Q(10) = 28,6$ ($p < 0,001$), $\hat{z}_t^2$: 7,2 ($p = 0,705$)
- Vîrfuri: 114% (2008), 89% (2020); ultima zi: 26,2%; 5,1% dintre zile ies din banda $\pm 2\hat{\sigma}_t$
- Interpretare: sub nivelul de lungă durată (26,2% față de 32,8%); modelul se așteaptă ca volatilitatea să crească lent spre acest nivel, dar nivelul este imprecis ($1 - \alpha - \beta = 0,0102$)


B2: EUR/RON și Bitcoin [Propus]

- ▣ **Întrebarea:** se comportă cursul EUR/RON și Bitcoin la fel ca BET? Model: [B1](#).
- ▣ **Date:** EUR/RON (cursul de referință BNR) din iulie 2005, Bitcoin din septembrie 2014; randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Repetați pașii 1–4 din [B1](#) pentru ambele serii (EUR/RON: estimați pe 10 r_t).
 2. Raportați $\hat{\alpha} + \hat{\beta}$ și precizați dacă timpul de înjumătățire și volatilitatea de lungă durată există.
 3. Interpretare: ce înseamnă $\hat{\alpha} + \hat{\beta} = 1$ pentru o prognoză a volatilității peste un an?
- ▣ **Raportați:** un tabel și două fraze
- ▣ Notebook: secțiunea [B2](#)

B3: efectul de levier la S&P 500 [Rezolvat]

- ▣ **Întrebarea:** cresc scăderile volatilitatea S&P 500 mai mult decât creșterile de aceeași mărime?
- ▣ **Date:** închiderile S&P 500 din 2000, randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați GARCH(1,1)-t și GJR-GARCH(1,1)-t; raportați γ cu statistica t robustă.
 2. Calculați statistica LR pentru GJR față de GARCH, p-value-ul ei și cele două valori BIC.
 3. Aplicați testul de asimetrie (sign bias) pe reziduurile standardizate ale GARCH-t.
 4. Desenați ambele curbe de impact ale știrilor și calculați varianța GJR după șocuri de -2% și $+2\%$.
 5. Interpretare: cum schimbă efectul de levier VaR-ul din ziua de după o scădere?
- ▣ **Raportați:** patru statistici cu p-value-uri, două varianțe, graficul și două fraze
- ▣ Notebook: secțiunea [B3](#)

B3: rezolvare (1/2) [Rezolvat]



B3: rezolvare (2/2) [Rezolvat]

- GJR: $\hat{\alpha} = 0,000$, $\hat{\gamma} = 0,205$ ($t = 10,0$), $\hat{\beta} = 0,881$; LR = 235,7 ($p < 0,001$); BIC 18169,0 $\rightarrow$ 17942,2
- Testul de asimetrie pe reziduurile GARCH-t: $\chi^2(3) = 40,7$ ($p < 0,001$), t al semnului = 3,56
- Variația GJR după -2% : 2,14; după $+2\%$: 1,31; raportul 1,62
- Interpretare: doar scăderile cresc variația ($\hat{\alpha} = 0$); după o scădere, VaR este de circa $\sqrt{1,62} = 1,27$ ori VaR-ul de după o creștere egală; un GARCH simetric subestimează riscul după zilele proaste


B4: asimetria la BET, EUR/RON și Bitcoin [Propus]

- ▣ **Întrebarea:** există un efect de levier la BET, la EUR/RON și la Bitcoin? Model: B3.
- ▣ **Date:** BET din 2000, EUR/RON din 2005, Bitcoin din 2014; randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați GJR-GARCH(1,1)- t și EGARCH(1,1)- t ; raportați ambele valori γ , cu statisticile t robuste.
 2. Calculați testul LR pentru GJR față de GARCH și modificarea BIC.
 3. Interpretare: pentru EUR/RON un randament pozitiv înseamnă un leu mai slab; ce sînt „știrile proaste” pentru această serie?
- ▣ **Raportați:** un tabel și două fraze
- ▣ Notebook: secțiunea B4

B5: GARCH față de EWMA pentru S&P 500 [Rezolvat]

- **Întrebarea:** prognozează GARCH(1,1)-t varianța de mâine a S&P 500 mai bine decât EWMA și este VaR 1% al lui depășit în 1% dintre zile?
- **Date:** S&P 500 din 2000; prognoze pentru fiecare zi de la 2 ianuarie 2015
- **Cerințe**
 1. Reestimați GARCH(1,1)-t la fiecare 250 de zile pe toate datele pînă în acea zi și calculați prognozele pe o zi h_t ; calculați EWMA cu $\lambda = 0,94$.
 2. Calculați media QLIKE pentru ambele modele și statistica t Diebold–Mariano.
 3. Numărați depășirile VaR 1% GARCH-t și VaR 1% EWMA-Normal și comparați-le cu numărul așteptat.
 4. Desenați diferența cumulată a pierderilor.
 5. Interpretare: ce model i-ați da unui manager de risc și ce ați mai îmbunătăți?
- **Raportați:** patru valori, două numărători, graficul și două fraze
- Notebook: secțiunea [B5](#)

B5: rezolvare (1/2) [Rezolvat]



B5: rezolvare (2/2) [Rezolvat]

- 2 944 de zile; media QLIKE: GARCH-t 0,761, EWMA 0,819; DM: diferența medie $-0,058$, $t = -3,69$ ($p < 0,001$): GARCH-t este mai bun
- Depășiri VaR 1%: GARCH-t 49 (1,66%), EWMA-Normal 65 (2,21%); așteptat circa 29
- Interpretare: GARCH-t, dar ambele modele VaR sînt depășite prea des; adăugăm efectul de levier (B3) și testăm formal numărul de depășiri (Kupiec (1995))

B6: GARCH față de EWMA pentru BET și EUR/RON [Propus]

- ▣ **Întrebarea:** se păstrează rezultatul din B5 pentru BET și pentru EUR/RON? Model: B5.
- ▣ **Date:** BET din 2000, EUR/RON din 2005; prognoze pentru fiecare zi din ianuarie 2015
- ▣ **Cerințe**
 1. Calculați prognozele GARCH(1,1)-t și EWMA în afara eșantionului, ca în B5.
 2. Calculați media QLIKE pentru ambele modele și testul DM.
 3. Găsiți ziua cu cea mai mare diferență a pierderilor și recalculați media QLIKE fără ea.
 4. Numărați depășirile VaR 1% pentru ambele modele.
 5. Interpretare: de ce poate fi testul DM nesemnificativ când o medie QLIKE este jumătate din cealaltă?
- ▣ **Raportați:** un tabel și două fraze
- ▣ **Notebook:** secțiunea B6

C1: este leul mai liniștit decât înainte? [Propus]

- **Întrebarea:** s-a schimbat volatilitatea EUR/RON între perioadele 2005–2012, 2013–2019 și 2020–2026 și poate un singur model GARCH să descrie toate trei perioadele?
- **Date:** randamentele logaritmice zilnice EUR/RON în % (cursul de referință BNR); model: [B1](#)
- **Cerințe**
 1. Pentru fiecare perioadă calculați volatilitatea de selecție anualizată și ponderea zilelor cu $|r_t| > 0,5\%$.
 2. Estimați GARCH(1,1)-t pe fiecare perioadă și raportați $\alpha + \beta$, α și ν .
 3. Găsiți cea mai mare variație zilnică din fiecare perioadă și data ei.
 4. Interpretare: este schimbarea volatilității o proprietate a pieței sau a politicii de curs de schimb?
- **Raportați:** un tabel și un plan de proiect
- **Notebook:** secțiunea [C1](#)

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI să interpreteze un GARCH(1,1)-t estimat pentru BET (date zilnice, din 2000):
 $\hat{\omega} = 0,0448$, $\hat{\alpha} = 0,192$, $\hat{\beta} = 0,799$, $\hat{\nu} = 5,01$. Răspunsul:
 - (a) Timpul de înjumătățire al unui șoc de volatilitate este $\ln 0,5 / \ln \beta = 3,1$ zile.
 - (b) Varianța de lungă durată este $\omega/(1 - \alpha) = 0,055$, o volatilitate anuală de 3,7%.
 - (c) Un AR(1) estimat prin OLS dă $\phi = 0,109$ cu SE 0,012, $t = 8,9$: randamentele BET sînt puternic previzibile.
 - (d) Ljung-Box Q(10) al pătratelor reziduurilor standardizate = 8,3, $p = 0,60$: modelul GARCH-t este corect.
 - (e) Cu inovații Student-t, cuantila de 1% a lui z este mai aproape de 0 decît valoarea Normală -2,326, deci VaR 1% este mai mic.
 - (f) $\alpha + \beta = 0,991 < 1$, deci modelul este staționar în covarianță, iar volatilitatea revine la nivelul de lungă durată.
- Cerințe
 - 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă din notebook (secțiunea C2).
 - 2. Raportați: o listă de șase verdicte, fiecare cu un rînd de justificare.

Idei de reținut

- ▣ Testăm efectele ARCH pe reziduurile modelului pentru medie: ARCH-LM = nR^2 și Ljung–Box pe pătrate
- ▣ $\alpha + \beta$ decide termenul lung: timpul de înjumătățire, varianța de lungă durată, forma prognozelor; $\alpha + \beta = 1$: IGARCH
- ▣ Riscul pe mai multe zile este suma prognozelor zilnice ale varianței, nu $\sqrt{H}$ ori volatilitatea de azi
- ▣ Inovațiile cu cozi groase schimbă cuantila VaR; asimetria schimbă VaR-ul după zilele proaste
- ▣ Comparăm prognozele în afara eșantionului (QLIKE, DM) și căutăm zilele care determină singure rezultatul

După seminar

- ▣ Detalii: [Capitolul 5](#): faptele stilizate, ARCH și GARCH, estimarea, ARMA-GARCH, asimetria, diagnosticarea, prognozele, VaR 1%
- ▣ [C1](#) poate deveni un proiect de echipă: regimurile de volatilitate ale leului și ale altor valute din regiune
- ▣ Lectură: [Huang și Petukhina \(2022\)](#), cap. 6; [Tsay \(2010\)](#), cap. 3

Bibliografie (1/2)

- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. doi:10.1016/0304-4076(86)90063-1
- Bollerslev, T. (1987). A conditionally heteroskedastic time series model for speculative prices and rates of return. *Review of Economics and Statistics*, 69(3), 542–547. doi:10.2307/1925546
- Bollerslev, T., & Wooldridge, J. M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172. doi:10.1080/07474939208800229
- Christie, A. A. (1982). The stochastic behavior of common stock variances: Value, leverage and interest rate effects. *Journal of Financial Economics*, 10(4), 407–432. doi:10.1016/0304-405X(82)90018-6
- Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007. doi:10.2307/1912773
- Engle, R. F., & Ng, V. K. (1993). Measuring and testing the impact of news on volatility. *Journal of Finance*, 48(5), 1749–1778. doi:10.1111/j.1540-6261.1993.tb05127.x
- Glosten, L. R., Jagannathan, R., & Runkle, D. E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801. doi:10.1111/j.1540-6261.1993.tb05128.x

Bibliografie (2/2)

- ▣ Huang, C., & Petukhina, A. (2022). *Applied Time Series Analysis and Forecasting with Python*. Springer. doi:10.1007/978-3-031-13584-2
- ▣ J.P. Morgan/Reuters (1996). *RiskMetrics – Technical Document* (4th ed.). Morgan Guaranty Trust Company. [msci.com](https://www.msci.com)
- ▣ Kupiec, P. H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84. doi:10.3905/jod.1995.407942
- ▣ Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303. doi:10.1093/biomet/65.2.297
- ▣ Nelson, D. B. (1991). Conditional heteroskedasticity in asset returns: A new approach. *Econometrica*, 59(2), 347–370. doi:10.2307/2938260
- ▣ Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. doi:10.1016/j.jeconom.2010.03.034
- ▣ Tsay, R. S. (2010). *Analysis of Financial Time Series* (3rd ed.). Wiley. doi:10.1002/9780470644560