



Serii de timp

Seminarul 5: Volatilitate condiționată: ARCH și GARCH



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **AI:** Artificial Intelligence (inteligență artificială)
- ▣ **AR:** AutoRegressive (model) — model autoregresiv
- ▣ **ARCH:** AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ **ARCH-LM:** ARCH Lagrange Multiplier (test) — testul multiplicatorului Lagrange pentru efecte ARCH
- ▣ **ARMA:** AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **ARMA-GARCH:** ARMA model for the mean with GARCH errors (model ARMA pentru medie cu erori GARCH)
- ▣ **BET:** Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BIC:** Bayesian Information Criterion (criteriul informațional bayesian al lui Schwarz)
- ▣ **BNR:** Banca Națională a României
- ▣ **DM:** Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ **EGARCH:** Exponential GARCH (GARCH exponențial)
- ▣ **EODHD:** EOD Historical Data (market-data provider) — furnizor de date de piață

Acronime folosite în acest material (2/2)

- **EWMA**: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- **GJR**: Glosten–Jagannathan–Runkle (GARCH model) — modelul GARCH asimetric Glosten–Jagannathan–Runkle
- **GJR-GARCH**: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- **IGARCH**: Integrated GARCH (GARCH integrat)
- **LR**: Likelihood Ratio (test) — testul raportului de verosimilitate
- **MLE**: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- **OLS**: Ordinary Least Squares (metoda celor mai mici pătrate)
- **QLIKE**: Quasi-LIKelihood (loss function) — funcția de pierdere de tip cvasi-verosimilitate
- **SE**: Standard Error (eroare standard)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum detectăm, modelăm, estimăm și prognozăm o varianță care se schimbă în fiecare zi?
 - ▶ seminarul are loc **înaintea** Cursului 5: secțiunea „Noțiuni necesare azi” dă toate definițiile folosite în cerințe
- ▣ Traseul
 - ▶ Partea A: algebra GARCH, prognoze și VaR 1%, un test ARCH-LM, știri asimetrice, pe hîrtie
 - ▶ Partea B: efecte ARCH și AR(1)-GARCH(1,1)-t, asimetria, prognoze în afara eșantionului pentru BET, S&P 500, EUR/RON și Bitcoin
 - ▶ Partea C: o întrebare deschisă despre leu și un răspuns AI de verificat
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); prima celulă instalează pachetul arch (`pip install arch`)

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	persistența, varianța de lungă durată, timpul de înjumătățire și un pas GARCH(1,1)	Rezolvat, Propus	A1
A3, A4	proгноze pe mai mulți pași, volatilitatea pe 10 zile și VaR 1%	Rezolvat, Propus	A3
A5, A6	un test ARCH-LM din rezultatele unei regresii; impactul știrilor în GJR și EGARCH	Rezolvat, Propus	A5, A1
B1, B2	efecte ARCH și AR(1)-GARCH(1,1)-t: BET; EUR/RON și Bitcoin	Rezolvat, Propus	B1
B3, B4	asimetria și efectul de levier: S&P 500; BET, EUR/RON, Bitcoin	Rezolvat, Propus	B3
B5, B6	GARCH față de EWMA în afara eșantionului, VaR 1%: S&P 500; BET, EUR/RON	Rezolvat, Propus	B5
C1, C2	este leul mai liniștit decât înainte? ce este greșit într-un răspuns AI?	Propus	B1, A1

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model

Datele folosite

Seria	Sursa	Frecvența	Perioada
S&P 500, BET	EODHD	zilnic, închidere	2000–2026
EUR/RON	cursul de referință BNR	zilnic	2005–2026
Bitcoin	EODHD	zilnic, 7 zile pe săptămână	2014–2026

- Randamente logaritmice zilnice în %: $r_t = 100 (\ln P_t - \ln P_{t-1})$; weekendurile și închiderile repetate din zilele libere se elimină (cu excepția Bitcoin)
- EUR/RON variază cu circa 0,3% pe zi: notebook-ul estimează modelele pe 10 r_t și convertește rezultatele înapoi în %
- În notebook: `returns('bet')`, `arch_lm(x)`, `fit(r, mean='AR', dist='t')` (pachetul `arch`); nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/5): efecte ARCH

- $r_t = \mu_t + \varepsilon_t$, $\varepsilon_t = \sigma_t z_t$; z_t i.i.d., media 0, varianța 1 (**inovațiile**)
 - ▶ μ_t : **media condiționată** (un model ARMA, [Capitolul 2](#)); $\sigma_t^2 = \text{Var}(r_t \mid \text{trecut})$: **varianța condiționată**
 - ▶ randamentele zilnice sînt aproape necorelate, dar pătratele lor sînt corelate: **volatility clustering**
- **Testul ARCH-LM Engle (1982)**: regresia prin OLS a lui $\hat{\varepsilon}_t^2$ pe o constantă și pe $\hat{\varepsilon}_{t-1}^2, \dots, \hat{\varepsilon}_{t-q}^2$
 - ▶ $\hat{\varepsilon}_t$: reziduurile modelului pentru medie; q : numărul de pătrate trecute; n : numărul de observații din regresie; R^2 : coeficientul ei de determinare
 - ▶ H_0 : fără efecte ARCH; $LM = nR^2 \sim \chi^2(q)$; valorile de 5%: $\chi^2(5)$ 11,07, $\chi^2(10)$ 18,31
 - ▶ statistica Ljung–Box $Q(m)$ a lui $\hat{\varepsilon}_t^2$ [Ljung și Box \(1978\)](#) este un al doilea test cu aceeași H_0
- **Kurtosis-ul** $K = E[(r - \mu)^4]/\sigma^4$: 3 pentru distribuția Normală, mai mare pentru cozi groase

Noțiuni necesare azi (2/5): ARCH, GARCH și EWMA

- **ARCH(1) Engle (1982):** $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2$, $\omega > 0$, $0 \leq \alpha < 1$
 - ▶ ω : nivelul minim al varianței; α : reacția la pătratul șocului de ieri
 - ▶ varianța necondiționată $\omega/(1 - \alpha)$; cu z_t Normale și $3\alpha^2 < 1$: kurtosis-ul $3(1 - \alpha^2)/(1 - 3\alpha^2)$
- **GARCH(1,1) Bollerslev (1986):** $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$, $\omega > 0$, $\alpha, \beta \geq 0$
 - ▶ β : memoria, adică ponderea varianței de ieri; 252: numărul de zile de tranzacționare dintr-un an
 - ▶ **persistența** $\alpha + \beta$; **varianța de lungă durată** $\bar{\sigma}^2 = \omega/(1 - \alpha - \beta)$ dacă $\alpha + \beta < 1$; volatilitatea anuală $\sqrt{252} \bar{\sigma}$
 - ▶ **timpul de înjumătățire** $h_{1/2} = \ln 0,5 / \ln(\alpha + \beta)$ zile: timpul în care dispăre jumătate dintr-un șoc de varianță
- **EWMA J.P. Morgan/Reuters (1996):** $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$ (netezirea exponențială a lui r_t^2 , Capitolul 0)
 - ▶ λ : ponderea varianței de ieri (0,94 pentru date zilnice)
 - ▶ un GARCH cu $\omega = 0$ și $\alpha + \beta = 1$: un **IGARCH** (GARCH integrat): fără timp de înjumătățire și fără varianță de lungă durată
 - ▶ **AR(1)-GARCH(1,1):** $r_t = c + \phi r_{t-1} + \varepsilon_t$ cu erori GARCH, ambele părți estimate împreună

Noțiuni necesare azi (3/5): prognoze și VaR

□ Prognoze făcute la sfârșitul zilei t

- ▶ $E_t[\cdot]$: media condiționată de informația din ziua t ; $\bar{\sigma}^2$: varianța de lungă durată; H : numărul de zile
- ▶ o zi: $\sigma_{t+1}^2 = \omega + \alpha(r_t - \mu)^2 + \beta\sigma_t^2$; h zile: $E_t[\sigma_{t+h}^2] = \bar{\sigma}^2 + (\alpha + \beta)^{h-1}(\sigma_{t+1}^2 - \bar{\sigma}^2)$
- ▶ varianța pe H zile: $\sum_{h=1}^H E_t[\sigma_{t+h}^2] = H\bar{\sigma}^2 + (\sigma_{t+1}^2 - \bar{\sigma}^2) \frac{1 - (\alpha + \beta)^H}{1 - \alpha - \beta}$

□ VaR 1% (value at risk, valoarea expusă la risc): pierderea depășită cu probabilitatea 1%: $\text{VaR}_{t+1} = -(\mu + \sigma_{t+1} q_{0,01}(z))$

- ▶ $q_{0,01}(z)$: cuantila de 1% a inovației z ; ν : gradele de libertate ale distribuției Student-t; t_ν^{-1} : funcția ei cuantilă
- ▶ Normală: $q_{0,01} = -2,326$; Student-t standardizată: $q_{0,01} = t_\nu^{-1}(0,01)\sqrt{(\nu - 2)/\nu}$, de exemplu $t_5^{-1}(0,01) = -3,365$

Noțiuni necesare azi (4/5): estimare

- **MLE** (maximum likelihood estimation, estimarea prin verosimilitate maximă): $\hat{\theta}$ maximizează $\ell(\theta) = -\frac{1}{2} \sum_t [\ln 2\pi + \ln \sigma_t^2 + (r_t - \mu_t)^2 / \sigma_t^2]$; arch raportează SE (erori standard) robuste [Bollerslev și Wooldridge \(1992\)](#)
 - ▶ θ : vectorul parametrilor; $\ell(\theta)$: log-verosimilitatea, mai mare pentru parametrii care fac randamentele observate mai probabile
 - ▶ inovații cu cozi groase: Student-t standardizată cu ν grade de libertate [Bollerslev \(1987\)](#)
- **Testul LR** (likelihood ratio, raportul de verosimilitate) al unui model mai mic față de unul mai mare: $2(\ell_1 - \ell_0) \sim \chi^2(r)$
 - ▶ ℓ_1, ℓ_0 : log-verosimilitățile maximizate ale modelului mai mare și ale celui mai mic; r : numărul de restricții;
 $\chi_{0,95}^2(1) = 3,84$

Noțiuni necesare azi (5/5): asimetria și compararea prognozelor

- **GJR-GARCH** Glosten, Jagannathan și Runkle (1993): $\sigma_t^2 = \omega + (\alpha + \gamma I_{t-1})\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$, $I_{t-1} = 1$ dacă $\varepsilon_{t-1} < 0$
 - ▶ I_{t-1} : 1 după o scădere, 0 altfel; γ : reacția suplimentară a varianței la șocurile negative
 - ▶ **efectul de levier** Christie (1982): $\gamma > 0$, scăderile cresc volatilitatea mai mult decât creșterile; persistența $\alpha + \beta + \gamma/2$
 - ▶ **EGARCH** Nelson (1991): $\ln \sigma_t^2 = \omega + \alpha(|z_{t-1}| - E|z_{t-1}|) + \gamma z_{t-1} + \beta \ln \sigma_{t-1}^2$; $E|z| = 0,7979$ pentru z Normal; levier: $\gamma < 0$
 - ▶ **testul de asimetrie (sign bias)** Engle și Ng (1993): $\chi^2(3)$ pe reziduurile standardizate $\hat{z}_t = (r_t - \hat{\mu}_t)/\hat{\sigma}_t$; o respingere înseamnă că modelului îi lipsește asimetria
- **În afara eșantionului**: prognoza h_t pentru ziua t folosește doar date pînă la $t - 1$; aproximarea varianței adevărate este r_t^2
 - ▶ pierderea **QLIKE** Patton (2011): $L_t = r_t^2/h_t + \ln h_t$; cu cît media este mai mică, cu atît mai bine
 - ▶ L_t^A, L_t^B : pierderile modelelor A și B în ziua t
 - ▶ **testul DM** Diebold și Mariano (1995): statistica t a mediei lui $L_t^A - L_t^B$, cu SE de tip HAC (robuste la autocorelație); $t < -1,96$: A este mai bun
 - ▶ **depășire VaR**: o zi cu $r_t < -\text{VaR}_t$; un VaR 1% corect este depășit în circa 1% dintre zile

A1: algebra GARCH(1,1) [Rezolvat]

Cerință

- ▣ Randamente zilnice în %: $\omega = 0,02$, $\alpha = 0,08$, $\beta = 0,90$, $\mu = 0$, 252 de zile de tranzacționare pe an.
- ▣ 1. Calculați persistența și varianța de lungă durată.
- ▣ 2. Calculați volatilitatea de lungă durată anualizată.
- ▣ 3. Calculați timpul de înjumătățire al unui șoc de varianță.
- ▣ 4. Azi $\sigma_t^2 = 1,5$ și $r_t = -3\%$; calculați σ_{t+1}^2 și σ_{t+1} .
- ▣ Raportați: patru valori și o frază.

Rezolvare

- ▣ 1. $\alpha + \beta = 0,98$; $\bar{\sigma}^2 = 0,02/(1 - 0,98) = 1,000$
- ▣ 2. $\sqrt{252 \times 1,000} = 15,87\%$ pe an
- ▣ 3. $\ln 0,5 / \ln 0,98 = -0,69315 / (-0,02020) = 34,3$ zile
- ▣ 4. $0,02 + 0,08 \times 9 + 0,90 \times 1,5 = 2,090$; $\sigma_{t+1} = 1,446\%$
- ▣ O scădere de 3% crește varianța cu 39%; jumătate din excedent dispare după 34,3 zile de tranzacționare, circa 7 săptămîni.

A2: o piață mai reactivă [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ $\omega = 0,05$, $\alpha = 0,12$, $\beta = 0,85$, $\mu = 0$; azi $\sigma_t^2 = 2,0$ și $r_t = +1,5\%$. Model: A1.
- ▣ 1. Calculați persistența, varianța de lungă durată și volatilitatea de lungă durată anualizată.
- ▣ 2. Calculați timpul de înjumătățire.
- ▣ 3. Calculați σ_{t+1}^2 .
- ▣ 4. Scrieți EWMA cu $\lambda = 0,94$ ca un GARCH(1,1) și precizați care dintre mărimile de la 1–2 există pentru el.
- ▣ Raportați: patru valori și două fraze.

A3: prognoze și VaR 1% [Rezolvat]

Cerință

- ▣ Modelul din A1, cu $\sigma_{t+1}^2 = 2,090$ și inovații Normale.
- ▣ 1. Calculați $E_t[\sigma_{t+5}^2]$ și $E_t[\sigma_{t+10}^2]$.
- ▣ 2. Calculați varianța și volatilitatea pe 10 zile.
- ▣ 3. Comparați cu regula rădăcinii pătrate a timpului, $\sqrt{10}\sigma_{t+1}$, și cu $\sqrt{10}\bar{\sigma}^2$.
- ▣ 4. Calculați VaR 1% pe o zi și pe 10 zile.
- ▣ Raportați: șase valori și o frază.

Rezolvare

- ▣ 1. $1 + 0,98^4(2,090 - 1) = 1 + 0,9224 \times 1,09 = 2,005$;
 $1 + 0,98^9 \times 1,09 = 1,909$
- ▣ 2. $10 \times 1 + 1,09 \times (1 - 0,98^{10})/0,02 =$
 $10 + 1,09 \times 9,146 = 19,97$; volatilitatea 4,47%
- ▣ 3. $\sqrt{10 \times 2,090} = 4,57\%$ (prea mare), $\sqrt{10} = 3,16\%$ (prea mică)
- ▣ 4. $2,326 \times 1,446 = 3,36\%$; $2,326 \times 4,47 = 10,40\%$
- ▣ Varianța ridicată scade lent: riscul pe 10 zile este între cele două reguli simple, mai aproape de prima.

A4: prognoze cu inovații Student-t [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Modelul din A2, cu $\sigma_{t+1}^2 = 2,020$ și inovații Student-t standardizate cu $\nu = 5$ ($t_5^{-1}(0,01) = -3,365$). Model: A3.
- ▣ 1. Calculați $E_t[\sigma_{t+10}^2]$ și varianța pe 10 zile.
- ▣ 2. Calculați cuantila $q_{0,01}$ a distribuției t standardizate.
- ▣ 3. Calculați VaR 1% pe o zi și pe 10 zile, cu inovații t și cu inovații Normale.
- ▣ Raportați: șase valori și o frază.

A5: un test ARCH-LM din rezultatele unei regresii [Rezolvat]

Cerință

- Pe randamentele zilnice ale unui indice bursier se estimează un AR(1). Regresia lui $\hat{\varepsilon}_t^2$ pe o constantă și cinci laguri folosește $n = 1000$ de observații și dă $R^2 = 0,062$; statistica Ljung-Box a lui $\hat{\varepsilon}_t^2$ este $Q(10) = 95,3$.
- 1. Calculați statistica ARCH-LM și comparați-o cu valoarea de 5% a distribuției $\chi^2(5)$.
- 2. Comparați $Q(10)$ cu valoarea de 5% a distribuției $\chi^2(10)$.
- 3. Precizați ce model ați estima în continuare.
- 4. Pentru un ARCH(1) cu $\omega = \alpha = 0,5$ și z_t Normale, calculați varianța necondiționată și kurtosis-ul.
- Raportați: două decizii, două valori și o frază.

Rezolvare

- 1. $LM = 1000 \times 0,062 = 62,0 > 11,07$ ($p < 0,001$): respingem H_0 , efecte ARCH
- 2. $95,3 > 18,31$ ($p < 0,001$): pătratele sînt autocorelate; aceeași concluzie
- 3. AR(1)-GARCH(1,1), estimat simultan; apoi aceleași teste pe $\hat{z}_t$
- 4. $\bar{\sigma}^2 = 0,5/(1 - 0,5) = 1,0$; $K = 3 \times 0,75/0,25 = 9,0$: inovații Normale, dar randamente cu cozi groase

A6: știri bune și știri proaste [Propus]

Rezolvarea se discută la seminar


Cerință

- ▣ GJR-GARCH: $\omega = 0,02$, $\alpha = 0,03$, $\gamma = 0,12$, $\beta = 0,90$; EGARCH: $\omega = 0$, $\alpha = 0,12$, $\gamma = -0,08$, $\beta = 0,98$; în ambele $\sigma_t^2 = 1$, $\mu = 0$. Model: A1.
- ▣ 1. Calculați σ_{t+1}^2 GJR după $\varepsilon_t = -2$ și după $\varepsilon_t = +2$, precum și raportul lor.
- ▣ 2. Calculați persistența și timpul de înjumătățire GJR.
- ▣ 3. Calculați σ_{t+1}^2 EGARCH pentru aceleași două șocuri (folosiți $E|z| = 0,7979$).
- ▣ Raportați: șase valori și o frază.

B1: efecte ARCH și AR(1)-GARCH(1,1)-t pentru BET [Rezolvat]

- ▣ **Întrebarea:** are BET efecte ARCH, cât de persistentă este volatilitatea lui și unde se află azi față de nivelul de lungă durată?
- ▣ **Date:** închiderile BET din 2000, randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați un AR(1) pentru medie prin OLS, apoi aplicați ARCH-LM(5) și Ljung–Box $Q(10)$ pe pătratele reziduurilor.
 2. Estimați AR(1)-GARCH(1,1)-t și raportați parametrii cu erorile standard robuste.
 3. Calculați persistența, timpul de înjumătățire și volatilitatea de lungă durată anualizată și comparați-le cu volatilitatea de selecție.
 4. Verificați $Q(10)$ pentru $\hat{z}_t$ și $\hat{z}_t^2$ și desenați randamentele din 2018 cu benzile $\pm 2\hat{\sigma}_t$.
 5. Interpretare: este volatilitatea BET din ultima zi peste sau sub nivelul de lungă durată și ce așteaptă modelul pentru lunile următoare?
- ▣ **Raportați:** două statistici de test, un tabel cu șase parametri, cinci valori, graficul și două fraze
- ▣ **Notebook:** secțiunea B1

B1: rezolvare (1/2) [Rezolvat]



B1: rezolvare (2/2) [Rezolvat]

	c	ϕ	ω	α	β	ν
estimare	0,077	0,091	0,0441	0,189	0,801	5,09
SE robustă	0,010	0,013	0,0085	0,023	0,023	0,32

- Reziduurile AR(1): ARCH-LM = $nR^2 = 1017$ ($R^2 = 0,153$), $Q(10)$ al pătratelor = 2496: efecte ARCH puternice
- $T = 6\,669$; $\alpha + \beta = 0,990$, timpul de înjumătățire $\ln 0,5 / (-0,01028) = 67,4$ zile; volatilitatea de lungă durată 32,8%, față de 22,1% în eșantion; $\hat{z}_t$: $Q(10) = 28,6$ ($p < 0,001$), $\hat{z}_t^2$: 7,2 ($p = 0,705$)
- Vîrfuri: 114% (2008), 89% (2020); ultima zi: 26,2%; 5,1% dintre zile ies din banda $\pm 2\hat{\sigma}_t$
- Interpretare: sub nivelul de lungă durată (26,2% față de 32,8%); modelul se așteaptă ca volatilitatea să crească lent spre acest nivel, dar nivelul este imprecis ($1 - \alpha - \beta = 0,0102$)


B2: EUR/RON și Bitcoin [Propus]

- ▣ **Întrebarea:** se comportă cursul EUR/RON și Bitcoin la fel ca BET? Model: B1.
- ▣ **Date:** EUR/RON (cursul de referință BNR) din iulie 2005, Bitcoin din septembrie 2014; randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Repetați pașii 1–4 din B1 pentru ambele serii (EUR/RON: estimați pe 10 r_t).
 2. Raportați $\hat{\alpha} + \hat{\beta}$ și precizați dacă timpul de înjumătățire și volatilitatea de lungă durată există.
 3. Interpretare: ce înseamnă $\hat{\alpha} + \hat{\beta} = 1$ pentru o prognoză a volatilității peste un an?
- ▣ **Raportați:** un tabel și două fraze
- ▣ Notebook: secțiunea B2

B3: efectul de levier la S&P 500 [Rezolvat]

- ▣ **Întrebarea:** cresc scăderile volatilitatea S&P 500 mai mult decât creșterile de aceeași mărime?
- ▣ **Date:** închiderile S&P 500 din 2000, randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați GARCH(1,1)-t și GJR-GARCH(1,1)-t; raportați γ cu statistica t robustă.
 2. Calculați statistica LR pentru GJR față de GARCH, p-value-ul ei și cele două valori BIC.
 3. Aplicați testul de asimetrie (sign bias) pe reziduurile standardizate ale GARCH-t.
 4. Desenați ambele curbe de impact ale știrilor și calculați varianța GJR după șocuri de -2% și $+2\%$.
 5. Interpretare: cum schimbă efectul de levier VaR-ul din ziua de după o scădere?
- ▣ **Raportați:** patru statistici cu p-value-uri, două varianțe, graficul și două fraze
- ▣ **Notebook:** secțiunea B3

B3: rezolvare (1/2) [Rezolvat]



B3: rezolvare (2/2) [Rezolvat]

- GJR: $\hat{\alpha} = 0,000$, $\hat{\gamma} = 0,205$ ($t = 10,0$), $\hat{\beta} = 0,881$; LR = 235,7 ($p < 0,001$); BIC 18169,0 $\rightarrow$ 17942,2
- Testul de asimetrie pe reziduurile GARCH-t: $\chi^2(3) = 40,7$ ($p < 0,001$), t al semnului = 3,56
- Variația GJR după -2% : 2,14; după $+2\%$: 1,31; raportul 1,62
- Interpretare: doar scăderile cresc variația ($\hat{\alpha} = 0$); după o scădere, VaR este de circa $\sqrt{1,62} = 1,27$ ori VaR-ul de după o creștere egală; un GARCH simetric subestimează riscul după zilele proaste


B4: asimetria la BET, EUR/RON și Bitcoin [Propus]

- ▣ **Întrebarea:** există un efect de levier la BET, la EUR/RON și la Bitcoin? Model: B3.
- ▣ **Date:** BET din 2000, EUR/RON din 2005, Bitcoin din 2014; randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați GJR-GARCH(1,1)- t și EGARCH(1,1)- t ; raportați ambele valori γ , cu statisticile t robuste.
 2. Calculați testul LR pentru GJR față de GARCH și modificarea BIC.
 3. Interpretare: pentru EUR/RON un randament pozitiv înseamnă un leu mai slab; ce sînt „știrile proaste” pentru această serie?
- ▣ **Raportați:** un tabel și două fraze
- ▣ Notebook: secțiunea B4

B5: GARCH față de EWMA pentru S&P 500 [Rezolvat]

- **Întrebarea:** prognozează GARCH(1,1)-t varianța de mîine a S&P 500 mai bine decît EWMA și este VaR 1% al lui depășit în 1% dintre zile?
- **Date:** S&P 500 din 2000; prognoze pentru fiecare zi de la 2 ianuarie 2015
- **Cerințe**
 1. Reestimați GARCH(1,1)-t la fiecare 250 de zile pe toate datele pînă în acea zi și calculați prognozele pe o zi h_t ; calculați EWMA cu $\lambda = 0,94$.
 2. Calculați media QLIKE pentru ambele modele și statistica t Diebold–Mariano.
 3. Numărați depășirile VaR 1% GARCH-t și VaR 1% EWMA-Normal și comparați-le cu numărul așteptat.
 4. Desenați diferența cumulată a pierderilor.
 5. Interpretare: ce model i-ați da unui manager de risc și ce ați mai îmbunătăți?
- **Raportați:** patru valori, două numărători, graficul și două fraze
- Notebook: secțiunea B5

B5: rezolvare (1/2) [Rezolvat]



B5: rezolvare (2/2) [Rezolvat]

- 2 944 de zile; media QLIKE: GARCH-t 0,761, EWMA 0,819; DM: diferența medie $-0,058$, $t = -3,69$ ($p < 0,001$): GARCH-t este mai bun
- Depășiri VaR 1%: GARCH-t 49 (1,66%), EWMA-Normal 65 (2,21%); așteptat circa 29
- Interpretare: GARCH-t, dar ambele modele VaR sînt depășite prea des; adăugăm efectul de levier (B3) și testăm formal numărul de depășiri ([Kupiec \(1995\)](#))

B6: GARCH față de EWMA pentru BET și EUR/RON [Propus]

- **Întrebarea:** se păstrează rezultatul din B5 pentru BET și pentru EUR/RON? Model: B5.
- **Date:** BET din 2000, EUR/RON din 2005; prognoze pentru fiecare zi din ianuarie 2015
- **Cerințe**
 1. Calculați prognozele GARCH(1,1)-t și EWMA în afara eșantionului, ca în B5.
 2. Calculați media QLIKE pentru ambele modele și testul DM.
 3. Găsiți ziua cu cea mai mare diferență a pierderilor și recalculați media QLIKE fără ea.
 4. Numărați depășirile VaR 1% pentru ambele modele.
 5. Interpretare: de ce poate fi testul DM nesemnificativ când o medie QLIKE este jumătate din cealaltă?
- **Raportați:** un tabel și două fraze
- Notebook: secțiunea B6

C1: este leul mai liniștit decât înainte? [Propus]

- ▣ **Întrebarea:** s-a schimbat volatilitatea EUR/RON între perioadele 2005–2012, 2013–2019 și 2020–2026 și poate un singur model GARCH să descrie toate trei perioadele?
- ▣ **Date:** randamentele logaritmice zilnice EUR/RON în % (cursul de referință BNR); model: B1
- ▣ **Cerințe**
 1. Pentru fiecare perioadă calculați volatilitatea de selecție anualizată și ponderea zilelor cu $|r_t| > 0,5\%$.
 2. Estimați GARCH(1,1)-t pe fiecare perioadă și raportați $\alpha + \beta$, α și ν .
 3. Găsiți cea mai mare variație zilnică din fiecare perioadă și data ei.
 4. Interpretare: este schimbarea volatilității o proprietate a pieței sau a politicii de curs de schimb?
- ▣ **Raportați:** un tabel și un plan de proiect
- ▣ **Notebook:** secțiunea C1

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI să interpreteze un GARCH(1,1)-t estimat pentru BET (date zilnice, din 2000):
 $\hat{\omega} = 0,0448$, $\hat{\alpha} = 0,192$, $\hat{\beta} = 0,799$, $\hat{\nu} = 5,01$. Răspunsul:
 - (a) Timpul de înjumătățire al unui șoc de volatilitate este $\ln 0,5 / \ln \beta = 3,1$ zile.
 - (b) Varianța de lungă durată este $\omega/(1 - \alpha) = 0,055$, o volatilitate anuală de 3,7%.
 - (c) Un AR(1) estimat prin OLS dă $\phi = 0,109$ cu SE 0,012, $t = 8,9$: randamentele BET sînt puternic previzibile.
 - (d) Ljung-Box Q(10) al pătratelor reziduurilor standardizate = 8,3, $p = 0,60$: modelul GARCH-t este corect.
 - (e) Cu inovații Student-t, cuantila de 1% a lui z este mai aproape de 0 decît valoarea Normală -2,326, deci VaR 1% este mai mic.
 - (f) $\alpha + \beta = 0,991 < 1$, deci modelul este staționar în covarianță, iar volatilitatea revine la nivelul de lungă durată.
- Cerințe
 - 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă din notebook (secțiunea C2).
 - 2. Raportați: o listă de șase verdicte, fiecare cu un rînd de justificare.

Idei de reținut

- ▣ Testăm efectele ARCH pe reziduurile modelului pentru medie: ARCH-LM = nR^2 și Ljung–Box pe pătrate
- ▣ $\alpha + \beta$ decide termenul lung: timpul de înjumătățire, varianța de lungă durată, forma prognozelor; $\alpha + \beta = 1$: IGARCH
- ▣ Riscul pe mai multe zile este suma prognozelor zilnice ale varianței, nu $\sqrt{H}$ ori volatilitatea de azi
- ▣ Inovațiile cu cozi groase schimbă cuantila VaR; asimetria schimbă VaR-ul după zilele proaste
- ▣ Comparăm prognozele în afara eșantionului (QLIKE, DM) și căutăm zilele care determină singure rezultatul

După seminar

- ▣ Cursul 5 dezvoltă fiecare temă de azi: faptele stilizate, ARCH și GARCH, estimarea, ARMA-GARCH, asimetria, diagnosticarea, prognozele, VaR 1%
- ▣ Încercați cerințele [Propus] în notebook
- ▣ C1 poate deveni un proiect de echipă: regimurile de volatilitate ale leului și ale altor valute din regiune
- ▣ Lectură: [Huang și Petukhina \(2022\)](#), cap. 6; [Tsay \(2010\)](#), cap. 3
- ▣ **Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar**

Bibliografie (1/2)

- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. doi:[10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1)
- Bollerslev, T. (1987). A conditionally heteroskedastic time series model for speculative prices and rates of return. *Review of Economics and Statistics*, 69(3), 542–547. doi:[10.2307/1925546](https://doi.org/10.2307/1925546)
- Bollerslev, T., & Wooldridge, J. M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172. doi:[10.1080/07474939208800229](https://doi.org/10.1080/07474939208800229)
- Christie, A. A. (1982). The stochastic behavior of common stock variances: Value, leverage and interest rate effects. *Journal of Financial Economics*, 10(4), 407–432. doi:[10.1016/0304-405X\(82\)90018-6](https://doi.org/10.1016/0304-405X(82)90018-6)
- Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:[10.1080/07350015.1995.10524599](https://doi.org/10.1080/07350015.1995.10524599)
- Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007. doi:[10.2307/1912773](https://doi.org/10.2307/1912773)
- Engle, R. F., & Ng, V. K. (1993). Measuring and testing the impact of news on volatility. *Journal of Finance*, 48(5), 1749–1778. doi:[10.1111/j.1540-6261.1993.tb05127.x](https://doi.org/10.1111/j.1540-6261.1993.tb05127.x)
- Glosten, L. R., Jagannathan, R., & Runkle, D. E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801. doi:[10.1111/j.1540-6261.1993.tb05128.x](https://doi.org/10.1111/j.1540-6261.1993.tb05128.x)

Bibliografie (2/2)

- ▣ Huang, C., & Petukhina, A. (2022). *Applied Time Series Analysis and Forecasting with Python*. Springer. doi:10.1007/978-3-031-13584-2
- ▣ J.P. Morgan/Reuters (1996). *RiskMetrics – Technical Document* (4th ed.). Morgan Guaranty Trust Company. [msci.com](https://www.msci.com)
- ▣ Kupiec, P. H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84. doi:10.3905/jod.1995.407942
- ▣ Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303. doi:10.1093/biomet/65.2.297
- ▣ Nelson, D. B. (1991). Conditional heteroskedasticity in asset returns: A new approach. *Econometrica*, 59(2), 347–370. doi:10.2307/2938260
- ▣ Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256. doi:10.1016/j.jeconom.2010.03.034
- ▣ Tsay, R. S. (2010). *Analysis of Financial Time Series* (3rd ed.). Wiley. doi:10.1002/9780470644560