



Serii de timp

Seminarul 8: Memorie lungă și ARFIMA



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **ACF**: Autocorrelation Function (funcția de autocorelație)
- ▣ **AI**: Artificial Intelligence (inteligență artificială)
- ▣ **AIC**: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ **AR**: AutoRegressive (model) — model autoregresiv
- ▣ **ARCH**: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ **ARFIMA**: AutoRegressive Fractionally Integrated Moving Average (model) — model autoregresiv fracționar integrat cu medie mobilă
- ▣ **ARIMA**: AutoRegressive Integrated Moving Average (model) — model autoregresiv integrat cu medie mobilă
- ▣ **ARMA**: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **BET**: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BIC**: Bayesian Information Criterion (criteriul informațional bayesian al lui Schwarz)
- ▣ **BNR**: Banca Națională a României
- ▣ **DFA**: Detrended Fluctuation Analysis (analiza fluctuațiilor fără tendință)

Acronime folosite în acest material (2/2)

- ▣ **EODHD**: EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ **FIGARCH**: Fractionally Integrated GARCH (model GARCH fracționar integrat)
- ▣ **FRED**: Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- ▣ **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ **GPH**: Geweke–Porter–Hudak (estimator) — estimatorul Geweke–Porter–Hudak al parametrului de memorie lungă
- ▣ **IAPC**: Indicele armonizat al prețurilor de consum
- ▣ **IPC**: Indicele prețurilor de consum
- ▣ **LW**: Local Whittle (estimator) — estimatorul Whittle local
- ▣ **MA**: Moving Average (medie mobilă)
- ▣ **ML**: Machine Learning (învățare automată)
- ▣ **OLS**: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **RV**: Realised Volatility (volatilitatea realizată)
- ▣ **SE**: Standard Error (eroare standard)
- ▣ **SUA**: Statele Unite ale Americii

Întrebarea de azi și traseul

- ▣ **Întrebarea:** se stinge un șoc într-o serie exponențial (ARMA) sau mult mai lent (memorie lungă) și cum măsurăm diferența?
 - ▶ seminarul are loc **înaintea** Cursului 8: secțiunea „Noțiuni necesare azi” dă toate definițiile folosite în cerințe
- ▣ Traseul
 - ▶ Partea A: ponderi fracționare și autocorelații ARFIMA; R/S și GPH calculate de mână; o prognoză ARFIMA; ponderile GARCH și FIGARCH
 - ▶ Partea B: Nilul și ruptura lui; inflația din România; volatilitatea S&P 500; BET și EUR/RON
 - ▶ Partea C: inflația din SUA și regimurile monetare; un răspuns AI de verificat
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); fiecare cerință indică secțiunea din notebook

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	ponderile lui $(1 - L)^d$, ACF a unui ARFIMA(0, d , 0), intervalele lui d	Rezolvat, Propus	A1
A3, A4	R/S și H de mână; o pantă GPH de mână	Rezolvat, Propus	A3
A5, A6	o prognoză ARFIMA; ponderile GARCH și FIGARCH	Rezolvat, Propus	A5
B1, B2	Nilul și ruptura lui; inflația din România	Rezolvat, Propus	B1
B3, B4	volatilitatea S&P 500; BET și EUR/RON	Rezolvat, Propus	B3
C1, C2	inflația din SUA și regimurile; erorile dintr-un răspuns AI	Propus	B1, B2

- ▣ **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model

Datele folosite

Seria	Sursa	Frecvența	Perioada
Debitul Nilului la Aswan	statsmodels (nile)	anual	1871–1970
IAPC, România	Eurostat (prc_hicp_minr)	lunar, 2015 = 100	2005–2026
IPC, Statele Unite	FRED (CPIAUCSL)	lunar, ajustat sezonier	1947–2026
S&P 500, BET	EODHD	zilnic, închidere	2000–2026
EUR/RON	cursul de referință BNR	zilnic	2005–2026

- Inflația din România: rata lunară $100\Delta \ln P_t$ din care se scad mediile lunare (ajustare sezonieră) și rata anuală $100(\ln P_t - \ln P_{t-12})$
- În notebook: `gph`, `local_whittle`, `hurst_rs`, `arfima_exact_ml`, `monthly_rv`; nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/5): memorie scurtă și memorie lungă

- ▣ $\rho(k)$: autocorelația la lagul k ([Capitolul 1](#)); memoria = cât de repede tinde $\rho(k)$ spre zero
- ▣ **Memoria scurtă** (ARMA, [Capitolul 2](#)): $|\rho(k)| \leq Cr^k$, $0 < r < 1$; autocorelațiile sînt sumabile
 - ▶ $C > 0$: o constantă; r : rata de descreștere pe lag; AR(1): $\rho(k) = \phi^k$
- ▣ **Memoria lungă**: $\rho(k) \sim Ck^{2d-1}$, $0 < d < 1/2$: descreștere hiperbolică, $\sum_k \rho(k) = \infty$
 - ▶ d : parametrul de memorie; $\sim$: raportul celor doi membri tinde la 1 cînd $k \rightarrow \infty$
 - ▶ echivalent, densitatea spectrală are un pol la zero: $f(\lambda) \sim G\lambda^{-2d}$ cînd $\lambda \rightarrow 0$ (λ : frecvența, în radiani; $G > 0$: o constantă)
- ▣ **Exponentul Hurst** $H = d + 1/2$: $H = 0,5$ fără memorie, $H > 0,5$ persistență, $H < 0,5$ antipersistență
 - ▶ Hurst a găsit $H \approx 0,7$ pentru Nil [Hurst \(1951\)](#)

Noțiuni necesare azi (2/5): diferențierea fracționară și ARFIMA

- Operatorul lag $Lx_t = x_{t-1}$; diferența fracționară $(1 - L)^d$, pentru d real, folosește toate valorile trecute
 - ▶ $(1 - L)^d = \sum_k \pi_k L^k$, cu $\pi_0 = 1$, $\pi_k = \pi_{k-1}(k - 1 - d)/k$; π_k : ponderea lui x_{t-k}
 - ▶ inversul $(1 - L)^{-d} = \sum_k \psi_k L^k$, $\psi_k = \psi_{k-1}(k - 1 + d)/k$: ψ_k este efectul unui șoc după k perioade
- **ARFIMA**(p, d, q): $\phi(L)(1 - L)^d(x_t - \mu) = \theta(L)\varepsilon_t$ Granger și Joyeux (1980), Hosking (1981)
 - ▶ $\phi(L)$, $\theta(L)$: polinoamele AR și MA (Capitolul 2); μ : media; ε_t : zgomot alb cu varianța σ^2
- Integrale: inversabil pentru $d > -1/2$; staționar pentru $d < 1/2$; cu revenire la medie pentru $d < 1$; $d = 1$ rădăcină unitară
 - ▶ dacă $1/2 \leq d < 3/2$, diferențiem o dată: $(1 - L)x_t$ este ARFIMA cu $d - 1$

Noțiuni necesare azi (3/5): ARFIMA(0, d , 0) în cifre

- ▣ Autocorelațiile, prin recurență: $\rho(1) = d/(1 - d)$, $\rho(k) = \rho(k - 1)(k - 1 + d)/(k - d)$
- ▣ Varianța: $\gamma(0) = \sigma^2 \Gamma(1 - 2d)/\Gamma(1 - d)^2$
 - ▶ $\Gamma(\cdot)$: funcția gamma, $\Gamma(n) = (n - 1)!$ pentru numere întregi; pentru $d > 0$, $\gamma(0) > \sigma^2$: memoria acumulează șocurile trecute
- ▣ Prognoza la un pas: $\hat{x}_{T+1} = \mu - \sum_{k \geq 1} \pi_k (x_{T+1-k} - \mu)$
 - ▶ x_T : ultima observație; deoarece $\pi_k < 0$ pentru $k \geq 1$ când $0 < d < 1$, fiecare abatere trecută de la μ împinge prognoza în sensul ei

Noțiuni necesare azi (4/5): estimatori ai lui d și H

- ▣ **R/S**: într-un bloc de n valori, $Y_k = \sum_{i \leq k} (x_i - \bar{x})$, $R = \max Y_k - \min Y_k$, S abaterea standard (împărțitor n)
 - ▶ $\bar{x}$: media blocului; $H = \text{panta lui } \log_{10}(R/S)_n \text{ față de } \log_{10} n$; **DFA**: panta fluctuației fără tendință $\log F(n)$
- ▣ **GPH**: OLS a lui $y_j = \log I(\lambda_j)$ pe $X_j = -\log(4 \sin^2(\lambda_j/2))$, $j = 1, \dots, m$; panta $= \hat{d}$, $SE = \pi/\sqrt{24m}$
 - ▶ $I(\lambda_j)$: periodograma (o estimare zgomotoasă a lui f) la frecvența Fourier $\lambda_j = 2\pi j/T$; T : numărul de observații; m : numărul frecvențelor joase folosite
 - ▶ panta OLS $= \sum (X_j - \bar{X})(y_j - \bar{y}) / \sum (X_j - \bar{X})^2$
- ▣ **Whittle local (LW) Robinson (1995)**: o verosimilitate locală pe aceleași m frecvențe, $SE = 1/(2\sqrt{m})$; lățimea de bandă $m = \lfloor T^{0,65} \rfloor$
 - ▶ **ML exactă Sowell (1992)**: verosimilitatea completă ARFIMA(p, d, q); comparăm modelele după AIC și BIC

Noțiuni necesare azi (5/5): volatilitate și memorie aparentă

- Randamentele r_t sînt aproape necorelate; $|r_t|$ și volatilitatea realizată au memorie lungă [Ding, Granger și Engle \(1993\)](#)
 - ▶ **volatilitatea realizată** lunară: $\sqrt{RV_m}$, $RV_m = \sum_{t \in m} r_t^2$, suma pătratelor randamentelor zilnice din luna m ; modelăm logaritmul ei
 - ▶ **testul permutării**: permutăm zilele aleator; memoria reală dispăre, distribuția rămîne
- GARCH(1,1) ca ARCH(∞): ponderea $\alpha\beta^{k-1}$ pentru ε_{t-k}^2 ; FIGARCH [Baillie, Bollerslev și Mikkelsen \(1996\)](#): ponderi $\approx k^{-1-d}$
 - ▶ ε_{t-k}^2 : pătratul șocului de acum k zile; α, β : parametrii GARCH ([Capitolul 5](#)); σ_t^2 : varianța condiționată de azi
 - ▶ cu $\phi = \beta = 0$, ponderile FIGARCH sînt $\lambda_k = -\pi_k$ ale lui $(1 - L)^d$
- **Memoria lungă aparentă**: schimbările de nivel și schimbările rare de regim dau $\hat{d} > 0$ pentru serii cu memorie scurtă [Diebold și Inoue \(2001\)](#); reestimați după eliminarea rupturilor

A1: ponderi fracționare și ACF [Rezolvat]

Cerință

- O serie este ARFIMA(0; 0,25; 0), cu $\sigma^2 = 1$.
- 1. Calculați $\pi_1, \dots, \pi_4$ pentru $(1 - L)^{0,25}$.
- 2. Calculați $\rho(1)$ și $\rho(2)$ și precizați H și clasa procesului.
- 3. Comparați $\rho(5)$ cu valoarea unui AR(1) cu același $\rho(1)$.
- Raportați: patru ponderi, două autocorelații, H , două valori ale lui $\rho(5)$.

Rezolvare

- 1. $\pi_1 = -0,25$; $\pi_2 = -0,25 \cdot 0,75/2 = -0,0938$;
 $\pi_3 = -0,0938 \cdot 1,75/3 = -0,0547$;
 $\pi_4 = -0,0547 \cdot 2,75/4 = -0,0376$
- 2. $\rho(1) = 0,25/0,75 = 0,333$;
 $\rho(2) = 0,333 \cdot 1,25/1,75 = 0,238$; $H = 0,75$: staționar, memorie lungă
- 3. ARFIMA: $\rho(5) = 0,151$; AR(1): $0,333^5 = 0,0041$, de aproximativ 37 de ori mai mic

A2: intervalul în care se află d [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Două serii: (a) ARFIMA(0; 0,6; 0); (b) ARFIMA(0; -0,3; 0). Model: A1.
- ▣ 1. Calculați π_1 și π_2 ale lui $(1 - L)^d$ pentru fiecare.
- ▣ 2. Precizați dacă fiecare serie este staționară, inversabilă și cu revenire la medie.
- ▣ 3. Pentru (b) calculați $\rho(1)$ și $\rho(2)$; pentru (a) calculați $\rho(1)$ al primei diferențe.
- ▣ Raportați: patru ponderi, două clasificări, trei autocorelații.

A3: R/S de mînă și H din trei puncte [Rezolvat]

Cerință

- Blocul:
 $x = (0,6; 0,4; 0,5; 0,3; -0,4; -0,6; -0,2; -0,5)$. Un grafic R/S dă $(R/S)_n = 4,1; 9,6; 22,4$ pentru $n = 16; 64; 256$.
- 1. Calculați $\bar{x}$, abaterile cumulate Y_k , R , S și R/S .
- 2. Calculați H ca pantă a lui $\log_{10}(R/S)_n$ față de $\log_{10} n$ și $d = H - 0,5$.
- Raportați: R/S , H , d și o frază.

Rezolvare

- 1. $\bar{x} = 0,0125$; Y_k : 0,5875; 0,9750; 1,4625; 1,7500; 1,3375; 0,7250; 0,5125; 0; $R = 1,750$, $S = 0,457$, $R/S = 3,83$
- semnele sînt grupate (patru pozitive, apoi patru negative): amplitudinea este mare, ca pentru o serie persistentă
- 2. $\log_{10} n$: 1,204; 1,806; 2,408; $\log_{10}(R/S)$: 0,613; 0,982; 1,350; panta $H = 0,61$, $d = 0,11$: persistență moderată

A4: o pantă GPH de mînă [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Pentru $m = 4$ frecvențe: $X_j = 0,5; 1,6; 2,3; 3,0$ și $\log l(\lambda_j) = 1,2; 1,8; 2,0; 2,5$. Model: A3.
- ▣ 1. Calculați $\bar{X}$, $\bar{y}$, $\sum(X_j - \bar{X})(y_j - \bar{y})$ și $\sum(X_j - \bar{X})^2$.
- ▣ 2. Calculați $\hat{d}$ și eroarea standard $\pi/\sqrt{24m}$.
- ▣ 3. Testați $H_0: d = 0$ la 5% și comentați mărimea lui m .
- ▣ Raportați: patru sume, $\hat{d}$, SE, o decizie și o frază.

A5: o prognoză ARFIMA la un pas [Rezolvat]

Cerință

- ▣ ARFIMA(0; 0,4; 0), cu $\mu = 2$; ultimele patru valori: $x_T = 3,0$, $x_{T-1} = 2,5$, $x_{T-2} = 2,8$, $x_{T-3} = 1,5$.
- ▣ 1. Scrieți primele patru ponderi $-\pi_k$ ale lui $(1 - L)^{0,4}$.
- ▣ 2. Calculați $\hat{x}_{T+1}$ folosind aceste patru laguri.
- ▣ 3. Comparați cu un AR(1) cu același $\rho(1)$.
- ▣ Raportați: patru ponderi, două prognoze și o frază.

Rezolvare

- ▣ 1. $-\pi_k$: 0,4; 0,12; 0,064; 0,0416
- ▣ 2. $\hat{x}_{T+1} =$
 $2 + 0,4(1,0) + 0,12(0,5) + 0,064(0,8) + 0,0416(-0,5) =$
 $2 + 0,4000 + 0,0600 + 0,0512 - 0,0208 = 2,490$
- ▣ 3. AR(1): $\phi = \rho(1) = 0,4/0,6 = 0,667$,
 $\hat{x}_{T+1} = 2 + 0,667 \cdot 1,0 = 2,667$; AR(1) se uită doar la x_T ,
 ARFIMA distribuie ponderea pe trecut (în practică, pe toate cele T valori)

A6: durata efectului unui șoc al volatilității [Propus]

Rezolvarea se discută la seminar


Cerință

- ▣ GARCH(1,1) cu $\alpha = 0,10$, $\beta = 0,88$; FIGARCH(0, d , 0) cu $d = 0,4$ (ponderile $\lambda_k = -\pi_k$). Model: A5.
- ▣ 1. Calculați ponderea lui ε_{t-k}^2 în σ_t^2 pentru $k = 1, 2, 3$ în ambele modele.
- ▣ 2. Calculați ambele ponderi la $k = 20$ și $k = 100$; pentru FIGARCH folosiți $\lambda_k \approx d k^{-1-d} / \Gamma(1 - d)$, $\Gamma(0,6) = 1,489$.
- ▣ 3. Explicați ce model păstrează mai mult timp o criză în volatilitatea de azi.
- ▣ Raportați: zece ponderi și o frază.


B1: are Nilul memorie lungă? [Rezolvat]

- ▣ **Întrebarea:** este persistența debitului Nilului memorie lungă sau efectul schimbării din 1898?
- ▣ **Date:** debitul anual la Aswan, 1871–1970 ($T = 100$)
- ▣ **Cerințe**
 1. Reprezentați grafic seria și ACF pînă la lagul 20.
 2. Estimați H prin R/S, d prin GPH și Whittle local ($m = \lfloor T^{0.65} \rfloor$) și prin ML exactă pentru ARFIMA(0, d , 0).
 3. Scădeți media din 1871–1898 și media din 1899–1970 și repetați pasul 2.
 4. Interpretare: are Nilul memorie lungă?
- ▣ **Raportați:** două valori ale ACF, patru estimări înainte și după, o frază
- ▣ Notebook: secțiunea B1

B1: rezolvare [Rezolvat]



— Nile flow at Aswan (10^8 m^3)
 — regime means, break after 1898
 — ACF, raw series



— ACF, regime means removed
 95% band for white noise

- Seria brută: $\hat{\rho}(1) = 0,50$, $\hat{\rho}(10) = 0,09$; $H_{R/S} = 0,78$; GPH 0,44 (SE 0,15), LW 0,40 (SE 0,11), ML 0,36 (SE 0,07); $m = 19$
- Mediile 1098 și 850; după eliminarea lor: $\hat{\rho}(1) = 0,16$; $H_{R/S} = 0,63$; GPH $-0,07$, LW $-0,17$, ML 0,05 (SE 0,10)
- Interpretare: pentru 1871–1970 dovada de memorie lungă provine dintr-o singură ruptură; R/S rămîne peste 0,5 deoarece este deplasat în sus în eșantioane scurte


B2: memoria lungă a inflației din România [Propus]

- ▣ **Întrebarea:** cât de persistentă este inflația din România și schimbă modul de măsurare a inflației răspunsul?
- ▣ **Date:** IAPC lunar, 2005–2026: rata lunară ajustată sezonier cu mediile lunare și rata anuală; model: B1
- ▣ **Cerințe**
 1. Estimați d al ratei lunare prin GPH și Whittle local, cu $m = \lfloor T^a \rfloor$, $a = 0,5; 0,65; 0,8$.
 2. Estimați ARFIMA(0, d , 0) și ARMA(1,1) prin ML exactă și comparați BIC.
 3. Estimați d al ratei anuale prin Whittle local și comparați cele două ACF.
 4. Interpretare: de ce dă rata anuală un d apropiat de 1?
- ▣ **Raportați:** șase estimări, două valori BIC, un d , două fraze
- ▣ Notebook: secțiunea B2

B3: memoria volatilității S&P 500 [Rezolvat]

- ▣ **Întrebarea:** unde se află memoria randamentelor bursiere: în randamente sau în mărimea lor?
- ▣ **Date:** randamentele logaritmice zilnice S&P 500 din 2000 și volatilitatea lor realizată lunară
- ▣ **Cerințe**
 1. Estimați d pentru r_t și pentru $|r_t|$ prin Whittle local și GPH.
 2. Permutați aleator zilele și reestimați d pentru $|r_t|$; reprezentați grafic ambele ACF ale lui $|r_t|$.
 3. Estimați d pentru logaritmul volatilității realizate lunare.
 4. Interpretare: ce arată testul permutării?
- ▣ **Raportați:** opt estimări, graficul și o frază
- ▣ Notebook: secțiunea B3

B3: rezolvare [Rezolvat]



- $T = 6\,714$ de zile; r_t : LW $-0,01$, GPH $0,02$ (SE $0,03$; $0,04$); $|r_t|$: LW $0,53$, GPH $0,56$
- $|r_t|$ permutat: LW $-0,03$, GPH $-0,03$; ACF a lui $|r_t|$: $0,289$ (lagul 1), $0,127$ (lagul 50), $0,009$ (lagul 200); log RV (321 de luni): LW $0,41$, GPH $0,37$
- Interpretare: permutarea păstrează fiecare valoare zilnică și le distruge ordinea; memoria dispare, deci ea se află în succesiunea perioadelor calme și agitate (volatility clustering), nu în distribuția randamentelor

B4: BET și EUR/RON [Propus]

- **Întrebarea:** au BET și cursul EUR/RON aceeași memorie și este ea stabilă înainte și după criza din 2008?
- **Date:** randamentele logaritmice zilnice ale BET (din 2000) și ale cursului de referință EUR/RON (din iulie 2005); model: B3
- **Cerințe**
 1. Estimați d pentru r_t și $|r_t|$ prin Whittle local pe tot eșantionul.
 2. Repetați pe subeșantioanele pînă în 2007 și 2010–2026.
 3. Comparați estimările pentru r_t cu banda Monte Carlo de 95% a seriilor i.i.d. de 1900 de zile.
 4. Interpretare: este reală memoria randamentelor BET pe tot eșantionul?
- **Raportați:** douăsprezece estimări, o bandă și două fraze
- Notebook: secțiunea B4

C1: inflația din SUA și regimurile monetare [Propus]

- **Întrebarea:** este memoria lungă a inflației din SUA o proprietate a inflației sau a schimbărilor de politică monetară?
- **Date:** inflația lunară IPC din SUA, anualizată, 1947–2026; regimurile 1947–1984, 1985–2019, 2020–2026; modele: B1, B2
- **Cerințe**
 1. Estimați d prin Whittle local pe tot eșantionul și în fiecare regim.
 2. Eliminați cele trei medii de regim și reestimați d .
 3. Propuneți încă o verificare (un test de ruptură, un model Markov switching, o comparație de prognoze).
 4. Interpretare: poate un d constant să descrie 80 de ani de inflație?
- **Raportați:** cinci estimări, o verificare și un plan de proiect
- Notebook: secțiunea C1

C2: verificați un răspuns AI [Propus]

- ▣ Un student a întrebat un asistent AI despre memoria lungă a inflației din România și a S&P 500. Răspunsul:
- ▣ (a) Inflația lunară are $d = 0,31$, deci exponentul Hurst este $H = d - 0,5 < 0$: este antipersistentă.
- ▣ (b) Rata anuală dă $d = 1,00$, deci inflația din România are rădăcină unitară.
- ▣ (c) Cu $d = 0,31$ seria este staționară, iar șocurile ei se sting.
- ▣ (d) Folosiți `statsmodels.tsa.arima.model.ARIMA(x, order=(0, 0.31, 0))` pentru a estima modelul ARFIMA.
- ▣ (e) Randamentele S&P 500 au $d = -0,01$, iar $|r|$ are $d = 0,53$, deci randamentele sînt previzibile.
- ▣ (f) O estimare GPH semnificativă demonstrează memoria lungă.
- ▣ **Cerințe**
 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă din notebook (secțiunea C2).
- ▣ **Raportați:** o listă de șase verdicte, fiecare cu un rînd de justificare

Idei de reținut

- ▣ $(1 - L)^d$: ponderile prin recurența $\pi_k = \pi_{k-1}(k - 1 - d)/k$; ARFIMA(0, d , 0): $\rho(1) = d/(1 - d)$
- ▣ $H = d + 1/2$; R/S și GPH sînt pante ale unor regresii log-log
- ▣ Inflația lunară din România: $d \approx 0,3$; S&P 500: memorie în $|r_t|$, nu în r_t
- ▣ Rupturile pot crea memorie lungă: Nilul, randamentele BET, inflația din SUA
- ▣ Un răspuns AI este o ciornă: verificați relația dintre H și d , biblioteca și transformarea datelor

După seminar

- Cursul 8 dezvoltă fiecare temă de azi
 - ▶ descreșterea hiperbolică, diferențierea fracționară, ARFIMA, estimatorii, prognoza, volatilitatea, memoria aparentă
- Încercați cerințele [Propus] în notebook
- C1 poate deveni un proiect de echipă: memoria inflației și regimurile monetare din România
- Lectură: Baillie (1996); Graves et al. (2017); Ding, Granger și Engle (1993)
- **Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar**

Bibliografie

- ▣ Baillie, R. T. (1996). Long memory processes and fractional integration in econometrics. *Journal of Econometrics*, 73(1), 5–59. doi:10.1016/0304-4076(95)01732-1
- ▣ Baillie, R. T., Bollerslev, T., & Mikkelsen, H. O. (1996). Fractionally integrated generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 74(1), 3–30. doi:10.1016/S0304-4076(95)01749-6
- ▣ Diebold, F. X., & Inoue, A. (2001). Long memory and regime switching. *Journal of Econometrics*, 105(1), 131–159. doi:10.1016/S0304-4076(01)00073-2
- ▣ Ding, Z., Granger, C. W. J., & Engle, R. F. (1993). A long memory property of stock market returns and a new model. *Journal of Empirical Finance*, 1(1), 83–106. doi:10.1016/0927-5398(93)90006-D
- ▣ Granger, C. W. J., & Joyeux, R. (1980). An introduction to long-memory time series models and fractional differencing. *Journal of Time Series Analysis*, 1(1), 15–29. doi:10.1111/j.1467-9892.1980.tb00297.x
- ▣ Graves, T., Gramacy, R., Watkins, N., & Franzke, C. (2017). A brief history of long memory: Hurst, Mandelbrot and the road to ARFIMA, 1951–1980. *Entropy*, 19(9), 437. doi:10.3390/e19090437
- ▣ Hosking, J. R. M. (1981). Fractional differencing. *Biometrika*, 68(1), 165–176. doi:10.1093/biomet/68.1.165
- ▣ Hurst, H. E. (1951). Long-term storage capacity of reservoirs. *Transactions of the American Society of Civil Engineers*, 116(1), 770–799. doi:10.1061/TACEAT.0006518
- ▣ Robinson, P. M. (1995). Gaussian semiparametric estimation of long range dependence. *The Annals of Statistics*, 23(5), 1630–1661. doi:10.1214/aos/1176324317
- ▣ Sowell, F. (1992). Maximum likelihood estimation of stationary univariate fractionally integrated time series models. *Journal of Econometrics*, 53(1–3), 165–188. doi:10.1016/0304-4076(92)90084-5