



Serii de timp

Seminarul 8: Memorie lungă și ARFIMA



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **ACF**: Autocorrelation Function (funcția de autocorelație)
- ▣ **AI**: Artificial Intelligence (inteligență artificială)
- ▣ **AR**: AutoRegressive (model) — model autoregresiv
- ▣ **ARCH**: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ **ARFIMA**: AutoRegressive Fractionally Integrated Moving Average (model) — model autoregresiv fracționar integrat cu medie mobilă
- ▣ **ARIMA**: AutoRegressive Integrated Moving Average (model) — model autoregresiv integrat cu medie mobilă
- ▣ **ARMA**: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **BET**: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BIC**: Bayesian Information Criterion (criteriul informațional bayesian al lui Schwarz)
- ▣ **BNR**: Banca Națională a României
- ▣ **DFA**: Detrended Fluctuation Analysis (analiza fluctuațiilor fără tendință)
- ▣ **EODHD**: EOD Historical Data (market-data provider) — furnizor de date de piață

Acronime folosite în acest material (2/2)

- ▣ **FIGARCH**: Fractionally Integrated GARCH (model GARCH fracționar integrat)
- ▣ **FRED**: Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- ▣ **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ **GPH**: Geweke–Porter–Hudak (estimator) — estimatorul Geweke–Porter–Hudak al parametrului de memorie lungă
- ▣ **IAPC**: Indicele armonizat al prețurilor de consum
- ▣ **IPC**: Indicele prețurilor de consum
- ▣ **LW**: Local Whittle (estimator) — estimatorul Whittle local
- ▣ **MA**: Moving Average (medie mobilă)
- ▣ **ML**: Machine Learning (învățare automată)
- ▣ **OLS**: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **RV**: Realised Volatility (volatilitatea realizată)
- ▣ **SE**: Standard Error (eroare standard)
- ▣ **SUA**: Statele Unite ale Americii

Întrebarea de azi și structura seminarului (1/3)

- ▣ Întrebarea seminarului
 - ▶ **se stinge un șoc într-o serie exponențial (ARMA) sau mult mai lent (memorie lungă) și cum măsurăm diferența?**
- ▣ Trei tipuri de exerciții
 - ▶ **A:** exerciții de calcul, pe hîrtie
 - ▶ **B:** exerciții pe date reale, rezolvate în notebook
 - ▶ **C:** întrebări deschise, de exemplu corectarea unui răspuns dat de un instrument AI
- ▣ Fiecare exercițiu este marcat
 - ▶ **[Rezolvat]:** rezolvarea completă este prezentată la seminar
 - ▶ **[Propus]:** îl rezolvați dumneavoastră; soluția se discută la seminar

Întrebarea de azi și structura seminarului (2/3)

▣ Exercițiile de azi, în ordine

- ▶ A1: ponderi fracționare și ACF
- ▶ A2: intervalul în care se află d
- ▶ A3: R/S de mână și H din trei puncte
- ▶ A4: o pantă GPH de mână
- ▶ A5: o prognoză ARFIMA la un pas
- ▶ A6: durata efectului unui șoc al volatilității
- ▶ B1: are Nilul memorie lungă?
- ▶ B2: memoria lungă a inflației din România
- ▶ B3: memoria volatilității S&P 500
- ▶ B4: BET și EUR/RON
- ▶ C1: inflația din SUA și regimurile monetare
- ▶ C2: verificarea unui răspuns AI

Întrebarea de azi și structura seminarului (3/3)

- ▣ Rezultate de obținut (nu se predă nimic)
 - ▶ răspunsurile la exercițiile A
 - ▶ câte o figură și un tabel pentru fiecare exercițiu B
 - ▶ răspunsul A1 corectat din C2
 - ▶ o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#)
 - ▶ fiecare cerință indică secțiunea din notebook
- ▣ Seminar: prof. Daniel Traian Pele, danpele@ase.ro

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	ponderile lui $(1 - L)^d$, ACF a unui ARFIMA(0, d , 0), intervalele lui d	Rezolvat, Propus	A1
A3, A4	R/S și H de mână; o pantă GPH de mână	Rezolvat, Propus	A3
A5, A6	o prognoză ARFIMA; ponderile GARCH și FIGARCH	Rezolvat, Propus	A5
B1, B2	Nilul și ruptura lui; inflația din România	Rezolvat, Propus	B1
B3, B4	volatilitatea S&P 500; BET și EUR/RON	Rezolvat, Propus	B3
C1, C2	inflația din SUA și regimurile; erorile dintr-un răspuns AI	Propus	B1, B2

- ▣ **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model

Datele folosite

Seria	Sursa	Frecvența	Perioada
Debitul Nilului la Aswan	statsmodels (nile)	anual	1871–1970
IAPC, România	Eurostat (prc_hicp_minr)	lunar, 2015 = 100	2005–2026
IPC, Statele Unite	FRED (CPIAUCSL)	lunar, ajustat sezonier	1947–2026
S&P 500, BET	EODHD	zilnic, închidere	2000–2026
EUR/RON	cursul de referință BNR	zilnic	2005–2026

- Inflația din România: rata lunară $100\Delta \ln P_t$ din care se scad mediile lunare (ajustare sezonieră) și rata anuală $100(\ln P_t - \ln P_{t-12})$
- În notebook: `gph`, `local_whittle`, `hurst_rs`, `arfima_exact_ml`, `monthly_rv`; nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/22): autocorelația și memoria

- ▣ **Autocovarianța și autocorelația** unei serii staționare x_t la lagul k

$$\gamma(k) = \text{Cov}(x_t, x_{t-k}), \quad \rho(k) = \frac{\gamma(k)}{\gamma(0)}$$

- ▶ $\gamma(0) = \text{Var}(x_t)$; $\rho(k) \in [-1, 1]$: corelația dintre două valori aflate la k perioade distanță

- ▣ **Autocorelația de selecție** (ACF a datelor, [Capitolul 1](#))

$$\hat{\rho}(k) = \frac{\sum_{t=k+1}^T (x_t - \bar{x})(x_{t-k} - \bar{x})}{\sum_{t=1}^T (x_t - \bar{x})^2}$$

- ▶ T : numărul de observații; $\bar{x}$: media de selecție; banda fără corelație: $\pm 1,96/\sqrt{T}$

- ▣ **Memoria**: cât de repede tinde $\rho(k)$ spre zero când lagul k crește

- ▶ descreștere rapidă: un șoc este uitat repede; descreștere lentă: trecutul îndepărtat contează în continuare

Noțiuni necesare azi (2/22): memorie scurtă și memorie lungă

- ▣ **Memoria scurtă** (modelele ARMA, [Capitolul 2](#)): descreștere exponențială

$$|\rho(k)| \leq C r^k, \quad 0 < r < 1$$

- ▶ $C > 0$: o constantă; r : factorul de descreștere pe lag; AR(1): $\rho(k) = \phi^k$, deci $r = |\phi|$
- ▶ autocorelațiile sînt sumabile: $\sum_k |\rho(k)| < \infty$

- ▣ **Memoria lungă**: descreștere hiperbolică (după o lege de putere)


$$\rho(k) \sim C k^{2d-1}, \quad 0 < d < \frac{1}{2}$$

- ▶ d : **parametrul de memorie**; $\sim$: raportul celor doi membri tinde la 1 cînd $k \rightarrow \infty$
- ▶ exponentul $2d - 1$ este în $(-1, 0)$: descreșterea este atît de lentă încît $\sum_k \rho(k) = \infty$

- ▣ **Exponentul Hurst** $H = d + 1/2$


- ▶ $H = 0,5$: fără memorie; $H > 0,5$: persistență; $H < 0,5$: antipersistență
- ▶ Hurst a găsit $H \approx 0,7$ pentru debitul anual al Nilului [Hurst \(1951\)](#)

Noțiuni necesare azi (3/22): cele două descreșteri într-un grafic



- Stînga: ARFIMA(0; 0,3; 0) și un AR(1) cu același $\rho(1) = 0,429$
 - ▶ la lagul 10: $\rho(10) = 0,173$ pentru ARFIMA, dar doar $0,429^{10} = 0,0002$ pentru AR(1)
- Dreapta: aceleași curbe pe axe log-log
 - ▶ $\log \rho(k) \approx \log C + (2d - 1) \log k$: o lege de putere este o dreaptă cu panta $2d - 1 = -0,4$
 - ▶ descreșterea exponențială se curbează în jos și iese din grafic după aproximativ 10 laguri

Noțiuni necesare azi (4/22): traiectorii simulate pentru trei valori ale lui d



- ▣ Aceleași șocuri ε_t (zgomot alb, varianța 1), filtrate cu trei valori ale lui d (modelul este definit în slide-urile următoare)
- ▣ $d = -0,3$ ($H = 0,2$): **antipersistent**
 - ▶ o valoare peste medie tinde să fie urmată de una sub medie: $\rho(1) < 0$, traiectoria este mai „zimțată” decât zgomotul alb
- ▣ $d = 0,4$ ($H = 0,9$): **persistent**
 - ▶ excursii lungi deasupra sau sub medie, care seamănă cu tendințe sau cu schimbări de nivel, deși media este constantă

Noțiuni necesare azi (5/22): operatorul lag și diferențierea fracționară

- ▣ **Operatorul lag** L : $Lx_t = x_{t-1}$, $L^k x_t = x_{t-k}$
 - ▶ prima diferență: $(1 - L)x_t = x_t - x_{t-1}$, cazul $d = 1$
- ▣ **Diferența fracționară** $(1 - L)^d$ pentru d real: seria binomială

$$(1 - L)^d x_t = \sum_{k=0}^{\infty} \pi_k x_{t-k}, \quad \pi_0 = 1, \quad \pi_k = \pi_{k-1} \frac{k-1-d}{k}$$

- ▶ π_k : ponderea valorii x_{t-k} ; $d = 1$ dă $\pi_1 = -1$ și $\pi_k = 0$ pentru $k \geq 2$ (diferența obișnuită)
- ▶ pentru $0 < d < 1$: fiecare $\pi_k < 0$ ($k \geq 1$), iar $|\pi_k|$ descrește lent, ca k^{-1-d} : contează toate valorile trecute
- ▣ Exemplu, $d = 0,4$: $\pi_1 = -0,4$, $\pi_2 = -0,4 \cdot 0,6/2 = -0,12$, $\pi_3 = -0,12 \cdot 1,6/3 = -0,064$


Noțiuni necesare azi (6/22): răspunsul la impuls ψ_k

- ▣ **Filtrul invers:** seria ca sumă a șocurilor trecute (forma $MA(\infty)$)

$$x_t = (1 - L)^{-d} \varepsilon_t = \sum_{k=0}^{\infty} \psi_k \varepsilon_{t-k}, \quad \psi_0 = 1, \quad \psi_k = \psi_{k-1} \frac{k-1+d}{k}$$

- ▶ ψ_k : efectul asupra lui x_t al unui șoc unitar petrecut acum k perioade
- ▣ Exemplu, $d = 0,4$: $\psi_1 = 0,4$, $\psi_2 = 0,4 \cdot 1,4/2 = 0,28$, $\psi_3 = 0,28 \cdot 2,4/3 = 0,224$
 - ▶ pentru $0 < d < 1/2$, ψ_k descrește ca k^{d-1} : lent, dar spre 0, deci seria este staționară
- ▣ Pentru un $AR(1)$, $\psi_k = \phi^k$: efectul unui șoc se stinge exponențial

Noțiuni necesare azi (7/22): ponderile fracționare și răspunsul la impuls într-un grafic



- Stînga: ponderile $-\pi_k$ ale lui $(1 - L)^d$ pe axe log-log sînt aproape drepte: o lege de putere în k
- Dreapta: pentru $d = 0,4$, $\psi_{10} = 0,112$, față de $0,667^{10} = 0,017$ pentru un AR(1) cu același $\rho(1) = 0,667$

Noțiuni necesare azi (8/22): modelul ARFIMA

- **ARFIMA**(p, d, q): un model ARMA pentru seria diferențiată fracționar [Granger și Joyeux \(1980\)](#), [Hosking \(1981\)](#)

$$\phi(L)(1-L)^d(x_t - \mu) = \theta(L)\varepsilon_t$$

- $\phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p$, $\theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q$: polinoamele AR și MA ([Capitolul 2](#))
- μ : media; ε_t : zgomot alb cu varianța σ^2 ; $d = 0$: ARMA; $d = 1$: ARIMA($p, 1, q$)

Intervalul lui d	Proprietăți
$d \leq -1/2$	neinvertibil
$-1/2 < d < 0$	staționar, invertibil, antipersistent
$d = 0$	memorie scurtă (ARMA)
$0 < d < 1/2$	staționar, invertibil, memorie lungă
$1/2 \leq d < 1$	nestaționar, dar cu revenire la medie: un șoc tot se stinge
$d = 1$	rădăcină unitară: un șoc este permanent

- Pentru $1/2 \leq d < 3/2$, diferențiem o dată: $(1-L)x_t$ este ARFIMA cu parametrul de memorie $d - 1$

Noțiuni necesare azi (9/22): ARFIMA(0, d , 0) în cifre

▣ Autocorelațiile, prin recurență

$$\rho(1) = \frac{d}{1-d}, \quad \rho(k) = \rho(k-1) \frac{k-1+d}{k-d}, \quad k \geq 2$$

- ▶ exemplu $d = 0,3$: $\rho(1) = 0,3/0,7 = 0,429$, $\rho(2) = 0,429 \cdot 1,3/1,7 = 0,328$
- ▶ pentru k mare: $\rho(k) \approx \frac{\Gamma(1-d)}{\Gamma(d)} k^{2d-1}$, constanta C din definiția memoriei lungi

▣ Variația

$$\gamma(0) = \sigma^2 \frac{\Gamma(1-2d)}{\Gamma(1-d)^2}$$

- ▶ $\Gamma(z) = \int_0^\infty u^{z-1} e^{-u} du$: funcția gamma; $\Gamma(n) = (n-1)!$ pentru numere întregi $n \geq 1$; $\Gamma(1/2) = \sqrt{\pi}$
- ▶ $d > 0$: $\gamma(0) > \sigma^2$, memoria acumulează șocurile trecute; $\gamma(0) \rightarrow \infty$ când $d \rightarrow 1/2$


Noțiuni necesare azi (10/22): prognoza la un pas

- Din $(1 - L)^d(x_{T+1} - \mu) = \varepsilon_{T+1}$, înlocuim șocul necunoscut ε_{T+1} cu media lui, 0

$$\hat{x}_{T+1} = \mu - \sum_{k \geq 1} \pi_k (x_{T+1-k} - \mu)$$

- ▶ x_T : ultima observație; x_{T+1-k} : valoarea cu $k - 1$ perioade înaintea ei; în practică suma se oprește la $k = T$
- Citirea formulei pentru $0 < d < 1$
 - ▶ ponderile $-\pi_k$ sînt pozitive: fiecare abatere trecută de la μ împinge prognoza în sensul ei
 - ▶ ponderile descresc lent, deci și abaterile vechi contează
- Comparăție: AR(1), $\hat{x}_{T+1} = \mu + \phi(x_T - \mu)$
 - ▶ în prognoză intră doar ultima valoare; ϕ : coeficientul AR(1)

Noțiuni necesare azi (11/22): statistica R/S



- Pentru un bloc $x_1, \dots, x_n$ cu media $\bar{x}$ [Hurst \(1951\)](#):

$$Y_k = \sum_{i=1}^k (x_i - \bar{x}), \quad k = 1, \dots, n$$


- Y_k : abaterea cumulată de la medie; $Y_n = 0$

- **Amplitudinea și abaterea standard**

$$R = \max_k Y_k - \min_k Y_k, \quad S = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

- R/S : amplitudinea abaterilor cumulate, în unități de S ; crește ca n^H

- Graficul: un bloc persistent are serii lungi de același semn
- Y_k se îndepărtează mult de 0, deci R este mare (39, față de 17 pentru zgomotul alb)

Noțiuni necesare azi (12/22): H dintr-o regresie log-log

- Împărțim seria în blocuri de mărime n și facem media R/S pe blocuri: $(R/S)_n$

$$\log_{10}(R/S)_n \approx a + H \log_{10} n$$

- ▶ repetăm pentru mai multe valori n ; $\hat{H}$ = panta OLS a lui $\log_{10}(R/S)_n$ față de $\log_{10} n$; $\hat{d} = \hat{H} - 0,5$
- ▶ a : termenul liber; OLS: metoda celor mai mici pătrate
- Graficul: zgomotul alb dă $\hat{H} = 0,53$, puțin peste 0,5
- ▶ R/S este deplasat în sus în blocuri mici; $d = 0,3$ dă $\hat{H} = 0,79 \approx 0,8$
- DFA (analiza fluctuațiilor fără tendință) Peng et al. (1994)
 - ▶ cumulăm seria, ajustăm o dreaptă în fiecare bloc de mărime n ; $F(n)$: rădăcina mediei pătratelor reziduurilor
 - ▶ $F(n) \propto n^H$: $\hat{H}$ = panta lui $\log F(n)$ față de $\log n$

Noțiuni necesare azi (13/22): periodograma și densitatea spectrală

- ▣ **Frecvențele Fourier** $\lambda_j = 2\pi j/T, j = 1, \dots, \lfloor T/2 \rfloor$
 - ▶ λ_j în radiani pe perioadă; îi corespunde un ciclu de T/j perioade; $\lfloor \cdot \rfloor$: partea întreagă
 - ▶ frecvențele joase (j mic): cicluri lungi; aici se vede memoria lungă
- ▣ **Periodograma**: cât din varianță se află în ciclurile cu frecvența λ_j

$$I(\lambda_j) = \frac{1}{2\pi T} \left| \sum_{t=1}^T (x_t - \bar{x}) e^{-i\lambda_j t} \right|^2$$

- ▶ i : unitatea imaginară; $I(\lambda_j)$ este o estimare zgomotoasă a densității spectrale $f(\lambda_j)$
- ▣ **Memoria lungă** = un pol al densității spectrale la frecvența zero

$$f(\lambda) \sim G \lambda^{-2d} \quad \text{cînd } \lambda \rightarrow 0$$
 - ▶ $G > 0$: o constantă; ARFIMA(0, d , 0): $f(\lambda) = \frac{\sigma^2}{2\pi} (4 \sin^2(\lambda/2))^{-d}$, iar $4 \sin^2(\lambda/2) \approx \lambda^2$ pentru λ mic

Noțiuni necesare azi (14/22): estimatorul GPH

- **GPH Geweke și Porter-Hudak (1983)**: logaritmăm $I(\lambda_j) \approx f(\lambda_j)$ la cele mai joase m frecvențe: o regresie liniară în d

$$\log I(\lambda_j) = c + d X_j + u_j, \quad X_j = -\log(4 \sin^2(\lambda_j/2)), \quad j = 1, \dots, m$$

- ▶ c : termenul liber; u_j : eroarea; m : **lățimea de bandă**, numărul frecvențelor joase folosite

- Estimarea este panta OLS, cu $y_j = \log I(\lambda_j)$


$$\hat{d} = \frac{\sum_{j=1}^m (X_j - \bar{X})(y_j - \bar{y})}{\sum_{j=1}^m (X_j - \bar{X})^2}, \quad \text{SE}(\hat{d}) = \frac{\pi}{\sqrt{24m}}$$

- ▶ $\bar{X}$, $\bar{y}$: mediile pe cele m frecvențe; SE: eroarea standard asimptotică

- **Testul pentru $H_0: d = 0$** (fără memorie lungă)

- ▶ $t = \hat{d}/\text{SE}(\hat{d})$, comparat cu distribuția Normală: respingem la 5% dacă $|t| > 1,96$
- ▶ lățimea de bandă uzuală $m = \lfloor T^{0,65} \rfloor$; un m mic: mai puțină deplasare din dinamica pe termen scurt, dar mai mult zgomot

Noțiuni necesare azi (15/22): periodograma și GPH într-un grafic



- Stînga: periodograma unui ARFIMA(0; 0,3; 0) simulat ($T = 2048$) oscilează în jurul lui $f(\lambda)$, care crește spre $\lambda = 0$
- Dreapta: regresia GPH pe primele $m = \lfloor 2048^{0,65} \rfloor = 142$ frecvențe dă $\hat{d} = 0,30$ (SE = $\pi/\sqrt{24 \cdot 142} = 0,054$)

Noțiuni necesare azi (16/22): Whittle local, ML exactă și criteriile informaționale

- **Whittle local (LW)** [Robinson \(1995\)](#): $\hat{d}$ minimizează, pe aceleași m frecvențe,

$$R(d) = \log \left(\frac{1}{m} \sum_{j=1}^m \lambda_j^{2d} I(\lambda_j) \right) - \frac{2d}{m} \sum_{j=1}^m \log \lambda_j$$

- ▶ o verosimilitate care folosește doar $f(\lambda) \approx G\lambda^{-2d}$ lângă zero; $SE(\hat{d}) = 1/(2\sqrt{m})$, mai mică decât la GPH

- **Verosimilitatea maximă exactă (ML)** [Sowell \(1992\)](#)

- ▶ maximizează verosimilitatea Normală completă L a modelului ARFIMA(p, d, q) în raport cu d, ϕ_i, θ_j și σ^2
- ▶ folosește toate frecvențele: mai precisă dacă modelul este corect, deplasată dacă partea de termen scurt este greșită

- **Criteriile informaționale**: câștigă modelul cu valoarea cea mai mică


$$AIC = -2 \ln L + 2k, \quad BIC = -2 \ln L + k \ln T$$

- ▶ In L : logaritmul verosimilității maximizate; k : numărul parametrilor estimați; BIC penalizează mai mult parametrii în plus

Noțiuni necesare azi (17/22): memoria volatilității și testul permutării


- Randamentele $r_t = 100 \ln(P_t/P_{t-1})$ sînt aproape necorelate, dar mărimea lor $|r_t|$ are memorie lungă [Ding, Granger și Engle \(1993\)](#)
 - ▶ P_t : prețul de închidere din ziua t ; **volatilitatea realizată** lunară $\sqrt{RV_m}$, cu $RV_m = \sum_{t \in m} r_t^2$ (zilele t din luna m); modelăm $\log RV_m$
- **Testul permutării**: permutăm aleator zilele și reestimăm d
 - ▶ permutarea păstrează distribuția valorilor și le distruge ordinea: memoria reală $d \approx 0$ după permutare
- Motivul: memoria lui $|r_t|$ înseamnă că perioadele calme și cele agitate durează (volatility clustering)
 - ▶ privește mărimea mișcărilor, nu semnul lor: direcția rămîne imprevizibilă

Noțiuni necesare azi (18/22): testul permutării într-un grafic



□ Simulare: ACF a lui $|r_t|$ este pozitivă pînă la lagul 200, LW $\hat{d} = 0,28$; după permutare, în bandă, $\hat{d} = -0,04$

Noțiuni necesare azi (19/22): ponderile GARCH și FIGARCH



- GARCH(1,1): $\alpha\beta^{k-1}$, $\alpha = 0.08$, $\beta = 0.9$
- FIGARCH: $\lambda_k = -\pi_k$, $d = 0.4$
- - - $d k^{-1-d}/\Gamma(1-d)$

□ **GARCH(1,1)** (Capitolul 5): $\sigma_t^2 = \omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$

- σ_t^2 : varianța condiționată a zilei t ; ε_t : șocul; $\omega > 0$, $\alpha, \beta \geq 0$: parametrii
- înlocuind repetat $\sigma_{t-1}^2, \sigma_{t-2}^2, \dots$ (forma ARCH(∞)):

$$\sigma_t^2 = \frac{\omega}{1-\beta} + \alpha \sum_{k \geq 1} \beta^{k-1} \varepsilon_{t-k}^2$$

- ponderea lui ε_{t-k}^2 : $\alpha\beta^{k-1}$, exponențială

□ **FIGARCH(0, d, 0)** Baillie, Bollerslev și Mikkelsen (1996):


$$\sigma_t^2 = \omega + [1 - (1-L)^d] \varepsilon_t^2$$

- ponderile $\lambda_k = -\pi_k \approx d k^{-1-d}/\Gamma(1-d)$: hiperbolice
- graficul, $k = 100$: $2,4 \cdot 10^{-6}$ (GARCH), față de $4,3 \cdot 10^{-4}$ (FIGARCH)

Noțiuni necesare azi (20/22): memoria lungă aparentă

- O serie cu memorie scurtă și o schimbare de nivel: $x_t = \mu_t + \varepsilon_t$, unde media μ_t se schimbă o singură dată (o **ruptură**)
 - ▶ ACF rămîne pozitivă la laguri mari și $\hat{d} > 0$, deși nu există memorie [Diebold și Inoue \(2001\)](#)
 - ▶ remediul: estimăm media fiecărui regim, o scădem și reestimăm d
- **Banda Monte Carlo**: simulăm multe serii i.i.d. de aceeași lungime și estimăm d pe fiecare
 - ▶ cuantilele de 2,5% și 97,5% ale acestor $\hat{d}$: banda de 95% a lui $\hat{d}$ cînd nu există memorie; i.i.d.: independente și identic distribuite
- O estimare $\hat{d}$ în afara benzii: dovadă de memorie sau de ruptură; în interior: compatibilă cu lipsa memoriei

Noțiuni necesare azi (21/22): o ruptură care seamănă cu memoria lungă



- Stînga: zgomot alb a cărui medie scade cu 1 după prima treime a eșantionului ($T = 400$)
- Dreapta: ACF rămîne deasupra benzii 40 de laguri, iar LW dă $\hat{d} = 0,32$; după eliminarea celor două medii, $\hat{d} = 0,07$

Noțiuni necesare azi (22/22): rata lunară și rata anuală a inflației

- ▣ P_t : indicele prețurilor din luna t ; **rata lunară** $\pi_t^m = 100 \Delta \ln P_t = 100(\ln P_t - \ln P_{t-1})$
 - ▶ ajustarea sezonieră prin mediile lunare: din fiecare lună (ianuarie, februarie, ...) se scade media ei pe toți anii
- ▣ **Rata anuală** este suma ultimelor 12 rate lunare

$$100(\ln P_t - \ln P_{t-12}) = \sum_{j=0}^{11} \pi_{t-j}^m$$

- ▶ două rate anuale consecutive au 11 rate lunare comune (sume suprapuse)
- ▶ chiar pentru rate lunare i.i.d., rata anuală are $\rho(k) = (12 - k)/12$ pentru $k < 12$: o autocorelație puternică produsă de definiție

A1: ponderi fracționare și ACF [Rezolvat]

Cerință

- O serie este ARFIMA(0; 0,25; 0), cu $\sigma^2 = 1$.
- 1. Calculați $\pi_1, \dots, \pi_4$ pentru $(1 - L)^{0,25}$.
- 2. Calculați $\rho(1)$ și $\rho(2)$ și precizați H și clasa procesului.
- 3. Comparați $\rho(5)$ cu valoarea unui AR(1) cu același $\rho(1)$.
- Raportați: patru ponderi, două autocorelații, H , două valori ale lui $\rho(5)$.

Rezolvare

- 1. $\pi_1 = -0,25$; $\pi_2 = -0,25 \cdot 0,75/2 = -0,0938$;
 $\pi_3 = -0,0938 \cdot 1,75/3 = -0,0547$;
 $\pi_4 = -0,0547 \cdot 2,75/4 = -0,0376$
- 2. $\rho(1) = 0,25/0,75 = 0,333$;
 $\rho(2) = 0,333 \cdot 1,25/1,75 = 0,238$; $H = 0,75$: staționar, memorie lungă
- 3. ARFIMA: $\rho(5) = 0,151$; AR(1): $0,333^5 = 0,0041$, de aproximativ 37 de ori mai mic

A2: intervalul în care se află d [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Două serii: (a) ARFIMA(0; 0,6; 0); (b) ARFIMA(0; -0,3; 0). Model: [A1](#).
- ▣ 1. Calculați π_1 și π_2 ale lui $(1 - L)^d$ pentru fiecare.
- ▣ 2. Precizați dacă fiecare serie este staționară, inversabilă și cu revenire la medie.
- ▣ 3. Pentru (b) calculați $\rho(1)$ și $\rho(2)$; pentru (a) calculați $\rho(1)$ al primei diferențe.
- ▣ Raportați: patru ponderi, două clasificări, trei autocorelații.



A3: R/S de mînă și H din trei puncte [Rezolvat]

Cerință

- Blocul:
 $x = (0,6; 0,4; 0,5; 0,3; -0,4; -0,6; -0,2; -0,5)$. Un grafic R/S dă $(R/S)_n = 4,1; 9,6; 22,4$ pentru $n = 16; 64; 256$.
- 1. Calculați $\bar{x}$, abaterile cumulate Y_k , R , S și R/S .
- 2. Calculați H ca pantă a lui $\log_{10}(R/S)_n$ față de $\log_{10} n$ și $d = H - 0,5$.
- Raportați: R/S , H , d și o frază.

Rezolvare

- 1. $\bar{x} = 0,0125$; Y_k : 0,5875; 0,9750; 1,4625; 1,7500; 1,3375; 0,7250; 0,5125; 0; $R = 1,750$, $S = 0,457$, $R/S = 3,83$
- semnele sînt grupate (patru pozitive, apoi patru negative): amplitudinea este mare, ca pentru o serie persistentă
- 2. $\log_{10} n$: 1,204; 1,806; 2,408; $\log_{10}(R/S)$: 0,613; 0,982; 1,350; panta $H = 0,61$, $d = 0,11$: persistență moderată

A4: o pantă GPH de mînă [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Pentru $m = 4$ frecvențe: $X_j = 0,5; 1,6; 2,3; 3,0$ și $\log l(\lambda_j) = 1,2; 1,8; 2,0; 2,5$. Model: A3.
- ▣ 1. Calculați $\bar{X}$, $\bar{y}$, $\sum(X_j - \bar{X})(y_j - \bar{y})$ și $\sum(X_j - \bar{X})^2$.
- ▣ 2. Calculați $\hat{d}$ și eroarea standard $\pi/\sqrt{24m}$.
- ▣ 3. Testați $H_0: d = 0$ la 5% și comentați mărimea lui m .
- ▣ Raportați: patru sume, $\hat{d}$, SE, o decizie și o frază.



A5: o prognoză ARFIMA la un pas [Rezolvat]

Cerință

- ▣ ARFIMA(0; 0,4; 0), cu $\mu = 2$; ultimele patru valori: $x_T = 3,0$, $x_{T-1} = 2,5$, $x_{T-2} = 2,8$, $x_{T-3} = 1,5$.
- ▣ 1. Scrieți primele patru ponderi $-\pi_k$ ale lui $(1 - L)^{0,4}$.
- ▣ 2. Calculați $\hat{x}_{T+1}$ folosind aceste patru laguri.
- ▣ 3. Comparați cu un AR(1) cu același $\rho(1)$.
- ▣ Raportați: patru ponderi, două prognoze și o frază.

Rezolvare

- ▣ 1. $-\pi_k$: 0,4; 0,12; 0,064; 0,0416
- ▣ 2. $\hat{x}_{T+1} =$
 $2 + 0,4(1,0) + 0,12(0,5) + 0,064(0,8) + 0,0416(-0,5) =$
 $2 + 0,4000 + 0,0600 + 0,0512 - 0,0208 = 2,490$
- ▣ 3. AR(1): $\phi = \rho(1) = 0,4/0,6 = 0,667$,
 $\hat{x}_{T+1} = 2 + 0,667 \cdot 1,0 = 2,667$; AR(1) se uită doar la x_T ,
ARFIMA distribuie ponderea pe trecut (în practică, pe toate cele T valori)

A6: durata efectului unui șoc al volatilității [Propus]

Rezolvarea se discută la seminar


Cerință

- ▣ GARCH(1,1) cu $\alpha = 0,10$, $\beta = 0,88$; FIGARCH(0, d , 0) cu $d = 0,4$ (ponderile $\lambda_k = -\pi_k$). Model: A5.
- ▣ 1. Calculați ponderea lui ε_{t-k}^2 în σ_t^2 pentru $k = 1, 2, 3$ în ambele modele.
- ▣ 2. Calculați ambele ponderi la $k = 20$ și $k = 100$; pentru FIGARCH folosiți $\lambda_k \approx d k^{-1-d} / \Gamma(1 - d)$, $\Gamma(0,6) = 1,489$.
- ▣ 3. Explicați ce model păstrează mai mult timp o criză în volatilitatea de azi.
- ▣ Raportați: zece ponderi și o frază.


B1: are Nilul memorie lungă? [Rezolvat]

- ▣ **Întrebarea:** este persistența debitului Nilului memorie lungă sau efectul schimbării din 1898?
- ▣ **Date:** debitul anual la Aswan, 1871–1970 ($T = 100$)
- ▣ **Cerințe**
 1. Reprezentați grafic seria și ACF pînă la lagul 20.
 2. Estimați H prin R/S, d prin GPH și Whittle local ($m = \lfloor T^{0.65} \rfloor$) și prin ML exactă pentru ARFIMA(0, d , 0).
 3. Scădeți media din 1871–1898 și media din 1899–1970 și repetați pasul 2.
 4. Interpretare: are Nilul memorie lungă?
- ▣ **Raportați:** două valori ale ACF, patru estimări înainte și după, o frază
- ▣ Notebook: secțiunea [B1](#)

B1: rezolvare [Rezolvat]



— Nile flow at Aswan (10^8 m^3)
— regime means, break after 1898
—•— ACF, raw series



—•— ACF, regime means removed
 95% band for white noise

- Seria brută: $\hat{\rho}(1) = 0,50$, $\hat{\rho}(10) = 0,09$; $H_{R/S} = 0,78$; GPH 0,44 (SE 0,15), LW 0,40 (SE 0,11), ML 0,36 (SE 0,07); $m = 19$
- Mediile 1098 și 850; după eliminarea lor: $\hat{\rho}(1) = 0,16$; $H_{R/S} = 0,63$; GPH $-0,07$, LW $-0,17$, ML 0,05 (SE 0,10)
- Interpretare: pentru 1871–1970 dovada de memorie lungă provine dintr-o singură ruptură; R/S rămâne peste 0,5 deoarece este deplasat în sus în eșantioane scurte


B2: memoria lungă a inflației din România [Propus]

- **Întrebarea:** cât de persistentă este inflația din România și schimbă modul de măsurare a inflației răspunsul?
- **Date:** IAPC lunar, 2005–2026: rata lunară ajustată sezonier cu mediile lunare și rata anuală; model: [B1](#)
- **Cerințe**
 1. Estimați d al ratei lunare prin GPH și Whittle local, cu $m = \lfloor T^a \rfloor$, $a = 0,5; 0,65; 0,8$.
 2. Estimați ARFIMA(0, d , 0) și ARMA(1,1) prin ML exactă și comparați BIC.
 3. Estimați d al ratei anuale prin Whittle local și comparați cele două ACF.
 4. Interpretare: de ce dă rata anuală un d apropiat de 1?
- **Raportați:** șase estimări, două valori BIC, un d , două fraze
- Notebook: secțiunea [B2](#)

B3: memoria volatilității S&P 500 [Rezolvat]

- ▣ **Întrebarea:** unde se află memoria randamentelor bursiere: în randamente sau în mărimea lor?
- ▣ **Date:** randamentele logaritmice zilnice S&P 500 din 2000 și volatilitatea lor realizată lunară
- ▣ **Cerințe**
 1. Estimați d pentru r_t și pentru $|r_t|$ prin Whittle local și GPH.
 2. Permutați aleator zilele și reestimați d pentru $|r_t|$; reprezentați grafic ambele ACF ale lui $|r_t|$.
 3. Estimați d pentru logaritmul volatilității realizate lunare.
 4. Interpretare: ce arată testul permutării?
- ▣ **Raportați:** opt estimări, graficul și o frază
- ▣ Notebook: secțiunea [B3](#)

B3: rezolvare [Rezolvat]



- $T = 6\,714$ de zile; r_t : LW $-0,01$, GPH $0,02$ (SE $0,03$; $0,04$); $|r_t|$: LW $0,53$, GPH $0,56$
- $|r_t|$ permutat: LW $-0,03$, GPH $-0,03$; ACF a lui $|r_t|$: $0,289$ (lagul 1), $0,127$ (lagul 50), $0,009$ (lagul 200); log RV (321 de luni): LW $0,41$, GPH $0,37$
- Interpretare: permutarea păstrează fiecare valoare zilnică și le distruge ordinea; memoria dispare, deci ea se află în succesiunea perioadelor calme și agitate (volatility clustering), nu în distribuția randamentelor

B4: BET și EUR/RON [Propus]

- **Întrebarea:** au BET și cursul EUR/RON aceeași memorie și este ea stabilă înainte și după criza din 2008?
- **Date:** randamentele logaritmice zilnice ale BET (din 2000) și ale cursului de referință EUR/RON (din iulie 2005); model: [B3](#)
- **Cerințe**
 1. Estimați d pentru r_t și $|r_t|$ prin Whittle local pe tot eșantionul.
 2. Repetați pe subeșantioanele pînă în 2007 și 2010–2026.
 3. Comparați estimările pentru r_t cu banda Monte Carlo de 95% a seriilor i.i.d. de 1900 de zile.
 4. Interpretare: este reală memoria randamentelor BET pe tot eșantionul?
- **Raportați:** douăsprezece estimări, o bandă și două fraze
- Notebook: secțiunea [B4](#)

C1: inflația din SUA și regimurile monetare [Propus]

- **Întrebarea:** este memoria lungă a inflației din SUA o proprietate a inflației sau a schimbărilor de politică monetară?
- **Date:** inflația lunară IPC din SUA, anualizată, 1947–2026; regimurile 1947–1984, 1985–2019, 2020–2026; modele: [B1](#), [B2](#)
- **Cerințe**
 1. Estimați d prin Whittle local pe tot eșantionul și în fiecare regim.
 2. Eliminați cele trei medii de regim și reestimați d .
 3. Propuneți încă o verificare (un test de ruptură, un model Markov switching, o comparație de prognoze).
 4. Interpretare: poate un d constant să descrie 80 de ani de inflație?
- **Raportați:** cinci estimări, o verificare și un plan de proiect
- Notebook: secțiunea [C1](#)

C2: verificați un răspuns AI [Propus]

- Un student a întrebat un asistent AI despre memoria lungă a inflației din România și a S&P 500. Răspunsul:
- (a) Inflația lunară are $d = 0,31$, deci exponentul Hurst este $H = d - 0,5 < 0$: este antipersistentă.
- (b) Rata anuală dă $d = 1,00$, deci inflația din România are rădăcină unitară.
- (c) Cu $d = 0,31$ seria este staționară, iar șocurile ei se sting.
- (d) Folosiți `statsmodels.tsa.arima.model.ARIMA(x, order=(0, 0.31, 0))` pentru a estima modelul ARFIMA.
- (e) Randamentele S&P 500 au $d = -0,01$, iar $|r|$ are $d = 0,53$, deci randamentele sînt previzibile.
- (f) O estimare GPH semnificativă demonstrează memoria lungă.
- **Cerințe**
 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă din notebook (secțiunea C2).
- **Raportați:** o listă de șase verdicte, fiecare cu un rînd de justificare

Idei de reținut

- ▣ $(1 - L)^d$: ponderile prin recurența $\pi_k = \pi_{k-1}(k - 1 - d)/k$; ARFIMA(0, d , 0): $\rho(1) = d/(1 - d)$
- ▣ $H = d + 1/2$; R/S și GPH sînt pante ale unor regresii log-log
- ▣ Inflația lunară din România: $d \approx 0,3$; S&P 500: memorie în $|r_t|$, nu în r_t
- ▣ Rupturile pot crea memorie lungă: Nilul, randamentele BET, inflația din SUA
- ▣ Un răspuns AI este o ciornă: verificați relația dintre H și d , biblioteca și transformarea datelor

După seminar

- Cursul 8 dezvoltă fiecare temă de azi
 - ▶ descreșterea hiperbolică, diferențierea fracționară, ARFIMA, estimatorii, prognoza, volatilitatea, memoria aparentă
- Încercați cerințele [Propus] în notebook
- C1 poate deveni un proiect de echipă: memoria inflației și regimurile monetare din România
- Lectură: Baillie (1996); Graves et al. (2017); Ding, Granger și Engle (1993)
- **Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar**

Bibliografie (1/2)

- ▣ Baillie, R. T. (1996). Long memory processes and fractional integration in econometrics. *Journal of Econometrics*, 73(1), 5–59. doi:10.1016/0304-4076(95)01732-1
- ▣ Baillie, R. T., Bollerslev, T., & Mikkelsen, H. O. (1996). Fractionally integrated generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 74(1), 3–30. doi:10.1016/S0304-4076(95)01749-6
- ▣ Diebold, F. X., & Inoue, A. (2001). Long memory and regime switching. *Journal of Econometrics*, 105(1), 131–159. doi:10.1016/S0304-4076(01)00073-2
- ▣ Ding, Z., Granger, C. W. J., & Engle, R. F. (1993). A long memory property of stock market returns and a new model. *Journal of Empirical Finance*, 1(1), 83–106. doi:10.1016/0927-5398(93)90006-D
- ▣ Geweke, J., & Porter-Hudak, S. (1983). The estimation and application of long memory time series models. *Journal of Time Series Analysis*, 4(4), 221–238. doi:10.1111/j.1467-9892.1983.tb00371.x
- ▣ Granger, C. W. J., & Joyeux, R. (1980). An introduction to long-memory time series models and fractional differencing. *Journal of Time Series Analysis*, 1(1), 15–29. doi:10.1111/j.1467-9892.1980.tb00297.x

Bibliografie (2/2)

- ▣ Graves, T., Gramacy, R., Watkins, N., & Franzke, C. (2017). A brief history of long memory: Hurst, Mandelbrot and the road to ARFIMA, 1951–1980. *Entropy*, 19(9), 437. doi:10.3390/e19090437
- ▣ Hosking, J. R. M. (1981). Fractional differencing. *Biometrika*, 68(1), 165–176. doi:10.1093/biomet/68.1.165
- ▣ Hurst, H. E. (1951). Long-term storage capacity of reservoirs. *Transactions of the American Society of Civil Engineers*, 116(1), 770–799. doi:10.1061/TACEAT.0006518
- ▣ Peng, C.-K., Buldyrev, S. V., Havlin, S., Simons, M., Stanley, H. E., & Goldberger, A. L. (1994). Mosaic organization of DNA nucleotides. *Physical Review E*, 49(2), 1685–1689. doi:10.1103/PhysRevE.49.1685
- ▣ Robinson, P. M. (1995). Gaussian semiparametric estimation of long range dependence. *The Annals of Statistics*, 23(5), 1630–1661. doi:10.1214/aos/11176324317
- ▣ Sowell, F. (1992). Maximum likelihood estimation of stationary univariate fractionally integrated time series models. *Journal of Econometrics*, 53(1–3), 165–188. doi:10.1016/0304-4076(92)90084-5