



Serii de timp

Seminarul 9: Învățare automată pentru serii de timp



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- **AI:** Artificial Intelligence (inteligență artificială)
- **AR:** AutoRegressive (model) — model autoregresiv
- **ARIMA:** AutoRegressive Integrated Moving Average (model) — model autoregresiv integrat cu medie mobilă
- **AUC:** Area Under the (ROC) Curve (aria de sub curba ROC)
- **BET:** Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- **DHR:** Dynamic Harmonic Regression (regresie armonică dinamică)
- **DM:** Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- **ENTSO-E:** European Network of Transmission System Operators for Electricity (rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică)
- **EODHD:** EOD Historical Data (market-data provider) — furnizor de date de piață
- **GB:** Gradient Boosting (ensemble of regression trees) — gradient boosting (ansamblu de arbori de regresie)
- **HLN:** Harvey–Leybourne–Newbold (small-sample correction of the DM test) — corecția Harvey–Leybourne–Newbold a testului DM pentru eșantioane mici

Acronime folosite în acest material (2/2)

- ▣ **IAPC**: Indicele armonizat al prețurilor de consum
- ▣ **LSTM**: Long Short-Term Memory (network) — rețea cu memorie pe termen lung și scurt
- ▣ **MAE**: Mean Absolute Error (eroarea absolută medie)
- ▣ **MASE**: Mean Absolute Scaled Error (eroarea absolută medie scalată)
- ▣ **MIMO**: Multiple-Input Multiple-Output (forecasting strategy) — strategia cu mai multe ieșiri: un model dă toate orizonturile deodată
- ▣ **ML**: Machine Learning (învățare automată)
- ▣ **OLS**: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **RF**: Random Forest (pădure aleatoare)
- ▣ **RMSE**: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ **RW**: Random Walk (forecast) — prognoza de tip mers aleator
- ▣ **SSE**: Sum of Squared Errors (suma pătratelor erorilor)
- ▣ **UE**: Uniunea Europeană

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum transformăm o serie de timp într-o problemă de învățare automată și cum știm dacă rezultatul depășește o metodă simplă de referință?
 - ▶ seminarul are loc **înaintea** Cursului 9: secțiunea „Noțiuni necesare azi” dă toate definițiile folosite în cerințe
- ▣ Traseul
 - ▶ Partea A: un tabel de laguri și prognoze pe mai mulți pași; leakage-ul; o împărțire a unui arbore; ridge și lasso într-o dimensiune; un interval conformal; MASE și o statistică Diebold–Mariano
 - ▶ Partea B: gradient boosting pentru consumul de energie electrică al României; strategiile recursivă și directă și valoarea sărbătorilor; inflația din România cu trei luni înainte; semnul randamentelor BET
 - ▶ Partea C: o idee de proiect și un răspuns AI de verificat
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); fiecare cerință indică secțiunea din notebook

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	un tabel de laguri, prognoze recursive și directe; leakage-ul într-o medie mobilă	Rezolvat, Propus	A1
A3, A4	o împărțire a unui arbore de regresie; ridge și lasso într-o dimensiune	Rezolvat, Propus	A3
A5, A6	un interval conformal și funcția pinball; MASE și o statistică DM	Rezolvat, Propus	A5
B1, B2	consumul de energie: boosting față de metoda naivă sezonieră; recursiv, direct, sărbători	Rezolvat, Propus	B1
B3, B4	inflația din România; semnul randamentelor BET	Rezolvat, Propus	B3
C1, C2	un model global ca proiect; erorile dintr-un răspuns AI	Propus	B1, B3

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model

Datele folosite

Seria	Sursa	Frecvența	Perioada
Consumul de energie electrică, România	ENTSO-E	orar, mediat pe zi (GW)	2022–2026
IAPC, 27 de țări UE	Eurostat (prc_hicp_minr)	lunar, 2015 = 100	2005–2026
BET	EODHD	zilnic, închidere	2000–2026

- ENTSO-E: rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică; același fișier de consum ca în [Capitolul 4](#)
- În notebook: `direct_frame`, `forecast_direct`, `forecast_recursive`, `dm_raw`, `inflation_forecasts`, `sign_frame`; modele scikit-learn cu semănțe fixe; nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/5): de la o serie la un tabel

- ▣ **Învățarea supervizată:** învățăm $\hat{f}$ din perechi (variabile explicative $\mathbf{x}_i$, ținta y_i) astfel încât $\hat{f}(\mathbf{x})$ să fie aproape de y pe date **noi**
 - ▶ pentru o serie: la originea t , variabilele = lagurile $y_t, y_{t-1}, \dots$, medii mobile ale valorilor trecute, calendarul zilei-țintă; ținta y_{t+h} , h : orizontul
- ▣ **Strategii pe mai mulți pași**
 - ▶ recursivă: un model pentru $h = 1$, aplicat din nou cu propriile prognoze ca intrări
 - ▶ directă: câte un model pentru fiecare orizont h , antrenat pe ținta y_{t+h}
 - ▶ MIMO (multiple-input multiple-output): un model cu H ieșiri, H : orizontul maxim
- ▣ O serie de lungime n cu p laguri dă $n - p - h + 1$ rînduri complete pentru orizontul h

Noțiuni necesare azi (2/5): validare și leakage

- Validarea **walk-forward**: antrenăm pe datele de pînă la origine, prognozăm blocul următor, mutăm originea; erorile se combină pe toate originile
 - ▶ niciodată K -fold aleator pentru modele de prognoză cu ținte suprapuse sau cu variabile exogene
- **Leakage-ul** (scurgerea de informație): informație indisponibilă la origine intră în variabile sau în antrenare
 - ▶ o medie mobilă care conține y_{t+1} ; scalare estimată pe tot eșantionul; ținte suprapuse fără spațiu (gap); vremea efectivă în locul celei prognozate
 - ▶ variabilele de calendar (ziua săptămînii, sărbătorile) se cunosc dinainte: nu există leakage
- Metode de referință ([Capitolul 0](#)): naivă $\hat{y}_{T+h} = y_T$, naivă sezonieră $\hat{y}_{T+h} = y_{T+h-m}$
 - ▶ T : originea prognozei (ultima observație); m : perioada sezonieră ($m = 7$ pentru date zilnice: aceeași zi a săptămînii trecute)

Noțiuni necesare azi (3/5): ridge și lasso

- ▣ Cele mai mici pătrate penalizate: ajustare plus o penalizare care contractă coeficienții β_j spre 0
 - ▶ **ridge**: $\min \sum_t (y_t - \mathbf{x}_t' \beta)^2 + \lambda \sum_j \beta_j^2$; **lasso**: penalizarea $\lambda \sum_j |\beta_j|$ (unii $\hat{\beta}_j = 0$)
 - ▶ $\mathbf{x}_t$: variabilele rîndului t ; $\lambda \geq 0$: intensitatea penalizării ($\lambda = 0$: OLS)
- ▣ O variabilă standardizată (media 0, abaterea standard 1): formule explicite
 - ▶ $S_{xy} = \sum x_t y_t$, $S_{xx} = \sum x_t^2$; OLS S_{xy}/S_{xx} ; ridge $S_{xy}/(S_{xx} + \lambda)$
 - ▶ lasso $\text{sign}(S_{xy}) \max(|S_{xy}| - \lambda/2, 0)/S_{xx}$: exact 0 cînd $\lambda/2 \geq |S_{xy}|$ (prag moale, soft thresholding)

Noțiuni necesare azi (4/5): arbori și ansambluri

- ▣ **Arborele de regresie:** împărțirea „ $x \leq c$ ”; fiecare parte prognozează media țintelor ei
 - ▶ c : pragul; cel mai bun c minimizează SSE totală (suma pătratelor erorilor față de cele două medii)
 - ▶ candidații: mijloacele dintre valorile consecutive ordonate ale lui x ; un arbore nu poate prognoza în afara intervalului țintelor de antrenare
- ▣ **Random forest:** media multor arbori adânci pe eșantioane bootstrap
 - ▶ **gradient boosting** (GB): arbori mici adăugați unul câte unul pe reziduuri, fiecare înmulțit cu o rată de învățare $\nu \in (0, 1]$
 - ▶ scikit-learn: `HistGradientBoostingRegressor`; aceeași familie ca `LightGBM` și `XGBoost`

Noțiuni necesare azi (5/5): evaluare și intervale

- **MASE** = MAE / (MAE în eșantion a metodei naive sezoniere); MAE: eroarea absolută medie; sub 1: mai bună decât cea metodă de referință
 - ▶ **Diebold–Mariano** (Capitolul 4): $d_t = L(e_{1t}) - L(e_{2t})$, $DM = \bar{d} / \sqrt{\hat{s}^2/n}$; $|DM|$ peste valoarea critică: acuratețe diferită
 - ▶ e_{1t} , e_{2t} : erorile celor două modele; L : funcția de pierdere (absolută sau pătratică); $\bar{d}$, $\hat{s}^2$: media și varianța lui d_t ; n : numărul de origini
- **Funcția pinball** pentru o prognoză cuantică q de nivel τ : $\tau(y - q)$ dacă $y \geq q$, altfel $(1 - \tau)(q - y)$
 - ▶ intervalul **conformal prin împărțire**: $\hat{y} \pm \hat{q}$, $\hat{q} = a \lceil (n + 1)(1 - \alpha) \rceil$ -a cea mai mică dintre n erori absolute de calibrare; α : proporția admisă în afara intervalului; $\lceil \cdot \rceil$: rotunjirea în sus
- **Clasificarea semnelor**: reperul este clasa majoritară din datele de antrenare, nu 50%
 - ▶ $z = (\text{acc} - \text{acc}_0) / \sqrt{\text{acc}_0(1 - \text{acc}_0)/n}$ compară acuratețea acc cu acuratețea reperului, acc_0 , pe n zile de test

A1: un tabel de laguri și două strategii [Rezolvat]

Cerință

- ▣ Seria $y_1, \dots, y_8$: 10, 12, 11, 13, 14, 13, 15, 16.
- ▣ 1. Construiți tabelul cu variabilele y_{t-1} , y_{t-2} și ținta y_t ; câte rînduri are?
- ▣ 2. Cu modelul estimat $\hat{y}_t = 2 + 0,6 y_{t-1} + 0,3 y_{t-2}$, calculați prognozele recursive $\hat{y}_9$, $\hat{y}_{10}$, $\hat{y}_{11}$.
- ▣ 3. Un model direct pe doi pași este $\hat{y}_{t+2} = 3 + 0,5 y_t + 0,3 y_{t-1}$: calculați $\hat{y}_{10}$ și numărul de rînduri al tabelului lui.
- ▣ Raportați: tabelul, trei prognoze recursive, o prognoză directă, două numere de rînduri.

Rezolvare

t	y_{t-1}	y_{t-2}	y_t
3	12	10	11
4	11	12	13
5	13	11	14
6	14	13	13
7	13	14	15
8	15	13	16

- ▣ 1. 6 rînduri ($t = 3, \dots, 8$)
- ▣ 2. $\hat{y}_9 = 2 + 0,6 \cdot 16 + 0,3 \cdot 15 = 16,10$;
 $\hat{y}_{10} = 2 + 0,6 \cdot 16,10 + 0,3 \cdot 16 = 16,46$; $\hat{y}_{11} = 16,71$
- ▣ 3. $\hat{y}_{10} = 3 + 0,5 \cdot 16 + 0,3 \cdot 15 = 15,50$; 5 rînduri (originile $t = 2, \dots, 6$)

A2: găsiți leakage-ul [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Seria zilnică 10, 12, 11, 13, 14; ținta este ultima valoare, 14. Model: A1.
- ▣ 1. Calculați media corectă pe 3 zile pentru această țintă și media pe care ar da-o un `rolling(3).mean()` scris neglijent, fără `shift(1)`.
- ▣ 2. Pentru fiecare alegere, precizați dacă produce leakage: (a) o scalare estimată pe 2022–2026 înainte de împărțire; (b) indicatorii de sărbătoare ai zilei-țintă; (c) temperatura măsurată în ziua-țintă; (d) validare cu 5 grupuri amestecate pentru o țintă pe 21 de zile.
- ▣ Raportați: două medii și patru verdicte, fiecare cu un motiv.

A3: o împărțire a unui arbore de regresie [Rezolvat]

Cerință

- ▣ Șase zile: x = consumul din aceeași zi a săptămînii trecute, y = consumul de azi (GW): (4,8; 5,0), (5,0; 5,2), (5,6; 5,9), (6,0; 6,0), (6,4; 6,6), (6,9; 7,0).
- ▣ 1. Enumerați cele cinci praguri candidate.
- ▣ 2. Pentru fiecare, calculați cele două medii ale frunzelor și SSE totală.
- ▣ 3. Alegeți împărțirea și dați prognoza pentru $x = 6,2$.
- ▣ Raportați: un tabel cu cinci rînduri, pragul ales, o prognoză.

Rezolvare

prag	media stînga	media dreapta	SSE
4,9	5,00	6,14	1,912
5,3	5,10	6,38	0,827
5,8	5,37	6,53	0,953
6,2	5,53	6,80	0,828
6,7	5,74	7,00	1,672

- ▣ Fără împărțire: media 5,95, SSE 2,995
- ▣ Cea mai bună: $x \leq 5,3$, SSE 0,827; frunzele 5,10 și 6,38 GW
- ▣ $x = 6,2 > 5,3$: prognoza 6,38 GW

A4: ridge și lasso într-o dimensiune [Propus]

Rezolvarea se discută la seminar

Cerință

- O variabilă standardizată cu $S_{xy} = 40$ și $S_{xx} = 50$. Model: A3 și formulele din „Noțiuni necesare azi (3/5)”.
- 1. Calculați coeficientul OLS.
- 2. Calculați coeficientul ridge pentru $\lambda = 10$ și $\lambda = 50$.
- 3. Calculați coeficientul lasso pentru $\lambda = 20$ și $\lambda = 100$.
- 4. Explicați într-o frază ce metodă poate elimina un lag din model.
- Raportați: cinci coeficienți și o frază.

A5: un interval conformal și funcția pinball [Rezolvat]

Cerință

- Un model prognozează consumul de mîine, $\hat{y} = 6,10$ GW. În 9 zile de calibrare, erorile lui absolute au fost 0,12; 0,30; 0,05; 0,22; 0,41; 0,18; 0,09; 0,27; 0,35 GW.
- 1. Construiți intervalul conformal de 80%.
- 2. O prognoză cuantică de 90% este $q = 6,4$ GW: calculați funcția pinball dacă $y = 6,0$ și dacă $y = 6,6$.
- Raportați: k , $\hat{q}$, intervalul, două valori ale pierderii.

Rezolvare

- 1. Ordonate: 0,05; 0,09; 0,12; 0,18; 0,22; 0,27; 0,30; 0,35; 0,41; $k = \lceil 10 \cdot 0,8 \rceil = 8$; $\hat{q} = 0,35$
- intervalul $6,10 \pm 0,35 = [5,75; 6,45]$ GW
- 2. $y = 6,0 < q$: $(1 - 0,9)(6,4 - 6,0) = 0,04$; $y = 6,6 > q$: $0,9 \cdot 0,2 = 0,18$
- o valoare peste o cuantilă mare costă de nouă ori mai mult pe GW: pierderea împinge q în sus pînă cînd doar 10% dintre valori o depășesc

A6: MASE și o statistică Diebold–Mariano [Propus]

Rezolvarea se discută la seminar


Cerință

- ▣ Erorile absolute medii (GW) a două modele la 6 origini: $A = 0,30; 0,25; 0,40; 0,28; 0,35; 0,22$; $B = 0,32; 0,30; 0,38; 0,35; 0,41; 0,30$; scala MASE 0,31 GW. Model: A5 și „Noțiuni necesare azi (5/5)”.
- ▣ 1. Calculați MAE și MASE pentru fiecare model.
- ▣ 2. Calculați $d_t = A_t - B_t$, media $\bar{d}$ și abaterea standard s ale lui d_t , apoi $DM = \bar{d}/(s/\sqrt{6})$.
- ▣ 3. Comparați $|DM|$ cu valoarea critică de 5% a distribuției $t(5)$ și formulați concluzia.
- ▣ Raportați: patru valori de acuratețe, $\bar{d}$, DM și o decizie.

B1: gradient boosting pentru consumul de energie electrică [Rezolvat]

- **Întrebarea:** prognozează un model gradient boosting consumul zilnic din săptămîna următoare mai bine decît „aceeași zi a săptămîinii trecute”?
- **Date:** consumul mediu zilnic al României (GW), 2022–2026; origini săptămînale de la 5 ianuarie la 22 iunie 2026; orizonturile 1–7 zile
- **Cerințe**
 1. Construiți tabelele directe (14 laguri, medii pe 7 și 28 de zile, aceeași zi a săptămîinii, calendarul zilei-țintă) cu `direct_frame`.
 2. La fiecare origine, antrenați cîte un `HistGradientBoostingRegressor` pentru fiecare orizont pe datele de dinaintea originii și prognozați următoarele 7 zile.
 3. Calculați MAE, RMSE și MASE pentru GB și pentru prognoza naivă sezonieră.
 4. Aplicați testul Diebold–Mariano pe erorile absolute medii pe origine.
 5. Interpretare: la ce orizonturi este cîștigul GB cel mai mare și de ce?
- **Raportați:** șase valori de acuratețe, o statistică DM cu p-value-ul ei, o frază
- Notebook: secțiunea B1

B1: rezolvare [Rezolvat]



- 25 de origini, 7 orizonturi; MAE: GB 320 MW, naivă sezonieră 391 MW; RMSE 409 și 521 MW; MASE 1,04 și 1,27 (scala 308 MW)
- DM (cu corecția Harvey–Leybourne–Newbold pentru eșantioane mici, HLN) = $-2,63$, $p = 0,015$; originea cu cea mai mare eroare pentru GB: 5 ianuarie 2026 (MAE 576 MW)
- Interpretare: cu o zi înainte, GB are 252 MW față de 411 MW: folosește nivelul de ieri, pe care metoda naivă sezonieră îl ignoră; la 7 zile (371 și 429 MW) ambele se bazează pe tiparul săptămânii trecute


B2: recursiv, direct și valoarea sărbătorilor [Propus]

- **Întrebarea:** prognozează strategia recursivă la fel de bine ca strategia directă și cât ajută variabilele de sărbătoare?
- **Date:** datele și originile din B1; model: B1
- **Cerințe**
 1. Repetați B1 cu strategia recursivă (`forecast_recursive`).
 2. Repetați modelul direct fără cele trei variabile de sărbătoare (`easter`, `xmas`, `holiday`).
 3. Raportați MAE pentru cele trei modele pe toate zilele, pe zilele de sărbătoare legală și pe celelalte zile.
 4. Interpretare: ce grup de variabile explică cea mai mare parte a diferenței și în ce zile?
- **Raportați:** nouă valori MAE și o frază
- Notebook: secțiunea B2

B3: inflația din România cu trei luni înainte [Rezolvat]

- ▣ **Întrebarea:** poate învățarea automată prognoza inflația din România cu trei luni înainte mai bine decât mersul aleator și un model AR liniar?
- ▣ **Date:** inflația anuală IAPC a 27 de țări UE (Eurostat), lunar, 2005–2026
- ▣ **Cerințe**
 1. Construiți variabilele fiecărei țări (lagurile inflației, variațiile lunare, luna calendaristică) și ținta $\pi_{t+3} - \pi_t$ cu `inflation_frame`.
 2. În fiecare ianuarie din 2016, reestimați AR, lasso, random forest și GB doar pe România, precum și un GB global pe toate țările; prognozați fiecare lună a anului.
 3. Calculați RMSE pentru fiecare model și raportul lui față de mersul aleator.
 4. Aplicați testul DM pentru AR față de RW și pentru GB global față de GB local.
 5. Interpretare: ce s-a întâmplat cu toate modelele în 2021–2023?
- ▣ **Raportați:** șase valori RMSE, două teste DM și o frază
- ▣ Notebook: secțiunea B3

B3: rezolvare [Rezolvat]



- ▣ 125 de origini, ianuarie 2016–mai 2026; RMSE (pp): RW 1,41, AR 1,28 (0,90), lasso 1,45 (1,02), RF 1,49 (1,06), GB local 1,64 (1,16), GB global 1,37 (0,97)
- ▣ DM: AR față de RW $-1,33$ ($p = 0,186$); GB global față de GB local $-1,60$ ($p = 0,113$)
- ▣ Interpretare: de la jumătatea lui 2021 până la jumătatea lui 2023, toate valorile RMSE cresc (RW 2,27, AR 2,02, GB global 2,09 pp): șocul energetic nu se afla în trecutul inflației; combinarea a 27 de țări ajută arborii, dar niciun model nu este semnificativ mai bun decât AR

B4: semnul randamentelor BET [Propus]

- ▣ **Întrebarea:** poate un clasificator prognoza dacă BET crește mâine mai bine decât „crește întotdeauna”?
- ▣ **Date:** randamentele logaritmice zilnice ale BET din 2000; anii de test 2015–2026; model: B3 (reestimări anuale)
- ▣ **Cerințe**
 1. Construiți variabilele din `sign_frame` (cinci laguri ale randamentului, sume pe 5, 21, 63 de zile, volatilitatea pe 21 și 63 de zile) și ținta $1\{r_{t+1} > 0\}$.
 2. În fiecare ianuarie, estimați o regresie logistică și un clasificator gradient boosting pe toate zilele anterioare; reperul prognozează clasa majoritară din datele de antrenare.
 3. Raportați acuratețea celor trei, statistica z față de reper și AUC (probabilitatea ca o zi de creștere aleasă la întâmplare să primească un scor mai mare decât o zi de scădere; 0,5: fără putere).
 4. Interpretare: ce spune rezultatul despre eficiența în formă slabă a pieței de la București?
- ▣ **Raportați:** trei valori ale acurateței, două statistici z , două valori AUC și o frază
- ▣ Notebook: secțiunea B4

C1: un model global pentru consumul de energie din Europa [Propus]

- **Ideea:** ENTSO-E publică consumul orar al fiecărei țări europene; un model GB global antrenat pe 20 de țări poate prognoza România mai bine decât unul local
 - ▶ variabile: laguri scalate cu media fiecărei țări, ziua săptămânii, sărbătorile naționale, un identificator al țării
- Întrebări la care trebuie să răspundeți
 - ▶ 1. Depășește modelul global GB local și DHR pe cele 26 de origini din [Capitolul 4](#)?
 - ▶ 2. Prognozează mai bine Paștele ortodox, deși majoritatea țărilor sărbătoresc Paștele occidental?
 - ▶ 3. Ce țări ajută cel mai mult România (eliminând pe rînd cîte o țară)?
- Un posibil proiect de echipă: date, cod, teste DM și un raport de două pagini; model: B1, B3

C2: verificați un răspuns AI [Propus]

- Un student a întrebat un asistent AI dacă învățarea automată poate prognoza piețele și consumul de energie. Răspunsul:
- (a) Un random forest validat cu 5 grupuri explică 36,8% din randamentul S&P 500 din luna următoare, deci piața este previzibilă.
- (b) Un model logistic prognozează semnul zilnic cu acuratețea de 53,8%, mult peste 50%: un semnal profitabil.
- (c) Pentru consum, GB are MASE 0,97, deci este cu 3% mai precis decât DHR.
- (d) Standardizați întâi toată seria, apoi împărțiți-o în antrenare și test.
- (e) Un LSTM este întotdeauna mai precis decât ARIMA, pentru că are memorie lungă.
- (f) Variabilele de calendar ale zilei-țintă, precum sărbătorile, sînt permise, deoarece se cunosc dinainte.
- **Cerințe**
 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă din notebook-ul cursului (secțiunile 2, 6, 9).
- **Raportați:** o listă de șase verdicte, fiecare cu un rînd de justificare

Idei de reținut

- ▣ O prognoză este o predicție din variabile cunoscute la origine: laguri, medii mobile trecute, calendar
- ▣ Strategiile recursivă și directă: le comparăm pe aceleași origini
- ▣ Leakage-ul: orice valoare de după origine, inclusiv prin scalare sau prin grupuri amestecate
- ▣ GB depășește prognoza naivă sezonieră pentru consum; niciun model nu depășește reperul „întotdeauna în creștere” pentru semnul randamentelor BET
- ▣ Un răspuns AI este o ciornă: verificați schema de validare și reperul din spatele fiecărei acurateți declarate

După seminar

- Cursul 9 dezvoltă fiecare temă de azi
 - ▶ variabile și strategii, validarea walk-forward, ridge și lasso, arbori și boosting, rețele neuronale și LSTM, intervale de prognoză, modele globale, competițiile M4 și M5
- Încercați cerințele [Propus] în notebook
- C1 poate deveni un proiect de echipă: un model global pentru consumul de energie din Europa
- Lectură: [Huang și Petukhina \(2022\)](#), cap. 10; [Hyndman și Athanasopoulos \(2021\)](#), secț. 12.4; [Montero-Manso și Hyndman \(2021\)](#)
- **Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar**

Bibliografie

- ▣ Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- ▣ Huang, C., & Petukhina, A. (2022). *Applied Time Series Analysis and Forecasting with Python*. Springer. doi:10.1007/978-3-031-13584-2
- ▣ Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.), Section 12.4, Neural network models. OTexts. otexts.com/fpp3/nnetar.html
- ▣ Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. doi:10.1016/j.ijforecast.2006.03.001
- ▣ Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), 1–21. doi:10.1145/2382577.2382579
- ▣ Koenker, R., & Bassett, G. (1978). Regression quantiles. *Econometrica*, 46(1), 33–50. doi:10.2307/1913643
- ▣ Lei, J., G'Sell, M., Rinaldo, A., Tibshirani, R. J., & Wasserman, L. (2018). Distribution-free predictive inference for regression. *Journal of the American Statistical Association*, 113(523), 1094–1111. doi:10.1080/01621459.2017.1307116
- ▣ Montero-Manso, P., & Hyndman, R. J. (2021). Principles and algorithms for forecasting groups of time series: Locality and globality. *International Journal of Forecasting*, 37(4), 1632–1653. doi:10.1016/j.ijforecast.2021.03.004