



Serii de timp

Seminarul 9: Învățare automată pentru serii de timp



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- **AI:** Artificial Intelligence (inteligență artificială)
- **AR:** AutoRegressive (model) — model autoregresiv
- **ARIMA:** AutoRegressive Integrated Moving Average (model) — model autoregresiv integrat cu medie mobilă
- **AUC:** Area Under the (ROC) Curve (aria de sub curba ROC)
- **BET:** Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- **DHR:** Dynamic Harmonic Regression (regresie armonică dinamică)
- **DM:** Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- **ENTSO-E:** European Network of Transmission System Operators for Electricity (rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică)
- **EODHD:** EOD Historical Data (market-data provider) — furnizor de date de piață
- **GB:** Gradient Boosting (ensemble of regression trees) — gradient boosting (ansamblu de arbori de regresie)
- **HLN:** Harvey–Leybourne–Newbold (small-sample correction of the DM test) — corecția Harvey–Leybourne–Newbold a testului DM pentru eșantioane mici

Acronime folosite în acest material (2/2)

- ▣ **IAPC**: Indicele armonizat al prețurilor de consum
- ▣ **LSTM**: Long Short-Term Memory (network) — rețea cu memorie pe termen lung și scurt
- ▣ **MAE**: Mean Absolute Error (eroarea absolută medie)
- ▣ **MASE**: Mean Absolute Scaled Error (eroarea absolută medie scalată)
- ▣ **MIMO**: Multiple-Input Multiple-Output (forecasting strategy) — strategia cu mai multe ieșiri: un model dă toate orizonturile deodată
- ▣ **ML**: Machine Learning (învățare automată)
- ▣ **OLS**: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **RF**: Random Forest (pădure aleatoare)
- ▣ **RMSE**: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ **ROC**: Receiver Operating Characteristic (curve) — curba caracteristică de operare
- ▣ **RW**: Random Walk (forecast) — prognoza de tip mers aleator
- ▣ **SSE**: Sum of Squared Errors (suma pătratelor erorilor)
- ▣ **UE**: Uniunea Europeană

Întrebarea de azi și structura seminarului

- ▣ Întrebarea seminarului
 - ▶ **cum transformăm o serie de timp într-o problemă de învățare automată și cum știm dacă rezultatul depășește o metodă simplă de referință?**
- ▣ Rezultate de obținut (seminarul are rol de exercițiu: nu se predă și nu se notează nimic)
 - ▶ răspunsurile la exercițiile A
 - ▶ câte o figură și un tabel pentru fiecare exercițiu B
 - ▶ răspunsul AI corectat din C2
 - ▶ o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#)
 - ▶ fiecare cerință indică secțiunea din notebook
- ▣ Exercițiile, tipurile și ordinea lor: [harta exercițiilor](#) (slide-ul următor)
- ▣ Seminar: prof. Daniel Traian Pele, danpele@ase.ro

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	un tabel de laguri, prognoze recursive și directe; leakage-ul într-o medie mobilă	Rezolvat, Propus	A1
A3, A4	o împărțire a unui arbore de regresie; ridge și lasso într-o dimensiune	Rezolvat, Propus	A3
A5, A6	un interval conformal și funcția pinball; MASE și o statistică DM	Rezolvat, Propus	A5
B1, B2	consumul de energie: boosting față de metoda naivă sezonieră; recursiv, direct, sărbători	Rezolvat, Propus	B1
B3, B4	inflația din România; semnul randamentelor BET	Rezolvat, Propus	B3
C1, C2	un model global ca proiect; erorile dintr-un răspuns AI	Propus	B1, B3

- Tipurile: **A** calcule pe hîrtie; **B** date reale, rezolvate în notebook; **C** întrebări deschise și critica unui răspuns AI
- [Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model; soluția se discută la seminar

Datele folosite

Seria	Sursa	Frecvența	Perioada
Consumul de energie electrică, România	ENTSO-E	orar, mediat pe zi (GW)	2022–2026
IAPC, 27 de țări UE	Eurostat (prc_hicp_minr)	lunar, 2015 = 100	2005–2026
BET	EODHD	zilnic, închidere	2000–2026

- ENTSO-E: rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică; același fișier de consum ca în [Capitolul 4](#)
- În notebook: `direct_frame`, `forecast_direct`, `forecast_recursive`, `dm_raw`, `inflation_forecasts`, `sign_frame`; modele scikit-learn cu semințe fixe; nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/17): de la o serie la un tabel

- **Învățarea supervizată:** învățăm o funcție $\hat{f}$ din perechi (variabile explicative x_i , ținta y_i) astfel încât $\hat{f}(x)$ să fie aproape de y pe date **noi**
 - ▶ x_i : vectorul variabilelor explicative ale rîndului i ; modelul nu vede niciodată țintele datelor de test
- Pentru o serie $y_1, \dots, y_n$: un rînd pentru fiecare **origine a prognozei** t

$$y_{t+h} = f(x_t) + e_{t+h}, \quad x_t = (y_t, y_{t-1}, \dots, y_{t-p+1}, \text{medii mobile, calendar})$$

- ▶ h : orizontul; p : numărul de laguri; e_{t+h} : eroarea; fiecare variabilă explicativă trebuie să fie cunoscută la momentul t
- ▶ media mobilă a ultimelor w valori: $\bar{y}_t^{(w)} = \frac{1}{w} \sum_{j=0}^{w-1} y_{t-j}$; calendar: ziua săptămîinii, luna, sărbătorile zilei-țintă
- **Numărul de rînduri:** o serie de lungime n cu p laguri dă $n - p - h + 1$ rînduri complete pentru orizontul h
 - ▶ primelor $p - 1$ origini le lipsesc laguri; ultimelor h origini le lipsește ținta

Noțiuni necesare azi (2/17): un rând al tabelului într-un grafic



- Verde: cele patru laguri cunoscute la originea $t = 24$, variabilele explicative x_t ; roșu: ținta y_{t+3}
- Mutînd originea cu un pas la dreapta obținem rîndul următor: tabelul este o fereastră care alunecă pe serie

Noțiuni necesare azi (3/17): strategii pentru mai mulți pași

- ▣ **Recursivă**: un singur model pentru $h = 1$, aplicat din nou cu propriile prognoze ca intrări Ben Taieb et al. (2012)

$$\hat{y}_{t+1} = \hat{f}(y_t, y_{t-1}, \dots), \quad \hat{y}_{t+2} = \hat{f}(\hat{y}_{t+1}, y_t, \dots)$$

- ▶ un singur model; dar erorile primilor pași intră în pașii următori

- ▣ **Directă**: un model separat $\hat{f}_h$ pentru fiecare orizont, antrenat pe ținta y_{t+h}



$$\hat{y}_{t+h} = \hat{f}_h(y_t, y_{t-1}, \dots), \quad h = 1, \dots, H$$

- ▶ H : orizontul cel mai lung; erorile nu se acumulează, dar trebuie antrenate H modele

- ▣ **MIMO** (multiple-input multiple-output): un singur model cu H ieșiri ($\hat{y}_{t+1}, \dots, \hat{y}_{t+H}$)

Noțiuni necesare azi (4/17): validarea în timp

- Validarea **walk-forward**: antrenăm pe datele până la origine, prognoză blocul următor, mutăm originea
 - ▶ erorile se cumulează pe toate originile $t_1 < t_2 < \dots < t_N$: fiecare prognoză folosește doar trecutul, ca în timp real
- Validarea încrucișată **K-fold**: împărțim aleator rîndurile în K grupe și testăm pe fiecare grupă pe rînd
 - ▶ pentru o serie, rînduri din viitor ajung în datele de antrenare; cu ținte suprapuse, rîndurile de test aproape repetă rînduri de antrenare
 - ▶ niciodată K -fold amestecat pentru modele de prognoză cu ținte suprapuse sau cu variabile exogene



■ Training data ■ Test data

Noțiuni necesare azi (5/17): leakage

- ▣ **Leakage**: informație care nu este disponibilă la origine intră în variabilele explicative sau în antrenare [Kaufman et al. \(2012\)](#)
 - ▶ eroarea de test pare atunci mai bună decât poate fi orice prognoză reală
- ▣ Variabila **medie mobilă** pentru ținta y_t : doar valori dinaintea lui t

$$m_t = \frac{1}{w} \sum_{j=1}^w y_{t-j} \quad (\text{în pandas: } \text{rolling}(w).mean().shift(1))$$

- ▶ fără deplasare, fereastra se termină la y_t , iar variabila conține ținta
- ▣ Alte surse tipice de leakage
 - ▶ standardizarea (medii, abateri standard) estimată pe tot eșantionul, înainte de împărțire
 - ▶ vremea reală din ziua-țintă în locul prognozei disponibile la origine
 - ▶ variabilele de calendar (ziua săptămânii, sărbătorile) sînt cunoscute dinainte: nu produc leakage

Noțiuni necesare azi (6/17): metode de referință și măsuri de acuratețe

Metode de referință (Capitolul 0)

naivă: $\hat{y}_{T+h} = y_T$, naivă sezonieră: $\hat{y}_{T+h} = y_{T+h-m}$

- T : originea (ultima observație); m : perioada sezonieră ($m = 7$ pentru date zilnice; pentru $h \leq m$: aceeași zi a săptămânii trecute)

Erorile $e_i = y_i - \hat{y}_i$ pe N prognoze de test

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |e_i|, \quad \text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N e_i^2}$$

- MAE: eroarea absolută medie, în unitățile lui y ; RMSE: rădăcina erorii pătratice medii, penalizează mai mult erorile mari

MASE Hyndman și Koehler (2006): MAE scalată cu MAE în eșantion a metodei naive sezoniere

$$\text{MASE} = \frac{\text{MAE}}{\frac{1}{n-m} \sum_{t=m+1}^n |y_t - y_{t-m}|}$$

- n : lungimea eșantionului de antrenare; $\text{MASE} < 1$: mai bună decât metoda naivă sezonieră în eșantion; $\text{MASE} = 1,2$: cu 20% mai slabă

Noțiuni necesare azi (7/17): ridge și lasso

- **Modelul liniar:** $\hat{y}_t = \mathbf{x}_t^\top \beta = \sum_{j=1}^p \beta_j x_{tj}$; metoda celor mai mici pătrate (OLS) minimizează $\sum_t (y_t - \mathbf{x}_t^\top \beta)^2$

- ▶ multe laguri și variabile: OLS se supraajustează, coeficienții devin mari și instabili


- **Cele mai mici pătrate penalizate:** ajustarea plus o penalizare care micșorează β_j spre 0

$$\text{ridge: } \min_{\beta} \sum_t (y_t - \mathbf{x}_t^\top \beta)^2 + \lambda \sum_j \beta_j^2, \quad \text{lasso: } \min_{\beta} \sum_t (y_t - \mathbf{x}_t^\top \beta)^2 + \lambda \sum_j |\beta_j|$$

- ▶ ridge **Hoerl și Kennard (1970)**; lasso **Tibshirani (1996)**; $\lambda \geq 0$: intensitatea penalizării; $\lambda = 0$: OLS; λ mare: toți coeficienții aproape de 0
- ▶ variabilele se **standardizează** întâi (media 0, abaterea standard 1), pentru ca un singur λ să le trateze la fel; λ se alege prin validare walk-forward

- Lasso face unii $\hat{\beta}_j$ exact 0: selectează variabile; ridge doar îi micșorează

Noțiuni necesare azi (8/17): ridge și lasso cu o singură variabilă



- OLS = 0.75
- Ridge $S_{xy}/(S_{xx} + \lambda)$
- Lasso (soft thresholding)

- O singură variabilă standardizată x_t ; definim

$$S_{xy} = \sum_t x_t y_t, \quad S_{xx} = \sum_t x_t^2$$

- Formule explicite (minimizăm cele două funcții obiectiv în β)

$$\hat{\beta}_{OLS} = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_{ridge} = \frac{S_{xy}}{S_{xx} + \lambda}$$

$$\hat{\beta}_{lasso} = \text{sign}(S_{xy}) \frac{\max(|S_{xy}| - \lambda/2, 0)}{S_{xx}}$$

- **pragul moale** (soft thresholding): exact 0 când $\lambda/2 \geq |S_{xy}|$; $\text{sign}(\cdot)$: +1 sau -1

- Graficul ($S_{xy} = 30, S_{xx} = 40$): ridge tinde lent spre 0; lasso scade liniar și este 0 de la $\lambda = 60$

Noțiuni necesare azi (9/17): arborele de regresie


- **Arborele de regresie:** o succesiune de întrebări „ $x_j \leq c$?”; fiecare grup final (**frunză**) prognozează media țintelor sale
 - ▶ x_j : o variabilă explicativă; c : pragul; un arbore adânc are multe frunze

- **O împărțire:** pentru pragul c , frunza stângă $L = \{i : x_i \leq c\}$ și frunza dreaptă $R = \{i : x_i > c\}$

$$\text{SSE}(c) = \sum_{i \in L} (y_i - \bar{y}_L)^2 + \sum_{i \in R} (y_i - \bar{y}_R)^2$$

- ▶ $\bar{y}_L, \bar{y}_R$: mediile țintelor din cele două frunze; SSE: suma pătratelor erorilor
- ▶ cel mai bun c minimizează $\text{SSE}(c)$; candidații: mijloacele dintre valorile consecutive ale lui x ordonate
- Un arbore prognozează medii de frunze: nu poate prognoza în afara intervalului țintelor de antrenare (nu extrapolează o tendință)

Noțiuni necesare azi (10/17): o împărțire într-un grafic



- Stînga: 30 de puncte simulate; cea mai bună împărțire pune pragul acolo unde se schimbă nivelul lui y ; fiecare frunză prognozează media ei
- Dreapta: $SSE(c)$ pentru fiecare prag candidat; minimul este mult sub SSE fără împărțire

Noțiuni necesare azi (11/17): pădurile aleatoare și gradient boosting

- **Pădurea aleatoare** (random forest) [Breiman \(2001\)](#): media a B arbori adânci, fiecare crescut pe un eșantion bootstrap al rîndurilor

$$\hat{f}_{RF}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{f}_b(\mathbf{x})$$


- ▶ eșantion bootstrap: n rînduri extrase cu întoarcere; $\hat{f}_b$: arborele b ; media reduce varianța arborilor individuali

- **Gradient boosting** (GB) [Friedman \(2001\)](#): arbori mici adăugați unul cîte unul, fiecare ajustat pe reziduurile curente

$$F_0 = \bar{y}, \quad F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu h_m(\mathbf{x}), \quad m = 1, \dots, M$$


- ▶ h_m : un arbore mic ajustat pe reziduurile $y_i - F_{m-1}(\mathbf{x}_i)$; $\nu \in (0, 1]$: rata de învățare; M : numărul de arbori
- ▶ scikit-learn: `HistGradientBoostingRegressor`; aceeași familie ca `LightGBM` și `XGBoost`

Noțiuni necesare azi (12/17): ansamblurile într-un grafic



- Stînga: un arbore adînc urmărește fiecare punct zgomotos; media a 300 de arbori pe eșantioane bootstrap este mai netedă
- Dreapta: boosting cu $\nu = 0,1$; după 1 arbore ajustarea este aproape plată, după 100 de arbori urmărește curba

Noțiuni necesare azi (13/17): testul Diebold–Mariano




- Două prognoze ale acelorași n ținte; erorile e_{1t} , e_{2t} ; funcția de pierdere L (absolută sau pătratică) [Diebold și Mariano \(1995\)](#)

$$d_t = L(e_{1t}) - L(e_{2t}), \quad DM = \frac{\bar{d}}{\sqrt{\hat{s}^2/n}}$$

- ▶ $\bar{d}$, $\hat{s}^2$: media și varianța lui d_t ; H_0 : acuratețe egală, $\mathbb{E}(d_t) = 0$
- Citirea valorii
 - ▶ $DM < 0$: modelul 1 are pierderea mai mică; respingem H_0 la 5% dacă $|DM|$ depășește cuantila de 97,5% a lui $t(n-1)$
 - ▶ corecția **HLN** [Harvey, Leybourne și Newbold \(1997\)](#) pentru n mic și orizontul h : înmulțim DM cu $\sqrt{(n+1-2h+h(h-1)/n)/n}$
- Graficul: 60 de origini simulate, $\bar{d} < 0$, dar $|DM| = 1,43 < 2,00$: diferența nu este semnificativă

Noțiuni necesare azi (14/17): prognoze de cuantilă și funcția pinball




- O **prognoză de cuantilă** τ q : o valoare pe care rezultatul y ar trebui să o depășească cu probabilitatea $1 - \tau$
 - ▶ $\tau \in (0, 1)$: nivelul cuantilei; $\tau = 0,9$: 90% dintre rezultate ar trebui să fie sub q
- **Funcția pinball** Koenker și Bassett (1978)

$$\rho_{\tau}(y, q) = \begin{cases} \tau(y - q), & y \geq q \\ (1 - \tau)(q - y), & y < q \end{cases}$$

- ▶ pentru τ mare, un rezultat peste q costă mai mult decât unul sub q : pierderea împinge q în sus
- ▶ pierderea pinball medie este minimă la adevărata cuantilă τ ; $\tau = 0,5$: jumătate din eroarea absolută (mediana)


Noțiuni necesare azi (15/17): intervale conformale (split conformal)



- **Split conformal** [Lei et al. \(2018\)](#): un interval cu acoperire garantată, pentru orice prognoză punctuală $\hat{y}$
 - ▶ păstrăm n zile de **calibrare** nefolosite la antrenare; calculăm erorile lor absolute $|y_i - \hat{y}_i|$
- Intervalul cu acoperirea $1 - \alpha$

$$\hat{y} \pm \hat{q}, \quad \hat{q} = a \lceil (n + 1)(1 - \alpha) \rceil\text{-a cea mai mică eroare}$$
 - ▶ α : probabilitatea admisă de neacoperire ($\alpha = 0,1$: un interval de 90%); $\lceil \cdot \rceil$: rotunjirea în sus
 - ▶ valid dacă erorile sînt interschimbabile (fără schimbare de regim între calibrare și test)
- Graficul: $n = 99$, $\alpha = 0,1$: $\lceil 100 \cdot 0,9 \rceil = 90$, deci $\hat{q}$ este a 90-a cea mai mică eroare, 0,55

Noțiuni necesare azi (16/17): clasificarea semnului



- Ținta $1\{r_{t+1} > 0\}$: 1 dacă randamentul de mîne este pozitiv, altfel 0; **regresia logistică**:

$$\Pr(r_{t+1} > 0 \mid \mathbf{x}_t) = \frac{1}{1 + e^{-\mathbf{x}_t^\top \beta}}$$

- ▶ $1\{\cdot\}$: 1 dacă este adevărată condiția; prognoză „crește” dacă probabilitatea depășește 0,5

- **Acuratețea** acc : ponderea prognozelor corecte; **referința** acc_0 : clasa majoritară din datele de antrenare

$$z = \frac{\text{acc} - \text{acc}_0}{\sqrt{\text{acc}_0(1 - \text{acc}_0)/n}} \approx N(0, 1)$$

- ▶ n : numărul zilelor de test; $z > 1,645$: mai bun decît referința la 5% (unilateral)
- **AUC**: aria de sub curba ROC; 0,5: nicio capacitate, 1: ordonare perfectă

Noțiuni necesare azi (17/17): ajustarea în afara eșantionului; modele globale și locale

- ▣ R^2 în afara eșantionului: ponderea varianței ȋintelor de test explicată de prognoze

$$R_{oos}^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y}_{train})^2}$$

- ▶ $\bar{y}_{train}$: media ȋintelor de antrenare, cea mai simplă prognoză; $R_{oos}^2 < 0$: mai slab decît această medie
- ▣ Model **local**: antrenat pe o singură serie; model **global**: un singur model antrenat pe multe serii înrudite
 - ▶ modelul global are mult mai multe rînduri; seriile se fac comparabile (scalate), iar un identificator al seriei poate fi o variabilă explicativă
 - ▶ mersul aleator ($\hat{y}_{t+h} = y_t$) și un model AR rămîn metodele de referință

A1: un tabel de laguri și două strategii [Rezolvat]

Cerință

- ▣ Seria $y_1, \dots, y_8$: 10, 12, 11, 13, 14, 13, 15, 16.
- ▣ 1. Construiți tabelul cu variabilele y_{t-1} , y_{t-2} și ținta y_t ; câte rînduri are?
- ▣ 2. Cu modelul estimat $\hat{y}_t = 2 + 0,6 y_{t-1} + 0,3 y_{t-2}$, calculați prognozele recursive $\hat{y}_9$, $\hat{y}_{10}$, $\hat{y}_{11}$.
- ▣ 3. Un model direct pe doi pași este $\hat{y}_{t+2} = 3 + 0,5 y_t + 0,3 y_{t-1}$: calculați $\hat{y}_{10}$ și numărul de rînduri al tabelului lui.
- ▣ Raportați: tabelul, trei prognoze recursive, o prognoză directă, două numere de rînduri.

Rezolvare

t	y_{t-1}	y_{t-2}	y_t
3	12	10	11
4	11	12	13
5	13	11	14
6	14	13	13
7	13	14	15
8	15	13	16

- ▣ 1. 6 rînduri ($t = 3, \dots, 8$)
- ▣ 2. $\hat{y}_9 = 2 + 0,6 \cdot 16 + 0,3 \cdot 15 = 16,10$;
 $\hat{y}_{10} = 2 + 0,6 \cdot 16,10 + 0,3 \cdot 16 = 16,46$; $\hat{y}_{11} = 16,71$
- ▣ 3. $\hat{y}_{10} = 3 + 0,5 \cdot 16 + 0,3 \cdot 15 = 15,50$; 5 rînduri (originile $t = 2, \dots, 6$)

A2: găsiți leakage-ul [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Seria zilnică 10, 12, 11, 13, 14; ținta este ultima valoare, 14. Model: [A1](#).
- ▣ 1. Calculați media corectă pe 3 zile pentru această țintă și media pe care ar da-o un `rolling(3).mean()` scris neglijent, fără `shift(1)`.
- ▣ 2. Pentru fiecare alegere, precizați dacă produce leakage: (a) o scalare estimată pe 2022–2026 înainte de împărțire; (b) indicatorii de sărbătoare ai zilei-țintă; (c) temperatura măsurată în ziua-țintă; (d) validare cu 5 grupuri amestecate pentru o țintă pe 21 de zile.
- ▣ Raportați: două medii și patru verdicte, fiecare cu un motiv.

A3: o împărțire a unui arbore de regresie [Rezolvat]

Cerință

- ▣ Șase zile: x = consumul din aceeași zi a săptămînii trecute, y = consumul de azi (GW): (4,8; 5,0), (5,0; 5,2), (5,6; 5,9), (6,0; 6,0), (6,4; 6,6), (6,9; 7,0).
- ▣ 1. Enumerați cele cinci praguri candidate.
- ▣ 2. Pentru fiecare, calculați cele două medii ale frunzelor și SSE totală.
- ▣ 3. Alegeți împărțirea și dați prognoza pentru $x = 6,2$.
- ▣ Raportați: un tabel cu cinci rînduri, pragul ales, o prognoză.

Rezolvare

prag	media stînga	media dreapta	SSE
4,9	5,00	6,14	1,912
5,3	5,10	6,38	0,827
5,8	5,37	6,53	0,953
6,2	5,53	6,80	0,828
6,7	5,74	7,00	1,672

- ▣ Fără împărțire: media 5,95, SSE 2,995
- ▣ Cea mai bună: $x \leq 5,3$, SSE 0,827; frunzele 5,10 și 6,38 GW
- ▣ $x = 6,2 > 5,3$: prognoza 6,38 GW

A4: ridge și lasso într-o dimensiune [Propus]

Rezolvarea se discută la seminar

Cerință

- O variabilă standardizată cu $S_{xy} = 40$ și $S_{xx} = 50$. Model: A3 și formulele din Noțiuni necesare azi (8/17).
- 1. Calculați coeficientul OLS.
- 2. Calculați coeficientul ridge pentru $\lambda = 10$ și $\lambda = 50$.
- 3. Calculați coeficientul lasso pentru $\lambda = 20$ și $\lambda = 100$.
- 4. Explicați într-o frază ce metodă poate elimina un lag din model.
- Raportați: cinci coeficienți și o frază.

A5: un interval conformal și funcția pinball [Rezolvat]

Cerință

- Un model prognozează consumul de mîine, $\hat{y} = 6,10$ GW. În 9 zile de calibrare, erorile lui absolute au fost 0,12; 0,30; 0,05; 0,22; 0,41; 0,18; 0,09; 0,27; 0,35 GW.
- 1. Construiți intervalul conformal de 80%.
- 2. O prognoză cuantică de 90% este $q = 6,4$ GW: calculați funcția pinball dacă $y = 6,0$ și dacă $y = 6,6$.
- Raportați: k , $\hat{q}$, intervalul, două valori ale pierderii.

Rezolvare

- 1. Ordonate: 0,05; 0,09; 0,12; 0,18; 0,22; 0,27; 0,30; 0,35; 0,41; $k = \lceil 10 \cdot 0,8 \rceil = 8$; $\hat{q} = 0,35$
- intervalul $6,10 \pm 0,35 = [5,75; 6,45]$ GW
- 2. $y = 6,0 < q$: $(1 - 0,9)(6,4 - 6,0) = 0,04$; $y = 6,6 > q$: $0,9 \cdot 0,2 = 0,18$
- o valoare peste o cuantilă mare costă de nouă ori mai mult pe GW: pierderea împinge q în sus pînă cînd doar 10% dintre valori o depășesc

A6: MASE și o statistică Diebold–Mariano [Propus]

Rezolvarea se discută la seminar


Cerință

- ▣ Erorile absolute medii (GW) a două modele la 6 origini: $A = 0,30; 0,25; 0,40; 0,28; 0,35; 0,22$; $B = 0,32; 0,30; 0,38; 0,35; 0,41; 0,30$; scala MASE 0,31 GW. Model: [A5](#), [Noțiuni necesare azi \(6/17\)](#) și [Noțiuni necesare azi \(13/17\)](#).
- ▣ 1. Calculați MAE și MASE pentru fiecare model.
- ▣ 2. Calculați $d_t = A_t - B_t$, media $\bar{d}$ și abaterea standard s ale lui d_t , apoi $DM = \bar{d}/(s/\sqrt{6})$.
- ▣ 3. Comparați $|DM|$ cu valoarea critică de 5% a distribuției $t(5)$ și formulați concluzia.
- ▣ Raportați: patru valori de acuratețe, $\bar{d}$, DM și o decizie.

B1: gradient boosting pentru consumul de energie electrică [Rezolvat]

- **Întrebarea:** prognozează un model gradient boosting consumul zilnic din săptămîna următoare mai bine decît „aceeași zi a săptămîinii trecute”?
- **Date:** consumul mediu zilnic al României (GW), 2022–2026; origini săptămînale de la 5 ianuarie la 22 iunie 2026; orizonturile 1–7 zile
- **Cerințe**
 1. Construiți tabelele directe (14 laguri, medii pe 7 și 28 de zile, aceeași zi a săptămîinii, calendarul zilei-țintă) cu `direct_frame`.
 2. La fiecare origine, antrenați cîte un `HistGradientBoostingRegressor` pentru fiecare orizont pe datele de dinaintea originii și prognozați următoarele 7 zile.
 3. Calculați MAE, RMSE și MASE pentru GB și pentru prognoza naivă sezonieră.
 4. Aplicați testul Diebold–Mariano pe erorile absolute medii pe origine.
 5. Interpretare: la ce orizonturi este cîștigul GB cel mai mare și de ce?
- **Raportați:** șase valori de acuratețe, o statistică DM cu p-value-ul ei, o frază
- Notebook: secțiunea [B1](#)

B1: rezolvare [Rezolvat]



- 25 de origini, 7 orizonturi; MAE: GB 320 MW, naivă sezonieră 391 MW; RMSE 409 și 521 MW; MASE 1,04 și 1,27 (scala 308 MW)
- DM (cu corecția Harvey–Leybourne–Newbold pentru eșantioane mici, HLN) = $-2,63$, $p = 0,015$; originea cu cea mai mare eroare pentru GB: 5 ianuarie 2026 (MAE 576 MW)
- Interpretare: cu o zi înainte, GB are 252 MW față de 411 MW: folosește nivelul de ieri, pe care metoda naivă sezonieră îl ignoră; la 7 zile (371 și 429 MW) ambele se bazează pe tiparul săptămânii trecute


B2: recursiv, direct și valoarea sărbătorilor [Propus]

- **Întrebarea:** prognozează strategia recursivă la fel de bine ca strategia directă și cât ajută variabilele de sărbătoare?
- **Date:** datele și originile din B1; model: B1
- **Cerințe**
 1. Repetați B1 cu strategia recursivă (`forecast_recursive`).
 2. Repetați modelul direct fără cele trei variabile de sărbătoare (`easter`, `xmas`, `holiday`).
 3. Raportați MAE pentru cele trei modele pe toate zilele, pe zilele de sărbătoare legală și pe celelalte zile.
 4. Interpretare: ce grup de variabile explică cea mai mare parte a diferenței și în ce zile?
- **Raportați:** nouă valori MAE și o frază
- Notebook: secțiunea B2

B3: inflația din România cu trei luni înainte [Rezolvat]

- **Întrebarea:** poate învățarea automată prognoza inflația din România cu trei luni înainte mai bine decât mersul aleator și un model AR liniar?
- **Date:** inflația anuală IAPC a 27 de țări UE (Eurostat), lunar, 2005–2026
- **Cerințe**
 1. Construiți variabilele fiecărei țări (lagurile inflației, variațiile lunare, luna calendaristică) și ținta $\pi_{t+3} - \pi_t$ cu `inflation_frame`.
 2. În fiecare ianuarie din 2016, reestimați AR, lasso, random forest și GB doar pe România, precum și un GB global pe toate țările; prognozați fiecare lună a anului.
 3. Calculați RMSE pentru fiecare model și raportul lui față de mersul aleator.
 4. Aplicați testul DM pentru AR față de RW și pentru GB global față de GB local.
 5. Interpretare: ce s-a întâmplat cu toate modelele în 2021–2023?
- **Raportați:** șase valori RMSE, două teste DM și o frază
- Notebook: secțiunea [B3](#)

B3: rezolvare [Rezolvat]



- ▣ 125 de origini, ianuarie 2016–mai 2026; RMSE (pp): RW 1,41, AR 1,28 (0,90), lasso 1,45 (1,02), RF 1,49 (1,06), GB local 1,64 (1,16), GB global 1,37 (0,97)
- ▣ DM: AR față de RW $-1,33$ ($p = 0,186$); GB global față de GB local $-1,60$ ($p = 0,113$)
- ▣ Interpretare: de la jumătatea lui 2021 până la jumătatea lui 2023, toate valorile RMSE cresc (RW 2,27, AR 2,02, GB global 2,09 pp): șocul energetic nu se afla în trecutul inflației; combinarea a 27 de țări ajută arborii, dar niciun model nu este semnificativ mai bun decât AR

B4: semnul randamentelor BET [Propus]

- ▣ **Întrebarea:** poate un clasificator prognoza dacă BET crește mâine mai bine decât „crește întotdeauna”?
- ▣ **Date:** randamentele logaritmice zilnice ale BET din 2000; anii de test 2015–2026; model: [B3](#) (reestimări anuale)
- ▣ **Cerințe**
 1. Construiți variabilele din `sign_frame` (cinci laguri ale randamentului, sume pe 5, 21, 63 de zile, volatilitatea pe 21 și 63 de zile) și ținta $1\{r_{t+1} > 0\}$.
 2. În fiecare ianuarie, estimați o regresie logistică și un clasificator gradient boosting pe toate zilele anterioare; reperul prognozează clasa majoritară din datele de antrenare.
 3. Raportați acuratețea celor trei, statistica z față de reper și AUC (probabilitatea ca o zi de creștere aleasă la întâmplare să primească un scor mai mare decât o zi de scădere; 0,5: fără putere).
 4. Interpretare: ce spune rezultatul despre eficiența în formă slabă a pieței de la București?
- ▣ **Raportați:** trei valori ale acurateței, două statistici z , două valori AUC și o frază
- ▣ Notebook: secțiunea [B4](#)

C1: un model global pentru consumul de energie din Europa [Propus]

- **Ideea:** ENTSO-E publică consumul orar al fiecărei țări europene; un model GB global antrenat pe 20 de țări poate prognoza România mai bine decât unul local
 - ▶ variabile: laguri scalate cu media fiecărei țări, ziua săptămânii, sărbătorile naționale, un identificator al țării
- Întrebări la care trebuie să răspundeți
 - ▶ 1. Depășește modelul global GB local și DHR pe cele 26 de origini din [Capitolul 4](#)?
 - ▶ 2. Prognozează mai bine Paștele ortodox, deși majoritatea țărilor sărbătorească Paștele occidental?
 - ▶ 3. Ce țări ajută cel mai mult România (eliminând pe rînd cîte o țară)?
- Un posibil proiect de echipă: date, cod, teste DM și un raport de două pagini; model: [B1](#), [B3](#)

C2: verificați un răspuns AI [Propus]

- Un student a întrebat un asistent AI dacă învățarea automată poate prognoza piețele și consumul de energie. Răspunsul:
- (a) Un random forest validat cu 5 grupuri explică 36,8% din randamentul S&P 500 din luna următoare, deci piața este previzibilă.
- (b) Un model logistic prognozează semnul zilnic cu acuratețea de 53,8%, mult peste 50%: un semnal profitabil.
- (c) Pentru consum, GB are MASE 0,97, deci este cu 3% mai precis decât DHR.
- (d) Standardizați întâi toată seria, apoi împărțiți-o în antrenare și test.
- (e) Un LSTM este întotdeauna mai precis decât ARIMA, pentru că are memorie lungă.
- (f) Variabilele de calendar ale zilei-țintă, precum sărbătorile, sînt permise, deoarece se cunosc dinainte.
- **Cerințe**
 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă din notebook-ul cursului (secțiunile 2, 6, 9).
- **Raportați:** o listă de șase verdicte, fiecare cu un rînd de justificare

Idei de reținut

- ▣ O prognoză este o predicție din variabile cunoscute la origine: laguri, medii mobile trecute, calendar
- ▣ Strategiile recursivă și directă: le comparăm pe aceleași origini
- ▣ Leakage-ul: orice valoare de după origine, inclusiv prin scalare sau prin grupuri amestecate
- ▣ GB depășește prognoza naivă sezonieră pentru consum; niciun model nu depășește reperul „întotdeauna în creștere” pentru semnul randamentelor BET
- ▣ Un răspuns AI este o ciornă: verificați schema de validare și reperul din spatele fiecărei acurateți declarate

După seminar

- Cursul 9 dezvoltă fiecare temă de azi
 - ▶ variabile și strategii, validarea walk-forward, ridge și lasso, arbori și boosting, rețele neuronale și LSTM, intervale de prognoză, modele globale, competițiile M4 și M5
- Încercați cerințele [Propus] în notebook
- C1 poate deveni un proiect de echipă: un model global pentru consumul de energie din Europa
- Lectură: Huang și Petukhina (2022), cap. 10; Hyndman și Athanasopoulos (2021), secț. 12.4; Montero-Manso și Hyndman (2021)

Bibliografie

- ▣ Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- ▣ Huang, C., & Petukhina, A. (2022). *Applied Time Series Analysis and Forecasting with Python*. Springer. doi:10.1007/978-3-031-13584-2
- ▣ Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.), Section 12.4, Neural network models. OTexts. otexts.com/fpp3/nnetar.html
- ▣ Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. doi:10.1016/j.ijforecast.2006.03.001
- ▣ Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), 1–21. doi:10.1145/2382577.2382579
- ▣ Koenker, R., & Bassett, G. (1978). Regression quantiles. *Econometrica*, 46(1), 33–50. doi:10.2307/1913643
- ▣ Lei, J., G'Sell, M., Rinaldo, A., Tibshirani, R. J., & Wasserman, L. (2018). Distribution-free predictive inference for regression. *Journal of the American Statistical Association*, 113(523), 1094–1111. doi:10.1080/01621459.2017.1307116
- ▣ Montero-Manso, P., & Hyndman, R. J. (2021). Principles and algorithms for forecasting groups of time series: Locality and globality. *International Journal of Forecasting*, 37(4), 1632–1653. doi:10.1016/j.ijforecast.2021.03.004