



Serii de timp



Seminarul 10: Modele în spațiul stărilor, filtrul Kalman și modele Markov switching

Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material

- ▣ **AI:** Artificial Intelligence (inteligență artificială)
- ▣ **AR:** AutoRegressive (model) — model autoregresiv
- ▣ **ARMA:** AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **BET:** Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BIC:** Bayesian Information Criterion (criteriul informațional bayesian al lui Schwarz)
- ▣ **CBO:** Congressional Budget Office (oficiul pentru buget al Congresului SUA)
- ▣ **EODHD:** EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ **FRED:** Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- ▣ **GARCH:** Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ **HP:** Hodrick–Prescott (filter) — filtrul Hodrick–Prescott
- ▣ **IAPC:** Indicele armonizat al prețurilor de consum
- ▣ **NBER:** National Bureau of Economic Research (biroul național de cercetare economică al SUA, care datează recesiunile)
- ▣ **OLS:** Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **PIB:** Produsul intern brut
- ▣ **SD:** Standard Deviation (abaterea standard)
- ▣ **SE:** Standard Error (eroare standard)
- ▣ **SES:** Simple Exponential Smoothing (netezire exponențială simplă)
- ▣ **SUA:** Statele Unite ale Americii
- ▣ **TVA:** Taxa pe valoarea adăugată
- ▣ **UC:** Unobserved Components (model) — model cu componente neobservate

Întrebarea de azi și structura seminarului

- ▣ Întrebarea seminarului
 - ▶ **cum estimăm o mărime pe care nu o observăm niciodată (un nivel, un trend, un regim) din date zgomotoase, perioadă cu perioadă?**
- ▣ Rezultate de obținut (seminarul are rol de exercițiu: nu se predă și nu se notează nimic)
 - ▶ răspunsurile la exercițiile A
 - ▶ câte o figură și un tabel pentru fiecare exercițiu B
 - ▶ răspunsul A1 corectat din C2
 - ▶ o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#)
 - ▶ fiecare cerință indică secțiunea din notebook
- ▣ Exercițiile, tipurile și ordinea lor: [harta exercițiilor](#) (slide-ul următor)
- ▣ Seminar: prof. Daniel Traian Pele, danpele@ase.ro

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	filtrul Kalman al unui model local level pentru trei perioade; o valoare lipsă	Rezolvat, Propus	A1
A3, A4	starea de echilibru și netezirea exponențială; forme în spațiul stărilor și prognoze	Rezolvat, Propus	A3
A5, A6	duratele regimurilor; un pas al filtrului Hamilton	Rezolvat, Propus	A5
B1, B2	inflația de fond din România; deviația PIB a SUA	Rezolvat, Propus	B1
B3, B4	recesiunile în producția industrială din SUA; regimurile de volatilitate ale BET	Rezolvat, Propus	B3
C1, C2	regimurile inflației din România; erorile dintr-un răspuns AI	Propus	B3, A1–A6

- Tipurile: **A** calcule pe hîrtie; **B** date reale, rezolvate în notebook; **C** întrebări deschise și critica unui răspuns AI
- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model; soluția se discută la seminar

Datele folosite

Seria	Sursa	Frecvența	Perioada
IAPC, România	Eurostat (prc_hicp_minr)	lunar, 2015 = 100	1996–2026
PIB real și PIB potențial, SUA	FRED (GDPC1, GDPPOT)	trimestrial	1947–2026
producția industrială, SUA	FRED (INDPRO)	lunar	1960–2019
indicatorul de recesiune NBER	FRED (USREC)	lunar	1960–2019
BET, S&P 500	EODHD	săptămînal, din închideri zilnice	2000–2026

- Inflația lunară: $100\Delta \ln P_t$, ajustată sezonier (SA) prin eliminarea mediilor lunare ([Capitolul 4](#)); deviația PIB a CBO: $100(\text{PIB}_t/\text{GDPPOT}_t - 1)$
- În notebook: `kalman_by_hand`, `local_level_ml`, `uc_fit`, `hamilton_filter`, `MarkovRegression`; nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/18): forma în spațiul stărilor

- ▣ **Forma în spațiul stărilor:** o stare ascunsă α_t evoluează în timp și este observată cu zgomot **Durbin și Koopman (2012)**

$$\text{măsurare: } y_t = Z\alpha_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, H)$$

$$\text{tranziție: } \alpha_{t+1} = T\alpha_t + R\eta_t, \quad \eta_t \sim N(0, Q)$$

- ▣ Matricele sistemului
 - ▶ Z : leagă starea de observație; T : mută starea cu o perioadă înainte; R : transmite șocurile η_t în stare
 - ▶ H, Q : varianțele zgomotului de măsurare ε_t și ale șocurilor stării η_t ; cele două zgomote sînt independente
- ▣ Multe modele au această formă: ARMA, tendințe, cicluri, regresii cu coeficienți variabili; un singur algoritm (filtrul Kalman) le estimează pe toate

Noțiuni necesare azi (2/18): modelul de nivel local

- **Nivelul local:** observația = un nivel care se mișcă precum un mers aleator + zgomot

$$y_t = \mu_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2); \quad \mu_{t+1} = \mu_t + \eta_t, \quad \eta_t \sim N(0, \sigma_\eta^2)$$


- ▶ μ_t : nivelul (starea); $Z = T = R = 1$, $H = \sigma_\varepsilon^2$, $Q = \sigma_\eta^2$

- **Raportul semnal-zgomot**

$$q = \frac{\sigma_\eta^2}{\sigma_\varepsilon^2}$$

- ▶ q mic: nivelul abia se mișcă, majoritatea variațiilor lui y_t sînt zgomot; q mare: nivelul urmărește datele
- ▶ $q = 0$: o medie constantă; $\sigma_\varepsilon^2 = 0$: un mers aleator pur

Noțiuni necesare azi (3/18): raportul semnal-zgomot într-un grafic



- Aceleași șocuri, două valori ale lui q ; stînga, $q = 0,02$: nivelul se mișcă lent, iar observațiile sînt mult împrăștiate în jurul lui
- Dreapta, $q = 1$: nivelul se mișcă la fel de mult ca zgomotul, deci datele îl urmăresc îndeaproape

Noțiuni necesare azi (4/18): încă trei modele în forma spațiului stărilor

- **Tendința liniară locală:** un nivel și o pantă, ambele mersuri aleatoare

$$\mu_{t+1} = \mu_t + \beta_t + \eta_t, \quad \beta_{t+1} = \beta_t + \zeta_t, \quad \alpha_t = \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix}, \quad T = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$$

- ▶ β_t : panta (creșterea pe perioadă); ζ_t : șocul pantei; $Z = (1, 0)$

- **AR(2)** $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \eta_t$: starea pune una sub alta valoarea curentă și cea anterioară

$$\alpha_t = \begin{pmatrix} y_t \\ y_{t-1} \end{pmatrix}, \quad T = \begin{pmatrix} \phi_1 & \phi_2 \\ 1 & 0 \end{pmatrix}, \quad R = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad Z = (1, 0), \quad H = 0$$

- ▶ al doilea rând al lui T doar copiază y_t în starea următoare; $H = 0$: y_t este observat exact

- **Netezirea exponențială simplă (SES, Capitolul 0)**


$$\ell_t = \alpha y_t + (1 - \alpha) \ell_{t-1}, \quad \hat{y}_{t+1} = \ell_t$$

- ▶ ℓ_t : nivelul netezit; $\alpha \in (0, 1)$: ponderea celei mai noi observații

Noțiuni necesare azi (5/18): prognoze din forma spațiului stărilor

- Proгноzele iterează tranziția pornind de la ultima stare estimată $\hat{\alpha}_T$ (șocurile se înlocuiesc cu 0)

$$\hat{\alpha}_{T+h} = T \hat{\alpha}_{T+h-1} = T^h \hat{\alpha}_T, \quad \hat{y}_{T+h} = Z \hat{\alpha}_{T+h}$$



- Stînga: nivel local, toate orizonturile egale cu a_{n+1} ; varianța $P_{n+1} + (h-1)\sigma_\eta^2 + \sigma_\varepsilon^2$ crește cu h . Dreapta: AR(2) cu $\phi_1 = 0,5$, $\phi_2 = 0,3$ și o tendință cu panta 0,5

Noțiuni necesare azi (6/18): filtrul Kalman al modelului de nivel local

- Înainte de sosirea lui y_t : o predicție a_t a nivelului μ_t și varianța ei P_t **Kalman (1960)**

- pornire: a_1, P_1 date (un P_1 mare când începutul este necunoscut)

- **1. Surpriza și varianța ei**

$$v_t = y_t - a_t, \quad F_t = P_t + \sigma_\varepsilon^2$$

- **2. Actualizarea cu câștigul Kalman K_t**

$$K_t = \frac{P_t}{F_t} \in (0, 1), \quad a_{t|t} = a_t + K_t v_t, \quad P_{t|t} = P_t (1 - K_t)$$


- K_t : partea din surpriză adăugată nivelului; nivel incert (P_t mare) sau date precise (σ_ε^2 mic): K_t aproape de 1

- **3. Predicția pentru perioada următoare: nivelul este un mers aleator**

$$a_{t+1} = a_{t|t}, \quad P_{t+1} = P_{t|t} + \sigma_\eta^2$$

- y_t **lipsă**: sărim pasul 2, $a_{t|t} = a_t, P_{t|t} = P_t$; varianța crește cu σ_η^2 în fiecare perioadă fără date

Noțiuni necesare azi (7/18): filtrul Kalman într-un grafic



- Nivelul filtrat $a_{t|t}$ urmărește nivelul adevărat cu întârziere; banda $\pm 1.96\sqrt{P_{t|t}}$ este incertitudinea lui
- Blocul lipsă: nicio actualizare, $a_{t|t}$ rămîne constant, iar banda se lărgțește; prima observație de după gol primește un câștig mare

Noțiuni necesare azi (8/18): starea staționară și netezirea exponențială

- După câțiva pași P_t și K_t nu se mai schimbă: **starea staționară** $\bar{P}$, $\bar{K}$

$$\bar{P} = \sigma_\varepsilon^2 \frac{q + \sqrt{q^2 + 4q}}{2}, \quad \bar{K} = \frac{\bar{P}}{\bar{P} + \sigma_\varepsilon^2}$$


- $\bar{P}$ este aici varianța predicției a_t ; este soluția ecuației $\bar{P} = \bar{P}(1 - \bar{K}) + \sigma_\eta^2$

- În starea staționară filtrul **este** netezirea exponențială simplă [Muth \(1960\)](#)

$$a_{t+1} = a_t + \bar{K}(y_t - a_t) = \bar{K} y_t + (1 - \bar{K}) a_t$$


- recurența SES cu $\alpha = \bar{K}$ și $\ell_t = a_{t+1}$
 ► relația inversă, de la ponderea SES la raportul semnal-zgomot: $q = \alpha^2 / (1 - \alpha)$

Noțiuni necesare azi (9/18): câștigul Kalman într-un grafic



- Stînga: pornind de la $P_1 = 1$, K_t ajunge la $\bar{K}$ în câțiva pași; cu $q = 1$, $\bar{K} = 0,618$ (secțiunea de aur minus 1)
- Dreapta: $\bar{K}$, ponderea SES echivalentă, crește cu q : cu cît datele sînt mai zgomotoase (q mic), cu atît ultima observație contează mai puțin

Noțiuni necesare azi (10/18): verosimilitatea, filtrarea și netezirea



□ Verosimilitatea prin descompunerea erorilor de predicție

$$\log L = -\frac{1}{2} \sum_{t=1}^n \left(\log 2\pi + \log F_t + \frac{v_t^2}{F_t} \right)$$

- ▶ filtrul dă v_t și F_t pentru $\sigma_\varepsilon^2, \sigma_\eta^2$ date; maximizăm $\log L$ în raport cu cele două varianțe
- ▶ surprizele mari v_t în raport cu varianța lor F_t scad verosimilitatea
- Nivelul **filtrat** $a_{t|t}$: folosește $y_1, \dots, y_t$, ce se știa în timp real
- Nivelul **netezit** $\hat{\mu}_t$: folosește tot eșantionul $y_1, \dots, y_n$ (istoric) [Rauch, Tung și Striebel \(1965\)](#)
 - ▶ mai precis, dar revizuit când sosesc date noi; nu este disponibil în timp real

Noțiuni necesare azi (11/18): tendință și ciclu: deviația PIB de la potențial

- **Deviația PIB de la potențial** (output gap): ciclul ψ_t din $y_t = 100 \log \text{PIB}_t = \mu_t + \psi_t$ (tendință plus ciclu, în % din tendință)
 - ▶ reperul oficial (SUA): deviația CBO $100(\text{GDP}_t/\text{GDPPOT}_t - 1)$; CBO: Congressional Budget Office; GDPPOT: PIB-ul potențial
- **Modelul UC** (componente neobservate) [Harvey \(1989\)](#): o tendință netedă plus un ciclu AR(2), estimat cu filtrul Kalman

$$\Delta^2 \mu_{t+1} = \zeta_t, \quad \psi_t = \phi_1 \psi_{t-1} + \phi_2 \psi_{t-2} + \kappa_t$$

- ▶ $\Delta^2 \mu_{t+1} = \mu_{t+1} - 2\mu_t + \mu_{t-1}$: variația pantei; ζ_t, κ_t : șocuri independente

Noțiuni necesare azi (12/18): două filtre pentru deviația PIB de la potențial

- **Filtrul HP** [Hodrick și Prescott \(1997\)](#): tendința τ_t este soluția problemei

$$\min_{\tau} \sum_t (y_t - \tau_t)^2 + \lambda \sum_t (\Delta^2 \tau_t)^2, \quad \lambda = 1600 \text{ pentru date trimestriale}$$


- ▶ ajustare față de netezime; bilateral: τ_t folosește date de după t , deci ultimele valori se schimbă când sosesc trimestre noi

- **Filtrul Hamilton** [Hamilton \(2018\)](#): deviația este reziduul unei regresii OLS cu doi ani înainte

$$y_{t+8} = b_0 + b_1 y_t + b_2 y_{t-1} + b_3 y_{t-2} + b_4 y_{t-3} + u_{t+8}, \quad \text{deviația}_{t+8} = \hat{u}_{t+8}$$

- ▶ unilateral: folosește doar trecutul fiecărui trimestru

Noțiuni necesare azi (13/18): filtrul HP într-un grafic



- 100 log PIB trimestrial simulat, cu un ciclu AR(2) cunoscut; stînga: deviația HP pe tot eșantionul urmărește ciclul (corelația 0,74)
- Dreapta: ultima valoare HP a fiecărui eșantion care crește, adică ce vede un analist în timp real: corelația 0,51, valori trase spre 0
- Corelația a două deviații a_t , b_t : $r = \frac{\sum(a_t - \bar{a})(b_t - \bar{b})}{\sqrt{\sum(a_t - \bar{a})^2 \sum(b_t - \bar{b})^2}}$

Noțiuni necesare azi (14/18): modelul Markov switching

- **Markov switching Hamilton (1989)**: media și varianța depind de un **regim** ascuns $S_t \in \{1, 2\}$

$$y_t = \mu_{S_t} + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_{S_t}^2)$$

- ▶ μ_j, σ_j : media și abaterea standard în regimul j (de exemplu recesiune și expansiune)

- Regimul urmează un **lanț Markov**: regimul de mâine depinde doar de cel de azi

$$p_{ij} = \Pr(S_t = j \mid S_{t-1} = i), \quad \mathbf{P} = \begin{pmatrix} p_{11} & 1 - p_{11} \\ 1 - p_{22} & p_{22} \end{pmatrix}$$


- ▶ fiecare rând al matricei de tranziție $\mathbf{P}$ are suma 1; probabilitățile de tranziție în h pași: puterea matricei $\mathbf{P}^h$

- Probabilitatea **ergodică** (pe termen lung) a regimului 1

$$\pi_1 = \frac{1 - p_{22}}{2 - p_{11} - p_{22}}, \quad \pi_2 = 1 - \pi_1$$

- ▶ ponderea perioadelor petrecute în regimul 1 pe un eșantion lung

Noțiuni necesare azi (15/18): durata regimurilor



■ $p_{ii} = 0.75$: mean $1/(1 - p_{ii}) = 4$

■ $p_{ii} = 0.95$: mean $1/(1 - p_{ii}) = 20$

- Odată intrat în regimul i , lanțul rămîne cu probabilitatea p_{ii} în fiecare perioadă: **durata** D este geometrică

$$\Pr(D = k) = (1 - p_{ii}) p_{ii}^{k-1}, \quad k = 1, 2, \dots$$

► rămîne de $k - 1$ ori, apoi pleacă o dată


- **Durata așteptată**

$$\mathbb{E}(D_i) = \sum_{k \geq 1} k (1 - p_{ii}) p_{ii}^{k-1} = \frac{1}{1 - p_{ii}}$$

► graficul: $p_{ii} = 0,75$ dă 4 perioade, $p_{ii} = 0,95$ dă 20

- Multe episoade scurte și cîteva lungi: durata cea mai probabilă este întotdeauna 1

Noțiuni necesare azi (16/18): filtrul Hamilton



- $\xi_{t-1} = \Pr(S_{t-1} = 1 | Y_{t-1})$; Y_{t-1} : datele pînă la $t - 1$

- ▶ **predicție:**

$$\Pr(S_t = 1 | Y_{t-1}) = p_{11}\xi_{t-1} + (1 - p_{22})(1 - \xi_{t-1})$$

- **Densitatea** lui y_t în regimul j (distribuția Normală)


$$f_j(y_t) = \frac{1}{\sigma_j} \varphi\left(\frac{y_t - \mu_j}{\sigma_j}\right), \quad \varphi(z) = \frac{e^{-z^2/2}}{\sqrt{2\pi}}$$

- **Actualizare** (regula lui Bayes): probabilitatea a priori ori densitatea, normalizat

$$\xi_t = \frac{\Pr(S_t = 1 | Y_{t-1}) f_1(y_t)}{\sum_{j=1}^2 \Pr(S_t = j | Y_{t-1}) f_j(y_t)}$$

- ▶ numitorul $p(y_t | Y_{t-1})$ este contribuția perioadei t la verosimilitate
- ▶ graficul: a priori 0,3; y_t este mai aproape de μ_1 , deci $\xi_t = 0,57$

Noțiuni necesare azi (17/18): probabilitățile filtrate și netezite ale regimurilor



- Simulare: $p_{11} = 0,90$, $p_{22} = 0,97$; regimul 1: medie mică, varianță mare; zonele colorate: adevăratul regim 1
- Filtrată** $\Pr(S_t = 1 | Y_t)$: timp real, mai zgomotoasă; **netezită** $\Pr(S_t = 1 | Y_n)$: folosește date ulterioare, mai curată; o perioadă intră în regimul 1 dacă probabilitatea depășește 0,5

Noțiuni necesare azi (18/18): regimurile în practică: măsuri și verificări

- **Concordanța** cu o datare de referință (de exemplu recesiunile NBER; NBER: National Bureau of Economic Research)
 - ▶ acordul: ponderea perioadelor clasificate ca în referință; rata de detectare: ponderea recesiunilor de referință găsite
 - ▶ alarmele false: ponderea expansiunilor de referință clasificate drept recesiune
- **Volatilitatea anualizată** a regimului j din randamente săptămânale

$$\sigma_j^{an} = \sqrt{52} \sigma_j$$

- ▶ 52 de săptămâni pe an; comparăm cu volatilitatea GARCH(1,1) σ_t din [Capitolul 5](#)
 - ▶ volatilitatea implicată de regimuri: $\sqrt{\xi_t \sigma_1^2 + (1 - \xi_t) \sigma_2^2}$, cu ξ_t probabilitatea regimului 1
- **Numărul de regimuri**: comparăm 2 și 3 regimuri după $BIC = -2 \ln L + k \ln n$
 - ▶ k : numărul de parametri (medii, varianțe, probabilități de tranziție); câștigă cel mai mic BIC

A1: filtrul Kalman pentru trei perioade [Rezolvat]

Cerință

- ▣ Local level cu $\sigma_\varepsilon^2 = 1$, $\sigma_\eta^2 = 1$; a priori $a_1 = 0$, $P_1 = 1$; datele $y = (1, 3, 2)$.
- ▣ 1. Pentru $t = 1, 2, 3$ calculați F_t , K_t , v_t , $a_{t|t}$, $P_{t|t}$ și predicția următoare.
- ▣ 2. Dați prognoza lui y_4 și varianța ei.
- ▣ 3. Calculați câștigul de echilibru $\bar{K}$ pentru $q = 1$.
- ▣ Raportați: un tabel cu cei trei pași, o prognoză, $\bar{K}$.

Rezolvare

- ▣ 1. $t = 1$: $F = 2$, $K = 0,5$, $v = 1$, $a_{1|1} = 0,5$, $P_{1|1} = 0,5$; $a_2 = 0,5$, $P_2 = 1,5$
- ▣ $t = 2$: $F = 2,5$, $K = 0,6$, $v = 2,5$, $a_{2|2} = 0,5 + 0,6 \cdot 2,5 = 2$, $P_{2|2} = 0,6$; $a_3 = 2$, $P_3 = 1,6$
- ▣ $t = 3$: $F = 2,6$, $K = 0,615$, $v = 0$, $a_{3|3} = 2$, $P_{3|3} = 0,62$
- ▣ 2. $\hat{y}_4 = a_4 = 2,00$; $P_4 = 1,62$; $\text{Var} = P_4 + \sigma_\varepsilon^2 = 1,62 + 1 = 2,62$
- ▣ 3. $\bar{P} = (1 + \sqrt{5})/2 = 1,618$ (numărul de aur), $\bar{K} = 0,618$; K_t este deja 0,615 la $t = 3$

A2: o observație lipsă [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Local level cu $\sigma_\varepsilon^2 = 2$, $\sigma_\eta^2 = 0,5$; $a_1 = 5$, $P_1 = 2$; datele $y = (6, \text{lipsă}, 4)$. Model: A1.
- ▣ 1. Aplicați filtrul pentru $t = 1, 2, 3$, sărind peste actualizare la $t = 2$.
- ▣ 2. Explicați de ce K_3 este egal cu K_1 .
- ▣ Raportați: cei trei pași și o frază.

A3: netezirea exponențială este un filtru Kalman în echilibru [Rezolvat]

Cerință

- Un model local level și netezirea exponențială simplă (SES).
- 1. Arătați că actualizarea în echilibru $a_{t+1} = a_t + \bar{K}(y_t - a_t)$ este SES.
- 2. Calculați $\bar{K}$ pentru $q = 0,25$ ($q = 1$ este în A1).
- 3. Un model SES are $\alpha = 0,3$. Găsiți q al modelului local level din spatele lui.
- Raportați: un rînd de calcul, un câștig, un q .

Rezolvare

- 1. $a_{t+1} = \bar{K}y_t + (1 - \bar{K})a_t$: recurența SES cu $\alpha = \bar{K}$ și $\ell_t = a_{t+1}$
- 2. $q = 0,25$: $\bar{P}/\sigma_\varepsilon^2 = 0,640$, $\bar{K} = 0,390$
- 3. Din $\bar{P} = \bar{P}(1 - \bar{K}) + \sigma_\eta^2$: $\sigma_\eta^2 = \bar{K}\bar{P}$ și $\bar{P} = \alpha\sigma_\varepsilon^2/(1 - \alpha)$, deci $q = \alpha^2/(1 - \alpha) = 0,09/0,7 = 0,129$
- un α mic înseamnă un nivel care se mișcă puțin în raport cu zgomotul

A4: forme în spațiul stărilor și prognoze [Propus]

Rezolvarea se discută la seminar

Cerință

- Un AR(2) cu $\phi_1 = 0,5$, $\phi_2 = 0,3$, $\sigma^2 = 1$; un local linear trend. Model: A1 (pasul de predicție).
- 1. Scrieți Z , T , R , Q și H pentru AR(2).
- 2. Cu ultima stare $(y_T, y_{T-1}) = (2, 1)$, calculați prognozele pentru $h = 1, 2, 3$ prin $\hat{\alpha}_{T+h} = T\hat{\alpha}_{T+h-1}$.
- 3. Scrieți Z și T pentru local linear trend și prognozați trei pași de la $\mu_T = 100$, $\beta_T = 2$.
- Raportați: două seturi de matrice și șase prognoze.

A5: durata recesiunilor și a expansiunilor [Rezolvat]

Cerință

- Un model cu două regimuri pentru creșterea PIB: regimul 1 (recesiune) cu $p_{11} = 0,75$, regimul 2 (expansiune) cu $p_{22} = 0,95$.
- 1. Scrieți matricea de tranziție și calculați duratele așteptate.
- 2. Calculați probabilitățile ergodice.
- 3. Pornind dintr-o recesiune, calculați probabilitatea unei recesiuni după două trimestre.
- Raportați: două durate, două probabilități, o probabilitate în doi pași.

Rezolvare

- 1. $P = \begin{pmatrix} 0,75 & 0,25 \\ 0,05 & 0,95 \end{pmatrix}$; durate $1/0,25 = 4$ și $1/0,05 = 20$ de trimestre
- 2. $\pi_1 = 0,05/(0,25 + 0,05) = 0,167$, $\pi_2 = 0,833$: un trimestru din șase este de recesiune
- 3. $p_{11}^{(2)} = 0,75^2 + 0,25 \cdot 0,05 = 0,575$; șansa unei expansiuni este 0,425
- durata geometrică: multe recesiuni sînt scurte, cîteva sînt lungi; media este 4 trimestre

A6: un pas al filtrului Hamilton [Propus]

Rezolvarea se discută la seminar


Cerință

- ▣ Modelul din A5 cu $\mu_1 = -0,5$, $\mu_2 = 1$, $\sigma = 1$; trimestrul trecut $\Pr(S_{t-1} = 1 \mid Y_{t-1}) = 0,2$; acest trimestru $y_t = -1$. Model: A5.
- ▣ 1. Calculați probabilitatea prezisă $\Pr(S_t = 1 \mid Y_{t-1})$.
- ▣ 2. Calculați densitățile $f_1(y_t)$, $f_2(y_t)$ (distribuția Normală standard: $\varphi(0,5) = 0,352$, $\varphi(2) = 0,054$) și probabilitatea filtrată.
- ▣ 3. Dați contribuția la verosimilitate și probabilitatea prezisă pentru trimestrul următor.
- ▣ Raportați: patru probabilități și o log-densitate.

B1: inflația de fond din România [Rezolvat]

- ▣ **Întrebarea:** cât de repede se mișcă nivelul de fond al inflației din România și ce pondere de netezire exponențială aleg datele?
- ▣ **Date:** inflația lunară IAPC, ajustată sezonier, 2005–2026 ($T = 260$)
- ▣ **Cerințe**
 1. Estimați modelul local level prin verosimilitate maximă și raportați $\hat{\sigma}_\varepsilon^2$, $\hat{\sigma}_\eta^2$ și $\hat{q}$.
 2. Calculați câștigul de echilibru $\bar{K}$ și comparați-l cu ponderea SES estimată direct.
 3. Reprezentați grafic nivelul filtrat și netezit ($\times 12$, în % pe an) și raportați maximul și ultima valoare.
 4. Interpretare: ce spune mărimea lui $\hat{q}$ despre inflația lunară?
- ▣ **Raportați:** trei varianțe, două ponderi, două niveluri, o frază
- ▣ Notebook: secțiunea [B1](#)

B1: rezolvare [Rezolvat]



- $\hat{\sigma}_\varepsilon^2 = 0,142$, $\hat{\sigma}_\eta^2 = 0,0057$, $\hat{q} = 0,040$; $\bar{K} = 0,181$; SES prin cele mai mici pătrate: $\hat{\alpha} = 0,175$
- Nivelul netezit $\times 12$: maxim 12,3% (aprilie 2022), minim $-2,0\%$ (iunie 2015), ultima valoare 6,8% (august 2026, SE 1,9); seria brută $\times 12$ are SD 5,6
- Interpretare: q este mic: majoritatea mișcărilor lunare sînt zgomot (modificări de taxe, prețuri la alimente și energie); fiecare lună mută nivelul de fond cu aproximativ 0,181 din surpriză


B2: deviația PIB a SUA [Propus]

- ▣ **Întrebarea:** cât de aproape sînt trei deviații PIB statistice de deviația oficială a CBO și pe care ați folosi-o în timp real?
- ▣ **Date:** PIB-ul real al SUA și PIB-ul potențial al CBO, trimestrial, 1949–2026; model: [B1](#)
- ▣ **Cerințe**
 1. Calculați ciclul UC (trend neted plus AR(2)), deviația HP ($\lambda = 1600$) și filtrul Hamilton ($h = 8$, patru laguri) pentru $100 \log \text{PIB}$.
 2. Calculați deviația CBO $100(\text{PIB}/\text{GDPPOT} - 1)$ și corelația fiecărei măsuri cu ea, inclusiv a ciclului UC filtrat.
 3. Raportați abaterile standard și ultimele valori.
 4. Interpretare: ce măsură ați folosi pentru a judeca economia astăzi?
- ▣ **Raportați:** cinci corelații, patru abateri standard, patru valori recente, o frază
- ▣ **Notebook:** secțiunea [B2](#)

B3: recesiunile în producția industrială din SUA [Rezolvat]

- ▣ **Întrebarea:** regăsește un model cu două regimuri, estimat pe producția industrială, recesiunile NBER?
- ▣ **Date:** creșterea lunară a producției industriale din SUA, 1960–2019 (93 de luni de recesiune NBER)
- ▣ **Cerințe**
 1. Estimați un model cu două regimuri, cu medie și varianță variabile (MarkovRegression).
 2. Raportați mediile și abaterile standard ale regimurilor, p_{11} , p_{22} și duratele așteptate.
 3. Clasificați fiecare lună după probabilitatea netezită ($> 0,5$) și după cea filtrată și comparați cu lunile NBER.
 4. Interpretare: se potrivește regimul de recesiune cu recesiunile NBER?
- ▣ **Raportați:** șase parametri, două durate, două tabele de concordanță, o frază
- ▣ **Notebook:** secțiunea [B3](#)

B3: rezolvare [Rezolvat]



- ▣ Regimul de recesiune: media $-0,16\%$, SD 1,30; expansiunea: media $0,29\%$, SD 0,51; $\hat{\rho}_{11} = 0,874$, $\hat{\rho}_{22} = 0,970$; durate de 8,0 și 33,2 luni; ponderea ergodică 19%
- ▣ Netezit: 89% din luni coincid, 69% din lunile NBER găsite, 7% alarme false; filtrat: 86%, 57%, 10%
- ▣ Interpretare: da, pentru recesiunile profunde; regimul este „creștere scăzută și volatilă”, deci semnalează și unele încetiniri, iar în timp real găsește mai puține luni de recesiune

B4: regimurile de volatilitate ale BET [Propus]

- **Întrebarea:** are piața de la București regimuri calme și agitate și sînt ele aceleași cu cele ale S&P 500?
- **Date:** randamentele logaritmice săptămînale ale BET și S&P 500, 2000–2026; model: [B3](#)
- **Cerințe**
 1. Estimați un model cu două regimuri, cu medie și varianță variabile, pentru randamentele BET; raportați volatilitățile anualizate și duratele.
 2. Enumerați cei trei ani cu cea mai mare pondere de săptămîni agitate.
 3. Estimați un GARCH(1,1) ([Capitolul 5](#)) și corelați volatilitatea lui cu volatilitatea implicată de regimuri.
 4. Interpretare: sînt perioadele agitate ale BET aceleași cu cele ale S&P 500?
- **Raportați:** două volatilități, două durate, trei ani, două corelații, o frază
- **Notebook:** secțiunea [B4](#)

C1: regimurile inflației din România [Propus]

- **Întrebarea:** câte regimuri de inflație a avut România din 1996 și când a început regimul de inflație scăzută?
- **Date:** inflația lunară IAPC, neajustată sezonier, 1996–2026; țintirea inflației din august 2005; model: [B3](#)
- **Cerințe**
 1. Estimați modele cu două și trei regimuri (medie și varianță variabile) și comparați-le după BIC.
 2. Pentru trei regimuri, raportați mediile, duratele și data de la care regimul scăzut devine permanent.
 3. Propuneți încă o verificare (sezonalitatea, un regim cu termen AR, prognoze în afara eșantionului).
 4. Interpretare: a declanșat țintirea inflației regimul de inflație scăzută?
- **Raportați:** șase parametri, o dată, o verificare și un plan de proiect
- **Notebook:** secțiunea [C1](#)

C2: verificați un răspuns AI [Propus]

- Un student a întrebat un asistent AI despre modelele în spațiul stărilor și cu regimuri. Răspunsul:
- (a) Pentru Nil, $q = 0,097$, deci ponderea echivalentă de netezire exponențială este $\alpha = q = 0,097$.
- (b) Cîștigul Kalman este $K = \sigma^2_{\text{eps}} / (P + \sigma^2_{\text{eps}})$: cu cît datele sînt mai zgomotoase, cu atît primesc o pondere mai mare.
- (c) Cu $p_{11} = 0,75$, recesiunile durează în medie $p_{11} / (1 - p_{11}) = 3$ trimestre.
- (d) Pentru a anunța o recesiune în timp real, folosiți `smoothed_marginal_probabilities` din `statsmodels`.
- (e) Ultima valoare a deviației HP este o estimare de încredere a deviației PIB de azi.
- (f) În modelul local level prognozele pentru toate orizonturile sînt egale; doar varianța lor crește cu orizontul.
- **Cerințe**
 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă (Partea A, secțiunea C2 din notebook).
- **Raportați:** o listă de șase verdicte, fiecare cu un rînd de justificare

Idei de reținut

- ▣ Filtrul Kalman: $K_t = P_t / (P_t + \sigma_\varepsilon^2)$, $a_{t|t} = a_t + K_t v_t$; o valoare lipsă înseamnă fără actualizare
- ▣ Netezirea exponențială este un filtru local level în echilibru: $\alpha = \bar{K}$, $q = \alpha^2 / (1 - \alpha)$
- ▣ Inflația lunară din România: q mic, un nivel de fond care se mișcă lent
- ▣ Markov switching: durate $1/(1 - p_{ii})$; probabilitățile filtrate pentru timp real, cele netezite pentru istorie
- ▣ Un răspuns AI este o ciornă: verificați câștigul, formula duratei, filtrat față de netezit

După seminar

- Cursul 10 dezvoltă fiecare temă de azi
 - ▶ forma în spațiul stărilor, filtrul și netezitorul, verosimilitatea, trend și ciclu, modelele Markov switching
- Încercați cerințele [Propus] în notebook
- C1 poate deveni un proiect de echipă: regimurile inflației în România și în regiune
- Lectură: [Durbin și Koopman \(2012\)](#), cap. 2; [Hamilton \(1989\)](#); [Hamilton \(2018\)](#)

Bibliografie

- ▣ Durbin, J., & Koopman, S. J. (2012). *Time Series Analysis by State Space Methods* (2nd ed.). Oxford University Press. doi:10.1093/acprof:oso/9780199641178.001.0001
- ▣ Hamilton, J. D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2), 357–384. doi:10.2307/1912559
- ▣ Hamilton, J. D. (2018). Why you should never use the Hodrick–Prescott filter. *The Review of Economics and Statistics*, 100(5), 831–843. doi:10.1162/rest_a_00706
- ▣ Harvey, A. C. (1989). *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge University Press. doi:10.1017/CBO9781107049994
- ▣ Hodrick, R. J., & Prescott, E. C. (1997). Postwar U.S. business cycles: An empirical investigation. *Journal of Money, Credit and Banking*, 29(1), 1–16. doi:10.2307/2953682
- ▣ Kalman, R. E. (1960). A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, 82(1), 35–45. doi:10.1115/1.3662552
- ▣ Muth, J. F. (1960). Optimal properties of exponentially weighted forecasts. *Journal of the American Statistical Association*, 55(290), 299–306. doi:10.1080/01621459.1960.10482064
- ▣ Rauch, H. E., Tung, F., & Striebel, C. T. (1965). Maximum likelihood estimates of linear dynamic systems. *AIAA Journal*, 3(8), 1445–1450. doi:10.2514/3.3166