








Serii de timp

Seminarul 11: Foundation models pentru serii de timp



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Acronime folosite în acest material

- **AI**: Artificial Intelligence (inteligență artificială)
- **ARIMA**: AutoRegressive Integrated Moving Average (model) — model autoregresiv integrat cu medie mobilă
- **BNR**: Banca Națională a României
- **CPU**: Central Processing Unit (procesorul central)
- **CRPS**: Continuous Ranked Probability Score (scorul de probabilitate continuu pe ranguri)
- **DM**: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- **ENTSO-E**: European Network of Transmission System Operators for Electricity (rețeaua europeană a operatorilor de transport și de sistem pentru energie electrică)
- **ETS**: Error, Trend, Seasonality (exponential smoothing state space models) — eroare, trend, sezonalitate (modele de netezire exponențială)
- **FRED**: Federal Reserve Economic Data (baza de date economice a Rezervei Federale din St. Louis)
- **GPU**: Graphics Processing Unit (procesorul grafic)
- **IAPC**: Indicele armonizat al prețurilor de consum
- **MAE**: Mean Absolute Error (eroarea absolută medie)
- **MASE**: Mean Absolute Scaled Error (eroarea absolută medie scalată)
- **PIB**: Produsul intern brut
- **SUA**: Statele Unite ale Americii
- **WQL**: Weighted Quantile Loss (pierderea cuantilă ponderată)

Întrebarea de azi și structura seminarului

- Întrebarea seminarului
  - **este mai bună o prognoză făcută de un model care nu a văzut niciodată seria decît o prognoză de referință simplă și cum verificăm acest lucru?**
- Rezultate de obținut (seminarul are rol de exercițiu: nu se predă și nu se notează nimic)
  - scorurile din exercițiile A, calculate de mînă
  - cîte un tabel și o figură pentru fiecare exercițiu B
  - răspunsul AI corectat din C1
  - o frază de interpretare pentru fiecare exercițiu
- Notebook-ul de azi: deschideți notebook-ul seminarului în Google Colab
  - niciun model nu se rulează din nou: notebook-ul citește prognozele salvate ale cursului 11
- Exercițiile, tipurile și ordinea lor: harta exercițiilor (slide-ul următor)
- Seminar: prof. Daniel Traian Pele, danpele@ase.ro

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	pierderi pinball la o oră de consum; MASE (mean absolute scaled error, eroarea absolută medie scalată) pentru trei prognoze ale producției industriale	Rezolvat, Propus	A1
A3, A4	pierderea cuantilă ponderată (WQL, weighted quantile loss) pentru patru origini; este calibrat un interval de 80%?	Rezolvat, Propus	A3
B1, B2	modele zero-shot pentru inflația din România; eroarea pe orizonturi pentru vînzările cu amănuntul din SUA	Rezolvat, Propus	B1
B3	este Chronos-2 semnificativ mai bun? Teste Diebold–Mariano pe șapte serii	Rezolvat	B3
C1	ce este greșit într-un răspuns AI despre foundation models?	Propus	A1–B3

- Tipurile: **A** calcule pe hîrtie; **B** date reale, rezolvate în notebook; **C** critica unui răspuns AI
- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați dumneavoastră, după model; soluția se discută la seminar

Datele folosite

Seria	Sursa	Frecvența, orizontul	Originile prognozelor
consumul de energie electrică, România	ENTSO-E	orar, 48 de ore	2025–2026, săptămînal
producția industrială, România	Eurostat	lunar, 12 luni	2016–2025
PIB real, România	Eurostat	trimestrial, 4 trimestre	2012–2025
inflația IAPC, șomajul, România	Eurostat	lunar, 12 luni	2016–2025
EUR/RON	BNR	zilnic, 20 de zile	2016–2026
vînzările cu amănuntul, SUA	FRED (RSXFSN)	lunar, 12 luni	2016–2025

- Prognozele cursului 11, salvate o singură dată: prognoza sezonieră naivă, ETS, ARIMA și trei foundation models deschise (Chronos-Bolt tiny și small, Chronos-2), rulate zero-shot pe un CPU (central processing unit, procesorul central) Ansari et al. (2024)
- În notebook: `backtest_rows`, `abs_errors`, `pinball`, `summarise`, `dm_test`; nu este nevoie de cont, cheie sau GPU

Noțiuni necesare azi (1/5): prognoze zero-shot și cuantile

- **Foundation model**: o rețea pre-antrenată o singură dată pe multe serii; **zero-shot**: prognozează o serie nouă doar din valorile ei recente, fără antrenare pe acea serie
  - Chronos împarte contextul $x_1, \ldots, x_C$ la scala $s = \frac{1}{C}\sum_t |x_t|$, apoi atribuie lui x_t/s unul din 4093 de intervale (tokeni) Ansari et al. (2024)
- **Ieșirea**: pentru fiecare pas $j = 1, \ldots, h$, nouă cuantile $\hat{q}_\tau$, $\tau = 0{,}1; 0{,}2; \ldots; 0{,}9$
  - mediana $\hat{q}_{0{,}5}$ este prognoza punctuală; $[\hat{q}_{0{,}1}, \hat{q}_{0{,}9}]$ este intervalul central de 80%
  - modelele statistice de referință dau cuantile ale distribuției Normale: $\hat{q}_\tau = \hat{y} + z_\tau \hat{\sigma}$, cu $z_{0{,}9} = 1{,}2816$
- **Prognoza sezonieră naivă** cu perioada m: $\hat{y}_{T+j} = y_{T+j-m}$ (aceeași oră de săptămîna trecută, aceeași lună de anul trecut)

Noțiuni necesare azi (2/5): pierderea pinball și acoperirea

- **Pierderea pinball (cuantilă)** a unei prognoze cuantile q la nivelul τ, cînd se observă y

$$L_\tau(y, q) = \begin{cases} \tau\,(y - q), & y \geq q \\ (1 - \tau)\,(q - y), & y < q \end{cases}$$

  - pentru $\tau = 0{,}9$, o valoare peste cuantilă costă de 9 ori mai mult decît una sub ea: pierderea este minimă, în medie, la adevărata cuantilă de 90%
  - $L_{\mathbf{0{,}5}} = \frac{\mathbf{1}}{\mathbf{2}}|y - q|$: jumătate din eroarea absolută a medianei
- **Acoperirea** intervalului de 80%: ponderea valorilor y din $[\hat{q}_{\mathbf{0{,}1}}, \hat{q}_{\mathbf{0{,}9}}]$; un interval calibrat acoperă aproximativ 80%
  - sub 80%: prea îngust (prea încrezător); peste 80%: prea larg

Noțiuni necesare azi (3/5): pierderea cuantilă ponderată (WQL)

- **WQL** pentru o origine de prognoză: toate cele nouă niveluri și toți cei h pași, scalate cu mărimea seriei

$$\text{WQL} = \frac{\text{num}}{\text{den}} = \frac{\sum_{\tau} \sum_{j=\mathbf{1}}^{h} 2L_{\tau}(y_{T+j}, \hat{q}_{\tau,T+j})}{9 \sum_{j=\mathbf{1}}^{h} |y_{T+j}|}$$

  - o aproximare discretă a CRPS pentru întreaga distribuție de prognoză Gneiting și Raftery (2007); mai mic este mai bine
- **Pe mai multe origini**: raportul sumelor, $\sum_i \text{num}_i / \sum_i \text{den}_i$, nu media rapoartelor
  - originile cu valori mari ale seriei (consum mai mare iarna) cîntăresc mai mult
- **WQL relativ**: WQL al unui model împărțit la WQL al prognozei sezoniere naive, pe aceleași origini; sub 1: mai bun decît referința

Noțiuni necesare azi (4/5): MASE și scorurile relative

- **MASE** (mean absolute scaled error, eroarea absolută medie scalată) pentru o origine, cu mediana drept prognoză punctuală Hyndman și Koehler (2006)

$$\text{MASE} = \frac{\frac{1}{h}\sum_{j=1}^{h} |y_{T+j} - \hat{q}_{0.5,T+j}|}{s_m}, \qquad s_m = \frac{1}{T-m}\sum_{t=m+1}^{T} |y_t - y_{t-m}|$$

  - s_m: MAE (mean absolute error, eroarea absolută medie) în eșantion a prognozei sezoniere naive cu un pas înainte, doar pe context

- MASE < 1 înseamnă o comparație cu o referință în eșantion, cu un pas, nu cu prognoza sezonieră naivă din perioada de test
  - pentru o comparație corectă folosiți **MASE relativ**: MASE al modelului / MASE al prognozei sezoniere naive, pe aceleași origini

- **Mai multe serii**: media geometrică a scorurilor relative, $\exp\left(\frac{1}{K}\sum_k \ln r_k\right)$; un cîștig de 20% și o pierdere de 20% nu se anulează în media aritmetică

Noțiuni necesare azi (5/5): originile mobile și testul Diebold–Mariano

- **Origine mobilă**: la fiecare origine T_i fiecare model prognozează h pași din datele pînă la T_i; apoi originea se mută înainte (cu o lună, o săptămînă, 20 de zile)
  - scorul unei singure origini este zgomotos; testarea pe date istorice face media pe multe origini Hewamalage et al. (2023)
- **Testul Diebold–Mariano (DM)** Diebold și Mariano (1995): este zero media diferenței de pierderi?

$$d_i = L_i^A - L_i^B, \qquad \mathrm{DM} = \frac{\bar{d}}{\sqrt{\hat{\Omega}/n}} \approx N(0,1)$$

  - $\hat{\Omega} = \hat{\gamma}_{\mathbf{0}} + 2\sum_{k=\mathbf{1}}^{\ell}(1 - \frac{k}{\ell+\mathbf{1}})\hat{\gamma}_k$: varianța pe termen lung Newey–West; ferestrele de prognoză se suprapun cînd pasul dintre origini este mai mic decît h, deci $\ell = \lceil h/\mathrm{pas} \rceil - 1$
  - DM $< -1{,}96$: modelul A este semnificativ mai bun la 5%; $> 1{,}96$: semnificativ mai slab

A1: pierderi pinball la o singură oră [Rezolvat]

Cerință

- Consumul din România, originea 22 iunie 2026, ora 24 (23:00); valoarea observată $y = 5{,}803$ GW.
- Chronos-Bolt small: $\hat{q}_{0{,}1}$, $\hat{q}_{0{,}5}$, $\hat{q}_{0{,}9} = 5{,}184; 5{,}476; 5{,}776$.
- Prognoza sezonieră naivă: $4{,}591; 5{,}388; 6{,}185$ (mediana = aceeași oră cu o săptămînă înainte).
- 1. Calculați $L_{0{,}1}$, $L_{0{,}5}$, $L_{0{,}9}$ pentru ambele prognoze și sumele lor.
- 2. Este y în fiecare interval de 80%? Care prognoză are scorul mai bun?
- Raportați: șase pierderi, două sume, două verdicte.

Rezolvare

- 1. Bolt: y este peste toate cele trei cuantile, deci $L_\tau = \tau(y - q)$: $0{,}1 \cdot 0{,}620 = 0{,}062$; $0{,}5 \cdot 0{,}327 = 0{,}163$; $0{,}9 \cdot 0{,}027 = 0{,}025$; suma $0{,}250$
- Naivă: $0{,}1 \cdot 1{,}212 = 0{,}121$; $0{,}5 \cdot 0{,}415 = 0{,}208$; $y < \hat{q}_{0{,}9}$: $0{,}1 \cdot 0{,}382 = 0{,}038$; suma $0{,}367$
- 2. Bolt: $y > \hat{q}_{0{,}9}$, în afara intervalului (lățime 0,59 GW); naivă: în interval (lățime 1,59 GW)
- Bolt are totuși pierderea mai mică: un interval îngust care ratează puțin este mai bun decît unul larg; o singură oră nu dovedește nimic, deci facem media pe multe ore (A3)

◂ Înapoi ▸ Lista exercițiilor

A2: MASE pentru trei prognoze [Propus]

Rezolvarea se discută la seminar

Cerință

- Producția industrială a României, originea august 2025, $h = 12$ luni. Erorile absolute $|y_{T+j} - \hat{q}_{\mathbf{0.5},T+j}|$ (puncte de indice). Model: A1.

j	1	2	3	4	5	6	7	8	9	10	11	12
Chronos-2	3,96	0,56	0,49	3,49	0,23	7,23	4,16	3,17	5,10	4,93	3,88	4,19
Sez. naivă	2,70	2,50	0,40	2,80	1,30	3,00	1,70	0,70	2,60	7,40	3,30	6,40

- 1. Calculați MAE pentru Chronos-2 și pentru prognoza sezonieră naivă.
- 2. Contextul (307 luni) dă $s_{\mathbf{12}} = 4{,}354$. Calculați cele două valori MASE și MASE relativ al lui Chronos-2; ETS are MASE 1,204.
- 3. Pe toate cele 116 origini, media MASE este 1,017 pentru Chronos-2 și 1,252 pentru prognoza sezonieră naivă. Ce spune o singură origine?
- Raportați: două MAE, trei MASE, două rapoarte, o frază.

TSA_ch11_seminar

Înapoi Lista exercițiilor

A3: pierderea cuantilă ponderată pentru patru origini [Rezolvat]

Cerință

- Consumul din România, ultimele patru origini săptămînale din 2026 (zi.lună); numărătorul și numitorul WQL (48 de ore, 9 niveluri); C2 = Chronos-2, N = prognoza sezonieră naivă:

Origine	num C2	num N	den	WQL C2	WQL N
08.06	52,4	198,9	2264	0,0232	0,0878
15.06	52,5	86,7	2233	0,0235	0,0388
22.06	142,0	219,6	2526	0,0562	0,0869
29.06	130,8	197,1	2798	0,0468	0,0705

- 1. Calculați WQL pentru fiecare origine (ultimele două coloane).
- 2. Calculați WQL pentru cele patru origini ca raport al sumelor și media celor patru rapoarte.
- 3. Calculați WQL relativ al lui Chronos-2 (C2).

Rezolvare

- 1. De exemplu, 377,7 este suma numărătorilor C2; fiecare WQL este num/den (tabelul)
- 2. C2: 377,7/9821 = 0,0385; media rapoartelor 0,0374. Naivă: 702,3/9821 = 0,0715; media 0,0710
- 3. WQL relativ = 0,0385/0,0715 = 0,538 (cu mediile rapoartelor: 0,527)
- cele două variante diferă cînd numitorii diferă: raportul sumelor dă o pondere mai mare săptămînilor cu consum mare

TSA_ch11_seminar

Înapoi Lista exercițiilor

A4: este calibrat un interval de 80%? [Propus]

Rezolvarea se discută la seminar

Cerință

- Consumul din România, 52 de origini săptămînale $\times$ 48 de ore $= 2496$ de valori orare. Chronos-2: 1830 în intervalul de 80%; ETS: 2432. Model: A3.
- 1. Calculați cele două acoperiri și statistica binomială $z = (\hat{c} - 0{,}8)/\sqrt{0{,}8 \cdot 0{,}2/n}$, ca și cum toate orele ar fi independente.
- 2. Acoperirea fiecărei origini are abaterea standard 0,197 pentru Chronos-2 (0,050 pentru ETS) pe cele 52 de origini. Calculați $t = (\hat{c} - 0{,}8)/(\mathrm{SD}/\sqrt{52})$.
- 3. De ce este $|t|$ mult mai mic decît $|z|$? Este fiecare interval prea îngust sau prea larg?
- Raportați: două acoperiri, patru statistici, două verdicte.

Înapoi Lista exercițiilor

B1: prognoze zero-shot pentru inflația din România [Rezolvat]

- **Întrebarea**: sînt foundation models mai bune decît modelele statistice de referință pentru inflația lunară din România și a schimbat creșterea inflației din 2021–2023 clasamentul?
- **Date**: inflația lunară IAPC, 12 luni înainte, 117 origini, din ianuarie 2016 pînă în septembrie 2025 (rezultatele salvate)
- **Cerințe**
  1. Din rîndurile salvate, calculați pentru fiecare model media MASE, WQL (raportul sumelor), acoperirea și rapoartele față de prognoza sezonieră naivă.
  2. Repetați WQL relativ pentru originile dinainte și de după ianuarie 2021.
  3. Reprezentați grafic WQL relativ pe ferestre mobile de 24 de origini.
  4. Interpretare: este stabil în timp cîștigul foundation models?
- **Raportați**: un tabel cu șase modele, opt rapoarte, o figură, o frază
- Notebook: secțiunea B1

◂ Înapoi ▸ Lista exercițiilor

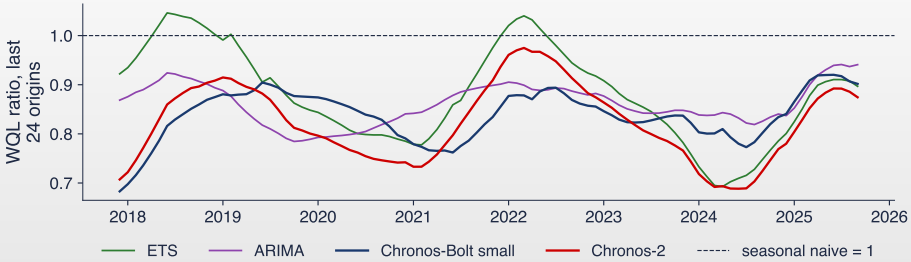
B1: rezolvare [Rezolvat]

Modelul	MASE	raport MASE	WQL	raport WQL	acoperire 80%
sezonieră naivă	**0,873**	**1,000**	**0,667**	**1,000**	**0,900**
ETS	**0,808**	**0,926**	**0,589**	**0,883**	**0,836**
ARIMA	**0,780**	**0,893**	**0,581**	**0,870**	**0,873**
Chronos-Bolt tiny	**0,720**	**0,825**	**0,537**	**0,806**	**0,858**
Chronos-Bolt small	**0,744**	**0,852**	**0,549**	**0,824**	**0,846**
Chronos-2	**0,726**	**0,831**	**0,542**	**0,812**	**0,800**

- Raportul WQL înainte / după ianuarie 2021 (60 și 57 de origini): Chronos-2 0,761 / 0,851, Bolt small 0,772 / 0,862, ETS 0,884 / 0,882, ARIMA 0,851 / 0,885
- Interpretare: toate modelele sînt mai bune decît prognoza sezonieră naivă, iar foundation models sînt în medie înaintea celorlalte; cîștigul scade după 2021 (fereastra care se încheie în martie 2022: 0,975), iar clasamentul se schimbă în timp

TSA_ch11_seminar

B1: WQL relativ în timp [Rezolvat]



- **Chronos-2 este cel mai bun dintre cele patru modele în 46% din ferestre; raportul lui variază între 0,688 (fereastra care se încheie în iunie 2024) și 0,975 (martie 2022)**
- **În 2022 șocul inflației a fost nou pentru toate modelele: ETS a pierdut în fața prognozei sezoniere naive, iar foundation models și-au pierdut cea mai mare parte din avans**

TSA_ch11_seminar

B2: eroarea pe orizonturi pentru vînzările cu amănuntul din SUA [Propus]

- **Întrebarea**: la ce orizonturi ajută cel mai mult un model zero-shot și contează mărimea modelului?
- **Date**: vînzările cu amănuntul din SUA (FRED RSXFSN, miliarde USD), 12 luni înainte, 117 origini, 2016–2025; model: B1
- **Cerințe**
  1. Din erorile absolute salvate, calculați MAE pentru fiecare model și fiecare pas $j = 1, \ldots, 12$.
  2. Împărțiți la MAE al prognozei sezoniere naive la același pas și reprezentați grafic rapoartele.
  3. Comparați cele trei foundation models (tiny, small, Chronos-2) cu ETS și ARIMA la $j = 1$ și $j = 12$.
  4. Interpretare: de ce cresc toate rapoartele spre 1 la orizonturi lungi?
- **Raportați**: zece rapoarte, o figură, o frază
- Notebook: secțiunea B2

Înapoi Lista exercițiilor

B3: este Chronos-2 semnificativ mai bun? [Rezolvat]

- **Întrebarea**: pe care dintre cele șapte serii este cîștigul lui Chronos-2 mai mare decît zgomotul testării pe date istorice?
- **Date**: WQL al fiecărei origini (num/den) pentru Chronos-2, ARIMA și prognoza sezonieră naivă, șapte serii
- **Cerințe**
  1. Pentru fiecare serie calculați $d_i = \mathrm{WQL}_i^{\mathbf{C2}} - \mathrm{WQL}_i^{\mathbf{rival}}$ pentru cei doi rivali.
  2. Calculați statistica DM cu varianța Newey–West și $\ell = \lceil h/\mathrm{pas} \rceil - 1$ laguri.
  3. Numărați seriile pe care Chronos-2 este semnificativ mai bun sau mai slab la 5%.
  4. Interpretare: înseamnă un WQL mediu mai bun întotdeauna un cîștig semnificativ?
- **Raportați**: paisprezece statistici DM, două numărători, o frază
- Notebook: secțiunea B3

◂ Înapoi ▸ Lista exercițiilor

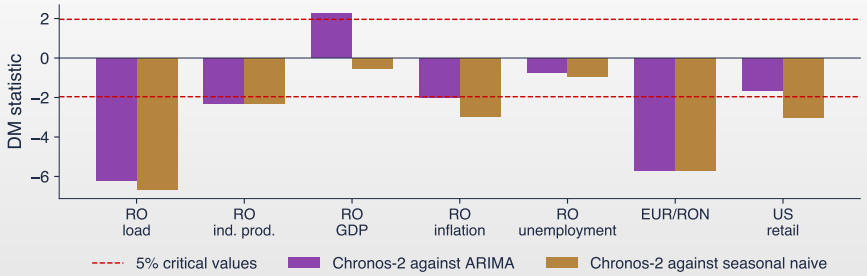
B3: rezolvare [Rezolvat]

Seria	ℓ	DM față de ARIMA	p	DM față de naivă	p
consumul de energie electrică (RO)	0	−6,20	<0,001	−6,67	<0,001
producția industrială (RO)	11	−2,32	0,020	−2,30	0,022
PIB real (RO)	3	2,25	0,025	−0,54	0,586
inflația (RO)	11	−2,00	0,045	−2,97	0,003
șomajul (RO)	11	−0,72	0,472	−0,95	0,344
EUR/RON	0	−5,71	<0,001	−5,72	<0,001
vînzările cu amănuntul (SUA)	11	−1,65	0,099	−3,01	0,003

- Semnificativ mai bun decît ARIMA pe 4 serii, mai slab pe 1 (PIB-ul RO, DM $= 2{,}25$); mai bun decît prognoza sezonieră naivă pe 5 serii, mai slab pe niciuna
- Interpretare: nu; la șomaj media WQL este mai mică, dar DM $= -0{,}72$; ferestrele de 12 luni care se suprapun lasă puține comparații independente

TSA_ch11_seminar

B3: statisticile DM într-un grafic [Rezolvat]



- Bare sub $-1{,}96$: Chronos-2 semnificativ mai bun; peste 1,96: semnificativ mai slab; consumul de energie dă cea mai puternică dovadă ($\text{DM} = -6{,}20$ față de ARIMA)
- Pentru PIB-ul trimestrial cîștigă un ARIMA bine specificat: Chronos-2 este mai bun doar la 36% din origini

TSA_ch11_seminar

C1: verificați un răspuns AI [Propus]

- **Un student a cerut unui asistent AI să rezume testarea pe date istorice din cursul 11. Răspunsul:**
- `(a) Chronos-2 bate toate modelele de referință pe toate cele șapte serii, deci ARIMA este depășit.`
- `(b) WQL pe mai multe origini este media WQL ale fiecărei origini.`
- `(c) Un interval de 80% care acoperă 73% din ore este bine calibrat: 73 este aproape de 80.`
- `(d) MASE sub 1 înseamnă că modelul bate prognoza sezonieră naivă în perioada de test.`
- `(e) Zero-shot înseamnă că modelul nu a văzut niciodată aceste serii, deci testarea nu poate fi contaminată.`
- `(f) Scalarea cu media permite unui singur model să prognozeze EUR/RON (aproximativ 5) și un indice (aproximativ 100) cu aceiași tokeni.`
- **Cerințe**
  1. **Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă (A1–B3, secțiunea C1 din notebook).**
- **Raportați: o listă de șase verdicte, fiecare cu un rînd de justificare**

Înapoi Lista exercițiilor

Idei de reținut

- Pierderea pinball: $\tau(y-q)$ peste cuantilă, $(1-\tau)(q-y)$ sub ea; WQL = raportul sumelor pe niveluri, pași și origini
- MASE este scalat cu o eroare din eșantion: comparați modelele cu MASE relativ, pe aceleași origini
- Testele de acoperire trebuie să țină seama de dependența orelor aceleiași origini
- Chronos-2 este cel mai bun model în medie, dar nu pe fiecare serie și nu întotdeauna semnificativ
- Un rezumat AI al unui benchmark este o ciornă: verificați agregarea, referința și testul

După seminar

- Cursul 11 dă detaliile
  - tokenii și fragmentele (patches), arhitectura Chronos, testarea completă, lungimea contextului, contaminarea
- Încercați cerințele [Propus] în notebook
- Idee de proiect: adăugați o serie nouă din România și repetați B1 și B3 cu funcțiile din notebook
- Lectură: Ansari et al. (2024); Gneiting și Raftery (2007); Hyndman și Koehler (2006); Diebold și Mariano (1995)
- **Seminarul are rol de exerciții și nu se notează; rezolvările cerințelor [Propus] se discută la seminar**

Bibliografie

- Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., et al. (2024). Chronos: Learning the language of time series. *Transactions on Machine Learning Research*. arXiv:2403.07815
- Ansari, A. F., Shchur, O., Küken, J., Auer, A., et al. (2025). Chronos-2: From univariate to universal forecasting. arXiv:2510.15821
- Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:10.1080/07350015.1995.10524599
- Gneiting, T., & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378. doi:10.1198/016214506000001437
- Hewamalage, H., Ackermann, K., & Bergmeir, C. (2023). Forecast evaluation for data scientists: Common pitfalls and best practices. *Data Mining and Knowledge Discovery*, 37(2), 788–832. doi:10.1007/s10618-022-00894-5
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. otexts.com/fpp3
- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. doi:10.1016/j.ijforecast.2006.03.001