



Serii de timp

Seminarul 15: Recapitulare și pregătire pentru examen



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **ACF**: Autocorrelation Function (funcția de autocorelație)
- ▣ **ADF**: Augmented Dickey–Fuller (test) — testul Dickey–Fuller augmentat
- ▣ **AI**: Artificial Intelligence (inteligență artificială)
- ▣ **AIC**: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ **AR**: AutoRegressive (model) — model autoregresiv
- ▣ **ARCH**: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ **ARCH-LM**: ARCH Lagrange Multiplier (test) — testul multiplicatorului Lagrange pentru efecte ARCH
- ▣ **ARFIMA**: AutoRegressive Fractionally Integrated Moving Average (model) — model autoregresiv fracționar integrat cu medie mobilă
- ▣ **ARIMA**: AutoRegressive Integrated Moving Average (model) — model autoregresiv integrat cu medie mobilă
- ▣ **ARMA**: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă
- ▣ **BET**: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BIC**: Bayesian Information Criterion (criteriul informațional bayesian al lui Schwarz)
- ▣ **DM**: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ **ECM**: Error Correction Model (model cu corecția erorii)
- ▣ **EODHD**: EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ **HLN**: Harvey–Leybourne–Newbold (small-sample correction of the DM test) — corecția Harvey–Leybourne–Newbold a testului DM pentru eșantioane mici
- ▣ **IAPC**: Indicele armonizat al prețurilor de consum

Acronime folosite în acest material (2/2)

- ▣ **KPSS**: Kwiatkowski–Phillips–Schmidt–Shin (test) — testul de staționaritate Kwiatkowski–Phillips–Schmidt–Shin
- ▣ **LB**: Ljung–Box (test) — testul de autocorelație Ljung–Box
- ▣ **LM**: Lagrange Multiplier (multiplicatorul Lagrange)
- ▣ **MA**: Moving Average (medie mobilă)
- ▣ **MAE**: Mean Absolute Error (eroarea absolută medie)
- ▣ **MASE**: Mean Absolute Scaled Error (eroarea absolută medie scalată)
- ▣ **OLS**: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **PACF**: Partial AutoCorrelation Function (funcția de autocorelație parțială)
- ▣ **PIB**: Produsul intern brut
- ▣ **RMSE**: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ **ROBOR**: Romanian Interbank Offer Rate (rata dobânzii la care băncile din România oferă depozite interbancare)
- ▣ **RSS**: Residual Sum of Squares (suma pătratelor reziduurilor)
- ▣ **SAR**: Seasonal AutoRegressive term (EViews) — termen autoregresiv sezonier (EViews)
- ▣ **SARIMA**: Seasonal ARIMA (model) — model ARIMA sezonier
- ▣ **SE**: Standard Error (eroare standard)
- ▣ **SES**: Simple Exponential Smoothing (netezire exponențială simplă)
- ▣ **SIGMASQ**: SIGMA SQuared, the innovation variance (EViews) — varianța inovațiilor (EViews)
- ▣ **TVA**: Taxa pe valoarea adăugată
- ▣ **VAR**: Vector AutoRegression (model vector autoregresiv)
- ▣ **VECM**: Vector Error Correction Model (model vectorial cu corecția erorii)

Întrebarea de azi și structura seminarului (1/3)

- ▣ Întrebarea seminarului
 - ▶ **puteți rezolva, pe hîrtie și pe date, o problemă de examen din orice capitol de bază?**
- ▣ Trei tipuri de exerciții
 - ▶ **A:** exerciții de calcul, pe hîrtie
 - ▶ **B:** exerciții pe date reale, rezolvate în notebook
 - ▶ **C:** întrebări deschise, de exemplu corectarea unui răspuns dat de un instrument AI
- ▣ Fiecare exercițiu este marcat
 - ▶ **[Rezolvat]:** rezolvarea completă este prezentată la seminar
 - ▶ **[Propus]:** îl rezolvați dumneavoastră; soluția se discută la seminar

Întrebarea de azi și structura seminarului (2/3)

- ▣ Exercițiile de azi, în ordine
 - ▶ A1: un ARIMA(0,1,1) calculat de mînă
 - ▶ A2: identificarea ratei șomajului din România
 - ▶ A3: rezultate SARIMA pentru PIB-ul României
 - ▶ A4: rezultate VAR și cauzalitate Granger
 - ▶ A5: rezultate GARCH pentru DAX și VaR 1%
 - ▶ B1: Box–Jenkins pentru producția industrială a României
 - ▶ B2: volatilitatea BET din 2015
 - ▶ B3: randamentele la 10 ani ale României și Germaniei
 - ▶ C1: o competiție de prognoză pentru inflația din România
 - ▶ C2: verificarea unui răspuns AI

Întrebarea de azi și structura seminarului (3/3)

- ▣ Rezultate de obținut (nu se predă nimic)
 - ▶ răspunsurile la exercițiile A
 - ▶ câte o figură și un tabel pentru fiecare exercițiu B
 - ▶ răspunsul A1 corectat din C2
 - ▶ o frază de interpretare pentru fiecare exercițiu
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#)
 - ▶ fiecare cerință indică secțiunea din notebook
- ▣ Seminar: prof. Daniel Traian Pele, danpele@ase.ro
- ▣ **Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar**

Harta exercițiilor

Cerința	Tema	Tipul	Capitole
A1	un ARIMA(0,1,1) calculat de mână: momente, ACF, prognoze, netezire exponențială	Rezolvat	0, 1, 3
A2	identificarea ratei șomajului din România: ADF, KPSS, corelogramă, Ljung–Box	Propus	1–3
A3	rezultate SARIMA pentru PIB-ul României și o prognoză de mână	Propus	4
A4	rezultate VAR, testul Granger F din două RSS, un efect pe termen lung	Propus	6
A5	rezultate GARCH(1,1)- t pentru DAX și VaR 1%	Propus	5
B1	Box–Jenkins pentru producția industrială a României	Rezolvat	3, 4
B2	volatilitatea BET din 2015	Propus	5
B3	randamentele la 10 ani ale României și Germaniei: cointegrare	Propus	3, 7
C1, C2	o competiție de prognoză pentru inflație; verificarea unui răspuns AI	Propus	0–10

□ [Rezolvat]

- rezolvarea completă în slide-uri și în notebook, un model de urmat

□ [Propus]

- îl rezolvați dumneavoastră, după model

Datele folosite

Seria	Sursa	Frecvența	Perioada
rata șomajului, România (ajustată sezonier)	Eurostat (une_rt_m)	lunar	2005–2026
PIB real, România (neajustat)	Eurostat (namq_10_gdp)	trimestrial	2000–2026
inflația IAPC și ROBOR 3M, România	Eurostat	lunar	2005–2026
producția industrială, România (ajustată calendaristic)	Eurostat (sts_inpr_m)	lunar	2005–2026
DAX, BET	EODHD	zilnic	2000–2026
randamente la 10 ani, România și Germania	EODHD	medii lunare ale datelor zilnice	2008–2026

- Partea A are nevoie doar de un calculator: tabelele cu rezultate sînt pe slide-uri; Partea B folosește notebook-ul
- Ratele de creștere în %: $100\Delta \ln y_t$; ratele anuale: $100\Delta_{12} \ln y_t$ (lunar), $100\Delta_4 \ln y_t$ (trimestrial); randamentele: $100\Delta \ln P_t$

Noțiuni necesare azi (1/22): descriere, staționaritate, ARMA

Mărimea	Formula
SES, MASE	$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}$; MASE = MAE / MAE (naiv sezonier, în eșantion)
ACF, banda	$\hat{\rho}(h) = \hat{\gamma}(h)/\hat{\gamma}(0)$, $\pm 1,96/\sqrt{T}$
Ljung-Box	$Q^*(m) = T(T+2) \sum_{h=1}^m \hat{\rho}(h)^2 / (T-h) \sim \chi^2(m-k)$, $k = \text{parametri ARMA}$
AR(1), MA(1)	$\rho(h) = \phi^h$; $\rho(1) = \theta/(1+\theta^2)$, $\rho(h) = 0$ pentru $h \geq 2$
Identificarea	ACF se anulează: MA; PACF se anulează: AR; ambele descresc: ARMA
Criterii	AIC = $-2 \ln L + 2k$, BIC = $-2 \ln L + k \ln T$; câștigă valoarea cea mai mică
Intervalul de prognoză	$\hat{y}_{T+h} \pm 1,96 \sigma \sqrt{\sum_{j=h}^{\infty} \psi_j^2}$

Noțiuni necesare azi (2/22): notațiile fișei precedente

▣ Netezirea și precizia

- ▶ ℓ_t : nivelul netezit; $\alpha \in (0, 1)$: ponderea celei mai noi observații y_t
- ▶ MAE: eroarea absolută medie; MASE sub 1: mai bun decât metoda naivă sezonieră în eșantion

▣ Corelograma și testul Ljung–Box

- ▶ $\hat{\gamma}(h)$: autocovarianța de selecție la lagul h ; $\hat{\rho}(h)$: autocorelația de selecție; T : volumul eșantionului
- ▶ $Q^*(m)$: suma ponderată a pătratelor primelor m autocorelații; k : numărul de parametri ARMA estimați
- ▶ un Q^* peste valoarea critică $\chi^2(m - k)$ (un p-value mic) respinge zgomotul alb

▣ Modele și criterii

- ▶ ϕ : coeficientul AR(1); θ : coeficientul MA(1); $\ln L$: logaritmul verosimilității maxime
- ▶ ψ_j : ponderile formei MA(∞) a modelului ($\psi_0 = 1$); σ : abaterea standard a șocurilor; h : orizontul

Noțiuni necesare azi (3/22): PACF și identificarea modelului

- **PACF** la lagul h : ultimul coeficient ϕ_{hh} al unei regresii $AR(h)$

$$y_t = \phi_{h1}y_{t-1} + \cdots + \phi_{hh}y_{t-h} + e_t$$

- ▶ corelația dintre y_t și y_{t-h} după eliminarea efectului lagurilor intermediare
- ▶ un $AR(p)$ are $\phi_{hh} = 0$ pentru $h > p$: PACF se anulează după lagul p

- **Ljung–Box** $Q^*(m)$: sînt primele m autocorelații simultan nule?


- ▶ H_0 : zgomot alb; pe reziduurile unui ARMA cu k parametri estimați, comparăm cu $\chi^2(m-k)$
- ▶ p-value = $\Pr(\chi^2(m-k) > Q^*)$; un p-value sub 0,05: reziduurile mai conțin autocorelație, schimbăm modelul

- **Criteriile informaționale**: L : verosimilitatea maximizată; k : numărul de parametri; T : volumul eșantionului

$$AICc = AIC + \frac{2k(k+1)}{T-k-1}$$

- ▶ AICc: AIC corectat pentru eșantioane mici; BIC penalizează fiecare parametru în plus cu $\ln T$ în loc de 2

Noțiuni necesare azi (4/22): ACF și PACF într-un grafic



- AR(1): ACF ϕ^h descrește, PACF se anulează după lagul 1; MA(1): ACF se anulează după lagul 1, PACF descrește cu semne alternante
- MA(1) aici: $\rho(1) = 0,6/(1 + 0,36) = 0,441$; pe date, comparăm fiecare bară cu banda $\pm 1,96/\sqrt{T}$


Noțiuni necesare azi (5/22): intervale de prognoză și ponderile ψ

- Orice model ARMA sau ARIMA este o sumă de șocuri trecute, $y_t = \sum_{j \geq 0} \psi_j \varepsilon_{t-j}$; **eroarea de prognoză** la orizontul h are varianța

$$\text{Var}(y_{T+h} - \hat{y}_{T+h}) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$$

- ▶ necunoscute sînt doar șocurile de după originea T : $\varepsilon_{T+1}, \dots, \varepsilon_{T+h}$
- **AR(1)**: $\psi_j = \phi^j$
 - ▶ suma converge la $1/(1 - \phi^2)$: intervalul rămîne mărginit, prognoza revine la medie
- **ARIMA(0,1,1)**: $\psi_0 = 1$, $\psi_j = 1 + \theta$ pentru $j \geq 1$
 - ▶ suma $1 + (h-1)(1 + \theta)^2$ crește liniar cu h : intervalul se lărgeste continuu (o rădăcină unitară)
 - ▶ partea MA este inversabilă dacă $|\theta| < 1$: rădăcina $-1/\theta$ a lui $1 + \theta z$ este în afara cercului unitate

Noțiuni necesare azi (6/22): intervalele de prognoză într-un grafic



- Stînga: ARIMA(0,1,1) cu $\theta = -0,6$, $\sigma = 1$: prognoză constantă, semilățimea $1,96\sqrt{1 + 0,16(h - 1)}$, fără limită
- Dreapta: AR(1) cu $\phi = 0,6$: prognoza revine la μ , semilățimea tinde la $1,96/\sqrt{1 - 0,36} = 2,45$

Noțiuni necesare azi (7/22): rădăcini unitare, ARIMA, SARIMA, evaluare

Mărimea	Formula
ADF	$\Delta y_t = c + bt + \gamma y_{t-1} + \sum_j \delta_j \Delta y_{t-j} + \varepsilon_t$; $H_0: \gamma = 0$ (rădăcină unitară)
ADF, valori critice la 5%	circa $-2,87$ (constantă), $-3,43$ (constantă și trend); respingem dacă τ este mai mic
KPSS	H_0 : staționaritate; valori critice la 5%: $0,463$ (constantă), $0,146$ (trend); respingem dacă este mai mare
ARIMA(0,1,1)	$\Delta y_t = \varepsilon_t + \theta \varepsilon_{t-1}$; $\hat{y}_{T+h} = y_T + \theta \varepsilon_T$, $\alpha_{SES} = 1 + \theta$
Varianța erorii	$\sigma^2[1 + (h-1)(1+\theta)^2]$
AR(1)×SAR(1) _s	$z_t = \phi z_{t-1} + \Phi z_{t-s} - \phi \Phi z_{t-s-1} + \varepsilon_t$
Rata anuală din z	$z_t = \Delta \Delta_s \ln y_t$; $\Delta_s \ln y_{T+1} = \Delta_s \ln y_T + \hat{z}_{T+1}$
Diebold–Mariano	$d_t = e_{1t}^2 - e_{2t}^2$, $DM = \bar{d}/(s_d/\sqrt{n})$; respingem acuratețea egală dacă $ DM > t_{0,975}(n-1)$

Noțiuni necesare azi (8/22): notațiile fișei precedente

▣ ADF și KPSS

- ▶ $\Delta y_t = y_t - y_{t-1}$; c : constanta; bt : trendul determinist; δ_j : coeficienții diferențelor cu lag
- ▶ $\gamma = 0$: rădăcină unitară; τ : statistica t a lui $\hat{\gamma}$, comparată cu valorile critice Dickey–Fuller, nu Student

▣ ARIMA și SARIMA

- ▶ ε_T : ultimul șoc; α_{SES} : ponderea netezirii exponențiale echivalente
- ▶ s : lungimea sezonului; Φ : coeficientul AR sezonier; $\Delta_s y_t = y_t - y_{t-s}$; z_t : seria diferențiată de două ori

▣ Diebold–Mariano

- ▶ e_{1t}, e_{2t} : erorile celor două prognoze; d_t : diferența pătratelor lor; $\bar{d}, s_d$: media și abaterea ei standard; n : numărul de prognoze
- ▶ $t_{0,975}(n-1)$: cuantila de 97,5% a distribuției Student cu $n-1$ grade de libertate

Noțiuni necesare azi (9/22): rădăcini unitare: ADF și KPSS

- ▣ **ADF Dickey și Fuller (1979):** scădem y_{t-1} dintr-un AR(1) $y_t = \phi y_{t-1} + \varepsilon_t$

$$\Delta y_t = \gamma y_{t-1} + \varepsilon_t, \quad \gamma = \phi - 1$$

- ▶ $\gamma = 0$ ($\phi = 1$): mers aleator, șocurile sînt permanente; $\gamma < 0$: staționar, șocurile se sting
- ▶ diferențele cu lag Δy_{t-j} din fișă preiau autocorelația rămasă; respingem $H_0: \gamma = 0$ dacă τ este sub valoarea critică



- ▣ **KPSS Kwiatkowski et al. (1992):** ipoteza nulă opusă, H_0 : staționaritate

$$KPSS = \frac{1}{T^2 \hat{\sigma}_{LR}^2} \sum_{t=1}^T S_t^2, \quad S_t = \sum_{s=1}^t \hat{e}_s$$

- ▶ $\hat{e}_s$: reziduurile lui y față de o constantă (sau un trend); S_t : sumele lor parțiale; $\hat{\sigma}_{LR}^2$: varianța pe termen lung a lui $\hat{e}$
- ▶ o rădăcină unitară face ca S_t să se îndepărteze mult de 0: KPSS mare, respingem staționaritatea

- ▣ Împreună: ADF nu respinge și KPSS respinge: $I(1)$; ADF respinge și KPSS nu respinge: $I(0)$; altfel dovezile sînt mixte

Noțiuni necesare azi (10/22): o rădăcină unitară într-un grafic



— Random walk: $y_t = y_{t-1} + \varepsilon_t$ ($\gamma = 0$)

— AR(1): $y_t = 0.8y_{t-1} + \varepsilon_t$ ($\gamma = -0.2$)

±1.96/√T

- Stînga: aceleași șocuri; mersul aleator se deplasează fără o medie fixă, AR(1) cu $\phi = 0,8$ revine mereu la 0
- Dreapta: ACF de selecție a mersului aleator rămîne mare 30 de laguri; $I(1)$: integrat de ordinul 1, staționar după o diferență


Noțiuni necesare azi (11/22): ARIMA sezonier și modelul airline

- **Diferența sezonieră** $\Delta_s y_t = (1 - L^s)y_t = y_t - y_{t-s}$; $s = 12$ (lunar), $s = 4$ (trimestrial)
 - ▶ $z_t = \Delta \Delta_s y_t$ elimină tendința și un tipar sezonier care se schimbă lent
- **SARIMA**(p, d, q)(P, D, Q) $_s$ [Box, Jenkins și Reinsel \(2008\)](#): polinoame AR și MA în L și în L^s
 - ▶ **modelul airline** $(0, 1, 1)(0, 1, 1)_{12}$:

$$(1 - L)(1 - L^{12})y_t = (1 + \theta L)(1 + \Theta L^{12})\varepsilon_t$$

- ▶ θ : coeficientul MA la lagul 1; Θ : coeficientul MA sezonier la lagul 12; z_t are vîrfuri ale ACF doar la lagurile 1, 11, 12 și 13
- **Acuratețea în afara eșantionului** pe N luni de test
 - ▶ $\text{RMSE} = \sqrt{\frac{1}{N} \sum_i e_i^2}$, $\text{MAE} = \frac{1}{N} \sum_i |e_i|$; prognoza naivă sezonieră $\hat{y}_{T+h} = y_{T+h-12}$ este reperul

Noțiuni necesare azi (12/22): diferențierea sezonieră într-un grafic



- Stînga: o serie lunară simulată, cu tendință și tipar sezonier
- Dreapta: ACF a lui $z_t = \Delta\Delta_{12}y_t$ pentru un model airline: vîrfuri negative la lagurile 1 și 12, deoarece $\theta < 0$ și $\Theta < 0$

Noțiuni necesare azi (13/22): volatilitate și mai multe serii

Mărimea	Formula
GARCH(1,1)	$\sigma_{t+1}^2 = \omega + \alpha \varepsilon_t^2 + \beta \sigma_t^2$, $\bar{\sigma}^2 = \omega / (1 - \alpha - \beta)$, $h_{1/2} = \ln 0,5 / \ln(\alpha + \beta)$
Volatilitatea anuală	$\sqrt{A \bar{\sigma}^2}$, A = zile de tranzacționare pe an
VaR 1%	$-(\mu + \sigma_{t+1} q_{0,01}(z))$; Student- t_ν : $q = t_\nu^{-1}(0,01) \sqrt{(\nu - 2)/\nu}$; Normal: $-2,326$
VAR(p)	$\mathbf{y}_t = \mathbf{c} + \mathbf{A}_1 \mathbf{y}_{t-1} + \dots + \mathbf{A}_p \mathbf{y}_{t-p} + \mathbf{u}_t$, OLS ecuație cu ecuație
Granger F	$[(RSS_R - RSS_U)/p] / [RSS_U / (T - Kp - 1)] \sim F(p, T - Kp - 1)$
Efectul pe termen lung	$\partial y / \partial x = \sum_j b_{yx,j} / (1 - \sum_j b_{yy,j})$
Engle–Granger, ECM	ADF pe reziduurile OLS, valoare critică circa $-3,34$ (două variabile); $h_{1/2} = \ln 0,5 / \ln(1 + \gamma)$
Johansen	urma $-T \sum_{i>r} \ln(1 - \hat{\lambda}_i)$; testăm pe rînd $r = 0, 1, \dots$; ne oprim la prima nerespingere

Noțiuni necesare azi (14/22): notațiile fișei precedente

□ GARCH și VaR

- ▶ σ_t^2 : varianța condiționată; ε_t : șocul; ω : constanta; α : reacția la șocuri; β : persistența
- ▶ $\bar{\sigma}^2$: varianța pe termen lung; $h_{1/2}$: timpul de înjumătățire al unui șoc de volatilitate; μ : randamentul mediu
- ▶ $q_{0,01}(z)$: cuantila de 1% a inovațiilor standardizate; ν : gradele de libertate ale distribuției Student- t

□ VAR și Granger

- ▶ $\mathbf{y}_t$: vectorul celor K variabile; $\mathbf{c}$: constantele; $\mathbf{A}_i$: matricea coeficienților lagului i ; $\mathbf{u}_t$: șocurile; p : numărul de laguri
- ▶ RSS_R , RSS_U : sumele pătratelor reziduurilor fără și cu lagurile variabilei testate
- ▶ $b_{yx,j}$: coeficientul lui x_{t-j} în ecuația lui y ; $b_{yy,j}$: cel al lui y_{t-j}

□ Cointegrarea

- ▶ $\gamma < 0$: coeficientul de corecție a erorii, viteza revenirii la echilibru
- ▶ $\hat{\lambda}_i$: valorile proprii estimate în procedura Johansen; r : rangul de cointegrare testat

Noțiuni necesare azi (15/22): GARCH: volatility clustering și timpul de înjumătățire

- **GARCH(1,1)** Bollerslev (1986): șocul de azi și varianța de ieri dau varianța de mâine

► α : reacția la un șoc; β : memoria varianței; $\alpha + \beta < 1$: varianța revine la $\bar{\sigma}^2$

- **Prognoza varianței** cu h zile înainte

$$\sigma_{T+h}^2 - \bar{\sigma}^2 = (\alpha + \beta)^{h-1} (\sigma_{T+1}^2 - \bar{\sigma}^2)$$


► timpul de înjumătățire $h_{1/2} = \ln 0,5 / \ln(\alpha + \beta)$ rezolvă $(\alpha + \beta)^h = 0,5$: distanța pînă la $\bar{\sigma}^2$ se înjumătățește

- **Testul ARCH-LM** Engle (1982) cu q laguri: regresăm $\hat{\varepsilon}_t^2$ pe $1, \hat{\varepsilon}_{t-1}^2, \dots, \hat{\varepsilon}_{t-q}^2$

$$LM = T R^2 \sim \chi^2(q) \text{ sub } H_0: \text{fără efecte ARCH}$$

► $\hat{\varepsilon}_t$: randamentele din care s-a scăzut media; R^2 : al acestei regresii; un LM mare: mărimea randamentelor este previzibilă

Noțiuni necesare azi (16/22): GARCH într-un grafic



- Stînga: randamente GARCH(1,1) simulate; perioadele calme și cele agitate alternează (volatility clustering), $\pm 2\sigma_t$ le urmărește
- Dreapta: $\alpha + \beta = 0.98$, deci $h_{1/2} = \ln 0.5 / \ln 0.98 = 34$ de zile: o varianță de patru ori $\bar{\sigma}^2$ își înjumătățește excesul în 34 de zile

Noțiuni necesare azi (17/22): VaR cu inovații Normale și Student- t

- Randamentul $r_{t+1} = \mu + \sigma_{t+1} z_{t+1}$, cu z de medie 0 și varianță 1; **VaR 1%**: pierderea depășită cu probabilitatea 1%

$$\text{VaR}_{1\%} = -(\mu + \sigma_{t+1} q_{0,01}(z)) > 0$$


- $q_{0,01}(z)$: cuantila de 1% a lui z ; VaR se raportează ca pierdere pozitivă, la nivelul „1%” (probabilitatea din coadă)

- Inovații **Student- t** : t_ν are varianța $\nu/(\nu - 2)$, deci se rescalează la varianța 1

$$q_{0,01}(z) = t_\nu^{-1}(0,01) \sqrt{(\nu - 2)/\nu}$$

- $t_\nu^{-1}(0,01)$: cuantila de 1% a distribuției Student cu ν grade de libertate; ν mic: cozi groase

Noțiuni necesare azi (18/22): VaR într-un grafic



- Distribuția Normală și Student- t_5 cu aceeași varianță: t are mai multă masă în centru și în cozi
- Cuantilele de 1%: $-2,326$ (Normală) și $-3,365 \cdot \sqrt{3/5} = -2,606$ (t_5): cu $\mu = 0$, $\sigma = 1\%$, VaR 1% este 2,33% sau 2,61%

Noțiuni necesare azi (19/22): cauzalitatea Granger și cointegrarea

- ▣ **Cauzalitatea Granger** Granger (1969): x cauzează Granger pe y dacă lagurile lui x îmbunătățesc prognoza lui y , date fiind lagurile lui y

► H_0 : toți $b_{yx,j} = 0$, testat cu statistica F din fișă; predictibilitate suplimentară, nu dovada unui mecanism causal

- ▣ **Cointegrarea Engle și Granger (1987)**: y_t, x_t sînt $I(1)$, dar o combinație a lor este staționară

$$u_t = y_t - c - \beta x_t \sim I(0), \quad \Delta y_t = \gamma u_{t-1} + \delta \Delta x_t + \varepsilon_t$$

► β : coeficientul pe termen lung; a doua ecuație este **modelul cu corecția erorii (ECM)**; $\gamma < 0$: y revine spre echilibru


► timpul de înjumătățire al unei abateri: $h_{1/2} = \ln 0,5 / \ln(1 + \gamma)$; δ : efectul pe termen scurt

- ▣ **Johansen Johansen (1991)**: valorile proprii $\hat{\lambda}_1 > \hat{\lambda}_2 > \dots$ ale unui VECM; două statistici pentru rangul r

$$\lambda_{urma}(r) = -T \sum_{i>r} \ln(1 - \hat{\lambda}_i), \quad \lambda_{max}(r) = -T \ln(1 - \hat{\lambda}_{r+1})$$

► valorile mari resping „cel mult r relații de cointegrare”; urma: față de pînă la K relații; valoarea proprie maximă: față de $r + 1$

Noțiuni necesare azi (20/22): cointegrarea într-un grafic



- Stînga: două serii $I(1)$ simulate care se mișcă împreună; niciuna nu are o medie fixă
- Dreapta: abaterea $u_t = y_t - 3 - 1.3x_t$ este staționară; cu $\gamma = -0.08$, $h_{1/2} = \ln 0.5 / \ln 0.92 = 8.3$ luni

Noțiuni necesare azi (21/22): extensii

Mărimea	Formula
ARFIMA(0, d , 0)	$\rho(1) = d/(1 - d)$, $H = d + 1/2$; staționar pentru $d < 1/2$, cu revenire la medie pentru $d < 1$
Local level	$F_t = P_t + \sigma_\varepsilon^2$, $K_t = P_t/F_t$, $a_{t t} = a_t + K_t(y_t - a_t)$, $P_{t+1} = P_t(1 - K_t) + \sigma_\eta^2$
Starea de echilibru	$\bar{P}/\sigma_\varepsilon^2 = (q + \sqrt{q^2 + 4q})/2$, $\bar{K} = \alpha_{SES}$, $q = \sigma_\eta^2/\sigma_\varepsilon^2$
Markov switching	$E(D_i) = 1/(1 - p_{ii})$, $\pi_1 = (1 - p_{22})/(2 - p_{11} - p_{22})$
Învățare automată	doar validare walk-forward; comparație cu un reper simplu
Valori	$\chi_{0,95}^2$: 3,84 (1); 5,99 (2); 9,49 (4); 12,59 (6); 18,31 (10); $F_{0,95}(2, 250) = 3,03$

Noțiuni necesare azi (22/22): notațiile fișei precedente

- Memoria lungă
 - ▶ d : ordinul de integrare fracționară; H : exponentul Hurst; $\rho(1)$: prima autocorelație
- Modelul local level și filtrul Kalman
 - ▶ a_t, P_t : nivelul prezis și varianța lui; $a_{t|t}$: nivelul actualizat cu y_t
 - ▶ $\sigma_\varepsilon^2, \sigma_\eta^2$: varianțele zgomotului de măsurare și ale zgomotului nivelului; q : raportul lor
 - ▶ F_t : varianța erorii de predicție $y_t - a_t$; K_t : cîștigul Kalman, partea din surpriză adăugată la nivel; $\bar{P}, \bar{K}$: valorile lor de echilibru
- Markov switching și valorile critice
 - ▶ p_{ii} : probabilitatea de a rămîne în regimul i ; $E(D_i)$: durata așteptată a regimului i ; π_1 : ponderea pe termen lung a regimului 1
 - ▶ $\chi_{0,95}^2$: cuantilele de 95% ale distribuției chi-pătrat, cu gradele de libertate între paranteze; $F_{0,95}(2, 250)$: cuantila de 95% a distribuției F

A1: un ARIMA(0,1,1) calculat de mînă [Rezolvat]

Cerință

- $\Delta y_t = \varepsilon_t - 0,6\varepsilon_{t-1}$, $\varepsilon_t \sim WN(0, 1)$; y_0 dat, $\varepsilon_0 = 0$; azi $y_T = 100$, $\hat{\varepsilon}_T = 1,5$.
- 1. Arătați că Δy_t este staționar și invertibil și calculați $\rho_{\Delta y}(1)$.
- 2. Calculați $\text{Var}(y_t)$ pentru $t = 10$ și $t = 100$ și precizați dacă y_t este staționar.
- 3. Prognozați y_{T+1} și y_{T+4} ; dați intervalul de 95% pentru $h = 4$.
- 4. Dați ponderea netezirii exponențiale echivalente.
- Raportați: cinci valori, un interval și o frază.

Rezolvare

- 1. Un MA(1) este întotdeauna staționar; rădăcina $1/0,6 = 1,667 > 1$: invertibil;
 $\rho(1) = -0,6/1,36 = -0,441$
- 2. $y_t = y_0 + \varepsilon_t + 0,4 \sum_{j < t} \varepsilon_j$: $\text{Var} = 1 + (t - 1)0,16$: 2,44 și 16,84: crește cu t , nestaționar
- 3. $\hat{y}_{T+h} = 100 - 0,6 \times 1,5 = 99,10$ pentru orice h ; varianțe 1,00 și 1,48; intervalul [96,72; 101,48]
- 4. $\alpha = 1 + \theta = 0,4$
- Interpretare: prognoza este orizontală, ca a netezirii exponențiale, dar intervalul ei se lărgeste continuu: o rădăcină unitară

A2: identificarea ratei șomajului din România [Propus]

Rezolvarea se discută la seminar

Cerință

Seria	ADF τ	p	ADF val. critică 5%	KPSS (val. critică 0,463)
u_t	-1,52	0,524	-2,87	1,037
Δu_t	-8,12	< 0,001	-2,87	0,096

- ▣ Rata șomajului u_t (ajustată sezonier, %), ianuarie 2005 – august 2026; ambele teste cu constantă. Δu_t ($T = 259$): ACF -0,19; 0,11; 0,09; -0,07; PACF -0,19; 0,08; 0,13; -0,04 (lagurile 1–4). Model: Seminarul 3, A1; Seminarul 2, A6.
- ▣ 1. Precizați H_0 pentru fiecare test și decideți ordinul de integrare al lui u_t .
- ▣ 2. Calculați banda $\pm 1,96/\sqrt{T}$ și Ljung–Box $Q(4)$ din cele patru valori ACF; decideți la 5%.
- ▣ 3. Propuneți un model ARIMA pentru u_t .
- ▣ Raportați: două decizii, două valori, un model.

A3: rezultate SARIMA pentru PIB-ul României [Propus]

Rezolvarea se discută la seminar

Cerință

Variabila dependentă: z_t	Coef.	SE	z	p
AR(1)	-0,083	0,106	-0,79	0,431
SAR(4)	-0,405	0,085	-4,79	< 0,001
SIGMASQ	10,41			
Ljung-Box $Q(8)$	18,14			0,006

- $z_t = \Delta\Delta_4 100 \ln \text{PIB}_t$, PIB real neajustat sezonier, T2 2001 – T2 2026 ($T = 101$). Ultimele valori ale lui z : 1,923 (T2 2025); -1,150 (T3 2025); -2,584 (T4 2025); -0,247 (T1 2026); -0,457 (T2 2026); creșterea anuală $\Delta_4 100 \ln \text{PIB}$ în T2 2026: -1,96%. Model: Seminarul 4, A4.
- 1. Scrieți ecuația modelului și precizați ce coeficienți sînt semnificativi.
- 2. Testați dacă reziduurile sînt zgomot alb ($\chi^2_{0,95}(6) = 12,59$).
- 3. Prognozați z și rata anuală de creștere pentru T3 2026.

A4: rezultate VAR și cauzalitate Granger [Propus]

Rezolvarea se discută la seminar

Cerință

	ecuația π_t	ecuația i_t
π_{t-1}	1,318 [21,58]	0,031 [0,48]
π_{t-2}	-0,342 [-5,52]	0,008 [0,13]
i_{t-1}	0,011 [0,19]	1,167 [19,60]
i_{t-2}	-0,012 [-0,22]	-0,219 [-3,81]
const.	0,112 [1,62]	0,063 [0,88]
R^2	0,97	0,97

- ▣ VAR(2) pentru inflația anuală a României π și ROBOR 3M i (%), martie 2005 – august 2026, $T = 258$; statisticile t între paranteze. Fără lagurile lui π , RSS a ecuației lui i crește de la 89,81 la 92,20. Model: Seminarul 6, A5.
- ▣ 1. Scrieți ecuația lui i .
- ▣ 2. Calculați statistica Granger F pentru „ π nu cauzează Granger i ” și decideți la 5% ($F_{0,95} = 3,03$).
- ▣ 3. Calculați efectul pe termen lung asupra ROBOR al unei creșteri permanente a inflației cu 1 pp.

A5: rezultate GARCH pentru DAX și VaR 1% [Propus]

Rezolvarea se discută la seminar

Cerință


DAX	μ	ω	α	β	ν
estimare	0,081	0,0206	0,097	0,895	7,08
SE	0,012	0,0049	0,011	0,012	0,617

- GARCH(1,1)- t , randamentele logaritmice zilnice DAX în %, din 2000 ($n = 6\,786$); ultima zi (septembrie 2026): $\sigma_T^2 = 0,662$, $\hat{\varepsilon}_T = -1,698$; circa 254 de zile de tranzacționare pe an; folosiți $\nu = 7$: $t_7^{-1}(0,01) = -2,998$. Model: Seminarul 5, A1 și A4.
- 1. Calculați persistența, timpul de înjumătățire și volatilitatea anuală pe termen lung.
- 2. Calculați σ_{T+1}^2 .
- 3. Calculați VaR 1% pe o zi și comparați-l cu VaR 1% Normal.

B1: Box–Jenkins pentru producția industrială a României [Rezolvat]

- **Întrebarea:** ce model SARIMA prognozează cel mai bine producția industrială a României și bate el metoda naivă sezonieră?
- **Date:** producția industrială (B–D), ajustată calendaristic, lunar, ianuarie 2005 – iulie 2026; eșantionul de test: ultimele 24 de luni
- **Cerințe**
 1. Aplicați ADF și KPSS pentru $100 \ln y_t$, prima diferență și $z_t = \Delta \Delta_{12} 100 \ln y_t$.
 2. Reprezentați ACF a lui z_t și propuneți un model.
 3. Estimați modelul airline și SARIMA(1, 1, 1)(0, 1, 1)₁₂ pe eșantionul de antrenare; comparați AICc, BIC și Ljung–Box.
 4. Prognozați cele 24 de luni de test cu ambele modele și cu metoda naivă sezonieră; comparați RMSE și MAE.
 5. Interpretare: ce model ați folosi pentru prognoză și de ce?
- **Raportați:** un tabel cu teste, un tabel cu două modele, trei valori RMSE și o frază
- Notebook: secțiunea [B1](#)

B1: rezolvare (1/2) [Rezolvat]



Modelul	AICc	BIC	LB(12) p	LB(24) p	RMSE test
airline (0, 1, 1)(0, 1, 1) ₁₂	1304,2	1314,3	0,065	0,432	3,75
(1, 1, 1)(0, 1, 1) ₁₂	1291,1	1304,5	0,789	0,972	5,29
naiv sezonier					3,85

B1: rezolvare (2/2) [Rezolvat]

- ▣ Teste: ADF $\tau = -1,31$ ($p = 0,885$) și KPSS $0,523 > 0,146$ pentru nivel; z_t : ADF $-6,47$, KPSS $0,055$: $d = D = 1$; ACF a lui z_t : $-0,09$; $-0,22$ la lagurile 1, 2; $-0,50$ la 12
- ▣ Airline: $\hat{\theta} = -0,205$, $\hat{\Theta} = -0,934$; modelul $(1, 1, 1)$: $\hat{\phi} = 0,574$, $\hat{\theta} = -0,828$, factori care aproape se anulează
- ▣ Interpretare: modelul $(1, 1, 1)$ câștigă în eșantion (BIC, reziduuri curate), dar pierde în afara eșantionului; modelul airline este puțin mai bun decât metoda naivă sezonieră: folosim modelul airline și păstrăm metoda naivă sezonieră ca reper

B2: volatilitatea BET din 2015 [Propus]

- **Întrebarea:** este bursa de la București azi mai liniștită sau mai agitată decât de obicei și ce înseamnă acest lucru pentru VaR 1% de mâine? Model: Seminarul 5, B1.
- **Date:** randamentele logaritmice zilnice ale BET în %, ianuarie 2015 – septembrie 2026 ($n = 2\,925$)
- **Cerințe**
 1. Aplicați testul ARCH-LM cu cinci laguri pe randamentele centrate.
 2. Estimați un GARCH(1,1) cu inovații Student- t ; raportați persistența și timpul de înjumătățire.
 3. Comparați volatilitatea anualizată pe termen lung, cea de selecție și cea de azi.
 4. Calculați VaR 1% de mâine cu cuantila t și cu cea Normală.
 5. Interpretare: este BET azi mai liniștit sau mai agitat decât de obicei?
- **Raportați:** un test, cinci parametri, trei volatilități, două valori VaR și o frază
- Notebook: secțiunea [B2](#)

B3: randamentele la 10 ani ale României și Germaniei [Propus]

- **Întrebarea:** este randamentul la 10 ani al României legat pe termen lung de cel al Germaniei? Model: Seminarul 7, B1 și A3.
- **Date:** medii lunare ale randamentelor zilnice la 10 ani (%), ianuarie 2008 – septembrie 2026 ($T = 224$)
- **Cerințe**
 1. Aplicați ADF pentru ambele randamente și pentru diferențele lor.
 2. Aplicați testul Engle–Granger (România în funcție de Germania) și raportați $\hat{\beta}$.
 3. Aplicați testele Johansen ale urmei și ale valorii proprii maxime.
 4. Estimați ecuația cu corecția erorii pentru fiecare randament și calculați timpul de înjumătățire.
 5. Interpretare: este randamentul României legat de cel al Germaniei?
- **Raportați:** patru rezultate ADF, două teste de cointegrare, doi coeficienți de ajustare și o frază
- Notebook: secțiunea [B3](#)

C1: o competiție de prognoză pentru inflația din România [Propus]

- ▣ **Întrebarea:** ce metodă ar fi prognozat cel mai bine inflația lunară din România în ultimii zece ani, cu o lună și cu douăsprezece luni înainte?
- ▣ **Date:** IAPC al României (Eurostat), lunar, 2005–2026; Cursul 15 aplică un singur SARIMA pe un singur eşantion de test
- ▣ **Cerințe**
 1. Enumerați cinci concurenți: naiv sezonier, SES, SARIMA, ARFIMA, un model ridge cu laguri și variabile dummy pentru luni.
 2. Descrieți o schemă cu origini mobile: prima origine, pasul, orizonturile, reestimările.
 3. Precizați cum ați trata modificările de taxe din 2010, 2015 și 2025.
 4. Alegeți măsurile de eroare și testul pentru comparație.
- ▣ **Raportați:** un plan de o pagină pe care o echipă îl poate transforma în proiect
- ▣ Notebook: secțiunea [C1](#)

C2: verificați un răspuns AI [Propus]

□ Un student a cerut unui asistent AI să verifice răspunsurile la Partea A. Răspunsul:

- ▶ (a) Pentru rata șomajului, ADF dă $p = 0,52$, deci rădăcina unitară se respinge la 5%.
- ▶ (b) KPSS = 1,04 > 0,463 respinge, deci nivelul șomajului este staționar.
- ▶ (c) Pentru DAX, $\alpha + \beta = 0,992$, deci un șoc se înjumătățește în $1/(1 - 0,992) = 128$ de zile.
- ▶ (d) VaR 99% al DAX pentru mâine este -2,31%.
- ▶ (e) Inflația cauzează Granger ROBOR ($p = 0,036$), ceea ce dovedește că inflația determină banca centrală să crească dobânzile.
- ▶ (f) Ljung-Box Q(12) pe reziduurile unui model AR(1) x SAR(1) are 12 grade de libertate.

□ Cerințe

1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și dați valoarea corectă (notebook, secțiunea C2).
2. Raportați: șase verdicte, fiecare cu un rând de justificare.

Idei de reținut

- ▣ Orice problemă de examen are trei părți: formula cu cifrele înlocuite, rezultatul cu unitate și semn, interpretarea
- ▣ Testele: precizați întîi H_0 ; ADF și KPSS au ipoteze nule opuse; Ljung–Box pe reziduuri pierde k grade de libertate
- ▣ Prognozele de mîină: scrieți modelul pentru z_t , înlocuiți ultimele valori, apoi refaceți diferențierile
- ▣ Un model mai bun în eșantion nu prognozează neapărat mai bine (B1); judecați-l pe un eșantion de test, față de un reper
- ▣ Un răspuns AI este o ciornă: verificați ipotezele nule, timpul de înjumătățire, nivelul VaR și gradele de libertate

După seminar

- ▣ Cursul 15 adună întreaga materie: harta cursului, cîte două slide-uri de recapitulare pentru fiecare capitol, trusa de instrumente, Box–Jenkins pe inflația din România, opt probleme de tip examen rezolvate, proiectul
- ▣ Încercați cerințele [Propus] întâi pe hîrtie, apoi verificați-le în notebook
- ▣ C1 poate deveni un proiect de echipă
- ▣ Exerciții suplimentare: [setul de probleme de exercițiu](#), 25 de probleme de examen cu rezultatele numerice
- ▣ Lectură: [Huang și Petukhina \(2022\)](#); [Hyndman și Athanasopoulos \(2021\)](#); [Box, Jenkins și Reinsel \(2008\)](#)
- ▣ **Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar**

Bibliografie (1/2)

- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. doi:[10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1)
- Box, G. E. P., Jenkins, G. M., & Reinsel, G. C. (2008). *Time Series Analysis: Forecasting and Control* (4th ed.). Wiley. doi:[10.1002/9781118619193](https://doi.org/10.1002/9781118619193)
- Dickey, D. A., & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366), 427–431. doi:[10.1080/01621459.1979.10482531](https://doi.org/10.1080/01621459.1979.10482531)
- Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263. doi:[10.1080/07350015.1995.10524599](https://doi.org/10.1080/07350015.1995.10524599)
- Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007. doi:[10.2307/1912773](https://doi.org/10.2307/1912773)
- Engle, R. F., & Granger, C. W. J. (1987). Co-integration and error correction: Representation, estimation, and testing. *Econometrica*, 55(2), 251–276. doi:[10.2307/1913236](https://doi.org/10.2307/1913236)

Bibliografie (2/2)

- ▣ Granger, C. W. J. (1969). Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37(3), 424–438. doi:[10.2307/1912791](https://doi.org/10.2307/1912791)
- ▣ Huang, C., & Petukhina, A. (2022). *Applied Time Series Analysis and Forecasting with Python*. Springer. doi:[10.1007/978-3-031-13584-2](https://doi.org/10.1007/978-3-031-13584-2)
- ▣ Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. otexts.com/fpp3
- ▣ Johansen, S. (1991). Estimation and hypothesis testing of cointegration vectors in Gaussian vector autoregressive models. *Econometrica*, 59(6), 1551–1580. doi:[10.2307/2938278](https://doi.org/10.2307/2938278)
- ▣ Kwiatkowski, D., Phillips, P. C. B., Schmidt, P., & Shin, Y. (1992). Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, 54(1–3), 159–178. doi:[10.1016/0304-4076\(92\)90104-Y](https://doi.org/10.1016/0304-4076(92)90104-Y)
- ▣ Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303. doi:[10.1093/biomet/65.2.297](https://doi.org/10.1093/biomet/65.2.297)