



Analiza și Prognoza seriilor de timp

Seminar 0: Fundamente



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Cuprins Seminar

Structura seminarului:

1. **Test Grilă** – Verificarea cunoștințelor
2. **Adevărat/Fals** – Verificări conceptuale
3. **Exerciții de Calcul** – Practică aplicată
4. **Exerciții cu asistență AI** – Analiză om vs. AI
5. **Rezumat** – Recapitulare

Quiz 1: Bazele seriilor de timp

Întrebare

Care dintre următoarele NU este o caracteristică a datelor de tip serie de timp?

- A. Observațiile sunt ordonate în timp
- B. Observațiile consecutive sunt de obicei corelate
- C. Observațiile sunt independente și identic distribuite
- D. Datele au o ordonare temporală naturală

Răspunsul pe slide-ul următor...

Quiz 1: Răspuns

Răspuns: C – Observațiile sunt independente și identic distribuite

Întrebare: Care NU este o caracteristică a datelor de tip serie de timp?

- A. Observațiile sunt ordonate în timp ✗
- B. Observațiile consecutive sunt de obicei corelate ✗
- C. **Observațiile sunt independente și identic distribuite** ✓
- D. Datele au o ordonare temporală naturală ✗

- ☐ Observațiile seriilor de timp sunt **dependente** (autocorelate), nu independente
- ☐ Ipoteza i.i.d. este fundamentală pentru analiza transversală, dar este **încălcată** în seriile de timp
- ☐ Această dependență temporală necesită **metode specializate**

Quiz 2: Descompunere

Întrebare


Când ar trebui să folosiți descompunerea multiplicativă în loc de cea aditivă?

- A. Când modelul sezonier are amplitudine constantă
- B. Când varianța seriei este stabilă în timp
- C. Când fluctuațiile sezoniere cresc proporțional cu nivelul
- D. Când seria nu are componentă de trend

Răspunsul pe slide-ul următor...

Quiz 2: Răspuns

Răspuns: C – Când fluctuațiile sezoniere cresc proporțional cu nivelul



- ☐ **Multiplicativă:** $X_t = T_t \times S_t \times \varepsilon_t$ — amplitudinea sezonieră **scalează** cu nivelul
- ☐ **Aditivă:** $X_t = T_t + S_t + \varepsilon_t$ — amplitudine constantă

Quiz 3: Netezire exponențială

Întrebare

În Netezirea exponențială Simplă cu $\alpha = 0.9$, ce se întâmplă?

- A. Prognozele sunt foarte netede și stabile
- B. Observațiile recente au foarte puțină pondere
- C. Prognozele reacționează rapid la schimbările recente
- D. Prognoza este în esență o medie pe termen lung

Răspunsul pe slide-ul următor...

Quiz 3: Răspuns

Răspuns: C – Prognozele reacționează rapid la schimbările recente

Cu $\alpha = 0.9$: $\hat{X}_{t+1} = 0.9X_t + 0.1\hat{X}_t$

- ☐ α **mare** (ex. 0.9): 90% pondere pe ultima observație
 - ▶ Prognoze foarte receptive la date noi
- ☐ α **mic** (ex. 0.1): prognoze mai netede, mai stabile
 - ▶ la în calcul mai multe observații din trecut

Quiz 4: Medii mobile

Întrebare


Ce observații folosește o medie mobilă centrată de ordin 5 (MA-5) pentru a estima trendul la momentul t ?

- A. $X_t, X_{t+1}, X_{t+2}, X_{t+3}, X_{t+4}$
- B. $X_{t-4}, X_{t-3}, X_{t-2}, X_{t-1}, X_t$
- C. $X_{t-2}, X_{t-1}, X_t, X_{t+1}, X_{t+2}$
- D. X_{t-1}, X_t, X_{t+1}

Răspunsul pe slide-ul următor...

Quiz 4: Răspuns

Răspuns: $C - X_{t-2}, X_{t-1}, X_t, X_{t+1}, X_{t+2}$



- ☐ **MA centrată:** folosește $(k - 1)/2$ observații de fiecare parte a lui t
- ☐ **MA-5:** 2 înainte + t + 2 după \Rightarrow fereastră mai mare = mai neted

Quiz 5: Evaluarea prognozei

Întrebare

Care metrică este cea mai potrivită pentru compararea acurateții prognozei între serii cu scale diferite?

- A. Eroarea Absolută Medie (MAE)
- B. Rădăcina Erorii Medii Pătratică (RMSE)
- C. Eroarea Absolută Medie Procentuală (MAPE)
- D. Eroarea Medie Pătratică (MSE)

Răspunsul pe slide-ul următor...

Quiz 5: Răspuns

Răspuns: C – Eroarea Absolută Medie Procentuală (MAPE)

$MAPE = \frac{100}{n} \sum \left| \frac{e_t}{X_t} \right|$ exprimă erorile ca **procente**.

- ☐ MAE, RMSE, MSE sunt **dependente de scală** (unități ale lui X_t)
- ☐ MAPE este **independentă de scală** (întotdeauna în %)
- ☐ Atenție: MAPE devine instabilă când $X_t \approx 0$

Quiz 6: Validare încrucișată

Întrebare


De ce nu putem folosi validarea încrucișată standard k-fold pentru seriile de timp?

- A. Datele seriilor de timp sunt prea mici
- B. Ar încălca ordonarea temporală (viitorul prezicând trecutul)
- C. Validarea încrucișată este întotdeauna invalidă
- D. Seriile de timp nu au nevoie de validare

Răspunsul pe slide-ul următor...


Quiz 6: Răspuns

Răspuns: B – Ar încălca ordonarea temporală



Principiu: datele viitoare nu pot fi folosite pentru a prezice trecutul! Se recomandă CV cu fereastră mobilă/în expansiune.

Vizual: Descompunerea seriei de timp



Componentele descompunerii

☐ **Trend:** mișcare pe termen lung **Sezonalitate:** tipar periodic **Reziduu:** zgomot aleatoriu

Adevărat sau Fals? — Întrebări

Afirmație	A/F?
1. Prognozele SES sunt plate (constante pentru toate orizonturile).	?
2. RMSE penalizează erorile mari mai mult decât MAE.	?
3. Descompunerea multiplicativă necesită date pozitive.	?
4. Un α mai mare înseamnă mai multă netezire.	?
5. Setul de test se folosește pentru ajustarea hiperparametrilor.	?
6. Naive sezonier folosește valoarea de acum un sezon.	?
7. MAPE poate fi infinit dacă valorile reale sunt zero.	?

Adevărat sau Fals? — Răspunsuri

Afirmație	A/F	Explicație
1. Prognozele SES sunt plate (constante pentru toate orizonturile).	A	Fără trend
2. RMSE penalizează erorile mari mai mult decât MAE.	A	Erori pătratice
3. Descompunerea multiplicativă necesită date pozitive.	A	Nu se poate \times negativ
4. Un α mai mare înseamnă mai multă netezire.	F	α mare = mai puțin neted
5. Setul de test se folosește pentru ajustarea hiperparametrilor.	F	Folosiți validare!
6. Naive sezonier folosește valoarea de acum un sezon.	A	$\hat{X}_{t+h} = X_{t+h-m}$
7. MAPE poate fi infinit dacă valorile reale sunt zero.	A	Împărțire la zero

Exercițiu 1: Netezire Exponențială Simplă

Problemă

- ▣ **Date:** $X = [10, 12, 11, 14, 13]$ cu $\alpha = 0.3$, $\hat{X}_1 = 10$
- ▣ **Calculați:** a) Prognozele \hat{X}_2 până la \hat{X}_6 ; b) MAE și RMSE
- ▣ **Formula:** $\hat{X}_{t+1} = \alpha X_t + (1 - \alpha)\hat{X}_t$

Soluție

t	1	2	3	4	5	6
X_t	10	12	11	14	13	?
\hat{X}_t	10	10	10.6	10.72	11.70	12.09

- ▣ **MAE** = 1.745 **RMSE** = 2.04

Exercițiu 2: Metrice de eroare

Problemă

- ▣ **Date:** $X = [100, 110, 105, 120]$, $\hat{X} = [95, 108, 110, 115]$
- ▣ **Calculați:** MAE, MSE, RMSE, MAPE

Soluție

- ▣ **Erori:** $e = [5, 2, -5, 5]$
- ▣ **MAE** $= (|5| + |2| + |-5| + |5|)/4 = 4.25$
- ▣ **MSE** $= (25 + 4 + 25 + 25)/4 = 19.75$
- ▣ **RMSE** $= \sqrt{19.75} = 4.44$
- ▣ **MAPE** $= 25 \times (0.05 + 0.018 + 0.048 + 0.042) = 3.95\%$

Exercițiu 3: Indici sezonieri

Problemă

- ▣ **Date:** Indici sezonieri: $S = [0.85, 1.05, 0.90, 1.20]$, Trend T4: $T = 1000$
- ▣ **Calculați:** a) Verificați normalizarea. b) Prognoza T4. c) Desezonalizați $X_{T4} = 1150$

Soluție

- ▣ a) **Normalizare:** $\sum S_i = 0.85 + 1.05 + 0.90 + 1.20 = 4.00 \checkmark$
- ▣ b) **Prognoză:** $\hat{X}_{T4} = 1000 \times 1.20 = 1200$
- ▣ c) **Desezonalizare:** $X_{desezonalizat} = 1150/1.20 = 958.33$ (sub trend)

AI în analiza seriilor de timp

De ce folosim instrumente AI în acest curs?

- ▣ Asistenții AI (Claude, ChatGPT, GitHub Copilot) pot genera cod și analiză
- ▣ Rolul vostru este să **evaluați, interpretați și criticați** — competențe pe care AI nu le poate înlocui

Obiective de învățare:

- ▣ Scrieți prompt-uri precise pentru sarcini econometrice
- ▣ Identificați erori în analiza statistică generată de AI
- ▣ Interpretați rezultatele critic folosind conceptele din curs
- ▣ Comparați soluțiile AI cu metodologia manuală

Important

- ▣ AI este un **instrument**, nu un înlocuitor al înțelegerii
- ▣ Trebuie să puteți explica *de ce* fiecare pas este corect

Exercițiu AI 1: Audit descompunere

Rezultat AI (vânzări lunare retail SUA, 2015–2023)

Prompt: “Am un fișier cu vânzări lunare retail din SUA, din 2015 până în 2023. Ce tendințe și pattern-uri apar?”

AI: “Am aplicat STL aditiv, perioadă=12. Trendul surprinde creșterea de la \$420 mld la \$580 mld. Componenta sezonieră este stabilă pe întreaga perioadă.”

Datele contrazic AI-ul:

- Oscilația sezonieră dec-ian: $\pm \$18$ mld în 2015, $\pm \$45$ mld în 2023
- Deviația std a reziduurilor: \$3,2 mld (2015–2017) vs \$8,7 mld (2021–2023)

Cerințe:

1. Calculați $\frac{\text{amplitudine sezonieră}}{\text{nivel}}$ pentru 2015 vs 2023. Dacă raportul e aproximativ constant, ce tip de descompunere implică?
2. Dacă $X_t = T_t \cdot S_t \cdot \varepsilon_t$, arătați că $\ln X_t = \underbrace{\ln T_t}_{\text{trend}} + \underbrace{\ln S_t}_{\text{sezon}} + \underbrace{\ln \varepsilon_t}_{\text{reziduu}}$ este aditivă.
3. Aplicați STL pe $\ln X_t$. Cum verificați varianța constantă a reziduurilor? (Indiciu: Breusch–Pagan sau grafic $|\hat{\varepsilon}_t|$ vs t .)
4. Care sunt consecințele folosirii STL aditiv pe date multiplicative pentru prognoză?

Exercițiu AI 2: Detectarea scurgerii de date

Cod AI (găsiți erorile)

```
df['ma12'] = df['sales'].rolling(12, center=True).mean()
df['detrended'] = df['sales'] - df['ma12']
model = ExponentialSmoothing(df['sales'], seasonal='add',
                             seasonal_periods=12).fit()
print(f"MAPE = {mape(df['sales'], model.fittedvalues):.1f}%")
# Output: MAPE = 1.1%
```

Găsiți trei erori critice:

1. `center=True` înseamnă $MA_{12}(t)$ folosește X_{t-5}, \dots, X_{t+6} — șase valori viitoare se scurg în caracteristică. Care este setarea corectă?
2. MAPE e calculat pe **valorile ajustate in-sample**, nu pe prognoze out-of-sample. Dacă MAPE real OOS = 8,3%, ce explică diferența de $7\times$?
3. Model sezonier aditiv pe date cu amplitudine crescătoare. Ce grafic diagnostic relevă aceasta? (Indiciu: $|S_t|$ vs nivelul T_t .)

Corectare: rescrieți cu `center=False`, împărțiți 80/20, calculați MAPE pe test, și comparați cu benchmark-ul naiv sezonier $\hat{X}_{t+h} = X_{t+h-12}$.

Exercițiu AI 3: Expertiza parametrilor de netezire

Comparație modele AI (Indicele Producției Industriale)

Model	α	β	γ	RMSE antrenare	RMSE test
SES	0,98	—	—	1,2	4,8
Holt	0,95	0,89	—	0,9	6,3
Holt-Winters	0,99	0,85	0,01	0,3	9,1

Concluzia AI: “Holt-Winters are cel mai mic RMSE — cel mai bun model.”

Cerințe:

1. Arătați că SES cu $\alpha \rightarrow 1$ dă $\hat{X}_{t+1|t} = X_t$ (prognoză naivă). Ce aproximează $\alpha = 0,98$?
2. RMSE pe test *crește* cu complexitatea: $4,8 \rightarrow 6,3 \rightarrow 9,1$. Numiți acest fenomen. Care coloană RMSE trebuie folosită la selecția modelului?
3. $\gamma = 0,01$: indicii sezonieri aproape nu se actualizează. Ce se întâmplă dacă tiparul sezonier se schimbă (ex. post-COVID)?
4. Ce model ați selecta și de ce? Calculați $AIC = T \ln(SSE/T) + 2k$ pentru fiecare.

Rezumat: Capitolul 0

Concepte cheie

1. **Serii de timp:** observații ordonate temporal, cu dependență (autocorelație)
2. **Descompunere:** aditivă ($X_t = T_t + S_t + \varepsilon_t$) vs multiplicativă ($X_t = T_t \times S_t \times \varepsilon_t$)
3. **Netezire exponențială:** SES, Holt, Holt-Winters — parametrul α controlează reactivitatea
4. **Evaluarea prognozei:** MAE, RMSE, MAPE — alegerea depinde de context
5. **Sezonalitate:** indici sezonieri, prognoză și desezonalizare

Întrebări?

Bibliografie I

Fundamente ale seriilor de timp

- ▣ Hyndman, R.J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*, 3rd ed., OTexts.
- ▣ Shumway, R.H., & Stoffer, D.S. (2017). *Time Series Analysis and Its Applications*, 4th ed., Springer.
- ▣ Brockwell, P.J., & Davis, R.A. (2016). *Introduction to Time Series and Forecasting*, 3rd ed., Springer.

Serii de timp financiare

- ▣ Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed., Wiley.
- ▣ Franke, J., Härdle, W.K., & Hafner, C.M. (2019). *Statistics of Financial Markets*, 4th ed., Springer.

Bibliografie II

Abordări moderne și Machine Learning

- ▣ Nielsen, A. (2019). *Practical Time Series Analysis*, O'Reilly Media.
- ▣ Petropoulos, F., et al. (2022). *Forecasting: Theory and Practice*, International Journal of Forecasting.
- ▣ Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition, International Journal of Forecasting.


Resurse online și cod


- ▣ **Quantlet**: <https://quantlet.com> — Repository de cod pentru statistică
- ▣ **Quantinar**: <https://quantinar.com> — Platformă de învățare metode cantitative
- ▣ **GitHub TSA**: https://github.com/QuantLet/TSA/tree/main/TSA_ch0 — Cod Python pentru acest seminar

Vă mulțumim!

Întrebări?

Materialele seminarului sunt disponibile la: <https://danpele.github.io/Time-Series-Analysis/>

 Quantlet

 Quantinar