

Analiza și Prognoza Seriilor de Timp

Capitolul 0: Fundamente

Seminar



Quiz 1: Bazele seriilor de timp

Întrebare

Care dintre următoarele NU este o caracteristică a datelor de tip serie de timp?

Variante de răspuns

- (A) Observațiile sunt ordonate în timp
- (B) Observațiile consecutive sunt de obicei corelate
- (C) Observațiile sunt independente și identic distribuite
- (D) Datele au o ordonare temporală naturală

Răspunsul pe slide-ul următor...

Quiz 1: Răspuns

Răspuns: C – Observațiile sunt independente și identic distribuite

Întrebare: Care NU este o caracteristică a datelor de tip serie de timp?

Variante de răspuns

- (A) Observațiile sunt ordonate în timp ✗
- (B) Observațiile consecutive sunt de obicei corelate ✗
- (C) **Observațiile sunt independente și identic distribuite** ✓
- (D) Datele au o ordonare temporală naturală ✗

- Observațiile seriilor de timp sunt **dependente** (autocorelate), nu independente
- Ipoteza i.i.d. este fundamentală pentru analiza transversală, dar este **încălcată** în seriile de timp
- Această dependență temporală necesită **metode specializate**

Întrebare

Când ar trebui să folosiți descompunerea multiplicativă în loc de cea aditivă?


Variante de răspuns

- (A) Când modelul sezonier are amplitudine constantă
- (B) Când varianța seriei este stabilă în timp
- (C) Când fluctuațiile sezoniere cresc proporțional cu nivelul
- (D) Când seria nu are componentă de trend

Răspunsul pe slide-ul următor...

Quiz 2: Răspuns

Răspuns: C – Când fluctuațiile sezoniere cresc proporțional cu nivelul



- **Multiplicativă:** $X_t = T_t \times S_t \times \varepsilon_t$ — amplitudinea sezonieră scalează cu nivelul
- **Aditivă:** $X_t = T_t + S_t + \varepsilon_t$ — amplitudine constantă

Quiz 3: Netezire exponențială

Întrebare

În Netezirea exponențială Simplă cu $\alpha = 0.9$, ce se întâmplă?

Variante de răspuns

- (A) Prognozele sunt foarte netede și stabile
- (B) Observațiile recente au foarte puțină pondere
- (C) Prognozele reacționează rapid la schimbările recente
- (D) Prognoza este în esență o medie pe termen lung

Răspunsul pe slide-ul următor...

Quiz 3: Răspuns

Răspuns: C – Prognozele reacționează rapid la schimbările recente

Cu $\alpha = 0.9$: $\hat{X}_{t+1} = 0.9X_t + 0.1\hat{X}_t$

- α **mare** (ex. 0.9): 90% pondere pe ultima observație
 - Prognoze foarte receptive la date noi
- α **mic** (ex. 0.1): prognoze mai netede, mai stabile
 - la în calcul mai multe observații din trecut

Quiz 4: Medii mobile

Întrebare

Ce observații folosește o medie mobilă centrată de ordin 5 (MA-5) pentru a estima trendul la momentul t ?

Variante de răspuns


- (A) $X_t, X_{t+1}, X_{t+2}, X_{t+3}, X_{t+4}$
- (B) $X_{t-4}, X_{t-3}, X_{t-2}, X_{t-1}, X_t$
- (C) $X_{t-2}, X_{t-1}, X_t, X_{t+1}, X_{t+2}$
- (D) X_{t-1}, X_t, X_{t+1}

Răspunsul pe slide-ul următor...

Quiz 4: Răspuns

Răspuns: $C - X_{t-2}, X_{t-1}, X_t, X_{t+1}, X_{t+2}$

Moving average: smoothing



- **MA centrată:** folosește $(k - 1)/2$ observații de fiecare parte a lui t
- **MA-5:** 2 înainte + t + 2 după \Rightarrow fereastră mai mare = mai neted

Quiz 5: Evaluarea prognozei

Întrebare

Care metrică este cea mai potrivită pentru compararea acurateții prognozei între serii cu scale diferite?

Variante de răspuns

- (A) Eroarea Absolută Medie (MAE)
- (B) Rădăcina Erorii Medii Pătratice (RMSE)
- (C) Eroarea Absolută Medie Procentuală (MAPE)
- (D) Eroarea Medie Pătratică (MSE)

Răspunsul pe slide-ul următor...

Quiz 5: Răspuns

Răspuns: C – Eroarea Absolută Medie Procentuală (MAPE)

$MAPE = \frac{100}{n} \sum \left| \frac{e_t}{X_t} \right|$ exprimă erorile ca **procente**.

- MAE, RMSE, MSE sunt **dependente de scală** (unități ale lui X_t)
- MAPE este **independentă de scală** (întotdeauna în %)
- Atenție: MAPE devine instabilă când $X_t \approx 0$

 TSA_ch0_forecast_eval

Quiz 6: Validare încrucișată

Întrebare

De ce nu putem folosi validarea încrucișată standard k-fold pentru seriile de timp?


Variante de răspuns

- (A) Datele seriilor de timp sunt prea mici
- (B) Ar încălca ordonarea temporală (viitorul prezicând trecutul)
- (C) Validarea încrucișată este întotdeauna invalidă
- (D) Seriile de timp nu au nevoie de validare

Răspunsul pe slide-ul următor...


Quiz 6: Răspuns

Răspuns: B – Ar încălca ordonarea temporală



Principiu: datele viitoare nu pot fi folosite pentru a prezice trecutul! Se recomandă CV cu fereastră mobilă/în expansiune.

Vizual: Descompunerea seriei de timp



Componentele descompunerii

- **Trend:** mișcare pe termen lung
- Sezonalitate:** tipar periodic
- Reziduu:** zgomot aleatoriu

Afirmație	A/F?
1. Prognozele SES sunt plate (constante pentru toate orizonturile).	?
2. RMSE penalizează erorile mari mai mult decât MAE.	?
3. Descompunerea multiplicativă necesită date pozitive.	?
4. Un α mai mare înseamnă mai multă netezire.	?
5. Setul de test se folosește pentru ajustarea hiperparametrilor.	?
6. Naive sezonier folosește valoarea de acum un sezon.	?
7. MAPE poate fi infinit dacă valorile reale sunt zero.	?

Adevărat sau Fals? — Răspunsuri

Afirmație	A/F	Explicație
1. Prognozele SES sunt plate (constante pentru toate orizonturile).	A	Fără trend
2. RMSE penalizează erorile mari mai mult decât MAE.	A	Erori pătratice
3. Descompunerea multiplicativă necesită date pozitive.	A	Nu se poate \times negativ
4. Un α mai mare înseamnă mai multă netezire.	F	α mare = mai puțin neted
5. Setul de test se folosește pentru ajustarea hiperparametrilor.	F	Folosiți validare!
6. Naive sezonier folosește valoarea de acum un sezon.	A	$\hat{X}_{t+h} = X_{t+h-m}$
7. MAPE poate fi infinit dacă valorile reale sunt zero.	A	Împărțire la zero

Exercițiu 1: Netezire Exponențială Simplă

Problemă

- **Date:** $X = [10, 12, 11, 14, 13]$ cu $\alpha = 0.3$, $\hat{X}_1 = 10$
- **Calculați:** a) Prognozele \hat{X}_2 până la \hat{X}_6 ; b) MAE și RMSE
- **Formula:** $\hat{X}_{t+1} = \alpha X_t + (1 - \alpha)\hat{X}_t$

Soluție

t	1	2	3	4	5	6
X_t	10	12	11	14	13	?
\hat{X}_t	10	10	10.6	10.72	11.70	12.09

- **MAE** = 1.745 **RMSE** = 2.04

Exercițiu 2: Metrici de eroare

Problemă

- **Date:** $X = [100, 110, 105, 120]$, $\hat{X} = [95, 108, 110, 115]$
- **Calculați:** MAE, MSE, RMSE, MAPE

Soluție

- **Erori:** $e = [5, 2, -5, 5]$
- **MAE** $= (|5| + |2| + |-5| + |5|)/4 = 4.25$
- **MSE** $= (25 + 4 + 25 + 25)/4 = 19.75$
- **RMSE** $= \sqrt{19.75} = 4.44$
- **MAPE** $= 25 \times (0.05 + 0.018 + 0.048 + 0.042) = 3.95\%$

Exercițiu 3: Indici sezonieri

Problemă

- **Date:** Indici sezonieri: $S = [0.85, 1.05, 0.90, 1.20]$, Trend T4: $T = 1000$
- **Calculați:** a) Verificați normalizarea. b) Prognoza T4. c) Desezonalizați $X_{T4} = 1150$

Soluție

- a) **Normalizare:** $\sum S_i = 0.85 + 1.05 + 0.90 + 1.20 = 4.00 \checkmark$
- b) **Prognoză:** $\hat{X}_{T4} = 1000 \times 1.20 = \mathbf{1200}$
- c) **Desezonalizare:** $X_{desezonalizat} = 1150/1.20 = \mathbf{958.33}$ (sub trend)

Exercițiu AI: Gândire critică

Prompt de testat în ChatGPT / Claude / Copilot

“Folosind yfinance, descarcă datele SPY. Descompune seria și prognozează anul viitor cu netezire exponențială. Care model e cel mai bun? Arată-mi rezultatele.”

Exercițiu:

- 1 Rulați prompt-ul într-un LLM la alegere și analizați critic răspunsul.
- 2 AI alege descompunere aditivă sau multiplicativă? Alegerea e justificată?
- 3 Cum evaluează modelele — folosește RMSE pe antrenare sau pe test?
- 4 Verificați parametrii de netezire (α , β , γ). Valori aproape de 1,0 sunt problematice?
- 5 Codul împarte corect datele în antrenare/test, sau evaluează pe date de antrenare?

Atenție: Codul generat de AI poate rula fără erori și arăta profesional. *Asta nu înseamnă că e corect.*

Concepte cheie

1. **Serii de timp:** observații ordonate temporal, cu dependență (autocorelație)
2. **Descompunere:** aditivă ($X_t = T_t + S_t + \varepsilon_t$) vs multiplicativă ($X_t = T_t \times S_t \times \varepsilon_t$)
3. **Netezire exponențială:** SES, Holt, Holt-Winters — parametrul α controlează reactivitatea
4. **Evaluarea prognozei:** MAE, RMSE, MAPE — alegerea depinde de context
5. **Sezonalitate:** indici sezonieri, prognoză și desezonalizare

Întrebări?

Fundamente ale seriilor de timp

- Hyndman, R.J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*, 3rd ed., OTexts.
- Shumway, R.H., & Stoffer, D.S. (2017). *Time Series Analysis and Its Applications*, 4th ed., Springer.
- Brockwell, P.J., & Davis, R.A. (2016). *Introduction to Time Series and Forecasting*, 3rd ed., Springer.

Serii de timp financiare

- Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed., Wiley.
- Franke, J., Härdle, W.K., & Hafner, C.M. (2019). *Statistics of Financial Markets*, 4th ed., Springer.

Abordări moderne și Machine Learning

- Nielsen, A. (2019). *Practical Time Series Analysis*, O'Reilly Media.
- Petropoulos, F., et al. (2022). *Forecasting: Theory and Practice*, International Journal of Forecasting.
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition, International Journal of Forecasting.


Resurse online și cod


- **Quantlet**: <https://quantlet.com> — Repository de cod pentru statistică
- **Quantinar**: <https://quantinar.com> — Platformă de învățare metode cantitative
- **GitHub TSA**: https://github.com/QuantLet/TSA/tree/main/TSA_ch0 — Cod Python pentru fiecare capitol

Vă mulțumim!

Întrebări?

Materialele seminarului sunt disponibile la: <https://danpele.github.io/Time-Series-Analysis/>

 Quantlet

 Quantinar