



# Analiza și Prognoza seriilor de timp

## Seminar 1: Procese Stochastice și Staționaritate



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

## Cuprins Seminar

### Structura seminarului:

1. **Prezentare generală** – Rezumatul conceptelor cheie
2. **Test de recapitulare** – Verificarea cunoștințelor
3. **Întrebări Adevărat/Fals** – Verificări conceptuale
4. **Probleme practice** – Practică aplicată
5. **Exemple rezolvate** – Practică de programare
6. **Subiecte de discuție** – Gândire critică
7. **Exerciții cu Inteligență Artificială** – Gândire critică

## Formule Esențiale

### Descompunere:

- ▣ Aditivă:  $X_t = T_t + S_t + \varepsilon_t$
- ▣ Multiplicativă:  $X_t = T_t \times S_t \times \varepsilon_t$

### Netezire Exponențială:

- ▣ SES:  $\hat{X}_{t+1} = \alpha X_t + (1 - \alpha) \hat{X}_t$
- ▣ Holt: adaugă trend  $b_t$
- ▣ HW: adaugă sezonalitate  $S_t$

### Staționaritate:

- ▣  $\mathbb{E}[X_t] = \mu$  (constantă)
- ▣  $\text{Var}(X_t) = \sigma^2$  (constantă)
- ▣  $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$

### Mers aleatoriu:

- ▣  $X_t = X_{t-1} + \varepsilon_t$
- ▣  $\text{Var}(X_t) = t\sigma^2$  (crește cu timpul)

## Sinteză: Concepte și Metode

Concept	Idee principală	Când se aplică
Descompunere aditivă	Amplitudine sezonieră constantă	Varianță stabilă
Descompunere multiplicativă	Sezonalitatea crește cu nivelul	Varianță în creștere
SES	Doar nivel ( $\alpha$ )	Fără trend, fără sezonalitate
Holt	Nivel + Trend ( $\alpha, \beta$ )	Trend, fără sezonalitate
Holt-Winters	Nivel + Trend + Sezonalitate	Trend și sezonalitate
Testul ADF	$H_0$ : rădăcină unitară	Test pentru nestăționaritate
Testul KPSS	$H_0$ : staționară	Confirmă staționaritatea
Diferențiere	Elimină trendul stochastic	Mers aleatoriu, rădăcină unitară
Regresie	Elimină trendul determinist	Trend liniar/polinomial

## Test 1: Staționaritate

### Întrebare

Un proces de mers aleatoriu  $X_t = X_{t-1} + \varepsilon_t$  este:

### Variante de răspuns

- (A) Strict staționar
- (B) Slab staționar
- (C) Nestaționar deoarece varianța crește cu timpul
- (D) Staționar după adăugarea unei constante

*Răspunsul pe slide-ul următor...*


## Test 1: Răspuns

Răspuns: C – Nestaționar deoarece varianța crește cu timpul

Pentru mersul aleatoriu:  $X_t = \sum_{i=1}^t \varepsilon_i$

- $\mathbb{E}[X_t] = 0$  (medie constantă – OK)
- $\text{Var}(X_t) = t\sigma^2$  (varianța depinde de  $t$  – NU e OK!)
  - ▶ Varianța **nu** este constantă  $\Rightarrow$  încalcă staționaritatea
- **Soluție:** diferențierea dă  $\Delta X_t = \varepsilon_t$  — staționară

## Vizual: Mers aleatoriu vs Staționar



- Traiectoriile mersului aleatoriu deviază fără un tipar previzibil
- Varianța crește linear cu timpul  $\Rightarrow$  nestaționar

## Test 2: Teste pentru Rădăcină Unitară

### Întrebare

Rulați testele ADF și KPSS. ADF nu respinge  $H_0$ , iar KPSS respinge  $H_0$ . Ce concluzie rezultă?

### Variante de răspuns

- (A) Seria este staționară
- (B) Seria are o rădăcină unitară (nestaționară)
- (C) Rezultatele sunt neconcludente
- (D) Sunt necesare teste suplimentare

*Răspunsul pe slide-ul următor...*



## Test 2: Răspuns

Răspuns: B – Seria are o rădăcină unitară (nestaționară)

- ▣ ADF:  $H_0$  = rădăcină unitară. Nu respingem  $\Rightarrow$  evidență PENTRU rădăcină unitară
- ▣ KPSS:  $H_0$  = staționară. Respingem  $\Rightarrow$  evidență ÎMPOTRIVA staționarității
  - ▶ Ambele teste confirmă: seria este **nestaționară**
- ▣ **Următorul pas:** diferențiați seria înainte de a modela cu ARMA

## Test 3: Tipuri de Trend

### Întrebare

Un trend determinist poate fi eliminat prin:

### Variante de răspuns

(A) Diferențiere      indent (B) Regresie pe timp      indent (C) Ajustare sezonieră      indent (D)  
Netezire cu medie mobilă

*Răspunsul pe slide-ul următor...*

## Test 3: Răspuns

### Răspuns: B – Regresie pe timp

- ▣ **Trend determinist:**  $Y_t = \alpha + \beta t + \varepsilon_t$  ( $\beta$  fix)
- ▣ **Metoda de eliminare:** regresie  $Y_t$  pe  $t$ , analizați reziduurile  $\hat{\varepsilon}_t$
- ▣ **De ce nu diferențiere?**
  - ▶ Diferențierea dă  $\Delta Y_t = \beta + \Delta \varepsilon_t$  — elimină trendul dar lasă o constantă
  - ▶ Diferențierea este corectă doar pentru trenduri *stochastice* (rădăcini unitare)

## Test 4: Interpretarea ACF

### Întrebare

Dacă ACF-ul unei serii de timp descrește foarte lent (rămâne semnificativ pentru multe lag-uri), aceasta sugerează:



### Variante de răspuns

- (A) Seria este zgomot alb
- (B) Seria este probabil nestaționară
- (C) Seria nu are autocorelație
- (D) Seria este perfect predictibilă

*Răspunsul pe slide-ul următor...*

## Test 4: Răspuns

Răspuns: B – Seria este probabil nestaționară



- **Staționară:** ACF descrește rapid ( $\rho_k = \phi^k \rightarrow 0$ )
- **Nestaționară:** ACF rămâne aproape de 1  $\Rightarrow$  diferențiere necesară

## Test 5: Metoda Holt

### Întrebare

Netezirea exponențială Holt diferă de SES prin adăugarea:



### Variante de răspuns

(A) O componentă sezonieră      indent (B) O componentă de trend      indent (C) O componentă ciclică      indent (D) O componentă neregulată

*Răspunsul pe slide-ul următor...*

## Test 5: Răspuns

Răspuns: B – O componentă de trend



□ **Holt:**  $L_t = \alpha Y_t + (1 - \alpha)(L_{t-1} + b_{t-1}); \quad b_t = \beta(L_t - L_{t-1}) + (1 - \beta)b_{t-1}$

□ **Proгноză:**  $\hat{Y}_{t+h} = L_t + h \cdot b_t$

## Test 6: Zgomot alb

### Întrebare

Care proprietate NU este necesară pentru ca un proces să fie zgomot alb?

### Variante de răspuns


- (A)  $\mathbb{E}[\varepsilon_t] = 0$
- (B)  $\text{Var}(\varepsilon_t) = \sigma^2$  (constantă)
- (C)  $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$  pentru  $t \neq s$
- (D)  $\varepsilon_t \sim N(0, \sigma^2)$

*Răspunsul pe slide-ul următor...*





## Test 6: Răspuns

Răspuns: D – Normalitatea NU este necesară



- **Zgomot alb**: medie zero, varianță constantă, necorelat
- **Zgomot alb Gaussian**: adaugă normalitate  $\Rightarrow$  independent (nu doar necorelat)

## Vizual: Proprietățile Zgomotului Alb



- **Stânga:** zgomotul alb fluctuează în jurul lui zero
- **Dreapta:** ACF nu arată autocorelație (toate valorile  $\approx 0$  după lag 0)

## Test 7: Orizont de Prognoză

### Întrebare

Pe măsură ce orizontul de prognoză  $h$  crește, ce se întâmplă de obicei cu intervalele de prognoză?

### Variante de răspuns

(A) Devin mai înguste  
indent (D) Dispar


indent (B) Rămân la aceeași lățime

indent (C) Devin mai largi

*Răspunsul pe slide-ul următor...*

## Test 7: Răspuns

Răspuns: C – Devin mai largi



- Mers aleatoriu:  $\text{Var} = h\sigma^2$  (crește liniar)
- IC 95%:  $\hat{Y}_{t+h} \pm 1.96\sqrt{h}\sigma$  (se lărgeste cu  $\sqrt{h}$ )

## Test 8: Detectarea Sezonalității

### Întrebare

ACF-ul arată vârfuri semnificative la lag-urile 12, 24 și 36 pentru date lunare. Aceasta sugerează:

### Variante de răspuns

(A) Fără sezonalitate      indent (B) Sezonalitate anuală      indent (C) Sezonalitate săptămânală  
indent (D) Zgomot aleatoriu

*Răspunsul pe slide-ul următor...*

## Test 8: Răspuns

### Răspuns: B – Sezonalitate anuală

- ▣ **Identificarea tiparului:**
  - ▶ Lag 12: corelație cu aceeași lună de anul trecut
  - ▶ Lag 24: aceeași lună de acum doi ani
  - ▶ Lag 36: aceeași lună de acum trei ani
- ▣ **Perioada sezonieră:**  $s = 12$  (date lunare cu ciclu anual)
- ▣ **Exemple tipice:** vânzări cu amănuntul (decembrie), consum de energie (vară/iarnă), turism

## Test 9: Limitarea MAPE

### Întrebare

MAPE (Eroarea Absolută Medie Procentuală) NU ar trebui folosită când:

### Variante de răspuns

- (A) Comparați modele pe același set de date
- (B) Valorile reale pot fi zero sau aproape de zero
- (C) Prognozați prețuri de acțiuni
- (D) Datele au un trend

*Răspunsul pe slide-ul următor...*

## Test 9: Răspuns

Răspuns: B – Când valorile reale pot fi zero sau aproape de zero

- ▣ **Formula:**  $MAPE = \frac{100\%}{n} \sum_{t=1}^n \left| \frac{Y_t - \hat{Y}_t}{Y_t} \right|$
- ▣ **Problema:**  $Y_t \approx 0 \Rightarrow MAPE \rightarrow \infty$
- ▣ **Alternative:**
  - ▶ **SMAPE:**  $\frac{200\%}{n} \sum \frac{|Y_t - \hat{Y}_t|}{|Y_t| + |\hat{Y}_t|}$  (mărginită 0–200%)
  - ▶ **MASE:**  $\frac{1}{n} \sum \frac{|e_t|}{\frac{1}{n-1} \sum |Y_t - Y_{t-1}|}$  (independent de scală)



## Adevărat sau Fals? (Setul 1)

### Întrebare

Marcați fiecare afirmație ca Adevărat (A) sau Fals (F):

1. O serie de timp cu medie constantă este întotdeauna staționară. \_\_\_\_\_
2. Varianța unui mers aleatoriu crește liniar cu timpul. \_\_\_\_\_
3. Un proces staționar poate avea varianță care se schimbă în timp. \_\_\_\_\_
4. Testele ADF și KPSS au aceeași ipoteză nulă. \_\_\_\_\_
5. RMSE mai mic înseamnă întotdeauna prognoze mai bune. \_\_\_\_\_
6. Autocorelația la lag 0 este întotdeauna egală cu 1. \_\_\_\_\_

*Răspunsul pe slide-ul următor...*

## Adevărat sau Fals: Răspunsuri (Setul 1)

1. Medie constantă  $\Rightarrow$  staționară.
2. Var a mersului aleatoriu crește liniar cu  $t$ .
3. Proces staționar poate avea varianță variabilă.
4. ADF și KPSS au aceeași  $H_0$ .
5. RMSE mai mic  $\Rightarrow$  prognoze mai bune.
6.  $\rho(0) = 1$  întotdeauna.

**FALS** — și varianță constantă, covarianță doar de lag

**ADEVĂRAT** —  $\text{Var}(X_t) = t\sigma^2$

**FALS** —  $\text{Var}(X_t) = \sigma^2$  constantă

**FALS** — ADF: rădăcină unitară; KPSS: staționară

**FALS** — dependent de scală

**ADEVĂRAT** —  $\gamma(0)/\gamma(0) = 1$  prin definiție

## Adevărat sau Fals? (Setul 2)

### Întrebare

Marcați fiecare afirmație ca Adevărat (A) sau Fals (F):

1. ACF-ul unui proces AR(1) staționar descrește exponențial. \_\_\_\_\_
2. Zgomotul alb este întotdeauna distribuit normal. \_\_\_\_\_
3. Diferențierea poate face o serie nestaționară să devină staționară. \_\_\_\_\_
4. PACF-ul unui proces MA(1) se anulează după lag 1. \_\_\_\_\_
5. Corelația zero între două variabile implică independență. \_\_\_\_\_
6. Holt-Winters este potrivit pentru date fără sezonalitate. \_\_\_\_\_

*Răspunsul pe slide-ul următor...*

## Adevărat sau Fals: Răspunsuri (Setul 2)

1. ACF-ul unui AR(1) staționar descrește exponențial.
2. Zgomotul alb este întotdeauna normal.
3. Diferențierea poate face o serie nestaționară staționară.
4. PACF-ul unui MA(1) se anulează după lag 1.
5. Corelația zero implică independență.
6. Holt-Winters: potrivit fără sezonalitate.

**ADEVĂRAT** —  $\rho(h) = \phi^h$

**FALS** — Gaussian = caz special

**ADEVĂRAT** — elimină rădăcinile unitare

**FALS** — ACF se anulează, PACF descrește

**FALS** — pot exista relații neliniare

**FALS** — folosiți Holt sau SES

## Exercițiu 1: Autocovarianță

**Enunț:** Pentru un proces staționar cu:  $\mathbb{E}[X_t] = 5$ ,  $\gamma(0) = 4$ ,  $\gamma(1) = 2$ ,  $\gamma(2) = 1$

Calculați:

- a) Funcția de autocorelație  $\rho(0), \rho(1), \rho(2)$
- b)  $\text{Cov}(X_t, X_{t-1})$
- c)  $\text{Corr}(X_5, X_7)$
- d) Dacă  $X_t = 6$ , care este  $\mathbb{E}[X_{t+1}|X_t = 6]$  presupunând AR(1)?

## Exercițiu 1: Soluție

### a) Autocorelații:

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)}$$

$$\square \rho(0) = \gamma(0)/\gamma(0) = 1$$

$$\square \rho(1) = \gamma(1)/\gamma(0) = 2/4 = 0.5$$

$$\square \rho(2) = \gamma(2)/\gamma(0) = 1/4 = 0.25$$

$$\text{b) } \text{Cov}(X_t, X_{t-1}) = \gamma(1) = 2 \quad (\text{prin staționaritate, covarianța la lag 1})$$

$$\text{c) } \text{Corr}(X_5, X_7) = \rho(|7 - 5|) = \rho(2) = 0.25$$

$$\text{d) Pentru AR}(1) \text{ cu } \phi = \rho(1) = 0.5:$$

$$\mathbb{E}[X_{t+1}|X_t] = \mu + \phi(X_t - \mu) = 5 + 0.5(6 - 5) = 5.5$$

## Exercițiu 2: Proprietățile Mersului Aleatoriu

**Enunț:** Considerați un mers aleatoriu  $X_t = X_{t-1} + \varepsilon_t$  unde  $\varepsilon_t \sim WN(0, 4)$  și  $X_0 = 100$ .

Calculați:

- a)  $\mathbb{E}[X_{10}]$
- b)  $\text{Var}(X_{10})$
- c)  $\text{Cov}(X_5, X_{10})$
- d) Intervalul de încredere de 95% pentru  $X_{100}$
- e) Dacă  $X_5 = 108$ , care este prognoza optimală pentru  $X_6$ ?

## Exercițiu 2: Soluție

**Mers aleatoriu:**  $X_t = X_0 + \sum_{i=1}^t \varepsilon_i$  cu  $\sigma^2 = 4$

a)  $\mathbb{E}[X_{10}] = X_0 = 100$  (media rămâne la valoarea de pornire)

b)  $\text{Var}(X_{10}) = 10 \times \sigma^2 = 10 \times 4 = 40$

c)  $\text{Cov}(X_5, X_{10}) = \min(5, 10) \times \sigma^2 = 5 \times 4 = 20$

d) Pentru  $X_{100}$ :

▣  $\mathbb{E}[X_{100}] = 100$ ,  $\text{Var}(X_{100}) = 400$ ,  $SD = 20$

▣ IC 95%:  $100 \pm 1.96 \times 20 = [60.8, 139.2]$

e) Prognoza optimală:  $\hat{X}_6 = X_5 = 108$

(Proprietate a mersului aleatoriu: prognoza optimală este ultima valoare observată)



## Exercițiu Python 1: Import și Vizualizare

**Cerință:** Importați datele S&P 500 și realizați un grafic de bază al seriei de timp.

### Cod inițial

```
import yfinance as yf
import matplotlib.pyplot as plt
sp500 = yf.download('^GSPC', start='2020-01-01', end='2025-01-01')
# TODO: Reprezentați grafic prețurile de închidere
# TODO: Adăugați titlu și etichete
# TODO: Calculați și afișați statistici de bază
```

### Întrebări:

1. Care este media și deviația standard a randamentelor?
2. Seria pare staționară? Argumentați.

## Exercițiu Python 2: Descompunere

**Cerință:** Aplicați descompunerea STL pe datele privind pasagerii aerieni.

### Cod inițial

```
from statsmodels.tsa.seasonal import STL
import pandas as pd

# Încărcați pasagerii aerieni
url = 'https://raw.githubusercontent.com/.../airline.csv'
airline = pd.read_csv(url, parse_dates=['Month'],
                      index_col='Month')

# TODO: Aplicați descompunerea STL cu period=12
# TODO: Reprezentați grafic toate componentele
# TODO: Ce procent din varianță este explicat de trend?
```

**Indicație:** `STL(data, period=12).fit()`

## Exercițiu Python 3: Netezire Exponențială

**Cerință:** Comparați metodele SES, Holt și Holt-Winters pe date reale.

### Cod inițial

```
from statsmodels.tsa.holtwinters import (SimpleExpSmoothing,
    ExponentialSmoothing)

# Împărțiți datele: 80% antrenare, 20% test
train = airline[:'1958']
test = airline['1959':]

# TODO: Ajustați SES, Holt și Holt-Winters
# TODO: Generați prognoze pentru perioada de test
# TODO: Calculați RMSE pentru fiecare metodă
# TODO: Care metodă are cele mai bune performanțe? De ce?
```

## Exercițiu Python 4: Testarea Staționarității

**Cerință:** Verificați staționaritatea prin testele ADF și KPSS.


### Cod inițial

```
from statsmodels.tsa.stattools import adfuller, kpss
prices = sp500['Close']
returns = prices.pct_change().dropna()
# TODO: Rulați testul ADF pe prețuri și randamente
# TODO: Rulați testul KPSS pe prețuri și randamente
# TODO: Interpretați rezultatele
# ADF: adfuller(series) | KPSS: kpss(series, regression='c')
```

### Întrebări:

1. Prețurile sunt staționare? Randamentele sunt staționare?
2. Rezultatele ADF și KPSS converg?


## Studiu de Caz: Indicele S&P 500



### Observații

- ▣ **Sus:** Prețuri S&P 500 — trend ascendent clar (nestaționar)
- ▣ **Jos:** Randamente  $r_t = \log(P_t/P_{t-1})$  — staționare, fluctuații în jurul mediei zero
- ▣ Grupare vizibilă a volatilității



## Descompunerea Seriilor de Timp: Exemplu Real



### Observații

- ▣ **Trend:** Direcția pe termen lung; **Sezonalitate:** Modele periodice regulate
- ▣ **Reziduu:** Ce rămâne după eliminarea trendului și sezonality
- ▣ Descompunerea  $\Rightarrow$  înțelegerea structurii înainte de modelare

## Testarea Staționarității: Rezultate ADF



### Observații

- ▣ ADF compară statistica de test cu valorile critice;  $\text{stat. test} < \text{val. critică} \Rightarrow \text{respingem } H_0$  (staționară)
- ▣ **Prețuri:**  $\text{ADF} > -2.86 \Rightarrow \text{nestaționară}$
- ▣ **Randamente:**  $\text{ADF} < -2.86 \Rightarrow \text{staționară}$

## Comparație Staționaritate: Prețuri vs Randamente

### Rezultate Test ADF


Serie	Statistică ADF	valoare-p	Concluzie
Prețuri S&P 500	-0.82	0.812	Nestaționară
Randamente S&P 500	-45.3	< 0.001	Staționară

### Observație Cheie

- Prețurile financiare sunt de obicei  $I(1)$  – integrate de ordinul 1
- Diferențele de ordinul întâi (randamente)  $\Rightarrow$  staționaritate
- De aceea modelăm **randamentele**, nu prețurile!



## Proгноză cu Netezire Exponențială



### Observații

- Holt-Winters: date cu trend + sezonalitate;  $\alpha, \beta, \gamma$  controlează adaptabilitatea
- Surprinde trendul și sezonalitatea — simplă, dar eficientă pentru aplicații practice

## Întrebare de Discuție 1

### Scenariu

- ▣ Date lunare de vânzări pentru o companie de retail
- ▣ Sezonality clară (vânzări ridicate în decembrie) + trend ascendent
- ▣ Vârfurile sezoniere au devenit mai mari în timp

### Discutați:

1. Descompunere aditivă sau multiplicativă? Argumentați.
2. Ce metodă de netezire exponențială ați recomanda?
3. Cum evaluați performanța prognozei?
4. Ce riscuri implică alegerea greșită a descompunerii?

## Întrebare de Discuție 2

### Scenariu

Un coleg afirmă:

- ☐ „Am rulat testul ADF pe datele mele de prețuri de acțiuni"
- ☐ „Am obținut o valoare-p de 0.65"
- ☐ „Deci datele mele sunt staționare și pot ajusta direct un model ARMA"

### Discutați:

1. Unde greșește raționamentul?
2. Care sunt ipotezele testului ADF?
3. Ce pași ar trebui urmați înainte de a estima un model ARMA?
4. Ce rol joacă testul KPSS în clarificarea situației?

## Întrebare de Discuție 3

### Scenariu

- ▣ Construiți un model de prognoză: MAPE de 2%
- ▣ Managerul este impresionat și vrea implementare imediată

### Discutați:

1. Ce verificări sunt necesare înainte de implementare?
2. Împărțirea antrenare/validare/test este corectă?
3. Există riscul contaminării datelor (*data leakage*)?
4. Ce verificări suplimentare sunt necesare?
5. Cum monitorizați performanța modelului în producție?

## Întrebare de Discuție 4

### Scenariu

Proгноza cererii zilnice de electricitate pentru săptămâna următoare:

- ▣ Tipare zilnice pronunțate (vârfuri la ora 18)
- ▣ Tipare săptămânale (mai scăzut în weekend)
- ▣ Tipare anuale (mai ridicat vara/iarna)

### Discutați:

1. Cum abordați sezonalitatea multiplă?
2. Este Holt-Winters adecvat? Argumentați.
3. Care este avantajul termenilor Fourier în acest caz?
4. Cum organizați eșantioanele de antrenare/validare/test?

## Exercițiu AI: Gândire critică

Prompt de testat în ChatGPT / Claude / Copilot

“Folosind yfinance, descarcă seria de prețuri BTC-USD. Seria de prețuri este staționară? Dacă nu, transformă seria astfel încât să devină staționară. Pot folosi seria randamentelor pentru a prezice prețul viitor? Arată-mi.”

**Exercițiu:**

1. Rulați prompt-ul într-un LLM la alegere și analizați critic răspunsul.
2. AI interpretează corect ipotezele nule ale testelor ADF și KPSS?
3. Se oprește la prima diferențiere sau supra-diferențiază? De ce contează?
4. Verificați concluzia despre randamente — “zgomot alb” înseamnă “fără structură”?
5. Ține cont de clusterizarea volatilității (efecte ARCH) în randamente?

**Atenție:** Codul generat de AI poate rula fără erori și arăta profesional. *Asta nu înseamnă că e corect.*

## Concluzii

- ▣ **Seriile de timp sunt dependente**
  - ▶ Nu i.i.d. ca datele transversale — autocorelația este cheia
- ▣ **Alegeți corect tipul de descompunere**
  - ▶ Multiplicativă când amplitudinea sezonieră crește cu nivelul
- ▣ **Înțelegeți parametrii de netezire**
  - ▶  $\alpha$  mare = reactiv,  $\alpha$  mic = neted
- ▣ **Testați staționaritatea**
  - ▶ Folosiți atât ADF cât și KPSS împreună
- ▣ **Evaluare corectă**
  - ▶ Nu antrenați niciodată pe setul de test!
- ▣ **Mersul aleatoriu este nestaționar**
  - ▶ Varianța crește cu timpul:  $\text{Var}(X_t) = t\sigma^2$

### Următorul Seminar

- ▣ Identificarea, estimarea și prognoza modelelor ARMA/ARIMA

## Surse de Date și Software

### Instrumente Software:

- ▣ statsmodels – Modele statistice pentru Python
- ▣ pandas – Manipulare date și serii de timp
- ▣ matplotlib, seaborn – Vizualizare
- ▣ scipy – Funcții statistice

### Date și Exemple:

- ▣ Serii de timp simulate pentru ilustrații
- ▣ Exemple bazate pe Hyndman & Athanasopoulos (2021)



## Bibliografie I

### Manuale fundamentale

- ▣ Hyndman, R.J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*, 3rd ed., OTexts.
- ▣ Shumway, R.H., & Stoffer, D.S. (2017). *Time Series Analysis and Its Applications*, 4th ed., Springer.
- ▣ Brockwell, P.J., & Davis, R.A. (2016). *Introduction to Time Series and Forecasting*, 3rd ed., Springer.

### Serii de timp financiare

- ▣ Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed., Wiley.
- ▣ Franke, J., Härdle, W.K., & Hafner, C.M. (2019). *Statistics of Financial Markets*, 4th ed., Springer.

## Bibliografie II

### Abordări moderne și Machine Learning

- ▣ Nielsen, A. (2019). *Practical Time Series Analysis*, O'Reilly Media.
- ▣ Petropoulos, F., et al. (2022). *Forecasting: Theory and Practice*, International Journal of Forecasting.
- ▣ Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition, International Journal of Forecasting.

### Resurse online și cod


- ▣ **Quantlet**: <https://quantlet.com> — Repository de cod pentru statistică
- ▣ **Quantinar**: <https://quantinar.com> — Platformă de învățare metode cantitative
- ▣ **GitHub TSA**: [https://github.com/QuantLet/TSA/tree/main/TSA\\_ch1](https://github.com/QuantLet/TSA/tree/main/TSA_ch1) — Cod Python pentru fiecare capitol

# Vă mulțumim!

## Întrebări?

Materialele seminarului sunt disponibile la:

<https://danpele.github.io/Time-Series-Analysis/>

 Quantlet

 Quantinar