

Analiza și Prognoza Seriilor de Timp

# Capitolul 2: Modele ARMA

Seminar





## Test 1: Operatorul Lag

### Întrebare

Care este rezultatul aplicării  $(1 - L)^2$  lui  $X_t$ ?

- A.  $X_t - X_{t-1}$
- B.  $X_t - 2X_{t-1} + X_{t-2}$
- C.  $X_t + X_{t-1} + X_{t-2}$
- D.  $X_t - X_{t-2}$

# Test 1: Răspuns

Răspuns: B

$$X_t - 2X_{t-1} + X_{t-2}$$

Explicație:

$$\begin{aligned}(1 - L)^2 X_t &= (1 - 2L + L^2) X_t \\ &= X_t - 2X_{t-1} + X_{t-2}\end{aligned}$$

Aceasta este diferența de ordinul doi a lui  $X_t$ .



Operatorul lag:  $L^k X_t = X_{t-k}$

TSA\_ch2\_lag\_operator

## Test 2: Staționaritatea AR(1)

### Întrebare

Pentru ce valoare a lui  $\phi$  procesul AR(1)  $X_t = 0.5 + \phi X_{t-1} + \varepsilon_t$  este staționar?

- A.  $\phi = 1.2$
- B.  $\phi = 1.0$
- C.  $\phi = -0.8$
- D.  $\phi = -1.5$

## Test 2: Răspuns

Răspuns: C

$\phi = -0.8$  (Staționar)

Condiția de staționaritate AR(1):

$$|\phi| < 1$$

Verificarea fiecărei opțiuni:

- A:  $|1.2| = 1.2 > 1$  ✗
- B:  $|1.0| = 1$  (rădăcină unitară) ✗
- C:  $|-0.8| = 0.8 < 1$  ✓
- D:  $|-1.5| = 1.5 > 1$  ✗

ch2\_ar1.pdf

AR(1): regiunea staționară  $|\phi| < 1$

### Întrebare

Observați următorul model ACF: vârf semnificativ la lag 1, apoi toate lag-urile în benzile de încredere. PACF arată descreștere graduală. Ce model este sugerat?

- A. AR(1)
- B. MA(1)
- C. ARMA(1,1)
- D. Zgomot alb

## Test 3: Răspuns

Răspuns: B

MA(1)

Regula cheie de identificare:

- ACF se anulează după lag  $q \Rightarrow \text{MA}(q)$
- PACF se anulează după lag  $p \Rightarrow \text{AR}(p)$

Aici: ACF se anulează la lag 1, PACF descrește  
 $\Rightarrow$  **MA(1)**

ch2\_ma1.pdf

MA(1): ACF se anulează după lag 1



## Test 4: Invertibilitatea MA

### Întrebare

Pentru procesul MA(1)  $X_t = \varepsilon_t + 1.5\varepsilon_{t-1}$ , este procesul invertibil?

- ☐ A. Da, deoarece procesele MA sunt întotdeauna invertibile
- ☐ B. Da, deoarece  $1.5 > 0$
- ☐ C. Nu, deoarece  $|\theta| = 1.5 > 1$
- ☐ D. Nu, deoarece procesele MA nu sunt niciodată invertibile

## Test 4: Răspuns

Răspuns: C

Nu este invertibil ( $|\theta| = 1.5 > 1$ )

**Invertibilitatea MA(1):**

Necesită  $|\theta| < 1$

Echivalent: rădăcina lui  $\theta(z) = 1 + \theta z = 0$  trebuie să fie în afara cercului unitate.

Aici:  $z = -1/1.5 = -0.67$  este în interior!

⇒ **Nu este invertibil**

ch2\_ma1.pdf

## Test 5: Reprezentarea ARMA

### Întrebare

Forma compactă  $\phi(L)X_t = \theta(L)\varepsilon_t$  reprezintă ce model?

- ☐ A. Model AR pur
- ☐ B. Model MA pur
- ☐ C. Model ARMA
- ☐ D. Niciunul dintre cele de mai sus

## Test 5: Răspuns

Răspuns: C

Model ARMA

**Notăția cu polinoame lag:**

- $\phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p$
- $\theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q$

**Cazuri speciale:**

- $\theta(L) = 1$ : AR pur
- $\phi(L) = 1$ : MA pur

ch2\_arma.pdf

### Întrebare

Când comparăm  $ARMA(1,1)$  și  $ARMA(2,1)$  folosind BIC, care afirmație este corectă?

- ☐ A. BIC mai mic înseamnă întotdeauna prognoze mai bune
- ☐ B. BIC penalizează complexitatea mai puțin decât AIC
- ☐ C. Modelul cu BIC mai mic este preferat
- ☐ D. BIC poate compara doar modele cu același număr de parametri

## Test 6: Răspuns

Răspuns: C

Modelul cu BIC mai mic este preferat


Criterii Informaționale:

$$\text{AIC} = -2 \ln(\hat{L}) + 2k$$

$$\text{BIC} = -2 \ln(\hat{L}) + k \ln(n)$$

BIC penalizează complexitatea **mai mult** decât AIC (pentru  $n > 7$ ).

⇒ BIC favorizează modele mai simple.



Selecția modelului: AIC vs BIC

## Test 7: Testul Ljung-Box

### Întrebare

După ajustarea unui model ARMA(2,1), rulați testul Ljung-Box pe reziduuri și obțineți valoare- $p = 0.02$ . Ce concluzie trageți?

- ☐ A. Modelul este adecvat
- ☐ B. Reziduurile sunt zgomot alb
- ☐ C. Există autocorelație semnificativă în reziduuri
- ☐ D. Modelul are prea mulți parametri

## Test 7: Răspuns

Răspuns: C

Autocorelație semnificativă în reziduuri

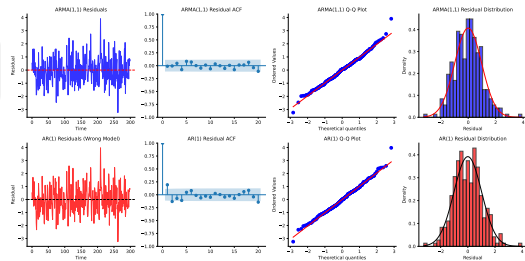
### Testul Ljung-Box:

- $H_0$ : Reziduurile sunt zgomot alb
- $H_1$ : Autocorelație prezentă

valoare-p = 0.02 < 0.05

⇒ **Respingem  $H_0$**

Modelul este **inadecvat** — încercați alte ordine.



Diagnostic: ACF trebuie să fie zgomot alb



## Test 8: Prognoză

### Întrebare

Pentru un model AR(1) cu  $\phi = 0.6$  și medie  $\mu = 10$ , ce se întâmplă cu prognozele când orizontul  $h \rightarrow \infty$ ?

- ☐ A. Prognozele cresc fără limită
- ☐ B. Prognozele converg la 0
- ☐ C. Prognozele converg la  $\mu = 10$
- ☐ D. Prognozele oscilează pentru totdeauna

## Test 8: Răspuns

Răspuns: C

Proгноzele converg la  $\mu = 10$

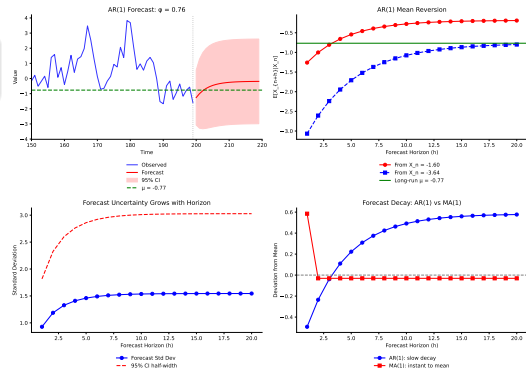
Formula de prognoză AR(1):

$$\hat{X}_{n+h|n} = \mu + \phi^h(X_n - \mu)$$

Deoarece  $|\phi| = 0.6 < 1$ :

$$\lim_{h \rightarrow \infty} \phi^h = 0$$

$\Rightarrow$  Proгноzele converg la  $\mu$ .  
Revenire la medie!



Proгноze AR(1): revenire la medie

TSA\_ch2\_forecasting

## Test 9: Rădăcinile AR(2)

### Întrebare

Un proces AR(2) are rădăcinile caracteristice  $z_1 = 0.8$  și  $z_2 = -0.5$ . Este staționar?

- ☐ A. Da, deoarece ambele rădăcini sunt în interiorul cercului unitate
- ☐ B. Nu, deoarece o rădăcină este negativă
- ☐ C. Nu, deoarece rădăcinile trebuie să fie în afara cercului unitate
- ☐ D. Nu se poate determina fără mai multe informații

## Test 9: Răspuns

Răspuns: C

Rădăcinile trebuie să fie în afara cercului unitate

**Condiția de staționaritate:**

Rădăcinile lui  $\phi(z) = 0$  trebuie să fie **în afara** cercului unitate ( $|z| > 1$ ).

Aici:

- $|z_1| = 0.8 < 1$  ✗
- $|z_2| = 0.5 < 1$  ✗

Ambele în interior  $\Rightarrow$  **Nestaționar**

ch2\_ar2.pdf

## Test 10: Proprietățile MA(q)

### Întrebare

Pentru un proces MA(2), ACF-ul:

- ☐ A. Descrește exponențial
- ☐ B. Se anulează după lag 2
- ☐ C. Se anulează după lag 1
- ☐ D. Nu se anulează niciodată

## Test 10: Răspuns

Răspuns: B

Se anulează după lag 2

**Proprietatea ACF pentru  $MA(q)$ :**

$$\rho(h) = 0 \text{ pentru } h > q$$

- $MA(1)$ : ACF se anulează după lag 1
- $MA(2)$ : ACF se anulează după lag 2
- $MA(q)$ : ACF se anulează după lag  $q$

Caracteristica cheie de identificare!

ch2\_ma1.pdf

Afirmație	A/F?
1. Un proces AR(2) poate prezenta comportament pseudo-ciclic.	?
2. Procesele MA necesită o condiție de staționaritate.	?
3. PACF-ul unui proces AR(p) se anulează după lag $p$ .	?
4. Dacă AIC selectează ARMA(2,1) și BIC selectează ARMA(1,1), nu pot fi ambele corecte.	?
5. Intervalele de încredere se îngustează pe măsură ce orizontul crește.	?
6. Ecuațiile Yule-Walker pot fi folosite pentru a estima parametrii MA.	?

## Adevărat sau Fals? — Răspunsuri

- 1 **ADEVĂRAT**: AR(2) cu rădăcini complexe  $\Rightarrow$  oscilații amortizate
- 2 **FALS**: Procesele MA sunt întotdeauna staționare; au nevoie de *invertibilitate*
- 3 **ADEVĂRAT**: Caracteristica cheie de identificare a AR( $p$ )
- 4 **FALS**: Ambele sunt „corecte” pentru criteriile lor (AIC: estimare, BIC: parcimonie)
- 5 **FALS**: IC se *lărgesc* cu orizontul (mai multă incertitudine)
- 6 **FALS**: Yule-Walker este pentru AR; MA folosește MLE

ch2\_ar2.pdf

AR(2): rădăcini complexe  $\Rightarrow$  cicluri



## Exercițiul 1: Proprietățile AR(1)

**Problemă:** Considerați procesul AR(1):

$$X_t = 2 + 0.7X_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim WN(0, 9)$$

Calculați:

- ❶ Media  $\mu$
- ❷ Varianța  $\gamma(0)$
- ❸ Autocovarianța  $\gamma(1)$  și  $\gamma(2)$
- ❹ Autocorelația  $\rho(1)$  și  $\rho(2)$

# Exercițiul 1: Soluție

Dat:  $c = 2$ ,  $\phi = 0.7$ ,  $\sigma^2 = 9$

## 1. Media:

$$\mu = \frac{c}{1-\phi} = \frac{2}{1-0.7} = \frac{2}{0.3} = \mathbf{6.67}$$

## 2. Varianța:

$$\gamma(0) = \frac{\sigma^2}{1-\phi^2} = \frac{9}{1-0.49} = \mathbf{17.65}$$


## 3. Autocovarianța:

$$\gamma(1) = \phi \cdot \gamma(0) = 0.7 \times 17.65 = \mathbf{12.35}$$

$$\gamma(2) = \phi^2 \cdot \gamma(0) = 0.49 \times 17.65 = \mathbf{8.65}$$

## 4. Autocorelația:

$$\rho(1) = \phi = \mathbf{0.7}, \quad \rho(2) = \phi^2 = \mathbf{0.49}$$



Simulare AR(1) și ACF

AR(1) Solution Summary	
Model: $X_t = 2 + 0.7X_{t-1} + \epsilon_t$ $\epsilon_t \sim \text{WN}(0, 9)$	
Results:	
1. Mean:	
$\mu = c/(1-\phi) = 2/(1-0.7) = 6.6667$	
2. Variance:	
$\gamma(0) = \sigma^2/(1-\phi^2) = 9/(0.51) = 17.6471$	
3. Autocovariance:	
$\gamma(1) = \phi \cdot \gamma(0) = 0.7 \times 17.65 = 12.3529$	
$\gamma(2) = \phi^2 \cdot \gamma(0) = 0.48999999999999994 \times 17.65 = 8.6471$	
4. Autocorrelation:	
$\rho(1) = \phi = 0.7$	
$\rho(2) = \phi^2 = 0.48999999999999994$	

## Exercițiul 2: Proprietățile MA(1)

**Problemă:** Considerați procesul MA(1):

$$X_t = 5 + \varepsilon_t - 0.4\varepsilon_{t-1}, \quad \varepsilon_t \sim WN(0, 4)$$

Calculați:

- ❶ Media  $\mu$
- ❷ Varianța  $\gamma(0)$
- ❸ Autocovarianța  $\gamma(1)$
- ❹ Autocorelația  $\rho(1)$
- ❺ Este acest proces invertibil?

## Exercițiul 2: Soluție

Dat:  $\mu = 5$ ,  $\theta = -0.4$ ,  $\sigma^2 = 4$

1. Media:

$$\mathbb{E}[X_t] = \mu = 5$$

2. Variația:

$$\gamma(0) = \sigma^2(1 + \theta^2) = 4(1.16) = 4.64$$


3. Autocovarianța:

$$\gamma(1) = \theta\sigma^2 = -0.4 \times 4 = -1.6$$

4. Autocorelația:

$$\rho(1) = \frac{\gamma(1)}{\gamma(0)} = \frac{-1.6}{4.64} = -0.345$$

5. Invertibilitate:  $|\theta| = 0.4 < 1 \Rightarrow$  **Da**



MA(1) Solution Summary	
Model: $X_t = 5 + \epsilon_t + (-0.4)\epsilon_{t-1}$ $\epsilon_t \sim \text{WN}(0, 4)$	
Results:	
1. Mean:	$\mathbb{E}[X_t] = 5$
2. Variance:	$\gamma(0) = \sigma^2(1+\theta^2) = 4(1.16) = 4.64$
3. Autocovariance at lag 1:	$\gamma(1) = \theta\sigma^2 = -0.4 \times 4 = -1.6$
4. Autocorrelation:	$\rho(1) = \theta/(1+\theta^2) = -0.3448$ $\rho(h) = 0$ for $h \geq 1$
5. Invertibility:	$ \theta  = 0.4 < 1$ - INVERTIBLE ✓

MA(1): ACF se anulează după lag 1

## Exercițiul 3: Rădăcinile Caracteristice

**Problemă:** Considerați procesul AR(2):

$$X_t = 0.5X_{t-1} + 0.3X_{t-2} + \varepsilon_t$$

- 1 Scrieți ecuația caracteristică
- 2 Găsiți rădăcinile caracteristice
- 3 Este acest proces staționar?

## Exercițiul 3: Soluție

### 1. Ecuația caracteristică:

$$\phi(z) = 1 - 0.5z - 0.3z^2 = 0$$

$$\text{Sau: } 0.3z^2 + 0.5z - 1 = 0$$

### 2. Rădăcinile (formula quadratică):

$$z = \frac{-0.5 \pm \sqrt{0.25 + 1.2}}{0.6}$$


$$z_1 = 1.17, \quad z_2 = -2.84$$

### 3. Verificarea staționarității:

$$|z_1| = 1.17 > 1 \quad \checkmark$$

$$|z_2| = 2.84 > 1 \quad \checkmark$$

Ambele în afara cercului unitate  $\Rightarrow$  **Staționar**



Rădăcini în afara cercului  $\Rightarrow$  staționar

## Exercițiul 4: Prognoză

**Problemă:** Ați ajustat un model AR(1):

$$X_t = 3 + 0.8X_{t-1} + \varepsilon_t, \quad \sigma^2 = 4$$

Dat  $X_{100} = 20$ , calculați:

- ❶ Prognoza la 1 pas înainte  $\hat{X}_{101|100}$
- ❷ Prognoza la 2 pași înainte  $\hat{X}_{102|100}$
- ❸ Prognoza pe termen lung când  $h \rightarrow \infty$
- ❹ Intervalul de încredere de 95% pentru  $\hat{X}_{101|100}$

## Exercițiul 4: Soluție

Dat:  $c = 3$ ,  $\phi = 0.8$ ,  $\sigma^2 = 4$ ,  $X_{100} = 20$

Media:  $\mu = \frac{3}{1-0.8} = 15$

### 1. Prognoza la un pas:

$$\hat{X}_{101|100} = 3 + 0.8 \times 20 = 19$$

### 2. Prognoza la doi pași:


$$\hat{X}_{102|100} = 3 + 0.8 \times 19 = 18.2$$

### 3. Prognoza pe termen lung:

$$\lim_{h \rightarrow \infty} \hat{X}_{100+h|100} = \mu = 15$$

### 4. IC 95%:

$$19 \pm 1.96 \times 2 = [15.08, 22.92]$$



Prognoza converge la medie



# Exercițiu Python 1: Simulare și Ajustare AR(1)

## Sarcină:

- 1 Simulați 300 de observații dintr-un AR(1) cu  $\phi = 0.6$
- 2 Reprezentați grafic seria și ACF/PACF
- 3 Ajustați un model AR(1) și comparați  $\hat{\phi}$  vs  $\phi$  real
- 4 Examinați diagnosticele reziduurilor

## Cod cheie:

```
from statsmodels.tsa.arima.model import ARIMA
model = ARIMA(x, order=(1, 0, 0)).fit()
print(model.summary())
```

## Exercițiu Python 2: Selecția Modelului

### Sarcină:

- 1 Încărcați o serie de timp și verificați staționaritatea (testul ADF)
- 2 Comparați AIC/BIC pentru AR(1), MA(1), ARMA(1,1), ARMA(2,1)
- 3 Selectați cel mai bun model
- 4 Generați prognoze cu intervale de încredere

### Funcții cheie:

- `adfuller(x)` pentru testul de staționaritate
- `model.aic`, `model.bic` pentru criterii
- `model.get_forecast(h)` pentru predicții

## Exercițiu Python 3: Verificarea Diagnosticelor

**Sarcină:** După ajustarea unui model, efectuați diagnostice complete:

- 1 Reprezentați grafic reziduurile în timp
- 2 Reprezentați grafic ACF-ul reziduurilor
- 3 Creați graficul Q-Q pentru normalitate
- 4 Rulați testul Ljung-Box

**Funcții cheie:**

- `model.resid` pentru reziduuri
- `plot_acf(resid)` pentru graficul ACF
- `stats.probplot(resid)` pentru graficul Q-Q
- `acorr_ljungbox(resid, lags=[10])` pentru test

## Discuție 1: Selecția Modelului

**Scenariu:** Modelați rate de inflație lunare. După verificarea staționarității:

- ACF: semnificativ la lag-urile 1, 2, 3, apoi descrește
- PACF: semnificativ la lag-urile 1, 2, apoi se anulează
- AIC selectează ARMA(2,3)
- BIC selectează AR(2)

**Întrebări:**

- 1 Ce sugerează modelul ACF/PACF?
- 2 De ce nu sunt de acord AIC și BIC?
- 3 Ce model ați alege și de ce?
- 4 Ce verificări suplimentare ați efectua?

## Discuție 2: Evaluarea Prognozei

**Scenariu:** Ajustați un model ARMA(1,1) pe randamente zilnice de acțiuni. Ajustarea în eșantion arată bine (Ljung-Box  $p = 0.45$ ), dar RMSE în afara eșantionului este mai rău decât mersul aleatoriu.

### Întrebări:

- 1 Este aceasta surprinzător? De ce sau de ce nu?
- 2 Ce ne spune despre predictibilitatea randamentelor?
- 3 Ar trebui să concluzionați că modelul ARMA este inutil?
- 4 Ce alternative ați putea considera?

**Indiciu:** Gândiți-vă la Ipoteza Pieței Eficiente și la ce captează ARMA vs. gruparea volatilității.

Concept	Formula
Media AR(1)	$\mu = c/(1 - \phi)$
Varianța AR(1)	$\gamma(0) = \sigma^2/(1 - \phi^2)$
ACF AR(1)	$\rho(h) = \phi^h$
Staționaritate AR(1)	$ \phi  < 1$
Varianța MA(1)	$\gamma(0) = \sigma^2(1 + \theta^2)$
ACF MA(1)	$\rho(1) = \theta/(1 + \theta^2), \rho(h) = 0$ pentru $h > 1$
Invertibilitate MA(1)	$ \theta  < 1$
Prognoza AR(1)	$\hat{X}_{n+h n} = \mu + \phi^h(X_n - \mu)$
IC Prognoză	$\hat{X} \pm z_{\alpha/2} \times \sqrt{\text{MSFE}(h)}$
AIC	$-2 \ln(\hat{L}) + 2k$
BIC	$-2 \ln(\hat{L}) + k \ln(n)$

# Întrebări?

Succes la exerciții!

**Următorul Seminar:** ARIMA și Modele Sezoniere