



# Analiza și Prognoza seriilor de timp

Seminar 4: Modele SARIMA



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

## Cuprins Seminar

### Structura seminarului:

- 1. Prezentare Generală** – Rezumatul conceptelor cheie
- 2. Test de Recapitulare** – Verificarea cunoștințelor
- 3. Întrebări Adevărat/Fals** – Verificări conceptuale
- 4. Probleme Practice** – Practică aplicată
- 5. Exemple Rezolvate** – Soluții detaliate
- 6. Analiză pe Date Reale** – Aplicații empirice
- 7. Subiecte de Discuție** – Gândire critică
- 8. Rezumat** – Sinteză finală
- 9. Exerciții AI** – Inteligență artificială aplicată
- 10. Formule cheie** – Referință rapidă



## Test 1: Diferențierea Sezonieră

### Întrebare

Pentru date lunare cu sezonalitate anuală, ce face operatorul  $(1 - L^{12})$ ?

### Variante de răspuns

- (A)** la 12 diferențe consecutive      indent **(B)** Calculează  $Y_t - Y_{t-12}$       indent **(C)** Face media pe 12 luni      indent **(D)** Elimină primele 12 observații



## Test 1: Diferențierea Sezonieră

### Întrebare

Pentru date lunare cu sezonialitate anuală, ce face operatorul  $(1 - L^{12})$ ?

### Variante de răspuns

- (A) Ia 12 diferențe consecutive indent (B) Calculează  $Y_t - Y_{t-12}$  indent (C) Face media pe 12 luni indent (D) Elimină primele 12 observații

Răspuns: B – Calculează  $Y_t - Y_{t-12}$

**Operatorul de diferență sezonieră:**

$$(1 - L^{12})Y_t = Y_t - L^{12}Y_t = Y_t - Y_{t-12}$$

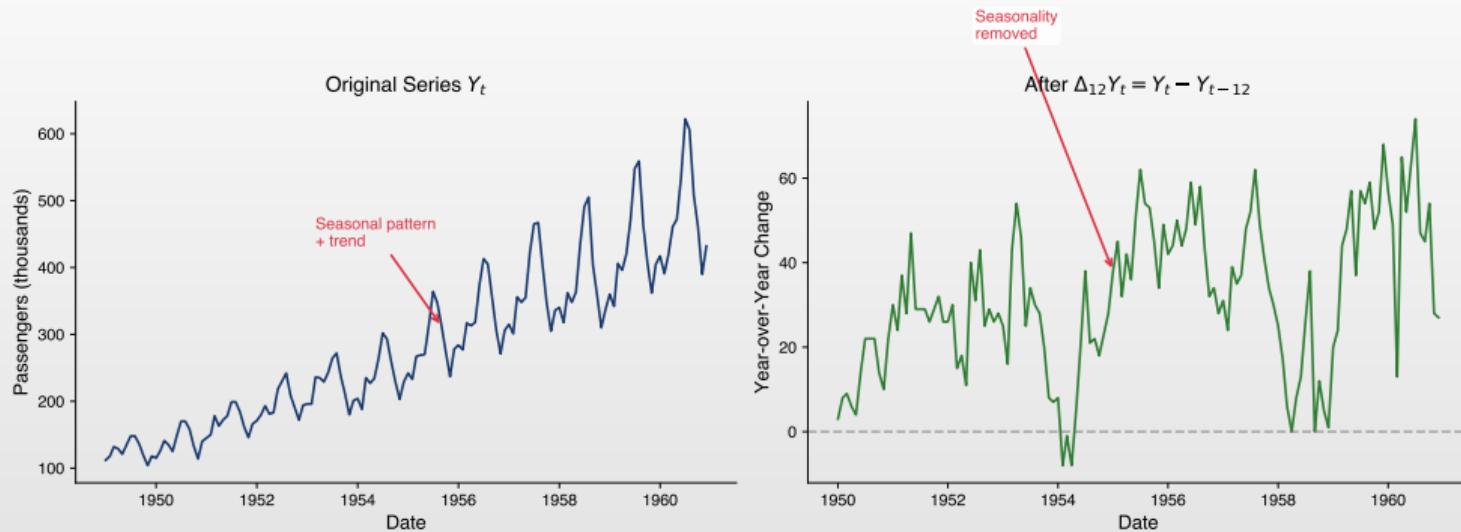
**Exemplu** (vânzări ianuarie):  $Y_{Jan2025} - Y_{Jan2024}$

**Efect:** Elimină modelul sezonier anual stabil

**Notă:**  $(1 - L^s)$  pentru orice perioadă sezonieră  $s$  (trimestrial:  $s = 4$ , săptămânal:  $s = 52$ )



## Vizual: Diferența Sezonieră



Diferențierea sezonieră elimină modelele anuale comparând aceleași perioade între ani.

TSA\_ch4\_def\_seasonal\_diff



## Test 2: Notația SARIMA

### Întrebare

Ce reprezintă SARIMA(1, 1, 1)  $\times$  (1, 1, 1)<sub>12</sub>?

### Variante de răspuns

- (A) 12 modele ARIMA diferite
- (B) ARIMA cu 12 termeni AR și 12 termeni MA
- (C) ARIMA(1,1,1) cu ARIMA(1,1,1) sezonier la perioada 12
- (D) Un model care necesită 12 ani de date



## Test 2: Răspuns

Răspuns: C – ARIMA(1,1,1) cu ARIMA(1,1,1) sezonier la perioada 12

### SARIMA( $p, d, q$ ) $\times (P, D, Q)_s$ Notation

$$\phi(L)\Phi(L^s)(1-L)^d(1-L^s)^D Y_t = \theta(L)\Theta(L^s)\varepsilon_t$$

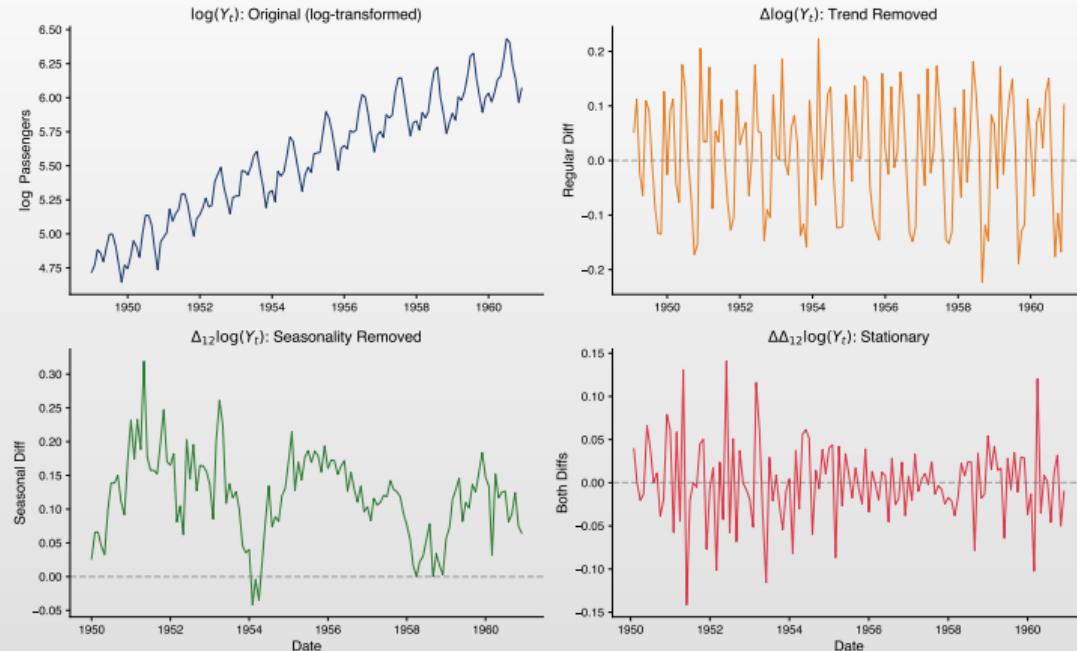
Regular (Non-Seasonal)			Seasonal		
$p$	= AR order	(Number of AR lags)	$P$	= Seasonal AR	(SAR lags at s, 2s, ...)
$d$	= Differencing	(Regular differences)	$D$	= Seasonal Diff	$((1-L^s)^D)$
$q$	= MA order	(Number of MA lags)	$Q$	= Seasonal MA	(SMA lags at s, 2s, ...)
			$s$	= Period	(Seasonal period)

Example: SARIMA(1, 1, 1)  $\times (0, 1, 1)_{12}$

Monthly data with: AR(1), MA(1), one regular diff,  
one seasonal diff at lag 12, seasonal MA(1)

$$(1 - \phi_1 L)(1 - \Phi_1 L^{12})(1 - L)(1 - L^{12}) Y_t = (1 + \theta_1 L)(1 + \Theta_1 L^{12}) \varepsilon_t$$

## Vizual: Structura Modelului SARIMA



SARIMA combină componente ARIMA obișnuite cu componente sezoniere la lag-ul s. [Q TSA\\_ch4\\_def\\_sarima](#)



## Test 3: Modelul Airline

### Întrebare

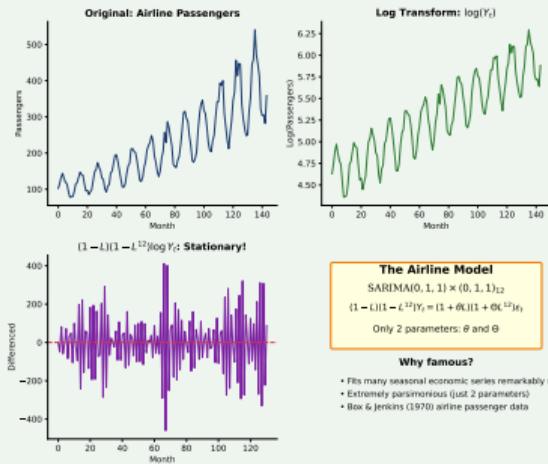
“Modelul airline” se referă la SARIMA(0, 1, 1) × (0, 1, 1)<sub>12</sub>. Câți parametri are (excluzând varianța)?

### Variante de răspuns

- (A) 2 parametri      indent (B) 4 parametri      indent (C) 6 parametri      indent (D) 12  
parametri

## Test 3: Răspuns

Răspuns: A – 2 parametri ( $\theta_1$  și  $\Theta_1$ )



**Modelul airline:**  $(1 - L)(1 - L^{12})Y_t = (1 + \theta_1 L)(1 + \Theta_1 L^{12})\varepsilon_t$

Se potrivește remarcabil de bine pe multe serii economice sezoniere (Box & Jenkins, 1970)



## Test 4: ACF-ul Datelor Sezoniere

### Întrebare

Pentru date lunare cu sezonalitate puternică, unde vă așteptați să vedeați vârfuri ACF semnificative?

### Variante de răspuns

- (A) Doar la lag 1 indent (B) Doar la lag 12 indent (C) La lagurile 12, 24, 36, ...  
indent (D) Distribuite aleatoriu



## Test 4: ACF-ul Datelor Sezoniere

### Întrebare

Pentru date lunare cu sezonalitate puternică, unde vă așteptați să vedeați vârfuri ACF semnificative?

### Variante de răspuns

- (A) Doar la lag 1      indent (B) Doar la lag 12      indent (C) La lagurile 12, 24, 36, ...  
indent (D) Distribuite aleatoriu

Răspuns: C – La lagurile 12, 24, 36, ...

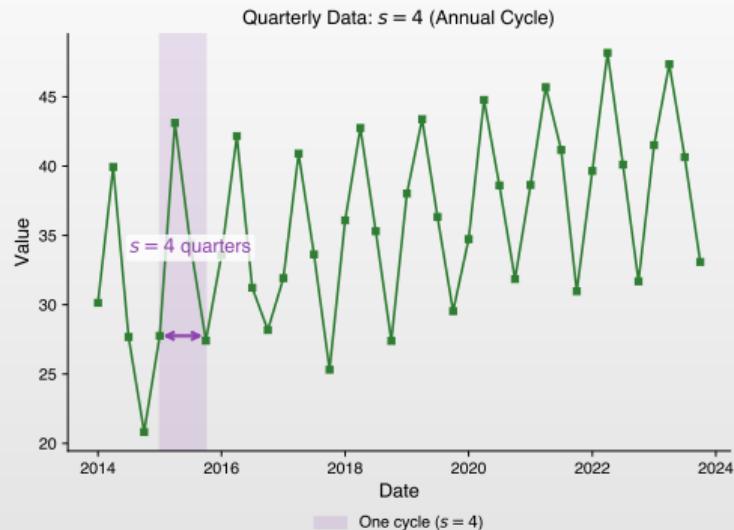
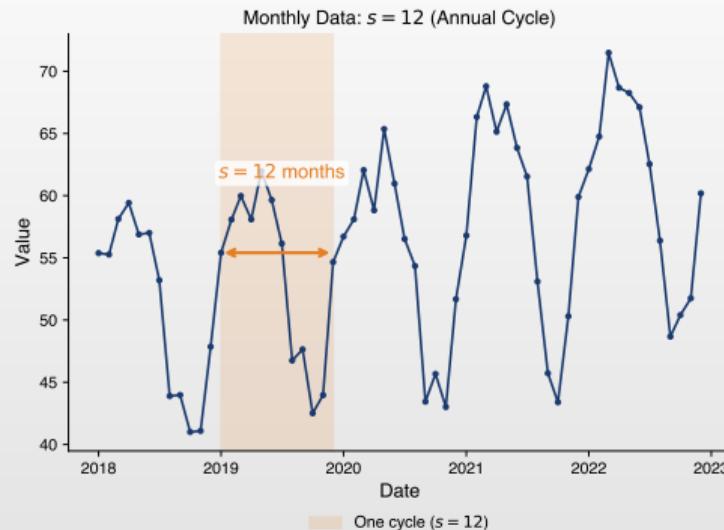
**Intuiție:** Ianuarie 2024 este similar cu ianuarie 2023, 2022, etc.

**Model ACF:** Vârfuri la lagurile  $s, 2s, 3s, \dots$  ( $\rho_{12}, \rho_{24}, \rho_{36} \neq 0$ )

**Diagnostic:** Descreștere lentă la lagurile sezoniere  $\Rightarrow D = 1$ ; Întrerupere după lag  $s \Rightarrow Q = 1$



## Vizual: Modele de Sezonalitate



Modelele sezoniere se repetă la intervale regulate (lunar, trimestrial, etc.) și pot fi aditive sau multiplicative.

Q [TSA\\_ch4\\_def\\_seasonality](#)



## Test 5: Structura Multiplicativă

### Întrebare

În SARIMA, ce înseamnă "structură multiplicativă"?

### Variante de răspuns

- (A) Amplitudinea sezonieră crește proporțional
- (B) Polinoamele obișnuite și sezoniere sunt înmulțite
- (C) Înmulțim datele cu factori sezonieri
- (D) Modelul este estimat folosind înmulțirea



## Test 5: Structura Multiplicativă

### Întrebare

În SARIMA, ce înseamnă "structură multiplicativă"?

### Variante de răspuns

- (A) Amplitudinea sezonieră crește proporțional
- (B) Polinoamele obișnuite și sezoniere sunt înmulțite
- (C) Înmulțim datele cu factori sezonieri
- (D) Modelul este estimat folosind înmulțirea

Răspuns: B – Polinoamele obișnuite și sezoniere sunt înmulțite

SARIMA multiplicativ:  $\phi(L)\Phi(L^s)(1 - L)^d(1 - L^s)^D Y_t = \theta(L)\Theta(L^s)\varepsilon_t$

Exemplu:  $(1 - \phi_1 L)(1 - \Phi_1 L^{12}) = 1 - \phi_1 L - \Phi_1 L^{12} + \phi_1 \Phi_1 L^{13}$

Termenul încrucișat  $\phi_1 \Phi_1 L^{13}$ : Captează interacțiunea între dinamica pe termen scurt și lung



## Test 6: Diferențierea Sezonieră vs Obisnuită

### Întrebare

Când ați aplica atât diferențierea obișnuită ( $d = 1$ ) cât și sezonieră ( $D = 1$ )?

### Variante de răspuns

- (A) Când datele au doar un trend
- (B) Când datele au doar sezonalitate
- (C) Când datele au atât trend cât și nestaționaritate sezonieră
- (D) Niciodată – se anulează reciproc



## Test 6: Diferențierea Sezonieră vs Obisnuită

### Întrebare

Când ați aplica atât diferențierea obișnuită ( $d = 1$ ) cât și sezonieră ( $D = 1$ )?

### Variante de răspuns

- (A) Când datele au doar un trend
- (B) Când datele au doar sezonalitate
- (C) Când datele au atât trend cât și nestaționaritate sezonieră
- (D) Niciodată – se anulează reciproc

Răspuns: C – Atât trend cât și nestaționaritate sezonieră

Combinat:  $W_t = (1 - L)(1 - L^{12})Y_t = Y_t - Y_{t-1} - Y_{t-12} + Y_{t-13}$

Când este necesar: ACF cu descreștere lentă la lagurile 1,2,3...  $\Rightarrow d = 1$ ; la lagurile 12,24,36...  $\Rightarrow D = 1$

Exemple: Pasageri aerieni, vânzări retail, cerere de energie



## Test 7: Detectarea Sezonalității din ACF

### Întrebare

ACF-ul unei serii de timp lunare arată descreștere lentă la lag-urile 12, 24 și 36. Ce sugerează aceasta?

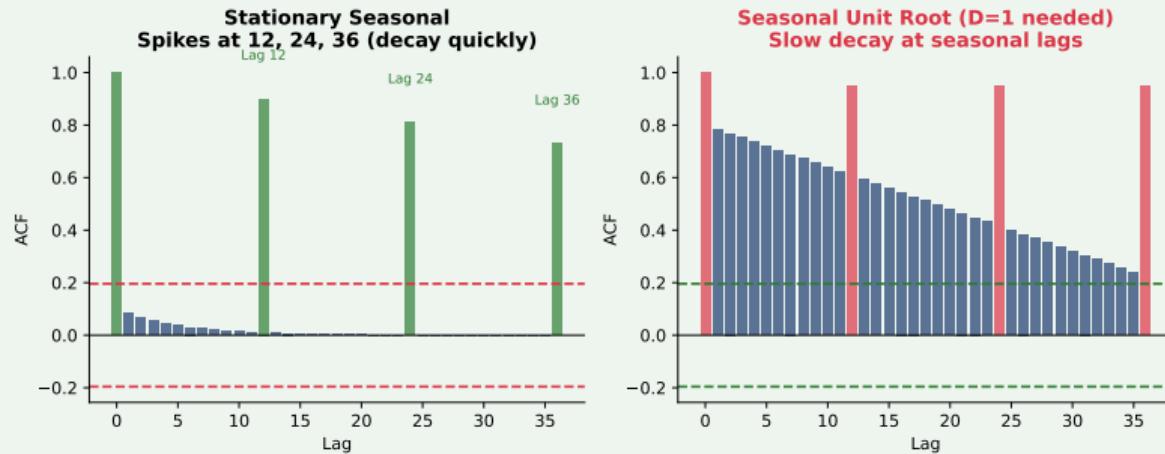
### Variante de răspuns

- (A) Seria este staționară
- (B) Seria necesită doar diferențierea obișnuită
- (C) Seria are o rădăcină unitară sezonieră necesitând  $D = 1$
- (D) Seria este zgomot alb



## Test 7: Răspuns

Răspuns: C – Rădăcină unitară sezonieră necesitând  $D = 1$



**Stânga:** Sezonieră staționară (descreștere rapidă la lag-urile sezoniere)

**Dreapta:** Rădăcină unitară sezonieră (descreștere lentă  $\Rightarrow$  necesită  $D = 1$ )



## Test 8: Sezonalitate Multiplicativă vs Aditivă

### Întrebare

Dacă amplitudinea sezonieră a unei serii de timp crește proporțional cu nivelul, aceasta indică:

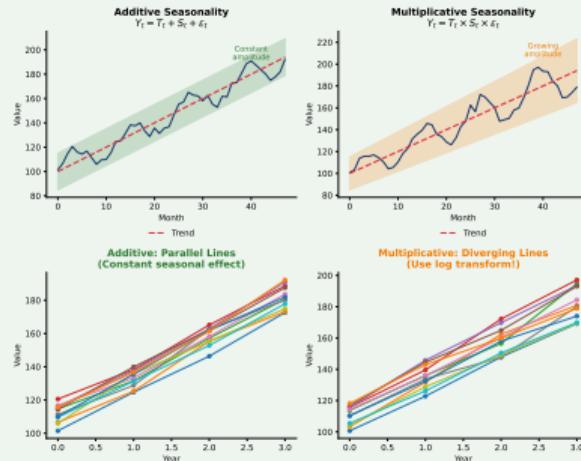
### Variante de răspuns

- (A) Sezonalitate aditivă – folosiți  $(1 - L^s)$
- (B) Sezonalitate multiplicativă – folosiți transformarea log
- (C) Fără sezonalitate prezentă
- (D) Nevoie doar de diferențiere obișnuită



## Test 8: Răspuns

Răspuns: B – Sezonalitate multiplicativă, folosiți transformarea log



**Multiplicativă:** Amplitudinea sezonieră crește cu nivelul (linii divergente)  
**Soluție:** Aplicați transformarea log înainte de a ajusta SARIMA



## Test 9: Graficul Subseriilor Sezoniere

### Întrebare

Într-un grafic de subserii sezoniere, ce indică sezonalitatea multiplicativă?

### Variante de răspuns

- (A) Liniile pentru fiecare lună sunt paralele
- (B) Liniile pentru fiecare lună divergează (dispersia crește în timp)
- (C) Toate luniile au aceeași medie
- (D) Liniile sunt orizontale



## Test 9: Graficul Subseriilor Sezoniere

### Întrebare

Într-un grafic de subserii sezoniere, ce indică sezonalitatea multiplicativă?

### Variante de răspuns

- (A) Liniile pentru fiecare lună sunt paralele
- (B) Liniile pentru fiecare lună divergează (dispersia crește în timp)
- (C) Toate luniile au aceeași medie
- (D) Liniile sunt orizontale

Răspuns: B – Liniile divergează (dispersia crește în timp)

**Graficul subseriilor:** Grupează datele pe luni, reprezintă valorile fiecărei luni de-a lungul anilor  
Paralele  $\Rightarrow$  Aditivă; Divergente  $\Rightarrow$  Multiplicativă; Orizontale  $\Rightarrow$  Fără trend

**ACTIONE:** Dacă multiplicativă, aplicați log înainte de a ajusta SARIMA



## Test 10: Invertibilitatea în SARIMA

### Întrebare

Pentru ca SARIMA(0, 1, 1)  $\times$  (0, 1, 1)<sub>12</sub> să fie invertibil, care condiție trebuie îndeplinită?

### Variante de răspuns

- (A)  $|\theta_1| < 1$  doar
- (B)  $|\Theta_1| < 1$  doar
- (C) Atât  $|\theta_1| < 1$  cât și  $|\Theta_1| < 1$
- (D) Nu există condiție de invertibilitate pentru modelele MA



## Test 10: Invertibilitatea în SARIMA

### Întrebare

Pentru ca SARIMA(0, 1, 1)  $\times$  (0, 1, 1)<sub>12</sub> să fie invertibil, care condiție trebuie îndeplinită?

### Variante de răspuns

- (A)  $|\theta_1| < 1$  doar
- (B)  $|\Theta_1| < 1$  doar
- (C) Atât  $|\theta_1| < 1$  cât și  $|\Theta_1| < 1$
- (D) Nu există condiție de invertibilitate pentru modelele MA

Răspuns: C – Atât  $|\theta_1| < 1$  cât și  $|\Theta_1| < 1$

Invertibilitate: Toate rădăcinile MA în afara cercului unitate

MA multiplicativ:  $(1 + \theta_1 L)(1 + \Theta_1 L^{12})$

Rădăcini: Obișnuită  $|z| = |-1/\theta_1| > 1 \Leftrightarrow |\theta_1| < 1$ ; Sezonieră  $|\Theta_1| < 1$

Ambele condiții necesare pentru invertibilitate generală!



## Test 11: Testul HEGY

### Întrebare

Testul HEGY este folosit pentru:

#### Variante de răspuns

- (A) Estimarea parametrilor SARIMA
- (B) Testarea rădăcinilor unitare la diferite frecvențe (trend și sezoniere)
- (C) Verificarea normalității reziduurilor
- (D) Compararea modelelor SARIMA folosind criterii informaționale



## Test 11: Testul HEGY

### Întrebare

Testul HEGY este folosit pentru:

#### Variante de răspuns

- (A) Estimarea parametrilor SARIMA
- (B) Testarea rădăcinilor unitare la diferite frecvențe (trend și sezoniere)
- (C) Verificarea normalității reziduurilor
- (D) Compararea modelelor SARIMA folosind criterii informaționale

Răspuns: B – Testarea rădăcinilor unitare la diferite frecvențe

**Testul HEGY** (Hylleberg-Engle-Granger-Yoo, 1990):

Testează la: Frecvența zero ( $\omega = 0$ )  $\Rightarrow d = 1$ ; Nyquist ( $\omega = \pi$ ); Sezonieră  $\Rightarrow D = 1$

Decizie: Respingeți toate  $\Rightarrow$  variabile dummy sezoniere; Nu respingeți sezoniera  $\Rightarrow$  diferențiere sezonieră



## Test 12: Identificarea MA Sezonier

### Întrebare

După aplicarea  $(1 - L)(1 - L^{12})$ , ACF arată un singur vârf semnificativ doar la lag 12 (fără vârf la lag 1). PACF descrește la lagurile sezoniere. Aceasta sugerează:

### Variante de răspuns

- (A) SARIMA(0, 1, 0)  $\times$  (0, 1, 1)<sub>12</sub>
- (B) SARIMA(0, 1, 1)  $\times$  (0, 1, 0)<sub>12</sub>
- (C) SARIMA(1, 1, 0)  $\times$  (1, 1, 0)<sub>12</sub>
- (D) SARIMA(0, 1, 1)  $\times$  (0, 1, 1)<sub>12</sub>

## Test 12: Identificarea MA Sezonier

### Întrebare

După aplicarea  $(1 - L)(1 - L^{12})$ , ACF arată un singur vârf semnificativ doar la lag 12 (fără vârf la lag 1). PACF descrește la lagurile sezoniere. Aceasta sugerează:

### Variante de răspuns

- (A) SARIMA(0, 1, 0)  $\times$  (0, 1, 1)<sub>12</sub>
- (B) SARIMA(0, 1, 1)  $\times$  (0, 1, 0)<sub>12</sub>
- (C) SARIMA(1, 1, 0)  $\times$  (1, 1, 0)<sub>12</sub>
- (D) SARIMA(0, 1, 1)  $\times$  (0, 1, 1)<sub>12</sub>

Răspuns: A – SARIMA(0, 1, 0)  $\times$  (0, 1, 1)<sub>12</sub>

Model: Lag-uri obișnuite – fără vârfuri în ACF/PACF; Lag-uri sezoniere – ACF se anulează la s, PACF descrește  
Interpretare: Fără MA obișnuit ( $q = 0$ ); MA(1) sezonier indicat ( $Q = 1$ )

Model:  $(1 - L)(1 - L^{12})Y_t = (1 + \Theta_1 L^{12})\varepsilon_t$



## Test 1.3: Supradiferentierea

### Întrebare

După diferențiere, ACF arată un vârf negativ mare la lag 1 sau lag  $s$ . Aceasta indică de obicei:

#### Variante de răspuns

- (A) Modelul necesită mai mulți termeni AR
- (B) Seria a fost supradiferențiată
- (C) Seria este perfect staționară
- (D) Prezența heteroscedasticității



## Test 1.3: Supradiferentierea

### Întrebare

După diferențiere, ACF arată un vârf negativ mare la lag 1 sau lag  $s$ . Aceasta indică de obicei:

#### Variante de răspuns

- (A) Modelul necesită mai mulți termeni AR
- (B) Seria a fost supradiferențiată
- (C) Seria este perfect staționară
- (D) Prezența heteroscedasticității

#### Răspuns: B – Seria a fost supradiferențiată

Semnătură: ACF la lag 1  $\approx -0.5 \Rightarrow$  supradif la  $d$ ; ACF la lag  $s \approx -0.5 \Rightarrow$  supradif la  $D$

De ce?  $\Delta^2 Y_t = \varepsilon_t - \varepsilon_{t-1}$  este MA(1) cu  $\theta = -1$ , dând  $\rho_1 = -0.5$

Corecție: Reduceti  $d$  sau  $D$  cu unu și re-examinați ACF/PACF



## Test 14: Orizontul de Prognoză

### Întrebare

Pentru un model SARIMA cu  $D = 1$ , ce se întâmplă cu intervalele de încredere ale prognozei când orizontul  $h \rightarrow \infty$ ?

### Variante de răspuns

- (A) Converg la o lățime fixă      indent (B) Cresc fără limită      indent (C) Se micșorează la zero  
indent (D) Oscilează sezonier



## Test 14: Orizontul de Prognoză

### Întrebare

Pentru un model SARIMA cu  $D = 1$ , ce se întâmplă cu intervalele de încredere ale prognozei când orizontul  $h \rightarrow \infty$ ?

### Variante de răspuns

- (A) Converg la o lățime fixă      indent (B) Cresc fără limită      indent (C) Se micșorează la zero  
indent (D) Oscilează sezonier

Răspuns: B – Cresc fără limită

**Proprietatea rădăcinii unitare:** Orice rădăcină unitară cauzează varianță de prognoză nemărginită

Pentru **SARIMA cu  $D = 1$ :**  $\text{Var}(\hat{Y}_{T+h} - Y_{T+h}) \rightarrow \infty$  când  $h \rightarrow \infty$

**Intuiție:** řocurile sezoniere se acumulează; prognozele pe termen lung au IC-uri largi



## Test 15: Selectarea Perioadei Sezoniere

### Întrebare

Aveți date zilnice care arată modele săptămânale clare. Ce perioadă sezonieră s ar trebui să folosiți într-un model SARIMA?

### Variante de răspuns

- (A)  $s = 12$  (lunar)      indent (B)  $s = 7$  (săptămânal)      indent (C)  $s = 365$  (anual)      indent  
(D)  $s = 24$  (orar)



## Test 15: Selectarea Perioadei Sezoniere

### Întrebare

Aveți date zilnice care arată modele săptămânale clare. Ce perioadă sezonieră  $s$  ar trebui să folosiți într-un model SARIMA?

### Variante de răspuns

- (A)  $s = 12$  (lunar)      indent    (B)  $s = 7$  (săptămânal)      indent    (C)  $s = 365$  (anual)      indent  
(D)  $s = 24$  (orar)

Răspuns: B –  $s = 7$  (săptămânal)

Date	Model	Perioada $s$
Zilnice	Săptămânal	7
Lunare	Anual	12
Trimestriale	Anual	4

Regulă:  $s =$  observații per ciclu al modelului dominant



## Test 16: Componenta AR Sezonieră

### Întrebare

În componenta sezonieră  $\Phi(L^s) = 1 - \Phi_1 L^s$ , ce ne spune coeficientul  $\Phi_1 = 0.8$ ?

### Variante de răspuns

- (A) 80% din valoarea perioadei curente vine din perioada anterioară
- (B) Există 80% corelație între observațiile consecutive
- (C) 80% din valoarea perioadei curente este explicată de aceeași perioadă din anul trecut
- (D) Modelul sezonier explică 80% din varianță



## Test 16: Componenta AR Sezonieră

### Întrebare

În componenta sezonieră  $\Phi(L^s) = 1 - \Phi_1 L^s$ , ce ne spune coeficientul  $\Phi_1 = 0.8$ ?

### Variante de răspuns

- (A) 80% din valoarea perioadei curente vine din perioada anterioară
- (B) Există 80% corelație între observațiile consecutive
- (C) 80% din valoarea perioadei curente este explicată de aceeași perioadă din anul trecut
- (D) Modelul sezonier explică 80% din varianță

Răspuns: C – 80% explicat de aceeași perioadă din anul trecut

SAR(1):  $Y_t = \Phi_1 Y_{t-12} + \varepsilon_t$

Cu  $\Phi_1 = 0.8$ :  $Y_{Jan2024} = 0.8 \cdot Y_{Jan2023} + \varepsilon_t$

Interpretare: Persistență sezonieră puternică – 80% explicat de aceeași lună din anul trecut

Staționaritate: Necesită  $|\Phi_1| < 1$  (satisfăcută aici)



## Test 17: Stationaritatea Sezonieră

### Întrebare

Un proces sezonier cu  $\Phi_1 = 1$  în SARIMA( $0, 0, 0$ )  $\times$  ( $1, 0, 0$ )<sub>12</sub> este:

### Variante de răspuns

- (A) Staționar
- (B) Are o rădăcină unitară sezonieră (integrat sezonier)
- (C) Explosiv
- (D) Nedefinit



## Test 17: Stationaritatea Sezonieră

### Întrebare

Un proces sezonier cu  $\Phi_1 = 1$  în SARIMA( $0, 0, 0$ )  $\times (1, 0, 0)_{12}$  este:

### Variante de răspuns

- (A) Staționar
- (B) Are o rădăcină unitară sezonieră (integrat sezonier)
- (C) Explosiv
- (D) Nedefinit

Răspuns: B – Are o rădăcină unitară sezonieră

Model:  $Y_t = Y_{t-12} + \varepsilon_t$  (mers aleator sezonier)

Proprietăți: Varianța crește cu timpul; fiecare lună urmează propriul său mers aleator; necesită  $D = 1$

Analogie: Ca mersul aleatoriu obișnuit dar la frecvența sezonieră



## Test 18: Compararea Modelelor

### Întrebare

Modelul A: SARIMA(1, 1, 1)  $\times$  (1, 1, 1)<sub>12</sub> are AIC = 520. Modelul B: SARIMA(0, 1, 1)  $\times$  (0, 1, 1)<sub>12</sub> are AIC = 525. Care afirmație este cea mai corectă?

### Variante de răspuns

- (A) Modelul A este întotdeauna mai bun deoarece are AIC mai mic
- (B) Modelul B ar trebui preferat datorită parcimoniei în ciuda AIC mai mare
- (C) Diferența AIC de 5 sugerează că Modelul A este substanțial mai bun
- (D) Nu putem compara modele cu ordine diferite



## Test 18: Compararea Modelelor

### Întrebare

Modelul A: SARIMA(1, 1, 1)  $\times$  (1, 1, 1)<sub>12</sub> are AIC = 520. Modelul B: SARIMA(0, 1, 1)  $\times$  (0, 1, 1)<sub>12</sub> are AIC = 525. Care afirmație este cea mai corectă?

### Variante de răspuns

- (A) Modelul A este întotdeauna mai bun deoarece are AIC mai mic
- (B) Modelul B ar trebui preferat datorită parcimoniei în ciuda AIC mai mare
- (C) Diferența AIC de 5 sugerează că Modelul A este substanțial mai bun
- (D) Nu putem compara modele cu ordine diferite

Răspuns: C – Diferența AIC de 5 sugerează că Modelul A este substanțial mai bun

Regulă empirică:  $\Delta\text{AIC} < 2$ : echivalente; 2–10: anumite dovezi;  $> 10$ : dovezi puternice

Aici:  $\Delta\text{AIC} = 5$  sugerează Modelul A semnificativ mai bun

Întotdeauna: Verificați și diagnosticele reziduurilor și performanța prognozei!



## Test 19: Modele Sezoniere în Reziduuri

### Întrebare

După ajustarea unui model SARIMA, observați vârfuri ACF semnificative la lagurile 12 și 24 în reziduuri. Ce indică aceasta?

### Variante de răspuns

- (A) Modelul este corect specificat
- (B) Componenta sezonieră este inadecvată
- (C) Datele nu sunt sezoniere
- (D) A apărut supraajustarea



## Test 19: Modele Sezoniere în Reziduuri

### Întrebare

După ajustarea unui model SARIMA, observați vârfuri ACF semnificative la lagurile 12 și 24 în reziduuri. Ce indică aceasta?

### Variante de răspuns

- (A) Modelul este corect specificat
- (B) Componenta sezonieră este inadecvată
- (C) Datele nu sunt sezoniere
- (D) A apărut supraajustarea

### Răspuns: B – Componenta sezonieră este inadecvată

Diagnostic: Reziduurile bune ar trebui să fie zgomot alb (fără ACF semnificativ)

ACF sezonier în reziduuri: Modelul nu a capturat structura sezonieră; încercați să creșteți  $P$  sau  $Q$ ; verificați că  $D$  este corect

ACTION: Încercați SARIMA cu ordin sezonier mai mare, verificați Ljung-Box la lagurile sezoniere



## Test 20: Prognoză Practică

### Întrebare

Prognozați vânzări retail lunare cu SARIMA( $0, 1, 1 \times (0, 1, 1)_{12}$ ). Pentru prognoza la 13 luni înainte, care observații istorice sunt cele mai influente?

### Variante de răspuns

- (A) Doar cea mai recentă observație
- (B) Observația de aceeași lună din anul trecut
- (C) Toate observațiile în mod egal
- (D) Doar observațiile din aceeași lună din toți anii anteriori



## Test 20: Prognoză Practică

### Întrebare

Prognozați vânzări retail lunare cu SARIMA( $0, 1, 1 \times (0, 1, 1)_{12}$ ). Pentru prognoza la 13 luni înainte, care observații istorice sunt cele mai influente?

### Variante de răspuns

- (A) Doar cea mai recentă observație
- (B) Observația de aceeași lună din anul trecut
- (C) Toate observațiile în mod egal
- (D) Doar observațiile din aceeași lună din toți anii anteriori

### Răspuns: B – Observația de aceeași lună din anul trecut

Pentru 13 luni înainte: Cea mai influentă este  $Y_{T-11}$  (aceeași lună anul trecut), de asemenea  $Y_T$  și  $Y_{T-12}$   
Intuiție: "ianuarie viitor arată ca ianuarie trecut, ajustat pentru trendul recent"



## Întrebări Adevărat/Fals (1-6)

### Întrebare

Determinați dacă fiecare afirmație este Adevărată sau Falsă:

1. Perioada sezonieră  $s$  pentru date trimestriale cu modele anuale este  $s = 4$ .
2. Modelele SARIMA pot gestiona doar o singură frecvență sezonieră.
3. Dacă AIC selectează SARIMA(1, 1, 1)  $\times$  (1, 1, 1)<sub>12</sub> și BIC selectează modelul airline, BIC greșește întotdeauna.
4. Testul Kruskal-Wallis poate detecta sezonalitatea fără a presupune normalitate.
5. După ajustarea unui model SARIMA, reziduurile nu ar trebui să arate ACF semnificativ la lag-urile sezoniere.
6. Transformarea logaritmică convertește sezonalitatea multiplicativă în aditivă.

*Răspunsul pe slide-ul următor...*



## Soluții Adevărat/Fals (1-6)

### Răspunsuri

1. **ADEVĂRAT**: Datele trimestriale cu ciclu anual au  $s = 4$  trimestre pe an.
2. **ADEVĂRAT**: SARIMA standard gestionează un  $s$ ; sezonalități multiple necesită TBATS sau termeni Fourier.
3. **FALS**: BIC penalizează complexitatea mai mult; modelul mai simplu poate fi mai bun pentru interpretare/prognoză.
4. **ADEVĂRAT**: Kruskal-Wallis este neparametric, comparând distribuțiile între sezoane.
5. **ADEVĂRAT**: ACF-ul reziduurilor ar trebui să fie în limitele de încredere la TOATE lag-urile inclusiv cele sezoniere.
6. **ADEVĂRAT**:  $\log(T \times S \times \varepsilon) = \log T + \log S + \log \varepsilon$  (formă aditivă).



## Problema 1: Expandarea Diferenței Sezoniere

### Exercițiu

Expandați complet  $(1 - L)(1 - L^{12})Y_t$ . Ce observații sunt implicate?



## Problema 1: Expandarea Diferenței Sezoniere

### Exercițiu

Expandați complet  $(1 - L)(1 - L^{12})Y_t$ . Ce observații sunt implicate?

### Soluție

$$(1 - L)(1 - L^{12}) = 1 - L - L^{12} + L^{13}$$

Prin urmare:  $(1 - L)(1 - L^{12})Y_t = Y_t - Y_{t-1} - Y_{t-12} + Y_{t-13}$

**Interpretare:** Aceasta este diferența diferențelor:

- Mai întâi diferența sezonieră:  $Y_t - Y_{t-12}$  (anul acesta vs anul trecut)
- Apoi diferența obișnuită:  $(Y_t - Y_{t-12}) - (Y_{t-1} - Y_{t-13})$



## Problema 2: Expandarea Modelului Airline

### Exercițiu

scrieți ecuația completă pentru modelul airline SARIMA(0, 1, 1) × (0, 1, 1)<sub>12</sub>:

$$(1 - L)(1 - L^{12})Y_t = (1 + \theta_1L)(1 + \Theta_1L^{12})\varepsilon_t$$


## Problema 2: Expandarea Modelului Airline

### Exercițiu

Scripti ecuația completă pentru modelul airline SARIMA(0, 1, 1) × (0, 1, 1)<sub>12</sub>:

$$(1 - L)(1 - L^{12})Y_t = (1 + \theta_1L)(1 + \Theta_1L^{12})\varepsilon_t$$

### Soluție

Expandați partea MA:  $(1 + \theta_1L)(1 + \Theta_1L^{12}) = 1 + \theta_1L + \Theta_1L^{12} + \theta_1\Theta_1L^{13}$

Modelul complet:  $Y_t - Y_{t-1} - Y_{t-12} + Y_{t-13} = \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}$

**Notă:** Termenul încrucișat  $\theta_1\Theta_1L^{13}$  este interacțiunea multiplicativă între componente MA obișnuite și sezoniere.



## Problema 3: Numărarea Parametrilor

### Exercițiu

Câtă parametri (excluzând  $\sigma^2$ ) sunt în SARIMA(2, 1, 1)  $\times$  (1, 0, 1)<sub>4</sub>?



## Problema 3: Numărarea Parametrilor

### Exercițiu

Câtă parametri (excluzând  $\sigma^2$ ) sunt în SARIMA(2, 1, 1)  $\times$  (1, 0, 1)<sub>4</sub>?

### Soluție

- AR obișnuit( $p = 2$ ):  $\phi_1, \phi_2 \Rightarrow 2$  parametri
- MA obișnuit( $q = 1$ ):  $\theta_1 \Rightarrow 1$  parametru
- AR sezonier( $P = 1$ ):  $\Phi_1 \Rightarrow 1$  parametru
- MA sezonier( $Q = 1$ ):  $\Theta_1 \Rightarrow 1$  parametru

**Total: 5 parametri**

Notă: Ordinele de diferențiere ( $d = 1, D = 0$ ) nu adaugă parametri – sunt transformări aplicate datelor.



## Problema 4: Prognoza SARIMA

### Exercițiu

Dat modelul airline cu  $\theta_1 = -0.4$  și  $\Theta_1 = -0.6$ , și:

- $Y_T = 500, Y_{T-1} = 495, Y_{T-11} = 480, Y_{T-12} = 470$
- $\varepsilon_T = 5, \varepsilon_{T-11} = -3, \varepsilon_{T-12} = 2$

Prognozați  $Y_{T+1}$ .

## Problema 4: Prognoza SARIMA

### Exercițiu

Dat modelul airline cu  $\theta_1 = -0.4$  și  $\Theta_1 = -0.6$ , și:

- $Y_T = 500$ ,  $Y_{T-1} = 495$ ,  $Y_{T-11} = 480$ ,  $Y_{T-12} = 470$
- $\varepsilon_T = 5$ ,  $\varepsilon_{T-11} = -3$ ,  $\varepsilon_{T-12} = 2$

Prognozați  $Y_{T+1}$ .

### Soluție

Din model:  $Y_{T+1} = Y_T + Y_{T-11} - Y_{T-12} + \varepsilon_{T+1} + \theta_1\varepsilon_T + \Theta_1\varepsilon_{T-11} + \theta_1\Theta_1\varepsilon_{T-12}$

Setând  $\mathbb{E}[\varepsilon_{T+1}] = 0$ :

$$\begin{aligned}\hat{Y}_{T+1} &= 500 + 480 - 470 + 0 + (-0.4)(5) + (-0.6)(-3) + (-0.4)(-0.6)(2) \\ &= 510 - 2 + 1.8 + 0.48 = 510.28\end{aligned}$$



## Problema 5: Identificarea Perioadei Sezoniere

### Exercițiu

Potriviți fiecare tip de date cu perioada sezonieră tipică s:

1. Date trimestriale de PIB
2. Vânzări retail lunare
3. Rezervări săptămânale la restaurante
4. Cerere zilnică de electricitate



## Problema 5: Identificarea Perioadei Sezoniere

### Exercițiu

Potrivite fiecare tip de date cu perioada sezonieră tipică  $s$ :

1. Date trimestriale de PIB
2. Vânzări retail lunare
3. Rezervări săptămânaile la restaurante
4. Cerere zilnică de electricitate

### Soluție

1. PIB trimestrial:  $s = 4$  (ciclul anual pe 4 trimestre)
  2. Vânzări retail lunare:  $s = 12$  (ciclul anual pe 12 luni)
  3. Rezervări săptămânaile la restaurante:  $s = 7$  (ciclul săptămânal) sau  $s = 52$  (anual)
  4. Cerere zilnică de electricitate:  $s = 7$  (model săptămânal) sau  $s = 365$  (anual)
- Notă:** Unele serii au modele sezoniere multiple (de ex., datele zilnice pot avea cicluri săptămânaile și anuale).



## Exemplu: Analiza Vânzărilor Retail Lunare

### Scenariu

Aveți 5 ani de date de vânzări retail lunare cu vârfuri clare în decembrie și scăderi în ianuarie.  
Construiți un model SARIMA potrivit.

### Abordare Pas cu Pas

- Inspecție vizuală:** Graficul arată trend ascendent + vârfuri puternice în decembrie
- Perioada sezonieră:** Date lunare cu model anual  $\Rightarrow s = 12$
- Transformare:** Considerați  $\log(Y_t)$  dacă amplitudinea sezonieră crește cu nivelul
- Diferențiere:** Încercați  $(1 - L)(1 - L^{12})Y_t$  – verificați ACF/PACF
- Selectarea modelului:** Începeți cu modelul airline, comparați prin AIC



## Exemplu: interpretarea ACF/PACF pentru Date Sezoniere

### Modele Observate (după diferențiere)

- ACF: Semnificativ la lagurile 1, 12; se anulează după lag 1 și lag 12
- PACF: Semnificativ la lagurile 1, 12, 13; descrește la multiplii de 12

### Interpretare

**Componenta obișnuită:** ACF se anulează la 1  $\Rightarrow$  MA(1)

**Componenta sezonieră:** ACF semnificativ doar la lag 12  $\Rightarrow$  MA(1) sezonier

**Model sugerat:** SARIMA(0, d, 1)  $\times$  (0, D, 1)<sub>12</sub> – modelul airline!

**Verificare alternativă:** Dacă PACF ar fi arătat anulare la lagurile sezoniere în loc de ACF, considerați termeni AR sezonieri.



## Exemplu: Implementare Python

### Ajustarea SARIMA în Python

```
from statsmodels.tsa.statespace.sarimax import SARIMAX
import pmdarima as pm

# Ajustare manuală
model = SARIMAX(y, order=(0,1,1), seasonal_order=(0,1,1,12))
results = model.fit()
print(results.summary())

# Selectie automată
auto_model = pm.auto_arima(y, seasonal=True, m=12,
                            start_p=0, max_p=2,
                            start_q=0, max_q=2,
                            d=1, D=1,
                            trace=True)
```

## Exemplu: interpretarea Resultatelor SARIMA

### Rezultate Exemplu statsmodels

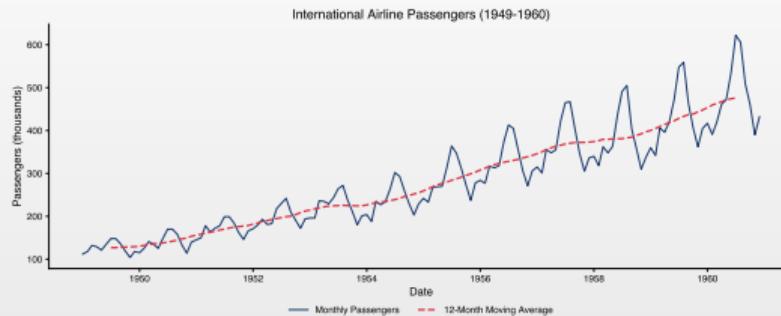
```
SARIMAX Results
=====
Model: SARIMAX(0,1,1)x(0,1,1,12)   AIC: 1348.52
                           BIC: 1358.21
=====
              coef    std err      z     P>|z|
-----
ma.L1      -0.4018    0.072   -5.58    0.000
ma.S.L12    -0.5521    0.081   -6.82    0.000
sigma2     1254.3201  142.856    8.78    0.000
```

### Interpretare

- $\hat{\theta}_1 = -0.40$ : MA negativ – řourile pozitive reduc valoarea perioadei următoare
- $\hat{\Theta}_1 = -0.55$ : Corelația pentru aceeași sezon este captată
- Ambii coeficienți semnificativi ( $p < 0.001$ );  $|\theta|, |\Theta| < 1$  – invertibil



## Studiu de caz: Numar de pasageri (1949–1960)



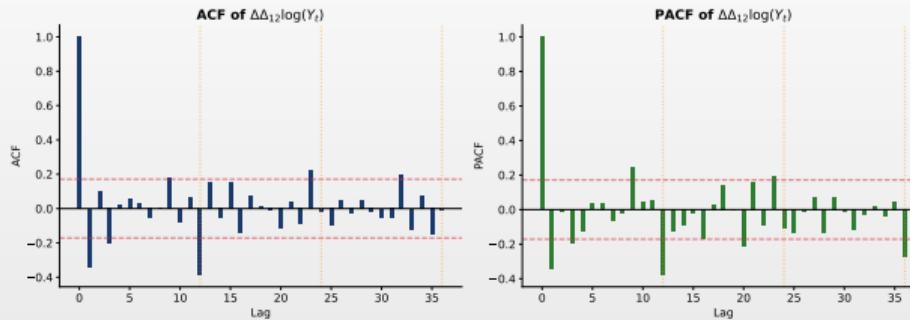
### Observații

- Set de date clasic Box-Jenkins: 144 observații lunare; **trend ascendent clar și model sezonier (vârfuri vara)**
- Amplitudinea sezonieră **crescă cu nivelul** ⇒ sezonalitate multiplicativă
- Sugerează: transformare logaritmică + modelare SARIMA

Q TSA\_ch4\_airline\_data



## Analiza ACF/PACF După Diferențiere



### Observații

- După  $(1 - L)(1 - L^{12})\log(Y_t)$ : seria pare staționară
- Vârf semnificativ la lag 1 în ACF  $\Rightarrow$  MA(1); la lag 12  $\Rightarrow$  MA(1) sezonieră
- Modelul sugerează: **SARIMA(0, 1, 1)(0, 1, 1)<sub>12</sub>** (modelul airline)

Q TSA\_ch4\_acf\_pacf

## Rezultate Estimare SARIMA: Date privind numarul de pasageri

Model: SARIMA(0, 1, 1)(0, 1, 1)<sub>12</sub> pe log(Pasageri)

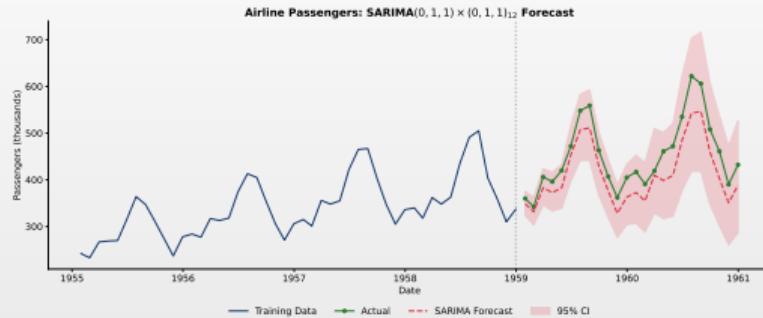
Parametru	Estimat	Eroare Std.	z-stat	valoare-p
$\theta_1$ (MA.L1)	-0.4018	0.0896	-4.48	< 0.001
$\Theta_1$ (MA.S.L12)	-0.5569	0.0731	-7.62	< 0.001
$\sigma^2$	0.00135	-	-	-

### Statistici de Ajustare a Modelului

- Log-Verosimilitate: 244.70
- AIC: -483.40, BIC: -474.53
- Ambii coeficienți MA semnificativi și în limitele de invertibilitate



## Prognoză: 24 Luni Înainte



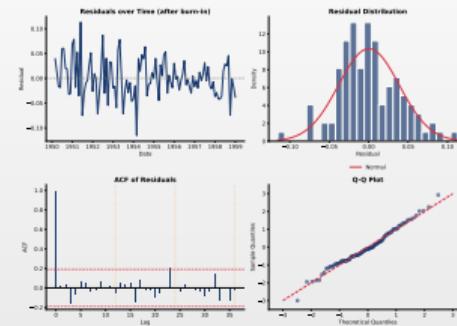
### Observații

- Prognozele captează atât trendul cât și modelul sezonier; IC 95% se largesc pe orizontul de prognoză
- Vârfurile sezoniere (iulie-august) și scăderile (februarie) clar vizibile
- Modelul extrapolează cu succes modelul sezonier multiplicativ

 TSA\_ch4\_sarima\_forecast



## Diagnostice Model



### Observații

- Reziduurile par aleatoare fără modele sistematice; distribuție aproximativ normală (Q-Q)
- ACF-ul reziduurilor în limitele de încredere — fără autocorelație semnificativă
- Testul Ljung-Box:  $p > 0.05$  la toate lag-urile testate  $\Rightarrow$  model adecvat

## Discuție: Sezonalitate Deterministă vs Stochastică

### Întrebare Cheie

Când ar trebui să folosiți variabile dummy sezoniere vs SARIMA pentru date sezoniere?

### Considerații

**Variabile dummy sezoniere (deterministe):**

- Model fix, care se repetă în fiecare an
- Același efect decembrie în fiecare an
- Potrivite când sezonialitatea este stabilă

**SARIMA (stochastic):**

- Model sezonier în evoluție
- Decembrie anul acesta depinde de decembrie anul trecut
- Mai bun când amplitudinea sezonieră variază



## Discuție: Transformarea Logaritmică

### Întrebare Cheie

Când ar trebui să luați logaritmi înainte de a ajusta SARIMA?

### Îndrumări

**Folosiți transformarea log când:**

- Fluctuațiile sezoniere cresc cu nivelul (sezonalitate multiplicativă)
- Varianța crește în timp
- Datele sunt strict pozitive (prețuri, vânzări, numărători)

**Evitați log când:**

- Modelul sezonier este aditiv (amplitudine constantă)
- Datele conțin zerouri sau negative
- Deja pe o scală de rate/proportii

**Sfat:** Comparați AIC-ul modelelor cu și fără transformare log.



## Discuție: Sezonalități Multiple

### Provocare

Datele zilnice de vânzări pot avea atât modele săptămânaile (7 zile) cât și anuale (365 zile). Cum gestionați aceasta?

### Abordări

1. **SARIMA imbricat:** Modelați la frecvența mai scurtă, includeți mai lungă ca exogenă
2. **Modele TBATS/BATS:** Gestionează explicit sezonalități multiple
3. **Termeni Fourier:** Adăugați termeni sin/cos pentru fiecare frecvență sezonieră
4. **Prophet/similare:** Instrumente moderne proiectate pentru sezonalități multiple

**Notă:** SARIMA standard gestionează doar o perioadă sezonieră. Pentru sezonialitate complexă, considerați metode specializate.



## Discuție: Prognozarea Datelor Sezoniere

### Întrebare Cheie

Care sunt provocările unice ale prognozării seriilor de timp sezoniere?

### Provocări și Soluții

- Orizontul contează:** Prognoza pe 12 luni înseamnă prezicerea unui ciclu complet
- Incertitudinea crește:** Prognozele sezoniere compun incertitudinea obișnuită
- Puncte de cotitură:** Captarea când sezoanele ating vârf/minim
- Rupturi structurale:** COVID-19 a perturbat multe modele sezoniere

### Bune practici:

- Folosiți validare încrucișată cu origine mobilă
- Comparați cu benchmark-ul naiv sezonier
- Raportați intervale de prognoză, mai ales la orizonturi sezoniere



## Exerciții pentru Acasă

1. **Teoretic:** Arătați că  $(1 - L)(1 - L^4)$  poate fi scris ca  $(1 - L - L^4 + L^5)$  și explicați ce face această transformare datelor trimestriale cu sezonalitate anuală.
2. **Calcul:** Pentru SARIMA(1, 0, 0)  $\times$  (1, 0, 0)<sub>4</sub> cu  $\phi_1 = 0.5$  și  $\Phi_1 = 0.8$ , scrieți polinomul AR complet și identificați toți coeficienții nenuli.
3. **Aplicat:** Descărcați datele lunare despre pasagerii aerieni și:
  - ▶ Reprezentați grafic seria și identificați trend/sezonalitate
  - ▶ Aplicați transformările potrivite
  - ▶ Ajustați modelul airline și interpretați coeficienții
  - ▶ Generați prognoze pe 24 de luni cu intervale de încredere
4. **Comparație:** Ajustați atât SARIMA(0, 1, 1)  $\times$  (0, 1, 1)<sub>12</sub> cât și SARIMA(1, 1, 0)  $\times$  (1, 1, 0)<sub>12</sub> pe datele despre pasagerii aerieni. Comparați folosind AIC, BIC și diagnosticele reziduurilor. Care este preferat?



## Indicii pentru Soluții

### Indicii

1. Expandați  $(1 - L)(1 - L^4) = 1 \cdot 1 - 1 \cdot L^4 - L \cdot 1 + L \cdot L^4 = 1 - L - L^4 + L^5$
2. Polinomul AR:  $(1 - \phi_1 L)(1 - \Phi_1 L^4) = 1 - 0.5L - 0.8L^4 + 0.4L^5$
3. Pentru datele pasagerilor aerieni:
  - ▶ Folosiți transformarea log (sezonalitate multiplicativă)
  - ▶ Atât  $d = 1$  cât și  $D = 1$  sunt necesare
  - ▶ Estimări tipice:  $\theta_1 \approx -0.4$ ,  $\Theta_1 \approx -0.6$
4. Modelul airline bazat pe MA se potrivește de obicei mai bine decât modelul AR sezonier pur pentru aceste date (AIC mai mic).

## Concluzii cheie din Acest Seminar

### Puncte Principale

1. Diferențierea sezonieră ( $1 - L^s$ ) elimină sezonalitatea stochastică
2. Notația SARIMA:  $(p, d, q) \times (P, D, Q)_s$  separă obișnuitul de sezonier
3. Modelul airline este surprinzător de eficient pentru multe seturi de date
4. Structura multiplicativă creează termeni de interacțiune
5. ACF/PACF arată modele atât la lag-urile obișnuite cât și la cele sezoniere
6. Transformarea log adesea necesară pentru sezonalitatea multiplicativă

### Seminarul Următor

Seminarul 5: Modele GARCH și Volatilitate — clustering al volatilității, modele ARCH/GARCH, extensii (EGARCH, GJR-GARCH), aplicații în managementul riscului.



## IA în modelarea SARIMA

### Context

Instrumentele IA pot ajusta modele SARIMA și genera prognoze sezoniere automat. Competența critică este evaluarea dacă metodologia sezonieră este corectă.

### Întrebări cheie despre orice analiză SARIMA generată de IA:

1. A verificat dacă sezonalitatea este multiplicativă și a aplicat log dacă e necesar?
2. Este perioada sezonieră  $s$  corect identificată din frecvența datelor?
3. A testat atât rădăcinile unitare obișnuite cât și sezoniere înainte de a alege  $d$  și  $D$ ?
4. Sunt reziduurile fără tipare sezoniere (verificați ACF la lag-urile  $s, 2s, 3s$ )?
5. A comparat cu un benchmark sezonier naiv?



## Exercițiu IA 1: Critică o analiză SARIMA generată de IA

### Scenariu

Ați cerut unui IA: "Ajustează cel mai bun model SARIMA pe date lunare de vânzări retail." A returnat:

- SARIMA(2, 1, 2)(2, 1, 2)<sub>12</sub> ajustat cu AIC = 1520
- Fără verificare sezonalitate multiplicativă vs. aditivă
- A aplicat  $D = 1$  "deoarece datele sunt lunare"
- Ljung-Box p-value = 0.03 pe reziduuri
- Prognoză pe 24 luni cu intervale de încredere de lățime constantă

### Critica voastră:

1. De ce este modelul probabil supra-parametrizat? Câți parametri are?
2. De ce trebuie verificată sezonalitatea multiplicativă înainte de ajustare?
3. De ce Ljung-Box  $p = 0.03$  nu este acceptabil la nivel de 5%?
4. De ce intervalele de încredere SARIMA trebuie să se întărească (nu să rămână constante)?



## Exercițiu IA 2: Rafinarea prompturilor pentru SARIMA

### Sarcină

Îmbunătățiți iterativ prompturile pentru ajustarea unui model SARIMA pe date lunare de pasageri.

**Runda 1** (vag): “Ajustează un model sezonier pe pasagerii lunari ai companiilor aeriene”

- Ce a produs IA? A verificat sezonalitatea multiplicativă?

**Runda 2** (mai bun): “Verifică dacă sezonalitatea e multiplicativă (log dacă da), aplică diferențiere sezonieră, ajustează SARIMA folosind AIC, verifică ACF rezidual la lag-uri sezoniere”

- A urmat IA metodologia Box-Jenkins sezonieră?

**Runda 3** (expert): “(1) Grafic serie, verifică dacă amplitudinea crește cu nivelul, (2) dacă multiplicativă, aplică log, (3) test ADF pe niveluri & diferențe sezoniere, (4) ajustează modelul airline + 2 alternative, (5) compară AIC/BIC, (6) Ljung-Box pe reziduuri, (7) prognoză rolling pe 24 luni cu RMSE”

- Comparați rezultatele din toate cele trei runde



## Exercițiu IA 3: Competiție de selecție a modelului

### Sarcină

Descărcați setul clasic de date cu pasageri aerieni (Box-Jenkins, 1970).

#### Abordarea voastră (manuală):

- Verificați sezonalitate multiplicativă vs. aditivă → log dacă e necesar
- Determinați  $d$  și  $D$  din ADF/KPSS și ACF sezonier
- ACF/PACF pe seria transformată → modele candidate
- Comparați modelul airline vs. SARIMA(1,1,0)(1,1,0)<sub>12</sub> via AIC/BIC
- Prognoză rolling 1-pas pe ultimele 24 observații

#### Abordarea IA:

- Cereți IA să “găsească cel mai bun model SARIMA și să progroneze pasagerii aerieni”

#### Comparați:

- A aplicat IA transformarea log? Ce model a selectat fiecare?
- Comparați RMSE out-of-sample; a verificat IA tiparele sezoniere reziduale?
- Predați:** Reflecție de 1 pagină despre punctele tari și slabe ale IA



## Rezumat Formule Cheie

Concept	Formula
Diferență sezonieră	$(1 - L^s)Y_t = Y_t - Y_{t-s}$
Diferențiere combinată	$(1 - L)(1 - L^s)Y_t = Y_t - Y_{t-1} - Y_{t-s} + Y_{t-s-1}$
SARIMA( $p, d, q$ ) $(P, D, Q)_s$	$\phi(L)\Phi(L^s)(1 - L)^d(1 - L^s)^D Y_t = \theta(L)\Theta(L^s)\varepsilon_t$
Modelul airline	$(1 - L)(1 - L^{12})Y_t = (1 + \theta_1 L)(1 + \Theta_1 L^{12})\varepsilon_t$
AR multiplicativ	$(1 - \phi_1 L)(1 - \Phi_1 L^s) = 1 - \phi_1 L - \Phi_1 L^s + \phi_1 \Phi_1 L^{s+1}$
MA multiplicativ	$(1 + \theta_1 L)(1 + \Theta_1 L^s) = 1 + \theta_1 L + \Theta_1 L^s + \theta_1 \Theta_1 L^{s+1}$
Invertibilitate	$ \theta_i  < 1$ și $ \Theta_j  < 1$ pentru toți $i, j$
Staționaritate	$ \Phi_j  < 1$ și rădăcini AR în afara cercului unitate
Transf. log	$\log(T \times S \times \varepsilon) = \log T + \log S + \log \varepsilon$

Notăție:  $s$  = perioadă sezonieră,  $\phi/\Phi$  = AR obișnuit/sezonier,  $\theta/\Theta$  = MA obișnuit/sezonier,  $d/D$  = ordin de diferențiere obișnuit/sezonier



# Vă mulțumim!

Întrebări?

Materialele seminarului sunt disponibile la:

<https://danpele.github.io/Time-Series-Analysis/>



Quantlet



Quantinar

## Bibliografie I

### Manuale fundamentale

- Hyndman, R.J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*, 3rd ed., OTexts.
- Shumway, R.H., & Stoffer, D.S. (2017). *Time Series Analysis and Its Applications*, 4th ed., Springer.
- Brockwell, P.J., & Davis, R.A. (2016). *Introduction to Time Series and Forecasting*, 3rd ed., Springer.

### Serii de timp financiare

- Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed., Wiley.
- Franke, J., Härdle, W.K., & Hafner, C.M. (2019). *Statistics of Financial Markets*, 4th ed., Springer.

## Bibliografie II

### Abordări moderne si Machine Learning

- Nielsen, A. (2019). *Practical Time Series Analysis*, O'Reilly Media.
- Petropoulos, F., et al. (2022). *Forecasting: Theory and Practice*, International Journal of Forecasting.
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition, International Journal of Forecasting.

### Resurse online si cod

- Quantlet:** <https://quantlet.com> — Repository de cod pentru statistica
- Quantinar:** <https://quantinar.com> — Platforma de invatare metode cantitative
- GitHub TSA:** [https://github.com/QuantLet/TSA/tree/main/TSA\\_ch4](https://github.com/QuantLet/TSA/tree/main/TSA_ch4) — Cod Python pentru acest seminar

