



Analiza și Prognoza Seriilor de Timp

Seminar 5b: Modele GARCH Multivariate



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Cuprins Seminar

- ▣ **Test de Recapitulare** – Verificare cunoștințe (10 întrebări)
- ▣ **Întrebări Adevărat/Fals** – Verificări conceptuale
- ▣ **Probleme Practice** – Calcule și interpretări
- ▣ **Flux de Lucru Python** – Estimare DCC pe date reale
- ▣ **Exercițiu cu asistență AI** – Gândire critică
- ▣ **Rezumat** – Concluzii cheie

Întrebarea 1

De ce modelele GARCH univariate nu sunt suficiente pentru managementul riscului de portofoliu?

- (A) Nu pot modela volatility clustering
- (B) Nu captează covarianțele variabile în timp între active
- (C) Nu permit estimarea prin verosimilitate maximă
- (D) Nu pot folosi distribuția Student-t

Gândiți-vă la ce informații necesită calculul VaR de portofoliu...

Răspuns Întrebarea 1

Răspuns Corect: (B)

- ☐ Nu captează covarianțele variabile în timp între active

Răspuns Întrebarea 1

Răspuns Corect: (B)

- ▣ Nu captează covarianțele variabile în timp între active

Explicație

- ▣ VaR de portofoliu: $\sigma_{p,t}^2 = w'H_t w$ necesită **întreaga matrice** H_t
- ▣ GARCH univariat dă doar varianțele individuale $h_{ii,t}$, nu și covarianțele $h_{ij,t}$
- ▣ Corelațiile cresc în perioade de criză — a le ignora **subestimează riscul**
- ▣ Hedging-ul optim necesită $h_{12,t}/h_{22,t}$ — imposibil fără model multivariat

 TSA_ch5b_motivation

Întrebarea 2

Câte elemente unice are matricea de covarianță H_t pentru $N = 10$ active?

- (A) 10
- (B) 45
- (C) 55
- (D) 100

Răspuns Întrebarea 2

Răspuns Corect: (C)

▣ 55

Răspuns Întrebarea 2

Răspuns Corect: (C)

▣ 55

Calculul

- ▣ H_t este simetrică: $h_{ij,t} = h_{ji,t}$
- ▣ Elemente unice: $N(N+1)/2 = 10 \times 11/2 = 55$
- ▣ Din care: 10 varianțe ($h_{ii,t}$) și 45 covarianțe ($h_{ij,t}, i \neq j$)
- ▣ Aceasta este **blestemul dimensionalității** — motivația pentru modele structurate

 TSA_ch5b_curse_dim

Întrebarea 3

Ce proprietate garantează modelul BEKK prin construcție?

- (A) Stationaritatea
- (B) Pozitiv-definirea matricei H_t
- (C) Corelații constante
- (D) Absența propagării volatilității

Răspuns Întrebarea 3

Răspuns Corect: (B)

- ☒ Pozitiv-definirea matricei H_t

Răspuns Întrebarea 3

Răspuns Corect: (B)

- ▣ **Pozitiv-definirea matricei H_t**

Explicație

- ▣ BEKK: $H_t = CC' + A'\epsilon_{t-1}\epsilon'_{t-1}A + B'H_{t-1}B$
- ▣ CC' este p.d. (dacă C are rang plin)
- ▣ $A'MA$ este p.s.d. pentru orice M p.s.d.
- ▣ Suma de matrice p.d. și p.s.d. este p.d. $\Rightarrow H_t$ p.d. automat!
- ▣ **Atenție:** stationaritatea necesită o condiție separată pe raza spectrală

 TSA_ch5b_bekk_sim

Întrebarea 4

În modelul CCC, covarianța $h_{ij,t}$ este dată de:

- (A) $h_{ij,t} = \rho_{ij,t} \cdot \sigma_{i,t} \cdot \sigma_{j,t}$
- (B) $h_{ij,t} = \rho_{ij} \cdot \sigma_{i,t} \cdot \sigma_{j,t}$
- (C) $h_{ij,t} = \alpha_{ij} \cdot \varepsilon_{i,t-1} \varepsilon_{j,t-1}$
- (D) $h_{ij,t} = \rho_{ij} \cdot \bar{\sigma}_i \cdot \bar{\sigma}_j$

Răspuns Întrebarea 4

Răspuns Corect: (B)

☒ $h_{ij,t} = \rho_{ij} \cdot \sigma_{i,t} \cdot \sigma_{j,t}$

Răspuns Întrebarea 4

Răspuns Corect: (B)

☐ $h_{ij,t} = \rho_{ij} \cdot \sigma_{i,t} \cdot \sigma_{j,t}$

Explicație

- ☐ CCC: $H_t = D_t R D_t$ cu R **constant**
- ☐ Corelația ρ_{ij} nu se schimbă în timp (de unde numele “constantă”)
- ☐ Covarianța variază doar prin $\sigma_{i,t}$ și $\sigma_{j,t}$ (modelate cu GARCH univariat)
- ☐ (A) ar fi DCC (cu $\rho_{ij,t}$ variabil), (D) ar fi covarianța necondiționată

 TSA_ch5b_ccc_dcc

Întrebarea 5

Câți parametri de corelație necesită DCC(1,1) indiferent de N ?

- (A) $N(N - 1)/2$
- (B) N^2
- (C) 2
- (D) $3N$

Răspuns Întrebarea 5

Răspuns Corect: (C)

- ▣ 2 parametri (a și b)

Răspuns Întrebarea 5

Răspuns Corect: (C)

- ▣ 2 parametri (a și b)

Explicație

- ▣ DCC: $Q_t = (1 - a - b)\bar{Q} + az_{t-1}z'_{t-1} + bQ_{t-1}$
- ▣ a = reacția la șocuri, b = persistența — **scalari**, nu matrice!
- ▣ Aceasta este cheia scalabilității DCC: $N = 2$ sau $N = 500$, tot 2 parametri
- ▣ Plus $3N$ parametri GARCH univariați (estimați separat în Etapa 1)
- ▣ Total: $3N + N(N - 1)/2 + 2$ (incluzând corelația necondiționată $\bar{Q}$)

 TSA_ch5b_dcc_estimation

Întrebarea 6

Ce se întâmplă cu corelațiile DCC în perioadele de criză?

- (A) Scad, deoarece activele se mișcă independent
- (B) Rămân constante, deoarece DCC are revenire la medie
- (C) Cresc, deoarece șocurile negative comune cresc $q_{12,t}$
- (D) Devin negative, deoarece investitorii fug spre active sigure

Răspuns Întrebarea 6

Răspuns Corect: (C)

- ☐ **Cresc, deoarece șocurile negative comune cresc $q_{12,t}$**

Răspuns Întrebarea 6

Răspuns Corect: (C)

- ▣ **Cresc, deoarece șocurile negative comune cresc $q_{12,t}$**

Mecanismul

- ▣ Criză: $\varepsilon_{1,t-1} < 0, \varepsilon_{2,t-1} < 0 \Rightarrow z_{1,t-1} < 0, z_{2,t-1} < 0$
- ▣ Produsul: $z_{1,t-1} \cdot z_{2,t-1} > 0$ (pozitiv și mare!)
- ▣ $q_{12,t}$ crește $\Rightarrow \rho_{12,t}$ crește
- ▣ **Diversificarea eșuează exact când este cel mai necesară**
- ▣ Modelul aDCC captează acest efect și mai puternic prin termenul asimetric g

 TSA_ch5b_crisis_corr

Întrebarea 7

Care model GARCH multivariat captează propagarea volatilității (spillovers)?

- (A) CCC — prin corelații constante
- (B) DCC — prin corelații dinamice
- (C) BEKK complet — prin elementele off-diagonale ale lui A și B
- (D) BEKK diagonal — prin elementele diagonale ale lui A

Răspuns Întrebarea 7

Răspuns Corect: (C)

- ☐ BEKK complet — prin elementele off-diagonale ale lui A și B

Răspuns Întrebarea 7

Răspuns Corect: (C)

- ▣ **BEKK complet** — prin elementele off-diagonale ale lui A și B

Explicație

- ▣ $a_{21} \neq 0$: șocul din activul 1 afectează varianța activului 2 (shock spillover)
- ▣ $b_{21} \neq 0$: volatilitatea trecută a activului 1 afectează volatilitatea curentă a activului 2
- ▣ CCC/DCC: fiecare varianță urmează GARCH univariat — **fără spillovers**
- ▣ BEKK diagonal: A, B diagonale $\Rightarrow$ spillovers eliminate
- ▣ **Preț**: BEKK complet este fezabil doar pentru $N \leq 5$

 TSA_ch5b_bekk_spillover

Întrebarea 8

Raportul optim de hedging cu varianță minimă este:

- (A) $h_t^* = h_{11,t}/h_{22,t}$
- (B) $h_t^* = h_{12,t}/h_{22,t}$
- (C) $h_t^* = h_{12,t}/h_{11,t}$
- (D) $h_t^* = \rho_t \cdot \sigma_{1,t}/\sigma_{2,t}$ doar dacă corelația este constantă

Răspuns Întrebarea 8

Răspuns Corect: (B)

☐ $h_t^* = h_{12,t}/h_{22,t}$

Răspuns Întrebarea 8

Răspuns Corect: (B)

□ $h_t^* = h_{12,t}/h_{22,t}$

Demonstrație

- Portofoliu acoperit: $r_{\text{hedged}} = r_{\text{spot}} - h \cdot r_{\text{futures}}$
- Varianța: $\text{Var}(r_{\text{hedged}}) = h_{11,t} - 2h \cdot h_{12,t} + h^2 \cdot h_{22,t}$
- Minimizăm: $\frac{\partial}{\partial h} = -2h_{12,t} + 2h \cdot h_{22,t} = 0$
- $h_t^* = h_{12,t}/h_{22,t} = \rho_t \cdot \sigma_{1,t}/\sigma_{2,t}$
- Cu DCC: ρ_t variabil $\Rightarrow$ hedging mai precis în criză!

 TSA_ch5b_hedge_ratio

Întrebarea 9

Ce test verifică dacă corelațiile sunt constante (CCC vs DCC)?

- (A) Testul ARCH-LM
- (B) Testul Dickey-Fuller augmentat
- (C) Testul Engle–Sheppard pentru corelație constantă
- (D) Testul Ljung-Box pe randamente

Răspuns Întrebarea 9

Răspuns Corect: (C)

- ☐ Testul Engle–Sheppard (2001) pentru corelație constantă

Răspuns Întrebarea 9

Răspuns Corect: (C)

- ▣ Testul Engle–Sheppard (2001) pentru corelație constantă

Procedura

- ▣ H_0 : corelațiile sunt constante (CCC adecvat)
- ▣ H_1 : corelațiile variază în timp (necesită DCC)
- ▣ Se regresează $\text{vech}(z_t z_t' - \hat{R})$ pe valori decalate
- ▣ Statistica: $T \cdot R^2 \sim \chi^2$ sub H_0
- ▣ **Empiric**: CCC este aproape întotdeauna respins în date financiare

 TSA_ch5b_ccc_test

Întrebarea 10

Ce model este potrivit pentru un portofoliu de 100 de acțiuni?

- (A) VEC(1,1)
- (B) BEKK complet
- (C) DCC sau Factor GARCH
- (D) BEKK diagonal

Răspuns Întrebarea 10

Răspuns Corect: (C)

☐ DCC sau Factor GARCH

Răspuns Întrebarea 10

Răspuns Corect: (C)

▣ DCC sau Factor GARCH

Justificare

- ▣ VEC: ~ 25.500 parametri — complet nefezabil
- ▣ BEKK complet: ~ 20.000 parametri — nefezabil
- ▣ BEKK diagonal: ~ 5.250 parametri — dificil
- ▣ DCC: $302 + 2 = 304$ parametri (estimați în două etape) — **fezabil**
- ▣ Factor GARCH: K factori ($K \ll N$) — și mai eficient

 TSA_ch5b_model_choice

Adevărat sau Fals?

1. Modelul CCC presupune că corelațiile între active se schimbă în timp.
2. Estimarea DCC în două etape este consistentă dar nu pe deplin eficientă.
3. EWMA multivariat este echivalent cu BEKK Scalar cu $\omega = 0$ și $\alpha + \beta = 1$.
4. Modelul BEKK diagonal captează propagarea volatilității între active.
5. aDCC adaugă doar un parametru suplimentar față de DCC.
6. VaR-ul de portofoliu bazat pe DCC este mereu mai mare decât cel bazat pe CCC.
7. GO-GARCH funcționează prin descompunerea randamentelor în factori necorelați.
8. Corelațiile între acțiuni scad de obicei în perioadele de criză financiară.

Răspunsuri Adevărat/Fals

1. **FALS** — CCC = Constant Conditional Correlation. R este fix.
2. **ADEVĂRAT** — Consistent prin QML. Erori standard via sandwich estimator.
3. **ADEVĂRAT** — $H_t = (1 - \lambda)\epsilon_{t-1}\epsilon'_{t-1} + \lambda H_{t-1}$ cu $\lambda = 0.94$.
4. **FALS** — BEKK diagonal: A, B diagonale, deci **fără spillovers**. Doar BEKK complet captează spillovers.
5. **ADEVĂRAT** — Parametrul g pentru asimetria negativă. Include DCC ($g = 0$) ca caz particular.
6. **FALS** — VaR-ul DCC este mai mare **în crize** (corelații crescute), dar poate fi mai mic în perioade calme (corelații scăzute). Depinde de regim.
7. **ADEVĂRAT** — Folosește o matrice de mixare Z și factori cu GARCH individual.
8. **FALS** — Corelațiile **cresc** în crize (contagiune). Diversificarea eșuează.

Problema 1: VaR de portofoliu — CCC vs DCC

Enunț

Un portofoliu egal ponderat ($w_1 = w_2 = 0.5$) conține două active cu:

- ▣ Volatilități zilnice: $\sigma_{1,t} = 2\%$, $\sigma_{2,t} = 3\%$
- ▣ Corelație CCC: $\rho = 0.4$
- ▣ Corelație DCC (în criză): $\rho_t = 0.8$

Calculați:

- ▣ **(a)** Volatilitatea portofoliului cu CCC
- ▣ **(b)** Volatilitatea portofoliului cu DCC (în criză)
- ▣ **(c)** VaR la 99% (1 zi) pentru 1.000.000 EUR, ambele modele
- ▣ **(d)** Cu cât subestimează CCC riscul în criză?

Soluție Problema 1

Răspunsuri

- ▣ (a) $\sigma_p^2 = 0.25 \times 0.04 + 0.25 \times 0.09 + 2 \times 0.25 \times 0.4 \times 0.02 \times 0.03 = 0.0445\%$
 $\sigma_p = \sqrt{0.000445} = 2.11\%$
- ▣ (b) Cu $\rho_t = 0.8$: $\sigma_p^2 = 0.0325 + 0.012 = 0.000565$
 $\sigma_p = \sqrt{0.000565} = 2.38\%$
- ▣ (c) VaR 99% ($z_{0.01} = 2.326$):
 - ▶ CCC: $2.326 \times 0.0211 \times 1,000,000 = \mathbf{49,069}$ EUR
 - ▶ DCC: $2.326 \times 0.0238 \times 1,000,000 = \mathbf{55,359}$ EUR
- ▣ (d) CCC subestimează VaR cu $(55,359 - 49,069)/49,069 = \mathbf{12.8\%}$ în criză!

Problema 2: Hedging dinamic cu DCC

Enunț

Un fond deține acțiuni și le acoperă cu futures pe indice. La momentul t :

- ▣ $\sigma_{\text{spot},t} = 1.5\%$, $\sigma_{\text{futures},t} = 1.2\%$
- ▣ CCC: $\rho = 0.90$
- ▣ DCC (criză): $\rho_t = 0.97$

Calculați:

- ▣ (a) Raportul de hedging CCC: $h^* = \rho \cdot \sigma_{\text{spot}} / \sigma_{\text{futures}}$
- ▣ (b) Raportul de hedging DCC (criză)
- ▣ (c) Eficacitatea hedging-ului (HE) pentru fiecare model

Soluție Problema 2

Răspunsuri

- ▣ (a) CCC: $h^* = 0.90 \times 1.5/1.2 = \mathbf{1.125}$
- ▣ (b) DCC: $h_t^* = 0.97 \times 1.5/1.2 = \mathbf{1.213}$
- ▣ (c) Eficacitatea: $HE = \rho^2$
 - ▶ CCC: $HE = 0.90^2 = 81.0\%$ din varianță eliminată
 - ▶ DCC: $HE = 0.97^2 = 94.1\%$ din varianță eliminată

CCC sub-acoperă cu $1.213 - 1.125 = 0.088$ unități futures. Expunerea reziduală este semnificativă!

Concluzie

DCC ajustează automat raportul de hedging la condițiile de piață. CCC ratează creșterea corelației în criză.

Problema 3: Selecția modelului

Enunț

Un cercetător estimează modele pentru un portofoliu de 3 active:

Model	Parametri	Log-Lik	AIC	ρ dinamic?
CCC	12	-3,210	6,444	Nu
DCC	14	-3,185	6,398	Da
aDCC	15	-3,180	6,390	Da
BEKK Diagonal	12	-3,200	6,424	Da
BEKK Complet	24	-3,170	6,388	Da

- ☐ (a) Care model are AIC-ul cel mai bun?
- ☐ (b) Puteți testa CCC vs DCC cu un test LR? Calculați statistica.
- ☐ (c) Ce model recomandați și de ce?

Soluție Problema 3

Răspunsuri

- ▣ (a) BEKK complet are cel mai mic AIC (6,388), urmat de aDCC (6,390).
- ▣ (b) Da, CCC este imbricat în DCC ($a = b = 0$):
 $LR = 2 \times (-3,185 - (-3,210)) = 2 \times 25 = 50$
Sub H_0 : $LR \sim \chi^2(2)$. Valoare critică la 1%: 9.21.
 $50 \gg 9.21 \Rightarrow$ **CCC puternic respins!**
- ▣ (c) **aDCC**: AIC aproape de BEKK complet dar cu 9 parametri mai puțini. Pentru $N = 3$, BEKK complet este fezabil, dar aDCC oferă un compromis mai bun între flexibilitate și parsimonie. Dacă spillovers sunt importante $\Rightarrow$ BEKK complet.

Pasul 1: Descărcare date și calcul randamente

```
import pandas as pd
import numpy as np
import yfinance as yf
from arch import arch_model

# Descarcam S&P 500 si DAX
sp500 = yf.download('^GSPC', start='2010-01-01', end='2024-12-31')
dax = yf.download('^GDAXI', start='2010-01-01', end='2024-12-31')

# Randamente procentuale
r_sp = (sp500['Close'].pct_change() * 100).dropna()
r_dax = (dax['Close'].pct_change() * 100).dropna()

# Aliniam datele pe zile comune
returns = pd.concat([r_sp, r_dax], axis=1, join='inner')
returns.columns = ['SP500', 'DAX']
print(f'Observatii: {len(returns)}')
```

Pasul 2: Corelații mobile și estimare DCC

```
# Corelatii pe fereastră mobilă de 60 zile
rolling_corr = returns['SP500'].rolling(60).corr(returns['DAX'])

# Etapa 1: GARCH univariat pentru fiecare serie
res_sp = arch_model(returns['SP500'], vol='Garch', p=1, q=1,
                    dist='t').fit(disp='off')
res_dax = arch_model(returns['DAX'], vol='Garch', p=1, q=1,
                    dist='t').fit(disp='off')

# Reziduuri standardizate
z_sp = res_sp.std_resid
z_dax = res_dax.std_resid

# Etapa 2: DCC manual (forma scalară)
z = np.column_stack([z_sp, z_dax])
Qbar = np.corrcoef(z_sp, z_dax) # Q neconditional
```

Pasul 3: Corelații dinamice DCC

```
from scipy.optimize import minimize
def dcc_loglik(params, z, Qbar):
    a, b = params
    T, N = z.shape
    Qt, ll, rho_t = Qbar.copy(), 0, np.zeros(T)
    for t in range(1, T):
        Qt = (1-a-b)*Qbar + a*np.outer(z[t-1], z[t-1]) + b*Qt
        Rt = Qt / np.sqrt(np.outer(np.diag(Qt), np.diag(Qt)))
        rho_t[t] = Rt[0, 1]
        ll += np.log(np.linalg.det(Rt)) + z[t]@np.linalg.inv(Rt)@z[t] - z[t]
            @z[t]
    return 0.5 * ll, rho_t
res = minimize(lambda p: dcc_loglik(p, z, Qbar)[0],
               x0=[0.02, 0.95], bounds=[(0,0.3),(0,0.999)],
               constraints={'type':'ineq','fun': lambda p: 0.999-p[0]-p[1]})
a_hat, b_hat = res.x
_, rho_dcc = dcc_loglik([a_hat, b_hat], z, Qbar)
```

Pasul 4: VaR portofoliu și vizualizare

```
import matplotlib.pyplot as plt
COLORS = {'blue': '#1A3A6E', 'red': '#DC3545', 'green': '#2E7D32'}
# VaR portofoliu cu DCC
w = np.array([0.5, 0.5])
sigma_sp = res_sp.conditional_volatility / 100
sigma_dax = res_dax.conditional_volatility / 100
port_vol = np.sqrt(w[0]**2*sigma_sp**2 + w[1]**2*sigma_dax**2
                  + 2*w[0]*w[1]*rho_dcc*sigma_sp*sigma_dax)
VaR_99 = 2.326 * port_vol * 1_000_000
# Grafic
fig, ax = plt.subplots(figsize=(14, 5))
ax.plot(returns.index, rho_dcc, color=COLORS['blue'], lw=0.8)
ax.plot(returns.index, rolling_corr, color=COLORS['red'], lw=0.8, alpha=0.5)
ax.set_title('DCC vs Corelatii mobile: S&P 500 - DAX')
ax.legend(['DCC', 'Mobile 60 zile'],
         loc='upper center', bbox_to_anchor=(0.5, -0.12), ncol=2)
plt.tight_layout(); plt.show()
```

Exercițiu AI: gândire critică

Prompt de testat în ChatGPT / Claude / Copilot

“Folosind yfinance, descarcă prețurile zilnice de închidere ale S&P 500 (^GSPC) și FTSE 100 (^FTSE) din 2015-01-01 până în 2024-12-31. Calculează randamentele logaritmice. Estimează un model DCC-GARCH(1,1) în două etape: (1) GARCH(1,1) cu Student-t pentru fiecare serie, (2) parametrii DCC (a , b) pe reziduurile standardizate. Vizualizează corelațiile dinamice în timp. Calculează VaR de portofoliu egal ponderat la 99%. Compară cu VaR-ul CCC. Vreau cod Python complet cu grafice.”

Exercițiu de evaluare critică:

1. Rulați prompt-ul și analizați critic codul generat.
2. Verifică dacă DCC este estimat corect în **două etape** sau face MLE simultan?
3. Rescalează Q_t corect la R_t ? (diagonal $\neq 1$ înainte de rescalare)
4. Verifică restricția $a + b < 1$? Raportează erorile standard?
5. VaR-ul folosește volatilitatea de portofoliu $\sigma_{p,t} = \sqrt{w'H_t w}$, nu suma volatilităților?

Atenție: Codul generat de AI poate produce grafice frumoase dar R_t *incorrect* (ex: fără rescalare).

Rezumat Seminar

Concepte cheie

- ▣ **BEKK**: pozitiv-definire automată, spillovers, dar $\max N \leq 5$
- ▣ **CCC**: $H_t = D_t R D_t$, ρ constant — benchmark
- ▣ **DCC**: ρ_t dinamic, doar 2 parametri suplimentari — standard industrial
- ▣ **aDCC**: adaugă asimetria corelațiilor (levier)

Formule importante

$$\sigma_{p,t}^2 = w' H_t w; \quad h_t^* = h_{12,t} / h_{22,t}; \quad \text{VaR}_\alpha = z_\alpha \cdot \sigma_{p,t} \cdot V$$

Sfat: Începeți cu DCC-GARCH(1,1), testați CCC vs DCC cu Engle–Sheppard!

Exerciții pentru acasă

Exerciții

1. Descărcați randamentele BET și DAX. Estimați DCC-GARCH(1,1). Vizualizați ρ_t . Când este maximă corelația?
2. Calculați VaR zilnic de portofoliu (50/50) cu DCC și CCC. Comparați backtesting-ul.
3. Pentru Bitcoin și Ethereum, estimați DCC. Este corelația mai volatilă decât între indici bursieri?
4. Calculați raportul de hedging dinamic pentru acțiuni BET acoperite cu futures pe indice. Comparați CCC vs DCC.
5. Estimați BEKK diagonal bivariat pentru S&P 500 și EUR/USD. Există spillovers semnificative?

 TSA_ch5b_homework

Exercițiu de replicare: Engle (2002)

Obiectiv

Replicați Tabelul 1 din Engle (2002) — estimarea DCC pe indici bursieri.

1. Descărcați randamentele zilnice S&P 500 și DJIA (2000–2024)
2. Estimați GARCH(1,1) univariat pentru fiecare serie (Student-t)
3. Calculați reziduurile standardizate $\hat{z}_t$
4. Estimați parametrii DCC (a, b) prin maximizarea $\mathcal{L}_2$
5. Vizualizați corelația dinamică ρ_t și marcați perioadele de criză
6. **Întrebare:** corelația S&P 500–DJIA este mai stabilă decât S&P 500–DAX? De ce?

Ref: Engle, R.F. (2002). Dynamic Conditional Correlation: A Simple Class of Multivariate GARCH Models, *JBES*, 20(3), 339–350.

 TSA_ch5b_engle2002

Bibliografie I

Modele GARCH multivariate

- Engle, R.F. (2002). Dynamic Conditional Correlation. *JBES*, 20(3), 339–350.
- Bollerslev, T. (1990). Modelling the Coherence in Short-Run Nominal Exchange Rates. *REStat*, 72(3), 498–505.
- Engle, R.F. & Kroner, K.F. (1995). Multivariate Simultaneous Generalized ARCH. *Econometric Theory*, 11(1), 122–150.
- Cappiello, L., Engle, R.F. & Sheppard, K. (2006). Asymmetric Dynamics in Correlations. *JFE*, 4(4), 537–572.

Serii de timp financiare

- Bauwens, L., Laurent, S. & Rombouts, J.V.K. (2006). Multivariate GARCH Models: A Survey. *JAE*, 21(1), 79–109.
- Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed., Wiley.
- Franke, J., Härdle, W.K. & Hafner, C.M. (2019). *Statistics of Financial Markets*, 4th ed., Springer.

Vă mulțumesc!

Întrebări?

Materialele seminarului sunt disponibile la:

<https://danpele.github.io/Time-Series-Analysis/>

 Quantlet

 Quantinar